

CCFormer: 面向腾讯工业推荐的高效跨字段交互与分层序列压缩

Yunlong Wang*
aloyswang@tencent.com
腾讯平台与内容事业群

Huizhe Zhang*
huizhezhang@tencent.com
腾讯平台与内容事业群

Haonan Hu*
haonanhu@tencent.com
腾讯平台与内容事业群

Yudong Li†
elsonli@tencent.com
腾讯平台与内容事业群

Bing Wen
腾讯平台与内容事业群

Jianchao Tu
腾讯平台与内容事业群

Chengxiang Zhuo
腾讯平台与内容事业群

Zang Li
腾讯平台与内容事业群

摘要

近期对工业推荐系统的研究表明, 基于自注意力构建的序列推荐模型可以通过增加序列长度和模型容量受益于可预测的缩放定律。然而, 实际推荐系统对延迟和资源有严格约束, 因此难以在计算开销与细粒度特征交互之间取得平衡。本文提出 **CCFormer**, 一种面向工业推荐的高效 Transformer 主干网络, 统一了跨字段特征交互与压缩式长序列建模。具体而言, CCFormer 将特征字段分离的交叉注意力与长序列子空间 token 混合相结合, 以利用异构特征域中的长期偏好信号。通过逐步扩大感受野的分层序列压缩策略, 可以在减少信息损失的同时实现高效的长序列建模。在两个公开基准和一个大规模工业数据集上的大量实验表明, CCFormer 始终优于最先进的基线。在腾讯的视频推荐场景和广告排序场景中开展的在线 A/B 测试进一步验证了其工业实用性, 分别实现了 3.57% 的 CTR 提升和 1.71% 的广告收入提升, 同时相较于强基线 HSTU 将模型训练加速了 2.21 $\times$ 。CCFormer 已全面部署于腾讯的生产推荐系统中, 承载两个场景的主要流量。

CCS 概念

• 信息系统 → 推荐系统。

关键词

推荐系统, 扩展定律, 长序列建模

ACM 参考文献格式:

Yunlong Wang, Huizhe Zhang, Haonan Hu, Yudong Li, Bing Wen, Jianchao Tu, Chengxiang Zhuo, and Zang Li. 2027. CCFormer: 面向腾讯工业推荐的高效跨字段交互与分层序列压缩. In *Proceedings of 第 33 届 ACM SIGKDD 知识发现与数据挖掘会议 (KDD '27)*.

*同等贡献。

†通讯作者。

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.

KDD '27, 美国加利福尼亚州圣何塞

© 2027 Copyright held by the owner/author(s). Publication rights licensed to ACM.

ACM ISBN 978-1-4503-XXXX-X/2027/08

<https://doi.org/XXXXXXX.XXXXXXX>




图 1: 架构对比。

ACM, New York, NY, USA, 8 pages. <https://doi.org/XXXXXXX.XXXXXXX>

1 引言

序列推荐模型 (SRs) 能够自然地捕捉长期序列行为, 已广泛应用于在线广告、电子商务、信息流和短视频平台等多种工业场景 [35, 41]。传统的基于协同过滤或基于内容的推荐模型主要关注用户与物品之间的浅层交互。SRs 旨在通过对历史交互序列进行建模, 推断用户不断演变的偏好并预测其未来响应。近期研究日益转向长序列建模, 利用更丰富的历史行为来捕捉更全面、多样且动态的用户兴趣 [18, 20, 28]。

得益于对用户行为序列强大的表达能力, 基于 Transformer 的模型已成为主流架构 [2, 8, 29]。这类建立在自注意力之上的模型能够自适应地识别信息丰富的历史交互, 并捕获过去行为与目标物品之间的高阶交互。此外, 近期研究表明, 推荐模型同样可以从规模扩展中获益, 包括增大模型规模、延长序列长度以及分配更多计算预算 [38, 40]。这种规模扩展趋势使得更充分地利用用户长期历史成为可能, 从而提升序列用户表征的表达能力。然而, 基于 Transformer 的序列模型难以部署到实际推荐系统中。自注意力机制相对于序列长度具有二次方的计算和内存复杂度, 在建模长用户行为序列时成本高得难以承受 [11]。这一挑战在工业排序场景中尤为严峻, 因为模型必须在严格的时延和资源约束下处理海量流量。因此, 直接延长输入序列或增加模型容量通常会带来不可接受的训练和推理成本, 使基于 Transformer 的序列模型难以在实际系统中扩展。

为缓解长序列建模的效率瓶颈, 现有长序列推荐方法通常采用两种代表性范式: 压缩序列表征或序列截断 [19, 23, 34]。如图 1 所示, 一些传统方法在特征交互之前将长行为序列压缩为紧凑的序列表征。尽管这种序列压缩降低了计算成本, 但它可能丢失细粒度行为信号, 并削弱后续历史行为与目标物品之间的交互。近年来, 一些新兴方法检索或截取与目标相关的子序列, 并在有限窗口内保留 token 级建模 [3, 25], 或采用稀疏注意力以降低长序列建模的成本 [31, 37]。然而, 序列截断不可

避免地会舍弃可能有用的长期兴趣,而在保留序列内执行完整自注意力仍会引入不可忽略的计算开销。因此,一个关键挑战仍未得到充分探索:如何在工业推荐的长用户行为序列中实现充分且高效的特征交互。序列级特征交叉不足可能削弱模型发现细粒度偏好模式的能力,而穷尽式自注意力对于长序列而言成本过高 [6, 22]。这促使我们需要一种新的建模框架,既能保留丰富的序列特征交互,又能维持实用的效率。

为应对这些挑战,我们提出 **CCFormer**,这是一种面向长序列推荐、统一深层跨字段特征交互与序列压缩的高效 Transformer。具体而言,CCFormer 引入字段分离的交叉注意力,实现序列特征与跨域特征的交互。它使来自不同域(例如 User Profile、Item Feature)的 token 能够与整个行为序列显式交互,并从丰富的历史上下文中捕获长期偏好信号。此外,CCFormer 引入长序列子空间 token 混合模块,以从长行为历史中有效捕获与目标相关的偏好信号。最后,分层序列压缩策略通过扩展感受野保留对完整序列的访问,从而在大幅降低长序列建模计算成本的同时缓解信息损失。我们的贡献总结如下:

- 我们为长序列推荐提出了一种新的交互范式:字段分离的交叉注意力实现异构域 token 之间的高效早期融合,而子空间级相对时序位置编码则将具备近因感知能力的顺序信息注入行为序列。
- 据我们所知,这是首次尝试在工业排序模型中将 token 混合从统一特征 token 扩展到全长用户行为序列,并结合专门设计的分层序列压缩。该范式在保留丰富长序列信息的同时大幅降低计算开销,实现最高 $2.21\times$ 倍的训练加速。
- 我们在公共基准和工业数据集上针对先进工业基线开展了全面实验。规模定律分析以及在两个真实腾讯推荐场景中的在线 A/B 测试证明了 CCFormer 的有效性、可扩展性和实用性。

2 相关工作

传统深度学习推荐模型。传统深度学习推荐模型(DLRMs) [38] 致力于从高维稀疏类别特征和稠密数值特征中学习有效表示 [5, 10]。一种常见范式是将稀疏特征投影到低维嵌入空间,再将其与稠密特征结合以进行预测。这些模型设计了不同的特征交互机制,以提升推荐模型的表达能力。例如, Wide & Deep [7] 联合记忆低阶特征共现模式,并通过深度神经网络实现泛化。DeepFM [13] 将因子分解机与深度网络相结合,以捕获低阶和高阶特征交互。然而,传统 DLRMs 通常将用户历史行为视为聚合特征或短程特征,而非显式建模长期序列依赖。仅依赖静态特征交叉或池化后的行为表示,可能会忽略重要的序列信号。

基于 *Token Mixing* 的推荐模型。新兴方法不再依赖异构的手工特征交叉模块,而是构建序列化的统一特征,以利用具有大规模、非平稳词表的工业级推荐系统中的缩放定律 [38]。受 Vision Transformer 的 MLP 驱动替代方案 [30] 启发,近期一系列工作使用轻量级 token mixing 算子取代二次复杂度的自注意力。这些方法通过跨 token 混合子空间向量来交换 token 之间的信息,从而实现全局特征交互 [4, 14, 16]。例如, RankMixer [42] 将多头 token mixing 模块与逐 token 的前馈网络(FFNs)相结合,以高效建模异构特征子空间。TokenMixer-Large [17] 进一步通过 mixing-and-reverting 操作重新设计残差路径,改进了这一范式。然而,现有基于 token mixing 的推荐模型主要面向统一特征 token 设计,而非完整长度的用户

行为序列。不同于这些方法,我们的工作旨在将 token mixing 范式直接应用于完整行为序列,以进行长序列建模。

基于注意力的推荐模型。早期序列模型倾向于采用循环神经网络、卷积网络或注意力机制来编码历史行为 [18, 26, 33]。这些方法显著提升了用户行为建模的表达能力,并已在检索和排序场景中得到广泛探索。近期研究进一步将基于注意力的架构扩展到工业级推荐,通过可扩展框架联合建模行为序列、物品特征和用户画像 [12, 15, 19, 40]。这些工作表明,扩大序列长度、模型容量和特征交互模块的规模能够持续提升推荐性能,尤其是在用户兴趣分布于多样化历史行为和特征字段中时 [9, 21]。标准自注意力在实际推荐系统中会引入二次增长的计算与内存开销。此外,许多高效注意力变体主要关注降低序列建模开销,因此在捕获跨域特征交互方面效果较弱。因此,如何实现高效且充分的跨域特征交互,仍是基于注意力模型的一项关键挑战。

3 方法

本节详细介绍所提出 CCFormer 的架构。如图 2 所示,CCFormer 采用解耦式架构范式。它将输入特征空间显式划分为三个不同的语义字段:用户画像、历史行为序列和目标物品。现有基于 Transformer 的模型存在一个根本局限:对所有拼接后的 token 应用全局自注意力会产生难以承受的二次计算复杂度。为克服这一瓶颈,CCFormer 将特征交互过程解耦为两个正交组成部分:跨字段交互和序列内 token 交互。该设计使模型能够从大规模行为历史中有效提炼目标感知的用户兴趣,同时避免在完整 token 集上进行穷尽式自注意力所带来的二次开销。

形式化地,令 $\mathbf{U}^{(0)} \in \mathbb{R}^{B \times L_u \times d}$ 、 $\mathbf{S}^{(0)} \in \mathbb{R}^{B \times L_s \times d}$ 和 $\mathbf{T}^{(0)} \in \mathbb{R}^{B \times L_t \times d}$ 分别表示用户、行为序列和目标物品字段的初始 token 化表示。其中, B 表示批大小, d 表示隐藏维度, L_u 、 L_s 和 L_t 分别表示对应字段中的 token 数量。具体而言,异构的用户侧特征被投影为一组紧凑的用户 token,而每个历史行为和物品侧特征则被嵌入为细粒度的物品级 token。

CCFormer 的核心由 L 个堆叠的交互块组成。每个交互块通过上述解耦交互,对三个字段的表示进行迭代式优化:

$$(\mathbf{U}^{(\ell+1)}, \mathbf{S}^{(\ell+1)}, \mathbf{T}^{(\ell+1)}) = \text{CCFormerBlock}_\ell(\mathbf{U}^{(\ell)}, \mathbf{S}^{(\ell)}, \mathbf{T}^{(\ell)}), \quad (1)$$

经过 L 层深度特征提取后,来自三个字段的最终归一化表示被聚合,并输入任务特定的预测头以进行多任务学习。

3.1 特征字段分离的交叉注意力

CTR 预测涉及异构特征交互,例如用户到历史的偏好检索、目标到历史的相关性匹配,以及目标到用户的兼容性建模。在所有 token 上应用标准自注意力会统一处理不同特征字段,这不仅会产生不必要的计算,还可能削弱其语义角色。为解决这一问题,CCFormer 采用特征字段分离的交叉注意力模块,通过三条有向注意力流对这些交互进行建模。

在跨字段交互之前,我们首先对用户字段和目标字段应用轻量级逐 token 前馈网络:

$$\tilde{\mathbf{U}}^{(\ell)} = \text{SwiGLUFFN}_u^\ell(\mathbf{U}^{(\ell)}), \quad \tilde{\mathbf{T}}^{(\ell)} = \text{SwiGLUFFN}_t^\ell(\mathbf{T}^{(\ell)}). \quad (2)$$

用户字段生成查询、键和值,而行为序列仅提供键和值,因为它被用作待检索的上下文:

$$(\mathbf{Q}_u, \mathbf{K}_u, \mathbf{V}_u) = \text{RMSNorm}(\tilde{\mathbf{U}}^{(\ell)}) \mathbf{W}_u^{QKV} \quad (3)$$




图 2: CCFormer 概览。

$$(\mathbf{K}_s, \mathbf{V}_s) = \text{RMSNorm}(\mathbf{S}^{(\ell)}) \mathbf{W}_s^{KV}. \quad (4)$$

其中, $\mathbf{W}_u^{QKV} \in \mathbb{R}^{d \times 3d}$ 和 $\mathbf{W}_s^{KV} \in \mathbb{R}^{d \times 2d}$ 。我们应用 RM-SNorm [39] 来对齐各特征字段的尺度。

目标字段使用两个查询投影, 分别关注行为字段和用户字段:

$$\mathbf{Q}_{t \rightarrow s} = \bar{\mathbf{T}}^{(\ell)} \mathbf{W}_{t \rightarrow s}^Q, \quad \mathbf{Q}_{t \rightarrow u} = \bar{\mathbf{T}}^{(\ell)} \mathbf{W}_{t \rightarrow u}^Q. \quad (5)$$

随后, 有向交叉注意力计算为

$$\begin{aligned} \mathbf{O}_{u \rightarrow s} &= \text{Attn}(\mathbf{Q}_u, \mathbf{K}_s, \mathbf{V}_s; \mathbf{M}), \\ \mathbf{O}_{t \rightarrow s} &= \text{Attn}(\mathbf{Q}_{t \rightarrow s}, \mathbf{K}_s, \mathbf{V}_s; \mathbf{M}), \\ \mathbf{O}_{t \rightarrow u} &= \text{Attn}(\mathbf{Q}_{t \rightarrow u}, \mathbf{K}_u, \mathbf{V}_u), \end{aligned} \quad (6)$$

其中

$$\text{Attn}(\mathbf{Q}, \mathbf{K}, \mathbf{V}; \mathbf{M}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}} + \mathbf{M}\right) \mathbf{V}. \quad (7)$$

对于每个注意力头, 令 $d_k = d/h$ 表示头维度。当注意力在无掩码情况下应用时, 省略掩码 $\mathbf{M}$; 在与序列相关的注意力中, 则使用该掩码屏蔽填充的行为位置。

最后, 用户字段和目标字段更新为

$$\Delta \mathbf{U}^{(\ell)} = \mathbf{O}_{u \rightarrow s} \mathbf{W}_u^O, \quad \Delta \mathbf{T}^{(\ell)} = [\mathbf{O}_{t \rightarrow s}; \mathbf{O}_{t \rightarrow u}] \mathbf{W}_t^O. \quad (8)$$

通过这种方式, 用户字段选择性地检索历史行为, 而目标字段则联合捕获目标—历史相关性和目标—用户兼容性。

3.2 Token 子空间中的相对时间—位置编码

用户行为序列中的时间和位置线索对于捕获不断演化的偏好至关重要。近期研究 [19, 36, 38] 表明, 联合时间—位置建模能够显著提升推荐准确率。传统自注意力的 $O(L_s^2)$ 复杂度会引入难以承受的延迟, 阻碍现实世界中的长时域推荐。为了高效编码时间—位置信息, 我们在局部行为子空间中应用相对时间—位置编码, 将计算复杂度降低至 $O(L_s m)$ 。

给定序列表示 $\mathbf{S} \in \mathbb{R}^{B \times L_s \times d}$, 我们将 $\mathbf{S}$ 沿序列维度 L_s 划分为大小为 m 的组, 其中每组包含 m 个行为。对于第 i 个和

第 j 个行为 (它们位于第 p 个序列组中), 相对时间—位置编码定义如下:

$$\mathbf{W}_{p,i,j}^{\text{time}} = \alpha \cdot \beta^{|t_{p,i} - t_{p,j}|^\gamma}, \quad (9)$$

其中, α 和 γ 是正的可学习参数, $\beta \in (0, 1)$ 是时间衰减参数, $t_{p,i}$ 是第 i 个行为在第 p 组中的时间戳。我们构建相对时间编码矩阵 $\mathbf{W}_p^{\text{time}} \in \mathbb{R}^{m \times m}$, 用于第 p 组。由于 $\beta \in (0, 1)$, 权重 $\mathbf{W}_{p,i,j}^{\text{time}}$ 会随时间间隔 $|t_{p,i} - t_{p,j}|$ 增大而单调递减, 从而为时间上相近的行为赋予更大权重。

除时间信息外, 我们还引入可学习的相对位置偏置 $\mathbf{W}^{\text{pos_origin}} \in \mathbb{R}^{2m-1}$, 以捕获每个序列组内不同行为之间的位置关系。给定第 i 个和第 j 个行为 (它们位于第 p 个序列组中), 相对位置编码计算为:

$$\mathbf{W}_{p,i,j}^{\text{pos}} = \mathbf{W}^{\text{pos_origin}}[i - j + m - 1]. \quad (10)$$

我们构建相对位置矩阵 $\mathbf{W}_p^{\text{pos}} \in \mathbb{R}^{m \times m}$, 用于第 p 组。最后, 我们将时间—位置信息融入序列 $\mathbf{S}$:

$$\begin{aligned} \mathbf{S}^{t,p} &= \text{Concat}(\mathbf{S}_1^{t,p}, \mathbf{S}_2^{t,p}, \dots, \mathbf{S}_{L_s/m}^{t,p}), \\ \mathbf{S}_p^{t,p} &= (\mathbf{W}_p^{\text{time}} + \mathbf{W}_p^{\text{pos}}) \mathbf{S}[(p-1) \cdot m : p \cdot m]. \end{aligned} \quad (11)$$

3.3 长序列子空间 Token Mixing

在跨字段交互之后, 捕获历史行为之间的序列内依赖至关重要。然而, 标准自注意力机制面临二次计算瓶颈 $O(L_s^2)$, 该瓶颈随序列长度 L_s 增长。为规避这一限制, CCFormer 引入子空间 Token Mixing 模块。我们不计算稠密的成对注意力, 而是将行为序列划分为紧凑的 token 子空间, 并通过逐通道前馈网络 (PFN) 进行处理。形式化地, 首先将输入序列表示 $\mathbf{S} \in \mathbb{R}^{B \times L_s \times d}$ 重塑为子空间张量:

$$\mathbf{X} = \text{Reshape}(\mathbf{S}) \in \mathbb{R}^{B \times \frac{L_s}{m} \times \frac{d}{n} \times mn}, \quad (12)$$

在该形式中, 每个子空间向量 $\mathbf{X}_{b,p,c} \in \mathbb{R}^{mn}$ 联合封装 m 个相邻行为 token 和 n 个隐藏维度。这种结构重组至关重要: 它迫使细粒度 token 级和通道级信号在局部紧凑表示中直接交互。

随后, 我们对每个通道组独立应用 PFFN, 以提取子空间特定的模式。PFFN 被实例化为门控前馈架构, 以增强非线性表达能力:

$$\text{PFFN}_c(\mathbf{x}) = \mathbf{W}_c^o (\phi(\mathbf{x}\mathbf{W}_c^g) \odot (\mathbf{x}\mathbf{W}_c^v)), \quad (13)$$

其中, $\phi(\cdot)$ 表示平滑非线性激活函数, $\odot$ 表示逐元素乘法, $\mathbf{W}_c^g$, $\mathbf{W}_c^v$ 和 $\mathbf{W}_c^o$ 是第 c 个通道组特有的可学习权重矩阵。对于每个子空间, 变换计算为:

$$\mathbf{Z}_{b,p,c} = \text{PFFN}_c(\mathbf{X}_{b,p,c}). \quad (14)$$

通过在不同通道组间使用独立参数, 模型可以并行捕获多样且异构的行为模式。输出张量 $\mathbf{Z}$ 保持 $\mathbf{X}$ 的子空间拓扑, 随后被恢复为原始序列布局:

$$\hat{\mathbf{S}} = \text{Restore}(\mathbf{Z}) \in \mathbb{R}^{B \times L_s \times d}. \quad (15)$$

总体而言, 这种基于子空间的混合机制在表达能力与计算效率之间取得了良好平衡。通过在局部子空间内显式混合多个行为 token 和隐藏维度, 它能够有效捕获序列内依赖。




图 3: 随着模型层数增加, 序列 token 感受野的变化。

3.4 分层长序列 Token 压缩

尽管子空间 token 混合缓解了序列内部交互的成本, 但当序列长度 L_s 极大时, 处理完整行为序列在计算上仍然难以承受。此外, 长用户历史天然具有冗余性和局部相关性。为解决这一瓶颈, 我们引入分层 Token 压缩模块, 在更深的层中逐步压缩序列表征。形式化地, 在第 ℓ 个块中更新序列后, 我们沿序列维度应用一维卷积下采样算子:

$$\mathbf{S}^{(\ell+1)} = \text{Conv1D}_{k,s} \hat{\mathbf{S}}^{(\ell)} \quad (16)$$

其中, $\hat{\mathbf{S}}^{(\ell)}$ 表示第 ℓ 个 CCFormer 块经子空间 token 混合后的输出, $\mathbf{S}^{(\ell+1)}$ 则作为下一个块的输入序列表征。 k 和 s 分别表示卷积核大小和步幅。该操作通过融合相邻行为 token 聚合局部上下文, 为后续层生成缩短后的序列。

该压缩机制与子空间 token 混合模块天然互补。子空间 token 混合捕获每一层内的局部交互, 而卷积压缩则跨层合并局部信息。在图 3 中, 随着网络深度增加, 每个压缩 token 在原始行为序列上的感受野逐步扩大。这实现了多粒度用户兴趣建模: 浅层捕获短期、细粒度的行为模式, 而深层提取抽象的长期偏好信号。至关重要, 序列长度的逐步缩减显著降低了计算复杂度, 确保 CCFormer 能够扩展到超长用户序列建模。

3.5 训练与部署优化

CCFormer 构建于 Numerous-Torch 之上, 后者是我们面向大规模推荐模型的生产级训练与推理基础设施。Numerous-Torch 的作用是衔接灵活的模型创新与工业规模的推荐部署。在建模侧, 它保留了 PyTorch 原生的开发体验, 使研究人员能够高

效复用快速演进的 LLM 社区中的新进展。在系统侧, 它提供生产推荐工作负载所需的基础设施, 包括分布式数据摄取、大规模稀疏特征处理、稀疏-稠密联合训练、检查点恢复、模型导出, 以及基于最新用户反馈日志的持续训练。下面, 我们介绍在工业生产场景中采用的若干关键优化。

混合精度训练。我们对主模型计算采用混合精度训练 (BF16 或 FP16)。实践中, 该策略将内存开销降低了 35% 以上, 从而能够在相同训练预算下使用更大的批次或更多的模型参数。

稀疏参数压缩。对于大规模推荐模型, 稀疏的用户和物品 ID 特征占据了稀疏模型参数的大部分。我们使用 INT8 对称线性量化存储这些 ID 特征的嵌入表参数, 与全精度存储相比实现了约 70% 的压缩。此外, 我们采用双哈希策略 [27] 来缩减 ID 特征嵌入表的大小, 进一步将稀疏参数规模降低约 50%。通过结合这两项技术, 我们在不降低训练效果的情况下, 大幅减少了模型训练期间的内存占用和通信成本。

候选物品并行预测。在 CCFormer 块中, 目标 token 仅用作 query, 彼此之间从不进行注意力交互。该设计避免了跨目标信息泄漏, 并允许并行评分同一用户请求中的多个候选物品。在线服务期间, 一个请求中的所有候选目标都被打包进目标字段, 并且只进行一次前向传播。由于用户字段和序列字段的建模可在候选项之间共享, CCFormer 能够在单次前向传播中为所有目标生成多任务分数, 避免重复计算用户序列并提高服务吞吐量。与 DLRM 基线逐候选项的逐点推理相比, 尽管 CCFormer 的计算复杂度高出 20 $\times$, 这一并行预测方案仍使其在相同推理资源下将在线峰值 QPS 提高了 30%。

表 1: 数据集统计信息。

数据集	# 用户数	# 物品数	# 样本数
Taobao	987,994	4,162,024	100,150,807
KuaiRec	7,176	10,728	12,530,806
Industry	>30M	>10M	>4B

4 实验

数据集。我们在两个基准 (Taobao¹ 和 KuaiRec²) 及一个内部工业数据集上开展对比实验。数据集统计信息列于表 1。我们将用户点击过的物品作为行为序列, 并预测用户是否会点击目标物品 [24]。KuaiRec 是一个短视频推荐数据集, 提供了丰富的用户-物品交互记录。我们使用其提供的大矩阵数据, 并将观看比例大于或等于 2 的交互视为正样本。除非另有说明, 对于两个公开数据集, 行为序列均截断至长度 200。工业数据集采集自腾讯推荐系统的在线日志和真实用户反馈。该数据集包含一个月的生产数据, 由超过 40 亿个样本、3000 多万名用户和 1000 万项推荐内容组成。对于该工业数据集, 用户行为序列长度设为 1000。

基线。对于公开数据集, 我们将 CCFormer 与传统 DLRM 范式下的四个代表性基线 (DIN [41]、DeepFM [13]、SASRec [18] 和 MIMN [24]) 以及三个基于注意力的序列推荐模型 (HSTU [38]、OneTrans [40] 和 STCA [12]) 进行比较。每项实验重复 5 次, 并报告 AUC 及相应的相对提升。在工业数据集上, 我们进一步使用 AUC 和 Group AUC (GAUC) 作为评估指标, 将 CCFormer 与面向生产的强基线 (HSTU、OneTrans

¹<https://tianchi.aliyun.com/dataset/649>

²<https://kuaiREC.com/>

表 2: 公开数据集上的性能对比。以 DIN 模型作为计算 ΔAUC 的基础模型。

数据集	指标	DIN	DeepFM	SASRec	MIMN	HSTU	OneTrans	STCA	CCFormer
Taobao	AUC (%)	88.33 $\pm$ 0.22	89.06 $\pm$ 0.42	88.52 $\pm$ 0.65	91.79 $\pm$ 0.32	91.40 $\pm$ 0.25	91.35 $\pm$ 0.61	92.81$\pm$0.50	93.67$\pm$0.32
	ΔAUC (%)	0.00	1.90	0.50	9.03	8.01	7.88	11.69	13.93
KuaiRec	AUC (%)	80.22 $\pm$ 0.58	80.14 $\pm$ 0.51	79.83 $\pm$ 0.70	81.79 $\pm$ 0.81	82.62 $\pm$ 0.39	82.76$\pm$0.59	82.18 $\pm$ 0.16	83.35$\pm$0.29
	ΔAUC (%)	0.00	-0.26	-1.29	5.20	7.94	8.41	6.49	10.36

表 3: 工业数据集上的性能对比。以 HSTU 基线作为计算 ΔAUC 和 $\Delta GAUC$ 的基础模型。

模型	AUC (%)	ΔAUC (%)	GAUC (%)	$\Delta GAUC$ (%)
HSTU	77.66	0.00	70.86	0.00
OneTrans	77.69	0.11	70.90	0.19
STCA	77.73	0.25	70.95	0.43
CCFormer	77.94	1.01	71.36	2.40




图 4: 在 KuaiRec 上, 四种序列推荐模型随序列长度增加的 AUC 对比。

和 STCA) 进行比较。遵循 [32], ΔAUC 和 $\Delta GAUC$ 分别表示 AUC 和 GAUC 的相对提升。相对提升的计算方式为 $RelaImpr = \left(\frac{\text{Metric}(\text{measured model}) - 0.5}{\text{Metric}(\text{base model}) - 0.5} - 1 \right) \times 100\%$ 。我们采用基于树结构 Parzen 估计器 (TPE) 的超参数搜索 [1], 为每种方法选择最优配置。

实现细节。 除非另有说明, 在所有工业实验中, 我们将特征 token 维度设为 $d = 256$, 并堆叠 8 个 CCFormer 块。子空间组大小和通道组大小分别设为 $m = 8$ 和 $n = 16$ 。卷积压缩模块的卷积核大小为 $k = 3$, 步幅为 $s = 2$ 。所有模型均使用 Adam 优化, 学习率为 1×10^{-4} , 批大小为 4096。为确保公平比较, 所有实验均在由 16 块 NVIDIA H20 GPU 组成的集群上, 使用相同的硬件和软件配置进行。

4.1 总体性能

我们在两个公共基准和一个大规模工业数据集上评估 CCFormer, 结果见表 2 和表 3。结果表明, **CCFormer 在公共数据集和工业数据集上均始终取得最佳性能**。在 Taobao 和 KuaiRec 上, CCFormer 分别取得 93.67% 和 83.35% 的最佳 AUC。与各数据集上最强的序列基线 (Taobao 上的 STCA 和 KuaiRec 上的 OneTrans) 相比, 分别提升了 0.86 和 0.59 个百分点。我们进一步比较了四种先进序列推荐模型在不同序列长度 (200、




图 5: 序列长度的规模定律。我们改变序列长度 (500、1000、2000), 以 AUC 和 GAUC 评估性能。

500 和 1000) 下的表现, 如图 4 所示。在所有序列长度设置下, CCFormer 均持续优于 HSTU、OneTrans 和 STCA, 展现出其在用户行为序列建模中的稳定优势。CCFormer 的优势也在工业数据集上得到验证。与 HSTU 相比, CCFormer 的 AUC 提高 0.28 个点, GAUC 提高 0.50 个点, 对应 1.01% 和 2.40% 的相对提升。与最强基线 STCA 相比, CCFormer 进一步获得 0.21 个 AUC 点和 0.41 个 GAUC 点的提升。这些改进表明, CCFormer 能够有效建模用户、目标物品和行为序列之间的跨字段交互, 同时捕获细粒度的序列内部 token 交互。其在公共基准和工业数据集上的一致增益进一步表明, CCFormer 是可扩展长序列 CTR 预测的一种有效且实用的解决方案。

4.2 CCFormer 的规模扩展分析

在本节中, 我们研究 CCFormer 是否呈现可预测的规模扩展行为。我们重点关注序列长度和模型规模这两个对序列推荐模型至关重要的因素。所有实验均在相同的硬件和软件栈下进行。除性能指标外, 我们还报告每个模型对应的 GFLOPs。

序列长度缩放。 我们首先研究 CCFormer 能否在工业数据集上有效扩展到更长的用户行为序列。如图 5 所示, **在不同序列长度下, CCFormer 始终优于 HSTU**。随着序列长度增加, CCFormer 展现出可预测的缩放行为: AUC 从 77.72% 稳步提升至 78.17%, GAUC 从 70.95% 提升至 71.57%。与 HSTU 相比, 在不同序列长度设置下, CCFormer 的 AUC 和 GAUC 分别实现平均 1.08% 和 2.37% 的相对提升。**仅使用 0.5k 个行为 token 的 CCFormer, AUC 已与使用 2k 个行为 token 的 HSTU 持平, GAUC 则超过后者**。值得注意的是, 随着序列变长, 相对增益进一步扩大。长序列子空间 token mixing 从完整行为历史中捕获富有表达力的模式, 而序列压缩则以显著更低的成本保留较大的感受野。

模型规模缩放。 模型规模对工业数据集的影响如表 4 所示, 其中我们通过改变特征维度来控制模型容量。随着特征维度增大, CCFormer 遵循可预测的缩放定律, AUC 从 77.65% 提升

表 4: 模型规模的影响。HSTU 基线作为基础模型。

模型	特征 维度	AUC (%)	Δ AUC (%)	GAUC (%)	Δ GAUC (%)	GFLOPs/样本
HSTU	128	77.42	0.00	70.55	0.00	28.87
CCFormer	128	77.65	0.84	70.76	1.02	9.34
HSTU	256	77.66	0.00	70.86	0.00	38.37
CCFormer	256	77.94	1.01	71.36	2.40	18.28
HSTU	512	77.79	0.00	71.02	0.00	63.47
CCFormer	512	78.13	1.22	71.52	2.38	36.14




图 6: CCFormer 中卷积核大小和组大小的参数敏感性。

至 78.13%, GAUC 从 70.76% 提升至 71.52%。与相同特征维度设置下的 HSTU 相比, CCFormer 在 AUC 和 GAUC 上分别取得了 1.02% 和 1.93% 的平均相对提升。同时, CCFormer 每个样本所需的 GFLOPs 始终少于 HSTU。缩放分析表明, CCFormer 在效果与效率之间实现了更有利的权衡, 是工业长序列推荐中实用且可扩展的解决方案。

4.3 长序列建模超参数的影响

为评估 CCFormer 的鲁棒性, 我们研究了与长序列建模相关的两类超参数。具体而言, 序列压缩模块中的卷积核大小 k 控制相邻行为 token 上的感受野。组大小用于长序列子空间 token 混合, 其中序列组大小 m 沿序列维度划分为 token, 通道组大小 n 沿特征维度划分 token 嵌入。

卷积核大小。如图 6 所示, 增大卷积核大小会略微提升 AUC, 而整体性能保持稳定。当卷积核大小从 2 增至 7 时, AUC 从 77.92% 变为 77.95%。此外, 在不同卷积核大小下, CCFormer 始终以明显优势优于 HSTU。这表明, 分层压缩模块能够有效去除长行为序列中的冗余信息, 同时保留关键偏好信号。在工业实验中, 我们将步幅 s 设为 2, 以便在缩短序列、实现高效长序列建模的同时保持有竞争力的性能。

组大小。随后, 我们研究长序列子空间 token 混合模块中的关键超参数, 即序列组大小 m 和通道组大小 n 。如图 6 所示, 在 m 和 n 的不同组合下, CCFormer 的表现保持稳定, 且所有配置均始终优于 HSTU 基线。尽管较小的组大小在某些情况下可略微提升 AUC, 但总体变化有限。这表明, 子空间 token 混合无需精细调参即可稳健地捕捉潜在依赖关系。

4.4 消融研究

我们在工业数据集上开展消融研究, 以分析 CCFormer 各关键组件的贡献。为公平比较, 所有消融变体均在相同的硬件和软件栈上, 使用相同的训练与评估协议进行评估。如表 5 所示, 我们构建了四种消融变体来检验 CCFormer 的核心设计, 涵盖相对时间位置编码、长序列子空间 token 混合和分层序列压缩。我们使用训练吞吐量来衡量训练速度, 其定义为单位时间内处理的样本数。为了更直观地比较训练效率, 我们将训练加速比指标定义为相对于 HSTU 的训练吞吐量。

在表 5 中, 移除相对时间位置编码后, AUC 从 77.94% 降至 77.85%, GAUC 从 71.36% 降至 71.13%。由于用户兴趣具有高度时效性, 相对时间位置编码有助于 CCFormer 区分近期行为与过时行为, 并更好地捕捉感知新近性的偏好模式。移除序列 token 混合导致性能下降最大, AUC 和 GAUC 分别降至 77.73% 和 71.02%。此外, 以标准自注意力替换 token 混合后, AUC 略微提升至 77.96%, 但 GAUC 降至 71.21%, 训练加速比也从 $2.21\times$ 降至 $1.41\times$ 。子空间 token 混合提供了一种轻量级替代方案, 仅带来轻微的准确率损失, 却能显著提升训练效率。值得注意的是, 移除序列压缩后可取得 77.96% 的 AUC 和 71.25% 的 GAUC。更重要的是, 训练加速比从 $2.21\times$ 降至 $1.29\times$, 表明序列压缩是提升训练效率的关键组件。

4.5 在线 A/B 结果

我们报告 CCFormer 在腾讯两个实际商业推荐场景中的在线 A/B 测试结果: 视频推荐(场景 1)和广告排序(场景 2)。两个场景的在线基线分别是长期部署并经过迭代优化的 DLRM 和已部署的 HSTU 模型。每个在线实验组每天覆盖超过一百万名曝光用户, 实验持续两周。在表 6 中, CCFormer 在两个场景的多项业务指标上均取得一致提升。在场景 1 中, **Page View 的增益最大, 相对提升达 3.86%**。CCFormer 在 CTR、Video View 和 Unique Viewer 上也分别取得了 3.57%、3.47% 和 2.61% 的相对提升。用户点击率 (UCTR) 和用户 3 日活跃度均提升了 1.93%。CCFormer 不仅增强了用户的即时响应, 还改善了用户参与度和短期留存。CCFormer 在两个场景的广告收入上分别实现了 1.64% 和 1.71% 的提升。作为广告侧的关键业务指标, 这体现了 CCFormer 在工业变现中的实用价值。所有报告的在线收益均具有统计显著性 (双样本 t 检验, $p < 0.05$), 证实了生产环境中这些改进的可靠性。A/B 测试后, CCFormer 已在两个场景中全面上线, 目前承载全部生产流量, 全面部署后线上收益仍保持稳定。

表 5: 消融研究结果。以 HSTU 基线作为基础模型。

模型	说明	训练 加速比	AUC (%)	ΔAUC (%)	GAUC (%)	ΔGAUC (%)
HSTU	-	1	77.66	0.00	70.86	0.00
CCFormer	-	2.21	77.94	1.01	71.36	2.40
	移除相对时间位置编码	2.35	77.85	0.69	71.13	1.29
	长序列 token 混合 → 自注意力	1.41	77.96	1.08	71.21	1.68
	移除长序列 token 混合	2.40	77.73	0.25	71.02	0.77
	移除序列压缩	1.29	77.96	1.08	71.25	1.87

表 6: CCFormer 的在线 A/B 收益。

场景 1	指标	CTR	UCTR	3 日 活跃度	视频 观看量	独立 观看者	页面 浏览量	观看 时长	广告 收入	场景 2	指标	广告 观看量	广告 收入
	提升 (%)	3.57	1.93	1.93	3.47	2.61	3.86	1.29	1.64		提升 (%)	1.43	1.71

5 结论

我们提出了 CCFormer，它将特征字段分离的交叉注意力与子空间 token mixing 和分层压缩相统一，从而实现高效的长序列排序。CCFormer 在线下评估中始终优于强基线，并已全面部署于腾讯生产推荐系统中；在计算成本相当或更低的情况下，它在视频推荐和广告排序场景中均带来了显著的线上收益。未来，我们计划将 CCFormer 扩展至终身尺度序列，并探索面向检索阶段的压缩感知建模。

参考文献

[1] James Bergstra, Rémi Bardenet, Yoshua Bengio, and Balázs Kégl. 2011. Algorithms for Hyper-Parameter Optimization. In *Advances in Neural Information Processing Systems*, J. Shawe-Taylor, R. Zemel, P. Bartlett, F. Pereira, and K. Weinberger (Eds.), Vol. 24. Curran Associates, Inc. https://proceedings.neurips.cc/paper_files/paper/2011/file/86e8f7ab32cfd12577bc2619bc635690-Paper.pdf

[2] Zheng Chai, Qin Ren, Xijun Xiao, Huizhi Yang, Bo Han, Sijun Zhang, Di Chen, Hui Lu, Wenlin Zhao, Lele Yu, et al. 2025. Longer: Scaling up long sequence modeling in industrial recommenders. In *Proceedings of the Nineteenth ACM Conference on Recommender Systems*. 247–256.

[3] Jianxin Chang, Chenbin Zhang, Zhiyi Fu, Xiaoxue Zang, Lin Guan, Jing Lu, Yiqun Hui, Dewei Leng, Yanan Niu, Yang Song, and Kun Gai. 2023. TWIN: TTwo-stage Interest Network for Life-long User Behavior Modeling in CTR Prediction at Kuaishou. In *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. 3785–3794.

[4] Jin Chen, Shangyu Zhang, Bin Hu, Chao Zhou, Junwei Pan, Gengsheng Xue, Wentao Ning, Gengyu Weng, Wang Zheng, Shao-hua Liu, et al. 2026. RankUp: Towards High-rank Representations for Large Scale Advertising Recommender Systems. *arXiv preprint arXiv:2604.17878* (2026).

[5] Qiwei Chen, Huan Zhao, Wei Li, Pipei Huang, and Wenwu Ou. 2019. Behavior sequence transformer for e-commerce recommendation in alibaba. In *Proceedings of the 1st international workshop on deep learning practice for high-dimensional sparse data*. 1–4.

[6] Xiangyi Chen, Kousik Rajesh, Matthew Lawhon, Zelin Wang, Hanyu Li, Haomiao Li, Saurabh Vishwas Joshi, Pong Eksombatchai, Jaewon Yang, Yi-Ping Hsu, et al. 2025. Pinfm: foundation model for user activity sequences at a billion-scale visual discovery platform. In *Proceedings of the Nineteenth ACM Conference on Recommender Systems*. 381–390.

[7] Heng-Tze Cheng, Levent Koc, Jeremiah Harmsen, Tal Shaked, Tushar Chandra, Hrishi Aradhye, Glen Anderson, Greg Corrado,

Wei Chai, Mustafa Ispir, et al. 2016. Wide & deep learning for recommender systems. In *Proceedings of the 1st workshop on deep learning for recommender systems*. 7–10.

[8] Sunhao Dai, Jiakai Tang, Jiahua Wu, Kun Wang, Yuxuan Zhu, Bingjun Chen, Bangyang Hong, Yu Zhao, Cong Fu, Kangle Wu, et al. 2025. Onepiece: Bringing context engineering and reasoning to industrial cascade ranking system. *arXiv preprint arXiv:2509.18091* (2025).

[9] Qin Ding, Kevin Course, Linjian Ma, Jianhui Sun, Ruochen Liu, Zhao Zhu, Chunxing Yin, Wei Li, Dai Li, Yu Shi, et al. 2026. Bending the scaling law curve in large-scale recommendation systems. *arXiv preprint arXiv:2602.16986* (2026).

[10] Yufei Feng, Fuyu Lv, Weichen Shen, Menghan Wang, Fei Sun, Yu Zhu, and Keping Yang. 2019. Deep session interest network for click-through rate prediction. *arXiv preprint arXiv:1905.06482* (2019).

[11] Yulong Gu, Lixin Zou, and Chenliang Li. 2026. Deep Learning to Rank in Industrial Search Engines, Recommender Systems, and Online Advertising: An Overview and New Perspectives. *ACM Transactions on Information Systems* 44, 4 (2026), 1–52.

[12] Lin Guan, Jia-Qi Yang, Zhishan Zhao, Beichuan Zhang, Bo Sun, Xuanyuan Luo, Jinan Ni, Xiaowen Li, Yuhang Qi, Zhifang Fan, et al. 2026. Make it long, keep it fast: End-to-end 10k-sequence modeling at billion scale on Douyin Recommendation. In *Proceedings of the ACM Web Conference 2026*. 7989–7998.

[13] Huifeng Guo, Ruiming Tang, Yunming Ye, Zhenguo Li, and Xiuqiang He. 2017. DeepFM: a factorization-machine based neural network for CTR prediction. *arXiv preprint arXiv:1703.04247* (2017).

[14] Mingming Ha, Guanchen Wang, Linxun Chen, Xuan Rao, Yuexin Shi, Tianbao Ma, Zhaojie Liu, Yunqian Fan, Zilong Lu, Yanan Niu, et al. 2026. UniMixer: A Unified Architecture for Scaling Laws in Recommendation Systems. *arXiv preprint arXiv:2604.00590* (2026).

[15] Ruidong Han, Bin Yin, Shangyu Chen, et al. 2025. MTGR: Industrial-Scale Generative Recommendation Framework in Meituan. *arXiv preprint arXiv:2505.18654* (2025).

[16] Xu Huang, Hao Zhang, Zhifang Fan, Yunwen Huang, Zhuoxing Wei, Zheng Chai, Jinan Ni, Yuchao Zheng, and Qiwei Chen. 2026. MixFormer: Co-Scaling Up Dense and Sequence in Industrial Recommenders. *arXiv preprint arXiv:2602.14110* (2026).

[17] Yuchen Jiang, Jie Zhu, Xintian Han, Hui Lu, Kunmin Bai, Mingyu Yang, Shikang Wu, Ruihao Zhang, Wenlin Zhao, Shipeng Bai, et al. 2026. TokenMixer-Large: Scaling Up Large Ranking Models in Industrial Recommenders. *arXiv preprint arXiv:2602.06563* (2026).

[18] Wang-Cheng Kang and Julian McAuley. 2018. Self-attentive sequential recommendation. In *2018 IEEE international conference on data mining (ICDM)*. IEEE, 197–206.

- [19] Weijiang Lai, Beihong Jin, Di Zhang, Siru Chen, Jiongyan Zhang, Yuhang Gou, Jian Dong, and Xingxing Wang. 2026. Unleashing the Potential of Sparse Attention on Long-term Behaviors for CTR Prediction. In *Proceedings of the ACM Web Conference 2026*. 8041–8050.
- [20] Yang Li, Tong Chen, Peng-Fei Zhang, and Hongzhi Yin. 2021. Lightweight self-attentive sequential recommendation. In *Proceedings of the 30th ACM international conference on information & knowledge management*. 967–977.
- [21] Guanyu Lin, Jinwei Luo, Yinfeng Li, Chen Gao, Qun Luo, and Depeng Jin. 2025. Iterative sparse attention for long-sequence recommendation. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 39. 12147–12155.
- [22] Mingyang Liu, Yong Bai, Zhangming Chan, Sishuo Chen, Xiang-Rong Sheng, Han Zhu, Jian Xu, and Xinyang Chen. 2026. EST: Towards Efficient Scaling Laws in Click-Through Rate Prediction via Unified Modeling. *arXiv preprint arXiv:2602.10811* (2026).
- [23] Mengyang Ma, Xiaopeng Li, Wanyu Wang, Zhaocheng Du, Jingtong Gao, Pengyue Jia, Yuyang Ye, Yiqi Wang, Yunpeng Weng, Weihong Luo, et al. 2026. Blossomrec: Block-level fused sparse attention mechanism for sequential recommendations. In *Proceedings of the ACM Web Conference 2026*. 6389–6399.
- [24] Qi Pi, Weijie Bian, Guorui Zhou, Xiaoqiang Zhu, and Kun Gai. 2019. Practice on long sequential user behavior modeling for click-through rate prediction. In *Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining*. 2671–2679.
- [25] Qi Pi, Guorui Zhou, Yujing Zhang, Zhe Wang, Lejian Ren, Ying Fan, Xiaoqiang Zhu, and Kun Gai. 2020. Search-based User Interest Modeling with Lifelong Sequential Behavior Data for Click-Through Rate Prediction. In *Proceedings of the 29th ACM International Conference on Information & Knowledge Management*. 2685–2692.
- [26] Fei Sun, Jun Liu, Jian Wu, Changhua Pei, Xiao Lin, Wenwu Ou, and Peng Jiang. 2019. BERT4Rec: Sequential recommendation with bidirectional encoder representations from transformer. In *Proceedings of the 28th ACM international conference on information and knowledge management*. 1441–1450.
- [27] Dan Svenstrup, Jonas Meinertz Hansen, and Ole Winther. 2017. Hash Embeddings for Efficient Word Representations. In *Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems 2017, December 4-9, 2017, Long Beach, CA, USA*, Isabelle Guyon, Ulrike von Luxburg, Samy Bengio, Hanna M. Wallach, Rob Fergus, S. V. N. Vishwanathan, and Roman Garnett (Eds.). 4928–4936. <https://proceedings.neurips.cc/paper/2017/hash/f0f6ba4b5e0000340312d33c212c3ae8-Abstract.html>
- [28] Qiaoyu Tan, Jianwei Zhang, Jiangchao Yao, Ninghao Liu, Jingren Zhou, Hongxia Yang, and Xia Hu. 2021. Sparse-interest network for sequential recommendation. In *Proceedings of the 14th ACM international conference on web search and data mining*. 598–606.
- [29] Jiakai Tang, Sunhao Dai, Teng Shi, Jun Xu, Xu Chen, Wen Chen, Jian Wu, and Yuning Jiang. 2026. Think before recommend: Unleashing the latent reasoning power for sequential recommendation. *IEEE Transactions on Knowledge and Data Engineering* (2026).
- [30] Ilya O Tolstikhin, Neil Houlsby, Alexander Kolesnikov, Lucas Beyer, Xiaohua Zhai, Thomas Unterthiner, Jessica Yung, Andreas Steiner, Daniel Keysers, Jakob Uszkoreit, et al. 2021. Mlp-mixer: An all-mlp architecture for vision. *Advances in neural information processing systems* 34 (2021), 24261–24272.
- [31] Yifei Xia, Suhan Ling, Fangcheng Fu, Yujie Wang, Huixia Li, Xuefeng Xiao, and Bin Cui. 2025. Training-free and adaptive sparse attention for efficient long video generation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 15982–15993.
- [32] Weinan Xu, Hengxu He, Minshi Tan, Yunming Li, Jun Lang, and Dongbai Guo. 2020. Deep interest with hierarchical attention network for click-through rate prediction. In *Proceedings of the 43rd international ACM SIGIR conference on research and development in information retrieval*. 1905–1908.
- [33] Bencheng Yan, Yuejie Lei, Zhiyuan Zeng, Di Wang, Kaiyi Lin, Pengjie Wang, Jian Xu, and Bo Zheng. 2025. From Scaling to Structured Expressivity: Rethinking Transformers for CTR Prediction. *arXiv preprint arXiv:2511.12081* (2025).
- [34] Yuhao Yang, Zhi Ji, Zhaopeng Li, Yi Li, Zhonglin Mo, Yue Ding, Kai Chen, Zijian Zhang, Jie Li, LIU LIN, et al. 2026. Sparse meets dense: Unified generative recommendations with cascaded sparse-dense representations. *Advances in Neural Information Processing Systems* 38 (2026), 93746–93770.
- [35] Yanwu Yang and Panyu Zhai. 2022. Click-through rate prediction in online advertising: A literature review. *Information Processing & Management* 59, 2 (2022), 102853.
- [36] Dezhi Yi, Wei Guo, Wenyang Cui, Wenxuan He, Huifeng Guo, Yong Liu, Zhenhua Dong, and Ye Lu. 2026. FuXi- γ : Efficient Sequential Recommendation with Exponential-Power Temporal Encoder and Diagonal-Sparse Positional Mechanism. In *Proceedings of the 32nd ACM SIGKDD Conference on Knowledge Discovery and Data Mining V. 1*. 1797–1808.
- [37] Jingyang Yuan, Huazuo Gao, Damai Dai, Junyu Luo, Liang Zhao, Zhengyan Zhang, Zhenda Xie, Yuxing Wei, Lean Wang, Zhiping Xiao, et al. 2025. Native sparse attention: Hardware-aligned and natively trainable sparse attention. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. 23078–23097.
- [38] Jiaqi Zhai, Lucy Liao, Xing Liu, Yueming Wang, Rui Li, Xuan Cao, Leon Gao, Zhaojie Gong, Fangda Gu, Michael He, et al. 2024. Actions speak louder than words: Trillion-parameter sequential transducers for generative recommendations. *arXiv preprint arXiv:2402.17152* (2024).
- [39] Biao Zhang and Rico Sennrich. 2019. Root Mean Square Layer Normalization. In *Advances in Neural Information Processing Systems 32: Annual Conference on Neural Information Processing Systems 2019, NeurIPS 2019, December 8-14, 2019, Vancouver, BC, Canada*, Hanna M. Wallach, Hugo Larochelle, Alina Beygelzimer, Florence d'Alché-Buc, Emily B. Fox, and Roman Garnett (Eds.). 12360–12371. <https://proceedings.neurips.cc/paper/2019/hash/1e8a19426224ca89e83cef47f1e7f53b-Abstract.html>
- [40] Zhaoqi Zhang, Haolei Pei, Jun Guo, Tianyu Wang, Yufei Feng, Hui Sun, Shaowei Liu, and Aixin Sun. 2026. Onetrans: Unified feature interaction and sequence modeling with one transformer in industrial recommender. In *Proceedings of the ACM Web Conference 2026*. 8162–8170.
- [41] Guorui Zhou, Xiaoqiang Zhu, Chenru Song, Ying Fan, Han Zhu, Xiao Ma, Yanghui Yan, Junqi Jin, Han Li, and Kun Gai. 2018. Deep interest network for click-through rate prediction. In *Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining*. 1059–1068.
- [42] Jie Zhu, Zhifang Fan, Xiaoxie Zhu, Yuchen Jiang, Hangyu Wang, Xintian Han, Haoran Ding, Xinmin Wang, Wenlin Zhao, Zhen Gong, et al. 2025. Rankmixer: Scaling up ranking models in industrial recommenders. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management*. 6309–6316.