

迈向十亿级容量用户表示学习的稠密化定律

Bin Dou^{1,*}, Junru Zhang^{1,2,*}, Zhaoyi Yuan^{1,2,*}, Wuliang Huang¹, Letian Gong¹, Baokun Wang^{1,†}, Huan Li^{2,†}, Yu Cheng¹, Weiqiang Wang¹

¹ 蚂蚁集团 DeepFind 团队, ² 浙江大学

* 同等贡献, [†] 通讯作者 yike.wbk@antgroup.com, lihuan.cs@zju.edu.cn

真实工业场景中的用户表示学习通常通过增加用户数量、行为序列长度和模型规模来扩展。然而, 现有方法面临两个问题: (i) 十亿级容量下原始数据扩展的瓶颈: 随着原始文本用户行为输入规模增大, 性能增益逐渐减弱, 而分词可以缓解这一问题; (ii) 缺乏分词配置应如何随数据规模扩展的定量分析。本文提出用于刻画数据规模与最小充分分词容量之间定量关系的 用户行为稠密化定律。首先, 我们在十亿级支付宝数据集上开展原始数据 & 分词化数据扩展对比的先导研究, 揭示原始数据扩展瓶颈以及通过分词实现的突破。为推导不同数据规模下支配最小充分分词配置的扩展规律, 我们结合理论与实验分析, 总结其定量扩展模式。此外, 受所提出稠密化定律的启发, 我们提出一种名为 ALGN 的新分词方法。在不同数据源、分词方法和下游任务上的实验评估证明了稠密化定律的泛化性与可靠性, 该定律为大规模用户表示学习中的配置选择提供了指导。同时, ALGN 在性能和效率两方面均优于现有基线。



1 引言

深度表征学习取得的显著成功从根本上改变了现代个性化平台; 随着用户行为序列和模型参数规模的扩大, 下游性能持续提升 (Kang and McAuley, 2018; Sun et al., 2019; Pi et al., 2019)。如今, 从原始行为日志中提取的统一用户嵌入已成为推荐、CTR/CVR 预测、检索以及基于自然语言的用户定向等任务的共享基础 (Xiao et al., 2025; Zhang et al., 2021)。图 1 (a) 展示了这一范式。然而, 沿着实际维度进行扩展——包括更多用户、更长的历史窗口和更大的编码器 (Ardalani et al., 2022; Guo et al., 2024; Zhang et al., 2024b)——会带来重大挑战。用户行为日志在很大程度上受日常作息和重复习惯影响, 这意味着数据量迅速增长, 而新颖且与任务相关的信息增长得慢得多。这种差异引出了一个关键问题:

我们能否识别出使规模化模型有效的关键属性, 从而在不只是处理更多原始行为事件的情况下提升表征质量?

现有工业系统依赖于扩展原始序列数据, 但行为冗余的实证表现及其与下游性能之间的关系仍缺乏深入研究。在本工作中, 我们使用大规模真实世界的支付宝 PayBill 数据, 对我们所称的 原始行为扩展墙进行了全面的实证分析, 以确保实际相关性和生态有效性。

定义 1.1. 我们将 原始行为扩展墙定义为这样一种现象: 逐步扩展原始行为序列长度、用户规模或模型容量所带来的下游收益严格递减, 最终导致 损失与质量脱钩, 即预训练损失下降却无法提升下游准确率。

通过沿多个扩展维度开展系统评估, 我们证明工业用户表征学习存在严重的冗余饱和。延长观察窗口或扩大用户群体, 主要会引入重复且信息量低的事件。尤其值得注意的是, 当用户编码器的参数



图 1 (a) 用户表征学习流程。在用户行为序列上完成训练后，表征模型可支持多种下游应用，包括用于用户定向的文本检索、用于推荐系统的 U2U 检索，以及用于广告和风控场景的分类。在拥有十亿级用户的工业环境中，当通过增加行为时间跨度和用户数量等常见方式扩大输入数据量时，直接使用原始数据（例如原始用户行为文本描述）的模型在超过实际扩展阈值后会出现性能饱和，而 tokenization 能够缓解这一限制并实现持续的性能提升，如 (b) 所示。

量从 0.2B 扩展至 0.4B 时，我们观察到更大的模型只是在拟合冗余的行为细节，而未能提取更多与任务相关的信号，因此下游表征准确率几乎没有变化。

定义 1.2. 我们将行为稠密化定义为：将冗长的原始历史转化为紧凑表征，在抑制冗余的同时保留与任务相关的区分信息，从而优化每个有效输入单元所承载的下游相关信号量。

这种以密度为导向的视角揭示了一个根本性洞见：信息密度，而非仅仅模型容量，是限制用户编码器表达能力的关键瓶颈。我们假设，在行为稠密化定律的支配下，将用户表征推向更优的性能-成本前沿，能够重新获得原始规模扩展未能带来的收益。该定律基于三个原则：原始收益有界，即随着冗余占据主导，边际效用下降；密度驱动的规模扩展，即更稠密的表征会推动饱和和前沿外移；以及最小充分容量，即最优表征只分配足以保留必要任务相关信息的容量。

为验证这一假设，我们通过基于 RQ-VAE 的残差量化行为分词来实例化行为稠密化。它作为一种实用的密度算子，将重复的事件历史映射为紧凑的离散码序列。此外，考虑到行为信息并非均匀分布，我们提出一种基于熵的变长分词策略。该机制为高熵片段分配更多离散码，而为可预测的常规行为分配更少离散码，从而显式适应行为复杂度，并逼近最小充分表征容量。

我们的实证评估表明，在匹配 token 与计算预算的条件下，分词后的表征突破了原始规模扩展之墙。所提出的框架在大规模支付宝 PayBill 生产数据上带来了稳定的性能提升，并改善了编码器利用率。

本文的主要贡献如下：

1. **扩展诊断与分词效应。**我们发现扩展原始行为数据时会出现边际收益递减，并揭示分词化数据能够带来更持久的增益，从而缓解更大规模下的性能饱和。结合模型容量瓶颈的证据，这些发现表明，数据的信息密度而非仅仅是模型参数量，才是工业用户表示学习的主要制约因素，尤其是在十亿级数据容量下。
2. **可预测的分词配置方案。**我们将与输入数据量相对应的最优分词容量配置轨迹表述为用户表示学习的用户行为稠密化定律，从而能够在完成分词器方法校准后，根据行为数据规模和轻

量级统计量估计所需的容量配置。

3. **自适应分词分配**。我们提出一种新方法 自适应长度门控网络，它依据量化残差和表达不确定性，通过在不同用户样本间采用可变残差深度来自适应分配分词容量，从而更有效地分配离散表示空间，并且随着输入数据规模增大，从 稠密化定律的视角展现出优势。

2 相关工作

与本职工作相关的现有研究可归纳为三个方向：扩展原始行为数据、构建分词化行为表示，以及针对不同输入自适应调整 token 使用量。表 1 总结了这些研究对本研究所考察各维度的覆盖情况。

表 1 相关工作在本研究所考察各维度上的比较。

研究方向	原始数据	分词化数据	容量配置	容量分配
用户数据扩展 (Ardalani et al., 2022; Shin et al., 2023; Zhang et al., 2024a; Zivic et al., 2024; Guo et al., 2024; Zhai et al., 2024; Shen et al., 2025; Zhang et al., 2026)	✓	×	×	×
行为分词 (Feng et al., 2026; Liu et al., 2024a; Zhu et al., 2024; Liu et al., 2024b; Hou et al., 2025)	×	✓	×	×
基于残差量化的分词 (van den Oord et al., 2017; Lee et al., 2022; Rajput et al., 2023; He et al., 2025)	×	✓	×	×
自适应量化 (Huijben et al., 2024; Seo and Kang, 2024; Chae et al., 2025; Kusupati et al., 2022)	×	✓	×	✓
本文方法	✓	✓	✓	✓

原始行为数据扩展。大规模用户建模研究考察行为数据、模型容量和计算量如何影响下游效用 (Ardalani et al., 2022; Shin et al., 2023; Zhang et al., 2024a; Zivic et al., 2024; Guo et al., 2024; Zhai et al., 2024)。长历史方法通过兴趣提取、检索和长序列架构，提高对扩展行为序列的利用率 (Zhou et al., 2019; Li et al., 2019; Cen et al., 2020; Pi et al., 2020; Ren et al., 2025; Cao et al., 2022; Si et al., 2024; Zhou et al., 2024; Chai et al., 2025)。然而，新增记录可能包含重复或信息量较弱的信号，从而导致边际收益递减 (Shen et al., 2025; Zhang et al., 2026)。这些研究主要刻画原始行为数据的扩展特性。

Tokenized 行为数据。行为 tokenization 将原始用户数据转换为紧凑的离散表征。现有方法为用户理解学习可复用的行为单元或词表 (Feng et al., 2026; Liu et al., 2024a; Zhu et al., 2024; Liu et al., 2024b; Hou et al., 2025; Deng et al., 2025; Wang et al., 2026)。VQ-VAE (van den Oord et al., 2017) 通过向量量化学习离散潜在编码，而 RQ-VAE (Lee et al., 2022) 使用多个码本递归量化残差信息。在此基础上，TIGER 为生成式检索构建语义标识符 (Rajput et al., 2023)，U²QT 则引入多视图量化以生成紧凑的用户 token (He et al., 2025)。这些方法通常在选定的数据规模下使用固定的 tokenization 配置。

容量配置与自适应 tokenization。码本大小、残差深度和 token 长度决定 tokenized 表征的信息容量。现有方法通常依赖人工选择的配置 (Rajput et al., 2023; Liu et al., 2024a; Zhu et al., 2024; He et al., 2025)。自适应量化进一步允许不同输入激活不同数量的量化层级 (Huijben et al., 2024; Seo and Kang, 2024; Chae et al., 2025)。相关机制也已在灵活嵌入和自适应计算中得到研究 (Kusupati et al., 2022; Graves, 2016; Dehghani et al., 2019)。然而，这些方法侧重于输入层面的分配，并且通常假设最大可用容量已经预先指定。

表 2 符号、对应说明与关键统计量。虚线上方为预训练统计量，下方为下游评估设置。

符号	说明	统计信息
N	用户数量	100M–2B
D	用户行为序列长度	30–270 天
P	预训练用户嵌入模型的模型规模	0.05B–0.4B
u_n^d	用户 n 在第 d 个时间窗口内的行为信息，包括 Paybill B_n^d 、SPM S_n^d 和 Miniprogram M_n^d	每位用户每日事件数为 0–10；中位数 $\sim$ 为 6
$\mathbf{s}$	用于训练的行为文本 token	每位用户 $\sim$ 2200
$\mathcal{D}_{test}$	用于下游评估的测试数据集	分类：50 个数据集，每个数据集 0.5M 用户 文本检索：22 个数据集，每个数据集 0.5M 用户 U2U 检索：22 个数据集，每个数据集 0.5M 用户

3 预备知识

本节介绍本文采用的整体研究设置，包括符号约定、作为后续分析参考系统的表示模型预训练流程，以及下游评估协议。

3.1 符号约定

在支付宝这样的综合性互联网平台上，可以获取大量非敏感的用户信息与交互数据。令 $\mathcal{U} = \{u_1, u_2, \dots, u_N\}$ 表示由 N 个用户组成的行为序列数据集，每位用户的行为 u_n 按时间顺序（例如按日）组织，从而形成 $u_n = \{u_n^1, u_n^2, \dots, u_n^D\}$ ，覆盖 D 天。行为 u_n^d 包含多源数据，例如 PayBill B 、Super Position Model (SPM) 记录 S 以及 MiniProgram 使用描述 M ，表示为 $u_n^d = \{B_n^d, S_n^d, M_n^d\}, n = 1 \dots N, d = 1 \dots D$ 。每个数据源的信息都可以用文本形式表示，其中 $B_n^d \in \mathcal{T}^{L_n^d(B)}$ 、 $S_n^d \in \mathcal{T}^{L_n^d(S)}$ 和 $M_n^d \in \mathcal{T}^{L_n^d(M)}$ 分别表示 PayBill、SPM 和 MiniProgram 描述的原始文本， $\mathcal{T}$ 表示预定义的文本 token 词典， $L_n^d(\cdot)$ 表示用户 n 在第 d 个时间窗口内各数据源记录的行为事件数量（由于活跃程度存在异质性， $L_n^d(\cdot)$ 可能随用户和时间窗口而变化）。表 2 总结了本报告通篇使用的符号及其对应说明。

3.2 模型预训练框架

为建立面向用户行为序列的表征学习流程，我们遵循 (Dou et al., 2025)，采用基于行为—文本对比学习的自监督预训练框架，如图 2 所示。




图 2 通用用户表示的预训练框架。每位用户的行为序列被划分为过去片段和未来片段；前者由 Transformer 编码器进行编码，后者被输入经 LoRA 微调的 LLM 模型以生成嵌入，随后通过对比损失进一步对齐。

具体而言，针对每条行为信息 u_n^d ，我们设计文本模板 Q ，将其处理为结构化表达。需要注意的是，

不同数据源采用不同的模板。例如，用户产生的 paybill 信息会被串联成一段完整描述，其中包含购买某种商品、所属类别、交易金额和支付渠道。模板形式如下：

购买类别模板： 用户购买了 {items}，金额超过 {num} 美元，支付状态为 {status}。

在预训练阶段，我们首先收集并整理语料，将每个行为序列 u_n 划分为两部分：历史部分 $u_n^{\text{past}} = (u_n^1, \dots, u_n^m)$ 和未来部分 $u_n^{\text{future}} = (u_n^{m+1}, \dots, u_n^D)$ ，其中 m 对应划分时间窗口的边界。随后，基于 Transformer 的用户编码器 f_θ 处理过去片段 u_n^{past} ，生成嵌入 $\mathbf{e}_n^b \in \mathbb{R}^d$ 。与此同时，以未来片段 u_n^{future} 为输入实例化文本模板 Q ，并通过采样生成监督信号。该描述由经 LoRA(Hu et al., 2021) 微调的基于 LLM 的嵌入模型 g_ϕ (例如 Qwen3-Embedding(Zhang et al., 2025)) 编码，生成嵌入 $\mathbf{e}_n^q \in \mathbb{R}^d$ 。基础模型保持冻结，仅应用秩为 16 的低秩适配器。对于预训练目标，我们通过对比损失 Info-NCE(Oord et al., 2018) 对齐两个嵌入，其可表示为：

$$\mathcal{L}_{\text{CP}} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(\text{sim}(\mathbf{e}_i^b, \mathbf{e}_i^q) / \tau)}{\sum_{j=1}^B \exp(\text{sim}(\mathbf{e}_i^b, \mathbf{e}_j^q) / \tau)} \quad (1)$$

其中， B 表示训练批次大小， sim 表示余弦相似度函数， τ 是可学习的温度参数。分母对批次内全部 B 对进行求和，将来自同一用户的描述视为正样本，将不匹配的描述对视为负样本。

3.3 下游评估协议

我们采用固定的下游评估协议，在不同规模扩展设置下评估所学习用户表征的质量。评估包括现实工业应用中用户表征学习的三类常见任务：(i) **分类**；(ii) **基于文本的检索**；(iii) **U2U 检索**。可以看到，每项任务的评估数据集涵盖用户偏好、风险控制、推荐、营销等多种场景，所报告的数值是所有特定场景数据集上的指标平均值，用于评估所学习表征的性能和泛化能力。详细的数据集统计见表 2。




图 3 用于用户表示评估的三项下游任务。

3.3.1 分类

基于表征的分类任务通常与广告、营销和风控等工业场景直接相关，并普遍采用线性探测协议来评估分类性能 (Radford et al., 2021; Cherti et al., 2023)。具体而言，我们冻结预训练用户编码器，仅训练一个轻量级线性分类器，使其在提取的嵌入之上拟合给定数量的标注样本

对于每个预训练用户编码器 f_θ^* ，我们将其冻结，并用其提取所有下游数据集中的用户行为嵌入，随后将这些嵌入用于：

$$y_n^{\text{cls}} = \mathbb{I}[\mathbf{W}f_\theta^*(u_n) + b > \mathcal{T}^{\text{cls}}] \quad (2)$$

，其中 $\mathbf{W} \in \mathbb{R}^d, b \in \mathbb{R}$ 是用于二分类的线性网络，在留出的训练集和测试集上进行训练与评估； $\mathcal{T}^{\text{cls}}$ 是分类阈值，通常设为 0.5。

评估指标。在线性探测任务中,我们报告三个互补指标: AUC、KS 和**准确率**。AUC (ROC 曲线下面积) 衡量模型在所有分类阈值下将正样本排序在负样本之前的总体能力。KS (Kolmogorov–Smirnov) 值衡量正、负样本累积分数分布之间的最大间隔,反映模型在最优阈值处最强的区分能力。**准确率**衡量在指定决策阈值下被正确分类的样本比例,刻画整体预测正确性。这些指标共同评估与阈值无关的排序质量、类别可分性以及依赖阈值的分类性能,从而全面衡量下游分类效果。

3.3.2 基于文本的检索

基于文本查询的用户检索是零样本用户定向任务的关键组成部分,其目标是判断每个用户是否属于给定自然语言查询所对应的目标受众 Q 。如图所示,通过计算文本查询嵌入与每个候选用户嵌入之间的余弦相似度,选择相似度得分超过预设阈值的用户并进行定向投放。

$$y_n^{tbr} = \mathbb{I} \left[\text{sim}(f_\theta^*(u_n), \mathcal{E}_\theta^*(\text{Tok}[\mathcal{R}(q)])) > \mathcal{T}^{tbr} \right], \quad (3)$$

$$\mathcal{U}_q = \left\{ u_n \in \mathcal{U} \mid y_n^{tbr} = 1 \right\}$$

, 其中 sim 表示预训练期间使用的余弦相似度函数, $\mathcal{T}^{tbr}$ 为检索阈值 (通常设为 0.5)。

指标。采用 AUC、Precision 和 Recall 评估基于文本的用户检索任务。AUC 衡量所有决策阈值下相关用户与不相关用户之间的整体排序质量。Precision 衡量所选用户中真正与定向查询相关的用户比例,反映检索结果的可靠性。Recall 衡量全部相关用户中被成功检索出的比例,体现定向结果的覆盖率。这些指标共同评估排序质量、定向准确性与覆盖率,从而对基于文本的用户定向性能进行全面评价。

3.3.3 U2U 检索

基于少量种子用户的用户到用户检索是构建推荐系统的关键步骤。因此,我们还为该小样本任务设计了如图 3 (c) 所示的评估方法。小样本检索任务通过 prompt-tuning 完成。受已有研究 Zhou et al. (2022) 启发,可将种子用户 $\mathcal{D}_s = \{x_i\}_{i=1}^K$ 用作标签来学习能够提升 prompt 描述能力的上下文,具体做法是在输入文本中加入可学习 token $\mathbf{P} = [V_1, \dots, V_m]$ 。

$$\mathbf{P}^* = \arg \min_{\mathbf{P}} \mathcal{L}_{\cos}(f_\theta^*(u_n), f_\theta^*(\mathbf{P} \oplus \text{Tok}(q))) \quad (4)$$

, 其中 $\mathcal{L}_{\cos}$ 表示余弦相似度损失。训练完成后,经调优的 prompt 可作为输入,通过图 3 (b) 中的流程并按照式 3 实现用户定向,如下所示:

$$y_n^{u2ur} = \mathbb{I} \left[\text{sim}(f_\theta^*(u_n), \mathcal{E}_\theta^*(\mathbf{P} \oplus \text{Tok}[q])) > \mathcal{T}^{u2ur} \right], \quad (5)$$

$$\mathcal{U}_q = \left\{ u_n \in \mathcal{U} \mid y_n^{u2ur} = 1 \right\}$$

评估指标。采用与第 3.3.2 节相同的检索指标 AUC、**精确率**和**召回率**。

4 扩展定律分析: 原始数据扩展墙

遵循第 3.3 节建立的协议,我们从三个实际维度对用户表征的规模扩展行为进行实证刻画,即时间跨度 D 、用户规模 N 和模型容量 M 。对于每个维度,我们使用第 3.3 节定义的 AUC、KS 和准确率指标评估下游探测性能。图 4 展示了 (N, D) 网格上的原始规模扩展曲面,其中出现了明显的饱和模式。在这三个维度上,我们都观察到,仅仅增加原始行为数据或模型规模会使下游收益迅速递

减。这表明工业用户表征学习中存在一道原始行为规模扩展之墙：数据量的增长速度远快于有用任务相关信息的增长速度。




图 4 原始行为规模扩展在约 0.03B 用户和 60 天之后趋于饱和。三个探测指标在饱和阈值附近均呈现趋平趋势，表明额外增加原始数据量只会带来递减的下游收益。

4.1 用户规模饱和 (N)

要点 1：只有在行为多样性尚未得到充分覆盖时，增加用户数量才能提升表征质量。超过这一节点后，新增数据将主要由冗余行为模式构成。

我们首先考察增加用户数量能否持续提升表征质量。为此，我们将用户规模 N 从 0.01B 调整至 0.1B，同时将时间跨度固定为 $D = 180$ 天。编码器规模固定为约 0.1B 参数。

如图 4 所示，增加用户规模最初会提升下游探测性能。当 N 从 0.01B 增长至约 0.03B 时，三项指标均呈现明显上升趋势。这表明，在低数据规模区间增加用户能够引入有用的行为多样性，并提高所学习用户表征的可分性。

然而，当 N 超过约 0.03B 后，提升很快减弱。继续将用户规模增加至 0.1B 仅带来微小的性能增益。这种趋平趋势表明，主要行为模式已得到充分覆盖。超过这一节点后，新增用户主要贡献冗余信号，而非新的任务相关信息。

4.2 时间跨度中的冗余 (D)

要点 2：扩展行为窗口在早期阶段有所帮助，但冗长的原始历史主要会引入重复且信息量低的事件。

接下来，我们研究更长的行为历史能否为用户表征学习提供更多有用信息。我们将历史观察窗口 D 从 30 天调整至 120 天，同时将用户规模固定为 $N = 0.1B$ 。

图 4 显示，扩展时间跨度同样会导致收益递减。将 D 从 30 天增加至 60 天会带来明显的性能提升，这表明近期历史行为有助于编码器捕捉更完整的用户偏好和消费模式。

然而，历史长度超过 60 天后，更长历史带来的收益显著减弱。尽管历史输入量翻倍，将观察窗口从 60 天延长至 120 天对下游指标的提升仍然有限。这表明，长时间跨度的 PayBill 序列包含大量重复内容，包括周期性支付和习惯性消费行为。因此，新增历史导致序列长度的增长速度远快于下游相关信息的增长速度。附录图 12 所示的预训练动态也反映了这种饱和模式。随着时间跨度变长，对比对齐损失收敛到越来越相近的最终值，表明额外的历史上下文并未按比例提供更多有用的监督信号。

4.3 模型容量中的质量脱钩 (P)

要点 3: 更大的编码器能够取得更低的预训练损失，但下游准确率趋于饱和。这表明，信息密度而非仅仅模型容量才是关键瓶颈。

我们进一步考察增加模型容量能否克服冗余行为数据所导致的饱和。我们将用户规模和时间跨度分别固定为 $N = 0.1\text{B}$ 和 $D = 180$ 天，这一设置已处于上述识别出的数据饱和区间。随后，在保持所有其他训练配置不变的情况下，将基于 Transformer 的用户编码器从 0.05B 参数扩展到 0.4B 参数。

图 5 显示优化效果与下游表征质量之间存在明显不匹配。更大的模型始终取得更低的训练损失，证实增加模型容量能够提高拟合预训练目标的能力。然而，下游评估呈现出不同趋势。将模型规模从 0.05B 增至 0.2B 可提升测试准确率，但进一步扩展至 0.4B 几乎不再带来收益。尽管参数预算更大、计算成本更高，所学习的用户表征却并未变得更具区分性。

这一结果揭示了损失与质量的脱钩。较低的预训练损失并不必然转化为更好的下游表征质量。在数据饱和区间，额外参数主要用于拟合冗余的行为细节，而非学习更具泛化能力的用户特征。因此，限制因素不只是模型表达能力，而是原始行为输入中所包含的下游相关信号量。




图 5 在固定行为数据的条件下扩展模型参数呈现出强烈的收益递减。更大的模型仍可取得更低的训练损失，但下游评估准确率在中等模型规模之后迅速趋于饱和。这表明，表征质量受到信息密度而非仅仅模型容量的制约。

4.4 行为稠密化的启示与动机

总体要点: 进一步扩展规模的关键不再是处理更多原始行为事件，而是提高每个有效输入单元所承载的下游相关信息。

综合来看，最显著的性能提升仅限于由 $N \leq 0.03\text{B}$ 、 $D \leq 60$ 天和 $M \leq 0.2\text{B}$ 参数所界定的区域。超过这些阈值后，扩展用户规模、时间跨度或模型容量会引入大量额外成本，却只能带来微不足道的下游收益。这些实证结果表明，只有在冗余占据主导之前，增加原始数据量和模型规模才能改善用户表征。

这些观察表明，暴力规模扩展并非工业用户表征学习的可持续路径。一旦原始行为数据进入饱和区间，进一步增加数据量、计算量或模型参数都会导致收益迅速递减。因此，瓶颈不仅是模型容量不足，更在于原始行为序列的信息密度低，其中许多事件是重复的、可预测的，或与下游任务仅弱相关。

这促使我们从以数据量为导向的规模扩展转向以密度为导向的规模扩展。目标不再是依赖更多原始行为事件，而是在固定数据与计算预算下，让每个有效输入单元承载更多下游相关信号。下一节通过残差量化来实现这一思想。我们不再将冗长且重复的原始序列直接输入用户编码器，而是先将其转换为紧凑的离散行为 token，从而为提高行为信息密度和改善编码器利用率提供一种实用机制。

5 分词带来的稠密化收益

我们识别出一道原始行为扩展墙。一旦用户历史由冗余主导，增加用户规模、延长时间窗口或扩大模型容量都会产生递减的下游收益。这表明，进一步提升应来自提高行为输入的信息密度，而非仅仅处理更多原始事件。

为将这种面向密度的方法付诸实践，我们采用残差量化作为实用的行为 tokenizer。我们使用现有 tokenization 方法（例如 RQ-VAE (Lee et al., 2022; He et al., 2025)）作为量化骨干用于工业用户行为建模。具体而言，我们将冗长的多源 PayBill 历史压缩为紧凑的离散行为 token，随后在这些 tokenized 序列上训练相同的基于 Transformer 的用户编码器。该设计使我们能够检验收益是否来自更稠密的输入表征，而非下游编码器架构的变化。

图 6 展示了整体流程。首先，将原始多源 PayBill 行为映射为连续行为嵌入。随后，RQ-VAE tokenizer 通过残差量化将这些嵌入压缩为多层级离散 token。所得 token 序列被输入相同的用户编码器，并使用与原始序列设置相同的用户—文本对比对齐目标进行优化。




图 6 用于行为稠密化的基于 RQ-VAE 的分词方法概览。

5.1 基于 RQ-VAE 的行为 Tokenization

下面介绍残差量化如何将冗长且冗余的行为历史转换为紧凑的离散 token。为使 RQ-VAE 从图像处理适配到工业行为建模，我们首先进行了三项针对任务的修改。第一，分词器不再量化图像潜变量，而是处理多源 PayBill 行为嵌入。第二，我们将输出 token 长度 H 与原始时间跨度 D 解耦，使较长的历史能够由固定数量的行为 token 表示。第三，我们将分词器用作下游用户表示学习的行为稠密化模块，而非仅针对重建质量进行优化。

针对第一项修改，给定用户 u_n ，令 $\mathbf{X}_n = (\mathbf{x}_{n,1}, \mathbf{x}_{n,2}, \dots, \mathbf{x}_{n,L_n})$ 表示从原始行为历史 B_n 中得到的连续嵌入序列，其中每个 $\mathbf{x}_{n,\ell} \in \mathbb{R}^d$ 。直接建模 $\mathbf{X}_n$ 会保留所有原始事件，但同时也保留了来自重复惯例和弱信息交互的大量冗余。

为实现第二项修改并提高表示密度，我们采用局部聚合步骤，将原始序列映射为紧凑的潜在表示

$\mathbf{Z}_n = (\mathbf{z}_{n,1}, \mathbf{z}_{n,2}, \dots, \mathbf{z}_{n,H})$, 其中 $H \ll L_n$ 是行为分词器的固定 token 预算。该步骤将有效输入长度与原始时间跨度解耦, 并促使分词器在紧凑预算下保留信息量最大的行为语义。

对于每个潜向量 $\mathbf{z}_{n,h}$, RQ-VAE 执行多阶段残差量化。在第 m 阶段, 学习得到的码本 $\mathcal{C}^{(m)} = \{\mathbf{c}_1^{(m)}, \dots, \mathbf{c}_{K_m}^{(m)}\}$ 通过选择最近的码字来量化当前残差。该过程可简洁表示为

$$\begin{aligned} \mathbf{r}_{n,h}^{(1)} &= \mathbf{z}_{n,h}, \\ k_{n,h}^{(m)} &= \arg \min_{k \in \{1, \dots, K_m\}} \left\| \mathbf{r}_{n,h}^{(m)} - \mathbf{c}_k^{(m)} \right\|_2^2, \\ \mathbf{r}_{n,h}^{(m+1)} &= \mathbf{r}_{n,h}^{(m)} - \mathbf{c}_{k_{n,h}^{(m)}}^{(m)}, \\ \hat{\mathbf{z}}_{n,h} &= \sum_{m=1}^M \mathbf{c}_{k_{n,h}^{(m)}}^{(m)}, \\ \mathbf{t}_{n,h} &= (k_{n,h}^{(1)}, k_{n,h}^{(2)}, \dots, k_{n,h}^{(M)}). \end{aligned} \quad (6)$$

因此, 完整的用户历史被表示为紧凑的 token 序列 $\mathbf{T}_n = (\mathbf{t}_{n,1}, \mathbf{t}_{n,2}, \dots, \mathbf{t}_{n,H})$ 。

这种残差形式为行为建模提供了自然的由粗到细结构。较早的码本捕获主要的宏观层级语义, 例如稳定的消费类别、日常交通或频繁支付场景。较后的码本则细化残差变化, 例如商户层级的偏好或消费行为的细微变化, 而这些变化仍可能对下游定向具有预测价值。与单一码本相比, 残差量化能够在相同的紧凑 token 预算下保留更细粒度的行为差异。

分词器采用重建目标和承诺损失进行训练

$$\mathcal{L}_{\text{RQ}} = \mathcal{L}_{\text{rec}}(\mathbf{Z}_n, \hat{\mathbf{Z}}_n) + \sum_{m=1}^M \left\| \text{sg}[\mathbf{r}^{(m)}] - \hat{\mathbf{r}}^{(m)} \right\|_2^2 + \beta \sum_{m=1}^M \left\| \mathbf{r}^{(m)} - \text{sg}[\hat{\mathbf{r}}^{(m)}] \right\|_2^2 \quad (7)$$

其中, $\mathcal{L}_{\text{rec}}$ 表示重建损失, $\text{sg}[\cdot]$ 是停止梯度算子, β 控制承诺惩罚。

作为第三项改动, 在分词器预训练完成后, 我们冻结 RQ-VAE, 并采用与原始序列基线相同的对齐目标, 在 $\mathbf{T}_n$ 上训练用户编码器。这种分离使我们能够将下游收益严格归因于行为稠密化, 而非额外的编码器容量。

5.2 离散分词的实验评估




图 7 在匹配的数据规模下, token 化表征优于原始序列, 并且在原始建模趋于饱和的区域差距进一步扩大。子图 (a) 展示完整的二维规模扩展曲面; 子图 (b) 和 (c) 分别展示固定用户规模和固定时间跨度下的截面。

为评估残差量化能否缓解原始行为规模扩展之墙, 我们重复第 4 节的规模扩展协议。在匹配的数据与计算预算下, 我们比较原始序列建模和 token 化序列建模。在原始设置中, 用户编码器直接在

PayBill 序列上训练；在 token 化设置中，先将原始历史转换为 RQ-VAE token，再用相同的用户编码器在所得离散 token 序列上训练。所有模型均采用相同的用户-文本对比对齐目标，并使用相同的下游探测任务和指标进行评估。

图 7 比较了不同规模下的两种设置。沿时间维度，随着观察窗口延长，token 化表征的优势不断扩大。在较短时间跨度下，原始序列仍具有竞争力，因为行为冗余尚且有限。在约 $D \approx 64$ 天时，token 化曲线开始超越原始基线，并随着时间跨度进一步增加而表现出更明显的优势。这表明，残差量化能够从冗长且重复的历史中更好地提炼有用的行为信号。

沿用户规模维度也出现了类似模式。在用户规模较小时，原始模型与 token 化模型表现相近，因为增加用户仍会引入有用的行为多样性。随着用户规模增长、原始规模扩展接近饱和，token 化表征呈现出更明显的优势。在我们的实验中，这一交叉点约出现在 $N \approx 1.2 \times 10^7$ ，此后 token 化表征始终优于原始基线。这表明，当额外原始数据的边际效用降低时，行为稠密化最为有效。

为量化这一效果，令 $\mathcal{P}_{\text{raw}}(s)$ 和 $\mathcal{P}_{\text{tok}}(s)$ 分别表示原始建模与 token 化建模下的下游探测性能，其中 s 可表示时间跨度 D 或用户规模 N 。我们将 token 化收益定义为

$$\Delta(s) = \mathcal{P}_{\text{tok}}(s) - \mathcal{P}_{\text{raw}}(s). \quad (8)$$

从实证上看， $\Delta(s)$ 并非在所有规模下都恒为正。相反，当原始建模进入收益递减区间时，它转为正值并逐渐增大。这一模式证实，RQ-VAE 分词并非只是缩短输入，而是通过抑制重复细节、保留任务相关差异，提高了行为信息的有效密度。




图 8 随数据规模 & 训练计算量扩展的下游任务性能。

5.3 从原始规模扩展到密度规模扩展

实证比较支持行为稠密化的核心动机。一旦原始行为数据达到饱和，表征质量便不再主要受用户数量、历史窗口长度或编码器规模的限制。相反，根本限制因素是每个有效输入单元中所包含的下游相关信号量。在这里，RQ-VAE 分词充当一种实用的密度算子。它将学习问题从建模冗长、冗余的

原始序列转变为建模紧凑且语义集中的 token。通过抑制重复的常规行为并保留任务相关差异，分词器使中等容量的编码器能够更充分地利用长期行为历史，而无需成比例地增加计算负担。

然而，这些结果也揭示了定长分词的局限性。行为信息天然具有异质性：一些历史片段包含丰富而多样的信号，另一些则主要由可预测的常规行为构成。因此，为所有片段分配统一的 token 预算并非最优。这一观察直接引出下一节：我们根据行为复杂度自适应地分配 token 容量，而不是采用固定序列长度。

6 用户行为稠密化定律

我们揭示了原始行为规模扩展最终会趋于饱和，而分词恰好能在这一饱和区间提升性能。该收益反映了一项基本的密度原则：有效表征应在最大化下游相关信息的同时，最小化对冗余历史进行建模的成本。

我们将这一原则形式化为用户行为稠密化定律。我们不把稠密化视为一种启发式配置表，而是将其构建为性能与成本的 Pareto 优化问题。该定律刻画了 Pareto 最优表征容量如何随行为规模演化。RQ-VAE 分词是估计大规模行为数据下这条轨迹的一种具体求解器。




图 9 由三项任务推导得到的、跨不同数据源和分词方法的用户行为稠密化定律。

6.1 行为密度与帕累托最优稠密化

为显式量化这一原则，我们定义行为密度。令 $\mathbf{s} = (s_1, s_2, \dots, s_r)$ 表示广义行为规模状态，其中每个分量刻画一种行为复杂性来源，例如用户规模、时间跨度、模态数量或场景多样性。

令 $C(\phi)$ 表示稠密化表征 ϕ 的实际成本，令 $\hat{C}_{\text{raw}}(\mathbf{s})$ 表示有效原始预算，即原始序列建模达到相同下游效用所需的成本。规模状态 $\mathbf{s}$ 下的最优行为密度定义为

$$\rho^*(\mathbf{s}) = \frac{\hat{C}_{\text{raw}}(\mathbf{s})}{C^*(\mathbf{s})}. \quad (9)$$

行为稠密化的目标是最大化该密度比，使表征趋向更优的性能—成本前沿。

在给定规模状态 $\mathbf{s}$ 下，每种表征变换 ϕ 都会产生下游效用 $U(\phi, \mathbf{s})$ ，并带来表征成本 $C(\phi)$ 。引入部署权衡参数 λ 后，帕累托最优表征可表示为

$$\phi^*(\lambda, \mathbf{s}) = \arg \max_{\phi \in \Phi} [U(\phi, \mathbf{s}) - \lambda C(\phi)]. \quad (10)$$

参数 λ 控制系统对成本的敏感程度。较大的 λ 偏向成本更低的表征，而较小的 λ 则允许在能够带来充分下游增益时采用更高容量。因此，稠密化的目标不是最大化压缩比或 tokenizer 大小，而是专门寻找给定规模下效用—成本权衡最佳的表征。我们将该帕累托目标诱导出的解映射定义为用户行为稠密化定律。

6.2 最小充分 Tokenization 容量

我们使用不同的分词方法对这一理论解进行实例化。令 q_κ 表示由 $\kappa = (K, M, d, H)$ 配置的 RQ-VAE 分词器，其中 K 是码本大小， M 是残差量化阶段数， d 是编码嵌入维度， H 是输出 token 长度。

对于 RQ-VAE 分词，我们对一般表示成本 $C(\phi)$ 进行实例化，采用离散分词器容量 $C_{\text{tok}}(\kappa)$ 。我们将该容量量化为

$$C_{\text{tok}}(\kappa) = HM \log K + \eta H M d, \quad (11)$$

其中，第一项衡量离散码容量，第二项计入连续码嵌入成本。

对于给定规模 (N, D) ，理论上的 Pareto 目标是找到最优配置 κ^* 。然而，下游性能测量包含随机训练噪声，使得在 λ 上进行精确的连续优化并不稳定。因此，我们采用一种稳健的约束形式来近似 Lagrangian Pareto 目标。首先计算近似最优效用

$$U^*(N, D) = \max_{\kappa \in \mathcal{K}} U(q_\kappa, N, D), \quad (12)$$

随后严格选择能够达到该效用下界的最小配置：

$$\kappa^*(N, D) = \arg \min_{\kappa \in \mathcal{K}} C_{\text{tok}}(\kappa) \quad \text{subject to} \quad U(q_\kappa, N, D) \geq U^*(N, D) - \epsilon. \quad (13)$$

这一约束形式选择了一个对随机训练噪声和离散分词器配置均稳健的帕累托有效点。它能够可靠地识别最小充分容量，同时避免选择那些额外容量对下游增益可以忽略不计的更大配置。

6.3 诱导出的尺度定律

为了得到该解映射的紧凑经验形式，我们研究了不同规模状态下 Pareto 最优解的轨迹。在冗余占主导的区间，token 化表征的效用前沿相对于表征容量 C 呈现收益递减。该前沿的局部近似为

$$U(C, \mathbf{s}) = U_\infty(\mathbf{s}) - a(\mathbf{s})C^{-b}, \quad (14)$$

其中, $U_\infty(\mathbf{s})$ 是规模 $\mathbf{s}$ 下可达到的最大效用, $a(\mathbf{s})$ 衡量容量受限时的剩余效用差距, $b > 0$ 控制前沿的曲率。

将式 14 代入连续帕累托目标可得

$$C^*(\lambda, \mathbf{s}) = \arg \max_C [U(C, \mathbf{s}) - \lambda C]. \quad (15)$$

一阶条件为

$$a(\mathbf{s})b(C^*(\lambda, \mathbf{s}))^{-b-1} = \lambda, \quad (16)$$

解得

$$C^*(\lambda, \mathbf{s}) = \left(\frac{a(\mathbf{s})b}{\lambda} \right)^{\frac{1}{b+1}}. \quad (17)$$

假设尺度相关的间隙项按照一般幂律 $a(\mathbf{s}) = a_0 \prod_{i=1}^r (s_i/s_{i,0})^{\gamma_i}$ 增长, 我们可将公式 17 改写为

$$\ln C^*(\lambda, \mathbf{s}) = \beta + \sum_{i=1}^r \alpha_i \ln \frac{s_i}{s_{i,0}} - \alpha_\lambda \ln \lambda, \quad (18)$$

其中 $\alpha_i = \gamma_i/(b+1)$ 。在实际部署中, 权衡参数 λ 通常保持固定。因此, 公式 18 可化简为用户行为稠密化定律的一般操作形式:

$$\boxed{\ln C^*(\mathbf{s}) = \beta + \sum_{i=1}^r \alpha_i \ln \frac{s_i}{s_{i,0}}} \quad (19)$$

这一推导给出了收益递减效用前沿下帕累托最优容量的尺度依赖形式。它表明, 最优稠密化表示所需的容量会随行为复杂度呈幂律增长。

在我们的扩展实验中, 行为规模状态被具体实例化为 $\mathbf{s} = (N, D)$, 其中 N 表示用户规模, D 表示时间跨度。因此, 式 21 可简化为任务特定的经验形式

$$\ln C^*(N, D) = \beta + \alpha_N \ln \frac{N}{N_0} + \alpha_D \ln \frac{D}{D_0} \quad (20)$$

这证实 N 和 D 并非该定律的严格前提, 而只是本工作用于参数化行为规模的两个可控维度。

我们将公式 21 称为用户行为稠密化定律。在标量设置下, 其形式为

$$\boxed{\ln C^*(s) = \beta + \alpha \ln(s/s_0)} \quad (21)$$

为进一步分析, 系数 α_i 应概括特定行为数据分布与码空间表达形式下的容量轨迹, 可表示为

$$\alpha_i = f_i(\mathcal{U}_d, \mathcal{E}_\phi), \quad (22)$$

其中, $\mathcal{U}_d$ 刻画行为多样性和冗余性等数据属性, 而 $\mathcal{E}_\phi$ 刻画分词方法 ϕ 如何表达可用编码空间, 包括码本组织、残差深度和容量分配。分析表明, 数据源内部的多样性应与分词容量正相关, 因为更丰富的信息应映射到更大的表示空间以避免冲突。在本研究中, 为定量描述该属性, 我们使用基于 LLM 的文本嵌入 (例如 Qwen3-Embedding) 的平均 k-NN 余弦距离作为度量, 可表示为:

$$\mathcal{U}_d = \frac{1}{Mk} \sum_{i=1}^M \sum_{j \in \text{kNN}(i)} d(i, j) \quad (23)$$

6.4 解轨迹的实证验证

图 9 给出了不同实测数据规模下经验得到的最小充分 tokenization 配置。这些实测配置呈现出清晰的结构模式：随着用户规模或时间跨度增加，最小充分 tokenization 容量也单调增加。

通过这些经验配置上拟合公式 20，我们估计出不同数据源在图 9 中的扩展系数这一量化结果验证了我们的理论表述。在冗余主导区间，行为 tokenization 的帕累托最优容量严格按照用户规模和时间跨度的幂律函数增长。

关键在于，这并不意味着更大的 tokenizer 无条件更优；相反，它说明更大的行为规模需要更大的最小充分容量。超过该最优容量几乎不会带来性能收益，却会严重降低成本效率。因此，实测配置及其拟合系数构成了在大规模行为数据下估计所得的用户行为稠密化定律经验解轨迹。

我们还根据经验最小容量轨迹估计系数，并得到 α_i 与 $\mathcal{U}_d$ 之间的近似关系 $\alpha_i \propto \mathcal{U}_d^2$ ；为此，我们开展了一系列实验，以确定适配每种输入用户数据规模的最小充分配置，并使用帕累托最优方法拟合该定律（类似于 (Cherti et al., 2023)）。

为确保泛化性和可靠性，验证实验在三种 tokenization 方法——RQ-VAE、VQ-VAE 和 SARQ——以及三种不同用户数据源——Paybill、SPM 和 Miniprogram——上开展。我们还评估了第 3.3 节中的全部三项任务。对于每种 tokenization 方法的容量配置，我们计算所有可用 SID 的表征空间大小：RQ-VAE 的该值通过 $C_{RQ-VAE} = K^M$ 获得，VQ-VAE 的 C_{VQ-VAE} 由训练期间指定的搜索空间决定，而 SARQ 的 C_{SARQ} 是激活的 SID 容量空间。对于最优配置 C^* ，我们采用第 6.1 节中的搜索方法。

实验验证结果如图 9 所示。根据结果，我们总结出以下规律：

在对数输入尺度上呈近似线性关系。 在所有输入数据源和评估任务上，最优容量与输入用户数据规模在对数尺度上呈近似线性关系 ($\ln(C^*)$ 和 $\ln(s)$)，数据点的分布清楚地体现了这一点。

不同下游任务呈现一致趋势。 可以观察到，在所有任务中，最小充分配置与输入数据规模的变化趋势具有相似模式。在给定 tokenization 方法和数据源的情况下（图 9 (a)、(b) 或 (c) 中的同色曲线），由 (I)、(II) 和 (III) 中帕累托前沿得到的 $\ln(C^*)$ 与 $\ln(s)$ 之间斜率，在数值估计误差范围内可视为相同。

斜率受 Tokenization 方法影响。 对于不同 tokenization 方法，拟合分布有所不同，如各子图中的不同颜色线条所示。还可以观察到，与 RQ-VAE 相比，VQ-VAE 的斜率值更高，而 SARQ 的斜率值最低。我们的分析表明，这与各方法的表征空间冗余 $\mathcal{E}_\phi$ 有关。VQ-VAE 存在冗余存储问题，因为相似表征需要多个完整 SID，造成共享结构浪费。相比之下，RQ-VAE 支持 SID 的组合式复用从而减少码本中的 $\mathcal{E}_\phi$ 。然而，在 RQ-VAE 理论上可能的 K^M 种组合中，许多组合无效或被选中的概率极低；SARQ 能在一定程度上缓解这一问题。

斜率与源内独特性成正比。 通过比较图 9 各列子图中同色线条的斜率（例如 (a)、(b) 和 (c) 中的 (I)），我们还观察到，在同一种 tokenization 方法下，斜率很可能与数据源内部独特性 $\mathcal{U}_d$ 的平方值保持近似正比关系：三个数据源之间的比率约为 1 : 1.15 : 0.92，而 $\mathcal{U}_d$ 的比率约为 1 : 1.07 : 0.96（在 10^{-2} 数值误差范围内）。这一发现为基于 tokenization 的用户表征学习提供了指导：使用常见 tokenization 方法（固定 $\mathcal{E}_\phi$ ）时，可依据公式 23 计算 $\mathcal{U}_d$ ，再通过公式 21 和公式 22 得到最优码本容量配置。

7 新方法：基于自适应长度门控的 RQ-VAE 量化

遵循第 6 节的用户行为稠密化定律，我们进一步从规模层面的容量选择转向实例层面的容量分配。该定律表明，最优的稠密化表征应使用输入 token 成本所需的最小充分容量。然而，包括基于 VQ-VAE 和 RQ-VAE 的分词器在内的定长分词方法，会为所有行为时段分配相同数量的码级。这种统一分配忽略了用户行为的异质性。一些时段包含多样且模糊的行为信号，需要更深的残差码；另一些时段则主要由常规或重复行为构成，可用更短的码表示。

这促使我们提出一种变长分词策略。其核心原则很简单：只有当一个新残差码的预期边际效用大于其边际表征成本时，才应使用该码。因此，我们不再为所有行为时段选择单一的全局码长，而是自适应地决定每个行为表征是否应继续进入下一个量化层级。这提供了用户行为稠密化定律在实例层面的实现。

7.1 方法

为实现这一实例级容量分配原则，如图 10 所示，我们提出 自适应长度门控网络 (ALGN)，用于为用户行为数据生成可变长度的语义 ID。ALGN 构建于残差量化架构之上。在每个量化层级，它都会判断当前行为表示是否仍需要额外的残差编码。




图 10 自适应变长 tokenization 方法为高信息量行为时段分配更多编码，为常规或冗余时段分配更少编码；与固定长度基线相比，它以更少的平均 token 数实现相当或更高的准确率。

ALGN 的设计遵循边际效用视角。对于层级 l 上的行为表征，只有剩余信息仍足以抵偿额外编码成本时，继续使用下一个残差编码才是有益的。由于 tokenization 过程中无法直接观测真实的下游边际效用，我们使用两个信号对其进行近似。

首先，残差范数衡量当前编码路径尚未解释的信息量。令 r_{l-1} 表示层级 l 之前的残差，令 $e_{l,m}$ 表示该层级选中的编码嵌入。残差范数定义为

$$R_l = \|\mathbf{r}_{l-1} - \mathbf{e}_{l,m}\|_2. \quad (24)$$

较大的 R_l 表明当前编码仍不足以重建行为表示，因此增加一个残差编码可能带来有意义的效用。较小的 R_l 则表示剩余信息已大部分得到解释，继续量化过程可能导致收益递减。

其次，编码不确定性衡量当前语义分配的模糊程度。令 $p(m_l | m_{<l})$ 表示在先前编码选择条件下选择编码 m_l 的条件概率。我们将累积不确定性定义为

$$E_l = -\sum_{k=1}^l \log p(m_k | m_{<k}). \quad (25)$$

较大的 E_l 表示编码路径的不确定性更高，通常对应更复杂、更模糊或信息更丰富的行为模式。较小的 E_l 表明 tokenizer 对当前语义路径较为确信，因此不太需要额外的编码层级。

基于这两个代理信号，ALGN 将层级 l 上的继续概率估计为

$$g_l = \sigma(\text{sp}(w_R)R_l + \text{sp}(w_E)E_l - \text{sp}(w_C)c_l + b), \quad (26)$$

其中, w_R 、 w_E 、 w_C 和 b 是可学习参数, $\sigma(\cdot)$ 是 sigmoid 函数, $\text{sp}(\cdot)$ 是用于保持权重为正的 Softplus 函数。这里, c_l 表示激活层级 l 的边际成本, 例如累积编码长度或层级索引。该形式编码了预期的单调行为: 当残差信息或不确定性较高时, 继续量化的概率增大; 当额外编码成本变大时, 该概率减小。

随后, 激活的语义 ID 长度由继续量化概率首次低于阈值的层级决定:

$$L_{\text{act}} = \min \{l : g_l \leq \theta\}, \quad (27)$$

其中 θ 是停止阈值。若没有任何层级满足停止条件, tokenizer 将使用允许的最大长度 L_{max} 。

我们使用重构目标和长度分布正则项训练变长 tokenizer:

$$\mathcal{L} = \mathcal{L}_{\text{rec}}^{\text{act}} + \lambda \text{KL}(P_{\text{len}} \| Q), \quad (28)$$

其中 $\mathcal{L}_{\text{rec}}^{\text{act}}$ 是仅使用激活残差层级计算的重构损失, P_{len} 是由 ALGN 产生的激活编码长度经验分布。先验 Q 控制期望长度分布。在实践中, 我们采用几何分布等衰减先验:

$$Q(l) = (1 - \gamma)^{l-1} \gamma. \quad (29)$$

该正则项防止分词器以平凡方式激活所有残差层级, 并鼓励形成紧凑的长度分布。与直接惩罚每个样本的长度相比, 分布先验更灵活, 因为它可以纳入有关用户行为长尾特性的先验知识。

总体而言, ALGN 为行为分词实现了一条局部边际效用规则。定长 RQ-VAE 为每个行为时段分配相同容量, 而 ALGN 则根据剩余残差信息、量化不确定性和边际码成本动态分配容量。因此, 高信息量时段会获得更深的语义 ID, 而常规或冗余时段会提前停止。这将用户行为稠密化定律从规模层面的容量原则转化为实例层面的自适应分词机制。

7.2 实验结果

我们首先比较各方法的下游表示质量和所使用的 SID 容量。如第 5 节所研究, 所有分类与检索任务均呈现相似的性能趋势, 因此这里只报告 PayBill 数据上的分类指标。性能比较使用序列长度为 180 天、用户数为 0.1B 的数据集规模进行, 所有方法的输入设置保持一致。我们将长度先验 Q 在式 28 中设为参数为 $\gamma = 0.3$ 的几何分布, 并将 ALGN 与四种基线进行比较: 固定长度 RQ-VAE、基于先验的启发式方法、仅使用残差范数的变体, 以及仅使用信息熵的变体。该比较用于评估联合利用残差信息和语义不确定性的门控机制, 能否比固定容量、仅先验或单信号分配实现更优的容量分配。

7.2.1 比较

表 3 的结果表明, ALGN 超越了最佳基线 SARQ, AUC/KS/Acc 分别提高 1.07%/2.03%/0.36%, 同时节省 13.23% 的容量。

可变长度变体之间的比较进一步支持了 ALGN 的设计。启发式方法略微减少了 SID 使用量, 但只带来了有限的性能提升, 这表明仅凭先验长度统计不足以实现实例级容量分配。残差范数和信息熵各自都带来了更显著的改进, 说明剩余重建信息和语义不确定性都是估计额外编码层级边际效用的有效信号。ALGN 通过联合建模残差信息、编码不确定性和边际编码成本, 实现了最佳性能和最低的 SID 使用量。

这些结果从实例层面验证了用户行为稠密化定律。ALGN 不为所有行为时段分配固定容量, 而是仅在额外容量可能带来有用信息时分配更多残差编码。因此, 高信息量时段会获得更深的语义 ID, 而常规或冗余时段则会提前停止。这在降低平均分词成本的同时提升了下游表示质量。

表 3 不同 tokenization 方法的比较。使用 SID 容量占用率衡量效率，并报告分类指标以评估性能。

方法	容量 (%) ↓	AUC (%) ↑	KS (%) ↑	Acc (%) ↑
RQ-VAE(Lee et al., 2022)	100.00	74.56	39.02	82.44
VQ-VAE(van den Oord et al., 2017)	316.23	73.45	37.95	82.47
RQ-Kmeans(Deng et al., 2025)	100.00	73.77	38.34	82.85
SARQ(Wang et al., 2026)	76.24	75.36	41.28	83.16
ALGN	63.47	76.43	43.31	83.52

7.2.2 消融研究

表 4 ALGN 各组成部分的消融研究。

方法	容量 (%) ↓	AUC (%) ↑	KS (%) ↑	Acc (%) ↑
RQ-VAE(Lee et al., 2022)	100.00	74.56	39.02	82.44
启发式变长基线	86.91	74.43	38.10	82.39
不使用不确定性信号	77.83	75.11	40.21	82.77
不使用残差信号	76.24	75.36	41.28	83.16
不使用正则化	73.42	76.01	42.21	83.35
使用 SID 长度正则化	63.16	76.22	42.99	83.47
使用随机分布正则化	70.15	76.16	42.88	83.45
ALGN	63.47	76.43	43.31	83.52

与启发式变长基线相比，ALGN 通过自适应可变 SID 长度控制，将容量占用率从 86.91% 降至 63.47%，同时分别将 AUC/KS/Acc 提升 2.00%/5.21%/1.14%。

移除任一自适应信号都会降低效率和性能。不使用不确定性信号时，容量占用率上升至 77.83%，而 AUC/KS/Acc 相比 ALGN 分别下降 1.32/3.10/0.75%。移除残差信号也会导致类似的性能下降。

正则化消融实验进一步验证了所提出的设计。移除正则化后，容量占用率上升至 73.42%，AUC/KS/Acc 降至 76.01%/42.21%/83.35%。尽管直接进行 SID 长度正则化可实现略低的容量占用率，但 ALGN 的 AUC/KS/Acc 分别提高 0.21/0.32/0.05%；由于融入了有关用户行为长尾特性的先验知识，它展现出最佳的整体效率—性能权衡。与随机分布正则化相比，其 AUC/KS/Acc 也分别提高 0.27/0.43/0.07%，同时容量占用率降低 6.68%。

对稠密化定律的影响。 我们还开展实验，以评估 ALGN 对所提出稠密化定律的影响。图 11 中的结果表明，我们的方法有效地将扩展斜率降低至 ~ 0.59 ，这可能是因为减少了表征空间冗余 $\mathcal{E}_\phi$ 。

8 结论 & 局限性

更多数据和更大模型总能产生更优用户表示的观念，多年来一直支撑着工业界对行为序列建模的投入。本工作首次对这一假设进行了系统性的大规模实证检验。基于覆盖数亿用户的支付宝生产数据，我们证明了三种传统扩展轴——用户规模、时间跨度和模型容量——都存在明确的饱和阈值。用户数超过 0.03B 或时间窗口超过 60 天后，收益会迅速递减。更引人注目的是，在数据固定时，将模型参数扩展至 0.2B 以上虽会持续降低训练损失，却完全无法提升下游准确率，这说明优化目标与表示质量并非同一回事。这三项发现共同界定了工业用户行为建模的 **扩展墙**，并指向同一个诊断结论：瓶颈不在于数据量，而在于每个行为 token 所承载的预测信息。




图 11 分类任务下 ALGN 对稠密化定律的影响。

这一发现引出了我们的核心主张：从数据扩展转向 密度扩展。我们提出 数据稠密化的概念，与推动紧凑语言模型设计进步的模型层面稠密化原则形成明确呼应。通过 RQ-VAE 分词和匹配预算的评估协议，我们将这一原则付诸实践：紧凑、固定长度的离散编码比原始序列承载更多与任务相关的信号。稠密化表示使扩展曲线转向更有利的指数，从而让处理较短输入的小型编码器能够超越在更长原始历史上训练的大型模型。

对实践者而言，我们的发现可转化为具体且可部署的指导原则。本文报告的饱和阈值可直接为生产环境中的数据保留策略、训练预算分配和模型架构决策提供依据。RQ-VAE 分词生成的离散 token 天生与任务无关，可复用于用户定向、画像预测、CTR 估计等多种任务，从而将分词器的一次性训练成本分摊到整个应用组合中。在不加区分地扩展数据所带来的计算和环境成本日益受到审视之际，密度扩展提供了一种有原则的替代方案：从已有数据中获得更优表示，而不是以不断增加的成本收集更多数据。

我们承认当前研究存在一项局限：实验聚焦于单一数据模态，稠密化定律对视频消费等其他行为模态的泛化能力仍有待验证。我们也在公共基准数据集上进一步评估所提出的定律，以检验其在单一平台采集数据之外的稳健性。

这些局限指向了更广泛的研究议程。我们认为，在大规模用户建模中，信息密度应与模型容量和数据量一道被视为首要设计目标。其影响超越了本工作：如果密度能够被度量和优化，那么实际问题就会从“我们能收集多少数据？”转变为“我们如何设计使每个 token 的信号最大化的表示？”。我们邀请研究社区共同探索自适应分词策略、多模态密度估计以及数据稠密化的理论基础，携手 **从扩展墙迈向稠密化收益**：构建不依赖消耗更多数据，而是通过从已有数据中提取更多信息来实现扩展的表示系统。

参考文献

Newsha Ardalani, Carole-Jean Wu, Zeliang Chen, Bhargav Bhushanam, and Adnan Aziz. Understanding scaling laws for recommendation models. arXiv preprint arXiv:2208.08489, 2022.

Yue Cao, Xiaojiang Zhou, Jiaqi Feng, Peihao Huang, Yao Xiao, Dayao Chen, and Sheng Chen. Sampling is all

- you need on modeling long-term user behaviors for ctr prediction. In Proceedings of the 31st ACM International Conference on Information & Knowledge Management, pages 2974–2983, 2022.
- Yukuo Cen, Jianwei Zhang, Xu Zou, Chang Zhou, Hongxia Yang, and Jie Tang. Controllable multi-interest framework for recommendation. In Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining, pages 2942–2951, 2020.
- Yunkee Chae, Woosung Choi, Yuhta Takida, Junghyun Koo, Yukara Ikemiya, Zhi Zhong, Kin Wai Cheuk, Marco A Martínez-Ramírez, Kyogu Lee, Wei-Hsiang Liao, et al. Variable bitrate residual vector quantization for audio coding. In ICASSP 2025-2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), pages 1–5. IEEE, 2025.
- Zheng Chai, Qin Ren, Xijun Xiao, Huizhi Yang, Bo Han, Sijun Zhang, Di Chen, Hui Lu, Wenlin Zhao, Lele Yu, et al. Longer: Scaling up long sequence modeling in industrial recommenders. In Proceedings of the Nineteenth ACM Conference on Recommender Systems, pages 247–256, 2025.
- Mehdi Cherti, Romain Beaumont, Ross Wightman, Mitchell Wortsman, Gabriel Ilharco, Cade Gordon, Christoph Schuhmann, Ludwig Schmidt, and Jenia Jitsev. Reproducible scaling laws for contrastive language-image learning. In 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pages 2818–2829. IEEE, 2023.
- Mostafa Dehghani, Stephan Gouws, Oriol Vinyals, Jakob Uszkoreit, and Łukasz Kaiser. Universal transformers. In International Conference on Learning Representations, 2019.
- Jiaxin Deng, Shiyao Wang, Kuo Cai, Lejian Ren, Qigen Hu, Weifeng Ding, Qiang Luo, and Guorui Zhou. Onerec: Unifying retrieve and rank with generative recommender and iterative preference alignment. arXiv preprint arXiv:2502.18965, 2025.
- Bin Dou, Baokun Wang, Yun Zhu, Xiaotong Lin, Yike Xu, Xiaorui Huang, Yang Chen, Yun Liu, Shaoshuai Han, Yongchao Liu, et al. Transferable and forecastable user targeting foundation model. In Companion Proceedings of the ACM on Web Conference 2025, pages 181–190, 2025.
- Xinshun Feng, Mingzhe Liu, Yi Qiao, Tongyu Zhu, Leilei Sun, and Shuai Wang. Behavior tokens speak louder: Disentangled explainable recommendation with behavior vocabulary. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 40, pages 21092–21100, 2026.
- Alex Graves. Adaptive computation time for recurrent neural networks. arXiv preprint arXiv:1603.08983, 2016.
- Wei Guo, Hao Wang, Luankang Zhang, Jin Yao Chin, Zhongzhou Liu, Kai Cheng, Qiushi Pan, Yi Quan Lee, Wanqi Xue, Tingjia Shen, et al. Scaling new frontiers: Insights into large recommendation models. arXiv preprint arXiv:2412.00714, 2024.
- Chuan He, Yang Chen, Wuliang Huang, Tianyi Zheng, Jianhu Chen, Bin Dou, Yice Luo, Yun Zhu, Baokun Wang, Yongchao Liu, et al. Learning unified user quantized tokenizers for user representation. arXiv preprint arXiv:2508.00956, 2025.
- Yupeng Hou, Jianmo Ni, Zhankui He, Naveen Sachdeva, Wang-Cheng Kang, Ed H Chi, Julian McAuley, and Derek Zhiyuan Cheng. Actionpiece: Contextually tokenizing action sequences for generative recommendation. arXiv preprint arXiv:2502.13581, 2025.
- Edward J Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. Lora: Low-rank adaptation of large language models. arXiv preprint arXiv:2106.09685, 2021.
- Iris AM Huijben, Matthijs Douze, Matthew Muckley, Ruud JG Van Sloun, and Jakob Verbeek. Residual quantization with implicit neural codebooks. arXiv preprint arXiv:2401.14732, 2024.
- Wang-Cheng Kang and Julian McAuley. Self-attentive sequential recommendation. In 2018 IEEE international conference on data mining (ICDM), pages 197–206. IEEE, 2018.
- Aditya Kusupati, Gantavya Bhatt, Aniket Rege, Matthew Wallingford, Aditya Sinha, Vivek Ramanujan, William Howard-Snyder, Kaifeng Chen, Sham Kakade, Prateek Jain, and Ali Farhadi. Matryoshka representation learning. In Advances in Neural Information Processing Systems, volume 35, 2022.
- Doyup Lee, Chiheon Kim, Saehoon Kim, Minsu Cho, and Wook-Shin Han. Autoregressive image generation using residual quantization. In 2022 IEEE/CVF conference on computer vision and pattern recognition (CVPR), pages 11513–11522. IEEE, 2022.

- Chao Li, Zhiyuan Liu, Mengmeng Wu, Yuchi Xu, Huan Zhao, Pipei Huang, Guoliang Kang, Qiwei Chen, Wei Li, and Dik Lun Lee. Multi-interest network with dynamic routing for recommendation at tmall. In Proceedings of the 28th ACM international conference on information and knowledge management, pages 2615–2623, 2019.
- Qijiong Liu, Hengchang Hu, Jiahao Wu, Jieming Zhu, Min-Yen Kan, and Xiao-Ming Wu. Discrete semantic tokenization for deep ctr prediction. In Companion Proceedings of the ACM Web Conference 2024, pages 919–922, 2024a.
- Qijiong Liu, Jieming Zhu, Zhaocheng Du, Lu Fan, Zhou Zhao, and Xiao-Ming Wu. Learning multi-aspect item palette: A semantic tokenization framework for generative recommendation. arXiv preprint arXiv:2409.07276, 2024b.
- Aaron van den Oord, Yazhe Li, and Oriol Vinyals. Representation learning with contrastive predictive coding. arXiv preprint arXiv:1807.03748, 2018.
- Qi Pi, Weijie Bian, Guorui Zhou, Xiaoqiang Zhu, and Kun Gai. Practice on long sequential user behavior modeling for click-through rate prediction. In Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining, pages 2671–2679, 2019.
- Qi Pi, Guorui Zhou, Yujing Zhang, Zhe Wang, Lejian Ren, Ying Fan, Xiaoqiang Zhu, and Kun Gai. Search-based user interest modeling with lifelong sequential behavior data for click-through rate prediction. In Proceedings of the 29th ACM International Conference on Information & Knowledge Management, pages 2685–2692, 2020.
- Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In International conference on machine learning, pages 8748–8763. PMLR, 2021.
- Shashank Rajput, Nikhil Mehta, Anima Singh, Raghunandan Hulikal Keshavan, Trung Vu, Lukasz Heldt, Lichan Hong, Yi Tay, Vinh Tran, Jonah Samost, et al. Recommender systems with generative retrieval. Advances in Neural Information Processing Systems, 36:10299–10315, 2023.
- Qin Ren, Zheng Chai, Xijun Xiao, Yuchao Zheng, and Di Wu. Longretriever: Towards ultra-long sequence based candidate retrieval for recommendation. arXiv preprint arXiv:2508.15486, 2025.
- Jiwan Seo and Joonhyuk Kang. Rate-adaptive quantization: A multi-rate codebook adaptation for vector quantization-based generative models. arXiv preprint arXiv:2405.14222, 2024.
- Tingjia Shen, Hao Wang, Chuhan Wu, Jin Yao Chin, Wei Guo, Yong Liu, Huifeng Guo, Defu Lian, Ruiming Tang, and Enhong Chen. P-Law: Predicting quantitative scaling law with entropy guidance in large recommendation models. In Advances in Neural Information Processing Systems, volume 38, 2025.
- Kyuyong Shin, Hanock Kwak, Su Young Kim, Max Nihlén Ramström, Jisu Jeong, Jung-Woo Ha, and Kyung-Min Kim. Scaling law for recommendation models: Towards general-purpose user representations. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 37, pages 4596–4604, 2023. doi: 10.1609/aaai.v37i4.25582.
- Zihua Si, Lin Guan, ZhongXiang Sun, Xiaoxue Zang, Jing Lu, Yiqun Hui, Xingchao Cao, Zeyu Yang, Yichen Zheng, Dewei Leng, et al. Twin v2: Scaling ultra-long user behavior sequence modeling for enhanced ctr prediction at kuaishou. In Proceedings of the 33rd ACM International Conference on Information and Knowledge Management, pages 4890–4897, 2024.
- Fei Sun, Jun Liu, Jian Wu, Chao Pei, Xiaoyu Lin, Wenwu Ou, and Peng Jiang. Bert4rec: Sequential recommendation with bidirectional encoder representations from transformer. In Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM), pages 1441–1450, 2019.
- Aaron van den Oord, Oriol Vinyals, and Koray Kavukcuoglu. Neural discrete representation learning. In Advances in Neural Information Processing Systems, volume 30, 2017.
- Huimu Wang, Xingzhi Yao, Yiming Qiu, Qinghong Zhang, Haotian Wang, Yufan Cui, Songlin Wang, Sulong Xu, and Mingming Li. Towards efficient and generalizable retrieval: Adaptive semantic quantization and residual knowledge transfer. In Proceedings of the 49th International ACM SIGIR Conference on Research and Development in Information Retrieval, pages 4987–4992, 2026.
- Yutian Xiao, Shukuan Wang, Binhao Wang, Zhao Zhang, Yanze Zhang, Shanqi Liu, Chao Feng, Xiang Li, and Fuzhen Zhuang. Mars: Modality-aligned retrieval for sequence augmented ctr prediction. arXiv preprint arXiv:2509.01184, 2025.

- Jiaqi Zhai, Lucy Liao, Xing Liu, Yueming Wang, Rui Li, Xuan Cao, Leon Gao, Zhaojie Gong, Fangda Gu, Michael He, et al. Actions speak louder than words: Trillion-parameter sequential transducers for generative recommendations. arXiv preprint arXiv:2402.17152, 2024.
- Gaowei Zhang, Yupeng Hou, Hongyu Lu, Yu Chen, Wayne Xin Zhao, and Ji-Rong Wen. Scaling law of large sequential recommendation models. In Proceedings of the 18th ACM Conference on Recommender Systems, pages 444–453. ACM, 2024a. doi: 10.1145/3640457.3688129.
- Gaowei Zhang, Yupeng Hou, Hongyu Lu, Yu Chen, Wayne Xin Zhao, and Ji-Rong Wen. Scaling law of large sequential recommendation models. In Proceedings of the 18th ACM Conference on Recommender Systems, pages 444–453, 2024b.
- Weinan Zhang, Tianqi Liu, Jun Luo, Likang Zou, Gang Liu, and Xing Xiong. Deep learning for matching in search and recommendation. Foundations and Trends in Information Retrieval, 14(2–3):102–288, 2021.
- Yanzhao Zhang, Mingxin Li, Dingkun Long, Xin Zhang, Huan Lin, Baosong Yang, Pengjun Xie, An Yang, Dayiheng Liu, Junyang Lin, et al. Qwen3 embedding: Advancing text embedding and reranking through foundation models. arXiv preprint arXiv:2506.05176, 2025.
- Zhicheng Zhang, Zhaocheng Du, Jieming Zhu, Jiwei Tang, Fengyuan Lu, Wang Jiaheng, Song-Li Wu, Qianhui Zhu, Jingyu Li, Hai-Tao Zheng, et al. Length-adaptive interest network for balancing long and short sequence modeling in ctr prediction. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 40, pages 28627–28635, 2026.
- Guorui Zhou, Na Mou, Ying Fan, Qi Pi, Weijie Bian, Chang Zhou, Xiaoqiang Zhu, and Kun Gai. Deep interest evolution network for click-through rate prediction. In Proceedings of the AAAI conference on artificial intelligence, volume 33, pages 5941–5948, 2019.
- Kaiyang Zhou, Jingkang Yang, Chen Change Loy, and Ziwei Liu. Learning to prompt for vision-language models. International journal of computer vision, 130(9):2337–2348, 2022.
- Wen-Ji Zhou, Yuhang Zheng, Yinfu Feng, Yunan Ye, Rong Xiao, Long Chen, Xiaosong Yang, and Jun Xiao. Encode: Breaking the trade-off between performance and efficiency in long-term user behavior modeling. IEEE Transactions on Knowledge and Data Engineering, 37(1):265–277, 2024.
- Jieming Zhu, Mengqun Jin, Qijiong Liu, Zexuan Qiu, Zhenhua Dong, and Xiu Li. Cost: Contrastive quantization based semantic tokenization for generative recommendation. In Proceedings of the 18th ACM Conference on Recommender Systems, pages 969–974, 2024.
- Pablo Zivic, Hernan Vazquez, and Jorge Sánchez. Scaling sequential recommendation models with transformers. In Proceedings of the 47th international ACM SIGIR conference on research and development in information retrieval, pages 1567–1577, 2024.

9 附录

9.1 不同时间跨度下的训练损失收敛情况

预训练期间的训练损失是用于扩展比较的另一项信号，它反映预训练目标的优化行为。该损失根据式 2 计算。

从图 12 可以观察到，随着行为时间跨度从 30 天扩展到 180 天，训练损失收敛到逐渐更低的数值，从约 8.28 降至 8.15。与此同时，对比学习准确率呈现一致的正向规模扩展趋势：T2U 准确率从约 0.29 提升至 0.42，U2T 准确率从约 0.35 提升至 0.50，表明更大规模的行为输入能够改善两个方向上的表征对齐。

9.2 跨不同数据源的泛化能力

如图 13 所示，该压缩策略在异构数据源之间表现出很强的泛化能力和适应性。当把从 Bill 数据集推导出的压缩配置直接迁移到 SPM 和 Miniprogram 时，所保留的 AUC 分别约为数据源一致设置下 AUC 的 95.0% 和 97.5%。KS 也呈现类似趋势，在 SPM 和 Miniprogram 上的保留率分别为




图 12 在跨越 $D \in \{30, 60, 90, 120, 180\}$ 天的行为序列上预训练的模型，其 100,000 个训练步内的对比对齐损失。尽管所有配置均能收敛，但随着 D 增大，最终损失的降幅急剧减小。 $D \geq 90$ 天对应的曲线几乎重合，表明额外历史天数贡献的新优化信号极少，这与第 4 节观察到的下游指标饱和现象一致。




图 13 数据源泛化。

83.2% 和 88.5%。这些结果表明，该压缩策略并不强烈依赖特定数据源的特征，在跨源分布偏移下仍能保持有竞争力的预测性能，体现出其在多样化数据环境中的稳健性和实际应用价值。