

EST：通过统一建模迈向点击率预测的高效扩展定律

Mingyang Liu^{*}, Yong Bai^{*}, Zhangming Chan[‡], Sishuo Chen^{*}

Xiang-Rong Sheng^a, Han Zhu^a, Jian Xu^a, Xinyang Chen[†]

{mingyangliu1024, chenxinyang95}@gmail.com

{baiyong.by, zhangming.czm, chensishuo.css, xiangrong.sxr, zhuhan.zh, xiyu.xj}@alibaba-inc.com

^a 阿里巴巴淘天集团，中国北京

Abstract

近年来,如何高效扩展工业级点击率(Click-Through Rate, CTR)预估模型受到了广泛关注。现有方法通常会提前聚合用户行为以维持计算效率。然而,这种非统一或部分统一的建模方式会丢弃释放规模扩展收益所必需的细粒度、词元级信号,从而形成信息瓶颈。本文重新审视 CTR 预估与大语言模型 (Large Language Models, LLMs) 之间的根本差异,并识别出两个关键性质:行为特征与非行为特征之间的信息密度不对称性,以及内容丰富信号的模态特定先验。据此,我们提出高效可扩展 Transformer (Efficiently Scalable Transformer, EST),它无需有损聚合,而是在单一序列中处理全部原始输入,实现完全统一的建模。EST 集成了两个模块:轻量级交叉注意力 (Lightweight Cross-Attention, LCA),其裁剪冗余的自交互,从而聚焦于影响显著的跨特征依赖;内容稀疏注意力 (Content Sparse Attention, CSA),其利用内容相似度动态选择高信号行为。大量实验表明,EST 呈现稳定且高效的幂律扩展关系,能够随模型规模增长带来可预测的性能提升。在淘宝展示广告平台部署后,EST 显著优于生产基线,使 RPM (Revenue Per Mile, 每千次展示收入) 提升 3.27%、CTR 提升 1.22%,为构建可扩展的工业级 CTR 预估模型提供了一条切实可行的路径。

Keywords

推荐系统, 点击率预测, 扩展定律




Figure 1: 推荐系统中的点击率预测。

1 引言

点击率 (Click-through Rate, CTR) 预测是现代推荐系统中的一项基础任务,旨在估计用户点击某个物品的概率。如图 1 所示,工业级 CTR 预测模型通常会整合多种输入,包括非行为特征 $\mathcal{N}$ (例如用户画像、候选物品属性)、用户特定行为 $\mathcal{B}_u$

(例如短期历史行为),以及候选物品特定行为 $\mathcal{B}_c$ (例如,以候选物品为条件,从用户全生命周期行为中动态检索得到的子序列 [3, 5, 23, 35])。此外,这些行为往往具有多模态属性 [30],其中离散 ID 与图像、文本等丰富的内容信号交错出现。这些特征被输入深度网络,以建特征交互并生成最终预测。

近年来,大语言模型 (Large Language Model, LLM) 中的缩放定律 [1, 10, 12, 17, 20, 39] 取得了变革性的成功,受此启发,研究者积极探索适用于 CTR 预测的类似缩放策略 [8, 27, 32, 33, 37, 50]。然而,工业推荐系统面临严格的实际约束:模型必须在毫秒级时延预算内,为每次用户请求中的数千个候选物品打分。这一要求给标准 Transformer 架构带来了主要瓶颈,因为其计算成本会同时随模型规模和输入序列长度增长。在工业 CTR 预测场景中,由用户特定行为 $\mathcal{B}_u$ 、非行为特征 $\mathcal{N}$ 和候选物品特定行为 $\mathcal{B}_c$ 组成的统一输入序列,其规模可达到 10^3 个词元。严格的高吞吐、低时延要求促使我们研究高效缩放定律,目标是在受限计算预算下最大化缩放收益。

为实现这一目标,现有方案主要分为两种范式:

- 分层建模 [7, 18, 38, 41, 45, 51] 通过将行为序列 ($\mathcal{B}_u$ 和 $\mathcal{B}_c$) 压缩为定长表示来保持效率。这种压缩通常由 DIN [49] 或 LONGER [4] 等模块完成,随后再与非行为特征 $\mathcal{N}$ 进行联合建模。尽管这种方法较为高效,但这种早期聚合会造成显著的信息瓶颈,丢弃行为中细粒度的词元级信号,而这些信号对于释放缩放收益至关重要。
- 统一建模 [9, 47] 尝试在单个序列内联合建模 $\mathcal{B}_u$ 与 $\mathcal{N}$,以保留这些信号;同时通过复用计算,在计算预算约束下实现更深层的交互建模,即在同一次请求的多个候选物品之间共享用户侧计算。然而,现有统一方法仍然只是部分统一:候选物品特定行为 $\mathcal{B}_c$ 无法跨候选物品共享,因而通常被池化为定长摘要,造成信息损失。

上述局限表明,要有效扩大 CTR 预测模型的规模,就需要利用领域特定归纳偏置的架构。本文分析 CTR 预测与 LLM 建模之间的根本差异,据此设计一种可高效缩放、并实现完全统一建模的架构。我们得到两个关键洞见:(1) 信息密度的不对称性。与 LLM 中相对同质的词元序列不同,CTR 输入呈现出一种不对称结构:简洁、高信号的非行为特征 $\mathcal{N}$ (查询)需要与规模庞大、信息密度较低的行为序列 $\mathcal{B}$ (上下文)进行交互。这一结构先验意味着,在严格的计算预算下,标准自注意力这类稠密的全对全交互存在计算冗余,因为大多数行为到行为的交互对最终预测的增益十分有限。(2) 模态特定先验。用户行为是由多种模态交错组成的结构化记录,具体包括离散 ID 和稠密内容信号。这些异质信号需要采用不同的利用策略。与其简单地将内容特征视为同质的词元嵌入,不如将其用作相似度引导先验 [30, 35, 40],以弥合语义鸿沟,并引导 ID 空间内的交互;后者通常更为有效。

基于这些特性,我们开展了细致的实证分析,并得出两个可直接指导设计的洞见:

^{*} 同等贡献。[†] 通讯作者。

[‡] 该作者亦对本文的方法论作出了核心贡献。




Figure 2: EST 的架构。特征专用分词器将原始特征映射为相应的词元。轻量级交叉注意力 (Lightweight Cross-Attention, LCA) 捕获非行为词元与行为词元之间的交互。内容稀疏注意力 (Content Sparse Attention, CSA) 计算序列内部的内容相似度，并在行为序列内执行稀疏注意力。

- (1) 信息密度决定交互优先级。我们的分析表明，不同信息密度的特征之间的交互会带来不成比例的收益。具体而言，以非行为特征 $\mathcal{N}$ 作为查询、以行为序列 $\mathcal{B}$ 作为键/值的交叉注意力，是性能提升的主要驱动力；相比之下，行为到行为的交互大多是冗余的。由此，我们提出轻量级交叉注意力 (LCA)，它剪除低收益的自交互，仅保留关键的交叉交互，从而有效解除模型缩放与序列长度之间的耦合。
- (2) 内容信号用作关系先验时最为有效。我们发现，当图像、文本等内容信号被用于计算相似关系，而非直接注入为词元嵌入时，能够带来最大的性能收益。为此，我们提出内容稀疏注意力 (CSA)，利用基于内容的相似度动态选择最相关的行为。CSA 仅在具有高信号子集上执行注意力，因此能够以几乎可忽略的计算开销获得更优的预测性能。

总体而言，我们提出了 **EST**，一种高效可缩放的 **Transformer** 架构 (Efficiently Scalable Transformer-based architecture)。如 Figure 2 所示，在 **EST** 中，所有原始输入——包括非行为特征 $\mathcal{N}$ 、用户和候选物品行为 ($\mathcal{B}_u$ 与 $\mathcal{B}_c$)，以及与之关联的内容信号——都被组织成一个完全统一的序列，无需进行有损的预先聚合。该表示由可缩放的主干网络处理，其中每一层并行计算所提出的 LCA 和 CSA，使模型能够在单一框架内有效整合异质词元。实验结果表明，**EST** 呈现出高度高效的幂律缩放关系：随着模型参数数量和计算预算增加，预测性能持续提升，并显著优于现有的分层范式和部分统一范式。

总而言之，本文的主要贡献有以下三点：

- **基础洞见**：我们揭示了 CTR 预测与 LLM 之间的根本差异，具体包括信息密度的不对称性和模态特定先验。在此基础上，我们提炼出可直接指导推荐系统高效可缩放架构设计的归纳偏置。
- **高效可缩放架构**：我们提出新型架构 **EST**，在单个序列内对所有原始输入进行完全统一建模，从而消除有损早期聚合的必要性。**EST** 由 LCA 和 CSA 构成，它们通过优先处理高信号交互大幅减少计算冗余，使模型的缩放潜力摆脱长序列高昂开销的限制。

- **工业部署与实践洞见**：在淘宝展示广告系统中开展的大量离线和在线实验表明，**EST** 呈现出稳定且高效的幂律缩放关系。这些发现及实际部署经验，为探索工业 CTR 预测高效缩放的实践者提供了宝贵的路线图。

2 相关工作

深度 CTR 预测模型。随着深度学习的发展，CTR 预测模型已从传统机器学习 [16, 24] 演进到神经网络 [8, 13, 27, 36, 46]。这类模型通常包含将 ID 特征映射为嵌入的稀疏查找表，以及融合这些嵌入并生成最终预测的稠密网络。在稠密组件中，对用户行为进行建模以捕获用户兴趣是一种关键范式。早期方法 [11, 44] 使用循环神经网络 (RNN) 建模行为序列，而后续模型 [3–5, 23, 35, 49] 则通过计算候选物品的目标注意力来聚合行为。另一个主要方向聚焦于高阶特征交互。基于门控的网络 [2, 15, 33, 34] 和注意力机制 [18, 32, 37, 42] 等方法已广泛用于特征交互。然而，许多此类架构的参数规模与计算效率仍然受限，阻碍了其可扩展性和泛化能力。

可扩展 CTR 预测模型。受大型语言模型中观察到的缩放定律 [10, 12, 17] 启发，近期研究尝试扩展 CTR 预测模型的稠密组件，揭示出巨大的性能提升潜力。早期工作主要聚焦于扩展特征交互模块。例如，WuKong [45] 使用因子分解机 (Factorization Machine) 设计可堆叠架构，并通过实验证明，随着参数数量增加，模型性能会显著改善。后续工作采用 MLP-Mixer [51] 或 Transformer [7, 38, 41] 等可扩展架构推进这一方向，实现了更有效、更具可扩展性的设计。MTGR [9] 和 OneTrans [47] 进一步将序列建模与特征交互统一到单个可扩展 Transformer 中，成为迈向统一建模的关键一步。

3 预备知识

本节对 CTR 预测任务进行形式化描述，并介绍输入处理流程：该流程将异质原始特征映射为统一词元序列和预训练内容特征。

问题定义。 Figure 1 展示了推荐系统中的 CTR 预测任务。通常，在一次请求中，CTR 预测模型会估计用户 u 点击候选集合中候选物品 c 的概率 $\hat{y}_{u,c} \in [0, 1]$ ，该任务通常被表述为二分类问题。CTR 预测模型的输入特征空间包括用户画像 $\mathcal{U}$ 、候选物品特征 $\mathcal{C}$ 等非行为特征 $\mathcal{N}$ ，以及用户历史行为序列 $\mathcal{B}$ 。在实践中，用户行为序列可分为短期用户特定行为 $\mathcal{B}_u$ 和用户全生命周期行为 $\mathcal{B}_l$ 。为了高效处理全生命周期行为，我们采用通用检索单元（General Search Unit, GSU）[35]，检索得到候选物品特定子序列 $\mathcal{B}_c \subset \mathcal{B}_l$ ，其中包含与候选物品 c 最相关的物品。此外，行为序列和候选集合中的物品均为多模态结构化记录，其中包括离散 ID 嵌入和内容特征（例如图像和文本）。给定这些输入，CTR 预测模型输出点击分数 $\hat{y}_{u,c}$ ：

$$\hat{y}_{u,c} = f(\mathcal{B}_u, \mathcal{B}_c, \mathcal{N}).$$

输入处理。 在我们的模型中，所有异质原始特征都被投影为统一的词元序列（详见 Section 5.2）。行为序列 $(\mathcal{B}_u, \mathcal{B}_c)$ 与非行为特征 $\mathcal{N}$ 分别被转换为词元序列 $\mathbf{B}$ 和 $\mathbf{N}$ 。为引入内容信息，我们通过查表获得候选物品及行为序列中各物品的预训练内容表示 [30]；这些表示在整个训练过程中保持冻结，以保留预训练语义。模型输入由词元序列 $(\mathbf{B}, \mathbf{N})$ 与冻结的内容特征共同组成。

4 观察与洞见

本节研究 CTR 预测模型与 LLM 之间的根本差异，并揭示指导我们架构设计的两个关键洞见：

关键洞见

- 信息密度的不对称性
信息密度决定交互优先级。
- 模态特定先验
内容信号用作关系先验时最为有效。

4.1 信息密度的不对称性

LLM 通常处理同质词元，而 CTR 预测模型所处理的异质输入跨度很大，既包括长行为序列，也包括紧凑且信息丰富的非行为特征。由此产生一个关键问题：所有词元到词元的交互对 CTR 预测模型性能的贡献是否相同？为研究这一问题，我们将行为词元 $\mathbf{B}$ 与非行为词元 $\mathbf{N}$ 拼接成单个序列 $\mathbf{X} = [\mathbf{B}, \mathbf{N}]$ ，并使用自注意力对二者的交互进行建模：

$$(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = (\mathbf{X}\mathbf{W}^Q, \mathbf{X}\mathbf{W}^K, \mathbf{X}\mathbf{W}^V),$$

$$\mathbf{X} \leftarrow \text{Softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d}}\right)\mathbf{V} + \mathbf{X}.$$

注意力矩阵 $\mathbf{A} = \text{Softmax}(\mathbf{Q}\mathbf{K}^\top/\sqrt{d})$ 的可视化见 Figure 3a。为便于说明，记 $\langle \mathbf{N}, \mathbf{B} \rangle$ 为这样的注意力分块：非行为词元作为查询，行为词元作为键/值；其余分块以此类推。我们观察到两个性质。首先，注意力矩阵呈现出与不同查询—键组合相对应的清晰分块结构。其次， $\langle \mathbf{N}, \mathbf{B} \rangle$ 分块表现出更为分散且多样的模式，而其他分块则出现秩坍塌，即不同查询对应的注意力分布趋于同质化。

为了量化各分块注意力分布的差异，我们采用有效秩 [25, 26] 作为信息密度的代理指标。对于任意矩阵 $\mathbf{H} \in \mathbb{R}^{m \times n}$ ，有效秩定义为： $\text{erank}(\mathbf{H}) = \frac{1}{\max(m, n)} \|\mathbf{H}\|_F^2 / \|\mathbf{H}\|_2^2$ ，其中 $\|\cdot\|_F$ 和 $\|\cdot\|_2$ 分别表示 Frobenius 范数和谱范数。较高的有效秩意味着信息分布更加多样、冗余更少。如 Figure 3b 所示， $\langle \mathbf{N}, \mathbf{B} \rangle$ 分块的有效




Figure 3: 注意力矩阵的可视化及其有效秩。为保证视觉清晰度，图中仅展示候选物品特定行为词元与非行为词元的注意力分布，因为用户特定行为与候选物品特定行为呈现相似模式。

Table 1: 行为词元与非行为词元交互的分块掩码分析。

屏蔽分块	ΔAUC	ΔGAUC
完整注意力	-	-
$\langle \mathbf{B}, \mathbf{B} \rangle$	-0.01%	-0.00%
$\langle \mathbf{B}, \mathbf{N} \rangle$	-0.03%	-0.02%
$\langle \mathbf{N}, \mathbf{N} \rangle$	-0.03%	-0.02%
$\langle \mathbf{N}, \mathbf{B} \rangle$	-0.20%	-0.20%

秩显著高于其他分块，这表明该分块内的交互具有更高的信息密度。

我们进一步通过分块掩码分析验证上述观察。如 Table 1 所示，屏蔽 $\langle \mathbf{B}, \mathbf{B} \rangle$ 、 $\langle \mathbf{B}, \mathbf{N} \rangle$ 和 $\langle \mathbf{N}, \mathbf{N} \rangle$ 分块时，性能下降可以忽略不计；相比之下，屏蔽 $\langle \mathbf{N}, \mathbf{B} \rangle$ 分块会导致性能显著下降。这一观察证实，异质 CTR 特征之间的不同交互对性能的贡献确实并不均等，也为轻量级交叉注意力（LCA）模块的设计提供了有力依据（详见 Section 5.3）：该模块优先处理必要交互，同时简化冗余计算。

4.2 模态特定先验

内容特征能够提供基于 ID 的模型无法捕获的丰富语义信息。然而，已有研究表明，将内容特征直接整合进基于 ID 的模型往往只能得到次优性能。一种更简单却更有效的方法，是计算候选物品内容特征与用户过往交互物品内容特征之间的余弦相似度 [30, 40]。该策略利用预训练内容特征捕获细粒度的物品相关性，同时避免了端到端多模态训练的复杂性。

为了评估不同多模态整合策略的有效性，我们比较三种代表性范式：(1) 侧信息（Side Information）：将内容特征与 ID 嵌入拼接，作为每个物品的附加属性。(2) 语义 ID（Semantic ID）[22]：将内容特征离散化为基于聚类的语义 ID，随后将其视为传统类别特征。(3) SimTier [30]：利用内容特征计算目标物品与用户历史交互之间的相似度分布，将其作为基于相似度的信号。

如 Table 2 所示，基于相似度的 SimTier 方法显著优于侧信息和语义 ID 等直接整合方法。有趣的是，与单独使用 SimTier 相比，将侧信息与 SimTier 结合反而会导致性能小幅下降，这说明不同整合范式可能难以在单一优化目标下协调。这一观察表明，内容特征需要专门的利用机制，而不能依赖朴素的词元级交互。在该洞见的指导下，我们提出内容稀疏注意力（CSA）模块（详见 Section 5.4），利用内容相似度实现高效且有效的序列内交互。

Table 2: 多模态融合方法对比。

方法	ΔAUC	ΔGAUC
基于 ID 的模型	-	-
辅助信息	+0.44%	+0.89%
Semantic ID	+0.47%	+0.64%
SimTier	+1.18%	+1.58%
SimTier+ 辅助信息	+0.95%	+1.47%

5 方法

基于 Section 4 中得到的洞见，我们提出 EST，一种面向工业级 CTR 预估的高效（Efficiently）可扩展（Scalable）**Transformer** 架构。如 Figure 2 所示，EST 不进行预先聚合或合并，而是将所有原始特征组织为一个统一序列（见 Section 5.2）。EST 块的核心由两个专用模块构成：轻量级交叉注意力（LCA），用于捕获非行为输入与行为输入之间的关键交互（见 Section 5.3）；内容稀疏注意力（CSA），通过序列内部的内容相似度整合内容信息（见 Section 5.4）。

5.1 EST 概述

如 Section 3 所述，我们将原始输入特征记为 $\mathcal{X} = (\mathcal{B}_u, \mathcal{B}_c, \mathcal{N})$ 。这些异构输入通过专用词元化器投影至统一空间，或与预训练内容特征相关联，从而得到非行为词元序列 $\mathbf{N}$ 、行为词元序列 $(\mathbf{B}_u, \mathbf{B}_c)$ 以及相应的冻结内容特征 $(\mathbf{M}_u, \mathbf{M}_c)$ ，详见 Section 5.2。为简化记号，用 $\mathbf{B}$ 表示行为词元的拼接 $[\mathbf{B}_u, \mathbf{B}_c]$ 。如 Figure 2 所示，EST 块通过不同模块分别处理行为词元序列 $\mathbf{B}$ 与非行为词元序列 $\mathbf{N}$ 。非行为词元通过轻量级交叉注意力（LCA）模块与行为词元交互，行为词元则通过内容稀疏注意力（CSA）模块整合内容特征。我们用上标 $s-1$ 表示第 s 层的输入，计算如下：

$$\begin{aligned}\mathbf{N}^{(s)} &\leftarrow \text{LCA}(\text{Norm}(\mathbf{N}^{(s-1)}), \text{Norm}(\mathbf{B}^{(s-1)})) + \mathbf{N}^{(s-1)}, \\ \mathbf{B}^{(s)} &\leftarrow \text{CSA}(\text{Norm}(\mathbf{B}^{(s-1)})) + \mathbf{B}^{(s-1)}.\end{aligned}$$

经过注意力机制后，非行为词元与行为词元分别由前馈网络（Feed-Forward Networks, FFNs [28]）进一步处理：

$$\begin{aligned}\mathbf{N}^{(s)} &\leftarrow \text{PerToken-FFN}(\text{Norm}(\mathbf{N}^{(s)})) + \mathbf{N}^{(s)}, \\ \mathbf{B}^{(s)} &\leftarrow \text{Shared-FFN}(\text{Norm}(\mathbf{B}^{(s)})) + \mathbf{B}^{(s)},\end{aligned}$$

其中，PerToken-FFN 表示为每个非行为词元分别定制的网络，Shared-FFN 表示统一应用于所有行为词元的共享网络。

堆叠 S 层 EST 块后，对行为词元 $\mathbf{B}^{(S)}$ 进行均值池化，并将其与非行为词元 $\mathbf{N}^{(S)}$ 拼接，形成最终输入表示 $\mathbf{X}^{(S)}$ 。我们使用多层感知机（Multilayer Perceptron, MLP）预测用户 u 点击候选物品 c 的概率 $\hat{y}_{u,c}$ ：

$$\begin{aligned}\mathbf{X}^{(S)} &= [\mathbf{N}^{(S)}, \text{Mean}(\mathbf{B}^{(S)})], \\ \hat{y}_{u,c} &= \text{Sigmoid}(\text{MLP}(\mathbf{X}^{(S)})).\end{aligned}$$

给定标签 $y_{u,c}$ ，使用交叉熵损失训练模型：

$$\mathcal{L} = - \sum_{u,c} [y_{u,c} \log \hat{y}_{u,c} + (1 - y_{u,c}) \log (1 - \hat{y}_{u,c})].$$

5.2 词元化

为实现完全统一的建模，我们将所有异构原始输入投影为一维度 d 的词元。该过程在保留细粒度细节的同时，将类别

ID、用户历史等多种信号对齐至统一嵌入空间。此外，我们还引入冻结的内容特征，为模型补充丰富语义。

5.2.1 非行为特征词元化。 对于每个原始非行为特征 $n_i \in \mathcal{N}$ ，我们使用特征专属的词元化器，在不聚合或合并的情况下将其映射为词元 $\mathbf{n}_i \in \mathbb{R}^d$ 。将所得全部非行为词元拼接成序列 $\mathbf{N}$ ：

$$\begin{aligned}\mathbf{n}_i &= \text{MLP}_i(n_i), n_i \in \mathcal{N}, \\ \mathbf{N} &= [\mathbf{n}_1, \dots, \mathbf{n}_{L_N}], \mathbf{N} \in \mathbb{R}^{L_N \times d},\end{aligned}$$

其中， L_N 表示非行为特征的数量。该设计支持通过热启动实现即插即用的特征扩展，无需改变架构或重新初始化参数即可添加新特征。

5.2.2 行为特征词元化。 为简化记号，我们用 $\mathcal{B}_\gamma$ ($\gamma \in \{s, t\}$) 表示用户特定行为序列 $\mathcal{B}_u$ 或候选物品特定行为序列 $\mathcal{B}_c$ 。对于每个序列 $\mathcal{B}_\gamma$ ，我们采用序列专属词元化器，将序列内物品 $b_{\gamma,i}$ 的 ID 嵌入映射为维度为 d 的词元 $\mathbf{b}_{\gamma,i}$ 。将这些词元拼接成对应的行为词元序列 $\mathbf{B}_\gamma$ ：

$$\mathbf{B}_\gamma = [\text{MLP}_\gamma(b_{\gamma,1}), \dots, \text{MLP}_\gamma(b_{\gamma,L_{\mathbf{B}_\gamma}})], \mathbf{B}_\gamma \in \mathbb{R}^{L_{\mathbf{B}_\gamma} \times d}.$$

我们用 $\mathbf{B} = [\mathbf{B}_u, \mathbf{B}_c] \in \mathbb{R}^{L_{\mathbf{B}} \times d}$ 表示所有行为词元序列的拼接，其中 $L_{\mathbf{B}} = L_{\mathbf{B}_u} + L_{\mathbf{B}_c}$ 。

5.2.3 内容特征映射。 为引入内容特征，我们通过查找操作，将行为序列 $\mathcal{B}_u$ 与 $\mathcal{B}_c$ 中的每个物品映射至其对应的预训练内容特征 $\mathbf{m} \in \mathbb{R}^{d_M}$ 。由此得到内容序列 $\mathbf{M}_u \in \mathbb{R}^{L_{\mathbf{B}_u} \times d_M}$ 和 $\mathbf{M}_c \in \mathbb{R}^{L_{\mathbf{B}_c} \times d_M}$ ，它们提供了可与基于 ID 的词元互补的语义视角。这些特征连同候选物品内容特征在训练期间均保持冻结。冻结操作既可保留预训练特征的语义，又能减少联合学习高维稠密向量与离散 ID 嵌入时可能产生的优化不稳定性。

5.3 轻量级交叉注意力

受 Section 4 中“非行为词元与行为词元之间的交互信息量最大”这一观察启发，我们提出轻量级交叉注意力（Lightweight Cross-Attention, LCA）。该模块优先保留关键交互，同时舍弃其他冗余交互。在 LCA 中，非行为词元 $\mathbf{N} \in \mathbb{R}^{L_N \times d}$ 作为查询，拼接后的行为词元 $\mathbf{B} = [\mathbf{B}_u, \mathbf{B}_c] \in \mathbb{R}^{L_{\mathbf{B}} \times d}$ 作为键和值：

$$\begin{aligned}(\mathbf{Q}_N, \mathbf{K}_B, \mathbf{V}_B) &= (\phi(\mathbf{N}, \mathbf{W}^Q), \mathbf{B}\mathbf{W}^K, \mathbf{B}\mathbf{W}^V), \\ \text{LCA}(\mathbf{N}, \mathbf{B}) &= \phi\left(\text{Softmax}\left(\frac{\mathbf{Q}_N \mathbf{K}_B^\top}{\sqrt{d}}\right) \mathbf{V}_B, \mathbf{W}^O\right),\end{aligned}$$

其中， $\phi(\cdot)$ 表示逐词元矩阵乘法。具体而言， $\mathbf{W}_Q, \mathbf{W}_O \in \mathbb{R}^{L_N \times d \times d}$ 是词元特定的投影权重，每个非行为词元均维护一组独立参数，以捕获其独有的特征信号。与此同时， $\mathbf{W}_K, \mathbf{W}_V \in \mathbb{R}^{d \times d}$ 是统一应用于所有行为词元的共享投影权重，以保证计算可扩展性。

LCA 为工业部署带来了显著优势。由于用户特定行为序列 $\mathbf{B}_u$ 与候选物品无关，其对应投影 $\mathbf{B}_u \mathbf{W}^K$ 和 $\mathbf{B}_u \mathbf{W}^V$ 只需计算一次，便可在单次排序请求的所有候选物品间复用。这种用户—候选物品解耦计算显著降低了推理延迟。

计算复杂度。LCA 的复杂度来自投影与注意力计算。与标准自注意力相比，LCA 通过简化交互并支持用户—候选物品解耦计算，最大限度地减少计算冗余。形式化地，其复杂度降低

Algorithm 1: 内容稀疏注意力 (CSA)

Input: 行为词元 $\mathbf{B}_Y \in \mathbb{R}^{L_{B_Y} \times d}$, 冻结的内容特征 $\mathbf{M}_Y \in \mathbb{R}^{L_{B_Y} \times d_M}$, top-K 超参数 K

Output: CSA 输出 $\mathbf{O}_{B_Y} \in \mathbb{R}^{L_{B_Y} \times d}$

```

// 计算内容相似度矩阵
1  $\mathbf{G}_Y \leftarrow \mathbf{M}_Y \mathbf{M}_Y^T$ ; //  $L_{B_Y} \times L_{B_Y}$ 
// 逐行计算 top-K 索引及相似度
2  $\Omega_Y, \mathbf{E}_Y \leftarrow \text{TopK}(\mathbf{G}_Y, K)$ ; //  $L_{B_Y} \times K$ 
// 按索引收集 top-K 物品
3  $\mathbf{B}_Y^{\text{gth}} \leftarrow \text{Gather}(\mathbf{B}_Y, \Omega_Y)$ ; //  $L_{B_Y} \times K \times d$ 
// 基于内容相似度的稀疏注意力
4  $\mathbf{E}_Y \leftarrow \text{Unsqueeze}(\mathbf{E}_Y, -1)$ ; //  $L_{B_Y} \times K \times 1$ 
5  $\mathbf{O}_{B_Y} \leftarrow \text{Sum}(\mathbf{B}_Y^{\text{gth}} \odot \mathbf{E}_Y, \text{axis} = 1)$ ; //  $L_{B_Y} \times d$ 
6 return  $\mathbf{O}_{B_Y}$ 

```

如下:

$$\begin{aligned} \text{投影: } & O((L_N + L_B)d^2) \rightarrow O(L_N d^2 + L_B d^2), \\ \text{注意力: } & O((L_N + L_B)^2 d) \rightarrow O(L_N L_B d). \end{aligned}$$

在典型的工业场景中, $L_B \gg L_N$; 这种从二次复杂度到双线性复杂度的降低, 使 EST 能在不超出延迟预算的前提下处理长得多的行为序列。

5.4 内容稀疏注意力

在“内容相似度能够有效增强基于 ID 的模型”这一洞见指导下, 我们提出内容稀疏注意力 (Content Sparse Attention, CSA)。传统自注意力依赖可学习参数捕获词元关系, 而 CSA 则利用预训练内容特征中固定的语义结构来指导序列内部交互。该设计得到一个无需训练且计算高效的模块, 完整细节见 Algorithm 1。为了维持用户-候选物品解耦计算, CSA 分别独立作用于用户特定序列 $\mathcal{B}_u$ 与候选物品特定序列 $\mathcal{B}_c$ 。为简洁起见, 我们统一将二者记为 $\mathcal{B}_Y$, 其中 $Y \in \{s, c\}$ 。

给定行为序列 $\mathcal{B}_Y$, 我们利用其对应的归一化内容表示 $\mathbf{M}_Y \in \mathbb{R}^{L_{B_Y} \times d_M}$ 计算序列内相似度矩阵 $\mathbf{G}_Y = \mathbf{M}_Y \mathbf{M}_Y^T$, 其中每个元素 $\mathbf{G}_Y[i, j]$ 表示行为序列 $\mathcal{B}_Y$ 中第 i 个物品与第 j 个物品之间的内容相似度。相似度矩阵 $\mathbf{G}_Y$ 由冻结的内容特征导出, 不参与反向传播, 并可供所有层复用。 $\mathbf{G}_Y$ 承载语义关系, 因此可作为无需训练的注意力矩阵, 对行为内部的交互进行建模:

$$\mathbf{O}_{B_Y} = \mathbf{G}_Y \mathbf{B}_Y, \mathbf{O}_{B_Y} \in \mathbb{R}^{L_{B_Y} \times d}. \quad (1)$$

通过 Equation (1), 基于 ID 的物品行为词元在内容相似度的指导下相互关注。由此实现了 ID 特征所捕获的共现关系与内容特征所蕴含的语义关系之间的互补。

尽管形式简单, Equation (1) 的二次复杂度 $O(L_{B_Y}^2 d)$ 仍会带来较高计算成本。为降低该成本, 我们对相似度矩阵 $\mathbf{G}_Y$ 逐行执行 top-K 稀疏化。通过将每个物品的关注范围限制为与其最相似的 K 个物品, 我们实现了内容稀疏注意力。因此, 复杂度降低至 $O(L_{B_Y} K d)$, 并随 L_{B_Y} 线性扩展。

计算复杂度。计算复杂度来自内容注意力矩阵 $\mathbf{G}_Y$ 的计算, 以及 Algorithm 1 中的稀疏注意力:

$$\begin{cases} \text{内容注意力矩阵: } & O(L_{B_Y} d_M^2), \\ \text{稀疏注意力: } & O(L_{B_Y} K d). \end{cases}$$

CSA 的设计带来以下优势: (1) 并行预计算: 内容注意力矩阵的构建与 top-K 稀疏化均可在排序阶段同其他特征处理操作并行执行, 并由各 EST 层复用, 因此几乎不引入额外延迟。(2) 用户-候选物品解耦计算: CSA 分别独立处理 $\mathcal{B}_u$ 与 $\mathcal{B}_c$ 。因此, 用户特定行为的计算结果可在多个候选物品之间共享。(3) 线性复杂度: 在所有实验中, 我们固定 $K = 5$, 远小于序列长度 L_{B_Y} 。采用 top-K 稀疏化后, 计算复杂度随序列长度 L_{B_Y} 线性扩展。

5.5 训练与部署

尽管架构重设计带来了显著收益, 在工业环境中从头训练并部署 EST 依然十分困难。在线生产模型已在数万亿样本上训练多年, 因此很难超越其性能。为此, 我们使用历史生产模型初始化稀疏参数, 仅从头训练稠密参数。在数千亿样本上训练后, EST 的 GAUC 超过生产模型 0.74%, 并能随数据增加持续提升。为了最大化数据利用率, 我们采用多轮训练策略。然而, 推荐系统通常会因过拟合在第二轮训练开始时出现性能下降, 这一现象称为单轮限制 (one-epoch limitation) [48]。受 Liu et al. [21] 和 Fan et al. [6] 启发, 我们实现了一种异步范式:

$$\text{稀疏参数: } \theta_s^{(e)} \xleftarrow{\text{初始化}} \theta_s^{(0)}, \quad \forall e \geq 1,$$

$$\text{稠密参数: } \theta_d^{(e)} \xleftarrow{\text{初始化}} \begin{cases} \text{随机}, & e = 1, \\ \theta_d^{(e-1)}, & e \geq 2, \end{cases}$$

其中, $(\theta_s^{(e)}, \theta_d^{(e)})$ 表示第 e 轮的稀疏参数与稠密参数, 稀疏参数初始值 $\theta_s^{(0)}$ 来自历史生产模型。每轮训练中, 我们都将稀疏参数重置为 $\theta_s^{(0)}$, 同时继承上一轮的稠密参数; 仅在第一轮随机初始化稠密参数。该设计缓解了过拟合, 并额外带来 0.44% 的 GAUC 提升。

6 实验

通过离线评估和在线测试, 我们旨在回答以下研究问题 (Research Questions, RQs):

- **RQ1:** 性能比较。在计算开销和模型容量相当的情况下, 所提出的 EST 是否优于最先进的 CTR 预测模型?
- **RQ2:** 消融研究。各个组件对整体性能和效率有何贡献?
- **RQ3:** 缩放定律。随着计算开销和模型容量的扩展, EST 是否呈现出规律良好的缩放定律?
- **RQ4:** 在线 A/B 测试。将 EST 部署到生产系统后, 能够带来多大的实际改进?

6.1 实验设置

6.1.1 数据集. 在离线评估中, 我们使用从淘宝生产日志中采样的 CTR 数据集, 其中包含六天内收集的超过 10 亿次用户曝光。为评估可扩展性, 我们进一步将实验扩展到一个特征集更丰富的大型数据集, 该数据集包含同一时期收集的超过 35 亿次用户曝光。我们的离线数据集包含数百种异构特征, 包括非行为特征和用户行为序列。具体而言, 短期序列 $\mathcal{B}_u$ 和终身行

Table 3: CTR 预测性能。最佳与次佳结果分别以粗体和下划线标出。

建模范式	方法	AUC	Δ AUC	GAUC	Δ GAUC	参数量 (M)	GFLOPs
基础模型	MLP	0.6895	-	0.6459	-	83.13	9.64
传统 DNN 模型	AutoInt	0.6907	0.18%	0.6477	0.28%	5.20	1.10
	DCNv2	0.6916	0.31%	0.6482	0.35%	15.18	1.49
可扩展分层建模	RankMixer	0.6914	0.28%	0.6482	0.35%	136.84	15.46
	HiFormer	0.6928	0.49%	0.6493	0.53%	113.78	14.17
可扩展统一建模	MTGR	0.6917	0.32%	0.6474	0.23%	118.79	10.57
	OneTrans	0.6921	0.38%	0.6477	0.27%	111.98	15.94
	OneTrans-D	0.6941	0.68%	0.6500	0.64%	112.06	16.19
	OneTrans-F	0.6955	0.87%	0.6507	0.75%	110.54	52.79
	EST	0.6963	0.99%	0.6515	0.87%	103.81	18.48

为序列 $\mathcal{B}_l$ 分别截断为长度 300 和 5,000。对于终身行为序列，GSU 模块 [35] 提取前 50 个候选相关序列 $\mathcal{B}_c$ 。

6.1.2 评估指标. 为评估模型性能，我们采用 AUC (ROC 曲线下面积) 和 GAUC (分组 AUC) 作为效果指标，并采用参数量 (Params) 和推理 GFLOPs 作为效率指标。**AUC:** AUC 越高，表示整体排序能力越强。**GAUC:** GAUC 衡量用户内部排序的质量，并且已被证明与在线性能具有更稳定的相关性 [29, 31, 50]。GAUC 提升 0.001 通常被认为是具有较高置信度的显著增益。我们以 Δ AUC 和 Δ GAUC 报告相对提升。参数量：模型稠密部分的参数量，不包括稀疏嵌入表。推理 **GFLOPs:** 推理期间处理一个包含 60 个样本的批次所需的计算开销，以十亿次浮点运算 (GFLOPs) 计量。

6.1.3 基线方法. 我们与具有代表性的最先进方法进行比较，并按建模范式分类如下：

- 基础模型：一种朴素的基于 *MLP* 的特征交互模型。
- 传统 DNN 模型：AutoInt [32] 是具有代表性的基于注意力的特征交互模型。DCNv2 [33] 通过门控融合捕获高阶特征交互。
- 可扩展分层建模：RankMixer [51] 通过 token-mixer 引入一种有效架构。HiFormer [7] 对聚合后的输入应用异构注意力。
- 可扩展统一建模：MTGR [9] 堆叠 HSTU [43] 模块以进行统一序列建模。OneTrans [47] 是一种采用金字塔堆叠的基于 Transformer 的框架。

需要注意的是，MTGR 和 OneTrans 仅通过池化将候选相关行为序列聚合为一个 token。为探究候选相关行为的影响，我们实现了两个增强变体：**OneTrans-D** 使用 DIN 聚合候选相关序列，而 **OneTrans-F** 则直接拼接完整 (F) 的候选相关行为序列。

6.1.4 实现细节. 所有模型均使用 RecIS [52] 实现，并采用 AdamW 优化器进行优化。所有基线均使用相同的学习率 0.0004。离线实验在配备 32 个 PPU 的分布式训练系统上进行；PPU 是阿里巴巴内部研发的一种 GPU 架构。在缩放实验中，我们使用 128 个 PPU。每个 PPU 的批大小为 1000。为公平比较，EST 与其他可扩展基线采用相同的架构：6 层、token 维度为 128，参数量约为 100M。所有基线均以与 EST 类似的方式处理最后一层的输出：对行为 token 进行平均池化，并将其与非行为 token 拼接。

对于基础模型、传统 DNN 模型以及可扩展分层建模范式，我们采用 DIN [50] 模块压缩行为序列。对于 OneTrans-D，我们使用 DIN 模块压缩候选相关序列，再将其与用户行为序列和非行为 token 拼接。OneTrans-F 直接将所有行为 token 和非行为 token 拼接为单一 token 序列。

所有基线均采用 SimTier [30]，将候选物品与行为序列之间的内容相似程度转换为一种特定的非行为 token，并纳入非行为 token 序列 $\mathbf{N}$ 。在此基础上，EST 使用 CSA 利用序列内部的内容相似性，进一步提升内容特征的效用。

6.2 性能比较 (RQ1)

Table 3 展示了所有模型在离线评估数据集上的性能。在计算开销相当的情况下，EST 优于所有基线。通过比较模型性能，我们得出三条有启发性的结论。第一，**token** 特定的参数化注意力模块善于捕获异构特征之间的交互。对比传统 DNN 模型和可扩展分层建模方法，HiFormer 凭借异构注意力层取得了最佳性能增益。这一观察凸显了 token 特定参数化注意力在建模异构特征间复杂交互方面的潜力。

第二，有效建模候选相关行为序列对性能至关重要。尽管 OneTrans 和 MTGR 通过统一建模实现了充分的特征交互，但由于候选相关行为建模不足，其性能仍不及 HiFormer。然而，通过集成 DIN 模块来压缩候选相关行为序列，OneTrans-D 显著优于 HiFormer。此外，引入完整候选相关行为序列后，OneTrans-F 获得了进一步提升，但代价是计算开销显著增加。这些结果表明，充分利用候选相关行为序列至关重要，同时必须谨慎权衡计算成本。

第三，EST 在不牺牲效率的情况下提升了性能。在保持相近计算成本的同时，EST 的相对 GAUC 比 OneTrans 高 0.59%。与 OneTrans-F 相比，它以减少 65% 计算量的代价取得了 0.12% 的 GAUC 增益。这种效率源于对冗余交互的削减，同时保留了对候选相关行为的有效建模，并支持内容融合。

Table 4: 消融实验结果。

方法	FA	LCA	CSA	Δ AUC	Δ GAUC	Δ GFLOPs
Full-Attention	✓	-	-	0.6951	0.6506	66.27
EST	-	✓	-	-0.01%	-0.03%	-72.23%
	-	✓	✓	+0.17%	+0.14%	-72.11%

EST: 通过统一建模迈向点击率预测的高效扩展定律




Figure 4: 计算开销与 GAUC 之间的幂律关系。随着模型深度增加，最佳拟合曲线为： $\Delta\text{GAUC} = 0.61 \times C^{0.12}$ 。随着模型宽度增加，最佳拟合曲线为： $\Delta\text{GAUC} = 0.68 \times C^{0.10}$ 。




Figure 5: 模型容量与 GAUC 之间的幂律关系。随着模型深度增加，最佳拟合曲线为： $\Delta\text{GAUC} = 0.46 \times P^{0.14}$ 。随着模型宽度增加，最佳拟合曲线为： $\Delta\text{GAUC} = 0.63 \times P^{0.08}$ 。

6.3 消融研究 (RQ2)

我们以 Full-Attention 为比较基准，该模型采用完整自注意力 (full self-attention, FA) 实现统一建模。除此之外，数据组织方式、FFN 模块架构和超参数设置均与 EST 保持一致。Table 4 中的消融实验表明：(1) 与完整自注意力相比，我们的 LCA 在性能仅下降 0.03% 的情况下，将计算量减少了 72.23%。这进一步验证了我们在 Section 3 中的结论：完整自注意力包含冗余交互，而非行为特征与行为序列之间的交互信息量最为丰富。这些结果表明，LCA 的设计兼具效率与效果。(2) 在 LCA 模块的基础上，CSA 进一步将性能提升 0.14%，说明利用行为序列内部的内容相似性能够带来额外增益。与此同时，CSA 通过稀疏化设计保证了效率，仅引入极少的额外计算量。综上，LCA 与 CSA 的协同作用带来了可靠且高效的性能提升。

6.4 缩放定律 (RQ3)

我们考察 EST 是否沿两个维度呈现可预测的缩放行为：(1) 计算开销 C (推理 GFLOPs)；(2) 模型容量 P (稠密模型参数量)。我们遵循 Kaplan et al. [17]，使用幂律函数 $\Delta\text{GAUC}(X) = E \times X^\alpha$ 拟合 ΔGAUC 。 X 表示计算开销 C 或模型容量 P ，而 E 和 α 是待拟合的系数。

我们调整深度 S (堆叠模块的数量) 和宽度 d (token 维度)，其中推理 GFLOPs 的范围为 5 至 50，模型容量的范围为 30M 至 0.3B。经过对数变换后，我们在 Figure 4 和 Figure 5 中展示结果及拟合曲线。我们观察到，无论是计算开销还是模型容量， ΔGAUC 均遵循幂律趋势单调提升。与增加模型宽度相比，

增加模型深度时的增长趋势更为陡峭。这表明，通过扩展深度，模型能够提取复杂交互。

Table 5: 在线 A/B 测试结果

场景	CTR	RPM
Guess	+1.22%	+3.27%
Post	+2.01%	+2.66%

6.5 在线 A/B 测试 (RQ4)

我们将 EST 部署到淘宝展示广告这一全球最大的电子商务推荐系统之一，并通过在线 A/B 测试评估其实际业务影响。实验在全站广告产品 *QuanZhanTui* [19] 中进行，覆盖两个主要场景：“猜你喜欢” (Guess) 和“购后” (Post)。生产环境基线是一个复杂的 MLP 模型，并由多个最先进的模块增强，包括 CAN [2] 和 SENET [14] 等特征交互模块、SIM [23] 和 MUSE [35] 等序列建模模块，以及 SimTier 和 MAKE [30] 等内容建模模块。如 Table 5 所示，EST 在两个场景中均取得显著性能提升。具体而言，在 Guess 场景中，EST 将点击率 (Click-Through Rate, CTR) 提升了 1.22%，并将千次曝光收入 (Revenue Per Mile, RPM) 提升了 3.27%；在 Post 场景中，CTR 提升了 2.01%，RPM 提升了 2.66%。

7 结论

本文研究了在严格延迟约束下，将受 LLM 启发的扩展定律应用于工业级 CTR 预估所面临的挑战。通过分析 CTR 输入与 LLM 词元在信息密度和模态方面的内在差异，我们提炼出两条可用于指导高效 Transformer 设计的洞见。在这些洞见的指导下，我们提出 EST：一种高效可扩展的 Transformer 架构，可在单一词元序列中统一建模异构输入。EST 引入 LCA，聚焦于信息量最大的交互，从而减少冗余计算；同时采用 CSA，利用内容相似度以极小开销对长行为序列进行稀疏建模。离线评估表明，EST 达到了当前最优性能，并相对于模型容量和计算成本呈现清晰的幂律扩展趋势。在线 A/B 测试进一步验证了其实际业务价值，使 RPM 和 CTR 分别显著提升 3.27% 和 1.22%。

致谢

本研究由 CCF-ALIMAMA TECH Kangaroo Fund (CCF-ALIMAMA OF 2025001) 资助。

References

- [1] Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altmenschmidt, Sam Altman, Shyamal Anadkat, et al. 2023. Gpt-4 Technical Report. *arXiv:2303.08774* (2023).
- [2] Weijie Bian, Kailun Wu, Lejian Ren, Qi Pi, Yujing Zhang, Can Xiao, Xiang-Rong Sheng, Yong-Nan Zhu, Zhangming Chan, Na Mou, et al. 2022. CAN: Feature Co-Action Network for Click-Through Rate Prediction. In *Proceedings of the 15th ACM International Conference on Web Search and Data Mining (WSDM)*.
- [3] Yue Cao, Xiaojian Zhou, Jiaqi Feng, Peihao Huang, Yao Xiao, Dayao Chen, and Sheng Chen. 2022. Sampling Is All You Need on Modeling Long-Term User Behaviors for CTR Prediction. In *Proceedings of the 31st ACM International Conference on Information and Knowledge Management (CIKM)*.
- [4] Zheng Chai, Qin Ren, Xijun Xiao, Huizhi Yang, Bo Han, Sijun Zhang, Di Chen, Hui Lu, Wenlin Zhao, Lele Yu, et al. 2025. LONGER: Scaling Up Long Sequence Modeling in Industrial Recommenders. In *Proceedings of the 19th ACM Conference on Recommender Systems (RecSys)*.
- [5] Jianxin Chang, Chenbin Zhang, Zhiyi Fu, Xiaoxue Zang, Lin Guan, Jing Lu, Yiqun Hui, Dewei Leng, Yanan Niu, Yang Song, et al. 2023. TWIN: Two-Stage Interest Network for Lifelong User Behavior Modeling in CTR Prediction at Kuaishou. In *Proceedings of the 29th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*.

- [6] Zhongxiang Fan, Zhaocheng Liu, Jian Liang, Dongying Kong, Han Li, Peng Jiang, Shuang Li, and Kun Gai. 2024. Multi-Epoch learning with Data Augmentation for Deep Click-Through Rate Prediction. *arXiv:2407.01607* (2024).
- [7] Huan Gui, Ruoxi Wang, Ke Yin, Long Jin, Maciej Kula, Taibai Xu, Lichan Hong, and Ed H Chi. 2023. Hiformer: Heterogeneous Feature Interactions Learning with Transformers for Recommender Systems. *arXiv:2311.05884* (2023).
- [8] Huifeng Guo, Ruiming Tang, Yunming Ye, Zhenguo Li, and Xiuqiang He. 2017. DeepFM: A Factorization-Machine Based Neural Network for CTR Prediction. In *Proceedings of the 26th International Joint Conference on Artificial Intelligence (IJCAI)*.
- [9] Ruidong Han, Bin Yin, Shangyu Chen, He Jiang, Fei Jiang, Xiang Li, Chi Ma, Mincong Huang, Xiaoguang Li, Chunzhen Jing, et al. 2025. MTGR: Industrial-Scale Generative Recommendation Framework in Meituan. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management (CIKM)*.
- [10] Tom Henighan, Jared Kaplan, Mor Katz, Mark Chen, Christopher Hesse, Jacob Jackson, Heewoo Jun, Tom B Brown, Prafulla Dhariwal, Scott Gray, et al. 2020. Scaling Laws for Autoregressive Generative Modeling. *arXiv:2010.14701* (2020).
- [11] Balázs Hidasi, Alexandros Karatzoglou, Linas Baltrunas, and Domonkos Tikk. 2016. Session-Based Recommendations with Recurrent Neural Networks. In *Proceedings of the 4th International Conference on Learning Representations (ICLR)*.
- [12] Jordan Hoffmann, Sebastian Borgeaud, Arthur Mensch, Elena Buchatskaya, Trevor Cai, Eliza Rutherford, Diego de Las Casas, Lisa Anne Hendricks, Johannes Welbl, Aidan Clark, et al. 2022. Training Compute-Optimal Large Language Models. In *Proceedings of the 36th International Conference on Neural Information Processing Systems (NeurIPS)*.
- [13] Jiace Hu, Zhangming Chan, Yu Zhang, Shuguang Han, Siyuan Lou, Baolin Liu, Han Zhu, Yuning Jiang, Jian Xu, and Bo Zheng. 2023. PS-SA: An Efficient Self-Attention via Progressive Sampling for User Behavior Sequence Modeling. In *Proceedings of the 32nd ACM International Conference on Information and Knowledge Management (CIKM)*.
- [14] Jie Hu, Li Shen, and Gang Sun. 2018. Squeeze-and-Excitation Networks. In *2018 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*.
- [15] Tongwen Huang, Zhiqi Zhang, and Junlin Zhang. 2019. FiBiNET: Combining Feature Importance and Bilinear Feature Interaction for Click-Through Rate Prediction. In *Proceedings of the 13th ACM Conference on Recommender Systems (RecSys)*.
- [16] Yuchin Juan, Yong Zhuang, Wei-Sheng Chin, and Chih-Jen Lin. 2016. Field-Aware Factorization Machines for CTR Prediction. In *Proceedings of the 10th ACM Conference on Recommender Systems (RecSys)*.
- [17] Jared Kaplan, Sam McCandlish, Tom Henighan, Tom B Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu, and Dario Amodei. 2020. Scaling Laws for Neural Language Models. *arXiv:2001.08361* (2020).
- [18] Kaiyuan Li, Dongdong Mao, Yongxiang Tang, Yanhua Cheng, Yanxiang Zeng, Chao Wang, Xialong Liu, and Peng Jiang. 2025. INFNet: A Task-aware Information Flow Network for Large-Scale Recommendation Systems. *arXiv:2508.11565* (2025).
- [19] Ningyuan Li, Zhilin Zhang, Tianyan Long, Yuyao Liu, Rongquan Bai, Yurong Chen, Xiaotie Deng, Pengjie Wang, Chuan Yu, Jian Xu, and Bo Zheng. 2025. Beyond Advertising: Mechanism Design for Platform-Wide Marketing Service "QuanZhanTui". In *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)*.
- [20] Aixiu Liu, Bei Feng, Bing Xue, Bingxuan Wang, Bochao Wu, Chengda Lu, Chenggang Zhao, Chengqi Deng, Chenyu Zhang, Chong Ruan, et al. 2024. Deepseek-v3 Technical Report. *arXiv:2412.19437* (2024).
- [21] Zhaocheng Liu, Zhongxiang Fan, Jian Liang, Dongying Kong, and Han Li. 2023. Multi-Epoch Learning for Deep Click-Through Rate Prediction Models. *arXiv:2305.19531* (2023).
- [22] Xinchun Luo, Jiangxia Cao, Tianyu Sun, Jinkai Yu, Rui Huang, Wei Yuan, Hezheng Lin, Yichen Zheng, Shiyao Wang, Qigen Hu, et al. 2025. QARM: Quantitative Alignment Multi-Modal Recommendation at Kuaishou. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management (CIKM)*.
- [23] Qi Pi, Guorui Zhou, Yujing Zhang, Zhe Wang, Lejian Ren, Ying Fan, Xiaoqiang Zhu, and Kun Gai. 2020. Search-Based User Interest Modeling with Lifelong Sequential Behavior Data for Click-Through Rate Prediction. In *Proceedings of the 29th ACM International Conference on Information and Knowledge Management (CIKM)*.
- [24] Matthew Richardson, Ewa Dominowska, and Robert Ragno. 2007. Predicting Clicks: Estimating the Click-Through Rate for New Ads. In *Proceedings of the 16th International Conference on World Wide Web (WWW)*.
- [25] Olivier Roy and Martin Vetterli. 2007. The Effective Rank: A Measure of Effective Dimensionality. In *The 15th European Signal Processing Conference (EUSIPCO)*.
- [26] Mark Rudelson and Roman Vershynin. 2007. Sampling from Large Matrices: An Approach through Geometric Functional Analysis. *Journal of the ACM (JACM)* (2007).
- [27] Ying Shan, T Ryan Hoens, Jian Jiao, Haijing Wang, Dong Yu, and JC Mao. 2016. Deep Crossing: Web-Scale Modeling without Manually Crafted Combinatorial Features. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*.
- [28] Noam Shazeer. 2020. GLU Variants Improve Transformer. *arXiv:2002.05202* (2020).
- [29] Xiang-Rong Sheng, Jingyue Gao, Yueyao Cheng, Siran Yang, Shuguang Han, Hongbo Deng, Yuning Jiang, Jian Xu, and Bo Zheng. 2023. Joint Optimization of Ranking and Calibration with Contextualized Hybrid Model. In *Proceedings of the 29th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*.
- [30] Xiang-Rong Sheng, Feifan Yang, Litong Gong, Biao Wang, Zhangming Chan, Yujing Zhang, Yueyao Cheng, Yong-Nan Zhu, Tiezheng Ge, Han Zhu, et al. 2024. Enhancing Taobao Display Advertising with Multimodal Representations: Challenges, Approaches and Insights. In *Proceedings of the 33rd ACM International Conference on Information and Knowledge Management (CIKM)*.
- [31] Xiang-Rong Sheng, Liqin Zhao, Guorui Zhou, Xinyao Ding, Binding Dai, Qiang Luo, Siran Yang, Jingshan Lv, Chi Zhang, Hongbo Deng, et al. 2021. One Model to Serve All: STAR Topology Adaptive Recommender for Multi-Domain CTR Prediction. In *Proceedings of the 30th ACM International Conference on Information and Knowledge Management (CIKM)*.
- [32] Weiping Song, Chence Shi, Zhiping Xiao, Zhijian Duan, Yewen Xu, Ming Zhang, and Jian Tang. 2019. AutoInt: Automatic Feature Interaction Learning via Self-Attentive Neural Networks. In *Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM)*.
- [33] Ruoxi Wang, Rakesh Shivanna, Derek Cheng, Sagar Jain, Dong Lin, Lichan Hong, and Ed Chi. 2021. DCN V2: Improved Deep & Cross Network and Practical Lessons for Web-Scale Learning to Rank Systems. In *Proceedings of the Web Conference 2021 (WWW)*.
- [34] Zhiqiang Wang, Qingyun She, and Junlin Zhang. 2021. MaskNet: Introducing Feature-Wise Multiplication to CTR Ranking Models by Instance-Guided Mask. *arXiv:2102.07619* (2021).
- [35] Bin Wu, Feifan Yang, Zhangming Chan, Yu-Ran Gu, Jiawei Feng, Chao Yi, Xiang-Rong Sheng, Han Zhu, Jian Xu, Mang Ye, et al. 2025. MUSE: A Simple Yet Effective Multimodal Search-Based Framework for Lifelong User Interest Modeling. *arXiv:2512.07216* (2025).
- [36] Kailun Wu, Weijie Bian, Zhangming Chan, Lejian Ren, Shiming Xiang, Shuguang Han, Hongbo Deng, and Bo Zheng. 2022. Adversarial Gradient Driven Exploration for Deep Click-through Rate Prediction. In *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)*.
- [37] Xue Xia, Pong Eksombatchai, Nikil Pancha, Dhruvil Deven Badani, Po-Wei Wang, Neng Gu, Saurabh Vishwas Joshi, Nazanin Farahpour, Zhiyuan Zhang, and Andrew Zhai. 2023. TransAct: Transformer-Based Realtime User Action Model for Recommendation at Pinterest. In *Proceedings of the 29th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*.
- [38] Bencheng Yan, Yuejie Lei, Zhiyuan Zeng, Di Wang, Kaiyi Lin, Pengjie Wang, Jian Xu, and Bo Zheng. 2025. From Scaling to Structured Expressivity: Rethinking Transformers for CTR Prediction. *arXiv:2511.12081* (2025).
- [39] An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, et al. 2025. Qwen3 Technical Report. *arXiv:2505.09388* (2025).
- [40] Jia-Qi Yang, Chenglei Dai, Dan Ou, Ju Huang, De-Chuan Zhan, Qingwen Liu, Xiaoyi Zeng, and Yang Yang. 2023. COURIER: Contrastive User Intention Reconstruction for Large-Scale Pre-Train of Image Features. *arXiv:2306.05001* (2023).
- [41] Liren Yu, Wenming Zhang, Silu Zhou, Tao Zhang, Zhixuan Zhang, and Dan Ou. 2025. HHFT: Hierarchical Heterogeneous Feature Transformer for Recommendation Systems. *arXiv:2511.20235* (2025).
- [42] Zhichen Zeng, Xiaolong Liu, Mengyue Hang, Xiaoyi Liu, Qinghai Zhou, Chaofei Yang, Yiqun Liu, Yichen Ruan, Laming Chen, Yuxin Chen, et al. 2025. InterFormer: Effective Heterogeneous Interaction Learning for Click-Through Rate Prediction. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management (CIKM)*.
- [43] Jiaqi Zhai, Lucy Liao, Xing Liu, Yueming Wang, Rui Li, Xuan Cao, Leon Gao, Zhaojie Gong, Fangda Gu, Jiayuan He, et al. 2024. Actions Speak Louder than Words: Trillion-Parameter Sequential Transducers for Generative Recommendations. In *Proceedings of the 41st International Conference on Machine Learning (ICML)*.
- [44] Shuangfei Zhai, Keng-hao Chang, Ruofei Zhang, and Zhongfei Mark Zhang. 2016. DeepIntent: Learning Attentions for Online Advertising with Recurrent Neural Networks. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*.
- [45] Buyun Zhang, Liang Luo, Yuxin Chen, Jade Nie, Xi Liu, Shen Li, Yanli Zhao, Yuchen Hao, Yantao Yao, Ellie Dingqiao Wen, et al. 2024. Wukong: Towards a Scaling Law for Large-Scale Recommendation. In *Proceedings of the 41st International Conference on Machine Learning (ICML)*.

- [46] Yujing Zhang, Zhangming Chan, Shuhao Xu, Weijie Bian, Shuguang Han, Hongbo Deng, and Bo Zheng. 2022. KEEP: An Industrial Pre-training Framework for Online Recommendation via Knowledge Extraction and Plugging. In *Proceedings of the 31st ACM International Conference on Information & Knowledge Management (CIKM)*.
- [47] Zhaoqi Zhang, Haolei Pei, Jun Guo, Tianyu Wang, Yufei Feng, Hui Sun, Shaowei Liu, and Aixin Sun. 2025. OneTrans: Unified Feature Interaction and Sequence Modeling with One Transformer in Industrial Recommender. *arXiv:2510.26104* (2025).
- [48] Zhao-Yu Zhang, Xiang-Rong Sheng, Yujing Zhang, Biye Jiang, Shuguang Han, Hongbo Deng, and Bo Zheng. 2022. Towards Understanding the Overfitting Phenomenon of Deep Click-Through Rate Models. In *Proceedings of the 31st ACM International Conference on Information and Knowledge Management (CIKM)*.
- [49] Guorui Zhou, Na Mou, Ying Fan, Qi Pi, Weijie Bian, Chang Zhou, Xiaoqiang Zhu, and Kun Gai. 2019. Deep Interest Evolution Network for Click-Through Rate Prediction. In *Proceedings of the 33rd AAAI Conference on Artificial Intelligence (AAAI)*.
- [50] Guorui Zhou, Xiaoqiang Zhu, Chenru Song, Ying Fan, Han Zhu, Xiao Ma, Yanghui Yan, Junqi Jin, Han Li, and Kun Gai. 2018. Deep Interest Network for Click-Through Rate Prediction. In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*.
- [51] Jie Zhu, Zhifang Fan, Xiaoxie Zhu, Yuchen Jiang, Hangyu Wang, Xintian Han, Haoran Ding, Xinmin Wang, Wenlin Zhao, Zhen Gong, et al. 2025. RankMixer: Scaling Up Ranking Models in Industrial Recommenders. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management (CIKM)*.
- [52] Hua Zong, Qingtao Zeng, Zhengxiong Zhou, Zhihua Han, Zhensong Yan, Mingjie Liu, Hechen Sun, Jiawei Liu, Yiwen Hu, Qi Wang, YiHan Xian, Wenjie Guo, Houyuan Xiang, Zhiyuan Zeng, Xiangrong Sheng, Bencheng Yan, Nan Hu, Yuheng Huang, Jinqing Lian, Ziru Xu, Yan Zhang, Ju Huang, Siran Yang, Huimin Yi, Jiamang Wang, Pengjie Wang, Zhu Han, Jian Wu, Dan Ou, Jian Xu, Haihong Tang, Yuning Jiang, Bo Zheng, and Lin Qu. 2025. RecIS: Sparse to Dense, A Unified Training Framework for Recommendation Models. *arXiv:2509.20883* (2025).