

点击率预测模型中的端到端用户行为检索

Qiwei Chen*

Changhua Pei*

chenqiwei.cqw@alibaba-inc.com

changhua.pch@alibaba-inc.com

Alibaba Group.

Beijing, China

Shanshan Lv

lss271346@alibaba-inc.com

Alibaba Group.

Beijing, China

Chao Li

ruide.lc@alibaba-inc.com

Alibaba Group.

Beijing, China

Junfeng Ge

beili.gif@alibaba-inc.com

Alibaba Group.

Beijing, China

Wenwu Ou

santong.oww@taobao.com

Alibaba Group.

Beijing, China

ABSTRACT

点击率 (CTR) 预测是推荐系统 (RS) 的核心任务之一, 它为每个用户—物品对预测个性化的点击概率。近年来, 研究人员发现, 将用户行为序列, 尤其是长期用户行为序列纳入考虑, 可以大幅提升 CTR 模型的性能。某电商网站的报告显示, 23% 的用户在过去 5 个月内产生了超过 1000 次点击。尽管已有大量工作专注于序列用户行为建模, 但由于真实系统对推理时间有严格约束, 能够处理长期用户行为序列的工作仍然很少。为突破性能上限, 人们提出了两阶段方法。第一阶段设计一个辅助任务, 从长期用户行为序列中检索最相似的前 k 个物品。第二阶段在候选物品与第一阶段选出的 k 个物品之间执行经典注意力机制。然而, 检索阶段与主要 CTR 任务之间存在信息鸿沟, 这种目标分歧会大幅削弱长期用户序列带来的性能增益。受 Reformer 启发, 本文提出一种名为 ETA (端到端目标注意力) 的局部敏感哈希 (LSH) 方法, 它可以显著降低训练和推理成本, 使利用长期用户行为序列进行端到端训练成为可能。离线和线上实验均证实了模型的有效性。我们将 ETA 部署到一个大规模真实电商系统中, 与两阶段长用户序列 CTR 模型相比, GMV (商品交易总额) 额外提升了 3.1%。

KEYWORDS

推荐, 行为序列, 实时检索

ACM Reference Format:

Qiwei Chen, Changhua Pei, Shanshan Lv, Chao Li, Junfeng Ge, and Wenwu Ou. 2026. 点击率预测模型中的端到端用户行为检索. In *Proceedings of ACM Conference (Conference'17)*. ACM, New York, NY, USA, 9 pages. <https://doi.org/10.1145/nnnnnnnn.nnnnnnnn>

*两位作者对本研究贡献相同。

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than ACM must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.

Conference'17, July 2017, Washington, DC, USA

© 2026 Association for Computing Machinery.

ACM ISBN 978-x-xxxx-xxxx-x/YY/MM...\$15.00

<https://doi.org/10.1145/nnnnnnnn.nnnnnnnn>

1 引言

推荐系统 (RS) 被广泛部署, 以解决信息过载问题。在 RS 所采用的各种深度学习模型中, 点击率 (CTR) 预测模型是最重要的模型之一。工业界和学术界都十分重视提升 CTR 模型的 AUC (ROC 曲线下面积), 以改善 RS 的在线性能。在过去十年中, CTR 模型的性能得到了显著提升。其中一个重要里程碑是用户行为序列的引入, 尤其是长期用户行为序列 [20–22, 35, 36]。根据 [24] 的报告, 某电子商务网站中有 23% 的用户在过去 5 个月内产生了超过 1000 次点击。如何有效利用这些海量且信息丰富的用户行为已变得愈发重要, 这也是本文的目标。

研究者提出了多种方法来建模序列用户行为数据。早期方法, 例如求和/平均池化方法、基于 RNN 的方法 [4, 5, 11]、基于 CNN 的方法 [14, 27] 以及基于自注意力的方法 [12, 28], 将不同长度的用户行为序列编码为固定维度的隐藏向量。然而, 在对不同候选物品进行评分时, 这些方法无法捕获用户动态的局部兴趣。由于对用户的全部历史行为进行编码, 这些方法还会引入噪声。为克服全局池化方法的缺点, DIN [36] 提出使用目标注意力机制, 根据不同候选物品生成不同的用户序列表示, 其中目标候选物品充当查询 Q , 序列中的每个物品充当键 K 和值 V 。然而, 由于计算和存储资源成本高昂, DIN 仅使用最近 50 个行为进行目标注意力计算, 忽略了长用户行为序列中的丰富信息, 显然并非最优方案。

近期, SIM [21] 和 UBR4CTR [22] 等方法被提出用于从更长的用户行为序列中捕获用户动态兴趣, 并成为 SOTA (当前最佳) 方法。这些方法采用两阶段流程。在第一阶段, 设计一个辅助任务, 从长期用户行为序列中检索前 k 个相似物品, 从而预先准备好前 k 个相似物品。在第二阶段, 在目标物品与第一阶段选出的 k 个物品之间执行目标注意力机制。然而, 检索阶段使用的信息与主 CTR 模型存在目标偏离或已经过时。例如, UBR4CTR [22] 和 SIM [21] 使用类别等属性, 从用户行为序列中选择与目标候选物品共享相同属性的物品, 这与 CTR 模型的目标并不一致。SIM [21] 还尝试基于预训练嵌入构建离线倒排索引。在训练和推理期间, 模型可以搜索前 k 个“相似”物品。但大多数 CTR 模型采用在线学习范式, 嵌入会持续更新。因此, 与在线 CTR 模型中的嵌入相比, 离线倒排索引中的预训练嵌入已经过时。无论是偏离的目标还是过时的检索向量, 都会阻碍长期用户行为序列得到充分利用。

本文提出一种名为 ETA 的方法, 通过实现端到端的长期用户行为检索, 缓解 CTR 预测任务中上述信息鸿沟 (即目标偏离和嵌入过时)。我们使用 SimHash 为用户行为序列中的每个物品生成指纹, 然后利用汉明距离帮助选择前 k 个物品进行目标

注意力计算。我们的方法将检索复杂度从 $O(L * B * d)$ 次乘法降低为 $O(L * B)$ 次汉明距离计算，其中 L 是行为序列长度， B 是每次推荐时 CTR 模型需要评分的候选物品数量， d 是物品嵌入维度。复杂度的降低使我们能够移除离线辅助模型，并在训练和服务过程中执行实时检索。与 SOTA 模型相比，这显著提高了排序性能。本文的贡献可概括为以下三个方面。

- 我们为 CTR 预测任务提出一种 End-to-end Target Attention 方法，称为 **ETA**。据我们所知，ETA 是首个以端到端方式使用 CTR 模型对长期用户行为序列进行建模的工作。
- 离线实验和在线 A/B 测试均表明，与 SOTA 模型相比，ETA 取得了显著的性能提升。与两阶段 CTR 模型相比，将 ETA 部署到大型真实电子商务平台后，我们获得了额外 3.1% 的 GMV 提升。
- 我们进行了全面的消融研究，揭示在推理时间约束下更好地建模序列用户行为的实践经验。
- 我们的方法还可扩展到其他需要处理超长序列的场景和模型，例如长序列时间序列预测模型。

2 相关工作

CTR 预测任务是推荐系统、在线广告和信息检索中的关键任务之一。CTR 模型预测用户点击某个目标物品的概率，输出概率可用作下游排序任务的排序分数。CTR 模型的准确性会显著影响在线系统的线上表现。例如，在我们的在线 RS 中，CTR 模型的 AUC 提升 0.1%，就能带来数百万次真实点击及相应收入。大量工作从不同角度提升 CTR 模型的准确性，可分为三类：特征交互、用户行为序列和长期用户行为序列。

特征交互：特征交互的直觉是将特征空间中的共现模式与标签一并记忆。例如，特征 $AND(user_installed_app = netflix, impression_app = pandora)$ 能够更好地捕捉用户点击或未点击某个推荐 App 的模式。为更有效地建模特征交互，人们发表了一系列工作，代表性方法包括 FM[25]、FFM[19]、GBDT+LR[9]、Wide&Deep[3]、FNN[33]、AFM[30]、DeepCross[29]、DeepFM[8]、PNN[23] 和 xDeepFM[17]。任意两个模型之间都存在多方面差异，例如是否使用深度学习技术、权重与特征的嵌入是否共享，以及是否需要特征工程。

用户行为序列：用户行为序列具有高度个性化的特点，并包含用户兴趣的时空信息。将序列用户行为引入 CTR 模型是一个重要里程碑。Youtube[6] 在模型中使用已观看视频序列和搜索 Token 来捕捉用户兴趣。为更好地从用户行为序列中提取用户兴趣，人们提出了多种模型，包括 CNN[27, 32]、RNN[10, 35]、Attention[7, 26] 和 Capsule Network[15]。然而，上述模型学习到的用户兴趣向量对特定用户而言是全局性的。DIN[36] 提出一种基于注意力的方法，称为目标注意力，用于捕捉特定用户面对不同目标物品时多样化的局部兴趣。

长期用户行为序列：尽管目标注意力具有强大的多样化用户兴趣捕捉能力，其计算成本却很高。线上推理时间的严格限制使 DIN 类模型无法使用更长的用户序列。MIMN[20] 通过将用户兴趣建模与 CTR 任务的其余部分解耦来处理长期用户行为序列。每当观察到新行为时，用户兴趣向量都会以异步方式离线更新。由于离线环境没有推理时间限制，MIMN 理论上可以对任意长度的序列建模。然而，MIMN 无法针对不同目标物品学习不同的用户兴趣向量。SIM[21] 和 UBR4CTR[22] 在 CTR 任务中超越 MIMN，成为当前最先进的模型。SIM 和 UBR4CTR 都采用两阶段架构对长期用户行为序列建模。第一阶段设计一个辅助任务，从长期用户行为序列中检索最相似的前 k 个物品。




Figure 1: 两个向量 x 和 y 的 SimHash 局部敏感性示意图。详细实现见算法 1。每个 d 维向量都被转换为长度为 m 的签名向量。此处每次随机旋转均可视为一个“哈希函数”。旋转通过乘以随机哈希列向量 $H(i)$ 实现（算法 1 第 2 行）。随机旋转后，球面上的点被投影到带符号的坐标轴上（算法 1 第 3-7 行）。这里我们使用 4 个哈希函数和两条投影轴，将每个向量映射为 4 个二进制位。可以观察到，只有彼此接近的向量才能共享更多相同的 0/1，这一点显示在图的底部。

第二阶段在目标物品与第一阶段选出的 k 个物品之间执行目标注意力。

除上述 CTR 预测任务的相关工作外，还有大量工作旨在提高 Transformer 的效率与效果，其中最相关的是 Reformer[13] 和 Informer[37]。然而，它们仅关注经典 Transformer 的优化；由于大规模在线推荐系统对推理时间有严格约束，因此无法直接用于 CTR 预测任务。

3 预备知识

本节首先给出 CTR 预测任务的形式化定义，然后介绍如何通过 SimHash 机制生成一个 d 维嵌入向量的指纹。

3.1 CTR 预测任务的形式化定义

CTR 预测任务广泛应用于在线广告、推荐系统和信息检索。其旨在解决以下问题：

给定一次曝光 j ，其中某个物品展示给一名用户，预测用户点击的概率（标签记为 y_j ），并使用特征向量 x_j 。

$$p_j = P(y_j = 1 | x_j; \theta); j \in \mathcal{I}. \quad (1)$$

CTR 任务通常被建模为二分类问题。对于每次曝光 $j \in \mathcal{I}$ ，根据物品是否被点击记录二元标签 y_j 。随后，以监督方式训练 CTR 模型，使交叉熵损失最小化，如式 2 所示，其中 N 是曝光次数。 x_j 和 y_j 分别是曝光 j 的特征向量和标签。 θ 表示 CTR 模型的可训练参数。为便于说明，我们在表 1 中列出了本文使用的符号。

$$\mathcal{L}_{CTR}(\theta) = -\frac{1}{N} \sum_{j=1}^N \left(y_j * \log(p_j) + (1 - y_j) * \log(1 - p_j) \right). \quad (2)$$

3.2 SimHash

SimHash 算法最早由 [2] 提出，其著名应用之一是 [18]，该应用使用基于 SimHash 的指纹检测重复网页。SimHash 函数以物品的嵌入向量为输入，并生成其二进制指纹。算法 1 给出了 SimHash 一种可能实现的伪代码。SimHash 满足局部敏感性性质：若输入向量彼此相似，SimHash 的输出也会相似，如图 1 所示。图 1 中的每次随机旋转都可以视为一个“哈希函数”。旋转通过将输入嵌入向量与随机投影列向量 $H(i)$ 相乘实现，如

Algorithm 1: SimHash 算法的伪代码。

输入: 一个 d 维嵌入向量 $\mathbf{e}_k \in \mathbb{R}^{1 \times d}$
 一个固定的随机哈希矩阵 $\mathbf{H} \in \mathbb{R}^{d \times m}$, 其中每一列
 均可视为一个哈希函数。
 输出: $\mathbf{e}_k$ 的二进制签名向量 $\mathbf{sig}_k \in \mathbb{R}^{1 \times m}$ 。

```

1 for  $i \leftarrow 0$  to  $m - 1$  do
2    $\mathbf{sig}_k[i] = \sum_{j=1}^d \text{sgn}(\mathbf{e}_k[j] * \mathbf{H}[j][i])$ 
3   if  $\mathbf{sig}_k[i] > 0$  then
4      $\mathbf{sig}_k[i] = 1$ 
5   else
6      $\mathbf{sig}_k[i] = 0$ 
7   end if
8 end for
9 return  $\mathbf{sig}_k$ 

```

算法 1 第 2 行所示。随机旋转后, 球面上的点被投影到带符号的坐标轴上 (算法 1 第 3-7 行)。在图 1 中, 我们使用 4 个哈希函数和两条投影轴, 将每个向量映射为包含 4 个元素的签名向量。签名向量中的每个元素均为 1 或 0。该向量还可以进一步解码为一个整数, 以节省存储成本并加速后续汉明距离计算。从图 1 可以观察到, 相近的嵌入向量有较高概率获得相同的哈希签名 (比较图 1 的底部与图 1 的上部)。这一现象就是所谓的“局部敏感性”性质。借助局部敏感性, 嵌入向量之间的相似度可以由哈希签名之间的相似度代替。换言之, 两个向量之间的内积可以由汉明距离代替。值得注意的是, SimHash 算法对每次旋转所用“哈希函数”的选择并不敏感, 任意固定的随机哈希向量即可 (见算法 1 中的 $\mathbf{H}(i)$)。该算法易于实现, 也很容易应用于成批的嵌入向量。

4 模型

本节首先介绍我们的 ETA (End-to-End Target Attention) 模型的详细架构, 然后介绍 ETA 模型的不同子模块, 最后介绍 ETA 部署中的实践经验。

4.1 模型概述

如图 2 所示, 我们的模型以用户侧/物品侧特征作为输入, 并输出特定用户—物品对的点击概率。 $\mathcal{H}_{lu}$ 、 $\mathcal{H}_{su}$ 、 x_u 、 x_t 和 x_c 是原始输入特征。 θ 表示可训练参数。给定这些特征后, 我们分别使用长期兴趣提取单元 (第 4.4 节)、多头目标注意力 (第 4.3 节) 和嵌入层 (第 4.2 节), 将 $\mathcal{H}_{lu}$ 、 $\mathcal{H}_{su}$ 、 x_u 、 x_t 和 x_c 分别转换为隐藏向量。随后, 将这些隐藏向量拼接并输入 MLP (多层感知机) 部分。在 MLP 的最后一层, 使用 sigmoid 函数将隐藏向量映射为标量 $p(y_j | \mathcal{H}_{lu}, \mathcal{H}_{su}, x_u, x_t, x_c; \theta)$, 表示特定用户—物品对的点击概率。该概率可作为下游任务的排序分数。

4.2 嵌入层

对于不同类型的特征, 我们采用不同的嵌入技术。原始输入特征主要分为两类: 类别特征和数值特征。在模型中, 我们对类别特征使用独热编码。对于数值特征, 首先将特征划分到不同数值桶中, 然后使用独热编码标识不同的桶, 这与 [16] 的方法类似。需要注意的是, 由于存在数十亿个物品 ID, 独热编码向量可能极其稀疏。因此, 我们将所有独热编码向量映射为低维隐藏向量, 以减少参数数量。我们用 $\mathbf{e}_i \in \mathbb{R}^{d \times 1}$ 表示物品 i 的嵌入向量。随后, 将所有用户行为物品的嵌入向量组合为矩阵

Table 1: 本文使用的符号。

符号	描述
$\mathcal{I}$	曝光集合。
p_j	某次曝光 j 的点击概率。
y_j	曝光 j 的点击标签。
$\mathbf{x}_j$	曝光 j 的特征向量。
θ	CTR 模型的参数。
d	物品嵌入的维度。
$\mathbf{e} \in \mathbb{R}^{d \times 1}$	物品嵌入向量。
$\mathbf{h} \in \mathbb{R}$	嵌入向量 $\mathbf{e}$ 的哈希指纹。
$\mathbf{sig}_i$	由 i^{th} 个哈希函数生成的比特向量。
m	哈希指纹 $\mathbf{h}$ 的比特长度。
$\mathcal{H}_{lu}$	长期用户行为序列。
$\mathcal{H}_{su}$	短期用户行为序列。
x_u	用户画像的原始特征。
x_c	上下文信息的原始特征。
x_t	目标物品的原始特征。
L	长期用户行为序列的长度。
B	每个用户请求中待预测的候选物品数量。
$\mathbf{e}_u, \mathbf{e}_c, \mathbf{e}_t$	用户画像、上下文和目标物品各自的嵌入向量。
$\mathbf{E}_s \in \mathbb{R}^{L \times d}$	长期用户行为序列的嵌入矩阵。
$\mathbf{E}_t \in \mathbb{R}^{1 \times d}$	目标物品的嵌入矩阵。
$f(\cdot)$	两个嵌入向量的相似度函数。

$\mathbf{E}_s \in \mathbb{R}^{L \times d}$, 如式 3 所示。 L 是用户行为序列长度, d 是嵌入维度。

$$\mathbf{E}_s = \begin{bmatrix} \mathbf{e}_1^T \\ \mathbf{e}_2^T \\ \vdots \\ \mathbf{e}_L^T \end{bmatrix}. \quad (3)$$

4.3 多头目标注意力

多头注意力最早由 [28] 提出, 并被广泛应用于 CTR 预测任务 [21, 22, 30, 31, 34]。在 CTR 预测任务中, 目标物品充当查询 (Q), 用户行为序列中的每个物品充当键 (K) 和值 (V)。我们将这种多头注意力结构称为多头目标注意力, 缩写为 TA。TA 的计算如式 4 所示。TA 的主要部分是点积注意力, 如式 5 所示。点积注意力由两个步骤组成。首先, 根据行为物品和目标物品的嵌入矩阵 Q 和 K 计算各行物品与目标物品之间的相似度。其次, 将归一化后的相似度作为注意力权重, 计算所有行为物品嵌入的加权和, 其嵌入矩阵表示为 V 。

$$\text{TA}(\mathbf{E}_t, \mathbf{E}_s) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) \mathbf{W}^O, \quad (4)$$

where $\text{head}_i = \text{Attention}(\mathbf{E}_t \mathbf{W}_i^Q, \mathbf{E}_s \mathbf{W}_i^K, \mathbf{E}_s \mathbf{W}_i^V)$,

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V, \quad (5)$$

其中, $\mathbf{E}_t \in \mathbb{R}^{1 \times d}$, $\mathbf{E}_s \in \mathbb{R}^{L \times d}$ 分别是目标物品和行为序列的输入嵌入矩阵。 L 是序列长度, d 是每个行为物品的隐藏向量嵌入维度。为清晰起见, 这里只选取一个样本而非一批样本。矩




Figure 2: 本文 ETA (End-to-end Target Attention, 端到端目标注意力) 模型示意图。 $e_{k+1} \in \mathbb{R}^{d \times 1}$ 和 $e_t \in \mathbb{R}^{d \times 1}$ 表示行为物品 $k+1$ 与目标物品 t 的嵌入向量。 d 是物品嵌入的维度。 h_{k+1} 和 h_t 是由 SimHash 函数为物品 $k+1$ 和 t 生成的指纹。一个 d 维嵌入 e_{k+1} 可被哈希为一个 m 位整数。为清晰起见，图中省略了嵌入向量 e_{k+1} 和 e_t 在 SimHash 之前的投影。其他符号见表 1。

阵 Q, K, V 分别表示查询、键和值。 d_k, d_q, d_v 是 Q, K, V 中每个行向量的嵌入维度。 $\sqrt{d_k}$ 用于避免内积值过大。 softmax 函数用于将内积值转换为值向量 V 的加权权重。 $W_i^Q \in \mathbb{R}^{d \times d_k}, W_i^K \in \mathbb{R}^{d \times d_k}, W_i^V \in \mathbb{R}^{d \times d_v}$ 。 $W^O \in \mathbb{R}^{h d_o \times d}$ 是投影矩阵。 h 是注意力头的数量。

4.4 长期兴趣提取单元

这一部分是 ETA 模型的主要贡献。它将用户行为序列的编码长度从数十扩展到数千甚至更长，以捕捉用户的长期兴趣。如前所述，多头目标注意力的复杂度为 $O(L * B * d)$ ，其中 L 是用户序列长度， B 是候选物品数量， d 是表示维度。在大规模在线系统中， B 接近 1000， d 接近 128。因此，直接对数千个长期用户行为执行多头目标注意力是不可行的。

根据式 5， softmax 由最大的元素主导；对于每个查询，我们只需关注与查询最接近的键，这一点也得到了 [13, 21, 22] 的证实。因此，我们可以先从行为序列中检索 top- k 个物品，再对这 k 个行为执行多头目标注意力。然而，一个好的检索算法应满足两个约束：1) 检索部分的目标应与整个 CTR 模型保持一致。只有这样，top- k 检索出的物品才能对 CTR 模型作出最大贡献。2) 检索时间应满足严格的推理时延限制，以确保该算法可应用于现实系统，每秒服务数百万个请求。我们在表 2 中比较了不同的检索算法。SIM [21] 和 UBR4CTR [22] 构建离线倒排索引，以便在训练和推理期间快速搜索。然而，它们用于构建索引的输入是属性信息（例如类别）或物品的预训练嵌入，与 CTR 模型中使用的嵌入不同。这一差距违反了上述约束 1)，并可能导致性能下降。如果直接使用 CTR 模型中的嵌入，并通过内积搜索 k 近邻，则需要执行 $O(L * B * d)$ 次乘法，推理时间会大幅增加。 d 是嵌入向量的维度。 L 和 B 分别是行

为物品和目标物品的数量。这会违反上述约束 2)，因而无法在线部署。ETA 使用 SimHash 将两个向量的内积转换为汉明距离计算，如图 2 所示，从而使其能够部署在现实推荐系统中。此外，SimHash 的局部敏感特性可确保指纹始终与 CTR 模型中的原始嵌入同步。第 5 节的评估表明，这种兼容性能够显著提升性能。如何选择合适的哈希函数，以及检索部分与 ETA 其余部分之间的联合学习，将在第 4.5.2 节和第 4.5.1 节中说明。

经过 SimHash 函数和汉明距离层后，选出 top- k 个相似行为物品，这些物品来自 $\mathcal{H}_{lu}$ ，然后执行上述多头目标注意力以生成隐藏向量。该向量作为用户长期兴趣的表示，与其他向量一起输入 MLP（多层感知机）层。长期用户兴趣单元的形式化表达见下式 6。

$$\text{LTI}(E_t, E_s) = \text{TA}(E_t, E'_s), \quad (6)$$

$$E'_s = \begin{bmatrix} e_1^T \\ e_i^T \\ \vdots \\ e_k^T \end{bmatrix}, \quad (7)$$

$$e_i \in \text{topk}(\text{HammingDistance}(h_i, h_t)), \quad (8)$$

$$h_i = \text{SimHash}(e_i), h_t = \text{SimHash}(e_t), \quad (9)$$

其中，LTI 和 TA 分别是长期用户兴趣提取单元和多头目标注意力的缩写。 $E_s \in \mathbb{R}^{|\mathcal{H}_{lu}| \times d}$ 是长期用户行为序列 $\mathcal{H}_{lu}$ 的嵌入矩阵。 $E'_s \in \mathbb{R}^{k \times d}$ 由 top k 行组成，这些行选自 E_s ，这些行与目标物品 $E_t \in \mathbb{R}^{1 \times d}$ 具有最大的汉明距离。

Table 2: 不同检索算法的比较。 d 是嵌入向量的维度。 L 和 B 分别是行为物品和目标物品的数量。 m 是 SimHash 生成的指纹维度。 M 是每名用户的属性倒排索引大小。在现实 CTR 模型中, $L = 1024, B = 1024, d = 128, m = 4, M = 300$ 。值得注意的是, 直接在线执行内积违反时延约束, 无法部署于大规模在线 RS。

检索输入	检索方法	检索与 CTR 模型之间的目标差距	检索复杂度	代表性方法
属性	离线倒排索引	大	$O(B * \log(M))$	SIM(hard) [21] 和 UBR4CTR [22]
预训练嵌入	离线倒排索引和欧氏距离	中	$O(B * M * d)$	SIM(soft) [21]
基于 SimHash 的指纹	汉明距离	小	$O(B * L * m)$	ETA
CTR 模型的嵌入	内积	无	$O(B * L * d)$	无法部署

相似度函数. 如图 2 所示, 我们使用 SimHash 函数和汉明距离代替内积来计算两个嵌入向量的相似度。SimHash 函数以上述嵌入层的输出作为输入。对于每个输入嵌入向量, SimHash 函数都会生成其压缩数值作为指纹。SimHash 满足局部敏感特性: 如果输入特征彼此相似, 则哈希输出也相似。因此, 可以用哈希指纹之间的相似度替代嵌入向量之间的相似度。一个 d 维嵌入向量可编码为 m 位数值。随后, 两个指纹之间的相似度可通过汉明距离衡量。

Top-K 检索. 与基于内积的模型相比, top-k 检索层可以通过汉明距离更高效地找出与目标物品最相似的 top-k 个用户行为物品。两个整数之间的汉明距离定义为对应位不同的位置数量。为获得两个 m 位数值的汉明距离, 我们首先执行 XOR, 然后统计值为 1 的位数。如果将乘法定义为原子操作, 则两个 m 位数值值的汉明距离复杂度为 $O(1)$ 。基于汉明距离的 top-k 检索总复杂度为 $O(L * B * 1)$, 其中 L 是序列长度, B 是候选物品数量。值得注意的是, 每次执行 SimHash 函数后, 哈希指纹都可以随模型一起存储在嵌入表中。推理期间只需进行嵌入查找, 其复杂度可忽略不计。

4.5 部署

本节首先介绍 ETA 如何与检索部分联合训练, 然后介绍如何选择 SimHash 算法中使用的“哈希函数”, 最后介绍工程优化技巧。

4.5.1 检索部分的联合学习. 在训练阶段, 检索部分无需进行梯度更新。检索的目标是为后续多头注意力部分选择与查询最接近的键。在选出与查询最接近的 top-k 个键后, 将在这些 top-k 物品的原始嵌入向量上执行常规注意力计算和反向传播。检索部分唯一需要做的是在训练开始时初始化一个固定随机矩阵 $H \in \mathbb{R}^{d \times m}$ (见算法 1)。只要输入嵌入向量 $e_k \in \mathbb{R}^{1 \times d}$ 得到更新, SimHash 的签名也会相应更新。局部敏感特性确保每次迭代中, 都能使用 CTR 模型的最新嵌入无缝选出与查询最接近的 top-k 个键。因此, 检索与 CTR 模型之间的目标差距远小于其他检索方法, 例如表 2 所示的基于离线倒排索引的方法。从 CTR 模型的角度看, 检索部分是透明的, 却能确保模型使用最接近的物品执行多头注意力。评估部分 (第 5 节) 表明, 这种无需任何预训练或离线倒排索引构建的端到端训练能够显著提升 CTR 预测任务的性能。

4.5.2 “哈希函数”的选择. SimHash 是一种著名的局部敏感哈希 (LSH) [1] 算法。SimHash 的实现见算法 1, 其中使用固定随机哈希向量充当“哈希函数”。任何将字符串哈希为随机整数的传统哈希函数也都可以使用。然而, 出于矩阵计算的扩展性和效率考虑, 我们在算法中选择随机哈希向量以及算法 1 的

Table 3: 本文所用数据集的语料规模。

	用户数	物品数	类别数	实例数
Taobao.	987,994	4,162,024	9,439	100,150,807
Industrial(Our Own)	4 亿	7 亿	24,568	1420 亿

实现, 这与 Reformer [13] 相同。局部敏感哈希通过随机旋转和投影实现。随机旋转是指嵌入向量与固定随机哈希向量 $H(j)$ 之间的乘法。此处可以使用任意随机的 d 维向量。值得注意的是, 由于我们需要将内积结果投影到两个带符号的轴上以获得二进制签名, 因此 $H(j)$ 中的元素应在 0 附近随机生成。

4.5.3 工程优化技巧. 模型在线部署后, 可以进一步减少一步 SimHash 计算。对于长度为 m 的签名向量 sig_k , 它对应嵌入向量 e_k , 并由算法 1 计算; 由于签名向量可用 $\log(m)$ 位整数表示, 且 sig_k 中的每个元素非 1 即 0, 因此能够显著降低内存成本, 并加速汉明距离计算。两个整数之间的计算可在 $O(1)$ 时间复杂度内完成, 因而可以忽略不计。

5 实验

本节通过实验回答以下研究问题。

- **RQ1:** 我们的 ETA 模型是否优于基线模型?
- **RQ2:** 与基线模型相比, 我们的 ETA 模型推理时间如何? 推理时间与性能同等重要, 因为它决定模型能否上线部署并提供服务。
- **RQ3:** ETA 模型的哪一部分对性能和推理时间贡献最大?

在给出评估结果之前, 我们先介绍数据集、基线模型、指标和实验设置。

5.1 数据集

为全面比较 ETA 模型与基线模型, 我们同时使用公开数据集和工业数据集, 并开展线上 A/B 测试。对于公开数据集, 我们选择 Taobao 数据集, 基线模型 SIM [21] 和 UBR4CTR [22] 也采用了该数据集。我们还准备了一个工业数据集作为公开数据集的补充。表 3 简要介绍了这些数据集。

Taobao 数据集¹: 该数据集最初由 [38] 发布, 被广泛用作 CTR 预测任务与序列推荐任务的公开基准。它由 Taobao 移动应用中的用户行为日志组成, 用户行为包括点击、收藏、加入购物车和购买。该数据集包含 1 亿个实例。平均而言, 每位用户约有 101 次交互, 每个物品获得超过 24 次交互。最近 16 个行为被选作短期用户行为序列, 最近 256 个行为被选作长期用户行为序列。

¹<https://tianchi.aliyun.com/dataset/dataDetail?dataId=649&userId=1>

工业数据集²：该数据集采集自我们自己的在线 RS，它是本国顶级移动应用之一。我们的工业数据集具有三项优势。(i) 数据集包含曝光交互，即物品向用户展示但未被用户点击。曝光交互天然就是 CTR 模型的负样本，因此无需复杂的负采样。(ii) 我们工业数据集中的用户行为序列要长得多。数据集中有超过 1420 亿个实例，平均长度达到 938，是公开 Taobao 数据集的 9 倍。(iii) 我们的工业数据集包含由多名软件工程师设计的更多特征，因而更接近真实世界的 RS 模型。最近 48 个行为被选作短期用户行为序列，最近 1024 个行为被选作长期用户行为序列。在消融研究中，我们还尝试了长度取自 {256, 512, 2048} 的长期用户行为序列。

5.2 基线与指标

基线：我们将模型与以下主流 CTR 预测基线进行比较。选择每个基线是为了回答上述一个或多个相关研究问题。

- **Avg-Pooling DNN**：利用用户行为序列最简单的方法是平均池化，它将长度不一的用户序列编码为固定大小的隐向量。该基线可视为将目标注意力替换为平均池化的 DIN 变体，与 YouTube [6] 类似。将其与 DIN 比较，主要用于说明目标注意力的必要性。
- **DIN** [36]：DIN 通过一种称为目标注意力的注意力机制，针对不同目标物品对个性化用户兴趣建模。然而，DIN 仅使用短期用户行为序列。
- **DIN (长序列)**：是在 DIN 中加入长期用户行为序列 $\mathcal{H}_{lu}$ 。 $\mathcal{H}_{lu}$ 通过平均池化编码。将该基线与 DIN 比较，可衡量长期用户行为序列本身带来的信息增益。
- **SIM(hard)** [21]：SIM 是一种 CTR 预测模型，它提出搜索单元，以两阶段方式从长期用户行为序列中提取用户兴趣。SIM(hard) 是在第一阶段根据类别 ID 搜索 top-k 行为物品的 SIM。
- **UBR4CTR** [22]：UBR4CTR 同样是一种在 CTR 预测任务中利用长期用户行为序列的两阶段方法。在 UBR4CTR 中，特征选择模型生成查询，用于检索最相似的行为物品，并为线上使用构建倒排索引。由于 UBR4CTR 与 SIM 几乎同时发表，二者没有相互比较。本文首次同时比较 UBR4CTR 与 SIM。
- **SIM(hard)/UBR4CTR + timeinfo** 是在编码用户行为序列时加入时间嵌入的 SIM(hard)/UBR4CTR。

在 [21] 中，作者提出 SIM(soft) 作为基础算法 SIM(hard) 的变体。他们最终采用 SIM(hard) 作为线上服务算法，并将 SIM(hard)+timeinfo 部署上线，为主要流量提供服务。这是因为 SIM(hard) 无需预训练，更便于系统演进与维护。此外，SIM(hard) + timeinfo 能够取得与 SIM(soft) 相当的性能。因此，我们选择 SIM(hard) 和 SIM(hard) + timeinfo 作为强基线。

MIMN [20] 由提出 DIN 的同一团队提出。MIMN 提出一种多通路离线用户兴趣中心，用于提取长期用户兴趣。在发表时，它利用长期用户行为序列取得了当前最先进的性能。然而，MIMN 后来被同一团队提出的 SIM [21] 超越。由于 MIMN 对我们的研究问题帮助不大，受篇幅限制，我们省略该基线。

指标：在离线实验中，我们采用广泛使用的 ROC 曲线下面积 (AUC) 作为主要指标，并以推理时间作为补充指标。AUC 适用于二分类问题，用于衡量成对排序性能。推理时间定义为某个模型请求对一批物品进行打分的往返耗时。我们将模型部署上线，为从生产环境复制的用户请求提供服务，据此测量推理时间。为公平比较，各实验使用相同的机器和用户请求数量。

²该数据集将向公众发布，以促进长期用户兴趣建模研究。

Table 4: Taobao 数据集上的实验结果。

方法	AUC
Avg-Pooling DNN	0.8442
DIN	0.8626
DIN (长序列)	0.8661
UBR4CTR	0.8651
UBR4CTR+timeinfo	0.8683
SIM(hard)	0.8675
SIM(hard)+timeinfo	0.8708
ETA	0.8721
ETA+timeinfo	0.8746

Table 5: 工业数据集上的实验结果。

方法	AUC	推理时间 (ms)
Avg-Pooling DNN	0.7216	8
DIN	0.7279	11
DIN (长序列)	0.7311	14
UBR4CTR	0.7318	41
UBR4CTR+timeinfo	0.7331	41
SIM(hard)	0.7327	21
SIM(hard)+timeinfo	0.7338	21
ETA	0.7361	19
ETA+timeinfo	0.7373	19

在线 A/B 测试使用 CLICK 和 CTR 作为评估指标。CLICK 定义为被点击物品的总数。CTR 用于衡量平台中用户的点击意愿，定义为 $CLICK/PV$ ，其中 PV 定义为展示物品的总数。

5.3 实验设置

本节首先介绍离线数据集的预处理，然后列出基线模型和我们模型的超参数。

Taobao 数据集仅包含正向交互，例如评论、点击、收藏、加入购物车和购买。我们采用与 MIMN [20] 相同的数据预处理方法。首先，对于每个用户，我们选择最后一次行为作为正样本。然后，为该用户随机采样一个类别相同的新物品作为负样本。其余行为物品用作特征。根据样本的时间戳 t ，将样本划分为训练集 (80%)、验证集 (10%) 和测试集 (10%)。

我们的工业数据集天然包含正负样本，因为我们记录了每个用户的所有曝光。如果用户点击了曝光物品，则将该曝光标记为正样本；否则标记为负样本。与 SIM [21] 类似，我们使用过去两周的日志作为训练集，并使用随后一天的日志作为测试集。

对于不同数据集上的每个模型，我们使用验证集调节超参数以获得最佳性能。学习率的搜索范围为 1×10^{-4} 到 1×10^{-2} ，L2 正则化项的搜索范围为 1×10^{-4} 到 1。所有模型均使用 Adam 优化器。Taobao 数据集和我们的工业数据集的批大小分别为 256 和 1024。

5.4 性能比较

Taobao 数据集：Taobao 数据集上的评估结果见表 4。从表中可以看出，与所有基线相比，我们的 ETA 均取得了稳定的性能提升。ETA 比 SIM(hard) 高 0.46%，比 DIN(Long Sequence) 高 0.6%。加入时间嵌入后，ETA+timeinfo 比 SIM(hard)+timeinfo 高 0.38%，比 DIN(Long Sequence) 高 0.85%。在 SIM(hard) 和 UBR4CTR 上也

Table 6: 在线 A/B 测试中相对于不使用长期用户行为序列的 DIN 方法的性能相对提升与推理时间。需要注意的是, GMV 提升 1% 已是显著改进, 因为这意味着为推荐系统带来数百万的额外收入。

方法	CTR	GMV	推理时间
SIM(hard)+timeinfo	4.53%	6.6%	21ms
ETA+timeinfo	6.33%	9.7%	19ms

能观察到类似结果。与 DIN 相比, DIN(Long Sequence) 的 AUC 提升了 0.35%, 说明对长期用户行为序列进行建模对于 CTR 预测是有效的。我们还发现 UBR4CTR 的表现不如 DIN(Long Sequence)。这是因为 UBR4CTR 的特征选择模型仅选择特征 (例如类别、星期) 与目标物品相同的行为。UBR4CTR 中的这种过滤有助于去除序列噪声, 但也会缩短用户序列; 当用于 top-k 检索的物品数量不足时, 这一点会造成不利影响。从表 4 可见, DIN 比 Avg-Pooling DNN 高 1.84%, 表明使用目标注意力编码用户序列能够显著提升性能。

工业数据集: 我们自有工业数据集上的评估结果见表 5。需要注意的是, CTR 模型的 AUC 提升 0.1% 就能为我们的在线推荐系统带来数百万次真实点击和相应收入。与所有基线相比, 我们的 ETA 取得了最佳性能。基础版 ETA 相比 SIM(hard) 和 UBR4CTR 分别提升 0.34% 和 0.43%; ETA+timeinfo 相比 SIM(hard)+timeinfo 和 UBR4CTR+timeinfo 分别提升 0.35% 和 0.42%。与公开数据集上的实验结果不同, SIM(hard)+timeinfo 成为工业数据集上最强的基线, 并比 DIN(Long Sequence) 高 0.27%。这有两个原因。一方面, 工业数据集中的用户序列足够长, 适合基于长期用户序列的模型。工业数据集的平均长度达到 938, 是公开 Taobao 数据集的 9 倍。另一方面, DNN (Long Sequence) 使用平均池化对整个序列进行编码而不进行选择, 与 UBR4CTR、SIM 和 ETA 等基于检索的模型相比, 可能会引入噪声。

我们还可以发现, 相比 UBR4CTR, SIM(hard) 的性能提高了 0.09%。这主要源于二者对用户行为序列采用了不同的处理方式。在 SIM(hard) 中, 用户序列被划分为两个独立的子序列, 这与图 2 中的 ETA 类似。短期用户行为序列 $\mathcal{H}_{su}$ 由从物品 1 到物品 k 的最近 k 个用户行为组成。长期用户行为序列 $\mathcal{H}_{lu}$ 则由从物品 $k+1$ 到物品 n 中选出的另外 k 个行为组成。然而, UBR4CTR 从物品 1 到物品 n 中选择长度为 $2 * k$ 的行为序列。因此, 最近的 k 个物品 (图 2 中的 e_1 到 e_k) 被 SIM(hard) 以 100% 的概率选中, 而被 UBR4CTR 选中的概率则由特征选择模型决定的 p 。然而, 由于用户兴趣具有动态性且频繁变化, timeinfo 在用户兴趣建模中发挥着重要作用。因此, SIM(hard) 的表现优于 UBR4CTR。

在线 A/B 测试: 在线 A/B 测试的评估结果见表 6。表 6 给出了相对于 DIN 方法的性能提升, 其中该 DIN 方法不包含长期用户行为序列。从表 6 可见, 与基于 DIN 的方法相比, 我们的 ETA+timestamp 在 CTR 上提升 6.33%, 并带来 9.7% 的额外 GMV。与最强基线 SIM(hard)+timeinfo 相比, 我们的 ETA+timeinfo 在 CTR 上额外提升 1.8%, 在 GMV 上额外提升 3.1%。需要注意的是, GMV 提升 1% 已是显著改进, 因为这意味着为推荐系统带来数百万的额外收入。

5.5 推理时间比较

尽管使用长期用户行为序列提高了 CTR 预测性能, 但模型复杂度也相应增加。我们测量了不同模型的推理时间, 结果见表 4。Avg-Pooling DNN 的推理时间最短, 为 8 毫秒 (ms)。它仅使




Figure 3: 采用不同哈希指纹比特长度时 ETA 的 AUC。其他模型设置与表 5 中的 ETA 相同。

Table 7: 我们的 ETA 模型在工业数据集上的消融研究。v0 是 ETA 的基础版本。avg(.) 和 ta(.) 分别表示通过平均池化和目标注意力编码用户行为。ta(1024 -s- 48) 表示在从 1024 个连续用户行为物品中选出的前 48 个用户行为上执行目标注意力。ta(1024 -s- 48) 中的符号 s 表示使用 SimHash 从 1024 个行为中选出前 48 个。类似地, ta(1024 -i- 48) 中的符号 i 表示使用内积从 1024 个行为中选出前 48 个。

ETA 版本	编码方式	AUC	推理时间 (ms)
v0	ta(1024 -s- 48)	0.7361	19
v1	avg(1024)	0.7311	14
v2.1	ta(256 -s- 48)	0.7339	14
v2.2	ta(512 -s- 48)	0.7348	16
v2.3	ta(2048 -s- 48)	0.7394	23
v3	ta(1024 -i- 48)	0.7368	32
v4	ta(1024)	0.7371	35

用平均池化方法编码最近的行为物品。将平均池化替换为目标注意力后, 推理时间增加 3ms (从 8ms 增至 11ms)。引入长期用户行为序列后, 推理时间又增加 3ms (从 11ms 增至 14ms)。SIM 和我们的 ETA 推理时间相近, 约为 19~21 ms。UBR4CTR 的推理时间最长, 因为它在检索阶段之前额外使用了一个特征选择模型, 并且在线执行了相对耗时的基于 IDF 和 BM25 的流程, 以获得前 k 个物品。

5.6 消融研究

表 7 给出了消融研究结果, 以回答研究问题 RQ3。我们使用编码方式来区分 ETA 模型的不同版本 (v0 至 v4)。需要注意的是, v0 是 ETA 的基础版本。编码方式列于表 7 第二列, 其中 avg(.) 和 ta(.) 分别表示通过平均池化和目标注意力编码用户行为。ta(1024 -s- 48) 表示在从 1024 个连续用户行为物品中选出的前 48 个用户行为上执行目标注意力。ta(1024 -s- 48) 中的符号 s 表示使用 SimHash 从 1024 个行为中选出前 48 个。类似地, ta(1024 -i- 48) 中的符号 i 表示使用内积从 1024 个行为中选出前 48 个。

从表 7 可以得到以下观察。(i) 直接在原始的长度为 1024 的用户序列上执行多头目标注意力 (v4), 能够取得最佳性能, 但同时也具有最高的推理时间。与 v4 相比, 我们的基础 ETA (v0) 选择前 k 个行为进行注意力计算, 牺牲了约 0.1% 的 AUC, 却将推理时间降低了 46%。(ii) 比较 v3 和 v0, 在检索阶段用内积

替换 SimHash, 可使 AUC 提升 0.07%。然而, 推理时间增加了 68%, 这在我们严格的在线 SLA (服务级别协议) 下不可接受。

(iii) 当我们改变用户行为序列长度 ($v2.x$ 与 $v0$) 时, 可以观察到 AUC 与推理时间之间的权衡。可根据在线推理时间要求确定适当的序列长度。我们还在图 3 中评估了 SimHash 生成的不同哈希指纹比特长度 h 下的性能。如第 3.2 节所述, 指纹的比特长度可由 SimHash 所用哈希函数的数量控制。可以发现, 增加 h 的比特长度能够提高 AUC。然而, 当 h 的比特长度大于嵌入维度的 $2\times$ 时, AUC 的提升变得有限。

6 结论

本文提出用于 CTR 预测任务的 ETA 模型。据我们所知, ETA 是首个能够以端到端方式联合建模 CTR 与长期用户行为序列的方法。与当前最先进的两阶段模型相比, 端到端范式使检索部分能够与 CTR 模型的主体部分无缝共享信息, 从而显著提升预测性能。此外, 该范式也便于大规模在线 RS 中 CTR 模型的维护与演进。为实现端到端在线检索, 我们提出一种基于 SimHash 的方法, 将传统 top- k 检索的复杂度从 $O(L*B*d)$ 次乘法运算降低为 $O(L*B)$ 次汉明距离计算, 其中 L 是用户序列长度, B 是每个孩子请求对应的候选物品数量, d 是物品嵌入维度。离线和线上实验均证实了 ETA 的有效性。与当前最先进的模型相比, 在线 A/B 测试中的总 GMV 提升了 3.1%。ETA 已上线部署, 为主流流量提供服务。

REFERENCES

- [1] Alexandr Andoni, Piotr Indyk, Thijs Laarhoven, Ilya Razenshteyn, and Ludwig Schmidt. 2015. Practical and optimal LSH for angular distance. *arXiv preprint arXiv:1509.02897* (2015).
- [2] Moses S Charikar. 2002. Similarity estimation techniques from rounding algorithms. In *Proceedings of the thirty-fourth annual ACM symposium on Theory of computing*. 380–388.
- [3] Heng-Tze Cheng, Levent Koc, Jeremiah Harmsen, Tal Shaked, Tushar Chandra, Hrishu Aradhye, Glen Anderson, Greg Corrado, Wei Chai, Mustafa Ipsir, et al. 2016. Wide & deep learning for recommender systems. In *Proceedings of the 1st workshop on deep learning for recommender systems*. 7–10.
- [4] Kyunghyun Cho, Bart Van Merriënboer, Dzmitry Bahdanau, and Yoshua Bengio. 2014. On the properties of neural machine translation: Encoder-decoder approaches. *arXiv preprint arXiv:1409.1259* (2014).
- [5] Kyunghyun Cho, Bart Van Merriënboer, Caglar Gulcehre, Dzmitry Bahdanau, Fethi Bougares, Holger Schwenk, and Yoshua Bengio. 2014. Learning phrase representations using RNN encoder-decoder for statistical machine translation. *arXiv preprint arXiv:1406.1078* (2014).
- [6] Paul Covington, Jay Adams, and Emre Sargin. 2016. Deep neural networks for youtube recommendations. In *Proceedings of the 10th ACM conference on recommender systems*. 191–198.
- [7] Yufei Feng, Fuyu Lv, Weichen Shen, Menghan Wang, Fei Sun, Yu Zhu, and Keping Yang. 2019. Deep session interest network for click-through rate prediction. *arXiv preprint arXiv:1905.06482* (2019).
- [8] Hui Feng Guo, Ruiming Tang, Yunming Ye, Zhenguo Li, and Xiuqiang He. 2017. DeepFM: a factorization-machine based neural network for CTR prediction. *arXiv preprint arXiv:1703.04247* (2017).
- [9] Xinran He, Junfeng Pan, Ou Jin, Tianbing Xu, Bo Liu, Tao Xu, Yanxin Shi, Antoine Atallah, Ralf Herbrich, Stuart Bowers, et al. 2014. Practical lessons from predicting clicks on ads at facebook. In *Proceedings of the Eighth International Workshop on Data Mining for Online Advertising*. 1–9.
- [10] Balázs Hidasi, Alexandros Karatzoglou, Linas Baltrunas, and Domonkos Tikk. 2015. Session-based recommendations with recurrent neural networks. *arXiv preprint arXiv:1511.06939* (2015).
- [11] Sepp Hochreiter and Jürgen Schmidhuber. 1997. Long short-term memory. *Neural computation* 9, 8 (1997), 1735–1780.
- [12] Wang-Cheng Kang and Julian McAuley. 2018. Self-attentive sequential recommendation. In *2018 IEEE International Conference on Data Mining (ICDM)*. IEEE, 197–206.
- [13] Nikita Kitaev, Łukasz Kaiser, and Anselm Levskaya. 2020. Reformer: The efficient transformer. *arXiv preprint arXiv:2001.04451* (2020).
- [14] Yann LeCun, Bernhard Boser, John S Denker, Donnie Henderson, Richard E Howard, Wayne Hubbard, and Lawrence D Jackel. 1989. Backpropagation applied to handwritten zip code recognition. *Neural computation* 1, 4 (1989), 541–551.
- [15] Chao Li, Zhiyuan Liu, Mengmeng Wu, Yuchi Xu, Huan Zhao, Pipei Huang, Guoliang Kang, Qiwei Chen, Wei Li, and Dik Lun Lee. 2019. Multi-interest network with dynamic routing for recommendation at Tmall. In *Proceedings of the 28th ACM International Conference on Information and Knowledge Management*. 2615–2623.
- [16] Zeyu Li, Wei Cheng, Yang Chen, Haifeng Chen, and Wei Wang. 2020. Interpretable Click-Through Rate Prediction through Hierarchical Attention. In *Proceedings of the Thirteenth ACM International Conference on Web Search and Data Mining*. ACM.
- [17] Jianxun Lian, Xiaohuan Zhou, Fuzheng Zhang, Zhongxia Chen, Xing Xie, and Guangzhong Sun. 2018. xdeepfm: Combining explicit and implicit feature interactions for recommender systems. In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. 1754–1763.
- [18] Gurmeet Singh Manku, Arvind Jain, and Anish Das Sarma. 2007. Detecting near-duplicates for web crawling. In *Proceedings of the 16th international conference on World Wide Web*. 141–150.
- [19] Junwei Pan, Jian Xu, Alfonso Lobos Ruiz, Wenliang Zhao, Shengjun Pan, Yu Sun, and Quan Lu. 2018. Field-weighted factorization machines for click-through rate prediction in display advertising. In *Proceedings of the 2018 World Wide Web Conference*. 1349–1357.
- [20] Qi Pi, Weijie Bian, Guorui Zhou, Xiaoqiang Zhu, and Kun Gai. 2019. Practice on long sequential user behavior modeling for click-through rate prediction. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. 2671–2679.
- [21] Pi Qi, Xiaoqiang Zhu, Guorui Zhou, Yujing Zhang, Zhe Wang, Lejian Ren, Ying Fan, and Kun Gai. 2020. Search-based User Interest Modeling with Lifelong Sequential Behavior Data for Click-Through Rate Prediction. *arXiv preprint arXiv:2006.05639* (2020).
- [22] Jiarui Qin, Weinan Zhang, Xin Wu, Jiarui Jin, Yuchen Fang, and Yong Yu. 2020. User Behavior Retrieval for Click-Through Rate Prediction. *arXiv preprint arXiv:2005.14171* (2020).
- [23] Yanru Qu, Han Cai, Kan Ren, Weinan Zhang, Yong Yu, Ying Wen, and Jun Wang. 2016. Product-based neural networks for user response prediction. In *2016 IEEE 16th International Conference on Data Mining (ICDM)*. IEEE, 1149–1154.
- [24] Kan Ren, Jiarui Qin, Yuchen Fang, Weinan Zhang, Lei Zheng, Weijie Bian, Guorui Zhou, Jian Xu, Yong Yu, Xiaoqiang Zhu, et al. 2019. Lifelong Sequential Modeling with Personalized Memorization for User Response Prediction. In *Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval*. 565–574.
- [25] Steffen Rendle. 2010. Factorization machines. In *2010 IEEE International Conference on Data Mining*. IEEE, 995–1000.
- [26] Fei Sun, Jun Liu, Jian Wu, Changhua Pei, Xiao Lin, Wenwu Ou, and Peng Jiang. 2019. BERT4Rec: Sequential recommendation with bidirectional encoder representations from transformer. In *Proceedings of the 28th ACM International Conference on Information and Knowledge Management*. 1441–1450.
- [27] Jiayi Tang and Ke Wang. 2018. Personalized top-n sequential recommendation via convolutional sequence embedding. In *Proceedings of the Eleventh ACM International Conference on Web Search and Data Mining*. 565–573.
- [28] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. 2017. Attention Is All You Need. *CoRR abs/1706.03762* (2017). [arXiv:1706.03762](http://arxiv.org/abs/1706.03762)
- [29] Ruoxi Wang, Bin Fu, Gang Fu, and Mingliang Wang. 2017. Deep & cross network for ad click predictions. In *Proceedings of the ADKDD'17*. 1–7.
- [30] Jun Xiao, Hao Ye, Xiangnan He, Hanwang Zhang, Fei Wu, and Tat-Seng Chua. 2017. Attentional factorization machines: Learning the weight of feature interactions via attention networks. *arXiv preprint arXiv:1708.04617* (2017).
- [31] Weinan Xu, Hengxu He, Minshi Tan, Yunming Li, Jun Lang, and Dongbai Guo. 2020. Deep Interest with Hierarchical Attention Network for Click-Through Rate Prediction. *arXiv preprint arXiv:2005.12981* (2020).
- [32] Fajie Yuan, Alexandros Karatzoglou, Ioannis Arapakis, Joemon M Jose, and Xiangnan He. 2019. A simple convolutional generative network for next item recommendation. In *Proceedings of the Twelfth ACM International Conference on Web Search and Data Mining*. 582–590.
- [33] Weinan Zhang, Tianming Du, and Jun Wang. 2016. Deep learning over multi-field categorical data. In *European conference on information retrieval*. Springer, 45–57.
- [34] Guorui Zhou, Weijie Bian, Kailun Wu, Lejian Ren, Qi Pi, Yujing Zhang, Can Xiao, Xiang-Rong Sheng, Na Mou, Xinchun Luo, et al. 2020. CAN: Revisiting Feature Co-Action for Click-Through Rate Prediction. *arXiv preprint arXiv:2011.05625* (2020).
- [35] Guorui Zhou, Na Mou, Ying Fan, Qi Pi, Weijie Bian, Chang Zhou, Xiaoqiang Zhu, and Kun Gai. 2019. Deep interest evolution network for click-through rate prediction. In *Proceedings of the AAAI conference on artificial intelligence*, Vol. 33. 5941–5948.
- [36] Guorui Zhou, Xiaoqiang Zhu, Chenru Song, Ying Fan, Han Zhu, Xiao Ma, Yanghui Yan, Junqi Jin, Han Li, and Kun Gai. 2018. Deep interest network for

- click-through rate prediction. In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. 1059–1068.
- [37] Haoyi Zhou, Shanghang Zhang, Jieqi Peng, Shuai Zhang, Jianxin Li, Hui Xiong, and Wancai Zhang. 2020. Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting. *arXiv preprint arXiv:2012.07436* (2020).
- [38] Han Zhu, Daqing Chang, Ziru Xu, Pengye Zhang, Xiang Li, Jie He, Han Li, Jian Xu, and Kun Gai. 2019. Joint optimization of tree-based index and deep model for recommender systems. *arXiv preprint arXiv:1902.07565* (2019).