

Eureka: 面向企业 AI 云资源需求预测的智能特征工程

Hangxuan Li^{12*}, Renjun Jia^{13*}, Xuezhong Wu¹, Yunjie Qian¹, Zeqi Zheng¹,
and Xianling Zhang⁴✉

¹ Alibaba Cloud Computing Co. Ltd, 中国杭州

² 复旦大学计算机科学学院, 中国上海

³ 同济大学计算机科学与技术学院, 中国上海

⁴ 独立研究者, 美国

hqli23@m.fudan.edu.cn, 2332101@tongji.edu.cn, {weixi.wxz, ramsey.qyj,
zhengzeqi.zzq}@alibaba-inc.com, lilyzhng.ai@gmail.com

摘要 有效特征对于预测模型的性能至关重要, 但创建这些特征通常需要领域专业知识, 限制了其跨应用扩展能力。我们将特征工程定义为一个智能体式代码生成问题: 特征并非静态的数据变换, 而是可以生成、评估和迭代改进的可执行程序。我们提出了由 LLM 驱动、包含三个阶段的框架 **Eureka**。(1) 一个通过领域知识监督微调 (SFT) 得到的专家智能体以 JSON 格式生成结构化的特征设计方案。(2) 一个 *LLM* 特征工厂通过思维链推理将每个方案转换为可执行的 Python 代码, 把特征假设变成可运行程序。(3) 一个自进化对齐引擎采用具有双通道奖励 (基于指标的效用 + 语义对齐) 的强化学习 (GRPO) 来提升代码质量。通过将特征表示为程序, 学习到的生成模式可以跨领域迁移。在医疗、金融和社会领域的 7 个公开基准上的评估表明, Eureka 始终优于传统 AutoFE 和基于 LLM 的基线。我们还展示了 Eureka 在 Alibaba Cloud 云 GPU 资源需求预测中的有效性, 其中 Eureka 将需求满足率提高了 16%, 并将计算资源迁移率降低了 33%。

关键词: 特征工程 · 大语言模型 · 代码生成 · 云需求预测 · 强化学习

1 引言

预测模型的性能高度依赖特征质量。有效特征源自能够反映领域逻辑的变量, 但创建这些特征需要特定的专业知识, 限制了其跨领域扩展能力。我们观察到, 特征工程从根本上说是一个代码生成问题: 每个特征都是一个将原始输入转换为预测信号的程序。现有方法将特征设计视为数据问题 (选择或组合列), 但将特征表示为可执行代码, 可使其具备可组合、可测试和跨领域迁移的能力。这一视角在历史数据稀疏且模式波动剧烈的场景中尤为重要, 例如云 GPU 资源预测 [14,16,17]; 在这种场景下, 基础模型工作负载会产生突发且不规则的需求, 使传统方法失效。

在不同的下游任务中, 由于缺乏特征设计所需的领域专业知识和系统性反馈, 现有方法 (见图 1) 仍存在局限:

* Hangxuan Li 和 Renjun Jia 对本工作贡献相同。本工作在两位作者于 Alibaba Cloud Computing Co. Ltd. 实习期间完成。

✉ Xianling Zhang 是通讯作者。




Fig. 1. 不同特征生成范式的比较，重点展示各自的特征、生成方法及局限性/优势。

(1) 人工特征工程依赖领域专业知识，产生的特征仅在狭窄场景中有效，难以跨应用泛化。

(2) 自动化特征工程 (AutoFE) 能够扩展特征生成规模，但缺乏语义理解，生成的特征无法捕捉突发需求模式 [8,9,19]。

(3) 基于 LLM 的特征工程充当静态生成器，缺少用于部署后迭代的反馈闭环，因此无法适应 AI 工作负载中的不规则突发模式 [3,6,13]。

为解决这些局限，我们提出 **Eureka**，一个面向特征工程的智能体式代码生成框架，能够跨应用生成可执行且与领域对齐的特征。我们的系统已完全集成到生产服务中。我们的主要贡献如下：

- **Eureka Expert** (规划阶段) 将领域知识编码为启发式约束和设计模板，以指导对特征交互与跨资源依赖关系的探索。它引导系统发现具有领域意义的候选特征，过滤虚假相关性，并识别能够反映系统动态的高阶特征依赖关系。
- **LLM Feature Factory** (执行阶段) 通过条件代码生成将设计方案转换为具体特征。在领域启发式知识的指导下，它探索特征空间，并输出可执行实现，以从有限的历史数据中最大化信息信号。
- **Self-Evolving Alignment Engine** (优化阶段) 利用真实部署结果提供的双通道奖励反馈来提升特征质量。通过将离线优化与在线性能相连接，它能够使特征适应不规则的工作负载模式，同时防止过拟合。

这些组件共同构成一个闭环系统，其中领域知识指导代码生成，而生成代码的质量则反馈用于改进生成策略。在涵盖医疗、金融和社会领域的 7 个公开基准上的评估表明，Eureka 始终优于传统 AutoFE 和现有的基于 LLM 的方法。我们还在 Alibaba Cloud 的云 GPU 资源需求预测中对该框架进行了端到端验证，Eureka 将需求满足率提高了 16%，将计算资源迁移率降低了 33%，且生成的预警中有 91% 被运维团队采纳。

2 相关工作

自动化特征工程。特征工程仍是机器学习部署中的关键瓶颈，它既需要统计专业知识，也需要领域知识，并且在很大程度上依赖人工和经验。AutoFE 已成为 AutoML 的核心组成部分，用于降低反复试错的成本。FeatureTools 是应用最广泛的方法，可通过深度特征合成 (DFS) [9] 实现关系数据库中的自动化多表特




Fig. 2. 领域特定的特征生成框架。(a) 流水线：生成并筛选领域感知特征的端到端工作流。(b) 特征桶：按类型、来源或语义关系对特征进行分组。(c) 特征生成器：利用 LLM 生成用于创建特征的数学公式和 Python 代码。(d) LLM 训练范式：通过 SFT 和 GRPO 对 LLM 进行微调，以增强特征推理能力。

征融合。此外，还有通过捆绑搜索进行迭代式特征子采样以识别信息丰富特征的方法 [8]，以及结合剪枝算法进行特征提升、实现高效准确筛选的方法 [19,11]。用于 **AutoFE** 的 **LLM**。基础模型的最新进展推动了其在自动化特征工程中的应用 [4]。Hollmann et al. 提出了一种上下文感知方法，利用 LLM 根据任务描述生成具有语义意义的特征 [6]。Han et al. 利用先验知识和上下文线索提取基于规则的二元特征，以支持分类任务 [3]。Nam et al. 将特征生成表述为规则合成问题：由 LLM 提出变换规则，再由决策树识别最优规则。[13]。

然而，这些方法依赖通用世界知识，缺乏深层领域专业知识，因此在复杂的专业数据集上效果较弱。更重要的是，它们以开环方式运行，因而无法从过去的成功或失败中学习，往往退化为固定的组合模式。为克服这些局限，我们提出 **Eureka**，一个将领域引导知识与反馈驱动优化相结合的自进化框架。

3 方法

如图 2 所示，**Eureka** 由三个关键组件构成：**Eureka Expert**、**LLM Feature Factory** 和 **Self-Evolving Alignment Engine**。

3.1 Eureka Expert

Eureka Expert 是一个领域专家型 LLM，通过编码领域知识和业务逻辑来指导有原则的特征探索。通用 LLM 在专业业务场景中能力不足，因此我们采用监督微调（SFT）来嵌入这些知识。开源模型已部署在内部基础设施上，以实现针对具体任务的定制并确保数据安全。




Fig. 3. Eureka Expert

我们的自动化特征工程被表述为一个条件生成问题：给定业务上下文和原始特征的统计概况，目标是生成结构化的特征设计方案。其表示如下：

$$P^* = \arg \max_P p_\theta(P | C, M) \quad (1)$$

其中， C 、 M 和 P 分别表示业务场景描述、包含统计概况的特征元数据，以及生成的特征设计方案（遵循预定义的 JSON schema）。这里， $p_\theta(P | C, M)$ 是由参数为 θ 的 LLM 建模的条件概率。

模型在专家标注数据集 $\mathcal{D}$ 上进行微调，以生成高质量且与领域对齐的特征设计方案。每个样本包含输入 I_i （角色定义、任务要求和特征统计信息）以及输出 O_i （专家生成的含推理过程的方案）。这一过程使模型学会结构化推理和领域特定的构造策略，其形式化表示为：

$$\mathcal{L}_{\text{SFT}}(\theta) = - \sum_{(I_i, O_i) \in \mathcal{D}} \log p_\theta(O_i | I_i) \quad (2)$$

其中， $\mathcal{D} = \{(I_i, O_i)\}_{i=1}^N$ 是训练数据集。最小化 $\mathcal{L}_{\text{SFT}}$ 可促使模型学习专家推理和特征构造模式，将领域特定知识注入模型参数。通过在 $\mathcal{D}$ 中涵盖多样化业务场景和高质量特征集，微调后的模型能够泛化至不同领域和预测任务。SFT 过程在安全的内部基础设施上使用开源 LLM 进行，以确保企业数据得到保护。该模块输出一个含推理过程的特征设计方案，并将其传递给 LLM Feature Factory 进行实现。

3.2 LLM Feature Factory

LLM Feature Factory 是执行模块，通过代码生成与验证，将 Eureka Expert 的特征设计方案转换为具体特征。特征工程可以表述为一个双层优化问题：通过变换 $\mathcal{F} : \mathcal{X} \rightarrow \mathcal{X}'$ 发现特征 $\mathcal{X}'$ ，使在扩充后的特征空间中训练的模型 f 获得更好的性能：

$$\max_{\mathcal{F}} \xi(f^*; \mathcal{D}_{\text{val}} \cup \mathcal{F}(\mathcal{D}_{\text{val}})) \quad \text{s.t.} \quad f^* \in \arg \max_f \xi(f; \mathcal{D}_{\text{train}} \cup \mathcal{F}(\mathcal{D}_{\text{train}})) \quad (3)$$

Algorithm 1 三阶段 LLM 特征工程**Require:** 数据集 $\mathbf{X}$, LLM $\mathcal{M}$, 迭代次数 K **Ensure:** 增强后的数据集 $\mathbf{X}_{enhanced}$

```

1: 阶段 1: 将  $\mathcal{X} \leftarrow \text{partition}(\mathbf{X})$  转换为  $\{\mathcal{X}_{num}, \mathcal{X}_{cat}, \dots\}$ 
2: 初始化  $H_0 \leftarrow \emptyset$ 
3: for  $k = 1$  到  $K$  do
4:   阶段 2: 准备输入  $(N_j, D_j, H_{k-1}, \text{stats}(\mathbf{X}))$ 
5:   阶段 3——思维链:
6:      $R_k \leftarrow \mathcal{M}.\text{generate\_rationale}(\text{inputs})$ 
7:      $F_k \leftarrow \mathcal{M}.\text{formulate\_rule}(R_k)$ 
8:      $C_k \leftarrow \mathcal{M}.\text{generate\_code}(F_k)$ 
9:      $\mathbf{x}_{new} \leftarrow \text{execute}(C_k, \mathbf{X})$ 
10:     $P_k \leftarrow \text{evaluate}(\mathbf{x}_{new})$ 
11:    if  $P_k > \text{threshold}$  then
12:      Update:  $\mathbf{X} \leftarrow \mathbf{X} \cup \{\mathbf{x}_{new}\}$ ,  $H_k \leftarrow H_{k-1} \cup \{(N_k, D_k, P_k, S_k)\}$ 
13:    end if
14: end for
15: return  $\mathbf{X}$ 

```

由于变换不可微且计算复杂, 传统的基于梯度的方法面临挑战。为克服这些局限, 我们引入一个利用 LLM 作为外循环优化器的框架, 将特征工程重新表述为迭代搜索过程。

我们的方法如算法 1 所示, 分三个阶段运行。在阶段 1 中, 数据集按类型划分为若干子集。阶段 2 准备输入, 包括特征元数据、历史记录和统计摘要。阶段 3 采用思维链方法, 由 LLM 生成变换依据、制定特征规则并产出可执行代码。系统对新特征进行评估, 保留优质特征, 同时更新历史记录以供后续迭代使用。这一过程能够探索变换空间, 并利用语义理解生成有意义的特征。

3.3 Self-Evolving Alignment Engine

Self-Evolving Alignment Engine 是一个基于强化学习 (RL) 的模块。其目标是使 SFT 模型的输出与人类偏好的推理方式和领域特定的业务上下文 [15] 对齐, 从而使模型能够内化高质量和低质量特征的生成模式, 并提升后续泛化能力。给定相同的输入上下文, 我们从 SFT 模型中采样一组候选特征设计方案。每个方案都由 LLM Feature Factory 实例化, 在留出数据上评估, 然后使用结合以下两项的双通道奖励进行评分: (1) 基于指标的效用; (2) 语义/业务对齐。我们在 GRPO 框架下利用组内偏好学习优化模型; 该方法天然契合组级排序信号, 且无需单独训练奖励模型。

为平衡特征性能与推理质量, Self-Evolving Alignment Engine 将奖励函数分解为基于指标的分量和基于语义的分量。两者通过加权聚合相结合, 生成最终的优化信号 (公式 4)。

$$R_{\text{total}}(P_i) = \alpha \cdot R_{\text{metric}}(P_i) + \beta \cdot R_{\text{semantic}}(P_i) \quad (4)$$

基于指标的奖励 R_{metric} 使用一组归一化的统计和建模指标量化特征性能, 而基于语义的奖励 R_{semantic} 则评估推理质量和领域特定的业务对齐程度。 R_{metric} 计算为加权点积:

$$R_{\text{metric}}(P_i) = \mathbf{w}^T \tilde{\mathbf{m}}_i \quad (5)$$

$\mathbf{w} = [w_a, w_k, w_i, w_t, w_{\text{imp}}, -w_r]^T$ 是权重向量, 而 $\tilde{\mathbf{m}}_i$ 是归一化指标向量, 其中所有指标值均缩放至 $[0, 1]$ 。

除基于指标的性能外, 基于语义的奖励 R_{semantic} 还根据完整性、因果逻辑合理性以及业务上下文的对齐程度来衡量模型推理的质量。其计算方式是使用更强的 LLM 对候选项进行组内排序, 并将所得名次映射为 $[0, 1]$ 中的标量分数。该奖励的形式化定义如下:

$$R_{\text{semantic}}(P_i) = \frac{K - \text{rank}_{\text{LLM}}(P_i \mid \{P_j\}_{j=1}^K, \mathcal{C})}{K - 1} \quad (6)$$

这里, K 是候选特征的数量, $\text{rank}_{\text{LLM}}(\cdot)$ 是由更强的 LLM 评估器分配的名次。该评估器对候选集 $\{P_j\}_{j=1}^K$ 进行评估, 依据的标准 $\mathcal{C}$ 包括: (1) 推理完整性, (2) 因果逻辑合理性, 以及 (3) 领域对齐。受 RLAIIF 启发, 我们使用 LLM 评估器直接生成实时奖励信号, 从而无需训练单独的奖励模型。这通过利用候选组和相对排名与 GRPO 框架相契合。

为减轻评估器的随机性和偏差, 我们采用一种受控且具有一致性感知能力的评估协议。对于每一组, 我们随机打乱候选项顺序, 并针对 r 次独立乱序 (我们使用 $r=3$) 重新评估, 以降低位置效应; 使用受评分准则约束的提示词, 仅对 $\mathcal{C}$ 中的三项标准进行评分 (明确忽略冗长程度和文体修饰); 并使用固定模板和预算对展示给评估器的证据进行限制与归一化, 以尽量减少与长度相关的偏差。我们通过 Borda 计数聚合 r 个排序结果, 得到稳定的组内排序, 并进一步采用低方差解码来降低方差。我们使用评估器内一致性量化可靠性, 其计算方式为 Kendall's τ 在 r 个排序结果所有两两组合之间的平均值; 同时使用第二个独立评估器检查模型特定偏差, 并将两个聚合排序之间的 Spearman's ρ 作为评估器间一致性进行报告。当一致性较低时, 我们降低语义奖励的权重, 以避免噪声信号破坏 RL 的稳定性: 我们缩放 β , 缩放依据为评估器内一致性 $\bar{\tau}$, 并在 $\bar{\tau}$ 非常低时禁用语义奖励。

将 $K = 5$ 设定为兼顾偏好估计准确性与计算成本。控制基于指标和基于语义的奖励之间权衡的权重 α 和 β 在留出的验证集上进行调优, 并在主要实验中分别设为 $\alpha = 0.6$ 和 $\beta = 0.4$ 。所有指标值均通过最小—最大归一化映射至 $[0, 1]$, 语义排序则由基于 GPT-4 的评估器得出, 该评估器使用固定的评估提示词, 其中编码了 $\mathcal{C}$ 中的标准。训练采用 Adam 优化器, 学习率为 2×10^{-5} , 组批次大小为 $N_g = 64$, 裁剪参数为 0.2, 以确保更新稳定。

4 实验

4.1 实验设置

数据集。我们在 8 个分类数据集上进行评估: Adult [1]、Bank [12]、Blood [18]、Credit-g [5]、Diabetes¹、Heart²、Myocardial [2], 以及来自 Alibaba Cloud 的专有 EGS (Elastic GPU Service)³ 数据集。EGS 数据集源自真实的 GPU 使用日志, 用于突发需求预测; 它是一个按月统计的二分类数据集。随后, 我们应用滑动窗口变化率过滤器, 再依据相对排名和绝对阈值进行双重筛选, 以确保 EGS

¹ <https://kaggle.com/datasets/uciml/pima-indians-diabetes-database>

² <https://kaggle.com/datasets/fedesoriano/heart-failure-prediction>

³ Elastic GPU Service (EGS) 是 Alibaba Cloud 提供的一项云服务, 可提供开箱即用、可扩展的 GPU 加速计算资源。

Table 1. 实验中使用的各数据集的基本信息。括号内的数字分别表示类别属性和数值属性的数量。

数据	# 样本数	# 特征数	标签比例 (%)
Adult	48842	14 (7/7)	76:24
Bank	45211	16 (8/8)	88:12
Blood	748	4 (0/4)	76:24
Credit-g	1000	20 (12/8)	70:30
Diabetes	768	8 (0/8)	65:35
Heart	918	11 (4/7)	45:55
Myocardial	1700	111 (94/17)	22:78
EGS	4837	45 (0/45)	12:88

Table 2. 不同方法和数据集上的性能比较

方法	Adult	Bank	Blood	Credit	Diabetes	Heart	Myocardial	EGS
DFS	0.915	0.897	0.637	0.707	0.882	0.921	0.654	0.680
AutoFe	0.872	0.865	0.735	0.676	0.837	0.903	0.674	0.666
OpenFe	0.920	0.923	0.626	0.701	0.817	0.897	0.697	0.658
TabPFN	0.900	0.904	0.715	0.787	0.888	0.938	0.676	0.694
CAAFE	0.901	0.905	0.713	0.797	0.886	0.941	0.686	0.692
FeatLLM	0.894	0.851	0.678	0.743	0.811	0.881	0.663	0.675
Eureka-Qwen	0.926	0.932	0.738	0.794	0.873	0.926	0.737	0.679
Eureka-32B	0.926	0.932	0.716	0.824	0.884	0.936	0.711	0.688
Eureka-gpt4o	0.928	0.934	0.745	0.838	0.881	0.938	0.699	0.699
Eureka-grok2	0.928	0.934	0.735	0.815	0.886	0.940	0.719	0.686

数据的有效性。我们使用 $\leq 2K$ 个 Q&A 对构建监督微调数据集，主要用于为模型提供领域特定的背景知识。

基线方法。我们针对 5 种自动化 FE 方法进行了广泛评估：Deep Feature Synthesis (DFS) [9]、AutoFE [8]、OpenFE [19]、CAAFE [6] 和 FeatLLM [3]，涵盖传统方法和基于 LLM 的方法。

实验设置。所有方法生成的特征均与原始特征合并，并使用 LightGBM [10] 和 TabPFN [7] 进行评估。性能采用 ROC-AUC 衡量，并报告两个预测器中的最佳结果。对于我们提出的方法，每个训练实例均运行 100 个 epoch，使用 4 块 NVIDIA A100 GPU 耗时 6 小时。

4.2 整体性能比较

根据表 2 的结果，可以得出若干关键结论。所提出的 Eureka 框架在多个数据集上均取得了稳定而优越的性能，尤其在 Myocardial 等特征丰富的数据上表现突出。这一优势源于 Eureka 能够从语义上理解原始特征并生成融入领域知识的特征组合，这在复杂的高维场景中尤为有益。Eureka-Qwen、Eureka-grok2 和 Eureka-gpt4o 使用相应的专有 API，而 Eureka-32B 是基于 Qwen3-32B 微调得到的开源变体。其中，Eureka-gpt4o 在四个数据集（Adult、Bank、Blood 和 Credit-g）上取得最高准确率，并在其他数据集上保持竞争力。Eureka-Qwen 在 Myocardial 上领先（0.737），凸显了其处理特征丰富数据的能力；Eureka-grok2

则在 Heart 上表现最佳,并在 Adult 和 Bank 上取得强劲结果。总体而言, Eureka 持续领先的表现证明了该框架在自动化特征工程中的有效性和泛化能力。

4.3 消融研究

我们通过系统性移除核心模块,在 EGS 数据集上开展消融研究,以评估 Eureka 的各个组件。具体配置和性能见表 3。

Table 3. Eureka 组件的消融研究。

配置	ROC-AUC (%)	Δ 相较于 Eureka (%)
Eureka	69.97	—
不使用 Self Evolving Engine	69.45	-0.52
不使用 Eureka Expert	65.91	-4.06
不使用 LLM Factory	63.84	-6.13

首先, LLM Factory 至关重要,移除它会造成最大的性能下降 (6.13%)。这凸显了我们的自动化特征发现方法相较于传统手工特征工程的优越性。

其次,领域知识注入十分关键。用通用 LLM 替换 Eureka Expert 会使性能下降 4.06%。这验证了通过 SFT 注入的领域洞见对于生成与业务相关的特征至关重要。

最后,自进化对齐提供了关键的优化作用。尽管移除它仅导致 0.52% 的损失,但它能够利用双通道奖励反馈,引导生成可解释性和一致性更强的特征,使模型能够在后续迭代中内化成功策略。

4.4 案例研究

为说明 Eureka 的实际影响,我们展示了一个生产案例: Eureka 成功预测了一次传统监控系统无法检测到的 GPU 需求突增。如图 4 所示,该案例凸显了 Eureka 如何通过综合领域知识而非穷举特征组合,发现具有可解释性的高质量特征。

最初识别出了两个相关性较弱的特征——`gpu_anomaly_acceleration_squared` 和 `scaled_vcpu_gpu_ratio`,而传统方法很可能会将它们舍弃。凭借深厚的领域知识, Eureka Expert 将升高的 `scaled_vcpu_gpu_ratio` 重新解释为大规模 AI 训练的准备信号,而非系统异常;在这种情形下,辅助资源会先于 GPU 密集型阶段进行扩容。这种“准备性失衡”是统计模型通常会忽略的细微前兆,源于客户为应对预期的需求激增而主动提前扩充资源。

在这一业务洞见的指导下, LLM Feature Factory 自动生成候选特征,并通过 Self Evolving Alignment Engine 的验证,将新特征 `scaled_vcpu_gpu_volatility_ratio` 确定为最优特征。该特征旨在精确量化“准备性失衡”阶段。它用较高的 `scaled_vcpu_gpu_ratio` (准备信号)除以接近于零的 `gpu_anomaly_acceleration_squared` (表示 GPU 状态稳定),从而放大需求激增前的检测信号。这种数学结构针对重大训练作业前“暴风雨前的宁静”场景构造了强大而精准的信号。在实际应用中,该新特征的值会在需求达到峰值前数日激增,而标准指标仍保持平稳,从而使 Eureka 能够及时做出预测。




Fig. 4. 获得高质量特征的过程
Table 4. Eureka 在 Alibaba Cloud 的可量化业务影响。

影响领域	关键业务指标	改善幅度
运营采纳	生成预警的采纳率	91%
需求满足	需求满足率（顶级客户）	+16%
资源效率	服务器迁移损耗率降幅	-33%

5 实际应用

Eureka 框架已全面集成到 Alibaba 的 GPU 资源管理系统中，作为企业 AI 算力需求预测的核心模块。其主要目标是通过多源数据流生成 GPU 需求激增的早期预警信号。

为此，Eureka 构建了一套系统化流程：训练数据来源于需求记录，并辅以领域专家输入；模型每月重新训练，以适应不断变化的需求模式。2025 年 6 月至 9 月的验证结果证明了其有效性：Eureka 生成了 165 条预警记录，其中 91% 被资源运营团队采纳为可执行建议，证实了其业务影响（详见表 4）。

Eureka 框架已在工业应用中展现出显著的业务收益。在需求侧，其预测顶级客户需求激增的能力使这些客户的需求满足率提高了 16%，有效保障了服务质量。在供给侧，Eureka 解决了云服务器迁移过程中损耗率长期偏高的问题。通过生成“客户 + 地域”粒度的需求预测，系统能够在需求出现前重新调配运输途中的设备，确保关键资源提前部署，同时减少不必要的重新分配。借助 Eureka 的迁移策略，GPU 服务器迁移损耗率降低了 33%，直接提升了运营效率并降低了成本。

Eureka 的先进特征工程方法超越了传统时间序列预测。该框架利用跨特征交互和时间模式来应对复杂的资源需求动态。

除了直接的运营收益之外，Eureka 还证明了其提供准确预测和优化资源利用的能力。该框架正扩展至弹性计算的各个领域，以统一资源规划、实现大规模主动容量管理，并拓展至其他领域的更广泛应用。

6 结论

本文针对基础模型时代云服务商面临的企业 GPU 需求预测挑战展开研究。我们提出 Eureka，一种融合领域知识与持续学习的智能体式特征工程框架。Eureka 通过三组件架构，将 LLM 的生成能力与领域专业知识相结合。我们在公共基准和 Alibaba Cloud 数据集上均进行了实验。结果表明，Eureka 优于传统方法和现有 AutoFE 基线，在 GPU 突发需求预测任务上实现了 4.95% 的 AUC 提升。

Eureka 已在业务环境中证明了自身价值。自集成到 Alibaba Cloud 的 GPU 资源管理系统以来, Eureka 生成的预警达到了 91% 的采纳率。该系统使顶级客户的需求满足率提高了 16%, 保障了业务稳定性; 并通过预测将 GPU 服务器迁移损耗率降低了 33%, 从而提升了资源利用率和运营效率。

更广泛地说, Eureka 提供了一种可扩展范式, 可将基于 LLM 的智能体框架与企业应用中的领域知识相结合, 为供应链和资源管理领域构建适应性更强、知识感知能力更高的 AI 系统铺平道路。尽管我们的评估聚焦于 GPU 需求预测, 但将该框架扩展到其他资源类型或领域仍是一个重要方向。未来工作还包括探索自监督或自适应奖励学习, 以减少对人工定义启发式规则的依赖。

References

1. Becker, B., Kohavi, R.: Uci machine learning repository: Adult data set (2007)
2. Golovenkin, S.E., Voino-Yasenetsky, V.V., Shulman, V.O., Groen, D.: Chronic heart failure data set for predictive modeling. *Scientific Data* **7**(1), 1–8 (2020)
3. Han, S., Yoon, J., Arik, S.Ö., Pfister, T.: Large language models can automatically engineer features for few-shot tabular learning (2024)
4. Hegselmann, S., Buendia, A., Lang, H., Agrawal, M., Jiang, X., Sontag, D.: Tabllm: Few-shot classification of tabular data with large language models pp. 5549–5581 (2023)
5. Hofmann, H.: Uci machine learning repository: German credit data (2020)
6. Hollmann, N., Müller, S., Hutter, F.: Large language models for automated data science: Introducing caafe for context-aware automated feature engineering (2023)
7. Hollmann, N., Müller, S., Purucker, L., Krishnakumar, A., Körfer, M., Hoo, S.B., Schirrmeister, R.T., Hutter, F.: Accurate predictions on small data with a tabular foundation model. *Nature* (01 2025)
8. Horn, F., Pack, R.T., Rieger, M.: The autofeat python library for automated feature engineering and selection (2019)
9. Kanter, J.M., Veeramachaneni, K.: Deep feature synthesis: Towards automating data science endeavors. 2015 IEEE International Conference on Data Science and Advanced Analytics (DSAA) pp. 1–10 (2015)
10. Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., Liu, T.Y.: Lightgbm: A highly efficient gradient boosting decision tree (2017)
11. Li, L., Wang, H., Zha, L., Huang, Q., Wu, S., Chen, G., Zhao, J.: Learning a data-driven policy network for pre-training automated feature engineering (2023)
12. Moro, S., Cortez, P., Rita, P.: A data-driven approach to predict the success of bank telemarketing. *Decision Support Systems* **62**, 22–31 (2014)
13. Nam, J., Kim, K., Oh, S., Tack, J., Kim, J., Shin, J.: Optimized feature generation for tabular data via LLMs with decision tree reasoning (2024)
14. OpenAI, Achiam, J., Adler, S., et al.: Gpt-4 technical report (2024)
15. Ouyang, L., Wu, J., Jiang, X., et al.: Training language models to follow instructions with human feedback (2022)
16. Team, G., Anil, R., Borgeaud, S., et al.: Gemini: A family of highly capable multimodal models (2025)
17. Yang, A., Li, A., Yang, B., et al.: Qwen3 technical report (2025)
18. Yeh, I.C., Yang, K.J., Ting, T.M.: Uci machine learning repository: Blood transfusion service center data set (2008)
19. Zhang, T., Zhang, Z., Fan, Z., Luo, H., Liu, F., Liu, L.Y.D., Liu, Q., Cao, W., Li, J.: Openfe: Automated feature generation with expert-level performance (2022)