

HubMixer：面向参数高效推荐特征交互的渐进式潜在枢纽混合

Jie Zhou
快手科技
中国北京
zhoujie15@kuaishou.com

Zixian Gong
清华大学
中国北京
gong-zx22@mails.tsinghua.edu.cn

Wenhao Li
快手科技
中国北京
liwenhao05@kuaishou.com

Chang Liu
快手科技
中国北京
liuchang41@kuaishou.com

Enzhao Shen
快手科技
中国北京
shenenzhao@kuaishou.com

Bo Liu
快手科技
中国北京
liubo22@kuaishou.com

Xu Guo[✉]
快手科技
中国北京
guoxu08@kuaishou.com

Fei Pan
快手科技
中国北京
panfei05@kuaishou.com

Peng Jiang
快手科技
中国北京
jiangpeng@kuaishou.com

摘要

学习有效的特征交互是工业推荐与广告排序系统的核心。近期的 token 混合架构以轻量级混合算子简化了 Transformer 风格的自注意力，从而提高硬件效率并支持大规模部署。然而，推荐 token 在本质上具有异质性：用户画像、物品属性、行为序列、上下文特征、统计信号以及业务侧特征处于不同的语义空间，并以稀疏且样本特定的模式发生交互。因此，直接在原始异质 token 空间中混合所有 token 可能导致参数效率低下，因为模型必须隐式发现哪些特征组应当交互，以及应如何路由这些交互。

本文提出 HubMixer，一种用于推荐特征交互的参数高效潜在枢纽混合架构。HubMixer 并不直接混合原始特征 token，而是引入少量可学习的潜在枢纽，通过一种归纳-交互-读出范式来组织特征交互。首先，枢纽归纳通过潜在枢纽以交叉注意力查询输入 token，将异质 token 汇总为紧凑的潜在枢纽。其次，枢纽交互在更纯净的潜在枢纽空间中执行高阶交互。再次，token 条件读出使每个原始 token 能够从完成交互的枢纽中选择性读取信息，在保留 token 级字段身份的同时注入全局交互语义。读出信号通过残差连接注入回 token 表示，使堆叠模块能够逐步细化跨特征语义。在工业推荐任务上的大量离线实验表明，HubMixer 以更少的参数超越了强大的特征交互和 token 混合基线。消融研究验证了枢纽交互和 token 条件读出的有效性。快手短视频招聘业务中的在线 A/B 测试进一步显示，简历投递转化率获得了统计显著的 5.48% 提升，并且 HubMixer 已全面部署于生产环境。

Keywords

推荐系统、排序模型、特征交互

ACM Reference Format:

Jie Zhou, Zixian Gong, Wenhao Li, Chang Liu, Enzhao Shen, Bo Liu, Xu Guo[✉], Fei Pan, and Peng Jiang. 2018. HubMixer：面向参数高效推荐特征交互的渐进式潜在枢纽混合. In *Proceedings of 请务必填写版权确认邮件中的正确会议名称 (会议简称'XX')*. ACM, New York, NY, USA, 7 pages. <https://doi.org/XXXXXXX.XXXXXXX>

1 引言

工业推荐系统通过对大规模稀疏和稠密特征之间的交互进行建模来实现准确预测。在现代推荐排序模型中，输入特征通常包括用户画像、用户行为历史、物品特征、上下文特征以及实时反馈信号。这些特征通常会被转换为稠密嵌入并表示为一组 token，其中 token 交互建模直接影响最终的排序性能。

近期的一系列工作 [4, 12] 探索了用于推荐的类 Transformer 架构，例如基于自注意力的特征交互模型和 token 混合排序主干网络。标准自注意力提供内容自适应的 token-token 交互，但当 token 集合增大时，其二次复杂度可能令人难以承受。为提高效率，token 混合架构使用轻量级混合算子或矩阵友好的变换替代注意力。这些混合模型对工业部署颇具吸引力，因为它们能够降低计算开销、提高硬件利用率，并随着模型规模增大而表现出良好的可扩展性。

然而，推荐 token 与 NLP 中的同质语言 token 存在显著差异。自然语言 token 通常来自共享语义空间，并按有意义的序列排列。相比之下，推荐特征 token 具有高度异质性：用户年龄 token、历史点击序列 token、物品类别 token、上下文 token 和统计 token 承载不同的语义，具有不同的稀疏模式，并参与不同类型的交互。此外，有用的交互通常是稀疏且依赖于样本的。例如，用户行为 token 往往只有在与物品类别或求职意向 token 匹配时才具有信息量，而上下文 token 可能主要调节时间敏感或场景特定的特征。直接在原始异质 token 空间中混合所有 token，会使模型难以发掘有用的语义交互。

这一观察促使我们提出一个不同的问题：能否不直接混合异质 token，而是先将其组织到少量潜在语义枢纽中，在枢纽空间内执行高阶交互，再将交互后的语义注入回 token 表示？这种机制可以为异质特征交互提供更合适的归纳偏置。通过避免穷举式 token-token 混合，并将模型容量集中于一组紧凑的高价值交互子空间，它还可能提高参数效率。

本文提出 HubMixer，一种用于推荐的基于潜在枢纽的 token 混合架构。HubMixer 的核心组件是 HubMixer 模块，它引入少

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.

会议简称 XX, Woodstock, NY

© 2018 Copyright held by the owner/author(s). Publication rights licensed to ACM.

ACM ISBN 978-1-4503-XXXX-X/2018/06

<https://doi.org/XXXXXXX.XXXXXXX>

量可学习枢纽, 并通过三个阶段组织高效的信息交互。第一阶段为枢纽归纳, 使枢纽能够从异质 token 中选择性地聚合信息。第二阶段为枢纽交互, 在归纳得到的枢纽之间执行高阶交互。第三阶段为 token 条件读出, 让每个原始 token 查询完成交互的枢纽并获取针对该 token 的全局交互信号, 从而在逐步注入更高阶潜在交互语义的同时, 保留字段特定的 token 身份。

每个 HubMixer 模块并非显式建模所有特征 token 之间的稠密 $T \times T$ 交互, 而是通过 H 个潜在枢纽路由信息, 其中 $H \ll T$ 。这一视角解释了 HubMixer 为何能在较小的参数预算下取得强劲性能: 潜在枢纽为组织稀疏且异质的特征交互提供了显式归纳偏置。通过堆叠 HubMixer 模块, 同一种因子化交互会被反复应用于逐步细化的 token 表示, 使浅层能够捕获低阶跨字段模式, 而深层则进一步细化高阶交互语义。

我们的贡献总结如下:

- 我们从 token 混合的视角重新审视推荐中的特征交互。我们指出, 直接混合语义各异的特征 token 可能导致参数效率低下, 因为有用的交互往往是稀疏的、样本特定的, 并具有分组结构。
- 我们提出 HubMixer, 一种用于实现参数高效特征交互的渐进式潜在枢纽混合架构。每个 HubMixer 模块遵循归纳-交互-读出范式: 从特征 token 中归纳出紧凑的潜在枢纽, 在枢纽空间中执行交互, 并通过 token 条件读出细化每个 token。
- 我们在快手短视频招聘业务中进行了大量离线实验、消融研究和在线 A/B 测试。离线结果表明, HubMixer 以更少的参数超越了强大的 token 混合基线。在线 A/B 测试进一步显示, 简历投递转化率获得了统计显著的 5.48% 提升, 并且 HubMixer 已全面部署于生产环境。

2 相关工作

2.1 推荐中的特征交互

特征交互建模是推荐系统中的一个长期研究问题。因子分解机 [6] 等经典模型显式建模成对特征交互, 而 DCN [8]、DCNv2 [9] 和 AutoInt [7] 等神经排序模型则通过交叉网络或注意力机制改进交互建模。Wukong [10] 等近期大规模推荐模型进一步证明了可扩展模型容量对于工业排序的重要性。

然而, 随着工业推荐系统纳入日益多样的特征组和长行为序列, 交互建模变得更具挑战性。可能的 token-token 交互数量迅速增长, 而有用的交互往往稀疏且依赖于上下文。与现有特征交互模型不同, HubMixer 通过紧凑的潜在枢纽组织异构特征 token, 旨在提升跨特征交互的有效性和参数效率。

2.2 面向推荐的 Token 混合架构

Transformer 已在包括推荐在内的多个领域展现出强大的表示能力。Hyformer [2] 和 OneTrans [11] 等近期研究将注意力机制引入推荐模型, 并显著提升了模型性能。然而, 标准自注意力的二次计算成本限制了其可扩展性。为提升效率, RankMixer [12] 采用 MLP-Mixer 架构, 同时改善了工业排序中的模型性能和可扩展性。TokenMixer-Large [4] 进一步引入 token 混合和还原操作, 以提升大规模排序模型的扩展能力。

我们的工作与这一研究方向互为补充。HubMixer 并非主要在硬件利用率方面展开竞争, 而是专注于提升异构推荐特征的特征交互有效性和参数效率。它在保留紧凑潜在交互空间的同时, 通过可学习枢纽引入内容自适应路由。

2.3 潜在查询与交叉注意力架构

潜在架构引入一小组潜变量, 以概括大型输入集合或序列。代表性示例包括 Perceiver 风格的潜向量 [3] 和基于查询的设计。交叉注意力在两个表示集合之间提供一种非对称接口: 一个集合充当查询, 从另一个充当键和值的集合中选择性读取信息。这一性质使交叉注意力适合用于构建紧凑的抽象接口, 其中少量潜在查询可从更大的输入集合中提取与任务相关的信号。

一个尤其相关的实例是 Q-Former [5], 它通过一小组可学习查询, 在冻结的图像编码器与冻结的语言模型之间建立桥梁。这些查询通过交叉注意力关注图像特征, 随后由语言模型读取, 从而有效学习两个模态特定编码器之间的轻量级信息瓶颈。Q-Former 表明, 一组紧凑的可学习查询可作为有效的抽象接口。

受 Q-Former 框架启发, OneRec [1] 在其生命周期路径中使用可学习查询来关注长用户行为序列。它以归纳方式将用户的终身偏好概括为固定大小的表示, 在平衡表示容量和计算效率的同时, 从高基数输入中自适应地提取与任务相关的信号。

与主要使用可学习查询来压缩模态特征或长行为序列的 Q-Former 和 OneRec 不同, HubMixer 将潜在枢纽用作通用推荐特征 token 的中间交互中心。其目标不仅是表示压缩, 还包括结构化跨特征交互以及后续的 token 条件信息写入。

3 方法

3.1 整体架构

HubMixer 是一种基于潜在枢纽的 token 混合架构, 用于实现推荐系统中的参数高效特征交互。如图 1 所示, 该架构遵循四阶段流水线: token 化、枢纽归纳、枢纽交互和 token 条件读出。

3.2 Token 化

推荐排序模型通常涉及语义多样的特征组, 例如用户画像、行为序列、物品特征、上下文信号和统计特征。我们并未将所有特征嵌入展平为一个无结构向量, 而是根据其语义组组织特征, 并将其转换为一组特征 token:

$$\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T] \in \mathbb{R}^{T \times d}, \quad (1)$$

其中, T 是特征 token 的数量, d 是 token 维度。每个 token 对应一个特定的语义特征组或字段级表示。这种 token 化表示保留了特征语义, 并为后续的特征交互建模提供结构化输入空间。HubMixer 的目标是通过渐进式建模这些按语义组织的特征 token 之间的交互, 将 $\mathbf{X}$ 转换为细化后的 token 表示。

HubMixer 由堆叠的 HubMixer 模块组成。每个模块接收 token 表示 $\mathbf{X}^{(l)}$, 并输出细化后的表示 $\mathbf{X}^{(l+1)}$ 。HubMixer 模块首先从输入 token 中归纳出紧凑的潜在枢纽, 随后执行枢纽级交互, 最后通过 token 条件读出将交互后的信息写回 token。这种设计在提高参数效率的同时保持了模块的轻量性。

令 $\hat{\mathbf{H}}^{(l)} \in \mathbb{R}^{H \times d}$ 表示第 l 个模块中的 H 个基础可学习潜在枢纽, 其中 $H \ll T$ 。这些基础枢纽在不同样本间共享, 并进行端到端优化。它们充当语义路由器, 将异质特征 token 组织到紧凑的交互中心中。为了向原本静态的原型中注入样本级上下文, 我们使用由两层 MLP 生成的输入条件残差来增强可学习潜在枢纽:

$$\mathbf{p}^{(l)} = \frac{1}{T} \sum_{t=1}^T \mathbf{x}_t^{(l)}, \quad (2)$$

$$\mathbf{c}^{(l)} = \phi(\mathbf{W}_2^{(l)} \sigma(\mathbf{W}_1^{(l)} \mathbf{p}^{(l)} + \mathbf{b}_1^{(l)}) + \mathbf{b}_2^{(l)}) \quad (3)$$




图 1: HubMixer 的整体架构。首先将异构特征 token 归纳为紧凑的可学习潜在枢纽，随后在枢纽空间中进行交互，最后选择性查询交互后的枢纽，以获得 token 特定的读出。

其中， $\mathbf{C}^{(l)} \in \mathbb{R}^{H \times d}$ 是由全局 token 摘要生成的输入条件枢纽残差， T 表示 token 数量， $\sigma(\cdot)$ 表示 Swish 激活函数， $\phi(\cdot)$ 将向量重塑为 $\mathbb{R}^{H \times d}$ 。

因此，可学习潜在枢纽 $\mathbf{H}^{(l)}$ 的最终表达式如下：

$$\mathbf{H}^{(l)} = \tilde{\mathbf{H}}^{(l)} + \mathbf{C}^{(l)} \quad (4)$$

3.3 枢纽归纳

第一阶段将原始异质 token 汇总为潜在枢纽。受 Q-Former [5] 启发，我们使用少量可学习潜在枢纽作为查询，从输入特征 token 中选择性提取信息。给定归一化的 token 表示 $\tilde{\mathbf{X}}^{(l)} = \text{RMSNorm}(\mathbf{X}^{(l)})$ ，枢纽归纳执行从枢纽到 token 的交叉注意力，旨在将 token 表示归纳到可学习潜在枢纽 $\mathbf{H}^{(l)}$ 中：

$$\mathbf{Z}^{(l)} = \text{RMSNorm}(\mathbf{H}^{(l)} + \text{CrossAttn}(\mathbf{Q} = \mathbf{H}^{(l)}, \mathbf{K} = \tilde{\mathbf{X}}^{(l)}, \mathbf{V} = \tilde{\mathbf{X}}^{(l)})), \quad (5)$$

其中， $\mathbf{Z}^{(l)} \in \mathbb{R}^{H \times d}$ 是归纳得到的枢纽表示。

直观而言，每个枢纽都会学习关注特征 token 的混合。不同枢纽可以专注于不同的语义方面，例如用户兴趣、物品语义、上下文信号以及用户-物品交互。由于注意力权重依赖于输入内容，枢纽归纳提供了从异质特征 token 到潜在交互中心的样本特定路由。

3.4 枢纽交互

归纳完成后，HubMixer 在紧凑的枢纽空间中执行交互。我们对归纳得到的枢纽应用自注意力，以建模枢纽级依赖关系：

$$\tilde{\mathbf{Z}}^{(l)} = \text{RMSNorm}(\mathbf{Z}^{(l)} + \text{SelfAttn}(\mathbf{Q} = \mathbf{Z}^{(l)}, \mathbf{K} = \mathbf{Z}^{(l)}, \mathbf{V} = \mathbf{Z}^{(l)})). \quad (6)$$

由于枢纽数量很少，枢纽级交互具有较高的计算效率。

这一阶段至关重要，因为它在 token 信息被选择性聚合到少量潜在枢纽之后，对高阶特征交互进行建模。在推荐排序中，原始特征 token 来自不同的语义组，而对于给定请求，许多 token 对之间的相关性很弱。因此，直接建模所有 token-token 依赖关系会将模型容量消耗在大量用处较小的交互上。枢纽交互则在归纳得到的枢纽上运行，其中每个枢纽都已概括了一个依赖内容的相关特征信号子集。对这些枢纽之间的依赖关系进行建模，为捕获紧凑且高价值的跨特征交互提供了一种结构化归纳偏差。

3.5 Token 条件读出

完成枢纽空间交互后，交互后的枢纽编码了紧凑的全局跨特征语义。使用这些枢纽的一种直接方式是将其池化为单个全局向量，并输入预测模块。然而，这种设计可能会模糊字段特定的 token 身份；在推荐排序中，不同特征 token 针对不同目标发挥不同作用，因此这些身份至关重要。为此，HubMixer 通过 token 条件读出将交互后的枢纽语义投影回 token 空间。

具体而言，每个 token 使用其归一化表示作为查询，从交互后的枢纽中选择性读取信息：

$$\Delta \mathbf{X}^{(l)} = \text{CrossAttn}(\mathbf{Q} = \tilde{\mathbf{X}}^{(l)}, \mathbf{K} = \tilde{\mathbf{Z}}^{(l)}, \mathbf{V} = \tilde{\mathbf{Z}}^{(l)}), \quad (7)$$

其中, $\Delta \mathbf{X}^{(l)} \in \mathbb{R}^{T \times d}$ 是针对 token 的读出信号。与全局池化或广播不同, 该操作允许每个 token 根据自身表示获取潜在枢纽语义的定制化混合。

随后, 读出信号通过 LayerScale 风格的残差连接注入原始 token 流:

$$\mathbf{X}^{(l+1)} = \mathbf{X}^{(l)} + \gamma^{(l)} \odot \Delta \mathbf{X}^{(l)}, \quad (8)$$

其中, $\gamma^{(l)} \in \mathbb{R}^d$ 是可学习的 LayerScale 参数, $\odot$ 表示沿 token 维度广播的逐元素乘法。这种残差形式保留了原始的字段特定 token 表示, 同时使模型能够自适应地注入具备交互感知能力的枢纽信息。在实践中, LayerScale 提供了一种稳定机制来控制读出更新的幅度, 这在堆叠多个 HubMixer 模块时尤其有用。

因此, 第 l 个模块的输出不是池化后的枢纽表示, 而是一组细化的 token $\mathbf{X}^{(l+1)}$ 。这种设计保留了 token 级特征身份, 供下游多任务预测使用, 同时利用来自潜在枢纽空间的全局跨特征交互信号逐步丰富每个 token。

3.6 多任务预测与优化

我们使用多任务学习 (MTL) 模型对 HubMixer 进行端到端训练。令 $\mathcal{K}$ 表示排序任务集合。对于每个排序任务 k , 我们将任务标签记为 y_k , 将预测记为 $\hat{y}_k$ 。

给定最终 HubMixer 模块输出的 token, 增强后的 token 表示被送入 MTL 模块, 以同时优化多个排序目标。首先将这些 token 聚合为样本级表示:

$$\mathbf{r} = \text{Concat}(\mathbf{X}^{(L)}). \quad (9)$$

其中, $\text{Concat}(\cdot)$ 通过拼接所有 token 表示来实现。随后, 每个任务头产生各自的预测:

$$\hat{y}_k = \text{Sigmoid}_k(\text{MTL}_k(\mathbf{r})), \quad (10)$$

其中, k 是排序任务的索引。

二分类交叉熵损失函数被计算为排序任务 k 的损失:

$$\ell_k(y_k, \hat{y}_k) = -y_k \log \hat{y}_k - (1 - y_k) \log(1 - \hat{y}_k). \quad (11)$$

其中, $\ell_k(\cdot)$ 是任务特定的损失函数。

总体目标是所有任务损失的加权和:

$$\mathcal{L} = \sum_{k=1}^{|\mathcal{K}|} \lambda_k \cdot \ell_k(y_k, \hat{y}_k), \quad (12)$$

其中, λ_k 控制各任务的相对重要性。HubMixer 负责跨特征交互, 而 MTL 模型负责提取任务特定信号。

4 实验

4.1 实验设置

实验概述. 我们在一个采集自快手短视频招聘业务的大规模工业数据集上评估 HubMixer。该业务是依托快手内容分发场景构建的营收型蓝领招聘服务, 向潜在感兴趣的用户分发职位相关短视频和招聘线索, 覆盖约 4000 万日活跃用户。排序模型针对线索生成进行优化, 旨在同时提升用户投递简历的数量以及下游招聘转化。

数据收集与目标优化. 我们从快手的大规模日志中收集了潜在感兴趣用户一个月的行为数据, 并构建了一个包含超过 10 亿个样本的数据集。该数据集包含用户画像、用户行为序列特征、职位特征、短视频特征、上下文特征和统计特征。遵循生产环境设置, 我们将任务形式化为一个具有四个预测目标的多

任务排序问题: `plc_click`、`effective_view`、`interact` 和 `resume_submit`。这些目标对应招聘流程的不同阶段, 从初始点击和有效消费, 到交互, 再到最终的简历投递。

基线. 我们将 HubMixer 与具有代表性的工业特征交互及 token 混合排序模型进行比较, 包括 DCN、DCNv2、AutoInt、Wukong、RankMixer 和 TokenMixer。这些基线涵盖显式特征交叉模型、基于注意力的特征交互模型、面向交互的工业排序模块以及近期的 token 混合排序骨干网络。为确保公平比较, 所有模型均在相同的特征集合上训练, 并在相同的多任务设置下进行优化。

指标. 对于离线评估, 我们使用 AUC 评估模型性能; AUC 值越高, 表明模型的排序能力越强。由于四个任务对应不同阶段, 我们分别报告各任务的 AUC, 而不将所有目标合并为单一分数。对于在线实验, 我们的主要在线指标是简历投递转化率。然而, 由于用户投递简历的意愿会受到点击、有效消费和交互等因素影响, 我们将四个任务的预测结果组合成一个综合排序分数, 从整体视角建模用户的简历投递意图。

实现细节. 除非另有说明, 所有模型均采用相同的特征预处理流水线、嵌入维度、优化器、批大小、训练计划和多任务损失权重。对于所有 Mixer 模型, token 数量设为 32, Mixer 模块层数设为 2。具体而言, 我们的 HubMixer 默认枢纽数量设为 $H = 16$ 。

4.2 性能比较

表 1 将 HubMixer 与具有代表性的工业特征交互及 token 混合模型进行了比较, 包括 DCN、DCNv2、AutoInt、Wukong、RankMixer 和 TokenMixer。这些模型既涵盖了广泛使用的特征交叉架构, 也涵盖了近期用于推荐排序的 token 混合骨干。我们得到以下观察。

首先, DCN、DCNv2、AutoInt 和 Wukong 等传统特征交叉模型, 通常不及 RankMixer、TokenMixer 等近期的 token 混合排序模型。这表明, 在现代工业排序场景中, 仅仅提升特征交叉的阶数或改变其形式并不足够, 因为特征 token 在语义上高度多样, 而有用的交互具有稀疏性和样本依赖性。

其次, HubMixer 在四个排序目标上均取得最佳 AUC。从早期互动目标到更深层的转化导向目标, 改进均保持一致, 这表明 HubMixer 学到的交互模式对整个招聘流程都有帮助, 而非只对某个单一目标有效。

第三, HubMixer 使用的参数少于 RankMixer 和 TokenMixer, 同时取得了更高的 AUC。这一结果凸显了所提出的归纳-交互-读出范式的参数效率, 即通过紧凑的潜在枢纽路由特征交互, 相较于在扁平 token 空间中直接混合所有特征 token, 能够更有效地利用模型容量。

4.3 消融研究

模块消融. 我们首先评估 HubMixer 关键组件的贡献。我们将完整模型与两个变体进行比较: (1) 移除枢纽交互, 即不进行枢纽空间自注意力, 直接使用归纳得到的枢纽进行读出; (2) 以池化枢纽注入替代 token 条件读出, 即将完成交互的枢纽池化为一个全局向量, 并将其添加到所有 token。第二个变体用于检验是否有必要进行针对 token 的选择性读出, 抑或共享的全局摘要已足够。

表 2 报告了模块消融结果。完整的 HubMixer 在四项任务上始终取得最佳 AUC, 验证了完整归纳-交互-读出设计的有效性。移除枢纽交互会导致每个目标的性能明显下降, 平均 AUC

表 1: 在快手短视频招聘数据集上的性能比较。我们报告四个多任务排序目标上的 AUC 和参数量。

模型	plc_click	effective_view	interact	resume_submit	平均 AUC	# 参数量
DCN	0.8196	0.8453	0.8358	0.7818	0.8206	155.3M
DCNv2	0.8194	0.8468	0.8361	0.7825	0.8212	157.5M
AutoInt	0.8194	0.8459	0.8363	0.7823	0.8210	162.6M
Wukong	0.8183	0.8461	0.8365	0.7822	0.8208	154.6M
RankMixer	0.8221	0.8495	0.8389	0.7845	0.8238	155.1M
TokenMixer	0.8227	0.8491	0.8394	0.7852	0.8241	156.9M
HubMixer (本文)	0.8253	0.8507	0.8401	0.7864	0.8256	142.4M

表 2: Kuaishou 短视频招聘数据集上的模块消融。

变体	plc_click	effective_view	interact	resume_submit	平均 AUC
完整 HubMixer	0.8253	0.8507	0.8401	0.7864	0.8256
无枢纽交互	0.8221	0.8480	0.8383	0.7844	0.8232
池化到 Token 的读出	0.8242	0.8499	0.8390	0.7857	0.8247

从 0.8256 降至 0.8232。这表明，仅归纳潜在枢纽是不够的；枢纽间的高阶交互对于将归纳得到的摘要转化为有用的跨特征交互信号至关重要。

将 token 条件读出替换为池化枢纽注入同样会损害性能，尽管下降幅度小于移除枢纽交互。这一结果表明，全局枢纽信息确实有用，但相比于让每个 token 从交互后的枢纽中选择性检索相关信息，将池化后的枢纽表示统一添加到所有 token 上效果较差。换言之，token 条件读出在注入交互上下文的同时保留了 token 特定语义，这对于多任务招聘排序非常重要，因为不同特征 token 对点击、有效观看、互动和简历投递等目标的贡献可能各不相同。

枢纽数量的影响。我们进一步研究潜在枢纽数量的影响。枢纽数量控制潜在交互空间的容量：枢纽过少可能造成过度的信息瓶颈，而枢纽过多则会增加参数量和计算量，并可能带来递减的收益。我们将 $H = 16$ 设为默认配置，并与 $H = 4$ 、 $H = 8$ 和 $H = 32$ 进行比较。

表 3 表明，将枢纽数量从 4 增加到 16，能够持续提升四项任务的 AUC，说明更大的潜在枢纽空间具有更强的跨特征交互组织能力。然而，将枢纽数量从 16 进一步增加到 32 仅带来微小收益：平均 AUC 从 0.8256 提升到 0.8258，而参数量从 142.4M 增至 150.8M。这表明超过 16 个枢纽后，信息增益开始趋于饱和。因此，我们选择 $H = 16$ 作为默认设置，它为招聘排序任务提供了更好的准确率-参数量权衡。

4.4 在线 A/B 测试

为进一步验证 HubMixer 在真实生产环境中的有效性，我们将 HubMixer 部署到快手内容型招聘短视频分发系统中。在线 A/B 测试持续 7 天，覆盖了 7.2% 的生产流量。主要在线指标是简历投递转化率，它直接反映招聘业务下游的线索获取目标。

相较于基础模型，HubMixer 将整体简历投递转化率提升了 5.48%，且该提升具有统计显著性。这一在线收益表明，所提出的归纳-交互-读出架构不仅改善了离线 AUC，也能在大规模招聘短视频分发中转化为可衡量的业务影响。值得注意的是，在 A/B 测试之后，HubMixer 已在快手短视频招聘业务中全面部署。




图 2: HubMixer 与 TokenMixer 在各 Mixer 层中逐 token 的输入-输出余弦距离。数值越大，表示从模块输入到模块输出的方向性更新越强。

4.5 Token 表示增强分析

为进一步理解 HubMixer 为何优于强大的 token 混合基线，我们针对性能比较中最强的竞争基线 TokenMixer 进行了详细的表示分析。由于 TokenMixer 同样在 token 化的特征表示上运行，这一比较为考察不同 token 交互机制如何修改并增强特征 token 提供了受控视角。

我们从两个互补视角分析 token 表示：逐 token 的表示更新和线性探测性能。前者衡量每个混合器块对各 token 表示方向的改变程度，后者则考察增强后的表示是否包含更易访问的任务相关信息。

对于第 l 个块，令 $\mathbf{x}_{n,i}^{(l)}$ 和 $\mathbf{x}_{n,i}^{(l+1)}$ 分别表示实例 n 中第 i 个 token 的输入和输出表示。我们使用余弦距离衡量逐 token 的方向更新：

$$D_i^{(l)} = \mathbb{E}_n \left[1 - \cos \left(\mathbf{x}_{n,i}^{(l)}, \mathbf{x}_{n,i}^{(l+1)} \right) \right]. \quad (13)$$

$D_i^{(l)}$ 的值越大，意味着经过块级交互后，输出 token 与其输入表示越不相似，说明新注入的交互信息越多。

如图 2 所示，HubMixer 的输入-输出差异始终大于 TokenMixer。在第一个 Mixer 层中，HubMixer 的平均余弦距离为 0.200，接近 TokenMixer (0.105) 的两倍。在第二层中，HubMixer 仍保持更大的平均余弦距离 (0.051 对 0.037)。这些结果表明，经过模块

表 3: 潜在枢纽数量的影响。默认设置为 $H = 16$ 。

H	plc_click	effective_view	interact	resume_submit	平均 AUC	参数量
4	0.8231	0.8486	0.8382	0.7852	0.8238	136.1M
8	0.8244	0.8498	0.8394	0.7857	0.8248	138.3M
16 (默认)	0.8253	0.8507	0.8401	0.7864	0.8256	142.4M
32	0.8255	0.8511	0.8402	0.7865	0.8258	150.8M



图 3: HubMixer 与 TokenMixer 的线性探测比较。冻结骨干网络, 并在 token 级表示或拼接后的实例级表示上训练轻量级线性分类器。

级交互后, HubMixer 对 token 表示方向的改变比 TokenMixer 更为显著。

这一观察结果与 HubMixer 的设计动机一致。TokenMixer 直接在原始 token 空间中混合 token, 这可能导致相对温和的 token 更新。相比之下, HubMixer 首先从输入 token 中归纳出紧凑的潜在枢纽, 在枢纽空间中执行高阶交互, 随后通过 token 条件读出将交互后的信息写回每个 token。因此, 更大的输入-输出差异表明, HubMixer 能够向相应的 token 表示中注入更丰富的交互信息。同时, 热力图还显示, 这些更新并非均匀分布于所有 token, 这意味着注入的信息依赖于 token, 而不是简单的全局扰动。

然而, 仅有更大的表示更新并不一定意味着更高的表示质量, 因为它也可能源于不必要的扰动。因此, 我们进一步开展线性探测, 以评估增强后的 token 表示能否为下游排序任务提供 stronger 的预测能力。具体而言, 在训练完骨干模型后, 我们冻结骨干网络的所有参数, 并在每个 token 表示之上训练轻量级线性分类器。我们还在拼接表示 $\text{Concat}(\mathbf{X}^{(L)})$ 上评估实例级探针, 以衡量整体表示质量。

如图 3 所示, HubMixer 在大多数特征 token 上取得了高于 TokenMixer 的探测 AUC, 并且在聚合表示上也获得了更好的探测性能。由于探测分类器是线性的, 且骨干网络被冻结, 这一改进表明 HubMixer 使任务相关信号更易于访问。该结果与余弦距离分析相互补充: 与 TokenMixer 相比, HubMixer 不仅

对 token 表示进行了更大幅度的修改, 还生成了对多任务招聘排序更具预测性的表示。

综合来看, 这些结果表明, HubMixer 相对于 TokenMixer 的性能增益不能简单归因于更强的表示扰动。相反, 归纳-交互-读出范式通过注入任务相关的跨特征交互信息来增强 token 表示, 这有助于解释 HubMixer 在主要性能比较中取得更优 AUC 的原因。

5 讨论

5.1 作为归纳偏置的潜在枢纽

所提出的潜在枢纽可被视为一种架构归纳偏置, 用于在显式交互之前组织推荐特征。在工业排序系统中, 特征 token 往往来自不同的语义来源, 例如用户画像、行为序列、物品属性、上下文信号和统计特征。将这些 token 视为扁平序列, 会使模型只能完全依赖数据来发现有用的交互结构。相较之下, HubMixer 引入了一小组可学习的交互中心, 促使模型先将相关信号概括为紧凑的潜在语义, 再在这些语义之间执行交互。该设计并不假设固定的特征层次结构; 相反, 它让枢纽在端到端训练过程中学习柔性的、依赖内容的组织模式。

5.2 作为选择性信息写入的读出

token 条件读出阶段更适合被理解为选择性信息写入, 而非全局特征广播。经过交互的枢纽存储紧凑的跨特征语义, 而原始 token 则保留下游预测头所需的字段特定信息。token 条件读出连接了这两个空间: 每个 token 根据自身的查询决定吸收哪些枢纽信息, 从而生成用于最终预测的增强 token 表示。该设计尤其适用于多任务排序, 因为不同目标可能依赖同一特征集合的不同方面。例如, 以互动为导向的目标和以转化为导向的目标, 可能分别受益于用户意图、物品语义和上下文信号的不同组合。选择性读出将这些跨特征交互信号重新注入 token 表示, 使下游多任务预测头能够从增强后的 token 集合中提取有用证据, 而无需将所有 token 压缩为单一的全局摘要。

5.3 实际部署考量

从部署角度看, HubMixer 为工业排序系统提供了若干实用的调节选项。枢纽数量控制潜在交互空间的规模, 可根据可用的参数与延迟预算进行调整。HubMixer 块的数量控制渐进式交互细化的深度。此外, 枢纽归纳和 token 条件读出均被构造为特征 token 与一小组枢纽之间的交叉注意力, 其开销随 TH 而非 T^2 缩放。该结构便于采用批量交叉注意力、算子融合和小矩阵计算优化等工程优化手段。这些考量表明, 归纳-交互-读出设计不仅是一项建模原则, 也是一种能够适配不同生产约束的灵活框架。

5.4 未来方向

HubMixer 为未来探索开启了多个方向。首先, 当前设计通过轻量级输入条件残差, 在所有实例之间共享一组可学习的枢纽。一种更强的扩展方式是根据请求级上下文、用户意图或场景特定信号, 动态生成完整的枢纽集合。这类自适应枢纽可进一步提高潜在路由的灵活性, 尤其适用于流量分布和用户意图高度多样化的生产系统。

其次, 可以进一步促进枢纽的专业化。尽管可学习枢纽能够在端到端训练中自然形成不同的语义偏好, 但显式的多样性正则化或正交约束可能有助于不同枢纽覆盖互补的特征组与交互模式。在堆叠更多 HubMixer 块时, 这一方向尤其重要, 因为保持多样化的枢纽语义可能改善渐进式交互细化。

第三, HubMixer 可以与更先进的多任务学习设计结合。在本工作中, HubMixer 作为任务特定预测头之前的共享特征交互骨干。未来研究可以探索任务感知读出、任务条件枢纽或目标特定路由, 使不同排序目标能够在共享同一潜在枢纽空间的同时, 选择性地访问不同的交互语义。

第四, 枢纽交互算子本身可以变得更加灵活。当前实现采用潜在枢纽上的自注意力来建模高阶枢纽级依赖。由于枢纽数量远少于特征 token 数量, 该开销已经得到控制; 不过, 对于 FLOPs 或延迟预算更严格的场景, 可以用更轻量的算子替换枢纽交互模块, 例如基于 MLP 的枢纽混合或稀疏专家式枢纽混合。这些替代方案可能在保留整体归纳-交互-读出框架的同时, 进一步降低计算复杂度。

最后, 系统级优化对于大规模部署十分重要。由于枢纽归纳和 token 条件读出均被构造为特征 token 与一小组潜在枢纽之间的交叉注意力, 当 $H \ll T$ 时, 其计算量随 TH 而非 T^2 缩放。该结构为适合批处理的交叉注意力实现、算子融合和小矩阵计算优化提供了实际机会。这些工程方向能够在保留选择性归纳-交互-读出机制的同时, 进一步提升服务效率。

6 结论

在本工作中, 我们提出了 HubMixer, 这是一种面向推荐系统中参数高效特征交互的渐进式潜在枢纽混合架构。HubMixer 通过轻量级的输入条件残差引入一小组可学习的潜在枢纽, 并按照“归纳-交互-读出”范式组织跨特征交互。枢纽首先选择性地聚合语义多样的特征 token, 随后在紧凑的枢纽空间中执行高阶交互, 最后每个 token 通过 token 条件读出检索定制化的交互信号。该设计形成了一种内容自适应的交互机制, 将模型容量集中于结构化且高价值的跨特征模式, 而非分散到所有 token 对上。

我们进一步表明, 读出结果可直接作为模块输出, 并被送入多任务预测头。这一设计将跨特征交互与多任务信号提取清晰地分离开来: HubMixer 专注于生成增强的 token 表示, 而下游预测头则为最终目标提取任务特定信号。当沿深度方向堆叠时, token 表示的渐进式细化使模型能够捕获越来越抽象的跨特征交互。表示分析表明, 与 TokenMixer 相比, HubMixer 向 token 表示中注入了更强且与任务更相关的交互信息。输入-输出表示分析进一步证实, HubMixer 在注入交互上下文的同时, 能够更好地保留字段特定的 token 身份。

大量离线实验表明, HubMixer 以更少的参数实现了优于强 token 混合基线的排序性能。消融研究验证了枢纽交互和 token 条件读出各自的贡献。在线 A/B 测试进一步证实了 HubMixer 的生产价值, 使简历投递转化率取得了统计显著的 5.48% 提升; 此后, HubMixer 已全面部署于快手短视频招聘业务。这些结果

表明, 潜在枢纽混合为工业推荐排序中的参数高效特征交互提供了一种有效且可扩展的范式。

参考文献

- [1] Jiaxin Deng, Shiyao Wang, Kuo Cai, Lejian Ren, Qigen Hu, Weifeng Ding, Qiang Luo, and Guorui Zhou. 2025. Onerec: Unifying retrieve and rank with generative recommender and iterative preference alignment. *arXiv preprint arXiv:2502.18965* (2025).
- [2] Yunwen Huang, Shiyong Hong, Xijun Xiao, Jinqui Jin, Xuanyuan Luo, Zhe Wang, Zheng Chai, Shikang Wu, Yuchao Zheng, and Jingian Lin. 2026. HyFormer: Revisiting the Roles of Sequence Modeling and Feature Interaction in CTR Prediction. (2026), 590–599.
- [3] Andrew Jaegle, Felix Gimeno, Andy Brock, Oriol Vinyals, Andrew Zisserman, and Joao Carreira. 2021. Perceiver: General perception with iterative attention. In *International conference on machine learning*. PMLR, 4651–4664.
- [4] Yuchen Jiang, Jie Zhu, Xintian Han, Hui Lu, Kunmin Bai, Mingyu Yang, Shikang Wu, Ruihao Zhang, Wenlin Zhao, Shipeng Bai, et al. 2026. TokenMixer-Large: Scaling Up Large Ranking Models in Industrial Recommenders. *arXiv preprint arXiv:2602.06563* (2026).
- [5] Junnan Li, Dongxu Li, Silvio Savarese, and Steven Hoi. 2023. Blip-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. In *International conference on machine learning*. PMLR, 19730–19742.
- [6] Steffen Rendle. 2010. Factorization machines. In *2010 IEEE International conference on data mining*. IEEE, 995–1000.
- [7] Weiping Song, Chence Shi, Zhiping Xiao, Zhijian Duan, Yewen Xu, Ming Zhang, and Jian Tang. 2019. AutoInt: Automatic feature interaction learning via self-attentive neural networks. In *Proceedings of the 28th ACM international conference on information and knowledge management*. 1161–1170.
- [8] Ruoxi Wang, Bin Fu, Gang Fu, and Mingliang Wang. 2017. Deep & cross network for ad click predictions. In *Proceedings of the ADKDD'17*. 1–7.
- [9] Ruoxi Wang, Rakesh Shivanna, Derek Cheng, Sagar Jain, Dong Lin, Lichan Hong, and Ed Chi. 2021. Dcn v2: Improved deep & cross network and practical lessons for web-scale learning to rank systems. In *Proceedings of the web conference 2021*. 1785–1797.
- [10] Buyun Zhang, Liang Luo, Yuxin Chen, Jade Nie, Xi Liu, Shen Li, Yanli Zhao, Yuchen Hao, Yantao Yao, Ellie Dingqiao Wen, et al. 2024. Wukong: towards a scaling law for large-scale recommendation. In *Proceedings of the 41st International Conference on Machine Learning*. 59421–59434.
- [11] Zhaoqi Zhang, Haolei Pei, Jun Guo, Tianyu Wang, Yufei Feng, Hui Sun, Shaowei Liu, and Aixin Sun. 2026. Onetrans: Unified feature interaction and sequence modeling with one transformer in industrial recommender. In *Proceedings of the ACM Web Conference 2026*. 8162–8170.
- [12] Jie Zhu, Zhifang Fan, Xiaoxie Zhu, Yuchen Jiang, Hangyu Wang, Xintian Han, Haoran Ding, Xinmin Wang, Wenlin Zhao, Zhen Gong, et al. 2025. Rankmixer: Scaling up ranking models in industrial recommenders. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management*. 6309–6316.