

HyFormer：重新审视 CTR 预测中序列建模与特征交互的作用

Yunwen Huang*
huangyunwen.eleanor@bytedance.com
ByteDance AML
Beijing, China

Jinqiu Jin*
jinjinqiu.02@bytedance.com
ByteDance Search
Beijing, China

Zheng Chai†
chaizheng.cz@bytedance.com
ByteDance AML
Hangzhou, China

Shiyong Hong*
hongshiyong.66@bytedance.com
ByteDance Search
Beijing, China

Xuanyuan Luo
xuanyuanluo@bytedance.com
ByteDance AML
Hangzhou, China

Shikang Wu†
wushikang@bytedance.com
ByteDance Search
Beijing, China

Jingjian Lin
linjingjian000@gmail.com
ByteDance Search
Beijing, China

Xijun Xiao*
xiaoxijun@bytedance.com
ByteDance AML
Beijing, China

Zhe Wang
zhewang.tim@gmail.com
ByteDance Search
Beijing, China

Yuchao Zheng
zhengyuchao.yc@bytedance.com
ByteDance AML
Hangzhou, China

摘要

工业级大规模推荐模型 (LRM) 需要在严格的效率约束下联合建模长程用户行为序列与异构非序列特征。现有多数架构采用解耦流水线：首先使用 LONGER 等基于查询 token 的序列压缩器压缩长序列，再通过 RankMixer 等 token 混合模块与稠密特征融合，因此限制了表征容量与交互灵活性。本文提出 **HyFormer**，这是一种统一的混合 Transformer 架构，将长序列建模与特征交互紧密集成到同一骨干网络中。从序列建模视角出发，我们重新审视并设计 LRM 中的查询 token，并将 LRM 建模任务刻画为由两个核心组件构成的交替优化过程：查询解码 (*Query Decoding*) 将非序列特征扩展为全局 token (*Global Tokens*)，并在长行为序列的逐层键值表征上执行长序列解码；查询增强 (*Query Boosting*) 则通过高效 token 混合增强跨查询、跨序列的异构交互。两种互补机制迭代执行，在各层间逐步优化语义表征。亿级工业数据集上的大量实验表明，在相近的参数量与 FLOPs 预算下，HyFormer 始终优于强大的 LONGER 和 RankMixer 基线，并且随着参数量与 FLOPs 增长展现出更优的扩展特性。高流量生产系统中的大规模在线 A/B 测试进一步验证了其有效性，相较已部署的先进模型取得了显著收益。这些结果表明，HyFormer 作为工业 LRM 的统一建模框架兼具实用性与可扩展性。

CCS 概念

• 信息系统 → 推荐系统.

关键词

特征交互，大规模推荐模型，长序列建模，扩展定律

* 这些作者贡献相同。.

† 通讯作者。.

1 引言

现代工业级大规模推荐模型 (LRM) 运行于日益复杂的环境中，准确预测依赖对长程用户行为历史与丰富异构特征的联合建模，后者包括用户画像、上下文信号和交叉特征。随着用户参与时间跨度不断延长、特征空间持续扩展，如何有效整合长序列信号与高维非序列信息，已成为大规模推荐与搜索系统的核心挑战。为应对这一挑战，近期工业架构大多趋向一种将长序列建模 [1, 18, 29] 与特征交互 [6, 10, 19, 20] 相结合的分离式扩展范式。在该范式中，专用序列 Transformer 对长用户行为序列编码，以捕获时序依赖与用户兴趣；随后，压缩后的序列 token 通过 token 混合或交互模块与其他异构特征融合，从而实现跨特征推理。这种“先长序列建模，再异构特征交互”的流水线已被证明有效，并成为现代工业 LRM 扩展的主流设计。尽管其实证表现强劲，该范式从根本上限定为压缩、后期融合且单向的交互模式。随着序列长度与模型容量持续增长，这种两阶段设计暴露出限制模型表达力和可扩展性的根本缺陷。

- 现有架构中的序列 Transformer 在压缩序列时往往依赖过度简化的查询表征 [5, 26, 27]。实践中，用于聚合长行为序列的查询 token 通常仅源自候选相关特征或全局特征的有限子集，因而限制了长期用户兴趣建模时可利用的上下文信息量。然而，在 KV-Cache 与 M-Falcon 机制下直接增加查询 token 数量，会显著降低服务效率 [2, 22]。
- 序列压缩 token 与异构非序列 token 之间的交互通常只发生在模型后期。在现有范式下，跨特征推理被推迟到序列压缩之后，导致不同 token 类型之间的交互浅层且隐式。这种延迟融合限制了模型捕获多个行为序列与异构特征组之间细粒度依赖的能力，也使浅层表征无法受益于跨域上下文信息。
- 由于交互模块只作用于压缩后的序列表征，增加模型容量或序列长度主要改善孤立组件，而非增强联合表征。因此，扩展深度或参数量的效率较低：随着额外计算预算增加，性能提升速率逐渐放缓，因为计算无法有效转化为更丰富的联合表征。

上述局限促使我们从根本上重新思考长序列建模与异构特征交互的整合方式。与其将序列编码和 token 混合视为两个松散耦合的阶段, 不如采用统一建模框架, 在序列信号与非序列信号之间实现更深、更早且双向的交互。

本文提出 **HyFormer**, 一种在单一骨干网络中统一序列建模与特征交互的混合 *Transformer* 架构。HyFormer 引入一组**全局 token**, 作为长行为序列与异构特征之间共享的语义接口。通过堆叠式设计, HyFormer 在两种轻量但富有表达力的机制之间交替。查询解码模块使用全局查询 token 关注长行为序列的逐层键值表征, 使全局上下文能够直接塑造序列表征; 查询增强模块通过高效 token 混合进一步强化跨查询和跨序列交互, 在各层间逐步丰富语义表征。该设计使信息能够在序列建模与特征交互组件之间双向流动, 克服传统解耦流水线的局限。亿级工业数据集上的大量实验表明, 在相近参数量和 FLOPs 预算下, HyFormer 始终优于强大的序列模型与 token 混合基线。此外, HyFormer 在模型 FLOPs 与参数量方面展现出更优的扩展特性, 并在高流量生产系统的大规模在线 A/B 测试中取得显著收益。

综上, 本文贡献如下:

- 我们指出大规模工业推荐系统中主流解耦式序列建模与特征交互范式的根本局限, 并分析其单向、后期融合设计如何约束建模容量与可扩展性。
- 我们提出 HyFormer, 一种统一的混合 *Transformer* 架构, 通过查询解码和查询增强实现长程行为序列与异构特征之间逐层双向交互, 在真实工业场景中达到先进的性能与可扩展性。
- 我们在亿级工业数据集上实证验证了所提模型的有效性及其优越的扩展性能。目前, HyFormer 已在 ByteDance 全面部署, 每日服务数十亿用户。

2 相关工作

2.1 传统推荐范式

现代工业 LRM 通常由行为序列建模与特征交互网络两大组件构成。在此范式下, 专用序列模型首先编码用户行为历史, 其输出再与异构非序列特征一同输入下游交互模块。近期工业系统沿这一方向显著提升了序列建模的可扩展性。SIM [12]、ETA [4]、TWIN [3, 13]、TransAct [17] 和 LONGER [2] 等方法借助高效注意力机制、分层聚合、KV 缓存及服务友好设计, 将序列编码扩展到数百乃至数千个事件。这些工作在大规模流量下的长程用户行为建模中展现出清晰的幂律扩展趋势, 但基本仍保留序列编码与特征交互解耦的两阶段架构。

在特征交互方面, DeepFM [7]、xDeepFM [11] 和 DCNv2 [16] 等早期模型能够大规模建模低阶或有限阶特征交叉, 但随着交互深度增加, 收益逐渐递减。Wukong [24] 和 RankMixer [28] 等近期扩展研究指出, 交叉模块扩展已成为工业性能提升的关键驱动力。这些模型代表了当前大规模特征交互设计水平, 但在多数生产流水线中, 交互堆栈与序列编码器仍为松耦合, 导致后期融合, 无法对异构信号进行统一优化。

2.2 统一推荐架构

为缓解序列建模与特征交互之间的割裂, 近期研究开始探索在单一骨干中处理异构信号的统一架构。HSTU [23] 等分层生成架构通过上下文和候选信号为条件执行序列转导, 代表了一种统一推荐范式。InterFormer [21] 引入可学习交互 token, 实现双向信号交换, 从而弥合序列编码器与交互网络之间的鸿沟。MTGR [8] 进一步推进统一化, 将用户、行为、实时及候选特征

重组为异构 token, 并使用共享的 *Transformer* 式骨干编码, 使序列信息与交叉特征得以协同建模。沿袭 MTGR, OneTrans [25] 使用单一 *Transformer* 联合捕获序列依赖与高阶特征交互, 同时以金字塔压缩方式简化 *Transformer* 结构, 可视作 MTGR 的简化版本。

由于 MTGR [8] 和 OneTrans [25] 只是将查询 token 数量增加到与全部非序列 token 相同, 实践中很容易观察到服务效率显著下降 (见第 4 节)。此外, 单一统一 *Transformer* 结构通常不足以在工业级 LRM 中完成特征交互建模 [28]。总体而言, 统一架构朝着消除序列模型与特征交互堆栈之间长期割裂迈出了一步, 但如何以最小架构开销实现完全统一仍是开放问题。

3 方法

3.1 问题定义

令 $\mathcal{U}$ 和 $\mathcal{I}$ 分别表示用户空间与物品空间。对于用户 $u \in \mathcal{U}$, 将其原始行为历史记为 $S = [t_1^{(u)}, \dots, t_k^{(u)}]$, 其中每个 $t_t^{(u)} \in \mathcal{I}$; 并令 u 表示随附的非序列描述信息, 如画像属性、上下文信号和交叉特征。给定候选物品 $v \in \mathcal{I}$, 目标是估计用户 u 与物品 v 发生交互的概率:

$$P(y = 1 \mid S, u, v) \in [0, 1], \quad (1)$$

其中 $y \in \{0, 1\}$ 表示交互是否发生。

模型参数通过最小化标准二元交叉熵目标, 从历史数据 $\mathcal{D} = \{(S, u, v, y)\}$ 中学习:

$$\mathcal{L} = -\frac{1}{|\mathcal{D}|} \sum_{(S, u, v, y) \in \mathcal{D}} [y \log \hat{y} + (1 - y) \log(1 - \hat{y})], \quad (2)$$

其中 $\hat{y} = f_\theta(S, u, v)$ 表示 LRM 输出的预测交互概率。

3.2 整体框架

传统 LRM 架构通常采用流水线设计, 首先执行 LONGER [2] 等序列建模, 再将包含压缩序列信息的查询 token 用于 RankMixer [28] 等后续特征交互。如前所述, 这种分离流水线通常导致序列建模与异构特征交互均不充分。为克服这一局限, 本文提出统一混合框架, 通过堆叠 HyFormer 层联合建模非序列 (NS) token 与长行为序列。

HyFormer 的整体架构如图 1 所示。每个 HyFormer 层集成两种互补机制: (1) 查询解码: 通过基于 MLP 的查询生成, 将非序列与序列特征扩展为多个语义**全局 token** (即序列查询), 并在长序列 K/V 对上执行交叉注意力, 使全局信息能够直接塑造序列 token 表征; (2) 查询增强: 采用 MLP-Mixer 式 token 混合, 加强解码查询与非序列 token 之间的交互。

通过将全局异构特征混合与高效长序列建模紧密耦合, 所提框架相比现有分离式流水线架构实现了更丰富的异构交互、更深入的序列结构利用, 以及更优的性能与计算成本权衡。

3.3 查询生成

3.3.1 输入 Token 化. 遵循 RankMixer [28] 的 token 化策略, 输入 token 可按语义分组或自动切分组织。语义分组依据 token 的内在含义 (如用户、上下文或行为语义) 进行划分; 自动切分则将所有特征展平为单一嵌入, 并在不显式区分语义的情况下均匀切分。鉴于本场景中输入特征的语义角色明确, HyFormer 采用语义分组, 以保留结构化归纳偏置并提高可解释性。

3.3.2 查询生成. 查询生成模块将异构非序列特征转换为用于解码长行为序列的语义查询 token。所有非序列特征向量 $F_1, F_2, \dots, F_M \in$




Figure 1: 所提出的 HyFormer 架构概览。该架构引入由序列建模中原始“候选物品”扩展而来的全局 token，并通过基于 MLP-Mixer 的特征交互增强长序列查询容量，重新审视长序列建模与特征交互的作用。它通过交替执行查询解码与查询增强模块，将 LRM 建模任务刻画为交替优化过程。

$R^{1 \times D}$ 被拼接后，经轻量前馈网络映射。此外，通过对行为序列表征池化得到序列级全局摘要，并将其作为类似非序列特征的额外共享输入。

查询通过轻量投影结合非序列特征与池化序列摘要生成：

$$Q = [\text{FFN}_1(\text{Global Info}), \dots, \text{FFN}_N(\text{Global Info})] \in \mathbb{R}^{N \times D}, \quad (3)$$

其中

$$\text{Global Info} = \text{Concat}(F_1, \dots, F_M, \text{MeanPool}(\text{Seq})). \quad (4)$$

为保持服务效率，该模块支持特征选择和可选查询压缩，在保持生成查询数量稳定的同时，为下游解码保留足够的表征容量。

在更深的 HyFormer 层中，查询不再通过 MLP 重新生成，而是由每层复用上一层查询；实质上，以更深层交叉注意力输出作为更新后的查询，以日益丰富的语义检索长序列。

3.4 查询解码

查询解码模块负责将非序列特征转换为语义查询，并通过交叉注意力从长行为序列中提取目标感知信息。序列表征编码模块生成逐层键值表征后，查询解码模块利用查询生成模块产生的多个查询 token，通过多查询交叉注意力机制解码 K/V 表征。

3.4.1 序列表征编码. HyFormer 支持多种具有不同容量—效率权衡的序列编码策略。给定行为序列 S ，每种策略均为后续解码生成逐层键值表征 $(K_l^{(s)}, V_l^{(s)})$ 。

(i) 完整 Transformer 编码 [15]。在最高建模容量设置下，采用标准 Transformer 编码器：

$$H_l = \text{TransformerEnc}_l(S), \quad (5)$$

其通过完整自注意力捕获细粒度交互与长程依赖。

(ii) LONGER[2] 式高效编码。为提高长序列效率，使用紧凑短序列与完整历史之间的交叉注意力替代完整自注意力：

$$H_l = \text{CrossAttn}(S_{\text{short}}, S, S), \quad (6)$$

其中 S_{short} 是长度为 $L_H \ll L_S$ 的紧凑短序列。 S_{short} 作为查询， S 同时作为键和值。该形式替代完整自注意力，将计算复杂度从 $\mathcal{O}(L_S^2)$ 降至 $\mathcal{O}(L_H L_S)$ 。

(iii) 解码器式轻量编码。对于延迟敏感场景，使用无注意力的前馈操作变换序列表征：

$$H_l = \text{SwiGLU}_l(S), \quad (7)$$

以部分上下文建模容量换取最低计算成本。

在所有变体中，所得表征均经线性投影得到层特定的键值状态：

$$K_l = H_l W_l^K, \quad V_l = H_l W_l^V. \quad (8)$$

键值状态在每层重新计算，使序列特征随解码器深度共同演化，同时支持灵活部署配置。

3.4.2 基于交叉注意力的查询解码. 给定序列特定查询 token 及对应的逐层键值表征，HyFormer 通过交叉注意力执行查询解码。对于第 l 层的每个行为序列 S ，解码查询表征为：

$$\tilde{Q}_{(l)} = \text{CrossAttn}(Q_{(l)}, K_{(l)}, V_{(l)}), \quad (9)$$

其中 $\text{CrossAttn}(\cdot)$ 表示标准多头交叉注意力操作， $Q_{(l)} \in \mathbb{R}^{N \times D}$ 表示第 l 层使用的查询 token。

该解码步骤使全局非序列特征能够直接关注长行为序列，将上下文信号注入序列感知查询表征。解码后的查询 $\tilde{Q}_{(l)}$ 随后作为后续交互与增强模块的语义接口。

3.5 查询增强

查询增强模块在查询表征输入后续交叉注意力层之前对其增强。经过解码后，查询已编码序列感知信息，但其与静态异构非序

列特征的交互仍不充分。查询增强通过显式混合查询 token 间的信息，并注入额外非序列特征信号来解决这一问题。

结合解码输出，统一查询表征定义为

$$Q = [\tilde{Q}_l, F_1, \dots, F_M] \in \mathbb{R}^{T \times D}, \quad (10)$$

其中 $T = N + M$, $\tilde{Q}_l \in \mathbb{R}^{N \times D}$ 表示第 l 层获得的解码查询 token 集合，其余 M 个 token 对应非序列特征嵌入。

具体而言，增强模块采用受 RankMixer[28] 启发的 MLP-Mixer 式 [14] 轻量 token 混合操作，以丰富解码查询。首先将每个查询 token $q_t \in Q$ 划分为 T 个通道子空间：

$$q_t = [q_t^{(1)} \| q_t^{(2)} \| \dots \| q_t^{(T)}], \quad q_t^{(h)} \in \mathbb{R}^{D/T}. \quad (11)$$

对于每个子空间索引 $h \in \{1, \dots, T\}$, MLP-Mixer 通过拼接对应子空间，聚合所有 token 位置的信息：

$$\tilde{q}_h = \text{Concat}(q_1^{(h)}, q_2^{(h)}, \dots, q_T^{(h)}) \in \mathbb{R}^D. \quad (12)$$

汇集所有混合 token，得到 token 混合表征

$$\hat{Q} = [\tilde{q}_1, \tilde{q}_2, \dots, \tilde{q}_T] \in \mathbb{R}^{T \times D}. \quad (13)$$

随后使用轻量 Per-token 前馈模块进一步优化混合查询：

$$\tilde{Q} = \text{PerToken-FFN}(\hat{Q}), \quad (14)$$

其中 PerToken-FFN($\cdot$) 对每个查询 token 施加独立前馈变换，在保持线性计算复杂度的同时实现子空间特定优化。

最后，采用残差连接以稳定优化并保留原始解码语义：

$$Q_{\text{boost}} = Q + \tilde{Q}. \quad (15)$$

增强后的查询随后传入下一 HyFormer 层，使更深层能够使用逐渐丰富且更具表达力的表征检索长行为序列。

3.6 HyFormer 模块

HyFormer 模块由多层堆叠而成，每层包含一个查询解码块，随后接一个查询增强块。在每一层，语义查询通过交叉注意力与长行为序列交互，所得序列感知表征进一步优化后作为更深层的输入。

形式化地，在第 l 层，查询解码块接收输入全局查询 $Q^{(l-1)}$ ，并在长序列产生的逐层键值表征 ($K^{(l)}, V^{(l)}$) 上执行交叉注意力：

$$\hat{Q}^{(l)} = \text{CrossAttn}(Q^{(l-1)}, K^{(l)}, V^{(l)}). \quad (16)$$

随后将解码查询 $\hat{Q}^{(l)}$ 与非序列 token 拼接并传入查询增强块；该块采用轻量逐 token 变换丰富查询表征：

$$\tilde{Q}^{(l)} = \text{QueryBoost}(\text{Concat}(\hat{Q}^{(l)}, \text{NS Tokens})), \quad (17)$$

通过堆叠多个此类层，HyFormer 逐步优化语义查询，使更深层能够以越来越富有表达力的表征抽象长序列。顶层 HyFormer 的输出送入下游 MLP 完成最终预测，从而在 LRM 中高效、灵活地整合异构非序列特征与长行为序列。

3.7 多序列建模




Figure 2: HyFormer 中的多序列建模。

在工业推荐场景中，用户行为通常组织为多个异构序列，例如视频观看序列和商品购买序列。现实中的多个序列往往具有不同的特征空间和语义表征，我们通过实验发现，MTGR[8] 或 OneTrans[25] 采用的简单序列合并会导致性能显著下降（见第 4 节）。因此，HyFormer 不将不同序列合并为统一数据流，而是在每个 HyFormer 块中独立处理各行序列，以兼顾效率与效果。如图 2 所示，针对每个序列构建一组专用查询 token，并在对应序列表征上执行查询解码。该设计在解码时保留序列特定语义，同时允许后续通过查询级 token 混合处理跨序列交互，无需显式拼接序列。

3.8 训练与部署优化

3.8.1 长序列 GPU 池化。 用户长序列特征可能极其庞大，造成显著的数据传输开销（如 Host-to-Device 内存复制）和较高的主机内存压力。幸运的是，这类序列中真正唯一的特征 ID 数量有限（通常约占全部 token 的 25%）。我们利用这种稀疏性对特征去重，大幅降低传输成本和主机内存占用。具体而言，在计算图执行前，特征存储于压缩嵌入表中；执行期间，高性能前向算子直接在 GPU 上重建原始序列特征；反向传播时，配套反向算子将序列特征梯度聚合为嵌入表梯度，再向上游传播以更新稀疏参数。

3.8.2 异步 AllReduce。 为减少同步梯度聚合造成的空闲时间，系统启用异步 AllReduce，使第 k 步的梯度同步与第 $k+1$ 步的前向和反向计算重叠。该设计有效消除通信气泡并最大化 GPU 利用率，但代价是稠密参数引入一步陈旧性：由于其梯度只有在异步归约完成后才可用，更新规则变为 $W_k = W_{k-1} + g_{k-1}$ 即第 k 步的稠密参数使用前一步梯度。相比之下，稀疏参数可在局部梯度算出后立即更新，即 $W_k = W_{k-1} + g_k$ 因此实际上比稠密参数更新提前一步。虽然这种混合更新调度使稠密与稀疏参数状态之间产生轻微时间不一致，但实证结果表明，该陈旧性在实践中不会降低收敛质量或模型性能。

Table 1: 工业数据集上的整体性能

序列建模	特征交互	AUC↑	Δ AUC	参数量 ($\times 10^6$)	FLOPs ($\times 10^{12}$)
BaseArch: 传统两阶段模型					
LONGER[2]	RankMixer[14, 28]	0.6478	–	386	3.5
LONGER[2]	Full Transformer[15]	0.6472	-0.09%	416	6.2
LONGER[2]	Wukong[24]	0.6465	-0.20%	385	5.2
Full Transformer[15]	RankMixer[14, 28]	0.6481	+0.05%	388	6.6
Full Transformer[15]	Full Transformer[15]	0.6474	-0.06%	418	9.3
Full Transformer[15]	Wukong[24]	0.6468	-0.15%	387	8.3
UniArch: 统一块模型					
MTGR/OneTrans (w/ LONGER)[8, 25]		0.6480	+0.03%	406	6.6
MTGR/OneTrans (w/ Full Transformer)[8, 25]		0.6483	+0.08%	450	21.9
HyFormer (Ours)		0.6489	+0.17%	418	3.9

4 实验

4.1 实验设置

4.1.1 数据集. 我们在抖音搜索系统的点击率 (CTR) 预测任务上评估模型, 这是 ByteDance 真实的大规模工业搜索推荐场景。数据集取自连续 70 天的部分在线用户交互日志, 包含 30 亿个样本。每个样本包括用户特征、查询特征、文档特征、交叉特征及若干序列特征。模型使用的三个主要序列定义如下:

- 长期序列: 用户的长期搜索与点击行为序列, 长度可按需调整, 本文上限设为 3000。
- 搜索序列: 经 Query Search 模块筛选的用户 Top-50 搜索行为物品。
- Feed 序列: 经 Query Search 模块筛选的用户 Top-50 Feed 行为物品。

4.1.2 基线. 我们将模型与若干强基线比较, 它们可分为两类架构范式: 传统两阶段模型与统一架构模型。

传统两阶段模型遵循主流设计, 将序列建模与特征交互分为前后两个阶段。具体而言, 先由专用序列建模模块生成序列表征, 再与其他特征的 token 级表征交叉。长序列建模采用 LONGER[2] 或 Full Transformer[15]; 为捕获 token 化特征之间的交互, 我们采用 RankMixer[28]、Full Transformer[15] 和 Wukong[24] 等成熟特征交互架构。

相比之下, 统一块模型采用联合建模方式, 在单一模型块内同时对序列与非序列特征进行 token 化和处理, 将序列建模与异构特征交互整合为统一阶段。MTGR[8] 将全部特征 token 化, 并使用 Transformer 式骨干联合建模; OneTrans[25] 采用金字塔压缩骨干, 遵循类似的简化设计。在我们的 MTGR/OneTrans 实现中, MTGR/OneTrans (LONGER) 仅计算非序列与序列特征之间的交叉注意力, 不计算序列内部自注意力; 此外, 我们使用带序列完整自注意力的 MTGR/OneTrans (Full Transformer), 以增加 FLOPs 换取更优性能。

4.1.3 评估指标. 离线评估采用查询级 AUC (曲线下面积): 先对每个查询内的样本计算 AUC[9], 再对所有查询取平均。我们还报告稠密参数量与训练 FLOPs, 后者按批大小 2048 计算。

4.1.4 实现细节. 为便于实验, 推荐模型在离线评估中冷启动, 在在线评估中使用检查点预热。所有基线采用相同的 2048 批

大小和优化器设置。所有 MLP Mixer 模块的输入 token 数统一为 16。在多序列 HyFormer 实现中, 包含 13 个非序列 token 和 3 个全局 token (每个序列一个), 共 16 个 token。所有模型采用相同的超参数调优, 并在 64-GPU 集群上训练。

4.2 整体性能

4.2.1 现有方法比较. 所提出的 HyFormer 在全部评估模型中取得最高 AUC, 优于传统两阶段模型 (BaseArch) 与其他统一块模型 (UniArch)。BaseArch 组内性能受组件选择影响显著: 在特征交互方面, RankMixer [28] 始终优于 Self-Attention 和 Wukong[24]; 在序列建模方面, 引入序列内完整自注意力通常能带来收益。值得注意的是, 即便使用 Full Transformer 做序列建模并搭配 RankMixer, 最佳 BaseArch 组合仍因单向信息流的固有限制而不及 HyFormer。表中还显示 HyFormer 具有更高计算效率: 其准确率最高, 但训练前向和反向传播总 FLOPs 仅为 3.9×10^{12} , 显著低于包括 MTGR[8] 在内的多数竞争模型。整体性能结果凸显了传统两阶段范式的固有限局。

HyFormer 与 MTGR 等统一架构表明, 将序列建模与特征交互整合为连贯设计能够提升整体效果。然而, 表中结果显示, MTGR/OneTrans[8, 25] 依赖 Self-Attention 完成特征交互, 这种方式常会降低 AUC, 并显著损害交互模块的计算效率 [28]。HyFormer 无需采用这类昂贵替代或在序列键值侧进行复杂建模即可达到最佳准确率, 验证了在统一块内迭代执行查询解码与增强的核心原则。此外, MTGR/OneTrans 将全局 token 与序列 token 合并为键, 却只使用全局 token 作为查询, 使全局 token 更易关注自身而非序列 token。相比之下, HyFormer 强制采用分离信息流: 先将具体序列物品信息压缩并吸收到全局 token, 再让不同抽象全局 token 交互, 并跨层反复堆叠这一两步过程。HyFormer 的混合架构也为未来扩展提供更大灵活性, 可独立调整交互层/维度与序列建模层/维度, 比将二者刚性绑定于单个标准注意力层的方法更具适应性。

4.2.2 消融研究. 表 2 展示了 HyFormer 性能提升主要来源的消融研究。首先, 我们消融查询的组成。HyFormer 查询来自三类信息: 全局非序列特征、多序列池化 token 和原始目标特征。实验表明, 将查询退化为仅包含原始目标特征会严重限制后续深层特征交互, 导致 AUC 下降 0.08%。从完整查询中移除

跨序列池化 token 也会使 AUC 损失 0.05%，证明序列间交互在 HyFormer 结构中具有实质贡献。

其次，我们评估整体架构变化。恢复先序列建模、后独立特征交互的基线架构 (LONGER + RankMixer) 后，即使丰富查询信息，由于缺少深层交互，收益仍受限，AUC 仅提升 0.03% (-0.14% 对 -0.17%)。相比之下，在旨在贯穿模型强化交互的 HyFormer 框架中，扩展查询信息带来显著更大的 0.08% AUC 收益。

Table 2: HyFormer 组件消融研究


配置	AUC↑	Δ AUC	参数量 ($\times 10^6$)	FLOPs ($\times 10^{12}$)
查询全局上下文消融				
HyFormer	0.6489	-	418	3.9
查询 (无序列池化 token)	0.6486	-0.05%	415	3.9
查询 (无非序列与序列池化 token)	0.6484	-0.08%	414	3.8
查询增强消融				
HyFormer	0.6489	-	418	3.9
HyFormer w/o Global Tokens	0.6484	-0.08%	414	3.8
BaseArch w/ Global Tokens	0.6480	-0.14%	505	3.6
BaseArch w/o Global Tokens	0.6478	-0.17%	387	3.5
多序列建模消融				
HyFormer	0.6489	-	418	3.9
HyFormer + Merge Seq	0.6485	-0.06%	397	3.9

第三，我们对 HyFormer 的多序列建模策略进行消融。处理多序列主要有两种范式：通过维度对齐与拼接将序列合并后联合建模，或保持序列分离并独立建模。HyFormer 采用后者，为每个序列使用不同查询 token。实验观察到，序列合并与查询共享导致 AUC 显著损失 0.06%，凸显了 HyFormer 扩展查询并实现更广泛特征交互的优势。此外，合并迫使不同序列共享全局 token，忽略其差异性；所得表征捕获的差异化信息远少于 HyFormer 对各序列独立建模。我们推测，序列合并的这一固有局限也部分解释了 MTGR 和 OneTrans 表现不及 HyFormer 的原因。

综上，HyFormer 通过为不同序列使用独立 token，提供了通用的多序列建模框架，避免在序列之间强制对齐侧信息或稀疏维度。该设计不仅最大程度保留序列的固有差异，还能为更重要的序列自适应分配更多全局 token，并在离线实验中带来可观收益。

4.3 扩展分析

本节从序列侧信息、FLOPs 和参数量三个方面分析模型性能的扩展规律。如表 1 的整体性能所示，在先序列建模、后异构特征交互的范式下，LONGER + RankMixer 表现最佳，也是当前生产基线。因此，我们在扩展实验中将其作为 BaseArch 对照组，与 HyFormer 架构比较扩展性能。



(a) AUC 随参数数量的扩展

(b) AUC 随 FLOPs 的扩展

Figure 3: 相对于 FLOPs 与模型参数数量的扩展性能。

4.3.1 参数量与 FLOPs. 我们考察 HyFormer 在 200M 至 1B+ 参数规模范围内的扩展定律，结果如图 3(a) 所示。HyFormer 不仅初始性能优于 LONGER + RankMixer 基线，而且整体保持强劲扩展收益，曲线斜率更陡。这表明，HyFormer 中 LONGER 与 RankMixer 层交替堆叠所实现的双向信息流，使其在相近参数规模下从深度增长中获得显著更大收益。以计算成本 (FLOPs) 分析扩展规律时也呈现类似现象。如图 3(b) 所示，AUC 随 FLOPs 稳步增长，呈显著幂律趋势。这说明增加计算资源使模型能够处理信息更丰富的序列，并受益于初始查询扩展及 MLP-Mixer 特征交互对查询的反复增强，最终带来更大 AUC 提升。

这些结果表明，HyFormer 的架构设计重视扩展效率，通过更丰富的异构特征交互使每个参数产生更大收益，从而形成更陡的性能扩展曲线。

Table 3: 随序列稀疏维度的扩展

序列长度	架构	序列稀疏维度	AUC↑	Δ AUC	Δ AUC 差距
1k	BaseArch	64	0.6478	-	-
		224	0.6484	+0.09%	-
	HyFormer	64	0.6489	-	-
		224	0.6497	+0.12%	+0.03%
3k	BaseArch	64	0.6486	-	-
		224	0.6490	+0.06%	-
	HyFormer	64	0.6499	-	-
		224	0.6507	+0.12%	+0.06%

4.3.2 稀疏维度. 我们还分析了模型性能如何随序列 token 输入维度 (稀疏嵌入维度)，即序列侧信息丰富程度的扩展而变化。实验表明，无论序列长度如何，丰富序列侧信息给 HyFormer 带来的收益始终大于 LONGER + RankMixer 基线。如表 3 所示，对于长度 1000 的序列，将稀疏维度从包含三类侧信息 (物品 ID、搜索查询 textnet 分类和时间戳) 的 64 维扩展到包含七类信息 (新增搜索查询 ID、作者 ID、事件 ID 和播放时长) 的 224 维，基线的 Δ AUC 为 0.09%，HyFormer 则提升 0.12%。HyFormer 的增益显著更大，且该趋势在其他序列长度上同样成立。此外，随着序列变长，HyFormer 与 BaseArch 的性能差距扩大：维度扩展带来的额外收益从 1k 序列长度时的 0.03% 增至 3k 时的 0.06%。

这些结果表明，扩展序列键值信息在 HyFormer 框架中价值更大，并且序列越长，该优势越明显。这一收益源于 HyFormer 能够将更丰富的全局信息融入序列查询，并结合 LONGER 与 Mixer 模块间的双向信息流，共同实现更充分的特征交互。

4.4 在线 A/B 测试

本节给出 HyFormer 在抖音搜索平台上的在线 A/B 测试结果，并与强大的现有 RankMixer 基线比较。在线评估采用三个关键

指标：用户平均观看时长、用户视频完播次数和查询更改率。其中，查询更改率衡量用户手动将搜索查询细化为更具体查询（例如从“iPhone”改为“iPhone 17 Pro”）的概率，计算如下：

$$\text{query change rate} = \frac{N_{\text{reform}}}{N_{\text{total}}} \quad (18)$$

其中 N_{reform} 是发生查询改写的不同用户—查询对数量， N_{total} 是不同用户—查询对总数。该指标可反映用户的负面搜索体验。

如表 4 所示，在线 A/B 测试证实各关键指标均显著改善：用户平均观看时长提升 0.293%，用户视频完播次数增长 1.111%，查询更改率下降 0.236%。这些显著收益证明了 HyFormer 在真实十亿用户级平台环境中的实用价值与有效性。

Table 4: 抖音在线 A/B 测试结果

在线测试指标	收益
用户平均观看时长 ↑	+0.293%
用户视频完播次数 ↑	+1.111%
查询更改率 ↓	-0.236%

5 结论

本文提出 HyFormer 架构。不同于主流的“先长序列建模，再特征交互”范式——即先执行序列建模，再以单向信息流完成异构特征交互——HyFormer 引入全局 token，通过特征交互增强查询容量，重新定义长序列建模与特征交互的作用。该架构在查询解码和查询增强两个核心组件之间交替。从序列建模视角看，这对应一个迭代优化过程：使用全局 token 解码长序列，并通过跨特征交互增强全局 token。该设计为更充分的序列建模与特征交互提供了新颖有效的框架，同时也给出灵活的多序列建模范式。大量离线与在线实验验证了从单向信息流升级为双向协同演化范式的优越性，并提升了未来工业 LRM 的扩展上限。

参考文献

- [1] Fedor Borisov, Mingzhou Zhou, Qingquan Song, Siyu Zhu, Birjodh Tiwana, Ganesh Parameswaran, Siddharth Dangi, Lars Hertel, Qiang Charles Xiao, Xiaochen Hou, et al. 2024. LiRank: Industrial Large Scale Ranking Models at LinkedIn. In *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. 4804–4815.
- [2] Zheng Chai, Qin Ren, Xijun Xiao, Huizhi Yang, Bo Han, Sijun Zhang, Di Chen, Hui Lu, Wenlin Zhao, Lele Yu, Xionghang Xie, Shiru Ren, Xiang Sun, Yaocheng Tan, Peng Xu, Yuchao Zheng, and Di Wu. 2025. LONGER: Scaling Up Long Sequence Modeling in Industrial Recommenders. arXiv:2505.04421 [cs.IR] <https://arxiv.org/abs/2505.04421>
- [3] Jianxin Chang, Chenbin Zhang, Zhiyi Fu, Xiaoxue Zang, Lin Guan, Jing Lu, Yiqun Hui, Dewei Leng, Yanan Niu, Yang Song, and Kun Gai. 2023. TWIN: Two-stage Interest Network for Lifelong User Behavior Modeling in CTR Prediction at Kuaishou. arXiv:2302.02352 [cs.IR] <https://arxiv.org/abs/2302.02352>
- [4] Qiwei Chen, Yue Xu, Changhua Pei, Shanshan Lv, Tao Zhuang, and Junfeng Ge. 2022. Efficient long sequential user data modeling for click-through rate prediction. arXiv preprint arXiv:2209.12212 (2022).
- [5] Yufei Feng, Fuyu Lv, Weichen Shen, Menghan Wang, Fei Sun, Yu Zhu, and Keping Yang. 2019. Deep session interest network for click-through rate prediction. arXiv preprint arXiv:1905.06482 (2019).
- [6] Huan Gui, Ruoxi Wang, Ke Yin, Long Jin, Maciej Kula, Taibai Xu, Lichan Hong, and Ed H Chi. 2023. Hiformer: Heterogeneous feature interactions learning with transformers for recommender systems. arXiv preprint arXiv:2311.05884 (2023).
- [7] Huifeng Guo, Ruiming Tang, Yunming Ye, Zhenguo Li, and Xiuqiang He. 2017. DeepFM: A Factorization-Machine based Neural Network for CTR Prediction. arXiv:1703.04247 [cs.IR] <https://arxiv.org/abs/1703.04247>
- [8] Ruidong Han, Bin Yin, Shangyu Chen, He Jiang, Fei Jiang, Xiang Li, Chi Ma, Mincong Huang, Xiaoguang Li, Chunzhen Jing, Yueming Han, MengLei Zhou, Lei Yu, Chuan Liu, and Wei Lin. 2025. MTGR: Industrial-Scale Generative Recommendation Framework in Meituan. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management (CIKM ' 25)*. ACM, 5731–5738. doi:10.1145/3746252.3761565
- [9] David J Hand and Robert J Till. 2001. A simple generalisation of the area under the ROC curve for multiple class classification problems. *Machine learning* 45, 2 (2001), 171–186.
- [10] Kirill Khrylchenko, Artem Matveev, Sergei Makeev, and Vladimir Baikov. 2025. Scaling recommender transformers to one billion parameters. arXiv preprint arXiv:2507.15994 (2025).
- [11] Jianxun Lian, Xiaohuan Zhou, Fuzheng Zhang, Zhongxia Chen, Xing Xie, and Guangzhong Sun. 2018. xDeepFM: Combining Explicit and Implicit Feature Interactions for Recommender Systems. In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD ' 18)*. ACM, 1754–1763. doi:10.1145/3219819.3220023
- [12] Pi Qi, Xiaoqiang Zhu, Guorui Zhou, Yujing Zhang, Zhe Wang, Lejian Ren, Ying Fan, and Kun Gai. 2020. Search-based User Interest Modeling with Lifelong Sequential Behavior Data for Click-Through Rate Prediction. arXiv:2006.05639 [cs.IR] <https://arxiv.org/abs/2006.05639>
- [13] Zihua Si, Lin Guan, Zhongxiang Sun, Xiaoxue Zang, Jing Lu, Yiqun Hui, Xingchao Cao, Zeyu Yang, Yichen Zheng, Dewei Leng, Kai Zheng, Chenbin Zhang, Yanan Niu, Yang Song, and Kun Gai. 2024. TWIN V2: Scaling Ultra-Long User Behavior Sequence Modeling for Enhanced CTR Prediction at Kuaishou. In *Proceedings of the 33rd ACM International Conference on Information and Knowledge Management (CIKM ' 24)*. ACM, 4890–4897. doi:10.1145/3627673.3680030
- [14] Ilya O Tolstikhin, Neil Houlsby, Alexander Kolesnikov, Lucas Beyer, Xiaohua Zhai, Thomas Unterthiner, Jessica Yung, Andreas Steiner, Daniel Keysers, Jakob Uszkoreit, et al. 2021. Mlp-mixer: An all-mlp architecture for vision. *Advances in neural information processing systems* 34 (2021), 24261–24272.
- [15] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. *Advances in neural information processing systems* 30 (2017).
- [16] Ruoxi Wang, Rakesh Shivanna, Derek Cheng, Sagar Jain, Dong Lin, Lichan Hong, and Ed Chi. 2021. DCN V2: Improved Deep & Cross Network and Practical Lessons for Web-scale Learning to Rank Systems. In *Proceedings of the Web Conference 2021 (WWW ' 21)*. ACM, 1785–1797. doi:10.1145/3442381.3450078
- [17] Xue Xia, Pong Eksombatchai, Nikil Pancha, Dhruvil Deven Badani, Po-Wei Wang, Neng Gu, Saurabh Vishwas Joshi, Nazanin Farahpour, Zhiyuan Zhang, and Andrew Zhai. 2023. TransAct: Transformer-based Realtime User Action Model for Recommendation at Pinterest. In *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD ' 23)*. ACM, 5249–5259. doi:10.1145/3580305.3599918
- [18] Songpei Xu, Shijia Wang, Da Guo, Xianwen Guo, Qiang Xiao, Bin Huang, Guanlin Wu, and Chuanjiang Luo. 2025. Climber: Toward Efficient Scaling Laws for Large Recommendation Models. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management (CIKM ' 25)*. ACM, 6193–6200. doi:10.1145/3746252.3761561
- [19] Yi Xu, Chaofan Fan, Jinxin Hu, Yu Zhang, Zeng Xiaoyi, and Jing Zhang. 2025. STORE: Semantic Tokenization, Orthogonal Rotation and Efficient Attention for Scaling Up Ranking Models. arXiv preprint arXiv:2511.18805 (2025).
- [20] Liren Yu, Wenming Zhang, Silu Zhou, Tao Zhang, Zhixuan Zhang, and Dan Ou. 2025. HHFT: Hierarchical Heterogeneous Feature Transformer for Recommendation Systems. arXiv:2511.20235 [cs.IR] <https://arxiv.org/abs/2511.20235>
- [21] Zhichen Zeng, Xiaolong Liu, Mengyue Hang, Xiaoyi Liu, Qinghai Zhou, Chaofei Yang, Yiqun Liu, Yichen Ruan, Laming Chen, Yuxin Chen, Yujia Hao, Jiaqi Xu, Jade Nie, Xi Liu, Buyun Zhang, Wei Wen, Siyang Yuan, Hang Yin, Xin Zhang, Kai Wang, Wen-Yen Chen, Yiping Han, Huayu Li, Chunzhi Yang, Bo Long, Philip S. Yu, Hanghang Tong, and Jiyan Yang. 2025. InterFormer: Effective Heterogeneous Interaction Learning for Click-Through Rate Prediction. arXiv:2411.09852 [cs.IR] <https://arxiv.org/abs/2411.09852>
- [22] Jiaqi Zhai, Lucy Liao, Xing Liu, Yueming Wang, Rui Li, Xuan Cao, Leon Gao, Zhaojie Gong, Fangda Gu, Michael He, et al. 2024. Actions speak louder than words: Trillion-parameter sequential transducers for generative recommendations. arXiv preprint arXiv:2402.17152 (2024).
- [23] Jiaqi Zhai, Lucy Liao, Xing Liu, Yueming Wang, Rui Li, Xuan Cao, Leon Gao, Zhaojie Gong, Fangda Gu, Michael He, Yinghai Lu, and Yu Shi. 2024. Actions Speak Louder than Words: Trillion-Parameter Sequential Transducers for Generative Recommendations. arXiv:2402.17152 [cs.LG] <https://arxiv.org/abs/2402.17152>
- [24] Buyun Zhang, Liang Luo, Yuxin Chen, Jade Nie, Xi Liu, Daifeng Guo, Yanli Zhao, Shen Li, Yuchen Hao, Yantao Yao, et al. 2024. Wukong: Towards a scaling law for large-scale recommendation. arXiv preprint arXiv:2403.02545 (2024).
- [25] Zhaoqi Zhang, HaoLei Pei, Jun Guo, Tianyu Wang, Yufei Feng, Hui Sun, Shaowei Liu, and Aixin Sun. 2025. OneTrans: Unified Feature Interaction and Sequence Modeling with One Transformer in Industrial Recommender. arXiv:2510.26104 [cs.IR] <https://arxiv.org/abs/2510.26104>

- [26] Guorui Zhou, Na Mou, Ying Fan, Qi Pi, Weijie Bian, Chang Zhou, Xiaoqiang Zhu, and Kun Gai. 2019. Deep interest evolution network for click-through rate prediction. In *Proceedings of the AAAI conference on artificial intelligence*, Vol. 33. 5941–5948.
- [27] Guorui Zhou, Xiaoqiang Zhu, Chenru Song, Ying Fan, Han Zhu, Xiao Ma, Yanghui Yan, Junqi Jin, Han Li, and Kun Gai. 2018. Deep interest network for click-through rate prediction. In *Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining*. 1059–1068.
- [28] Jie Zhu, Zhifang Fan, Xiaoxie Zhu, Yuchen Jiang, Hangyu Wang, Xintian Han, Haoran Ding, Xinmin Wang, Wenlin Zhao, Zhen Gong, Huizhi Yang, Zheng Chai, Zhe Chen, Yuchao Zheng, Qiwei Chen, Feng Zhang, Xun Zhou, Peng Xu, Xiao Yang, Di Wu, and Zuotao Liu. 2025. RankMixer: Scaling Up Ranking Models in Industrial Recommenders. arXiv:2507.15551 [cs.IR] <https://arxiv.org/abs/2507.15551>
- [29] Pablo Zivic, Hernan Vazquez, and Jorge Sánchez. 2024. Scaling Sequential Recommendation Models with Transformers. In *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR 2024)*. ACM, 1567–1577. doi:10.1145/3626772.3657816