

LONGER：工业推荐系统中长序列建模的规模化

Zheng Chai*
chaizheng.cz@bytedance.com
ByteDance
Hangzhou, China

Huizhi Yang*
yanghuizhi@bytedance.com
ByteDance
Beijing, China

Di Chen
chendidi.666@bytedance.com
ByteDance
Beijing, China

Lele Yu
yulele@bytedance.com
ByteDance
San Jose, USA

Xiang Sun
sunxiang.0@bytedance.com
ByteDance
Beijing, China

Qin Ren*
renqin.97@bytedance.com
ByteDance
Beijing, China

Bo Han*
hanbo.1990@bytedance.com
ByteDance
Shanghai, China

Hui Lu
luhui.xx@bytedance.com
ByteDance
Hangzhou, China

Xionghang Xie
xiexionghang@bytedance.com
ByteDance
Beijing, China

Yaocheng Tan
tanyaoyaocheng@bytedance.com
ByteDance
Beijing, China

Xijun Xiao*
xiaoxijun@bytedance.com
ByteDance
Beijing, China

Sijun Zhang
zhangsijun.randyz@bytedance.com
ByteDance
Beijing, China

Wenlin Zhao
zhaowenlin@bytedance.com
ByteDance
Beijing, China

Shiru Ren
renshiru2000@gmail.com
ByteDance
Beijing, China

Peng Xu
xupeng@bytedance.com
ByteDance
San Jose, USA

Yuchao Zheng†
zhengyuchao.yc@bytedance.com
ByteDance
Beijing, China

Di Wu
di.wu@bytedance.com
ByteDance
Beijing, China

摘要

对超长用户行为序列进行建模，对于捕获工业推荐系统中的长期和短期偏好至关重要。现有方案通常依赖两阶段检索或间接建模范式，因而带来上下游不一致和计算效率低下的问题。本文提出 **LONGER**，即面向 GPU 高效推荐系统的长序列优化 Transformer (Long-sequence Optimized traNsformer for GPU-Efficient Recommenders)。LONGER 包含：(i) 用于稳定长上下文注意力的全局词元机制；(ii) 结合轻量级 InnerTransformer 和混合注意力策略的词元合并模块，以降低二次复杂度；(iii) 一系列工程优化，包括混合精度与激活重计算训练、KV 缓存服务，以及在 GPU 上统一更新稠密和稀疏参数的全同步模型

* 这些作者贡献相同。

† 通讯作者。

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.

RecSys '25, 捷克共和国布拉格

© 2025 Copyright held by the owner/author(s). Publication rights licensed to ACM.

ACM ISBN 979-8-4007-1364-4/2025/09

<https://doi.org/10.1145/3705328.3748065>

训练与服务框架。在字节跳动的广告和电商服务中，LONGER 在离线指标与在线 A/B 测试上均持续优于强基线，验证了其稳定有效性和工业级缩放定律。目前，LONGER 已在字节跳动数十个具有实际影响力的场景中得到验证并全面部署，服务数十亿用户。

CCS 概念

• 信息系统 → 推荐系统。

关键词

超长序列建模，工业推荐系统，缩放定律

1 引言

在推荐系统中，超长用户历史行为序列全面包含了用户的长期与短期偏好 [7, 8]。尽管早期序列建模架构已得到广泛研究，并在学术界和工业界普遍应用，但其应用仍主要局限于短序列场景（序列长度为 $10^2 - 10^3$ ）。对长序列（长度 $> 10^3$ ）进行完整建模能够显著提高推荐准确性和多样性，并有助于缓解信息茧房现象。然而，由于计算约束，当前工业界对长序列建模的实际做法主要采用以下策略：

- 两阶段检索。从原始超长序列中选出与当前候选物品最相关的 $\text{top-}k$ 个物品 (通常 k 为 10^2 量级), 随后进行端到端短序列建模。代表性工作包括 SIM[18] 和 TWIN[3, 21]。
- 预训练用户嵌入 [9, 13, 31]。在工业界, 一种常见做法是在源模型中预训练整个超长序列, 并得到压缩的用户嵌入 (User Embedding, UE), 再将其迁移至下游推荐模型。借助高性能先进 GPU, 该方法支持使用长度最高为 10^3 的序列和多层 Transformer 进行预训练。
- 记忆增强模型。多通道用户兴趣记忆网络 (MIMN) [17] 提出一种基于神经图灵机和记忆归纳单元的用户序列记忆结构; 大记忆网络 (LMN) [14] 则提出基于乘积量化分解的轻量结构。记忆增强推荐模型 (MARM) [15] 提出一种以记忆换计算的范式, 对计算密集模块的中间结果进行缓存。

尽管这些策略显著提高了计算效率, 但由于上下游不一致, 或只能间接感知原始超长序列, 它们不可避免地牺牲了原始完整序列信息。因此, 这些方法本质上只是向端到端长序列建模演进过程中的中间阶段。

近年来, 以 GPT[19] 为代表的大语言模型迅速发展, 并确立了缩放定律——一种用于预测模型规模、数据量和计算能力增加时性能提升的经验规律。近期, 这些缩放定律也开始指导推荐系统创新。例如, HSTU[25] 通过残差连接堆叠相同的自注意力层以建模长序列, 其性能优于普通 Transformer 架构。Wukong[26] 提出基于堆叠因子分解机和线性压缩块的交互架构, 并验证了推荐系统中的缩放定律。

与此同时, 计算基础设施的快速进步 (例如 GPU 算力与显存, 以及大规模计算平台和框架的工程化) 使我们能够在工业级推荐系统中率先探索端到端超长序列建模范式。因此, 推进超长序列的端到端建模、持续扩大序列长度, 并改进长序列建模架构, 已成为下一代序列建模框架的关键任务。

为此, 我们提出面向 GPU 高效推荐系统的长序列优化 Transformer, 即 **LONGER**。在该框架中, 我们将序列输入组织为全局词元和原始序列, 并在此基础上开发基于内部 Transformer 的词元合并方法, 以有效降低计算预算。此外, 考虑到用户超长序列中通常存在大量噪声, 我们采用高效的混合注意力策略, 在保持模型性能的同时提升计算效率。为在数十亿用户规模的工业场景中全面部署 LONGER, 我们还提出一系列工程优化, 包括采用混合精度和激活重计算的全同步训练与服务框架, 以及 KV 缓存服务策略。本文贡献概括如下:

- 我们提出 LONGER, 一种面向 GPU 高效推荐系统的长序列优化 Transformer 结构。它从工业 GPU 效率视角出发优化 Transformer 结构, 并在工业场景中以端到端方式将用户序列建模长度扩展至 10,000。
- LONGER 通过词元合并和混合注意力策略显著提高计算效率, 将 FLOPs 降低约 50%, 且经验验证几乎不损失性能。此外, 我们设计了充分优化的工业训练与服务框架, 进一步提高 GPU 计算效率并支持在线部署。
- 我们通过全面实验验证其有效性, 包括在十亿级工业数据集上的离线实验, 以及在抖音¹ 两个重要业务场景中的在线 A/B 测试。目前, LONGER 已在字节跳动数十个场景中广泛应用, 影响数十亿用户。

2 相关工作

2.1 传统短序列建模

迄今为止, 工业推荐系统主要采用序列建模与特征交互相结合的建模范式 [22, 24]。在这一框架中, 序列建模长期以来一直是刻画用户偏好的核心。众多研究中的一个重要里程碑是 DIN[30], 随后又出现了 DIEN[29]、CAN[28] 等方法。此外, 研究者还从不同角度广泛探索多域 [2, 4]、多兴趣 [1, 11] 和序列去噪方法 [5, 20], 以建模用户偏好。需要指出的是, 大多数精心设计的结构都面向短序列建模, 而长序列建模方法直到后来才受到越来越多关注。

2.2 长序列建模

如引言所述, 长序列建模方法大体可分为两阶段检索、预训练用户嵌入和记忆增强模型。总体而言, 基于检索和预训练的方法属于两阶段策略, 而记忆增强模型通常需要较长的训练周期, 才能在记忆槽中积累足够的命中率。近期, 已有一些工作尝试直接建模长序列 [25, 27, 32]。然而, 在大规模工业推荐系统中, GPU 高效的长序列建模仍未得到充分探索。

3 方法

3.1 问题定义

令 $\mathcal{U}$ 和 $\mathcal{I}$ 分别表示用户集合和物品集合。给定用户 $u \in \mathcal{U}$, 其原始行为序列为 $S_u = [i_1^{(u)}, \dots, i_L^{(u)}]$, 其中 $i_t^{(u)} \in \mathcal{I}$; 用户基础特征 u_d 包括用户画像、上下文特征和交叉特征; 目标物品为 $v \in \mathcal{I}$ 。推荐任务旨在预测点击或转化概率:

$$P(y = 1 | S_u, u_d, v) \in [0, 1] \quad (1)$$

其中, $y \in \{0, 1\}$ 表示 u 是否会与 v 发生交互。模型通过历史交互数据 $\mathcal{D} = \{(S_u, u_d, v, y)\}$ 学习这一映射, 并优化二元交叉熵损失:

$$\mathcal{L} = -\frac{1}{|\mathcal{D}|} \sum_{(S_u, u_d, v, y) \in \mathcal{D}} [y \log \hat{y} + (1 - y) \log(1 - \hat{y})] \quad (2)$$

其中, $\hat{y} = f_\theta(S_u, v)$ 为推荐模型预测的概率。

3.2 整体框架

我们提出的框架旨在解决推荐系统中长且复杂的用户行为序列建模难题, 同时保持工业规模下的训练与推理效率。图 1 展示了 LONGER 的整体架构。该框架集成输入生成、词元合并、混合注意力机制, 以及训练与服务优化, 从而实现高效、可扩展的长序列建模。

首先, 我们引入全局词元 (Global Tokens) 以增强模型输入结构。它们充当聚合锚点表示 (例如目标物品表示、用户 ID (UID) 嵌入), 以促进全局信息融合并稳定注意力分布。随后, 我们应用词元合并 (Token Merge) 压缩长行为序列, 在保留关键局部模式的同时降低计算复杂度。为了进一步保留组内依赖, 我们引入 InnerTrans, 即在合并后的词元片段内部应用的轻量级内部 Transformer。LONGER 模型结构中描述的核心模型采用混合注意力设计, 将交叉因果注意力 (突出序列中的显著部分) 与堆叠的自因果注意力层 (捕获序列中的高阶依赖) 相结合。

为确保可扩展性和部署可行性, 我们引入多项工程系统级优化。该框架在超大规模 GPU 集群上统一存储稠密与稀疏参数, 并提供全同步训练和服务。我们进一步采用混合精度训练

¹一个拥有数十亿用户、具有广泛影响力的短视频平台: <https://www.douyin.com/>




Figure 1: LONGER 模型架构。

与重计算提升内存和计算效率，从而减少激活内存并支持定制数值精度。最后，在推理过程中，我们部署 KV 缓存服务策略，缓存用户序列表示，并在多个候选物品的打分过程中复用，显著减少冗余计算。

这些组件共同构成一个统一系统，以高表达能力和高效率支持长序列建模，并可便捷部署于大规模真实推荐场景。

3.3 全局词元

我们引入全局词元作为附加于输入序列的辅助表示，以促进全局信息提取和锚定。这些词元可以包括目标物品表示词元、可学习 CLS 词元、UID 嵌入，以及高阶压缩的用户—物品交互特征。全局词元被设计为具有完整的注意力感受野，既可聚合整个序列中的上下文信号，也能影响所有其他序列词元。

这一架构增强有两个主要目的。首先，全局词元作为集中的信息锚点，增强用户历史、上下文属性与候选物品之间的特征交互。其次，它们能够稳定长序列中的注意力动态，尤其是在稀疏注意力配置下。StreamLLM [23] 表明，引入少量全局词元可缓解“注意力沉降”效应，即更深的注意力层会不成比例地关注早期词元。这些词元充当锚点，维持注意力多样性并保留长程依赖建模能力。

3.4 词元合并

令 L 为序列长度， d 为嵌入维度。由于注意力具有 $O(L^2d)$ 的二次复杂度，使用普通 Transformer 处理长行为序列（通常

$L \geq 2000$ ）会产生难以承受的计算成本，尤其是在 $L \gg d$ 时（工业推荐系统中通常为 $L = 2000$ 、 $d = 32$ ）。序列截断等传统方案会丢失长程依赖。为此，我们提出词元合并策略，将相邻词元分组并压缩为更短的序列，在模型效率和表示保真度之间取得平衡。该策略将序列长度缩短 K 倍，实际上执行了空间压缩。分组后的词元表示既可以通过简单拼接形成，也可以通过轻量级 InnerTrans 块引入组内交互，进一步增强表示。该设计在效率与表达能力之间提供灵活权衡：既保留局部语义，又能在更短的序列上进行全局建模。

对于标准结构的 Transformer 编码器层，其 FLOPs 和参数量可表示为 [16]：

$$\text{FLOPs}_{\text{vanilla trans}} = 24Ld^2 + 4L^2d \quad (3)$$

$$\text{Params}_{\text{vanilla trans}} = 12d^2 + 13d \quad (4)$$

计算复杂度。词元合并前后的注意力复杂度之比为：

$$\frac{\text{FLOPs}_{\text{Merge Token}}}{\text{FLOPs}_{\text{vanilla}}} = \frac{24Ld^2K + \frac{4L^2d}{K}}{24Ld^2 + 4L^2d} = \frac{6dK + \frac{L}{K}}{6d + L}$$

对于典型设置 $L = 2048$ 、 $d = 32$ ：

- 普通 Transformer: FLOPs $\approx 587\text{M}$
- 合并 ($K = 4$): FLOPs $\approx 336\text{M}$ (降低 42.8%)

参数扩展。词元合并通过缩短序列长度降低计算复杂度，同时增加参数量 Θ_{merge} ，从而同时提高效率与模型表达能力，并改善整体模型性能。

$$\Theta_{\text{merge}} = 12K^2d^2 + 13Kd \quad (5)$$

InnerTrans。为了将多个相邻词元合并为一个词元，若仅简单拼接组内词元，词元之间的交互可能不充分，从而丢失细粒度细节。为解决这一问题，我们引入 InnerTrans，在每个词元组内应用 Transformer 以实现局部交互。该方法可有效捕获各组内部的交互，避免直接拼接通常造成的信息损失。由于维度和序列长度都很小，InnerTrans 在实践中的计算预算十分有限。

$$\mathbf{M}_i = \text{TransformerBlock}([\mathbf{e}_i^1, \dots, \mathbf{e}_i^K]) \quad (6)$$

其中， $\mathbf{M}_i$ 表示第 i 组的表示， $\mathbf{e}_i^k$ 表示第 i 组中的第 k 个物品嵌入。

3.5 LONGER 模型结构

在模型架构中，我们采用结合交叉注意力层和自注意力层的混合注意力机制，以高效处理输入序列。

3.5.1 输入生成。模型输入由两个主要部分组成：全局词元与序列词元。全局词元表示上下文信息（例如第 3.3 节所述的目标物品特征和用户标识符），它们与序列词元拼接形成输入。

为了更好地捕获用户行为序列中的时间动态，我们为序列词元加入额外的位置侧信息。具体而言，我们引入两种位置编码：(1) 绝对时间差特征，用于量化每次用户交互与目标物品之间的时间距离；该特征作为侧信息与每个物品嵌入拼接；(2) 可学习的绝对位置嵌入，用于编码每个词元在序列中的位置，并与物品嵌入相加。

完成位置编码后，将所得词元输入多层感知机（MLP），生成输入表示 $\mathbf{R} \in \mathbb{R}^{(m+L) \times d} = [\mathbf{G} \in \mathbb{R}^{m \times d}; \mathbf{H} \in \mathbb{R}^{L \times d}]$ ，其中 $\mathbf{G}$ 和 $\mathbf{H}$ 分别表示全局词元与序列词元表示。随后，将 m 个全局词元 $\mathbf{G} \in \mathbb{R}^{m \times d}$ 与 k 个采样序列词元 $\mathbf{H}_s \in \mathbb{R}^{k \times d}$ 拼接，构造查询矩阵 $\mathbf{O}$ 。这些序列词元依据预定义采样策略从完整序列词元 $\mathbf{H}$ 中选出。类似的查询压缩思想也见于其他研究领域，例如 Perceiver[10] 和 Q-Former[12]，它们采用可学习词元策略进行压缩。实验中，我们全面比较了多种策略，包括选取最近的 k 个词元、均匀采样词元，以及初始化 k 个可学习词元，结果发现最近的 k 个策略效果最佳。采用混合注意力设计的第一动机是：模型性能相对于序列词元数量呈现明显的边际效应；仅采样完整序列的 40% 便可保留超过 95% 的性能增益，同时将 FLOPs 降低约 50%（见第 4 节）。组合查询构造如下：

$$\mathbf{O} = [\mathbf{G}; \mathbf{H}_s] \quad (7)$$

这种混合设计使注意力同时聚焦关键局部行为与全局上下文信号，使模型能够高效捕获特定序列依赖和更广泛的上下文信息。

3.5.2 交叉因果注意力（第一层）。在第一层注意力中，我们使用上一步生成的查询矩阵 $\mathbf{O}$ 和输入词元 $\mathbf{R} \in \mathbb{R}^{(m+L) \times d}$ 执行交叉因果注意力。交叉注意力机制的计算如下：

$$\mathbf{Q} = \mathbf{O}\mathbf{W}_Q, \quad \mathbf{K} = \mathbf{R}\mathbf{W}_K, \quad \mathbf{V} = \mathbf{R}\mathbf{W}_V \quad (8)$$

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d}} + \mathbf{M}\right)\mathbf{V} \quad (9)$$

其中， $\mathbf{W}_Q$ 、 $\mathbf{W}_K$ 和 $\mathbf{W}_V$ 分别表示形状为 $\mathbb{R}^{d \times d}$ 的查询、键和值投影，掩码矩阵 $\mathbf{M}$ 定义为：

$$\mathbf{M}_{i,j} = \begin{cases} 0, & \text{若 } j \geq i, \text{ 其中 } \{i, j\} \in [1, m+L] \\ -\infty, & \text{其他情况} \end{cases} \quad (10)$$

一方面，因果掩码设计保持了序列物品之间的时间相关性；另一方面，它确保候选物品对序列不可见，从而支持 KV 缓存服务机制（见第 3.6.3 节）。计算注意力后，结果再通过前馈网络（FFN）进一步处理。

3.5.3 自因果注意力（后续层）。交叉因果注意力层之后的若干层由自因果注意力块组成。这些层专注于学习采样词元序列内部的关系，使模型能够捕获行为序列词元自身的依赖与模式。每个自因果注意力层后都接一个 FFN，以进一步处理注意力机制学习到的信息。自因果注意力机制采用类似的公式计算：

$$\text{SelfAttention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d}} + \mathbf{M}\right)\mathbf{V} \quad (11)$$

此处，查询、键和值通过将独立的线性投影 $\mathbf{W}_Q$ 、 $\mathbf{W}_K$ 、 $\mathbf{W}_V$ 应用于上一层输出得到。

3.5.4 堆叠与压缩。自因果注意力层堆叠 N 次，以迭代细化输入序列表示。通过这些层后，模型生成压缩输出，即注意力机制的最终输出，随后用于下游预测任务。

$$\text{CrossAttn}(\mathbf{O}, \mathbf{R}) \rightarrow \text{SelfAttn}(\cdot) \times N \quad (12)$$

$\{z\}$
压缩长序列

$\{z\}$
高阶交互

通过在第一层使用交叉注意力、在后续层使用自注意力，我们的模型能够高效处理长序列，同时利用全局上下文和内部依赖。

3.6 训练与部署优化




Figure 2: 训练框架

3.6.1 训练框架。我们的训练框架是专为大规模稀疏模型设计的全同步系统，旨在充分发挥现代高性能 GPU 的能力。该框架基于软硬件协同设计理念，目标是在分布式训练中最大化计算吞吐量和内存效率。训练流程首先以批处理或流式形式摄取数据，随后通过 Fountain 模块进行预处理。处理后的训练数据被分发至多个 GPU 运行器，在其中同步更新稠密和稀疏参数。这一统一设计能够在设备和节点之间有效扩展，为生产环境中的大参数模型训练提供稳健基础。




Figure 3: KV 缓存服务

该框架的显著特点是统一的参数存储与训练架构。稠密和稀疏参数均在 GPU 机器上同步存储与更新，无需外部参数服务器组件。为更好地适应推荐系统中的特征分布模式，该框架针对稀疏嵌入采用分层内存系统，从而高效支持大型嵌入表。在这一设计中，高频特征存储在高带宽 GPU 显存（HBM）中，中频特征驻留在 CPU 主存（MEM）中，低频特征则卸载至本地固态硬盘（SSD）。这种分层存储布局经过优化，可匹配推荐数据的访问特征，在时延、吞吐量和容量之间提供实用权衡。其核心创新在于将计算和参数存储完全共置于 GPU 机器上，从而降低通信开销和内存传输时延，最终提高训练吞吐量、减少陈旧性并增强收敛稳定性。

3.6.2 混合精度训练与重计算。为缓解训练期间的 GPU 内存压力，我们将重计算策略与混合精度训练结合使用。梯度计算采用反向模式自动微分，它比前向模式更高效，但需要存储前向传播中的所有中间激活，而这些激活可能成为主要内存瓶颈。为此，我们在模型定义层支持重计算声明，使选定的激活可在前向传播中丢弃，并在反向传播中重新计算，从而以计算换取内存节省。由于原生 TensorFlow 未正式支持重计算，我们使用 `custom_gradient` 机制实现该功能，并通过代码级标注提供细粒度控制。

此外，为降低稠密模型扩展带来的计算开销，我们采用基于 BF16/FP16 的混合精度训练。用户可在模型层面配置精度，对关键组件使用较高精度，而在其他部分使用较低精度。该方法在生产工作负载中取得了显著收益：吞吐量平均提高 18%，训练时间缩短 16%，内存使用减少 18%，其中稠密层的内存降幅最高可达 28%。

3.6.3 KV 缓存服务。受 M-FALCON[25] 启发，为提高多候选打分时的推理效率，我们引入 KV 缓存机制，将用户行为词元与候选物品特定全局词元之间的注意力计算解耦。由于不同候选物品共享同一用户序列，其内部表示只需计算一次，随后即可复用。

具体而言，我们将注意力输入分为两部分：（1）用户序列词元；（2）与候选物品关联的全局词元。用户序列的键和值投影被预先计算并缓存。对于每个候选物品，只需计算其全局词元与缓存用户序列之间的注意力。由此形成两阶段推理过程：

- （1）预先计算并缓存用户序列的键值张量。
- （2）计算每个候选物品的全局词元与缓存用户序列之间的注意力。

如图 3 所示，该优化避免了冗余计算，并显著降低服务时延。在实践中，它提高了在线服务效率，将吞吐量降幅从最高 -40% 缩小至仅 -6.8%。

4 实验

4.1 实验设置

我们在抖音广告系统的转化率（Conversion Rate, CVR）预测任务上评估模型，该任务属于真实的大规模工业广告推荐场景。数据集由 2024 年 10 月 16 日至 2025 年 2 月 23 日收集的部分在线用户交互日志构建，涵盖连续 130 天、共 52 亿个样本。每个样本包括用户 ID（UID）、性别等用户人口统计特征、超长用户行为序列，以及一个候选广告物品。用户行为序列包含页面浏览、点击和转化等多种交互类型；物品侧特征则涵盖广告内容、展示上下文和相关元数据。我们采用时间一致的数据划分策略：前 123 天用于训练，其余 7 天用于离线评估。该设置符合真实部署实践，并能有效避免模型开发过程中的未来数据泄漏。

为进行比较，我们选取多种强基线，按其建模短程或长程用户行为的能力分类。短序列方法包括 TWIN[3] 和依赖 50 次交互的 DIN (Recent50)。长序列方法包括 SumPooling、DIN[30]、HSTU[25] 和 Transformer[6]；这些方法处理更长的行为历史，但在工业环境中通常面临可扩展性与效率问题。所有模型均采用相同的预处理流程和超参数调优，并在由 48 块 A100 GPU 组成的集群上开展实验。

4.2 整体性能

4.2.1 与现有方法的比较。我们使用推荐系统二分类任务的两个标准指标，在离线评估集上报告模型性能：AUC（ROC 曲线下面积）和 LogLoss。表 1 总结了多个基线与本文模型的结果。由表可见，我们的模型优于所有基线，AUC 达到 0.85290，LogLoss 为 0.47103；相较基础模型，AUC 相对提高 1.57%，相较最具竞争力的 Transformer 模型，AUC 提高 0.21%。需要指出，在工业场景中，0.1% 的提升就被视为显著改进，足以影响在线 A/B 测试表现。此外，本文模型的效率也显著高于普通 Transformer（见第 4.2.2 节）。这一改进证明，我们的方法能够在保持计算效率的同时有效捕获长程行为依赖。

4.2.2 消融实验。表 2 给出了 LONGER 关键组件及查询相关配置的消融实验。我们首先考察 TokenMerge 模块和 InnerTrans 组件的影响。相较不进行合并的基础模型，引入 TokenMerge (Concat, 250) 将 FLOPs 从 3.73×10^9 降至 3.03×10^9 ，同时使 AUC 提高 1.58%、LogLoss 降低 3.48%。进一步加入 InnerTrans 后又获得额外收益，取得最佳整体 LogLoss 0.47052，以及 1.63% 的 AUC 提升。

随后，我们改变用于汇总用户近期行为的查询数量（ k ）。结果表明，增大 k 通常可以提升性能，但也会增加计算量。值得注意的是，使用 100 个查询取得了良好权衡：AUC 为 0.85290，LogLoss 为 0.47103，与使用全部查询（ $k = 250$ ）时的性能非常接近，但 FLOPs 仅为后者的 54%。表 2 以粗体标出这一设置，表明它适合计算预算至关重要的真实部署环境。

最后，我们比较不同的查询选择策略。可以将这些策略视为查询集合的不同初始化方法。其中，使用随机初始化的可学习查询表现最差（AUC = 0.84946）。相比之下，直接选取最近 100 次用户行为（Recent 100）取得了最佳整体性能。均匀采样、结合近期物品和均匀采样物品等其他策略的 AUC 略低，LogLoss 略高。这些发现表明，使用信息丰富的行为——尤其是近期行为——初始化查询，对于在长序列建模中有效捕获用户意图至关重要。

总体而言，消融实验表明，架构增强（例如 TokenMerge、InnerTrans）和查询相关策略（例如查询数量与选择方法）都

Table 1: 各方法在工业数据集上的评估结果

	基础模型	SumPooling	TWIN	DIN (最近 50 条)	DIN	HSTU	Transformer	LONGER
AUC↑	0.83968	0.84201	0.84472	0.84698	0.84982	0.84994	0.85111	0.85290
LogLoss↓	0.48758	0.48538	0.48168	0.47830	0.47452	0.47490	0.47293	0.47103
ΔAUC(%)	-	+0.28	+0.60	+0.87	+1.21	+1.22	+1.36	+1.57
ΔLogLoss(%)	-	-0.45	-1.21	-1.90	-2.68	-2.60	-3.00	-3.39

Table 2: LONGER 查询数量与关键组件的消融实验。

配置	FLOPs (×10 ⁹)	AUC↑	LogLoss↓	ΔAUC	ΔLogLoss
LONGER (w/o Merge, 2000)	3.73	0.85111	0.47293	+1.36%	-3.00%
+TokenMerge4(Concat, 500)	2.13	0.85232	0.47145	+1.51%	-3.31%
+TokenMerge8(Concat, 250)	3.03	0.85291	0.47062	+1.58%	-3.48%
基于采用 <i>TokenMerge8</i> 的 LONGER					
+ InnerTrans	3.52	0.85332	0.47052	+1.63%	-3.50%
改变查询数量（采样最近的 <i>k</i> 个物品）					
查询数量 = 50	1.27	0.85235	0.47162	+1.51%	-3.27%
查询数量 = 80	1.59	0.85248	0.47157	+1.52%	-3.28%
查询数量 = 100	1.91	0.85290	0.47103	+1.57%	-3.39%
查询数量 = 150	2.36	0.85290	0.47101	+1.57%	-3.40%
查询数量 = 200	2.93	0.85331	0.47077	+1.62%	-3.45%
查询数量 = 250	3.52	0.85332	0.47052	+1.63%	-3.50%
查询选择策略					
可学习 100	1.91	0.84946	0.47523	+1.17%	-2.53%
最近 100	1.91	0.85290	0.47103	+1.57%	-3.39%
均匀采样 100	1.91	0.85183	0.47215	+1.45%	-3.16%
最近 50 + 其余均匀采样 50	1.91	0.85255	0.47129	+1.53%	-3.34%

对平衡准确性和效率起关键作用。实验结果验证了：通过精心设计关键组件和行为建模流程，LONGER 能够以更低的计算成本取得强劲性能。这种配置使我们的方法非常适合大规模工业部署，因为此类场景高度重视低时延推理和系统吞吐量。

4.3 缩放分析

本节分析模型性能随序列长度、FLOPs 和参数量的缩放关系。这些因素的缩放行为遵循如下通用形式：

$$y = \alpha x^\beta + \gamma$$

(13)

其中，*y* 表示性能指标（AUC 和 LogLoss），*x* 表示缩放因素（序列长度、FLOPs 或参数量），*α* 和 *β* 为常数，*γ* 表示常数偏移。

4.3.1 序列长度. 我们分析不同模型深度下性能随输入序列长度的缩放规律。如图 4 所示，增加词元数量能够持续提高 AUC 并降低 LogLoss，整体遵循幂律趋势。更深的模型能从更长序列中获得更多收益，但 AUC 增幅会随深度增加而放缓，表明存在边际收益递减。最优深度应在模型容量与计算约束之间取得平衡。

总体而言，更长序列能够提升性能，尤其是在搭配合适深度时；超过一定深度后，进一步增加深度带来的收益十分有限。




Figure 5: 性能随 FLOPs 与模型参数量的缩放关系。

4.3.2 参数量. 我们将层数固定为 2、输入序列长度固定为 2000，并通过扩大隐藏维度评估模型容量。如图 5(a) 所示，AUC 随参数量稳定增长，并呈现明显的幂律趋势（*R*² = 0.987）。结果表明，在架构固定时，增大模型宽度能够有效提升性能，且在当前参数范围内尚未出现饱和迹象。

4.3.3 FLOPs. 我们将模型维度固定为 32，通过改变层数和序列长度分析模型性能。如图 5(b) 所示，AUC 随 FLOPs 稳定增长，并呈现明显的幂律趋势（*R*² = 0.967）。这说明，即使模型宽度固定，增加计算资源仍可使模型处理更长或更复杂的用户行为序列，从而捕获高阶依赖并提高预测准确率。

这些结果表明，增加计算资源是提升性能的有效途径，但仍需在效率收益与真实系统中常见的计算和内存约束之间取得平衡。

4.4 在线 A/B 测试

本节给出在线 A/B 测试结果，以评估所提出模型在抖音广告和抖音电商平台真实场景中的有效性。这两个商业平台都具有广泛影响力，吸引了数十亿用户。这些场景中的基线模型已经非常强大，因此观察到的提升更具意义。双领域测试使我们能够评估模型在广告和电商环境中的泛化能力，而二者都是平台生态系统的关键组成部分。

4.4.1 抖音广告平台. 本节给出抖音广告 A/B 测试结果。我们使用两个关键指标评估模型性能：ADSS（广告主得分）和 ADVV（广告主价值），它们是工业广告系统中最重要指标。测试覆盖直播、短视频和商城三种广告形式。在直播场景中，模型使 ADSS 提高 1.063%、ADVV 提高 1.168%；在短视频场景中，ADSS 提高 2.097%、ADVV 提高 2.151%；在商城场景中，ADSS 提高 1.816%、ADVV 提高 1.407%。这些结果证实，模型在所有广告形式上都能稳定、有效地提升性能。

4.4.2 抖音电商服务. 在抖音电商 A/B 测试中，我们使用两个关键指标评估不同内容形式的有效性：Order/U（每用户订





Figure 4: LONGER 中的序列长度扩展。

Table 3: 抖音广告 A/B 测试结果

广告类型	ADSS	ADV V
直播	+1.063%	+1.168%
短视频	+2.097%	+2.151%
商城	+1.816%	+1.407%

单数) 和 GMV/U (每用户商品交易总额)。这些指标有助于理解模型不仅对总销售额, 也对用户级参与度和价值创造的影响。结果表明, 两个指标均显著提升。直播场景中, Order/U 提高 7.9222%, GMV/U 提高 6.5404%, 说明直播内容对每用户订单数和创造价值都有强烈正向作用。短视频内容中, Order/U 提高 4.6125%, GMV/U 提高 5.2771%, 证明短视频内容能够有效提高每用户整体销售额。结果凸显两种内容形式均带来显著影响, 其中直播在 Order/U 和 GMV/U 上的提升尤其突出。

Table 4: 抖音电商 A/B 测试结果

电商类型	Order / U	GMV / U
直播	+7.9222%	+6.5404%
短视频	+4.6125%	+5.2771%

5 结论

本文提出了 **LONGER**, 一种基于 Transformer 的框架, 旨在对工业推荐系统中的超长用户行为序列进行高效、可扩展的建模。通过引入全局词元、结合 InnerTrans 的词元合并、混合因果注意力等架构设计, 以及 GPU 同步框架、混合精度与重计算训练、KV 缓存服务等系统级优化, LONGER 能够在真实工业约束下实现端到端超长序列建模。在十亿级工业数据集上的大量实验, 以及广告和电商领域的在线 A/B 测试, 验证了其在数十亿用户工业规模下的鲁棒性与泛化能力。值得注意的是, LONGER 在显著降低计算开销的同时取得了具有竞争力的准确率, 非常适合部署在对时延敏感的生产环境中。未来工作包括研究更高效的序列建模技术, 以及改进工业场景中的跨域行为建模。

参考文献

- [1] Zheng Chai, Zhihong Chen, Chenliang Li, Rong Xiao, Houyi Li, Jiawei Wu, Jingxu Chen, and Haihong Tang. 2022. User-aware multi-interest learning for candidate matching in recommenders. In *Proceedings of the 45th international ACM SIGIR conference on research and development in information retrieval*. 1326–1335.
- [2] Zheng Chai, Hui Lu, Di Chen, Qin Ren, Yuchao Zheng, and Xun Zhou. 2025. Adaptive Domain Scaling for Personalized Sequential Modeling in Recommenders. In *Proceedings of the 48th International ACM SIGIR Conference on Research and Development in Information Retrieval*. 4234–4238.
- [3] Jianxin Chang, Chenbin Zhang, Zhiyi Fu, Xiaoxue Zang, Lin Guan, Jing Lu, Yiqun Hui, Dewei Leng, Yanan Niu, Yang Song, et al. 2023. TWIN: Two-stage interest network for lifelong user behavior modeling in CTR prediction at kuaishou. In *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. 3785–3794.
- [4] Jianxin Chang, Chenbin Zhang, Yiqun Hui, Dewei Leng, Yanan Niu, Yang Song, and Kun Gai. 2023. Pepnet: Parameter and embedding personalized network for infusing with personalized prior information. In *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. 3795–3804.
- [5] Huiyuan Chen, Yusan Lin, Menghai Pan, Lan Wang, Chin-Chia Michael Yeh, Xi-aoting Li, Yan Zheng, Fei Wang, and Hao Yang. 2022. Denoising self-attentive sequential recommendation. In *Proceedings of the 16th ACM conference on recommender systems*. 92–101.
- [6] Qiwei Chen, Huan Zhao, Wei Li, Pipei Huang, and Wenwu Ou. 2019. Behavior sequence transformer for e-commerce recommendation in alibaba. In *Proceedings of the 1st international workshop on deep learning practice for high-dimensional sparse data*. 1–4.
- [7] Gabriel de Souza Pereira Moreira, Sara Rabhi, Jeong Min Lee, Ronay Ak, and Even Oldridge. 2021. Transformers4rec: Bridging the gap between nlp and sequential/session-based recommendation. In *Proceedings of the 15th ACM conference on recommender systems*. 143–153.
- [8] Zhicheng He, Weiwen Liu, Wei Guo, Jiarui Qin, Yingxue Zhang, Yaochen Hu, and Ruiming Tang. 2023. A Survey on User Behavior Modeling in Recommender Systems. In *Proceedings of the Thirty-Second International Joint Conference on Artificial Intelligence*. 6656–6664.
- [9] Yupeng Hou, Shanlei Mu, Wayne Xin Zhao, Yaliang Li, Bolin Ding, and Ji-Rong Wen. 2022. Towards universal sequence representation learning for recommender systems. In *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. 585–593.
- [10] Andrew Jaegle, Felix Gimeno, Andy Brock, Oriol Vinyals, Andrew Zisserman, and Joao Carreira. 2021. Perceiver: General perception with iterative attention. In *International conference on machine learning*. PMLR, 4651–4664.
- [11] Chao Li, Zhiyuan Liu, Mengmeng Wu, Yuchi Xu, Huan Zhao, Pipei Huang, Guoliang Kang, Qiwei Chen, Wei Li, and Dik Lun Lee. 2019. Multi-interest network with dynamic routing for recommendation at Tmall. In *Proceedings of the 28th ACM international conference on information and knowledge management*. 2615–2623.

- [12] Junnan Li, Dongxu Li, Silvio Savarese, and Steven Hoi. 2023. Blip-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. In *International conference on machine learning*. PMLR, 19730–19742.
- [13] Zhiwei Liu, Ziwei Fan, Yu Wang, and Philip S Yu. 2021. Augmenting sequential recommendation with pseudo-prior items via reversely pre-training transformer. In *Proceedings of the 44th international ACM SIGIR conference on Research and development in information retrieval*. 1608–1612.
- [14] Hui Lu, Zheng Chai, Yuchao Zheng, Zhe Chen, Deping Xie, Peng Xu, Xun Zhou, and Di Wu. 2025. Large Memory Network for Recommendation. In *Proceedings of the ACM Web Conference*. doi:10.1145/3701716.3715514
- [15] Xiao Lv, Jiangxia Cao, Shijie Guan, Xiaoyou Zhou, Zhiguang Qi, Yaqiang Zang, Ming Li, Ben Wang, Kun Gai, and Guorui Zhou. 2024. MARM: Unlocking the Future of Recommendation Systems through Memory Augmentation and Scalable Complexity. *arXiv preprint arXiv:2411.09425* (2024).
- [16] Deepak Narayanan, Mohammad Shoeybi, Jared Casper, Patrick LeGresley, Mostofa Patwary, Vijay Korthikanti, Dmitri Vainbrand, Prethvi Kashinkunti, Julie Bernauer, Bryan Catanzaro, et al. 2021. Efficient large-scale language model training on gpu clusters using megatron-lm. In *Proceedings of the international conference for high performance computing, networking, storage and analysis*. 1–15.
- [17] Qi Pi, Weijie Bian, Guorui Zhou, Xiaoqiang Zhu, and Kun Gai. 2019. Practice on long sequential user behavior modeling for click-through rate prediction. In *Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining*. 2671–2679.
- [18] Qi Pi, Guorui Zhou, Yujing Zhang, Zhe Wang, Lejian Ren, Ying Fan, Xiaoqiang Zhu, and Kun Gai. 2020. Search-based user interest modeling with lifelong sequential behavior data for click-through rate prediction. In *Proceedings of the 29th ACM International Conference on Information & Knowledge Management*. 2685–2692.
- [19] Alec Radford, Karthik Narasimhan, Tim Salimans, and Ilya Sutskever. 2018. Improving Language Understanding by Generative Pre-Training. (2018). https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf OpenAI technical report.
- [20] Yehjin Shin, Jeongwhan Choi, Hyowon Wi, and Noseong Park. 2024. An attentive inductive bias for sequential recommendation beyond the self-attention. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 38. 8984–8992.
- [21] Zihua Si, Lin Guan, ZhongXiang Sun, Xiaoxue Zang, Jing Lu, Yiqun Hui, Xingchao Cao, Zeyu Yang, Yichen Zheng, Dewei Leng, et al. 2024. Twin v2: Scaling ultra-long user behavior sequence modeling for enhanced ctr prediction at kuaishou. In *Proceedings of the 33rd ACM International Conference on Information and Knowledge Management*. 4890–4897.
- [22] Ruoxi Wang, Bin Fu, Gang Fu, and Mingliang Wang. 2017. Deep & cross network for ad click predictions. In *Proceedings of the ADKDD'17*. 1–7.
- [23] Guangxuan Xiao, Yuandong Tian, Beidi Chen, Song Han, and Mike Lewis. 2024. Efficient Streaming Language Models with Attention Sinks. arXiv:2309.17453 [cs.CL] <https://arxiv.org/abs/2309.17453>
- [24] Zhichen Zeng, Xiaolong Liu, Mengyue Hang, Xiaoyi Liu, Qinghai Zhou, Chaofei Yang, Yiqun Liu, Yichen Ruan, Laming Chen, Yuxin Chen, et al. 2024. InterFormer: Towards Effective Heterogeneous Interaction Learning for Click-Through Rate Prediction. *arXiv preprint arXiv:2411.09852* (2024).
- [25] Jiaqi Zhai, Lucy Liao, Xing Liu, Yueming Wang, Rui Li, Xuan Cao, Leon Gao, Zhaojie Gong, Fangda Gu, Michael He, et al. 2024. Actions speak louder than words: Trillion-parameter sequential transducers for generative recommendations. *arXiv preprint arXiv:2402.17152* (2024).
- [26] Buyun Zhang, Liang Luo, Yuxin Chen, Jade Nie, Xi Liu, Daifeng Guo, Yanli Zhao, Shen Li, Yuchen Hao, Yantao Yao, et al. 2024. Wukong: Towards a scaling law for large-scale recommendation. *arXiv preprint arXiv:2403.02545* (2024).
- [27] Gaowei Zhang, Yupeng Hou, Hongyu Lu, Yu Chen, Wayne Xin Zhao, and Ji-Rong Wen. 2024. Scaling law of large sequential recommendation models. In *Proceedings of the 18th ACM Conference on Recommender Systems*. 444–453.
- [28] Guorui Zhou, Weijie Bian, Kailun Wu, Lejian Ren, Qi Pi, Yujing Zhang, Can Xiao, Xiang-Rong Sheng, Na Mou, Xinchun Luo, et al. 2020. CAN: revisiting feature co-action for click-through rate prediction. *arXiv preprint arXiv:2011.05625* (2020).
- [29] Guorui Zhou, Na Mou, Ying Fan, Qi Pi, Weijie Bian, Chang Zhou, Xiaoqiang Zhu, and Kun Gai. 2019. Deep interest evolution network for click-through rate prediction. In *Proceedings of the AAAI conference on artificial intelligence*, Vol. 33. 5941–5948.
- [30] Guorui Zhou, Xiaoqiang Zhu, Chenru Song, Ying Fan, Han Zhu, Xiao Ma, Yanghui Yan, Junqi Jin, Han Li, and Kun Gai. 2018. Deep interest network for click-through rate prediction. In *Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining*. 1059–1068.
- [31] Kun Zhou, Hui Wang, Wayne Xin Zhao, Yutao Zhu, Sirui Wang, Fuzheng Zhang, Zhongyuan Wang, and Ji-Rong Wen. 2020. S3-rec: Self-supervised learning for sequential recommendation with mutual information maximization. In *Proceedings of the 29th ACM international conference on information & knowledge management*. 1893–1902.
- [32] Pablo Zivic, Hernan Vazquez, and Jorge Sánchez. 2024. Scaling Sequential Recommendation Models with Transformers. In *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*. 1567–1577.