

MDL：通过标记化实现大规模工业推荐中的统一多分布学习

Shanlei Mu*
mushanlei@bytedance.com
字节跳动搜索
北京, 中国

Yuchen Jiang*
jiangyuchen.jyc@bytedance.com
字节跳动 AML
北京, 中国

Shikang Wu*
wushikang@bytedance.com
字节跳动搜索
北京, 中国

Shiyong Hong
hongshiyong.66@bytedance.com
字节跳动搜索
北京, 中国

Tianmu Sha
shatianmu@bytedance.com
字节跳动搜索
北京, 中国

Junjie Zhang
zhangjunjie.leo@bytedance.com
字节跳动搜索
北京, 中国

Jie Zhu
zhujie.zj@bytedance.com
字节跳动 AML
杭州, 中国

Zhe Chen
chenzhe.john@bytedance.com
字节跳动 AML
北京, 中国

Zhe Wang†
zhewang.tim@gmail.com
字节跳动搜索
北京, 中国

Jingjian Lin
linjingjian000@gmail.com
字节跳动搜索
北京, 中国

Abstract

工业推荐系统日益采用多场景学习 (MSL) 和多任务学习 (MTL) 来处理多样化的用户交互与上下文, 但现有方法存在两项关键缺陷: (1) 与复杂特征模块的交互有限, 导致大规模模型参数未被充分利用; (2) 难以在统一框架中联合建模场景信息与任务信息。为解决这些问题, 我们受大语言模型 (LLM) “提示 (prompting)” 范式启发, 提出统一的多分布学习 (Multi-Distribution Learning, MDL) 框架。MDL 将场景与任务信息视为专用标记 (token), 而非辅助输入或门控信号。具体而言, 我们提出统一信息标记化模块, 将特征、场景和任务转换为统一的标记化表示。为实现深层交互, 我们设计了三种相互协同的机制: (1) 用于丰富特征交互的特征标记自注意力; (2) 用于按场景/任务自适应激活特征的领域-特征注意力; (3) 用于联合分布预测的领域融合聚合。通过堆叠上述交互, MDL 使场景和任务信息能够以自底向上、逐层作用的方式“提示”并激活模型庞大的参数空间。在真实工业数据集上的大量实验表明, MDL 显著优于最先进的 MSL 和 MTL 基线。在抖音搜索平台开展的一个月在线 A/B 测试中, LT30 提升了 +0.0626%, 改搜率降低了 -0.3267%。MDL 已在生产环境中全面部署, 每日服务数亿用户。

* 同等贡献。
† 通讯作者。

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.
Conference'17, Washington, DC, USA
© 2026 Copyright held by the owner/author(s). Publication rights licensed to ACM.
ACM ISBN 978-x-xxxx-xxxx-x/YYYY/MM
<https://doi.org/10.1145/nnnnnnnn.nnnnnnn>

CCS Concepts

• 信息系统 → 推荐系统.

Keywords

推荐系统; 大规模推荐模型; 多场景学习; 多任务学习; 标记化

ACM Reference Format:

Shanlei Mu, Yuchen Jiang, Shikang Wu, Shiyong Hong, Tianmu Sha, Junjie Zhang, Jie Zhu, Zhe Chen, Zhe Wang, and Jingjian Lin. 2026. MDL: 通过标记化实现大规模工业推荐中的统一多分布学习. In . ACM, New York, NY, USA, 7 pages. <https://doi.org/10.1145/nnnnnnnn.nnnnnnn>

1 引言

如今, 推荐系统在满足用户个性化兴趣、缓解信息过载问题方面发挥着不可或缺的作用。在大规模工业推荐中, 推荐模型通常需要同时处理多个场景 (e.g., 首页信息流或横幅广告) 和多种用户行为 (e.g., 点击或点赞), 在推荐系统中分别称为多场景学习 (multi-scenario learning, MSL) [14] 和多任务学习 (multi-task learning, MTL) [29]。

在推荐领域, 多场景学习 (MSL) [3, 12, 13, 23–25, 37, 40] 旨在使用统一模型学习来自多个场景的数据, 而多任务学习 (MTL) [1, 11, 15–17] 则旨在通过多个相关目标优化统一模型。从技术角度看, 推荐中的 MSL 与 MTL 的关键在于建模多个分布之间的相互关系: 既要捕捉不同场景和任务之间的共性, 也要辨别其差异。现有方法大多采用共享-专属框架, 在主干网络中组合场景/任务共享组件与场景/任务专属组件。例如, 一类方法 [13, 16, 25] 基于专家混合 (Mixture-of-Experts, MoE) 结构, 通过同时设计共享专家和场景/任务专属专家来建模不同场景与任务。另一类方法 [3, 23] 基于动态参数生成方法, 利用场景或任务特定的先验信息生成专用网络参数 (如 MLP 或门控单元), 从而对不同场景和任务进行差异化建模。

尽管现有方法已取得显著成果，但仍有若干问题亟待解决。(1) 扩展能力受限：受大语言模型 (LLM) 缩放定律 [8, 10] 的启发，近期工业推荐系统着力通过扩大特征交互模块的模型参数规模来提升模型学习能力，并取得了突出效果 [6, 9, 30, 33, 34, 38, 41]。目前，最先进模型的参数规模通常已达到传统推荐模型的数百倍，一般超过 0.1B 参数 [30, 41]。在大参数推荐模型的基础上，现有 MSL 与 MTL 方法未能有效利用复杂的特征交互模块。这是因为这些方法通常仅作用于某些中间模块或浅层输出层，难以充分发挥扩大模型参数规模带来的优势。(2) 统一建模困难：多场景建模主要关注输入分布的差异，而多任务建模强调标签分布的差异。传统共享-专属结构针对这两个方面的设计往往不同。因此，以统一方式联合建模场景信息和任务信息颇具挑战。

为解决上述问题，我们进一步从 LLM 中汲取灵感，以增强推荐中的 MSL 与 MTL。LLM 通过输入适当的提示信息来完成特定的下游任务 [20, 26]。提示词元作为一种特殊词元，能够借助自注意力机制充分激活 LLM 中海量的潜在知识。类似地，我们认为场景信息和任务信息也可以像 LLM 中那样，在推荐模型内充当提示。通过将场景先验与任务先验词元化到统一的潜在空间中，我们使其从单纯的辅助输入转变为核心特征交互主干中的主动参与者。词元化先验不再将场景/任务信息局限于模型的“浅层”（例如门控或输出头），而是能够深入多层交互模块。这样，分布特定信号便可自适应调节模型庞大的参数空间，充分获取缩放定律带来的收益（对应第一个问题）。通过将输入侧的场景上下文与输出侧的任务目标均投影为一致的词元化形式，我们弥合了 MSL 与 MTL 之间的鸿沟。由此形成一个整体式联合建模框架，并通过统一的交互协议捕捉场景与任务之间的依赖关系（对应第二个问题）。

为此，我们提出多分布学习 (Multi-Distribution Learning, MDL) 框架，这是一种面向大规模推荐系统中多场景、多任务学习的统一方法。MDL 的核心遵循“词元化并交互” (Tokenize-and-Interact) 理念：以统一方式将特征、场景和任务信息词元化，再精心设计这些词元之间的有效交互，从而激活模型面向 MSL 与 MTL 的能力。具体而言，我们首先使用统一信息词元化模块，消除不同分布之间的表示鸿沟。该模块对原始输入特征进行语义分割和非线性变换，将其投影为一组离散的特征词元、场景词元和任务词元。基于这些词元，我们通过三种专门机制促进多粒度信息交换。特征词元自交互采用类似自注意力的机制来捕捉高阶特征依赖，为推荐模型提供基础表达能力。特征词元与场景/任务词元之间的交互通过领域感知注意力实现，其中，场景词元和任务词元充当“查询”，自适应地激活并聚合相关特征信息。借此，模型能够根据特定场景/任务上下文确定不同特征子空间的优先级，从而有效应对分布偏移。最后，场景词元与任务词元之间的交互通过领域融合模块实现：该模块聚合词元信息，为多分布预测生成统一且稳健的输出。通过堆叠多层结构，MDL 使特征、场景和任务信息能够以自底向上、逐层推进的方式充分交互。这种深度融合使分布特定提示可以动态引导模型庞大的参数空间，从而有效建模复杂的多分布数据。

为评估所提出的方法 MDL，我们在真实工业数据集上开展了大量实验。实验结果表明，在多种设置下，我们的方法在多场景、多任务推荐中均显著优于各类对比方法。此外，我们在抖音搜索上开展了为期一个月的在线 A/B 测试，实现 LT30 提升 +0.0626%、换网率降低 -0.3267% 的显著收益。目前，所提出的 MDL 方法已在抖音搜索中全面部署。

2 预备知识

我们首先对多场景、多任务推荐问题进行形式化描述。令 $\mathcal{X}$ 和 $\mathcal{Y}$ 分别表示特征空间与标签空间。特征空间通常由用户特征、序列特征、物品特征和交叉特征组成。标签空间表示不同的预测任务 $\mathcal{Y} = \{y^1, \dots, y^N\}$ (e.g., 点击或点赞)，其中 N 为任务数量。考虑 K 个不同场景 $\{\mathcal{S}^1, \dots, \mathcal{S}^K\}$ ，其中场景 k 的样本集合表示为 $\mathcal{S}^k = \{(x_i^k, y_i^{1,k}, y_i^{2,k}, \dots, y_i^{N,k})\}_{i=1}^{|\mathcal{S}^k|}$ 。这里， $x_i^k \in \mathcal{X}$ 是第 i 个样本的特征表示， $y_i^{n,k}$ ($n \in N$) 是第 n 个任务的标签。多场景、多任务推荐方法旨在利用所有场景的样本训练模型 $\hat{y}_i^{n,k} = p_{\Theta}(x_i^k)$ (其参数为 Θ)，使其能够准确预测每个用户行为标签 $y_i^{n,k}$ 。

不同任务采用不同的优化函数来优化模型参数 Θ ，多场景、多任务推荐的标准损失函数可形式化如下：

$$\mathcal{L}_{rec} = \sum_{k=1}^K \sum_{n=1}^N \sum_{i=1}^{|\mathcal{S}^k|} \ell(y_i^{n,k}, \hat{y}_i^{n,k}), \quad (1)$$

其中， $\ell(\cdot)$ 为损失函数，通常采用交叉熵损失。

3 方法

本节介绍用于推荐系统多场景、多任务学习的统一架构——Multi-Distribution Learning (MDL, 多分布学习) 框架。其核心思想是“标记化并交互” (Tokenize-and-Interact)。如图 1 所示，该方法包含统一信息标记化与域感知全标记交互两个模块。前者将异构输入转换为特征标记、场景标记和任务标记等离散潜在标记；后者规定标记间的交互方式，以统一、有效地建模多个场景与任务。下面分别详细介绍。

3.1 统一信息标记化

首先介绍如何以统一的标记化形式表示特征、任务与场景信息。

3.1.1 特征标记化。 输入特征是推荐模型的基础。真实工业推荐系统的输入通常包括用户特征 x_u (e.g., 用户 ID、用户画像)、物品特征 x_i (e.g., 视频 ID、作者 ID)、序列特征 x_{seq} (e.g., 用户历史点击行为) 和交叉特征 x_{cross} 。大多数用户、物品及交叉特征首先经嵌入层转换为高维嵌入 $\mathbf{e}$ ：

$$\mathbf{e}_u, \mathbf{e}_i, \mathbf{e}_{cross} = \text{EmbLayer}(x_u, x_i, x_{cross}). \quad (2)$$

序列特征 x_{seq} 通常由专门设计的序列模块 [2, 21, 39] 提取用户兴趣，并转换为嵌入 $\mathbf{e}_{seq}$ 。最终，所有特征均转化为维度不一的特征嵌入 $\mathbf{e}_{input} = [\mathbf{e}_u; \mathbf{e}_i; \mathbf{e}_{cross}; \mathbf{e}_{seq}]$ 。

为实现复杂特征交互 (e.g., 自注意力 [28]、MLP-Mixer [27])，现有大规模推荐方法通常将特征转换为数量与维度固定的隐表示 $\mathbf{T}_f \in \mathbb{R}^{N_f \times d_f}$ ，即特征标记 [30, 38, 41]。它们可保证后续阶段的高效并行计算和有效特征交互。遵循已有工作 [41]，MDL 采用基于语义的特征标记化方法。具体而言，我们利用领域知识，将特征人工划分为若干语义一致的组。分组特征依次拼接为输入嵌入 $\mathbf{e}_{input} = [\mathbf{e}_1; \mathbf{e}_2; \dots; \mathbf{e}_{N_f}]$ ，其中 N_f 为特征标记数。每个分组特征嵌入 $\mathbf{e}_j$ 包含一组表达相近语义的特征嵌入。投影层随后将 $\mathbf{e}_j$ 转换为固定维隐表示：

$$\mathbf{t}_j = \text{Proj}(\mathbf{e}_j), \quad (3)$$

其中 $\mathbf{t}_j \in \mathbb{R}^{d_f}$ ， d_f 为特征标记维度。最终得到特征标记 $\mathbf{T}_f = [\mathbf{t}_1; \mathbf{t}_2; \dots; \mathbf{t}_{N_f}]$ 。




Figure 1: 本文所提 MDL 方法的整体框架。

3.1.2 场景与任务标记化. 受大语言模型 (LLM) 启发, 为增强特征、场景和任务信息的交互, 我们将场景与任务信息标记化, 使其与特征标记对齐到同一语义空间。相较以往多场景、多任务推荐方法, 统一标记化框架使相关信号从底层开始与特征信息交互并逐层传播, 而非仅影响部分中间结果或浅层输出。类似 LLM 面向下游任务的提示, 这些场景与任务标记可作为提示标记, 激活模型的多场景、多任务推荐能力。

下面介绍场景和任务的标记化方法, 先以场景标记为例。与特征标记 T_f 类似, 场景标记 $T_s \in \mathbb{R}^{(N_s+1) \times d_s}$ 也是数量固定、由特定特征嵌入变换得到的一组隐表示。其输入由两部分组成: (1) 重要特征的额外嵌入 $\hat{e}_{\text{imp}}$ (e.g., 用户 ID、视频 ID), 它与特征标记的输入嵌入 e 不同, 但源于相同原始特征 x ; (2) 场景相关先验特征嵌入 $\hat{e}_{\text{spec}}$ (e.g., 场景特定用户行为序列)。两者兼顾初始信息的丰富性及不同场景标记的差异性。随后用非线性前馈网络进行转换:

$$t_s = \text{Relu}(\text{FFN}(\hat{e}_{\text{imp}} \oplus \hat{e}_{\text{spec}})). \quad (4)$$

不同场景标记 t_s 使用不同 FFN 参数, 即逐标记前馈网络 (Pertoken FFN) [41]。最终得到场景标记 $T_s = [t_{s,1}; t_{s,2}; \dots; t_{s,(N_s+1)}] \in \mathbb{R}^{(N_s+1) \times d_s}$, 其中 d_s 为其维度, N_s 为场景标记数, 等于推荐场景数 (e.g., 首页信息流或横幅广告)。除 N_s 个场景标记外, 还构造所有场景共享的全局场景标记 $t_{s,\text{global}} \in T_s$, 以学习场景间共性知识。

类似地, 输入其他重要特征嵌入和任务相关特征嵌入并经 Pertoken FFN 变换, 可得到任务标记 $T_t \in \mathbb{R}^{N_t \times d_t}$ 。 N_t 为任务标记数, 等于模型的预测任务数。

3.2 域感知全标记交互

获得初始特征、场景与任务标记后, 我们通过控制不同标记间的交互和信息传递来优化标记信息, 进而统一、有效地建模多场景、多任务推荐。交互分为三类: 特征标记自交互、特征-场景/任务标记交互和场景-任务标记交互。

3.2.1 特征标记自交互. 特征标记交互是大规模工业推荐模型的基础模块, 已得到广泛研究 [9, 38, 41]。它通过堆叠高效特征交互模块, 扩大模型参数规模来增强表达能力。自注意力 [28]、MLP-Mixer [27] 及其变体均已广泛用于此类设计。特征交互层可写为:

$$T_f^{(l+1)} = \text{Self-Interaction}(T_f^{(l)}), \quad (5)$$

其中 l 为层编号, $T_f^{(l)}, T_f^{(l+1)} \in \mathbb{R}^{N_f \times d_f}$ 分别表示交互前后的特征标记。本文沿用 RankMixer [41] 的设计, 主要包含 TokenMixing 模块与 Pertoken FFN:

$$T_f^{(l+1)} = \text{PertokenFFN}(\text{LN}(\text{TokenMixing}(T_f^{(l)}) + T_f^{(l)})). \quad (6)$$

该部分也可替换为其他特征交互方法。在多场景、多任务推荐中, 特征标记交互提供基础建模能力; 下面说明场景和任务标记如何进一步激活这些能力。

3.2.2 特征-场景/任务标记交互. 场景/任务标记与特征标记的交互, 使不同场景或任务利用不同特征信息, 实现差异化建模。任务与场景信息自底层即被标记化, 因而可自底向上逐层与特征信息充分交互, 缓解复杂特征交互模块此前仅作用于某些中间层或输出层而利用不足的问题。

我们将这类交互定义为域感知注意力 (Domain-aware Attention)。不失一般性, 以任务标记 T_t 和特征标记 T_f 为例。域感知注意力可视为交叉注意力变体: 以 T_t 为查询, 以 T_f 为键和值, 通过多头交叉注意力交互:

$$\hat{T}_t^{(l+1)} = \text{softmax}\left(\frac{(W_Q T_t^{(l)})(W_K T_f^{(l)})}{\sqrt{d}}\right) W_V T_f^{(l)}, \quad (7)$$

其中 l 为层编号, W_Q, W_K, W_V 是采用 PerToken FFN 形式的 QKV 投影矩阵。同理, 以场景标记 T_s 为查询, 与 T_f 执行相同交互:

$$\hat{T}_s^{(l+1)} = \text{softmax}\left(\frac{(W_Q T_s^{(l)})(W_K T_f^{(l)})}{\sqrt{d}}\right) W_V T_f^{(l)}. \quad (8)$$

借助交叉注意力, 特定任务和场景标记可依据自身数据特征, 自适应、有选择地聚合特征标记中的丰富信息, 实现差异化建模。由于标记化始于底层输入, 该交互可与特征标记自交互层共同堆叠多层; 逐层交互保证复杂结构中信息得到有效利用。

3.2.3 场景-任务标记交互. 任务与场景标记的交互着重融合二者信息, 使模型在特定场景中针对特定任务给出差异化预测。该交互由域融合模块 (Domain-fused Module) 控制。其核心是对每个样本, 为各任务标记 t_t 仅聚合对应的场景标记信息 t_s , 从而保证场景特定的任务预测。

域融合模块包含两步: (1) 样本级场景标记选择; (2) 任务与场景标记的混合信息融合。对每个样本, 依据其场景信

息，从完整集合 $T_s = \{t_{s,1}, t_{s,2}, \dots, t_{s,n_s}, t_{s,global}\}$ 中选择对应标记 $\{t_{s,i}, t_{s,j}\}$ 及全局标记 $t_{s,global}$ 。例如，服务 N_s 个场景的模型中，一个样本必属于一个或多个场景（场景可能重叠），据此选取对应场景标记。随后对 $\{t_{s,i}, t_{s,j}, t_{s,global}\}$ 做均值池化：

$$t_{s,avg} = \text{MeanPooling}(\{t_{s,i}, t_{s,j}, t_{s,global}\}), \quad (9)$$

其中 $t_{s,avg}$ 表示该样本对应的聚合场景信息。再将其融合到任务标记 T_t ；对每个 $t_{t,k} \in T_t$ ，直接使用求和池化：

$$T_t = T_t + t_{s,avg}. \quad (10)$$

实践中，简单池化既高效又足够有效。这种标记化信息融合将场景与任务预测解耦，支持任意场景与任务的灵活组合。

3.3 MDL 模块

介绍主要交互类型后，下面说明完整 MDL 模块内的交互过程。

特征标记的前向传播。特征标记主要依靠自交互传播信息。MDL 模块每一层的传播均遵循式 6。

场景标记的前向传播。场景标记的信息传播包括其与特征标记间的域感知注意力（式 8）、逐场景 FFN 和残差连接：

$$\hat{T}_s^{(l+1)} = \text{DomainAwareAttn}(T_s^{(l)}, T_f^{(l+1)}) + T_s^{(l)}, \quad (11)$$

$$T_s^{(l+1)} = \text{PertokenFFN}(\hat{T}_s^{(l+1)}) + \hat{T}_s^{(l+1)}. \quad (12)$$

域感知注意力后的逐场景 FFN 为各场景标记提供额外非线性变换，增强表达能力；残差连接则保证训练稳定性和跨层信息连续性。

任务标记的前向传播。任务标记的信息传播包括其与特征标记间的域感知注意力（式 7）、域融合模块（式 9、式 10）、逐任务 FFN 及残差连接：

$$\hat{T}_t^{(l+1)} = \text{DomainAwareAttn}(T_t^{(l)}, T_f^{(l+1)}) + T_t^{(l)}, \quad (13)$$

$$\tilde{T}_t^{(l+1)} = \text{DomainFusedModule}(\hat{T}_t^{(l+1)}, \hat{T}_s^{(l+1)}), \quad (14)$$

$$T_t^{(l+1)} = \text{PertokenFFN}(\tilde{T}_t^{(l+1)}) + \tilde{T}_t^{(l+1)}. \quad (15)$$

任务标记的信息传播同样采用 Pertoken FFN 和残差连接。

堆叠 L 层 MDL 模块后，得到最终任务标记 $T_t^{(L)}$ 。在其后接入 logits 层，作为不同预测任务的输出：

$$\hat{y}_n = \text{LogitsLayer}(t_{t,n}^{(L)}), \quad (16)$$

其中 $n \in N_t$ 为预测任务索引。最终任务标记已通过域融合模块为每个样本聚合相应场景信息，因此特定场景样本的梯度只更新对应场景标记。这样，场景标记仅受本场景信息影响，能够从特征标记中聚合信息并有效刻画场景差异。由于标记化信息自底向上聚合，最终预测输出数量不依赖场景数量，同时仍能实现跨场景差异化预测。

4 实验

4.1 实验设置

我们首先介绍实验设置，包括数据集、评估设置、对比方法和实现细节。

4.1.1 数据集。为评估所提出方法的有效性，我们采用来自抖音搜索系统的大规模生产数据集。该数据集采集自真实线上日志，涵盖 3 个主要搜索场景（*i.e.*, 单列搜索、双列搜索和内流搜索）以及 20 多个预测任务。具体而言，我们收集了连续两个月的用户交互日志，涉及数十亿用户和数亿文档。每个样本包含 500 多个特征，包括用户特征、物品特征、序列特征和交叉特征。此外，我们保留数据集的 1% 作为评估数据，并将其排除在训练过程之外。所有用于训练和评估的数据集均经过严格匿名化处理，以保护用户隐私。

4.1.2 评估设置。对于离线评估，我们采用 QAUC（查询级 AUC）作为主要性能指标。该指标反映模型对候选项的排序能力，并广泛应用于个性化搜索系统 [7, 9]。具体而言，QAUC 先计算每个查询内样本的 AUC，再对所有查询的结果取平均。其计算方式如下：

$$\text{QAUC} = \frac{\sum_{i=1}^N \text{AUC}_i}{N}, \quad (17)$$

其中， N 为不同 UID-查询对的数量。为评估模型在多个场景和任务上的性能，我们选取三个主要预测任务作为代表：点击、点赞和收藏，并在所采用生产数据集的三个不同场景中评估这些预测目标的性能。

对于线上评估，我们采用用户 30 日生命周期（*i.e.*, LT30）和查询改写率。LT30 指每位用户在最近 30 天内的平均活跃天数，是衡量 DAU 增长的重要指标。查询改写率衡量用户手动将搜索查询细化为更具体查询的概率（*e.g.*, 从“坦克”改为“坦克 300”）。其计算方式如下：

$$\text{Ratio}_{\text{change}} = \frac{\tilde{N}_{\text{reform}}}{N_{\text{total}}}, \quad (18)$$

其中， $\tilde{N}_{\text{reform}}$ 为发生查询改写的不同 UID-查询对数量。该指标衡量用户对搜索体验的满意程度，也广泛应用于个性化搜索系统 [7, 9]。数值越低表示用户体验越好，也说明模型的预测性能越优。

4.1.3 对比方法。为验证所提出方法的有效性，我们主要考虑以下方法：

- **RankMixer** [41]: 采用 Token Mixing 和 Per-Token FFN 策略捕获异构特征交互，在推荐方法中展现出显著的缩放定律。我们将该方法作为具有代表性的主干基线，不引入额外的多任务或多场景设计。

- **SharedBottom** [1]: 采用经典的共享-特定框架，共享底层参数，并为每个场景和推荐任务设计场景特定与任务特定的参数塔。

- **MMoE** [16]: 设计共享的多门控专家混合（Mixture-of-Experts, MoE）结构，以建模任务与场景关系，并从多个场景和任务中捕获共性表示。

- **STAR** [23]: 为所有域共享一个中心网络，并为每个场景和任务生成域特定网络。

- **HMoe** [13]: 提出隐式与显式专家混合相结合的方法，分别从特征空间隐式地、从标签空间显式地学习场景与任务关系。

- **PEPNet** [3]: 提出参数与嵌入个性化网络，用于学习多个场景与多个任务之间的异构关系。

其中，除 RankMixer 外，其余方法均专为多场景、多任务推荐模型设计。因此，在实际实现中，我们将这些方法集成到 RankMixer 主干中，并确保各模型的总参数量一致，以便进行性能比较。

Table 1: 不同方法在生产数据集上的性能比较。最佳性能和次佳性能分别以粗体和下划线标示。“提升”表示所提出方法相对于性能最佳基线的相对提升比例。

方法	单列搜索			双列搜索			内流搜索		
	QAUC _{Click}	QAUC _{Like}	QAUC _{Fav}	QAUC _{Click}	QAUC _{Like}	QAUC _{Fav}	QAUC _{Click}	QAUC _{Like}	QAUC _{Fav}
RankMixer	0.6389	0.6610	0.6624	0.6911	0.6621	0.6787	0.6393	0.6786	0.6621
SharedBottom	0.6391	0.6611	0.6614	0.6929	0.6629	0.6789	0.6395	0.6794	0.6609
MMoE	0.6394	0.6614	0.6623	<u>0.6931</u>	<u>0.6629</u>	0.6788	0.6397	0.6793	0.6629
STAR	0.6389	0.6611	0.6600	<u>0.6930</u>	<u>0.6624</u>	0.6784	0.6393	0.6796	0.6631
HMoE	<u>0.6397</u>	<u>0.6617</u>	0.6623	0.6925	0.6625	<u>0.6790</u>	0.6401	0.6790	<u>0.6634</u>
PEPNet	0.6396	0.6609	<u>0.6628</u>	0.6928	0.6625	0.6787	<u>0.6403</u>	<u>0.6797</u>	0.6627
MDL (本文)	0.6417	0.6632	0.6656	0.6950	0.6671	0.6842	0.6419	0.6820	0.6681
提升	+0.31%	+0.23%	+0.42%	+0.27%	+0.63%	+0.77%	+0.25%	+0.34%	+0.71%

4.1.4 实现细节。所有实验均在数百块 GPU 上、采用混合分布式训练框架完成，其中稀疏部分异步更新，稠密部分同步更新。所有模型均保持一致的优化器超参数。稠密部分采用 RMSProp 优化器，稀疏部分采用 Adagrad 优化器。批大小设为 2048。通过调整不同模型的层数和隐藏层维度，我们将所有模型的总参数量控制在约 0.5B。

4.2 性能比较


我们在所采用的数据集上将提出的方法与上述基线进行比较，结果汇总于表 1。由此可以得到以下观察：

与不包含任何多任务和多场景设计的代表性主干基线 RankMixer 相比，几乎所有多场景、多任务基线 (SharedBottom、MMoE、STAR、HMoE 和 PEPNet) 均取得了更好的性能。这是因为这些方法所设计的共享-特定结构能够更好地捕获不同场景和任务之间的共性与特性。进一步将所提出的 MDL 与所有基线比较，可以清楚地看到，MDL 在各场景和任务上均持续以较大优势优于基线。这是因为所提出的方法利用 Token 化，使场景、任务与特征信息之间能够进行更全面的交互。

此外，所提出的 MDL 在数据更稀疏的场景以及正样本率更低的任务上表现出更优的性能。与单列搜索上的提升相比，所提出方法在数据更稀疏的双列搜索和内流搜索场景中取得了更好的结果。同时，与点击任务相比，所提出方法在正样本率更低的点赞和收藏任务上获得了更显著的提升。我们认为，Token 化的信息表示和 Token 级交互能够进一步缓解多分布学习中的跷跷板效应。在训练过程中，该方法使模型能够更好地维持对相对弱势场景和任务的分布建模能力。

Table 2: 所提出方法在三个场景上的消融实验 (Δ QAUC_{Click})。

变体	单列	双列	内流
任务 Token 消融			
w/o 任务 Token	-0.12%	-0.11%	-0.09%
w/o 任务-特征交互	-0.04%	-0.05%	0.03%
场景 Token 消融			
w/o 场景 Token	-0.17%	-0.16%	-0.15%
w/o 全局场景 Token	-0.04%	-0.06%	-0.05%
w/o 场景-特征交互	-0.05%	-0.04%	-0.05%



(a) QAUC 随模型参数数量的缩放关系。 (b) QAUC 随模型 FLOPs 的缩放关系。

Figure 2: 不同模型在单列搜索场景中的点击 QAUC 增益与模型参数量/FLOPs 之间的缩放定律。

4.3 消融实验

本部分进一步分析所提出的各项技术或组件如何影响最终性能。我们构造了所提出方法 MDL 的五种变体进行比较，包括：

- w/o 任务 Token: 从输入中移除所有任务 Token，并采用任务塔进行多任务学习。
- w/o 任务-特征交互: 使用 RankMixer 中的交互替代任务 Token 上的域感知注意力。
- w/o 场景 Token: 从输入中移除所有场景 Token，并采用场景塔进行多场景学习。
- w/o 全局场景 Token: 从输入中移除全局场景 Token。
- w/o 场景-特征交互: 使用 RankMixer 中的交互替代场景 Token 上的域感知注意力。

MDL 各变体的实验结果见表 2。可以观察到，移除任一组件都会导致性能下降。w/o 任务 Token 和 w/o 场景 Token 变体说明了对场景信息与任务信息进行 Token 化的重要性。w/o 全局场景 Token 变体表明了全局 Token 的重要性。w/o 任务-特征交互和 w/o 场景-特征交互变体则验证了这些 Token 之间精心设计的交互机制的有效性。

4.4 进一步分析

本节对所提出的 MDL 进一步开展一系列详细分析，以验证其有效性。

4.4.1 缩放定律下的性能比较 (w.r.t.) 本部分考察所提出方法 w.r.t. 模型参数量和模型 FLOPs 的性能表现。为此，我们调整模型的隐藏表示维度 d 和层数 L ，以控制模型的参数量与 FLOPs。随后，我们在这些设置下比较 MDL 与代表性基线 MMoE 的性能，并将结果报告于图 2。由此可以发现，MDL 的性能始终优于 MMoE。同时，随着模型参数量和 FLOPs 增加，MDL 带来的性能增益也随之提高。与以往的多场景、多任务推荐方法相




Figure 3: 不同层中任务 Token 与特征 Token 之间的注意力分布。横轴表示特征 Token 的索引，纵轴表示对应特征 Token 获得的平均注意力权重。




Figure 4: 场景 Token 与特征 Token 之间的注意力分布。横轴表示特征 Token 的索引，纵轴表示对应特征 Token 获得的平均注意力权重。

Table 3: 抖音搜索线上 A/B 测试结果（相对提升）。

场景	查询改写率	LT30
ALL	-0.3267%	+0.0626%
单列搜索	-0.2678%	+0.0520%
双列搜索	-0.5079%	+0.0674%
内流搜索	-0.5492%	+0.0630%

比，所提出方法通过逐层的 Token 级交互，能够更好地利用模型参数进行多分布学习，从而充分获得缩放定律带来的收益。

4.4.2 注意力分数可视化。 所提出方法 MDL 的一个关键组成部分，是特征 Token 与场景/任务 Token 之间的交互。通过域感知注意力，任务 Token 和场景 Token 能够依据各自的数据特性，自适应且有选择地聚合来自特征 Token 的丰富信息，从而实现多场景、多任务学习中的差异化建模。为更好地验证并理解域感知注意力带来的收益，我们在图 3 和图 4 中可视化了不同任务 Token 与场景 Token 所学习到的注意力分布。

从图 3 可以观察到，在同一层内，不同任务 Token 与特征 Token 之间的注意力分布并不相同。这表明不同任务 Token 针对各自的分布学习到了不同的信息，从而对任务间差异进行建模。此外，对于同一任务 Token 与特征 Token 之间的注意力分布，其不同层中也有所变化。这说明随着信息交互逐层推进，任务 Token 能够动态捕获这些变化，并自适应地聚合相应信息。类似地，从图 4 可以观察到，不同场景 Token 与特征 Token 之间的注意力分布也存在差异。

4.5 线上实验

为进一步验证所提出方法 MDL 的有效性，我们在抖音搜索上开展了为期一个月的线上 A/B 测试。线上基线模型以 RankMixer [41] 为基础，并通过 MMoE [16] 实现多场景、多任务学习。核心线上指标包括查询改写率和 LT30，详见第 4.1.2 节。表 3 报告了不同场景下的相对提升以及整体性能。所提出方法使 LT30 提升 +0.0626%，并使查询改写率下降 -0.3267%。在各个场景中，该方法在核心指标上也均取得了显著提升。

5 相关工作

本节从两个方面回顾相关工作，即大规模推荐方法和多场景多任务推荐方法。

大规模推荐。 受大语言模型 (LLM) 缩放定律成功经验 [8, 10] 的启发，推荐模型的缩放定律近年来得到广泛研究，并已在真实工业推荐系统中取得显著成功 [6, 9, 30, 33, 34, 38, 41]。这类方法通常堆叠不同的高效特征交互结构，以增大模型参数规模和计算复杂度，进而提升推荐性能。其中一类方法着重扩展非序列特征交互模块的参数数量与复杂度，以获得更佳性能。例如，Wukong [34] 通过引入基于堆叠因子分解机的架构来扩展特征交互模块。RankMixer [41] 引入多头词元混合和逐词元前馈网络，在保持推理时延的同时扩展推荐模型并取得卓越性能。FAT [30] 引入域感知 Transformer，并在注意力中融入基于特征域的交互先验，以此扩展推荐模型。另一类典型方法采用基于 Transformer 的结构，以统一方式建模非序列特征和序列特征，并持续扩展模型规模。例如，HSTU [33] 将异构特征空间序列化，随后在上下文信号和候选信号的条件下执行序列转换。MTGR [6] 进一步基于 HSTU 扩展推荐模型，以实现加速并避免信息泄漏。OneTrans [38] 引入统一的 Transformer 主干，通过统一词元化器同时建模用户行为序列与特征交互，从而实现高效的参数扩展和卓越性能。与上述方法相比，我们进一步探索大规模推荐模型如何在多场景、多任务设置下取得更佳表现。

多场景与多任务推荐。 在真实工业推荐系统中，一个推荐模型通常需要服务于多个场景和任务。推荐系统中的多场景学习 (MSL) 与多任务学习 (MTL) 已在既往工作中得到广泛研究 [1, 3, 5, 13, 15–17, 23–25, 31, 40]。对于 MTL，现有方法大多采用共享-专属架构，将任务共享组件与任务专属组件组合起来 (e.g., SharedBottom [1]、Cross-stitch [17]、SNR [15])。此外，基于专家混合 (MoE) 的结构也被广泛提出，旨在通过设计不同的专家机制来增强多任务学习的有效性 (e.g., MMoE [16]、PLE [25])。MSL 则旨在使用统一模型学习多个场景的数据，进而提升推荐性能。现有工作大多同样采用共享-专属架构，将场景共享组件与场景专属组件组合起来。MTL 所使用的框架也可应用于 MSL：将不同场景的预测视为彼此独立的预测任务即可 (e.g., SharedBottom [1]、MMoE [16])。此外，研究者还提出了一些专门的多场景方法 [3, 4, 13, 18, 19, 22–24, 32, 35, 36, 40]。例如，HMoE [13] 提出融合隐式与显式 MoE 的结构，用以学习场景和任务之间的关系。STAR [23] 引入星型拓扑结构，其中所有场景共享一个中心网络，并为每个场景生成相应的场景专属网络。PEPNet [3] 利用场景相关先验信息，通过门控机制调整特征嵌入和隐藏单元。不同于这些基于共享-专属架构的方法，我们从词元化视角提出一种新颖的多分布学习框架，旨在增强大规模推荐模型在多场景、多任务设置下的学习能力和统一建模能力。

6 结论

本文面向大规模工业推荐系统中的多场景学习 (MSL) 与多任务学习 (MTL), 提出了一种新型多分布学习框架 **MDL**。不同于基于共享-专用架构的现有 MSL 与 MTL 推荐方法, MDL 受大语言模型 (LLM) 启发, 利用基于提示的标记化方式, 在不同场景与任务设定下完成模型预测。具体而言, MDL 将特征、场景和任务信息转换为统一的标记化表示, 并精心设计了标记之间的三种关键交互机制。离线评估与在线测试中的大量实验均验证了该方法的有效性。MDL 已在抖音搜索平台全面部署。

References

- [1] Rich Caruana. 1998. Multitask Learning. In *Learning to Learn*. 95–133.
- [2] Zheng Chai, Qin Ren, Xijun Xiao, Huizhi Yang, Bo Han, Sijun Zhang, Di Chen, Hui Lu, Wenlin Zhao, Lele Yu, Xionghang Xie, Shiru Ren, Xiang Sun, Yaocheng Tan, Peng Xu, Yuchao Zheng, and Di Wu. 2025. LONGER: Scaling Up Long Sequence Modeling in Industrial Recommenders. In *Recsys*. ACM, 247–256.
- [3] Jianxin Chang, Chenbin Zhang, Yiqun Hui, Dewei Leng, Yanan Niu, Yang Song, and Kun Gai. 2023. PEPNet: Parameter and Embedding Personalized Network for Infusing with Personalized Prior Information. In *KDD*. ACM, 3795–3804.
- [4] Yuting Chen, Yanshi Wang, Yabo Ni, Anxiang Zeng, and Lanfen Lin. 2020. Scenario-aware and Mutual-based approach for Multi-scenario Recommendation in E-Commerce. In *ICDM workshop*. 127–135.
- [5] Ke Ding, Xin Dong, Yong He, Lei Cheng, Chilin Fu, Zhaoxin Huan, Hai Li, Tan Yan, Liang Zhang, Xiaolu Zhang, and Linjian Mo. 2021. MSSM: A Multiple-level Sparse Sharing Model for Efficient Multi-Task Learning. In *SIGIR*. ACM, 2237–2241.
- [6] Ruidong Han, Bin Yin, Shangyu Chen, He Jiang, Fei Jiang, Xiang Li, Chi Ma, Mincong Huang, Xiaoguang Li, Chunzhen Jing, Yueming Han, Menglei Zhou, Lei Yu, Chuan Liu, and Wei Lin. 2025. MTGR: Industrial-Scale Generative Recommendation Framework in Meituan. In *CIKM*. 5731–5738.
- [7] Xintian Han, Honggang Chen, Quan Lin, Jingyue Gao, Xiangyuan Ren, Lifei Zhu, Zhisheng Ye, Shikang Wu, Xionghang Xie, Xiaochu Gan, Bingzheng Wei, Peng Xu, Zhe Wang, Yuchao Zheng, Jingjian Lin, Di Wu, and Junfeng Ge. 2025. LEMUR: Large scale End-to-end Multimodal Recommendation. *CoRR* abs/2511.10962 (2025).
- [8] Jordan Hoffmann, Sebastian Borgeaud, Arthur Mensch, Elena Buchatskaya, Trevor Cai, Eliza Rutherford, Diego de Las Casas, Lisa Anne Hendricks, Johannes Welbl, Aidan Clark, Tom Hennigan, Eric Noland, Katie Millican, George van den Driessche, Bogdan Damoc, Aurelia Guy, Simon Osindero, Karen Simonyan, Erich Elsen, Oriol Vinyals, Jack W. Rae, and Laurent Sifre. 2022. Training compute-optimal large language models. In *NeurIPS*. Article 2176, 15 pages.
- [9] Yunwen Huang, Shiyong Hong, Xijun Xiao, Jinjia Jin, Xuanyuan Luo, Zhe Wang, Zheng Chai, Shikang Wu, Yuchao Zheng, and Jingjian Lin. 2026. HyFormer: Revisiting the Roles of Sequence Modeling and Feature Interaction in CTR Prediction.
- [10] Jared Kaplan, Sam McCandlish, Tom Henighan, Tom B. Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu, and Dario Amodei. 2020. Scaling Laws for Neural Language Models. *CoRR* abs/2001.08361 (2020).
- [11] Danwei Li, Zhengyu Zhang, Siyang Yuan, Mingze Gao, Weilin Zhang, Chaofei Yang, Xi Liu, and Jiyan Yang. 2023. AdaTT: Adaptive Task-to-Task Fusion Network for Multitask Learning in Recommendations. In *KDD*. ACM, 4370–4379.
- [12] Jinyun Li, Huiwen Zheng, Yuanlin Liu, Minfang Lu, Lixia Wu, and Haoyuan Hu. 2023. ADL: Adaptive Distribution Learning Framework for Multi-Scenario CTR Prediction. In *SIGIR*. ACM, 1786–1790.
- [13] Pengcheng Li, Runze Li, Qing Da, Anxiang Zeng, and Lijun Zhang. 2020. Improving Multi-Scenario Learning to Rank in E-commerce by Exploiting Task Relationships in the Label Space. In *CIKM*. 2605–2612.
- [14] Xiaopeng Li, Jingtong Gao, Pengyue Jia, Xiangyu Zhao, Yichao Wang, Wanyu Wang, Yejing Wang, Yuhao Wang, Huifeng Guo, and Ruiming Tang. 2025. Scenario-Wise Rec: A Multi-Scenario Recommendation Benchmark. In *CIKM*. ACM, 1685–1695.
- [15] Jiaqi Ma, Zhe Zhao, Jilin Chen, Ang Li, Lichan Hong, and Ed H. Chi. 2019. SNR: Sub-Network Routing for Flexible Parameter Sharing in Multi-Task Learning. *AAAI*, 216–223.
- [16] Jiaqi Ma, Zhe Zhao, Xinyang Yi, Jilin Chen, Lichan Hong, and Ed H. Chi. 2018. Modeling Task Relationships in Multi-task Learning with Multi-gate Mixture-of-Experts. In *KDD*. 1930–1939.
- [17] Ishan Misra, Abhinav Shrivastava, Abhinav Gupta, and Martial Hebert. 2016. Cross-Stitch Networks for Multi-task Learning. In *CVPR*. 3994–4003.
- [18] Shanlei Mu, Penghui Wei, Wayne Xin Zhao, Shaoqun Liu, Liang Wang, and Bo Zheng. 2023. Hybrid Contrastive Constraints for Multi-Scenario Ad Ranking. In *CIKM*. ACM, 1857–1866.
- [19] Xichuan Niu, Bofang Li, Chenliang Li, Jun Tan, Rong Xiao, and Hongbo Deng. 2021. Heterogeneous Graph Augmented Multi-Scenario Sharing Recommendation with Tree-Guided Expert Networks. In *WSDM*. 1038–1046.
- [20] OpenAI. 2023. GPT-4 Technical Report. *CoRR* abs/2303.08774 (2023).
- [21] Qi Pi, Guorui Zhou, Yujing Zhang, Zhe Wang, Lejian Ren, Ying Fan, Xiaoqiang Zhu, and Kun Gai. 2020. Search-based User Interest Modeling with Lifelong Sequential Behavior Data for Click-Through Rate Prediction. In *CIKM*. ACM, 2685–2692.
- [22] Qijie Shen, Wanjie Tao, Jing Zhang, Hong Wen, Zulong Chen, and Quan Lu. 2021. SAR-Net: A Scenario-Aware Ranking Network for Personalized Fair Recommendation in Hundreds of Travel Scenarios. In *CIKM*. 4094–4103.
- [23] Xiang-Rong Sheng, Liqin Zhao, Guorui Zhou, Xinyao Ding, Binding Dai, Qiang Luo, Siran Yang, Jingshan Lv, Chi Zhang, Hongbo Deng, and Xiaoqiang Zhu. 2021. One Model to Serve All: Star Topology Adaptive Recommender for Multi-Domain CTR Prediction. In *CIKM*. 4104–4113.
- [24] Derun Song, Enneng Yang, Guibing Guo, Li Shen, Linying Jiang, and Xingwei Wang. 2024. Multi-Scenario and Multi-Task Aware Feature Interaction for Recommendation System. *ACM Trans. Knowl. Discov. Data* 18, 6, Article 142 (2024), 20 pages.
- [25] Hongyan Tang, Junning Liu, Ming Zhao, and Xudong Gong. 2020. Progressive Layered Extraction (PLE): A Novel Multi-Task Learning (MTL) Model for Personalized Recommendations. In *RecSys*. 269–278.
- [26] Qwen Team. 2025. Qwen3 Technical Report. *CoRR* abs/2505.09388 (2025).
- [27] Ilya O. Tolstikhin, Neil Houlsby, Alexander Kolesnikov, Lucas Beyer, Xiaohua Zhai, Thomas Unterthiner, Jessica Yung, Andreas Steiner, Daniel Keysers, Jakob Uszkoreit, Mario Lucic, and Alexey Dosovitskiy. 2021. MLP-Mixer: An all-MLP Architecture for Vision. In *NeurIPS*. 24261–24272.
- [28] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is All you Need. In *NeurIPS*. 5998–6008.
- [29] Yuhao Wang, Ha Tsz Lam, Yi Wong, Ziru Liu, Xiangyu Zhao, Yichao Wang, Bo Chen, Huifeng Guo, and Ruiming Tang. 2023. Multi-Task Deep Recommender Systems: A Survey. *CoRR* abs/2302.03525 (2023).
- [30] Bencheng Yan, Yuejie Lei, Zhiyuan Zeng, Di Wang, Kaiyi Lin, Pengjie Wang, Jian Xu, and Bo Zheng. 2025. From Scaling to Structured Expressivity: Rethinking Transformers for CTR Prediction. *CoRR* abs/2511.12081 (2025).
- [31] Ruirui Yan, Rui Fan, and Defu Lian. 2024. Multi-Task Recommendation with Task Information Decoupling. In *CIKM*. ACM, 2786–2795.
- [32] Xuanhua Yang, Xiaoyu Peng, Penghui Wei, Shaoqun Liu, Liang Wang, and Bo Zheng. 2022. AdaSparse: Learning Adaptively Sparse Structures for Multi-Domain Click-Through Rate Prediction. In *CIKM*. 4635–4639.
- [33] Jiaqi Zhai, Lucy Liao, Xing Liu, Yueming Wang, Rui Li, Xuan Cao, Leon Gao, Zhaojie Gong, Fangda Gu, Jiayuan He, Yinghai Lu, and Yu Shi. 2024. Actions Speak Louder than Words: Trillion-Parameter Sequential Transducers for Generative Recommendations. In *ICML*.
- [34] Buyun Zhang, Liang Luo, Yuxin Chen, Jade Nie, Xi Liu, Shen Li, Yanli Zhao, Yuchen Hao, Yantao Yao, Ellie Dingqiao Wen, Jongsso Park, Maxim Naumov, and Wenlin Chen. 2024. Wukong: Towards a Scaling Law for Large-Scale Recommendation. In *ICML*.
- [35] Qianqian Zhang, Xinru Liao, Quan Liu, Jian Xu, and Bo Zheng. 2022. Leaving No One Behind: A Multi-Scenario Multi-Task Meta Learning Approach for Advertiser Modeling. In *WSDM*. 1368–1376.
- [36] Yuanliang Zhang, Xiaofeng Wang, Jinxin Hu, Ke Gao, Chenyi Lei, and Fei Fang. 2022. Scenario-Adaptive and Self-Supervised Model for Multi-Scenario Personalized Recommendation. In *CIKM*. 3674–3683.
- [37] Zijian Zhang, Shuchang Liu, Jiao Yu, Qingpeng Cai, Xiangyu Zhao, Chunxu Zhang, Ziru Liu, Qidong Liu, Hongwei Zhao, Lantao Hu, Peng Jiang, and Kun Gai. 2024. M³oE: Multi-Domain Multi-Task Mixture-of Experts Recommendation Framework. In *SIGIR*. ACM, 893–902.
- [38] Zhaoqi Zhang, Haolei Pei, Jun Guo, Tianyu Wang, Yufei Feng, Hui Sun, Shaowei Liu, and Aixin Sun. 2025. OneTrans: Unified Feature Interaction and Sequence Modeling with One Transformer in Industrial Recommender. *CoRR* abs/2510.26104 (2025).
- [39] Guorui Zhou, Xiaoqiang Zhu, Chengru Song, Ying Fan, Han Zhu, Xiao Ma, Yanghui Yan, Junqi Jin, Han Li, and Kun Gai. 2018. Deep Interest Network for Click-Through Rate Prediction. In *SIGKDD*. ACM, 1059–1068.
- [40] Jie Zhou, Xianshuai Cao, Wenhao Li, Lin Bo, Kun Zhang, Chuan Luo, and Qian Yu. 2023. HiNet: Novel Multi-Scenario & Multi-Task Learning with Hierarchical Information Extraction. In *ICDE*. 2969–2975.
- [41] Jie Zhu, Zhifang Fan, Xiaoxie Zhu, Yuchen Jiang, Hangyu Wang, Xintian Han, Haoran Ding, Xinmin Wang, Wenlin Zhao, Zhen Gong, Huizhi Yang, Zheng Chai, Zhe Chen, Yuchao Zheng, Qiwei Chen, Feng Zhang, Xun Zhou, Peng Xu, Xiao Yang, Di Wu, and Zuotao Liu. 2025. RankMixer: Scaling Up Ranking Models in Industrial Recommenders. In *CIKM*. 6309–6316.