

OneRec: 以生成式推荐器与迭代偏好对齐 统一召回和排序

Jiaxin Deng*

KuaiShou Inc.

中国北京

dengjiaxin03@kuaishou.com

Shiyao Wang*

KuaiShou Inc.

中国北京

wangshiyao08@kuaishou.com

Kuo Cai*

KuaiShou Inc.

中国北京

caikuo@kuaishou.com

Lejian Ren*

KuaiShou Inc.

中国北京

renlejian@kuaishou.com

Qigen Hu*

KuaiShou Inc.

中国北京

huqigen03@kuaishou.com

Weifeng Ding*

KuaiShou Inc.

中国北京

dingweifeng@kuaishou.com

Qiang Luo*

KuaiShou Inc.

中国北京

luoqiang@kuaishou.com

Guorui Zhou*[†]

KuaiShou Inc.

中国北京

zhouguorui@kuaishou.com

摘要

近年来, 基于生成式检索的推荐系统 (GR) 作为一种颇具前景的范式逐渐兴起, 其以自回归方式直接生成候选视频。然而, 大多数现代推荐系统采用“检索—排序”策略, 其中生成模型仅在检索阶段充当筛选器。本

文提出 **OneRec**, 以统一的生成模型取代级联式学习框架。据我们所知, 这是首个在真实场景中显著超越当前复杂且精心设计的推荐系统的端到端生成模型。具体而言, OneRec 包括: 1) **编码器—解码器结构**, 该结构对用户历史行为序列进行编码, 并逐步解码用户可能感兴趣的视频。我们采用稀疏专家混合 (MoE), 在不按比例增加计算 FLOPs 的情况下扩展模型容量。2) **按会话生成的方法**。与传统的下一物品预测不同, 我们提出按会话生成; 相比依赖人工规则来恰当组合生成结果的逐点生成方式, 该方法更为简洁优雅, 且上下文更加连贯。3) **迭代偏好对齐模块**, 结合直接偏好优化 (DPO) 来提升生成结果的质量。不同于 NLP 中的 DPO, 推荐系统通常针对每次用户浏览请求只有一次结果展示机会, 因此无法同时获得正负样本。为解决这一限制, 我们设计了一个奖励模型来模拟用户生成, 并根据推荐系统在线学习的特点定制采样策略。大量实验表明, 数量有限的 DPO 样本即可对齐用户兴趣偏好, 并显著提升生成结果的质量。我们将

*同等贡献。

[†]通讯作者。

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.

会议简称 'XX, 纽约州伍德斯托克

© 2018 Copyright held by the owner/author(s). Publication rights licensed to ACM.

ACM ISBN 978-1-4503-XXXX-X/2018/06

<https://doi.org/XXXXXXXX.XXXXXXX>

OneRec 部署于短视频推荐平台快手的主场景; 该平台日活跃用户达数亿, 部署后观看时长提升了 1.6%, 这是一个显著的改进。

CCS Concepts

• 信息系统 → 计算广告; 多媒体信息系统.

Keywords

生成式推荐, 自回归生成, 语义分词, 直接偏好优化

ACM Reference Format:

Jiaxin Deng, Shiyao Wang, Kuo Cai, Lejian Ren, Qigen Hu, Weifeng Ding, Qiang Luo, and Guorui Zhou. 2018. OneRec: 以生成式推荐器与迭代偏好对齐统一召回和排序. In *Proceedings of* 请务必填写版权确认邮件中的正确会议名称 (会议简称'XX'). ACM, New York, NY, USA, 13 pages. <https://doi.org/XXXXXXX.XXXXXXX>

1 引言

为了平衡效率与效果, 大多数现代推荐系统采用级联排序策略 [6, 26, 34, 43]。如图 1(b) 所示, 典型的级联排序系统采用三阶段流水线: 召回 [6, 19, 54]、粗排 [28, 46] 和精排 [2, 3, 15, 16, 33, 52, 53]。每个阶段负责从接收到的物品中选出排名前 k 的物品, 并将结果传递给下一阶段, 从整体上权衡系统响应时间与排序准确性。




图 1: (a) 我们提出的端到端生成统一架构。(b) 典型的级联排序系统, 自下而上包括召回、预排序和排序三个阶段。

尽管现有方法在实践中效率较高, 但它们通常将各个排序器彼此独立地处理, 其中每个孤立阶段的效果构成后续排序阶段的性能上限, 从而限制了整个排序系统的性能。尽管已有多种工作 [11, 13, 18, 20, 34,

44] 试图通过促进排序器之间的交互来提升整体推荐性能, 但它们仍沿用传统的级联排序范式。近年来, 基于生成式召回的推荐系统 (GRs) [36, 45, 51] 已成为一种颇具前景的范式, 其以自回归序列生成的方式直接生成候选物品的标识符。通过使用编码物品语义的量化语义 ID 为物品建立索引 [24], 推荐器能够利用物品中丰富的语义信息。GRs 的生成特性使其适合通过束搜索解码直接选择候选物品, 并生成更具多样性的推荐结果。然而, 当前的生成模型仅在召回阶段充当选择器, 因为其推荐准确率尚未达到精心设计的多级级联排序器的水平。

为应对上述挑战, 我们提出了一个名为 **OneRec** 的统一端到端单阶段生成式推荐框架。首先, 我们提出了一种编码器—解码器架构。受大语言模型训练中观察到的缩放定律启发, 我们发现, 扩大推荐模型的容量同样能够持续提升性能。因此, 我们基于 MoE 结构 [7, 9, 55] 扩大模型参数规模, 显著增强了模型刻画用户兴趣的能力。其次, 不同于传统的逐点下一物品预测, 我们提出了一种会话级列表生成方法, 该方法考虑每个会话内物品之间的相对内容与顺序。逐点生成方法需要采用人工设计的策略来确保生成结果的连贯性和多样性。相比之下, 会话级学习过程通过输入偏好数据, 使模型能够自主学习最优的会话结构。最后但同样重要的是, 我们探索了使用直接偏好优化 (DPO) [35] 进行偏好学习, 以进一步提升生成结果的质量。在构造偏好对时, 我们借鉴困难负样本采样 [37], 从束搜索结果中构造自困难拒绝样本, 而不是进行随机采样。我们提出迭代偏好对齐 (IPA) 策略, 根据预训练奖励模型 (RM) 给出的分数对采样响应进行排序, 从中确定最优的选中样本和最差的拒绝样本。我们在大规模工业数据集上的实验表明了所提方法的优越性。我们还开展了一系列消融实验, 详细验证各模块的有效性。本文的主要贡献概括如下:

- 为克服级联排序的局限性, 我们提出了 OneRec, 一种单阶段生成式推荐框架。据我们所知, 这是首批能够利用统一生成模型处理物品推荐的工业级解决方案之一, 其性能显著超越传统的多阶段排序流水线。

- 我们通过会话级生成方式强调了模型容量和目标物品上下文信息的必要性, 从而实现更准确的预测, 并提升生成物品的多样性。
- 我们提出了一种基于个性化奖励模型的新颖自困难负样本选择策略。借助直接偏好优化, 我们增强了 OneRec 在更广泛用户偏好上的泛化能力。大量离线实验和在线 A/B 测试验证了其有效性与效率。

2 相关工作

2.1 生成式推荐

近年来, 随着生成模型取得显著进展, 生成式推荐受到越来越多的关注。传统的基于嵌入的检索方法在很大程度上依赖双塔模型计算每个候选物品的排序分数, 并利用高效的 MIPS 或 ANN [14, 17, 21, 31, 38] 搜索系统检索排名前 k 的相关物品; 与之不同, 生成式检索 (GR) [41] 方法将从数据库中检索相关文档的问题表述为序列生成任务, 依次生成相关文档的 token。文档 token 可以是文档标题、文档 ID 或预训练语义 ID [42]。GENRE [8] 首次将 transformer 架构用于实体检索, 基于条件上下文以自回归方式生成实体名称。DSI [42] 首次提出为文档分配结构化语义 ID, 并训练编码器—解码器模型进行生成式文档检索。沿循这一范式, TIGER [36] 提出了面向推荐系统的生成式物品检索模型形式。

除生成框架外, 如何对物品进行索引也受到越来越多的关注。近期研究聚焦于语义索引技术 [12, 36, 42], 旨在依据内容信息对物品进行索引。具体而言, TIGER [36] 和 LC-Rec [51] 对由物品标题和描述得到的文本嵌入应用残差量化 (RQ-VAE), 以进行 token 化。Recforest [12] 对物品文本嵌入采用层次化 k-means 聚类, 从而获得作为 token 的聚类索引。此外, EAGER [45] 等近期研究探索了在 token 化过程中同时融入语义信息与协同信息。

2.2 语言模型的偏好对齐

在大语言模型 (LLM) 的后训练 [10] 阶段, 基于人类反馈的强化学习 (RLHF) [32, 39] 是使 LLM 与人类价值

观对齐的常用方法; 它采用强化学习技术, 并由表征人类反馈的奖励模型进行指导。然而, RLHF 存在不稳定和低效率问题。直接偏好优化 (DPO) [35] 由此被提出, 它以闭式形式推导最优策略, 并支持直接使用偏好数据进行优化。除此之外, 研究者还提出了多种变体, 以进一步改进原始 DPO。例如, IPO [1] 通过一个通用目标绕过 DPO 中的两个近似。cDPO [35] 通过引入超参数 ϵ 缓解噪声标签的影响。rDPO [5] 设计了原始二元交叉熵损失的无偏估计。包括 CPO [47]、simDPO [5] 在内的其他变体也从不同方面增强或扩展了 DPO。然而, 与偏好数据由人工明确标注的传统 NLP 场景不同, 由于用户—物品交互数据稀疏, 推荐系统中的偏好学习面临独特挑战。因此, 如何将 DPO 适配于推荐仍在很大程度上未得到探索。不同于专注于在基于 LM 的推荐器用户偏好数据中引入多个负样本的 S-DPO, 我们训练一个奖励模型, 并依据奖励模型给出的分数为不同用户选择个性化偏好数据。

3 方法

本节提出 OneRec, 这是一种通过单阶段检索方式生成目标物品的端到端框架。在第 3.1 节中, 我们首先介绍工业应用中单阶段生成式推荐流水线的特征工程。随后, 在第 3.2 节中, 我们正式定义按会话生成任务, 并给出所提出 OneRec 模型的架构。最后, 我们在第 3.3 节中详细阐述模型如何借助个性化奖励模型进行自难负样本采样, 并说明如何通过直接偏好优化迭代提升模型性能。OneRec 的整体框架如图 2 所示。

3.1 预备知识

本节从特征工程的角度介绍单阶段生成式推荐流水线的构建。对于用户侧特征, OneRec 将正向历史行为序列 $\mathcal{H}_u = \{v_1^h, v_2^h, \dots, v_n^h\}$ 作为输入, 其中 v 表示用户有效观看或交互 (点赞、关注、分享) 过的视频, n 为行为序列长度。OneRec 的输出是由一个会话 $\mathcal{S} = \{v_1, v_2, \dots, v_m\}$ 构成的视频列表, 其中 m 是会话内的视频数量 (“会话” 的详细定义见第 3.2 节)。

对于每个视频 v_i , 我们使用与真实用户—物品行为分布对齐的多模态嵌入 $e_i \in \mathbb{R}^d$ 对其进行描述 [27]。基于预训练多模态表示, 现有生成式推荐框架 [25, 36]




图 2: OneRec 的整体框架由两个阶段组成: (i) 会话训练阶段, 使用按会话组织的数据训练 OneRec; (ii) IPA 阶段, 利用结合自难负样本的迭代式直接偏好优化。

使用 RQ-VAE [49] 将嵌入编码为语义 token。然而, 这种方法由于编码分布不平衡而并非最优, 这一问题被称为 沙漏现象 [23]。我们采用多层级平衡量化机制, 使用残差 K-Means 量化算法对 e_i 进行转换 [27]。在第一层级 ($l = 1$), 初始残差定义为 $r_i^1 = e_i$ 。在每个层级 l , 我们都有一个码本 $\mathcal{C}_l = \{c_1^l, \dots, c_K^l\}$, 其中 K 为码本大小。最近质心节点嵌入的索引通过 $s_i^l = \arg \min_k \|r_i^l - c_k^l\|_2$ 生成, 而下一层级 $l+1$ 的残差定义为 $r_i^{l+1} = r_i^l - c_{s_i^l}^l$ 。因此, 相应的码本 token 通过层次化索引生成:

$$\begin{aligned}
 s_i^1 &= \arg \min_k \|r_i^1 - c_k^1\|_2, & r_i^2 &= r_i^1 - c_{s_i^1}^1 \\
 s_i^2 &= \arg \min_k \|r_i^2 - c_k^2\|_2, & r_i^3 &= r_i^2 - c_{s_i^2}^2 \\
 &\vdots & & \\
 s_i^L &= \arg \min_k \|r_i^L - c_k^L\|_2
 \end{aligned}$$

其中, L 为语义 ID 的总层数。

为构建平衡码本 $\mathcal{C}_l = \{c_1^l, \dots, c_K^l\}$, 我们采用 算法 1 中详述的 Balanced K-means 对物品集合进行划分。给定完整视频集合 $\mathcal{V}$, 该算法将其划分为 K 个簇, 每个簇恰好包含 $w = |\mathcal{V}|/K$ 个视频。在迭代计算期间, 依据欧氏距离, 依次为每个质心分配距其最近的 w 个尚未分配的视频, 随后使用已分配视频的均值向量重新校准质心。当簇分配达到收敛时, 满足终止条件。

3.2 会话级列表生成

不同于仅预测下一个视频的传统逐点推荐方法, 会话级生成旨在根据用户的历史交互序列生成高价值会话列表, 使推荐模型能够捕捉推荐列表中视频之间的依赖关系。具体而言, 一个会话是指为响应用户的一次请求而返回的一批短视频, 通常由 5 至 10 个视频组成。会话内的视频通常会综合考虑用户兴趣、连贯性

Algorithm 1: Balanced K-means 聚类**Input:** 物品集合 $\mathcal{V}$, 簇数量 K

```

1 Compute  $w \leftarrow |\mathcal{V}|/K$ 
2 通过随机选择初始化质心  $\mathcal{C}_l = \{c_1^l, \dots, c_K^l\}$ ;
3 repeat
4   初始化未分配集合  $\mathcal{U} \leftarrow \mathcal{V}$ 
5   for 每个簇  $k \in \{1, \dots, K\}$  do
6     对  $\mathcal{U}$  按照与质心  $c_k^l$  距离的升序排序;
7     Assign  $\mathcal{V}_k \leftarrow \mathcal{U}[0 : w - 1]$ ;
8     Update centroid  $c_k^l \leftarrow \frac{1}{w} \sum_{r^l \in \mathcal{V}_k} r^l$ ;
9     移除已分配项  $\mathcal{U} \leftarrow \mathcal{U} \setminus \mathcal{V}_k$ ;
10  end
11 until 分配收敛;
Output: 优化后的码本  $\mathcal{C}_l = \{c_1^l, \dots, c_K^l\}$ 

```

和多样性等因素。我们设计了若干标准来识别高质量会话，包括：

- 用户在一个会话中实际观看的短视频数量大于或等于 5；
- 用户观看该会话的总时长超过某一阈值；
- 用户表现出点赞、收藏或分享视频等交互行为；

该方法确保我们的会话级模型能够从真实的用户参与模式中学习，并捕获会话列表中更准确的上下文信息。因此，我们的会话级模型 $\mathcal{M}$ 的目标可形式化为：

$$\mathcal{S} := \mathcal{M}(\mathcal{H}_u) \quad (1)$$

其中， $\mathcal{H}_u$ 由语义 ID 表示： $\mathcal{H}_u = \{(s_1^1, s_1^2, \dots, s_1^L), (s_2^1, s_2^2, \dots, s_2^L), \dots, (s_n^1, s_n^2, \dots, s_n^L)\}$ 和 $\mathcal{S} = \{(s_1^1, s_1^2, \dots, s_1^L), (s_2^1, s_2^2, \dots, s_2^L), \dots, (s_m^1, s_m^2, \dots, s_m^L)\}$ 。

如图 2 (a) 所示，与 T5 [48] 架构一致，我们的模型采用基于 Transformer 的框架，该框架由两个主要组件组成：用于建模用户历史交互的编码器，以及用于生成会话列表的解码器。具体而言，编码器利用堆叠的多头自注意力层和前馈层处理输入序列 $\mathcal{H}_u$ 。我们将编码后的历史交互特征记为 $\mathbf{H} = \text{Encoder}(\mathcal{H}_u)$ 。

解码器以目标会话的语义 ID 作为输入，并以自回归方式生成目标。为以合理的经济成本训练更大的

模型，对于解码器中的前馈神经网络 (FFN)，我们采用基于 Transformer 的语言模型中常用的 MoE 架构 [7, 9, 55]，并将第 l 个 FFN 替换为：

$$\begin{aligned} \mathbf{H}_t^{l+1} &= \sum_{i=1}^{N_{\text{MoE}}} (g_{i,t} \text{FFN}_i(\mathbf{H}_t^l)) + \mathbf{H}_t^l, \\ g_{i,t} &= \begin{cases} s_{i,t}, & s_{i,t} \in \text{Topk}(\{s_{j,t} | 1 \leq j \leq N\}, K_{\text{MoE}}), \\ 0, & \text{otherwise,} \end{cases} \\ s_{i,t} &= \text{Softmax}_i(\mathbf{H}_t^l \mathbf{e}_i^l), \end{aligned} \quad (2)$$

其中， N_{MoE} 表示专家总数， $\text{FFN}_i(\cdot)$ 是第 i 个专家 FFN， $g_{i,t}$ 表示第 i 个专家的门控值。门控值 $g_{i,t}$ 是稀疏的，即仅有 K_{MoE} 个门控值在总计 N_{MoE} 个门控值中非零。这一稀疏性保证了 MoE 层内的计算效率，并且每个 token 只会被分配给 K_{MoE} 个专家并在其中进行计算。

训练时，我们在编码开头添加起始 token $s_{[\text{BOS}]}$ ，按如下方式构造解码器输入：

$$\begin{aligned} \bar{\mathcal{S}} &= \{s_{[\text{BOS}]}, s_1^1, s_1^2, \dots, s_1^L, s_{[\text{BOS}]}, s_2^1, s_2^2, \dots, s_2^L, \\ &\quad \dots, s_{[\text{BOS}]}, s_m^1, s_m^2, \dots, s_m^L\} \end{aligned} \quad (3)$$

我们采用交叉熵损失，对目标会话的语义 ID 进行下一 token 预测。NTP 损失 $\mathcal{L}_{\text{NTP}}$ 表述为：

$$\mathcal{L}_{\text{NTP}} = - \sum_{i=1}^m \sum_{j=1}^L \log P(s_i^{j+1} | [s_{[\text{BOS}]}, s_1^1, s_1^2, \dots, s_1^L, \dots, s_{[\text{BOS}]}, s_i^1, \dots, s_i^j]; \Theta). \quad (4)$$

在会话级列表生成任务上进行一定量的训练后，我们得到种子模型 $\mathcal{M}_t$ 。

3.3 基于 RM 的迭代偏好对齐

第 3.2 节定义的高质量会话提供了宝贵的训练数据，使模型能够学习何为优质会话，从而保证生成视频的质量。在此基础上，我们旨在通过直接偏好优化(DPO)进一步提升模型能力。在传统自然语言处理(NLP)场景中，偏好数据由人工显式标注。然而，由于用户-物

Algorithm 2: 迭代偏好对齐 (IPA)

Input: 响应数量 N 、预训练 RM $R(\mathbf{u}, \mathcal{S})$ 、种子模型 $\mathcal{M}_t$ 、DPO 比例 r_{DPO} 、总轮数 T 以及每轮样本数 N_{sample}

```

1 for epoch  $\leftarrow t$  to  $T$  do
2   for sample  $\leftarrow 1$  to  $N_{\text{sample}}$  do
3     if  $\text{rand}() < r_{\text{DPO}}$  then
4       生成  $N$  个响应, 方式为  $\mathcal{M}_t$ :
5       for  $i \leftarrow 1$  to  $N$  do
6          $\mathcal{S}_u^i \sim \mathcal{M}_t(\mathcal{H}_u)$ ;
7          $r_u^i \leftarrow R(\mathbf{u}, \mathcal{S}_u^i)$ ;
8       end
9       选择最佳和最差响应:
10       $\mathcal{S}_u^w \leftarrow \mathcal{S}_u^{\arg \max_i r_u^i}$ ;
11       $\mathcal{S}_u^l \leftarrow \mathcal{S}_u^{\arg \min_i r_u^i}$ ;
12      计算 NTP 和 DPO 损失:
13       $\mathcal{L} \leftarrow \mathcal{L}_{\text{NTP}} + \lambda \mathcal{L}_{\text{DPO}}$ ;
14    else
15      计算 NTP 损失:
16       $\mathcal{L} \leftarrow \mathcal{L}_{\text{NTP}}$ ;
17    end
18    Update parameters:
19     $\Theta \leftarrow \Theta - \alpha \nabla_{\Theta} \mathcal{L}$ ;
20  end
21  更新模型快照:  $\mathcal{M}_{t+1} \leftarrow \mathcal{M}_t$ ;
22 end

```

Output: 优化后的参数 Θ

品交互数据具有稀疏性, 推荐系统中的偏好学习面临独特挑战, 因而需要奖励模型 (RM)。因此, 我们在第 3.3.1 节引入会话级奖励模型。此外, 我们提出迭代式直接偏好优化来改进传统 DPO, 使模型能够实现第 3.3.2 节所述的自我提升。

3.3.1 奖励模型训练. 我们用 $R(\mathbf{u}, \mathcal{S})$ 表示为不同用户选择偏好数据的奖励模型。这里, 输出 r 表示用户 u (通常由用户行为表示) 对会话 $\mathcal{S} = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m\}$ 的偏好所对应的奖励。为了使 RM 具备对会话进行排

序的能力, 我们首先提取目标感知表示 $\mathbf{e}_i = \mathbf{v}_i \odot \mathbf{u}$, 其对应于每个物品 $\mathbf{v}_i$, 而这些物品位于 $\mathcal{S}$ 中, 其中 $\odot$ 表示目标感知操作 (例如面向用户行为的目标注意力)。由此, 我们得到目标感知表示 $\mathbf{h} = \{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_m\}$, 对应于会话 $\mathcal{S}$ 。随后, 会话内的物品通过自注意力层相互交互, 以融合不同物品之间的必要信息:

$$\mathbf{h}_f = \text{SelfAttention}(\mathbf{h} \mathbf{W}_s^Q, \mathbf{h} \mathbf{W}_s^K, \mathbf{h} \mathbf{W}_s^V) \quad (5)$$

接下来, 我们使用不同的塔对多目标奖励进行预测, 并利用丰富的推荐数据对 RM 进行预训练:

$$\begin{aligned} \hat{r}^{swt} &= \text{Tower}^{swt}(\text{Sum}(\mathbf{h}_f)), \hat{r}^{vtr} = \text{Tower}^{vtr}(\text{Sum}(\mathbf{h}_f)), \\ \hat{r}^{wtr} &= \text{Tower}^{wtr}(\text{Sum}(\mathbf{h}_f)), \hat{r}^{ltr} = \text{Tower}^{ltr}(\text{Sum}(\mathbf{h}_f)), \end{aligned} \quad (6)$$

where $\text{Tower}(\cdot) = \text{Sigmoid}(\text{MLP}(\cdot))$

在获得每个会话的所有估计奖励 $\hat{r}^{swt}, \dots$ 和真实标签 $y^{swt}, \dots$ 后, 我们直接最小化二元交叉熵损失来训练 RM。损失函数 $\mathcal{L}_{\text{RM}}$ 定义如下:

$$\mathcal{L}_{\text{RM}} = - \sum_{swt, \dots}^{xtr} (y^{xtr} \log(\hat{r}^{xtr}) + (1 - y^{xtr}) \log(1 - \hat{r}^{xtr})) \quad (7)$$

3.3.2 迭代偏好对齐. 基于预训练的 RM $R(\mathbf{u}, \mathcal{S})$ 和当前 OneRec $\mathcal{M}_t$, 我们通过束搜索为每个用户生成 N 个不同的响应:

$$\mathcal{S}_u^n \sim M_t(\mathcal{H}_u) \quad \text{for all } u \in \mathcal{U} \text{ and } n \in [N], \quad (8)$$

其中, 我们使用 $[N]$ 表示 $\{1, 2, \dots, N\}$ 。

随后, 我们计算每个响应的奖励 r_u^n , 计算基于 RM $R(\mathbf{u}, \mathcal{S})$:

$$r_u^n = R(\mathbf{u}, \mathcal{S}_u^n) \quad (9)$$

接下来, 我们构建偏好对 $D_t^{\text{pairs}} = (\mathcal{S}_u^w, \mathcal{S}_u^l, \mathcal{H}_u)$, 具体做法是选择奖励值最高的胜者响应 ($\mathcal{S}_u^w, \mathcal{H}_u$) 和奖励值最低的败者响应 ($\mathcal{S}_u^l, \mathcal{H}_u$)。给定这些偏好对后, 我们即可训练一个新模型 M_{t+1} ; 该模型由模型 M_t 初始化, 并使用包含 DPO 损失 [35] 的损失函数进行更新, 以从偏好对中学习。每个偏好对对应的损失如下:

$$\begin{aligned} \mathcal{L}_{\text{DPO}} &= \mathcal{L}_{\text{DPO}}(\mathcal{S}_u^w, \mathcal{S}_u^l | \mathcal{H}_u) \\ &= -\log \sigma \left(\beta \log \frac{M_{t+1}(\mathcal{S}_u^w | \mathcal{H}_u)}{M_t(\mathcal{S}_u^w | \mathcal{H}_u)} - \beta \log \frac{M_{t+1}(\mathcal{S}_u^l | \mathcal{H}_u)}{M_t(\mathcal{S}_u^l | \mathcal{H}_u)} \right). \end{aligned} \quad (10)$$

如算法 2 和图 2 (b) 所示, 整体流程涉及训练一系列模型 $M_t, \dots, M_T$ 。为减轻束搜索推理期间的计算负担, 我们仅随机采样 $r_{\text{DPO}} = 1\%$ 的数据用于偏好对齐。对于每个后续模型 M_{t+1} , 它由前一个模型 M_t 初始化, 并使用偏好数据 D_t^{pairs} 进行训练, 该数据由 M_t 生成。




图 3: OneRec 在线部署框架。

4 系统部署

OneRec 已成功应用于真实工业场景。综合权衡稳定性与性能后, 我们部署 OneRec-1B 提供在线服务。如图 3 所示, 我们的部署架构由三个核心组件组成: 1) 训练系统, 2) 在线服务系统, 以及 3) DPO 样本服务器。系统将收集到的交互日志作为训练数据, 首先采用下一 token 预测目标 $\mathcal{L}_{\text{NTP}}$ 训练种子模型。模型收敛后, 我们加入 DPO 损失 $\mathcal{L}_{\text{DPO}}$ 进行偏好对齐, 并利用 XLA 和 bfloat16 混合精度训练优化计算效率与内存利用率。训练后的参数会同步到在线推理模块和 DPO 采样服务器, 用于实时服务和基于偏好的数据选择。为提升推理性能, 我们实现了两项关键优化: 一是将键值缓存解码机制与 float16 量化相结合, 以降低 GPU 内存开销; 二是采用束大小为 128 的束搜索配置, 以平衡生成质量与延迟。此外, 得益于 MoE 架构, 推理期间仅激活 13% 的参数。

5 实验

本节首先在离线设置下将 OneRec 与逐点方法及若干 DPO 变体进行比较。随后, 我们对所提出的模块开展消融实验, 以验证 OneRec 的有效性。最后, 我们将 OneRec 部署到线上, 并在 Kuaishou 上进行 A/B 测试, 以进一步验证其性能。

5.1 实验设置

5.1.1 实现细节. 我们的模型使用 Adam 优化器训练, 初始学习率为 2×10^{-4} 。我们使用 NVIDIA A800 GPU 优化 OneRec。整个训练过程中, DPO 样本比例 r_{DPO} 设为 1%, 并通过束搜索为每个用户生成 $N = 128$ 个不同响应; 语义标识符聚类过程为每个码本层使用 $K = 8192$ 个簇, 码本层数设为 $L = 3$; 混合专家架构包含 $N_{\text{MoE}} = 24$ 个专家, 每次前向传播激活 $K_{\text{MoE}} = 2$ 个专家, 并通过 top- k 选择; 对于会话建模, 我们考虑 $m = 5$ 个目标会话物品, 并采用 $n = 256$ 个历史行为作为上下文。

5.1.2 基线方法. 我们采用以下具有代表性的推荐模型、DPO 及其变体作为额外基线进行比较。基线方法包括:

- **SASRec** [22] 采用单向 Transformer 架构, 捕获用户-物品交互中的序列依赖关系, 用于下一物品预测。
- **BERT4Rec** [40] 利用采用掩码语言建模的双向 Transformer, 通过序列重构学习上下文物品表示。
- **FDSA** [50] 实现双重自注意力路径, 在异构推荐场景中联合建模物品级转移和特征级变换模式。
- **TIGER** [36] 利用分层语义标识符和生成式检索技术, 通过自回归序列生成实现序列推荐。
- **DPO** [35] 通过隐式奖励建模, 使用由人类反馈数据导出的闭式奖励函数来形式化偏好优化。
- **IPO** [1] 提出一种具有理论依据的偏好优化框架, 绕过标准 DPO 中固有的近似。
- **cDPO** [30] 引入一种考虑鲁棒性的变体, 其中包含标签翻转率参数 ϵ , 以应对有噪声的偏好标注。
- **rDPO** [5] 使用重要性采样构造无偏损失估计器, 以降低偏好优化中的方差。
- **CPO** [47] 通过联合训练序列似然奖励与监督微调目标, 将对比学习与偏好优化统一起来。
- **simPO** [29] 采用序列级奖励间隔进行偏好优化, 同时通过归一化概率平均消除对参考模型的依赖。
- **S-DPO** [4] 通过困难负样本采样和多物品对比学习使 DPO 适配推荐系统, 从而提升排序准确性。

表 1: 我们提出的 OneRec (绿色) 与 逐点方法 (棕色)、列表级方法 (蓝色) 和偏好对齐方法 (黄色) 的离线性能。最佳结果以粗体表示, 次优结果以下划线表示。带有 ↑ 的指标越高越好, 而带有 ↓ 的指标越低越好。

模型	观看时长指标				交互指标			
	swt↑		vtr↑		wtr↑		ltr↑	
	均值	最大值	均值	最大值	均值	最大值	均值	最大值
逐点判别式方法								
SASRec	0.0375±0.00	0.0803±0.00	0.4313±0.00	0.5801±0.00	0.00294±0.00	<u>0.00978±0.00</u>	0.0314±0.00	0.0604±0.004
BERT4Rec	0.0336±0.00	0.0706±0.00	0.4192±0.00	0.5633±0.00	0.00281±0.00	0.00932±0.00	0.0316±0.00	0.0606±0.004
FDSA	0.0325±0.00	0.0683±0.00	0.4145±0.00	0.5588±0.00	0.00271±0.00	0.00921±0.00	0.0313±0.00	0.0604±0.003
逐点生成式方法								
TIGER-0.1B	0.0879±0.00	0.1286±0.00	0.5826±0.00	0.6625±0.00	0.00277±0.00	0.00671±0.00	0.0316±0.00	0.0541±0.007
TIGER-1B	0.0873±0.00	0.1368±0.00	0.5827±0.00	0.6776±0.00	0.00292±0.00	0.00758±0.00	0.0323±0.00	0.0579±0.008
列表级生成式方法								
OneRec-0.1B	0.0973±0.00	0.1501±0.00	0.6001±0.00	0.6981±0.00	0.00326±0.00	0.00870±0.00	0.0349±0.00	0.0642±0.015
OneRec-1B	0.0991±0.00	0.1529±0.00	0.6039±0.00	0.7013±0.00	0.00349±0.00	0.00919±0.00	0.0360±0.00	0.0660±0.008
采用偏好对齐的列表级生成式方法								
OneRec-1B+DPO	0.1014±0.00	<u>0.1595±0.00</u>	0.6127±0.00	<u>0.7116±0.00</u>	0.00339±0.00	0.00896±0.00	0.0351±0.00	0.0644±0.008
OneRec-1B+IPO	0.0979±0.00	0.1528±0.00	0.6000±0.00	0.7012±0.00	0.00335±0.00	0.00905±0.00	0.0350±0.00	0.0654±0.004
OneRec-1B+cDPO	0.0993±0.00	0.1547±0.00	0.6030±0.00	0.7030±0.00	0.00339±0.00	0.00901±0.00	0.0355±0.00	0.0652±0.009
OneRec-1B+rDPO	0.1005±0.00	0.1555±0.00	0.6071±0.00	0.7059±0.00	0.00339±0.00	0.00899±0.00	0.0357±0.00	0.0657±0.006
OneRec-1B+CPO	0.0993±0.00	0.1538±0.00	0.6045±0.00	0.7029±0.00	0.00343±0.00	0.00911±0.00	0.0357±0.00	0.0659±0.014
OneRec-1B+simPO	0.0995±0.00	0.1536±0.00	0.6047±0.00	0.7022±0.00	<u>0.00349±0.00</u>	0.00918±0.00	0.0360±0.00	0.0659±0.008
OneRec-1B+S-DPO	<u>0.1021±0.00</u>	0.1575±0.00	0.6096±0.00	0.7070±0.00	0.00345±0.00	0.00909±0.00	<u>0.0361±0.00</u>	0.0659±0.008
OneRec-1B+IPA	0.1025±0.00	0.1933±0.00	0.6141±0.00	0.7646±0.00	0.00354±0.00	0.00992±0.00	0.0397±0.00	0.1203±0.010

5.1.3 评估指标. 我们使用若干关键指标评估模型性能。每个指标分别用于评估模型输出的不同方面, 并且我们在每轮迭代中从随机采样的测试用例集上进行评估。为估计每个特定用户-会话对各种交互概率, 我们使用预训练奖励模型评估推荐会话的价值。我们

计算不同目标指标的平均奖励, 包括会话观看时长(**swt**)、观看概率 (**vtr**)、关注概率 (**wtr**) 和点赞概率 (**ltr**)。在这些目标中, swt 和 vtr 属于观看时长指标, 而 wtr 和 ltr 属于交互指标。




图 4: DPO 样本比例 r_{DPO} 的消融研究。结果表明, 1% 的 DPO 训练比例可带来显著增益, 但进一步提高样本比例所带来的提升有限。

5.2 离线性能

表 1 给出了 OneRec 与各种基线的全面比较。对于观看时长指标, 我们主要关注会话观看时长 (swt); 对于交互指标, 我们主要关注点赞概率 (ltr)。我们的结果揭示了三个关键观察:

第一, 所提出的会话级生成方法显著优于传统的基于点积的方法以及 TIGER 等逐点生成方法。与 TIGER-1B 相比, OneRec-1B 的最大 swt 提高了 1.78%, 最大 ltr 提高了 3.36%。这表明, 会话级建模在维持推荐之间的上下文连贯性方面具有优势, 而逐点方法难以平衡生成输出的连贯性与多样性。

第二, 使用较小比例的 DPO 训练即可获得显著增益。仅使用 1% 的 DPO 训练比例 (r_{DPO}), OneRec-1B+IPA 相较基础 OneRec-1B 的最大 swt 提高了 4.04%, 最大 ltr 提高了 5.43%。这表明, 有限的 DPO 训练就能使模型有效对齐所期望的生成模式。

第三, 所提出的 IPA 策略优于各种现有 DPO 变体。如表 1 所示, 与其他 DPO 实现相比, IPA 取得了更优的性能。值得注意的是, 一些 DPO 基线的表现甚至不及未对齐的 OneRec-1B 模型, 这表明, 迭代挖掘模型自行生成的输出以进行偏好选择, 比其他方法更为有效。

5.3 消融研究

5.3.1 DPO 样本比例消融.为研究 DPO 训练中样本比例 r_{DPO} 的影响, 我们在受控条件下将 DPO 样本比例从 1% 调整至 5%。如图 4 所示, 消融结果表明, 提高样本比例仅能在多个评估目标上带来轻微的性能提升。值得注意的是, 尽管计算开销增加, 相对于 1% 基线, 超过该比例后的性能增益仍不显著。需要指出的是, 在 DPO 样本服务器推理期间, 样本比例与 GPU 资源利用量之间存在线性关系: 5% 的样本比例所需 GPU 资源比 1% 基线多 5 $\times$ 。这一扩展特性明确体现了计算效率与模型性能之间的权衡。因此, 在综合平衡计算效率与性能后, 我们采用 1% 的 DPO 样本比例进行训练; 该设置仅需较高样本比例所需计算资源的 20%, 即可达到观测到的最高性能的平均 95%。

5.3.2 模型规模消融.我们评估了 OneRec 随模型规模增大时的表现。如图 6 所示, 将 OneRec 从 0.05B 扩展至 1B 可持续提升准确率, 展现出稳定的缩放特性。具体而言, 相较于 OneRec-0.05B, OneRec-0.1B 的准确率最高显著提升 14.45%; 进一步扩展至 0.2B、0.5B 和 1B 时, 还可分别获得 5.09%、5.70% 和 5.69% 的额外准确率增益。

5.4 OneRec 的预测动态

如图 5 所示, 我们展示了不同层上 8192 个编码的预测概率分布, 其中红色星号表示奖励值最高的物品的语义 ID。与 OneRec 基线相比, OneRec+IPA 的预测分布出现显著的置信度迁移, 这表明我们提出的偏好对齐策略能够有效引导基础模型生成符合偏好的模式。此外, 我们观察到, 第一层的概率分布比后续各层表现出更大的离散性 (熵 = 6.00), 而后续层的分布逐渐集中 (第二层平均熵 = 3.71, 第三层熵 = 0.048)。这种分层式不确定性降低可归因于自回归解码机制: 初始层的预测从先前解码步骤继承了更高的不确定性, 而后续层则受益于累积上下文, 从而约束了决策空间。




图 5: 语义 ID 各层 softmax 输出概率分布的可视化。红色星形表示奖励值最高物品的语义 ID。




图 6: OneRec 模型规模扩展的可扩展性。结果表明, 随着参数规模增大, OneRec 能够持续获得性能提升。

5.5 在线 A/B 测试

为评估 OneRec 的在线性能, 我们在快手首页视频推荐场景中开展了严格的在线 A/B 测试, 并使用 1% 的主站流量对 OneRec 与当前多阶段推荐系统进行对比实验。我们使用总观看时长衡量用户观看视频的总时长, 并使用平均观看时长计算推荐系统向用户展示一次请求所返回的会话时, 用户对每个视频的平均观看时长。在线评估表明, OneRec 在总观看时长上提升了 1.68%, 在平均观看时长上提升了 6.56%, 说明 OneRec 能够取得更优的推荐效果, 并为平台带来可观的收益增长。

表 2: 在线 A/B 测试环境下, OneRec 相较于当前多阶段系统的绝对提升。

模型	总观看时长	平均观看时长
OneRec-0.1B	+0.57%	+4.26%
OneRec-1B	+1.21%	+5.01%
OneRec-1B+IPA	+1.68%	+6.56%

6 结论

本文重点介绍一种用于单阶段生成式推荐的工业解决方案。我们的方案形成了三项关键贡献: 首先, 通过应用 MoE 架构, 我们以较高的计算效率有效扩展模型参数, 为大规模工业推荐提供了可扩展的蓝图。其次, 我们发现有必要以按会话生成的方式对目标物品的上下文信息进行建模, 并证明上下文序列建模相比孤立的逐点建模方式, 能够从本质上更好地捕捉用户偏好的动态变化。此外, 我们提出迭代偏好对齐 (IPA) 策略, 以提升 OneRec 对多样化用户偏好模式的泛化能力。大量离线实验和在线 A/B 测试验证了 OneRec 的有效性与效率。此外, 对在线结果的分析表明, 除用户观看时长外, 我们的模型在点赞等交互指标方面仍存在局限。未来, 我们计划增强端到端生成式推荐的多目标建模能力, 从而提供更好的用户体验。

References

- [1] Mohammad Gheshlaghi Azar, Zhaohan Daniel Guo, Bilal Piot, Remi Munos, Mark Rowland, Michal Valko, and Daniele Calandriello. 2024. A general theoretical paradigm to understand learning from human preferences. In *International Conference on Artificial Intelligence and Statistics*. PMLR, 4447–4455.
- [2] Christopher JC Burges. 2010. From ranknet to lambdarank to lambdamart: An overview. *Learning* 11, 23-581 (2010), 81.
- [3] Jianxin Chang, Chenbin Zhang, Zhiyi Fu, Xiaoxue Zang, Lin Guan, Jing Lu, Yiqun Hui, Dewei Leng, Yanan Niu, Yang Song, et al. 2023. TWIN: TWo-stage interest network for lifelong user behavior modeling in CTR prediction at kuaishou. In *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. 3785–3794.
- [4] Yuxin Chen, Junfei Tan, An Zhang, Zhengyi Yang, Leheng Sheng, Enzhi Zhang, Xiang Wang, and Tat-Seng Chua. 2024. On Softmax Direct Preference Optimization for Recommendation. In *The Thirty-eighth Annual Conference on Neural Information Processing Systems*. <https://openreview.net/forum?id=qp5VbGTaM0>
- [5] Sayak Ray Chowdhury, Anush Kini, and Nagarajan Natarajan. 2024. Provably Robust DPO: Aligning Language Models with Noisy Feedback. In *ICML 2024*.
- [6] Paul Covington, Jay Adams, and Emre Sargin. 2016. Deep neural networks for youtube recommendations. In *Proceedings of the 10th ACM conference on recommender systems*. 191–198.
- [7] Damai Dai, Chengqi Deng, Chenggang Zhao, RX Xu, Huazuo Gao, Deli Chen, Jiashi Li, Wangding Zeng, Xingkai Yu, Y Wu, et al. 2024. Deepseekmoe: Towards ultimate expert specialization in mixture-of-experts language models. *arXiv preprint arXiv:2401.06066* (2024).
- [8] Nicola De Cao, Gautier Izacard, Sebastian Riedel, and Fabio Petroni. 2020. Autoregressive entity retrieval. *arXiv preprint arXiv:2010.00904* (2020).
- [9] Nan Du, Yanping Huang, Andrew M Dai, Simon Tong, Dmitry Lepikhin, Yuanzhong Xu, Maxim Krikun, Yanqi Zhou, Adams Wei Yu, Orhan Firat, et al. 2022. Glam: Efficient scaling of language models with mixture-of-experts. In *International Conference on Machine Learning*. PMLR, 5547–5569.
- [10] Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Amy Yang, Angela Fan, et al. 2024. The llama 3 herd of models. *arXiv preprint arXiv:2407.21783* (2024).
- [11] Hongliang Fei, Jingyuan Zhang, Xingxuan Zhou, Junhao Zhao, Xinyang Qi, and Ping Li. 2021. GemNN: gating-enhanced multi-task neural networks with feature interaction learning for CTR prediction. In *Proceedings of the 44th international ACM SIGIR conference on research and development in information retrieval*. 2166–2171.
- [12] Chao Feng, Wuchao Li, Defu Lian, Zheng Liu, and Enhong Chen. 2022. Recommender forest for efficient retrieval. *Advances in Neural Information Processing Systems* 35 (2022), 38912–38924.
- [13] Luke Gallagher, Ruey-Cheng Chen, Roi Blanco, and J Shane Culpepper. 2019. Joint optimization of cascade ranking models. In *Proceedings of the twelfth ACM international conference on web search and data mining*. 15–23.
- [14] Tiezheng Ge, Kaiming He, Qifa Ke, and Jian Sun. 2013. Optimized product quantization. *IEEE transactions on pattern analysis and machine intelligence* 36, 4 (2013), 744–755.
- [15] Huifeng Guo, Ruiming Tang, Yunming Ye, Zhenguo Li, and Xiquang He. 2017. DeepFM: a factorization-machine based neural network for CTR prediction. *arXiv preprint arXiv:1703.04247* (2017).
- [16] B Hidasi. 2015. Session-based Recommendations with Recurrent Neural Networks. *arXiv preprint arXiv:1511.06939* (2015).
- [17] Michael E Houle and Michael Nett. 2014. Rank-based similarity search: Reducing the dimensional dependence. *IEEE transactions on pattern analysis and machine intelligence* 37, 1 (2014), 136–150.
- [18] Jiri Hron, Karl Krauth, Michael Jordan, and Niki Kilbertus. 2021. On component interactions in two-stage recommender systems. *Advances in neural information processing systems* 34 (2021), 2744–2757.
- [19] Po-Sen Huang, Xiaodong He, Jianfeng Gao, Li Deng, Alex Acero, and Larry Heck. 2013. Learning deep structured semantic models for web search using clickthrough data. In *Proceedings of the 22nd ACM international conference on Information & Knowledge Management*. 2333–2338.
- [20] Xu Huang, Defu Lian, Jin Chen, Liu Zheng, Xing Xie, and Enhong Chen. 2023. Cooperative Retriever and Ranker in Deep Recommenders. In *Proceedings of the ACM Web Conference 2023*. 1150–1161.
- [21] Herve Jegou, Matthijs Douze, and Cordelia Schmid. 2010. Product quantization for nearest neighbor search. *IEEE transactions on pattern analysis and machine intelligence* 33, 1 (2010), 117–128.
- [22] Wang-Cheng Kang and Julian McAuley. 2018. Self-attentive sequential recommendation. In *2018 IEEE international conference on data mining (ICDM)*. IEEE, 197–206.
- [23] Zhirui Kuai, Zuxu Chen, Huimu Wang, Mingming Li, Dadong Miao, Wang Binbin, Xusong Chen, Li Kuang, Yuxing Han, Jiaxing Wang, et al. 2024. Breaking the Hourglass Phenomenon of Residual Quantization: Enhancing the Upper Bound of Generative Retrieval. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing: Industry Track*. 677–685.
- [24] Doyup Lee, Chiheon Kim, Saehoon Kim, Minsu Cho, and Wook-Shin Han. 2022. Autoregressive image generation using residual quantization. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 11523–11532.
- [25] Han Liu, Yinwei Wei, Xuemeng Song, Weili Guan, Yuan-Fang Li, and Liqiang Nie. 2024. MMGRec: Multimodal Generative Recommendation with Transformer Model. *arXiv preprint arXiv:2404.16555* (2024).

- [26] Shichen Liu, Fei Xiao, Wenwu Ou, and Luo Si. 2017. Cascade ranking for operational e-commerce search. In *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 1557–1565.
- [27] Xinchun Luo, Jiangxia Cao, Tianyu Sun, Jinkai Yu, Rui Huang, Wei Yuan, Hezheng Lin, Yichen Zheng, Shiyao Wang, Qigen Hu, et al. 2024. QARM: Quantitative Alignment Multi-Modal Recommendation at Kuaishou. *arXiv preprint arXiv:2411.11739* (2024).
- [28] Xu Ma, Pengjie Wang, Hui Zhao, Shaoguo Liu, Chuhan Zhao, Wei Lin, Kuang-Chih Lee, Jian Xu, and Bo Zheng. 2021. Towards a better tradeoff between effectiveness and efficiency in pre-ranking: A learnable feature selection based approach. In *Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2036–2040.
- [29] Yu Meng, Mengzhou Xia, and Danqi Chen. 2024. SimPO: Simple Preference Optimization with a Reference-Free Reward. In *Advances in Neural Information Processing Systems (NeurIPS)*.
- [30] Eric Mitchell. [n.d.]. A note on dpo with noisy preferences and relationship to ipo, 2023. URL <https://ericmitchell.ai/cdpo.pdf> ([n.d.]).
- [31] Marius Muja and David G Lowe. 2014. Scalable nearest neighbor algorithms for high dimensional data. *IEEE transactions on pattern analysis and machine intelligence* 36, 11 (2014), 2227–2240.
- [32] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, et al. 2022. Training language models to follow instructions with human feedback. *Advances in neural information processing systems* 35 (2022), 27730–27744.
- [33] Qi Pi, Guorui Zhou, Yujing Zhang, Zhe Wang, Lejian Ren, Ying Fan, Xiaoqiang Zhu, and Kun Gai. 2020. Search-based user interest modeling with lifelong sequential behavior data for click-through rate prediction. In *Proceedings of the 29th ACM International Conference on Information & Knowledge Management*. 2685–2692.
- [34] Jiarui Qin, Jiachen Zhu, Bo Chen, Zhirong Liu, Weiwen Liu, Ruiming Tang, Rui Zhang, Yong Yu, and Weinan Zhang. 2022. Rankflow: Joint optimization of multi-stage cascade ranking systems as flows. In *Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval*. 814–824.
- [35] Rafael Rafailov, Archit Sharma, Eric Mitchell, Christopher D Manning, Stefano Ermon, and Chelsea Finn. 2024. Direct preference optimization: Your language model is secretly a reward model. *Advances in Neural Information Processing Systems* 36 (2024).
- [36] Shashank Rajput, Nikhil Mehta, Anima Singh, Raghunandan Hukilal Keshavan, Trung Vu, Lukasz Heldt, Lichan Hong, Yi Tay, Vinh Tran, Jonah Samost, et al. 2023. Recommender systems with generative retrieval. *Advances in Neural Information Processing Systems* 36 (2023), 10299–10315.
- [37] Wentao Shi, Jiawei Chen, Fuli Feng, Jizhi Zhang, Junkang Wu, Chongming Gao, and Xiangnan He. 2023. On the theories behind hard negative sampling for recommendation. In *Proceedings of the ACM Web Conference 2023*. 812–822.
- [38] Anshumali Shrivastava and Ping Li. 2014. Asymmetric LSH (ALSH) for sublinear time maximum inner product search (MIPS). *Advances in neural information processing systems* 27 (2014).
- [39] Nisan Stiennon, Long Ouyang, Jeffrey Wu, Daniel Ziegler, Ryan Lowe, Chelsea Voss, Alec Radford, Dario Amodei, and Paul F Christiano. 2020. Learning to summarize with human feedback. *Advances in Neural Information Processing Systems* 33 (2020), 3008–3021.
- [40] Fei Sun, Jun Liu, Jian Wu, Changhua Pei, Xiao Lin, Wenwu Ou, and Peng Jiang. 2019. BERT4Rec: Sequential recommendation with bidirectional encoder representations from transformer. In *Proceedings of the 28th ACM international conference on information and knowledge management*. 1441–1450.
- [41] Yubao Tang, Ruqing Zhang, Jiafeng Guo, and Maarten de Rijke. 2023. Recent advances in generative information retrieval. In *Proceedings of the Annual International ACM SIGIR Conference on Research and Development in Information Retrieval in the Asia Pacific Region*. 294–297.
- [42] Yi Tay, Vinh Tran, Mostafa Dehghani, Jianmo Ni, Dara Bahri, Harsh Mehta, Zhen Qin, Kai Hui, Zhe Zhao, Jai Gupta, et al. 2022. Transformer memory as a differentiable search index. *Advances in Neural Information Processing Systems* 35 (2022), 21831–21843.
- [43] Lidan Wang, Jimmy Lin, and Donald Metzler. 2011. A cascade ranking model for efficient ranked retrieval. In *Proceedings of the 34th international ACM SIGIR conference on Research and development in Information Retrieval*. 105–114.
- [44] Yunli Wang, Zhiqiang Wang, Jian Yang, Shiyang Wen, Dongying Kong, Han Li, and Kun Gai. 2024. Adaptive Neural Ranking Framework: Toward Maximized Business Goal for Cascade Ranking Systems. In *Proceedings of the ACM on Web Conference 2024*. 3798–3809.
- [45] Ye Wang, Jiahao Xun, Minjie Hong, Jieming Zhu, Tao Jin, Wang Lin, Haoyuan Li, Linjun Li, Yan Xia, Zhou Zhao, et al. 2024. EAGER: Two-Stream Generative Recommender with Behavior-Semantic Collaboration. In *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. 3245–3254.
- [46] Zhe Wang, Liqin Zhao, Biye Jiang, Guorui Zhou, Xiaoqiang Zhu, and Kun Gai. 2020. Cold: Towards the next generation of pre-ranking system. *arXiv preprint arXiv:2007.16122* (2020).
- [47] Haoran Xu, Amr Sharaf, Yunmo Chen, Weiting Tan, Lingfeng Shen, Benjamin Van Durme, Kenton Murray, and Young Jin Kim. 2024. Contrastive preference optimization: Pushing the boundaries of llm performance in machine translation. *arXiv preprint arXiv:2401.08417* (2024).
- [48] Shuyuan Xu, Wenyue Hua, and Yongfeng Zhang. 2024. Openp5: An open-source platform for developing, training, and evaluating llm-based recommender systems. In *Proceedings of the 47th International ACM SIGIR Conference on Research and Development*

- in Information Retrieval*. 386–394.
- [49] Neil Zeghidour, Alejandro Luebs, Ahmed Omran, Jan Skoglund, and Marco Tagliasacchi. 2021. Soundstream: An end-to-end neural audio codec. *IEEE/ACM Transactions on Audio, Speech, and Language Processing* 30 (2021), 495–507.
- [50] Tingting Zhang, Pengpeng Zhao, Yanchi Liu, Victor S Sheng, Jiajie Xu, Deqing Wang, Guanfeng Liu, Xiaofang Zhou, et al. 2019. Feature-level deeper self-attention network for sequential recommendation.. In *IJCAI*. 4320–4326.
- [51] Bowen Zheng, Yupeng Hou, Hongyu Lu, Yu Chen, Wayne Xin Zhao, Ming Chen, and Ji-Rong Wen. 2024. Adapting large language models by integrating collaborative semantics for recommendation. In *2024 IEEE 40th International Conference on Data Engineering (ICDE)*. IEEE, 1435–1448.
- [52] Guorui Zhou, Na Mou, Ying Fan, Qi Pi, Weijie Bian, Chang Zhou, Xiaoqiang Zhu, and Kun Gai. 2019. Deep interest evolution network for click-through rate prediction. In *Proceedings of the AAAI conference on artificial intelligence*, Vol. 33. 5941–5948.
- [53] Guorui Zhou, Xiaoqiang Zhu, Chenru Song, Ying Fan, Han Zhu, Xiao Ma, Yanghui Yan, Junqi Jin, Han Li, and Kun Gai. 2018. Deep interest network for click-through rate prediction. In *Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining*. 1059–1068.
- [54] Han Zhu, Xiang Li, Pengye Zhang, Guozheng Li, Jie He, Han Li, and Kun Gai. 2018. Learning tree-based deep model for recommender systems. In *Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining*. 1079–1088.
- [55] Barret Zoph, Irwan Bello, Sameer Kumar, Nan Du, Yanping Huang, Jeff Dean, Noam Shazeer, and William Fedus. 2022. Designing effective sparse expert models. *arXiv preprint arXiv:2202.08906* 2, 3 (2022), 17.