

OptDist: 面向客户终身价值预测的最优分布学习

Yunpeng Weng^{*}
edwinweng@tencent.com
FiT, Tencent
Shenzhen, Guangdong, China

Xing Tang^{*}
xing.tang@hotmail.com
FiT, Tencent
Shenzhen, Guangdong, China

Zhenhao Xu
zenhaoxu@tencent.com
FiT, Tencent
Shenzhen, Guangdong, China

Fuyuan Lyu[†]
fuyuan.lyu@mail.mcgill.ca
McGill University & MILA
Montreal, Canada

Dugang Liu[‡]
dugang.ldg@gmail.com
Guangdong Laboratory of Artificial
Intelligence and Digital Economy
(SZ)
Shenzhen, Guangdong, China

Zexu Sun[†]
sunzexu21@ruc.edu.cn
Renmin University of China
Beijing, China

Xiuqiang He[‡]
xiuqianghe@tencent.com
FiT, Tencent
Shenzhen, Guangdong, China

Abstract

客户终身价值 (CLTV) 预测是客户关系管理 (CRM)、在线营销等商业应用中的一项关键任务。在真实商业场景中, CLTV 的分布复杂且多变, 因此准确预测 CLTV 极具挑战性。首先, 大量用户没有任何消费, 这些用户构成了难以拟合的复杂长尾部分。其次, 少量高价值用户的消费额比普通用户高出若干数量级, 使 CLTV 分布的取值范围十分宽广, 难以用单一分布捕捉。现有 CLTV 估计方法要么假设一个先验概率分布, 并为所有样本拟合一组分布相关参数; 要么以启发式方式预先人工划分分桶, 直接从后验分布中学习。然而, 这些方法都无法处理复杂且多变的分布。本文提出一种用于 CLTV 预测的新型最优分布选择模型 (OptDist), 它利用自适应最优子分布选择机制, 提高复杂分布建模的准确性。具体而言, OptDist 在分布学习模块 (DLM) 中训练多个候选子分布网络, 以对 CLTV 的概率分布进行建模。随后, 我们提出分布选择模块 (DSM), 为每个样本选择相应子分布, 从而实现自动、自适应的选择。此外, 我们设计了一种连接两个模块的对齐机制, 可有效引导优化。我们在两个公开数据集和一个私有数据集上开展了广泛实验, 验证了 OptDist 优于当前最先进的基线方法。此外, OptDist 已部署在一个大规模金融平台上, 用于获客营销活动, 线上实验同样证明了 OptDist 的有效性。

^{*}同等贡献

[†]本工作完成于作者在腾讯金融科技任职期间。

[‡]通讯作者

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.

CIKM '24, 2024 年 10 月 21–25 日, 美国爱达荷州博伊西

© 2024 Copyright held by the owner/author(s). Publication rights licensed to ACM.

ACM ISBN 979-8-4007-0436-9/24/10

<https://doi.org/10.1145/3627673.3679712>

CCS Concepts

• 信息系统 → 信息系统应用.

Keywords

客户终身价值, 概率分布, 金融平台

ACM Reference Format:

Yunpeng Weng, Xing Tang, Zhenhao Xu, Fuyuan Lyu, Dugang Liu, Zexu Sun, and Xiuqiang He. 2024. OptDist: 面向客户终身价值预测的最优分布学习. In 第 33 届 ACM 信息与知识管理国际会议 (CIKM '24) 论文集, 2024 年 10 月 21–25 日, 美国爱达荷州博伊西. ACM, New York, NY, USA, 10 pages. <https://doi.org/10.1145/3627673.3679712>

1 引言

客户终身价值 (CLTV) 预测是指估计一名用户可能为平台或公司带来的潜在收入 [20, 37]。准确预测 CLTV 在线广告、营销活动和客户留存策略等多种商业场景中具有重要意义 [17, 35, 38]。例如, 在资源受限的获客营销活动中, CLTV 有助于进一步决策。具体而言, 我们可以预测用户在商业平台上特定时间段内的 CLTV, 并投入更多资源吸引高价值客户, 从而高效、有效地利用预算并获得更高的投资回报率 (ROI)。

一些传统方法已经可以直接用于 CLTV 建模。其中一种是基于统计的方法 [9, 11–13], 该方法为 CLTV 假定一种概率分布, 并依据历史统计数据 (如每位客户的消费频率等) 求取统计分布参数。随着深度学习的发展, 一些基于价值的方法使用神经网络预测 CLTV 的精确数值 [8, 37, 39, 42]。然而, 基于统计的方法仅依赖用户历史统计数据, 而没有考虑个性化。例如, 一些用户的消费频率和新近度等历史统计信息可能相同, 因此这些方法只能粗略地为他们预测相同的 CLTV。对于基于价值的方法, 其中大多数采用均方误差 (MSE) 作为损失函数训练回归模型, 而 MSE 对 CLTV 中的异常值非常敏感。这会导致训练不稳定并降低预测性能。因此, 面对复杂且多变的分布, 这些方法无法准确预测 CLTV。

近期, 研究者对于处理 CLTV 分布开展了大量工作。总体而言, 这些方法可以分为两类。第一类引入深度概率模型进行 CLTV 建模。零膨胀对数正态模型 (ZILN) [37] 常用于预测 CLTV, 它




Figure 1: 某大型金融平台的对数 CLTV 分布，其中四个簇表示由聚类算法得到的用户群体。x 轴表示 $\log(\text{CLTV} + 1)$ ，y 轴表示样本数量。

使用深度神经网络对零膨胀对数正态概率分布进行建模。输入用户和物品属性后，深度学习模型可以针对特定物品上的某一用户行为预测 CLTV。然而，现实世界中的 CLTV 分布十分复杂，不同用户群体的分布存在显著差异。例如，我们根据用户属性将某大型金融平台上的用户划分为四个用户簇，并在图 1 中进一步展示各用户簇的 CLTV 分布。基于用户群体之间显著分布差异，我们可以得出结论：使用单一网络为所有用户学习相关参数可能导致学习不充分。另一类方法根据训练样本的连续 CLTV 值将其划分为若干组。多分布多专家 (MDME) 模型 [20] 根据用户 CLTV 值将数据样例划分为多个预定义子分布，每个子分布又包含大量预定义桶。该模型旨在确定用户属于哪个子分布，以及该子分布中的最优桶。然而，将用户简单划分为若干组需要基于规则的分桶操作，而且会因大量零值样本和高价值用户而产生极度不平衡的分类误差。此外，即使采用等频分桶，桶内的 CLTV 分布仍可能不均匀，导致桶归一化偏差出现误差。尽管已有这些研究，CLTV 预测仍然需要一种自适应的处理方式。

为解决上述局限，本文提出一种用于 CLTV 预测的新框架，名为 **Optimal Distribution Selection** (OptDist，最优分布选择)。受 AutoML [26, 27, 43] 在不同数据样本上所展现的内在自适应性能启发，OptDist 采用分布选择网络，以可微方式对每个样本自动选择子分布参数。具体而言，我们不再对所有数据样本使用同一个分布，而是在分布学习模块 (DLM) 中按照分而治之的方式，训练多个候选子分布网络 (SDN) 来建模 CLTV 概率分布。需要注意的是，每个 SDN 专注于训练一组可能的概率分布参数，从而降低整体 CLTV 建模的复杂度。此外，不同于现有方法手动将训练样本划分到不同子分布，OptDist 引入分布选择模块 (DSM)，通过 Gumbel-Softmax [18] 操作为每个训练样本自适应地选择一个子分布。因此，在推理阶段，我们可以仅使用 DSM 为每个待预测实例选择的最优子分布，而不会造成训练与推理之间的差距。然而，由于这两个模块采用不同的参数集，在该框架中训练 DSM 和 DLM 仍面临挑战。为解决这一问题，我们提出一种新的对齐机制，将 DSM 输出的概率与 DLM 输出的损失分布对齐。主要贡献概括如下：

- 我们提出一种名为 OptDist 的新型端到端 CLTV 预测框架。OptDist 探索多个候选概率分布，并为每个样本选择最优子分布，从而能够处理客户终身价值复杂且多变的分布。
- 我们分别设计 DLM 和 DSM 两个模块，用于学习子分布和执行分布选择。我们提出一种连接两个模块的对齐机制来训练该框架。借助这两个模块和对齐机制，OptDist 能够为每个数据样本自适应地选择最优子分布。
- 我们在两个公开数据集和一个私有工业数据集上开展了全面实验，以验证所提出 OptDist 模型相较基线的优越性。此外，我们已将 OptDist 应用于某大型金融平台的营销活动。在线 A/B 测试结果同样证明了 OptDist 的有效性。

2 相关工作

本节简要回顾相关工作。我们的研究涉及两个主题：CLTV 预测和面向推荐的 AutoML。下面对这些工作进行总结。

2.1 CLTV 预测

用户响应建模对在线营销和推荐系统至关重要。点击率预测或转化预测模型等传统方法，在以最大化商品交易总额 (GMV) 为目标的业务场景中表现出局限性。因此，一些工作 [34] 强调了为推荐系统估计收入的必要性，并在排序模型中综合考虑用户行为、转化率和点击率。为了提高 ROI 和 GMV，CLTV 估计已成为评估商业影响的重要指标。RFM [12] 和 Pareto/NBD [4, 13, 32] 模型等传统的基于统计的方法主要关注历史数据，却忽略了丰富的用户属性信息。因此，一些工作将用户信息纳入预测模型。文献 [10, 35] 提出了两阶段建模方法，同时预测购买可能性和客户价值。文献 [6] 利用 Word2vec [30] 创建用户嵌入以预测 CLTV。此外，一些工作研究了面向 CLTV 行为的多种序列模型 [3, 39]，例如将 RNN 与梯度提升机 (GBM) 结合 [3] 以捕获客户历史行为，或采用小波变换和基于注意力的 GRU 分析用户行为序列 [39]。MarfNet [40] 解决了 CLTV 建模中的特征缺失问题。这些工作与我们的研究方向相互独立，并有望与我们的方法结合以获得进一步提升。通过引入先验分布，ZILN [37] 为 CLTV 预测提供了一种多任务解决方案，将回访客户分类与回访客户消费额预测相结合。ExpLTV [41] 进一步将 ZILN 扩展到游戏大额付费用户检测和 CLTV 预测。除此之外，Order Dependency Monotonic Network [20] 设计了顺序依赖单调网络 (ODMN)，对不同时期 CLTV 之间的有序依赖关系进行建模，从而预测各时期的 CLTV 值。在每个时期，它使用多分布多专家 (MDME) 模块，通过预定义桶预测分类概率，并据此选择合适的专家来预测特定范围内的 CLTV。

2.2 面向推荐的 AutoML

近年来，自动机器学习 (AutoML) 技术因能够自动、高效地寻找最佳机器学习模型并提升性能，在推荐领域受到了广泛关注 [7, 21, 46]。以往大多数研究集中于参数搜索 (如嵌入维度 [28, 44, 45]) 以及特征分桶、特征交互等特征处理模式 [15, 25]。在嵌入维度搜索方面，AutoEmb [44] 提出了一种由 AutoML 驱动的方法，根据上下文信息及流行度为用户/物品特征域确定最优嵌入维度。AutoDim [45] 同样用于嵌入维度搜索，它为每个特征域学习多个具有不同维度的候选嵌入，并使用 Gumbel-softmax 技巧选择最佳嵌入维度。为实现连续特征的自动离散化和嵌入，从而提升模型性能，AutoDis [15] 引入了元嵌入和自动离散化模块。AutoCross [25] 聚焦于自动特征交互操作，在树状空间中执行束搜索并生成高阶交叉特征。不同于上述聚焦特征处理和表示学习的研究，AutoLoss [43] 专注于搜索合适的

损失函数, 其中包含多个候选损失函数以及一个用于确定其概率的控制器。OptDist 首次将 AutoML 技术引入 CLTV 预测, 为数据实例自适应搜索最优分布。

3 方法

OptDist 的整体框架如图 2 所示。OptDist 主要由共享表示学习、分布学习模块 (DLM) 和分布选择模块 (DSM) 组成。共享表示学习将原始特征转换为稠密向量。DLM 由多个子网络组成, 这些子网络学习某一特定概率分布的参数。DSM 包含一个分布选择网络, 旨在为每个数据实例从 DLM 中选择一个最优候选子分布。随后, 我们将介绍对齐机制以及如何优化所提出的方法。

3.1 问题定义

3.1.1 客户终身价值预测. 我们首先给出 CLTV 预测问题的定义。给定由 N 名用户组成的集合 $\mathcal{U}$, 以及用户 u 在固定时间窗口 d 内为平台带来的总收入。训练数据集 $\mathcal{D} = \{(\mathbf{x}_u, y_u) | u \in \mathcal{U}, y_u \in [0, +\infty)\}$ 中的每个样本均包含输入特征 $\mathbf{x}_u$ 和 CLTV 标签 $y_u \geq 0$ 。通常, 我们使用模型 $f(\cdot)$ 预测 CLTV, 其形式化表达如下:

$$\hat{y}_u = f(\mathbf{x}_u | \mathcal{D}, \Theta), \quad (1)$$

$$\mathcal{L}(\hat{y}, y) = \sum_{u=1}^U \mathcal{L}_u(\hat{y}_u, y_u), \quad (2)$$

其中, $\hat{y}_u$ 是预测的 CLTV, 即 pLTV; Θ 表示模型参数; $\mathcal{L}$ 是每名用户 $\mathcal{L}_u$ 的损失函数。

3.1.2 最优分布选择. 基于式 1, Θ 通常是一个难以捕捉上述 CLTV 分布的概率模型。因此, 我们将单个概率模型拆分为一系列子分布模型 $\Theta = [\theta_1, \dots, \theta_L]$ 。我们将分布选择构造为针对特定用户学习掩码向量 π_u , 并记作 $\tilde{\Theta} = \pi_u \odot \Theta = [\pi_{u,1}\theta_1, \dots, \pi_{u,L}\theta_L]$ 。基于上述符号定义, 我们将最优分布选择问题形式化定义如下:

$$\theta^* = \arg \min_{\pi_u, \Theta} \mathcal{L}_u(f(\mathbf{x}_u | \mathcal{D}, \pi_u \odot \Theta), y), \quad (3)$$

$$\text{s.t.} \quad \sum_{l=1}^L \pi_{u,l} = 1, \quad \pi_{u,l} \in \{0, 1\},$$

其中, L 是可供选择的候选子分布数量, θ_l 分别使用不同的随机种子初始化, 以提高子分布之间的多样性。

3.2 共享表示学习

输入特征 $\mathbf{x}_u \in \mathcal{R}^m$ 主要由类别特征和连续特征组成。通常, 每个类别特征 x_i (例如用户所在城市或性别) 都会通过嵌入表映射为低维向量 $\mathbf{e}_i$ 。对于访问次数等连续特征, 我们使用 Z-score [2] 对其进行归一化, 并将其视为一维向量 $\mathbf{e}_j$ 。所有特征向量拼接如下:

$$\mathbf{h} = [\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_m]. \quad (4)$$

随后, $\mathbf{h}$ 将通过共享底层网络进行转换, 生成共享样本表示, 并分别输入 DLM 和 DSM。需要注意的是, $\mathbf{h}$ 是 DSM 和 DLM 的输入。因此, 面向特定任务的其他表示学习模块也可以轻松接入本框架, 例如用于缺失特征问题的 MarfNet [40]、用于跨域适配的 CDFAF [33] 等。

3.3 分布学习模块

如图 1 所示, 在多数业务场景中, 由于零消费客户占比较大, 而高价值客户数量较少, 使用单一分布捕捉 CLTV 分布十分困难。因此, 我们采用分而治之的思想, 引入多个神经网络分别学习分布的一部分。

具体而言, 我们假设 CLTV 的整体复杂分布由多个子分布组成, 并且每名用户属于其中一个子分布。我们使用多个子网络 (称为子分布网络, SDN) 对各子分布建模。每个 SDN 专注于从分布相似的用户子集中学习, 从而避免用户之间显著的分差异影响参数学习的有效性。因此, OptDist 降低了整体概率分布建模的难度。需要注意的是, 与文献 [20] 中预先基于真实标签手动将样本划分为子分布的方法不同, OptDist 会自动搜索每名用户所属的最优子分布。

该模块有两个关键问题。第一, 确定子分布网络至关重要, 因为它决定了如何对分布进行建模。如前所述, 零膨胀对数正态分布 [37] 是专门针对 CLTV 分布提出的。ZILN 损失缓解了常用 MSE 损失对极端值过于敏感的问题。因此, 我们在框架中采用面向 ZILN 损失的网络作为 SDN。第二, 神经网络的设置数量决定了 OptDist 中的搜索空间。在训练过程中, 每个用户表示 $\mathbf{h}_u$ 都会输入固定数量的候选 SDN, 从而得到一组不同的 ZILN 分布参数 $\{\theta_1 = (p_1, \mu_1, \sigma_1), \theta_2 = (p_2, \mu_2, \sigma_2), \dots, \theta_L = (p_L, \mu_L, \sigma_L)\}$ 。由此, 搜索空间可达 N^L , 这给大型平台上的搜索带来了重大挑战。因此, 确定 L 时需要进行权衡。如果 L 过大, 会加重搜索负担; 如果过小, 则会导致模型无法拟合复杂分布。因此, 我们将 L 设为超参数, 并可在本框架中高效探索。综上, 我们计算用户 u 对每个 SDN _{i} 的负对数似然损失:

$$\mathcal{L}_{u,i} = \begin{cases} -\log(p_{u,i}) + \log(y_u \sqrt{2\pi}\sigma_{u,i}) + \frac{(\log y_u - \mu_{u,i})^2}{2\sigma_{u,i}^2}, & C_u = 1 \\ -\log(1 - p_{u,i}), & C_u = 0 \end{cases} \quad (5)$$

其中, C_u 表示用户 u 是否完成转化, y_u 是 CLTV 标签。随后, 我们重写式 3, 通过计算每名用户在各 SDN 上损失的加权和, 得到具体损失函数 $\mathcal{L}_u$:

$$\mathcal{L}_u = \sum_{i=1}^L \pi_{u,i} \cdot \mathcal{L}_{u,i}, \quad (6)$$

其中, $\pi_{u,i}$ 是用户 u 对第 i 个候选子分布的权重。 $\pi_{u,i}$ 由 DSM 模块的输出得到, 下一节将对此进行讨论。

3.4 分布选择模块

在 OptDist 中, 求解式 3 所示的最优分布选择问题颇具挑战。作为一种潜在解决方案, 强化学习智能体只能在选出最优分布网络后才能获得奖励。这种延迟奖励阻碍了强化学习的直接应用。因此, 为确定式 6 中的权重, OptDist 遵循文献 [43] 的设计, 引入分布选择模块。

OptDist 采用多层感知机 (MLP) 作为最优分布选择网络。该网络的输出形式化如下:

$$\alpha_u = \text{softmax}(\text{MLP}(\mathbf{h}_u | \theta_{mlp})), \quad (7)$$

其中, θ_{mlp} 是 MLP 的参数。值得注意的是, 选择网络可以轻松替换为其他更强大的模型 [16, 36], 但这超出了本文的讨论范围。

然而, 使用 softmax 操作可能会产生相对平滑的权重。这可能导致被选中 SDN 的训练受到其他 SDN 损失的影响, 从而导致次优结果。Gumbel-max 采样 [14] 是一种能够实现硬选择的技术:




Figure 2: 本文提出的 OptDist 整体框架。

$$S_u = \text{one_hot}(\arg \max_i [\log \alpha_{u,i} + g_{u,i}]), \quad (8)$$

$$g_{u,i} = -\log(-\log(U_{u,i})),$$

$$U_{u,i} \sim \text{Uniform}(0, 1).$$

然而，由于 $\arg \max$ 操作，这种离散选择不可微。为解决该问题，我们采用直通式 Gumbel-softmax [18]：

$$\pi_{u,i} = \frac{\exp((\log(\alpha_{u,i}) + g_{u,i})/\tau)}{\sum_i \exp((\log(\alpha_{u,i}) + g_{u,i})/\tau)}, \quad (9)$$

其中， τ 是温度参数，用于控制 Gumbel-softmax 分布与离散分布之间的近似程度。当 τ 趋近于 0 时，式 9 的效果会更接近 $\arg \max$ 操作，从而得到掩码向量 π_u 。

3.5 对齐机制

如式 6 所示，我们需要利用两个模块的输出来优化损失函数。具体而言，DLM 模块会更新分布网络参数，而 DSM 也会相应更新选择策略，使得优化困难且容易得到次优结果。为进一步改善优化，我们提出一种受元伪标签 [31] 启发的对齐机制。

在 OptDist 中，DLM 模块内的每个 SDN 都专注于使用 DSM 分配给该子分布的实例进行训练。然而，OptDist 中两组相互独立的参数在优化期间会彼此干扰。与此同时，DSM 缺乏显式监督信号，因而难以与 DLM 的输出对齐。仅依赖损失 $\mathcal{L}_u$ 很难同时充分训练 DSM 和 DLM。通过对每名用户由不同 SDN 生成的损失值进行归一化，对齐机制可以生成伪标签来指导 DSM 的训练，降低 DSM 搜索最优子分布的难度。如图 3 所示，给定可能分布上的一组损失值 $Q = \{\mathcal{L}_{u,i}\}_{i=1}^L$ 后，我们可以根据这些损失值得到硬伪标签 y_u^p ：

$$y_u^p = \text{one_hot}(\arg \min_i (\mathcal{L}_{u,i})). \quad (10)$$

首先，硬标签 y^p 可用于构造交叉熵损失。此外，考虑到实际应用中的 CLTV 分类不平衡，这可能导致高价值用户的交叉熵被忽略，使 DSM 难以识别他们。因此，为缓解该问题，我们




Figure 3: DSM 与 DLM 之间的对齐机制。Q 表示 SDN 的损失集合。

在交叉熵损失中引入了焦点权重 [22] 的一种变体。损失函数可定义为：

$$\mathcal{L}_u^{CE} = \sum_{i=1}^L -y_{u,i}^p (1 - \alpha_{u,i})^2 \log(\alpha_{u,i}). \quad (11)$$

随后，我们根据各子分布的损失生成软标签：

$$y_u^\omega = \text{softmax}(-\mathcal{L}_u) = [\omega_{u,1}, \omega_{u,2}, \dots, \omega_{u,L}] \quad (12)$$

$$\omega_{u,i} = \frac{\exp(-\mathcal{L}_{u,i})}{\sum_j \exp(-\mathcal{L}_{u,j})}. \quad (13)$$

根据 DLM， $\omega_{u,i}$ 越大，第 i 个子分布就越适合用户 u 。随后，我们在 DLM 与 DSM 之间采用 Kullback-Leibler (KL) 散度 [5]：

$$\mathcal{L}_u^{KL} = \sum_{i=1}^L \omega_{u,i} \log\left(\frac{\omega_{u,i}}{\alpha_{u,i}}\right). \quad (14)$$

同时考虑硬标签和软标签的优势在于，硬标签能够使 DSM 聚焦于 DLM 信息而忽略其他标签信息，而软标签则可对此形成补充。综上，OptDist 的总体损失定义为：

$$\mathcal{L}^{OptDist} = \frac{1}{N} \sum_{u \in \mathcal{U}} (\mathcal{L}_u + \mathcal{L}_u^{CE} + \mathcal{L}_u^{KL}). \quad (15)$$

3.6 优化与推理

3.6.1 优化方法. 在 OptDist 中, 可训练参数来自 DLM 和 DSM。我们分别将 DLM 和 DSM 的参数记为 $\Theta_L = \{\theta_1, \dots, \theta_L\}$ 和 $\Theta_S = \{\theta_{mlp}\}$ 。需要注意的是, π_u 在式 3 中由 DSM 按照式 9 直接生成。这里我们主要讨论如何优化框架参数。我们将 OptDist 构造为如下双层优化问题:

$$\begin{aligned} \min_{\Theta_S} \mathcal{L}_{val}^{OptDist}(\Theta_L^*, \Theta_S), \\ s.t. \quad \Theta_L^* = \arg \min_{\Theta_L} \mathcal{L}_{train}^{OptDist}(\Theta_L, \Theta_S^*), \end{aligned} \quad (16)$$

其中, DLM 参数 Θ_L 和 DSM 参数 Θ_S 分别被视为上层变量和下层变量。然而, 这种形式会增加模型训练的复杂度。因此, 我们采用可微架构搜索 (DARTS) [23] 的近似方案策略。OptDist 的所有参数记为 $\Theta = \{\Theta_L, \Theta_S\}$, 并在每个小批次内按如下方式更新:

$$\hat{\Theta} = \Theta - \eta \cdot \nabla \mathcal{L}_{train}^{OptDist}, \quad (17)$$

其中, η 是学习率。需要注意的是, Θ_L 与 Θ_S 既包含共享参数, 也包含独立参数, 而对齐机制缓解了近似单层优化的困难。

3.6.2 推理阶段. 对于每个待预测实例 $\mathbf{x}$, OptDist 首先通过共享嵌入底层获得表示 $\mathbf{h}$ 。随后, 该表示被输入 DSM, DSM 将输出该实例属于各子分布的概率 α 。在此阶段, 仅使用最优 SDN 的输出来计算预测 CLTV, 而该 SDN 的索引可通过对 α 执行 argmax 操作获得:

$$s = \arg \max ([\alpha_1, \alpha_2, \dots, \alpha_L]). \quad (18)$$

得到所选分布的索引后, 模型可以从对应 SDN 的输出中取得最优分布参数 $\theta_s = (p_s, \mu_s, \sigma_s)$, 并结合对数正态分布的期望公式得到估计 CLTV:

$$\hat{y} = p_s \times \exp(\mu_s + \sigma_s^2/2). \quad (19)$$

算法 1 概括了 OptDist 的优化与推理过程。在第 2–4 行中, 样本表示被输入若干子网络, 以获得子分布参数。由于每个子分布只需处理一部分相似样本的 CLTV 概率建模子问题, 因此子网络可以采用相对简单的 MLP 处理, 并且能够并行化, 从而不会增加模型的时间复杂度。第 5 行和第 6 行给出了 DSM 的输出, 第 7 行至第 11 行则进行分布评估。第 12 行执行模型参数更新。最后, 根据第 13–14 行得到预测结果。

4 实验

本节通过离线和线上实验验证所提出 OptDist 的有效性, 并回答以下研究问题:

- **RQ1:** 所提出 OptDist 的离线与线上性能和主流基线相比如何?
- **RQ2:** 关键超参数如何影响 OptDist 的性能?
- **RQ3:** OptDist 中的对齐机制对最终结果有何影响?
- **RQ4:** OptDist 能否学习到最优子分布?

Algorithm 1: OptDist 的优化算法

Input: 输入特征 $\mathbf{X} = \{\mathbf{x}_u | \forall u \in \mathcal{U}\}$;
子分布数量 L ;
温度 τ ;
初始模型参数 Θ ;
Learning rate η ;
Output: 预测的 CLTV $\hat{y}$
训练后的模型参数 $\hat{\Theta}$;

- 1 $\mathbf{H} = \text{Emb}(\mathbf{X})$;
- 2 **for** $i = 1$ 至 L **do**
- 3 $(p_i, \mu_i, \sigma_i) \leftarrow \text{SDN}_i(\mathbf{H})$;
- 4 **end**
- 5 $\alpha = \text{softmax}(\text{MLP}(\mathbf{H}))$;
- 6 $\pi = \text{gumbel_softmax}(\log(\alpha), \tau)$
- 7 **for** $i = 1$ 至 L **do**
- 8 | 计算负对数似然损失 $\mathcal{L}_i$, 用于对应的子分布 SDN_i ;
- 9 **end**
- 10 分别根据式 10 和式 13 生成硬标签和软标签;
- 11 根据式 $\mathcal{L}$ 以及式 6 至式 15 计算损失。
- 12 $\hat{\Theta} \leftarrow \Theta - \eta \cdot \nabla \mathcal{L}^{OptDist}$
- 13 $s = \arg \max(\alpha)$
- 14 $\hat{y} = p_s \times \exp(\mu_s + \sigma_s^2/2)$

4.1 实验设置

4.1.1 数据集. 我们在两个公开数据集和一个私有工业数据集上进行实验。对于下述数据集, 我们分别按照 7:1:2 的比例随机划分训练集、验证集和测试集。

Criteo-SSC.¹ Criteo 赞助搜索转化 (Criteo-SSC) 数据集是一个大规模公开数据集, 包含从 Criteo Predictive Search (CPS) 获得的日志。数据集中的每一行表示用户对产品广告的一次点击行为, 并包含产品属性和用户特征信息。标签表示该点击是否在 30 天内带来转化及相应收入。请注意, 我们从特征中移除了产品价格。

Kaggle.² Kaggle 的 Acquire Valued Shoppers Challenge 数据集 (下文简称 Kaggle 数据集) 包含约 3,300 家公司的 300,000 多名购物者的交易记录。与既有研究的实验设置 [37] 类似, 我们考虑的任务是预测用户在首次购买后一年内所购买的某家公司产品的总价值, 并重点关注首次购买发生在 2012-03-01 至 2012-07-01 之间的客户。我们保留交易数最多的三家公司。

Industrial. 私有数据集采集自一个提供多家基金公司共同基金的大型金融平台。由于客户可以自由决定投资金额, 其客户终身价值 (CLTV) 分布十分复杂。该数据集包含超过 450 万个样本, 每个样本对应一位从未在平台投资过的新用户的画像与访问行为特征。模型旨在预测这些用户是否会在未来 30 天内转化, 并估计相应的 CLTV。

表 1 总结了这三个数据集的详细信息。

4.1.2 指标. CLTV 预测是连续值预测, 因此我们使用 MAE 衡量预测值与用户实际 CLTV 之间的偏差; 该指标广泛用于回归任务 [19]。在实际商业应用中, 营销资源往往会优先分配给 CLTV 较高的客户, 因此人们更加关注根据预测 CLTV 对用户排序的准确性 [40]。遵循既有研究 [37, 40], 我们同时采用

¹<https://ailab.criteo.com/criteo-sponsored-search-conversion-log-dataset/>

²<https://www.kaggle.com/c/acquire-valued-shoppers-challenge>

Table 1: 数据集统计

数据集	样本数	正样本数	正样本比例
Criteo-SSC	15,995,633	1,150,996	7.20%
Kaggle	805,753	726,180	90.12%
Industrial	4,535,675	287,934	6.35%

Spearman 秩相关系数 (Spearman's ρ) 和归一化 **Gini 系数 (Norm-GINI)** 进行评估。请注意, 该值越大, CLTV 预测效果越好。除了使用这两个排序指标评估模型在所有样本上的总体排序性能外, 我们还单独在正样本上进行评估, 以比较模型区分非零 CLTV 样本的能力, 分别记为 **Norm-GINI(+)** 和 **Spearman's $\rho(+)$** 。

4.1.3 基线。 我们将所提出的 OptDist 与多种最先进的 CLTV 预测方法进行比较。请注意, 此处未纳入部分专注于表示学习的方法 [6, 39, 40]。基线方法总结如下:

- Two-stage [10]。该方法将 CLTV 预测分解为两个任务: 第一个是分类任务, 用于预测用户是否会流失; 第二个是回归任务, 用于预测用户带来的收入。
- MTL-MSE [29]。该方法按照多任务学习范式, 使用 MSE 损失估计转化率和 CLTV。
- ZILN [37]。ZILN 假设长尾 CLTV 分布服从零膨胀对数正态分布, 并使用 DNN 估计样本的均值 μ 、标准差 σ 和转化率 p 。
- MDME [20]。该基线根据 CLTV 将训练样本划分为多个子分布和桶, 并构造相应的分类问题, 预测样本所属的桶。在下一阶段, 估计桶内偏差, 从而为样本获得细粒度 CLTV 值。
- MDAN [24]。MDAN 使用多分类网络预测预定义的 LTV 桶标签, 并利用多通道学习网络为每个桶生成嵌入。通过加权求和将这些嵌入与分类网络的输出融合, 得到最终样本表示, 随后用于 CLTV 预测。

4.1.4 实现细节。 本小节介绍实现细节。为保证公平比较, 在 OptDist 和所有基线的全部实验中, 学习率均从 $[5e-4, 1e-3, 1.5e-3, 2e-3, 2.5e-3]$ 中选择。对于两个公开数据集, 批量大小设为 2048, 嵌入维度设为 5。对于工业数据集, 批量大小设为 512, 嵌入维度设为 12。对于 ZILN、MSE 和 MTL-MSE, MLP 部分的大小在 Kaggle 数据集上设为 $[64, 64, 64]$, 在 Criteo-SSC 数据集上设为 $[512, 256, 64]$, 在工业数据集上设为 $[512, 256, 128]$ 。对于 OptDist 的每个 SDN、MDME 的每个桶网络以及 MDAN 的每个通道网络, 对应大小分别设为 $[64, 32, 32]$ 、 $[256, 128, 64]$ 和 $[256, 128, 64]$ 。

我们的实现基于 Tensorflow [1], 所有实验均在一台 Linux 服务器上进行, 该服务器配备一块 Nvidia-Tesla V100-PCIe-32GB GPU、128GB 主内存以及 8 个 Intel(R) Xeon(R) Gold 6140 CPU 核心。

4.2 性能比较 (RQ1)

表 2 分别给出了各模型在所有数据集测试集上的评估结果。基于这些结果, 我们得到以下有启发性的观察:

- 与两阶段模型相比, MTL-MSE 在整体数据集评估中表现更好; 但在正样本空间的评估中, MTL-MSE 未必优于两阶段模型。这是因为在两阶段方法中, 对于预测转化率较高的用户, CLTV 的学习更充分, 而 MTL-MSE 的性能可能受到跷跷板现象的影响。




Figure 4: OptDist 在三个数据集上采用不同超参数时的 Norm-GINI。

- ZILN 的整体性能优于两阶段模型和 MTL-MSE, 表明对 CLTV 的概率分布进行建模可以缓解 MSE 对极端值敏感的问题。
- MDME 在不同数据集上的表现不稳定。例如, 它在 Criteo-SSC 数据集上的 MAE 较小, 但 Norm-GINI 和 Spearman 秩相关指标均较差, 说明其在该数据集上的排序能力较弱。在工业数据集上, 尽管整体 Spearman's ρ 相对优于 ZILN, 但整体 Norm-GINI 以及正样本空间中的排序指标均显著弱于 ZILN 和 OptDist。这是因为 MDME 需要预测样本所属的子分布和桶, 以及样本在桶内的位置, 这可能会放大累积误差。MDAN 通过融合多个通道的嵌入, 获得了比 MDME 更稳定的结果, 但它仍然需要预定义分桶。此外, 它在整合各通道表示后使用单一预测网络估计 CLTV, 可能无法有效捕获复杂的 CLTV 分布, 从而限制模型性能。
- 我们提出的 OptDist 在三个数据集上均优于基线。这表明, 通过自适应学习不同子分布的参数并选择最优子分布, 可以将复杂的整体分布分解为多个相对容易学习的子问题, 从而提高模型的预测性能。此外, OptDist 不需要额外对样本进行预定义分桶, 因此能够开展增量训练并快速部署到其他新场景。由于 CLTV 估计问题中的零值样本比例通常很高, MDME 很难实现等频分桶。而且, 即使正样本采用等频分桶, 桶内的 CLTV 分布也可能不均匀, 导致桶偏差估计不准确。我们认为, 预定义分桶以及使用桶内归一化位置的估计方法可能并不完全适合这种情况。

4.3 超参数敏感性分析 (RQ2)

在 OptDist 的 DSM 中, Gumbel-softmax 的温度系数会影响 $\mathcal{L}_u$ 中各 SDN 的权重。此外, DLM 中子分布的数量也是一个关键超参数。因此, 本节研究这两个超参数如何影响我们的框架。需要注意的是, 在实际业务场景中, 我们主要关注整体样本的 Norm-GINI 评估, 因为它反映模型能否帮助将营销资源分配给 CLTV 最高的用户 [40]。因此, 我们主要围绕该指标讨论不同参数对 OptDist 性能的影响。对于每个数据集, 我们将子分布数量设置为集合 $\{2, 3, 4, 5, 6\}$ 中的不同取值。总体而言, 一方面, 整体分布越复杂的数据集可能包含越多子分布, 因此需要更多 SDN 进行建模; 另一方面, 子分布数量的增加也会提高 DSM 的学习难度。图 4(a) 展示了模型在不同子分布设置下的排序性能。对于 Kaggle 和 Criteo-SSC 数据集, 子分布数量为 4 时模型性能最佳; 对于工业数据集, 子分布数量为 5 时性能最佳。图 4(b) 展示了框架在不同 Gumbel-softmax 温度系数下的性能。当温度系数过高时, 采样概率会变得更加平滑, 样本无法聚焦于其所选择子分布的训练, 从而影响性能。

Table 2: 不同模型在所有数据集上的总体性能。 $\uparrow$ 表示指标值越高越好, 而 $\downarrow$ 表示相反。 $\dagger$ 表示相较于最佳基线有统计显著的提升 ($p\text{-value} < 0.05$)。

数据集	模型	MAE $\downarrow$	Norm-GINI $\uparrow$	Spearman's ρ $\uparrow$	Norm-GINI(+) $\uparrow$	Spearman's $\rho(+)$ $\uparrow$
Criteo-SSC	Two-stage	21.719	0.5278	0.2386	0.2204	0.2565
	MTL-MSE	21.190	0.6330	0.2478	0.4340	0.3663
	ZILN	20.880	0.6338	0.2434	0.4426	0.3874
	MDME	16.598	0.4383	0.2269	0.2297	0.2952
	MDAN	20.030	0.6209	0.2470	0.4128	0.3521
	OptDist	15.784$\dagger$	0.6437$\dagger$	0.2505	0.4428	0.3903
Kaggle	Two-stage	74.782	0.5498	0.4313	0.5505	0.4596
	MTL-MSE	74.065	0.5503	0.4329	0.5349	0.4328
	ZILN	72.528	0.6693	0.5239	0.6627	0.5303
	MDME	72.900	0.6305	0.5163	0.6213	0.5289
	MDAN	73.940	0.6648	0.4367	0.6680	0.4567
	OptDist	70.929$\dagger$	0.6814$\dagger$	0.5249	0.6715$\dagger$	0.5346$\dagger$
Industrial	Two-stage	0.887	0.6670	0.0781	0.5588	0.4467
	MTL-MSE	0.548	0.7194	0.1161	0.5575	0.4274
	ZILN	0.389	0.7854	0.1208	0.5899	0.5401
	MDME	0.419	0.7277	0.1229	0.5609	0.5119
	MDAN	0.437	0.7629	0.1214	0.5816	0.5383
	OptDist	0.322$\dagger$	0.8283$\dagger$	0.1282$\dagger$	0.6271$\dagger$	0.5476$\dagger$


Table 3: OptDist 及其变体在不同数据集上的 Norm-GINI。

方法	Criteo-SSC	Kaggle	工业数据集
OptDist	0.6437	0.6814	0.8283
(不使用) Gumbel-softmax	0.6389	0.6628	0.8231
(w/o) $\mathcal{L}^{KL}$	0.6382	0.6786	0.8158
(不使用) $\mathcal{L}_u^{CE}$	0.6366	0.6761	0.8107
(不使用) $\mathcal{L}^{KL} + \mathcal{L}_u^{CE}$	0.6361	0.6740	0.8023

4.4 消融研究与案例研究 (RQ3&RQ4)

本小节通过消融实验和案例分析研究 OptDist 不同组成部分的影响。首先, 我们根据整体样本的 Norm-GINI 比较 OptDist 的不同变体: (1) (不使用) **Gumbel-softmax**: 移除 Gumbel-softmax 操作, 使用普通 softmax 生成掩码向量。(2) (不使用) $\mathcal{L}^{KL}$: 从对齐机制中移除 KL 散度损失项。(3) (不使用) $\mathcal{L}_u^{CE}$: 从对齐机制中移除交叉熵项。(4) (不使用) $\mathcal{L}^{KL} + \mathcal{L}_u^{CE}$: 省略 DSM 的对齐机制。

随后, 我们在表 3 中汇总消融实验结果。首先, 结果表明 Gumbel-softmax 操作有助于 OptDist 提升预测性能。需要注意的是, Gumbel-softmax 用于实现近似离散采样, 使每个 SDN 专注于从分布相似的用户子集中学习。其次, 移除对齐机制后, OptDist 的性能下降, 说明对齐机制能够有效缓解大搜索空间带来的训练困难。我们还分别对两个损失项进行消融, 以进一步研究对齐机制中 KL 损失和 CE 损失的作用。结果表明, 对齐机制中的 KL 散度损失和交叉熵损失都能提升性能, 从而验证了我们关于软标签和硬标签的设计。具体而言, 交叉熵损失可以在最佳子分布的引导下训练 DSM, 而 KL 散度损失则确保 DSM 也会考虑其他子分布。

**Figure 5:** Kaggle 数据集上不同子分布在真实 CLTV 与预测值 ($\hat{y}$) 方面的差异。

为了直观说明在 DLM 中将整体分布分解为多个子分布进行建模的有效性, 我们在 Kaggle 数据集上开展案例分析。图 5 从真实 CLTV 和 OptDist 预测两个方面, 可视化了各子分布中用户的分布情况。箱线图表明, OptDist 能够为每个用户选择最优分布, 并分别拟合相应的子分布。

4.5 在线 A/B 测试 (RQ1)

我们已在一个大型金融平台上部署本文提出的 OptDist, 用于预测用户在该平台上的 CLTV, 并将其应用于营销活动中的受众定向。

为确保实验公平, 对于每个营销活动, 我们随机将 50% 的流量分配到实验组, 另外 50% 分配到对照组, 以确保两组用户具有同质性。此外, 分配给两组流量的营销资源相同。随后, 不同模型对分配到的潜在用户进行预测和排序, 再选择数量相同的目标用户开展营销活动。

基于上述在线 A/B 测试设置, 我们在多个营销活动上开展在线实验, 重点关注过去访问过平台但从未购买的用户。评估指标为 ROI, 即用户贡献的收入与营销预算支出之比。表 4 给出了

Table 4: 在不同在线营销活动中，我们的 **OptDist** 相比基线在 **ROI** 方面的相对提升。

营销活动 ID	ROI-7	ROI-14	ROI-30
营销活动 A	+8.96%	+17.31%	+21.90%
营销活动 B	+9.04%	+9.83%	+12.51%
营销活动 C	+6.47%	+8.68%	+11.45%
营销活动 D	+14.42%	+16.53%	+19.06%

大型金融科技平台上的在线实验结果。对于每个营销活动，我们分别观察 7 天、14 天和 30 天后的 ROI 相对提升。在线实验结果表明，OptDist 在所有营销活动和观察时间窗口中均取得显著提升。这些发现说明，通过准确估计 CLTV，OptDist 在真实客户获取场景中具有有效性。

5 结论

准确预测 CLTV 对提高公司收入至关重要。本文提出一种用于 CLTV 预测的新框架 OptDist。OptDist 在 DLM 中学习多个候选概率分布，并在 DSM 中采用带有 Gumbel-softmax 操作的网络，生成各候选分布的探索权重。此外，我们提出一种对齐机制，根据 DLM 中 SDN 的损失为 DSM 生成伪标签，并利用这些伪标签指导 DSM 的训练，从而提高优化效率。通过这种方式，OptDist 将复杂的单分布建模问题分解为多个相对易学的子分布建模问题，并为每个用户选择最优子分布。我们在两个公开数据集和一个工业数据集上进行了全面的离线实验，结果证明了 OptDist 的优越性。此外，我们已将 OptDist 部署到真实应用中，并在多项营销活动中开展线上实验，结果一致表明 OptDist 有效。

Acknowledgments

感谢国家自然科学基金（编号：62302310）的支持。

References

- [1] Martin Abadi, Paul Barham, Jianmin Chen, Zhifeng Chen, Andy Davis, Jeffrey Dean, Matthieu Devin, Sanjay Ghemawat, Geoffrey Irving, Michael Isard, et al. 2016. {TensorFlow}: a system for {Large-Scale} machine learning. In *12th USENIX symposium on operating systems design and implementation (OSDI 16)*. 265–283.
- [2] Luai Al Shalabi, Ziyad Shaaban, and Basel Kasasbeh. 2006. Data mining: A pre-processing engine. *Journal of Computer Science* 2, 9 (2006), 735–739.
- [3] Josef Bauer and Dietmar Jannach. 2021. Improved Customer Lifetime Value Prediction With Sequence-To-Sequence Learning and Feature-Based Models. *ACM Transactions on Knowledge Discovery from Data (TKDD)* 15, 5 (2021), 1–37.
- [4] Albert C Bemmaro and Nicolas Gladys. 2012. Modeling purchasing behavior with sudden “death”: A flexible customer lifetime model. *Management Science* 58, 5 (2012), 1012–1021.
- [5] Christopher M Bishop. [n. d.]. *Pattern recognition and machine learning*. Vol. 4. Springer.
- [6] Benjamin Paul Chamberlain, Angelo Cardoso, CH Bryan Liu, Roberto Pagliari, and Marc Peter Deisenroth. 2017. Customer lifetime value prediction using embeddings. In *Proceedings of the 23rd ACM SIGKDD international conference on knowledge discovery and data mining*. 1753–1762.
- [7] Bo Chen, Xiangyu Zhao, Yejing Wang, Wenqi Fan, Huifeng Guo, and Ruiming Tang. 2024. A Comprehensive Survey on Automated Machine Learning for Recommendations. *ACM Trans. Recomm. Syst.* 2, 2, Article 13 (apr 2024), 38 pages.
- [8] Pei Chen, Anna Guitart, Ana Fernández del Río, and Africa Perianez. 2018. Customer lifetime value in video games using deep learning and parametric models. In *2018 IEEE international conference on big data (big data)*. IEEE, 2134–2140.
- [9] Richard Colombo and Weina Jiang. 1999. A stochastic RFM model. *Journal of Interactive Marketing* 13, 3 (1999), 2–12.
- [10] Anders Drachen, Mari Pastor, Aron Liu, Dylan Jack Fontaine, Yuan Chang, Julian Runge, Rafet Sifa, and Diego Klabjan. 2018. To be or not to be... social: Incorporating simple social features in mobile game customer lifetime value predictions. In *proceedings of the australasian computer science week multiconference*. 1–10.
- [11] Peter S Fader and Bruce GS Hardie. 2009. Probability models for customer-base analysis. *Journal of interactive marketing* 23, 1 (2009), 61–69.
- [12] Peter S Fader, Bruce GS Hardie, and Ka Lok Lee. 2005. RFM and CLV: Using iso-value curves for customer base analysis. *Journal of marketing research* 42, 4 (2005), 415–430.
- [13] Peter S Fader, Bruce GS Hardie, and Ka Lok Lee. 2005. “Counting your customers” the easy way: An alternative to the Pareto/NBD model. *Marketing science* 24, 2 (2005), 275–284.
- [14] Emil Julius Gumbel. 1954. *Statistical theory of extreme values and some practical applications: a series of lectures*. Vol. 33. US Government Printing Office.
- [15] Huifeng Guo, Bo Chen, Ruiming Tang, Weinan Zhang, Zhenguo Li, and Xiuqiang He. 2021. An embedding learning framework for numerical features in ctr prediction. In *Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining*. 2910–2918.
- [16] Huifeng Guo, Ruiming Tang, Yunming Ye, Zhenguo Li, and Xiuqiang He. 2017. DeepFM: a factorization-machine based neural network for CTR prediction. *arXiv preprint arXiv:1703.04247* (2017).
- [17] Bowei He, Yunpeng Weng, Xing Tang, Ziqiang Cui, Zexu Sun, Liang Chen, Xiuqiang He, and Chen Ma. 2024. Rankability-enhanced Revenue Uplift Modeling Framework for Online Marketing. *arXiv preprint arXiv:2405.15301* (2024).
- [18] Eric Jang, Shixiang Gu, and Ben Poole. 2016. Categorical reparameterization with gumbel-softmax. *arXiv preprint arXiv:1611.01144* (2016).
- [19] Fuxian Li, Jie Feng, Huan Yan, Guangyin Jin, Fan Yang, Funing Sun, Depeng Jin, and Yong Li. 2023. Dynamic graph convolutional recurrent network for traffic prediction: Benchmark and solution. *ACM Transactions on Knowledge Discovery from Data* 17, 1 (2023), 1–21.
- [20] Kunpeng Li, Guancui Shao, Naijun Yang, Xiao Fang, and Yang Song. 2022. Billion-user Customer Lifetime Value Prediction: An Industrial-scale Solution from Kuaishou. In *Proceedings of the 31st ACM International Conference on Information & Knowledge Management*. 3243–3251.
- [21] Yujun Li, Xing Tang, Bo Chen, Yimin Huang, Ruiming Tang, and Zhenguo Li. 2023. AutoOpt: Automatic Hyperparameter Scheduling and Optimization for Deep Click-through Rate Prediction. In *Proceedings of the 17th ACM Conference on Recommender Systems (Singapore, Singapore) (RecSys '23)*. Association for Computing Machinery, New York, NY, USA, 183–194.
- [22] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. 2017. Focal loss for dense object detection. In *Proceedings of the IEEE international conference on computer vision*. 2980–2988.
- [23] Hanxiao Liu, Karen Simonyan, and Yiming Yang. 2018. Darts: Differentiable architecture search. *arXiv preprint arXiv:1806.09055* (2018).
- [24] Wenshuang Liu, Guoqiang Xu, Bada Ye, Xinji Luo, Yancheng He, and Cunxiang Yin. 2024. MDAN: Multi-distribution Adaptive Networks for LTV Prediction. In *Pacific-Asia Conference on Knowledge Discovery and Data Mining*. Springer, 409–420.
- [25] Yuanfei Luo, Mengshuo Wang, Hao Zhou, Quanming Yao, Wei-Wei Tu, Yuqiang Chen, Wenyan Dai, and Qiang Yang. 2019. Autocross: Automatic feature crossing for tabular data in real-world applications. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. 1936–1945.
- [26] Fuyuan Lyu, Xing Tang, Huifeng Guo, Ruiming Tang, Xiuqiang He, Rui Zhang, and Xue Liu. 2022. Memorize, Factorize, or be Naive: Learning Optimal Feature Interaction Methods for CTR Prediction. In *2022 IEEE 38th International Conference on Data Engineering (ICDE)*. 1450–1462. <https://doi.org/10.1109/ICDE53745.2022.00113>
- [27] Fuyuan Lyu, Xing Tang, Dugang Liu, Liang Chen, Xiuqiang He, and Xue Liu. 2023. Optimizing Feature Set for Click-Through Rate Prediction. In *Proceedings of the ACM Web Conference 2023 (Austin, TX, USA) (WWW '23)*. Association for Computing Machinery, New York, NY, USA, 3386–3395. <https://doi.org/10.1145/3543507.3583545>
- [28] Fuyuan Lyu, Xing Tang, Hong Zhu, Huifeng Guo, Yingxue Zhang, Ruiming Tang, and Xue Liu. 2022. OptEmbed: Learning Optimal Embedding Table for Click-through Rate Prediction. In *Proceedings of the 31st ACM International Conference on Information & Knowledge Management (CIKM '22)*. Association for Computing Machinery, New York, NY, USA, 1399–1409.
- [29] Xiao Ma, Liqin Zhao, Guan Huang, Zhi Wang, Zelin Hu, Xiaoqiang Zhu, and Kun Gai. 2018. Entire space multi-task model: An effective approach for estimating post-click conversion rate. In *The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval*. 1137–1140.
- [30] Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. 2013. Efficient Estimation of Word Representations in Vector Space. [arXiv:1301.3781 \[cs.CL\]](https://arxiv.org/abs/1301.3781)
- [31] Hieu Pham, Zihang Dai, Qizhe Xie, and Quoc V. Le. 2021. Meta Pseudo Labels. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 11557–11568.
- [32] David C Schmittlein, Donald G Morrison, and Richard Colombo. 1987. Counting your customers: Who are they and what will they do next? *Management science* 33, 1 (1987), 1–24.
- [33] Hongzu Su, Zhekai Du, Jingjing Li, Lei Zhu, and Ke Lu. 2023. Cross-Domain Adaptive Learning for Online Advertisement Customer Lifetime Value Prediction. *Proceedings of the AAAI Conference on Artificial Intelligence* 37, 4 (Jun. 2023), 4605–4613.
- [34] Xing Tang, Yang Qiao, Fuyuan Lyu, Dugang Liu, and Xiuqiang He. 2024. Touch the Core: Exploring Task Dependence Among Hybrid Targets for Recommendation. *CoRR abs/2403.17442* (2024). <https://doi.org/10.48550/ARXIV.2403.17442> [arXiv:2403.17442](https://arxiv.org/abs/2403.17442)
- [35] Ali Vanderveld, Adhyan Pandey, Angela Han, and Rajesh Parekh. 2016. An engagement-based customer lifetime value system for e-commerce. In *Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining*. 293–302.
- [36] Ruoxi Wang, Rakesh Shivanna, Derek Cheng, Sagar Jain, Dong Lin, Lichan Hong, and Ed Chi. 2021. Dcn v2: Improved deep & cross network and practical lessons for web-scale learning to rank systems. In *Proceedings of the web conference 2021*. 1785–1797.
- [37] Xiaojing Wang, Tianqi Liu, and Jingang Miao. 2019. A deep probabilistic model for customer lifetime value prediction. *arXiv preprint arXiv:1912.07753* (2019).
- [38] Yunpeng Weng, Xing Tang, Liang Chen, Dugang Liu, and Xiuqiang He. 2024. Expected Transaction Value Optimization for Precise Marketing in FinTech Platforms. *arXiv preprint arXiv:2401.01525* (2024).
- [39] Mingzhe Xing, Shuqing Bian, Wayne Xin Zhao, Zhen Xiao, Xinji Luo, Cunxiang Yin, Jing Cai, and Yancheng He. 2021. Learning Reliable User Representations from Volatile and Sparse Data to Accurately Predict Customer Lifetime Value. In *Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining*. 3806–3816.
- [40] Xuejiao Yang, Binfeng Jia, Shuangyang Wang, and Shijie Zhang. 2023. Feature Missing-aware Routing-and-Fusion Network for Customer Lifetime Value Prediction in Advertising. In *Proceedings of the Sixteenth ACM International Conference on Web Search and Data Mining*. 1030–1038.
- [41] Shijie Zhang, Xin Yan, Xuejiao Yang, Binfeng Jia, and Shuangyang Wang. 2023. Out of the Box Thinking: Improving Customer Lifetime Value Modelling via Expert Routing and Game Whale Detection. In *Proceedings of the 32nd ACM International Conference on Information and Knowledge Management (CIKM '23)*. Association for Computing Machinery, New York, NY, USA, 3206–3215.
- [42] Shiwei Zhao, Runze Wu, Jianrong Tao, Manhu Qu, Minghao Zhao, Changjie Fan, and Hongke Zhao. 2023. perCLTV: A general system for personalized customer lifetime value prediction in online games. *ACM Transactions on Information Systems* 41, 1 (2023), 1–29.
- [43] Xiangyu Zhao, Haochen Liu, Wenqi Fan, Hui Liu, Jiliang Tang, and Chong Wang. 2021. Autoloss: Automated loss function search in recommendations. In *Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining*. 3959–3967.
- [44] Xiangyu Zhao, Haochen Liu, Wenqi Fan, Hui Liu, Jiliang Tang, Chong Wang, Ming Chen, Xudong Zheng, Xiaobing Liu, and Xiwang Yang. 2021. Autoemb: Automated embedding dimensionality search in streaming recommendations.

- In *2021 IEEE International Conference on Data Mining (ICDM)*. IEEE, 896–905.
- [45] Xiangyu Zhao, Haochen Liu, Hui Liu, Jiliang Tang, Weiwei Guo, Jun Shi, Sida Wang, Huiji Gao, and Bo Long. 2020. Memory-efficient embedding for recommendations. *arXiv preprint arXiv:2006.14827* (2020).
- [46] Ruiqi Zheng, Liang Qu, Bin Cui, Yuhui Shi, and Hongzhi Yin. 2023. AutoML for Deep Recommender Systems: A Survey. *ACM Trans. Inf. Syst.* 41, 4, Article 101 (mar 2023), 38 pages. <https://doi.org/10.1145/3579355>