

向未来学习：面向序列推荐的特权自蒸馏

Jiakai Tang^{1,3}, Yang Zhang², See-Kiong Ng², Xu Chen¹✉, Wen Chen³✉, Jian Wu³, Han Zhu³

¹ 中国人民大学高瓴人工智能学院, 北京, 中国

² 新加坡国立大学, 新加坡

³ 阿里巴巴集团, 北京, 中国

tangjiakai5704@ruc.edu.cn

摘要

序列推荐器通常采用独热的下一物品标签, 并基于与推理过程一致的因果(即仅前缀)目标进行训练。尽管这种监督方式与部署兼容, 但它几乎无法提供非目标物品之间相对偏好的信息。然而, 已记录的交互序列还蕴含着另一种监督来源: 目标之后发生的交互往往能够揭示用户意图的演变方式, 使目标更易于理解。我们将这些未来交互视为仅在训练时可用的特权信息——学习阶段可用, 但推理阶段不可用。这自然引出了一个问题: 能否在保持训练方式与模型推理时的预测方式一致的同时, 让未来交互充当更丰富的监督信号?

我们提出**特权自蒸馏 (Privileged Self-Distillation, PSD)**, 这是一个将学习时所用信息与推理时可用信息分离的简单框架。PSD 对同一个序列骨干网络应用两种注意力掩码: 未来感知视图基于过去和未来交互生成**特权教师**分布, 而仅前缀视图则生成用于部署的**学生**分布。通过蒸馏特权分布, 未来交互被转化为仅用于训练的监督, 而非推理时的输入。由于两个视图共享骨干网络, 教师的优势来自信息而非架构, 因而无需单独预训练教师, 并且其监督能够随学生的演进而自适应变化。PSD 还采用优势可达性门控, 将蒸馏聚焦于更可能由已观察前缀支持的教师信号, 并结合动量平均教师来稳定蒸馏目标。整个框架以单阶段端到端方式优化, 部署模型及其推理成本均保持不变。在多个公开基准和多种序列骨干网络上的大量实验表明, 相较于强基线, 该方法能够取得稳定且显著的提升。

CCS 概念

• 信息系统 → 推荐系统; 个性化; • 计算方法 → 机器学习。

关键词

序列推荐, 特权信息, 自蒸馏

1 引言

序列推荐根据用户的历史行为预测其下一次交互 [2, 18, 31]。在部署时, 推荐器只能观察用户过去的交互, 并为下一步对候选物品进行排序。为匹配这一部署条件, 现代序列推荐器通常采用下一物品预测, 即因果模型根据观察到的前缀估计下一物品分布, 并利用观察到的物品进行交叉熵优化。这种硬标签监督与服务兼容, 但信息量较低 [24]: 它过度自信地将全部概率质量赋予观察到的目标, 却使非目标候选物品之间的相对偏好在很大程度上缺乏约束。因此, 每个训练位置仅提供一个独热目标, 而记录轨迹的其余部分在训练期间并未被用作监督。

然而, 轨迹中这部分未使用的内容本身蕴含着可利用的信号。在训练时, 同一序列的未来后缀同样可见; 这些未来交互往往反映了潜在且不断演变的用户意图, 使当前目标更易于理解, 从而降低观察到的下一物品的不确定性, 并提供超越独热标签的监督。从这个意义上说, 未来交互充当了仅用于训练的特权信息 [16, 30]: 它在学习期间具有信息价值, 但在服务期间不可

✉ 共同通讯作者。




图 1: 随着未来交互的可见比例增加 (0% → 100%), HR@20、NDCG@20 以及目标物品平均排名的相对提升。即使仅能看到部分未来信息, 也会带来显著增益, 这表明未来交互所携带的预测信号远超因果模型仅从前缀中提取的信息。

用。这创造了一个有用却需要谨慎处理的机会: 未来交互可以丰富训练信号, 但部署的推荐器仍必须保持严格因果性。核心问题是**如何在服务时不使用未来信息的前提下向未来学习**。

一种看似直接的解决方案, 是在训练时让模型同时关注过去和未来交互。BERT4Rec [23] 中的掩码物品预测等双向目标遵循了这一直觉, 相比纯因果的下一物品预测, 它们能够利用更丰富的上下文。然而, 这会将内在的学习问题从因果下一物品预测转变为借助不可用上下文进行重建。所得模型或许能够学习有用的相关性, 但其预测路径不再与推理时使用的路径一致。图 1 从诊断角度展示了这一矛盾: 未来信息的可见性能够提升排序质量, 却也会在特权模型能够推断的信息与因果模型能够访问的信息之间造成差距。因此, 我们需要一种机制, 在从未来上下文中提取训练信号的同时, 确保部署的预测器保持严格因果性。

知识蒸馏 [5, 17, 37] 为分离这两种角色提供了一种自然方式: 特权教师可以利用更丰富的训练信息进行学习, 并将软标签监督传递给可部署的学生。然而, 传统蒸馏并未直接解决未来上下文特权信息所带来的约束。一些方法依赖单独训练的教师或紧凑模型迁移流程 [28]; 另一些方法则从额外标签来源、侧信息或交互序列之外收集的特权特征中获取监督 [33, 34, 36]。这些选择往往会引入额外参数、辅助特征或多阶段训练流程, 还可能导致静态教师与持续演进的学生之间不匹配: 教师被冻结或独立优化, 而学生仍在不断更新。近期研究也表明, 对于能力较弱的学生而言, 一个初始很强但固定不变的教师并不总是最佳监督者 [1, 6]。

这些局限表明, 可以采用一种替代方案: 不引入更强的教师, 而是让同一模型接触每个日志序列的两种视图。其中一种视图利用未来后缀构造特权训练信号, 另一种仍保持因果性, 并与推理时的信息路径一致。这使教师的优势保留在序列自身之内, 同时避免了额外参数、侧信息特征或独立的教师训练阶段。然而, 耦合这两种视图会带来两个并非显而易见的问题。(1) 特权教师将其大部分额外见解编码为对非目标物品的软偏好, 这对学生而言是一种**暗知识**; 但其中并非所有内容都能传递给因果学生: 有些偏好只有在未来后缀的支持下才成立, 强迫因果学生模仿这些无法触及的部分, 就是要求它使用部署时永远无法观测到的证据来解释选择。(2) 教师并非独立的监督来源: 它与

学生共享尚在学习的参数，因此每一步都会由尚未成熟的模型重新生成软目标，而其错误又会通过蒸馏回写至共享权重，进而重塑下一轮目标。缺乏稳定的参照时，错误会被自我确认而非纠正，特权信号也可能淹没于这种反馈循环中。

为解决这些问题，我们提出 **特权自蒸馏 (Privileged Self-Distillation, PSD)**，这是一个基于单个 Transformer 的单模型双角色框架。PSD 在两种注意力掩码下评估同一主干网络：双向掩码产生同时以过去和未来交互为条件的特权教师分布，因果掩码则产生推理时使用的学生分布。特权分布通过教师到学生的 KL 蒸馏传递给因果学生，但并非所有教师信号都被同等对待。PSD 应用一个优势可达性门控，在每个小批次内丢弃高差异的蒸馏项，从而将学习聚焦于更有可能从因果前缀中获得的特权信号。为稳定这种自指的监督，PSD 还维护了一个动量平均教师，其缓慢演化的参数能够平均掉瞬时错误，而不是强化它们。

我们的主要贡献概括如下：

- 我们将未来交互识别为序列推荐器的仅训练时特权信息，在保持因果部署约束的同时，挖掘出低信息量独热下一物品标签之外的监督信号。
- 我们提出特权自蒸馏，这是一个简单而有效的框架，它通过控制注意力掩码构造特权教师和因果学生，无需额外参数、辅助特征或多阶段训练。
- 我们在公开基准、多种序列主干网络和诊断性分析上提供了广泛的实证，表明 PSD 能够带来一致且显著的提升。

2 预备知识

2.1 任务定义

在序列推荐中，每个用户都会留下一个按时间顺序排列的交互序列 $\mathcal{S} = (i_1, i_2, \dots, i_L)$ ，其中每个物品 i_t 都属于物品集合 $\mathcal{I}$ 。给定前缀 $\mathcal{S}_{<t} = (i_1, \dots, i_{t-1})$ ，任务是识别用户在位置 t 上交互的物品。因此，带有参数 θ 的推荐器通过在物品集合 $\mathcal{I}$ 上进行 softmax 来对所有候选项排序：

$$p_\theta(\cdot | \mathcal{S}_{<t}) = \text{softmax}(\mathbf{z}_{\theta,t}), \quad (1)$$

其中，logit $\mathbf{z}_{\theta,t}$ 在因果注意力掩码下产生，该掩码限制每个位置只能关注其自身及前驱位置，从而使 $\mathbf{z}_{\theta,t}$ 仅为前缀 $\mathcal{S}_{<t}$ 的函数。标准学习目标是日志序列语料库 $\mathcal{D}$ 上的下一物品交叉熵，定义为：

$$\mathcal{L}_{\text{CE}}(\theta) = -\frac{1}{|\mathcal{D}|} \sum_{\mathcal{S} \in \mathcal{D}} \sum_{t=1}^{|\mathcal{S}|} \log p_\theta(i_t | \mathcal{S}_{<t}). \quad (2)$$

最小化式 (2) 可使训练与实际服务保持一致，因为部署的模型同样只依据前缀对候选物品进行排序。这种一致性的代价在于监督信号本身：独热标签只表达观察到的物品，对其他所有物品均不提供信息，因此每个训练位置只会提高单个目标的似然，而对目录中其余物品的排序基本不加约束。于是，模型在服务时被要求生成完整排序，却在训练期间从未被告知除观察到的物品之外，怎样的排序才是良好的排序。

2.2 作为特权信息的未来

然而，训练数据中已经存在更丰富的信号，却被因果目标所忽略。对于位置 t 上的目标，后缀 $\mathcal{S}_{>t} = (i_{t+1}, \dots, i_L)$ 在训练时完全可观测，但在部署时永远无法获得。这正是特权信息 [16, 30] 的设定：这种辅助视图可为学习提供信息，但不得进入部署后的预测器。后缀之所以有信息量，是因为用户行为具有时间连

贯性：紧随 i_t 之后的交互记录了用户兴趣的演变，提供了回溯性上下文，能在前缀所揭示信息的基础上进一步缩小合理目标的范围。形式化地说，它所消除的目标不确定性即为条件互信息

$$I(i_t; \mathcal{S}_{>t} | \mathcal{S}_{<t}) = H(i_t | \mathcal{S}_{<t}) - H(i_t | \mathcal{S}_{<t}, \mathcal{S}_{>t}) \geq 0, \quad (3)$$

只要给定过去时未来对目标具有预测能力，该值就严格为正。因此，同时以两侧信息为条件的预测器所获得的标签视图具有更低的熵，因而其贝叶斯风险也低于任何仅限于前缀的预测器。

这种不对称性无法在推理时弥合，因为模型一旦部署， $\mathcal{S}_{>t}$ 就不复存在。尽管如此，只要将未来用于塑造学习目标而不是输入预测路径，训练阶段仍可利用这种不对称性。我们通过同一个推荐器在不同信息集下产生的两个条件分布来形式化这一思路：一个特权教师模型

$$p_\theta^T(\cdot | \mathcal{S}_{<t}, \mathcal{S}_{>t}), \quad (4)$$

同时读取前缀和后缀；一个因果学生模型

$$p_\theta^S(\cdot | \mathcal{S}_{<t}), \quad (5)$$

仅限于前缀，并且是服务时唯一使用的分布。教师模型相对于学生模型的优势，恰好就是式 (3) 所量化的信息。然而，这一差距是一种双刃剑信号：教师模型的一部分置信度源于学生模型能够从前缀中恢复的模式，另一部分则完全依赖未来后缀，在推理时本质上不可获得。下一节要解决的核心问题是：如何将这种特权信号中可获得的部分传递给因果学生模型，同时抑制前缀永远无法佐证的部分。

3 方法

PSD 的架构概述见图 2。PSD 基于一个简单的观察：特权教师无需是第二个模型。通过在两种注意力掩码下进行评估，单个序列骨干网络即可同时承担两种角色，其中特权掩码在训练期间向教师模型开放未来后缀，而因果掩码将学生模型限制在服务时所用的信息路径上。由于两个视图共享所有嵌入、Transformer 层和预测头，教师模型的优势完全源于更丰富的信息访问，而非额外容量。在这一构造之上，我们设计了两种机制来解决引言中指出的问题：优势可达性门控将蒸馏限制在因果前缀能够支撑的信号上（第 3.2 节），动量平均教师则保持自指监督的稳定性（第 3.3 节）。

3.1 双掩码教师与学生

教师模型与学生模型的区别仅在于其注意力范围。在训练位置 t 处，学生模型与部署条件一致，仅关注前缀：

$$\mathcal{A}_t^S = \{k | k < t\}. \quad (6)$$

教师采用一个训练时的感受野，它还覆盖了后缀：

$$\mathcal{A}_t^T = \mathcal{R}_t \cup \{k | k > t\}, \quad (7)$$

其中， $\mathcal{R}_t \subseteq \mathcal{A}_t^S$ 是从骨干网络继承的前缀内部可见性模式：对于 SASRec 等自回归骨干网络，它仍保持因果性；对于 BERT4Rec 等骨干网络，则可以是完全双向的。无论哪种情况，目标物品 i_t 都会被排除在其自身的感受野之外，以防止标签泄漏；同时，学生模型永远不会观察后缀 $\mathcal{S}_{>t}$ ，从而保证部署后的模型严格满足因果性。两个感受野被转换为二值注意力掩码 $\mathbf{M}^S, \mathbf{M}^T \in \{0, 1\}^{L \times L}$ ，其中，当且仅当位置 t 可以关注位置 k 时， $\mathbf{M}_{t,k} = 1$ ，i.e., $k \in \mathcal{A}_t$ 。




图 2: PSD 概览。同一个 Transformer 骨干网络在两种注意力掩码下进行评估：因果掩码将学生模型限制在前缀 $S_{<t}$ ，而特权掩码还向教师模型开放后缀 $S_{>t}$ ，所有参数共享并共同演化。教师模型通过 $\mathcal{L}_{CE}^T$ 以观测到的目标为依据，其动量平均分布 $\bar{p}^T$ 通过门控蒸馏损失 $\mathcal{L}_{KD}^S$ 监督学生模型，从而屏蔽因果前缀无法支撑的高差异暗知识。推理时仅使用因果学生模型。

令 $f_\theta(\mathcal{S}; M)$ 表示在注意力掩码 M 下评估的骨干网络。每种掩码各进行一次前向传播，得到

$$\begin{aligned} h_t^S &= f_\theta(\mathcal{S}; M^S)_t, & p_t^S &= \text{softmax}(W h_t^S), \\ h_t^T &= f_\theta(\mathcal{S}; M^T)_t, & p_t^T &= \text{softmax}(W h_t^T), \end{aligned} \quad (8)$$

其中输出投影 W 由两者共享。两个视图接受非对称监督。教师模型从目标的两侧观察目标，并通过下一物品交叉熵目标以观测到的物品为依据，该目标形式化定义为：

$$\mathcal{L}_{CE}^T = -\frac{1}{|\mathcal{B}|} \sum_{(S,t) \in \mathcal{B}} \log p_t^T(i_t), \quad (9)$$

其中小批量 $\mathcal{B}$ 由序列-位置对组成。相比之下，学生模型不接受直接的独热监督：它并非在严格更弱的信息集上拟合同一个硬标签，而是被训练为匹配教师模型的预测分布。具体而言，其在位置 t 处的目标是从教师到学生的 KL 散度

$$d_t = D_{KL}(\text{sg}(p_t^T) || p_t^S), \quad (10)$$

其中 $\text{sg}(\cdot)$ 阻止梯度流入教师目标，从而使特权知识只沿单一方向传递。这种分工使特权视图能够吸收已观测的目标，而因果视图则获得仅靠目标本身无法传达的软化偏好结构。

3.2 门控特权蒸馏

通过式 (10)，学生从教师处继承了遍及整个物品集合的偏好结构，这是一种严格比独热标签更丰富的监督信号。然而，并非每个位置都值得进行这种传递。散度 d_t 本身提供了一个自然的选择准则，因为它衡量每个位置上学生的因果预测与教师的特权预测之间的差异。如果每一项教师偏好都能从前缀中恢复，那么在批次内均匀平均 d_t 就足够了。但在实践中，较大的 d_t 可能源于两种原因：① 教师可能依赖仅后缀中可用的证据；或者② 该模式可能超出学生在当前训练阶段的吸收能力。无论哪种情况，强制立即匹配都会施加学生尚无法证成的监督，使特权信号由引导来源变为干扰源。

为解决上述问题，PSD 引入了一个 **优势可达性门控**，将蒸馏限制在特权信号可传递的位置上。给定小批次 $\mathcal{B}$ ，令

$$\gamma_\delta = \text{Percentile}_\delta(\{d_t \mid (S,t) \in \mathcal{B}\}) \quad (11)$$

表示该批次内差异的第 δ 百分位数，并将每个位置的门控指示量定义为

$$g_t = \mathbb{I}(d_t \leq \gamma_\delta). \quad (12)$$

蒸馏损失仅在被接纳的位置上计算：

$$\mathcal{L}_{KD}^S = \frac{\sum_{(S,t) \in \mathcal{B}} g_t d_t}{\sum_{(S,t) \in \mathcal{B}} g_t}. \quad (13)$$

被门控拒绝的位置并未从学习中丢弃：它们仍通过 $\mathcal{L}_{CE}^T$ 为教师提供真实目标约束，但其软目标不会传递给学生。该门控因此得名：较小的 d_t 表示教师优势已可由前缀达到，而较大的 d_t 则对应尚不可迁移的优势，其原因可能是该优势完全建立在后缀之上，也可能是它超出了学生当前的能力。此外，这种拒绝并非永久性的：百分位数 δ 控制每个批次中参与蒸馏的位置比例，并且由于 γ_δ 会在每个批次内重新计算，训练早期被暂缓的位置可能会随着学生能力提升而重新进入蒸馏过程。因此，该准则无需依赖固定的绝对阈值，便能同时适应差异尺度的动态变化以及学生能力的持续增长。

3.3 动量平均教师

PSD 中的教师并非固定的预言机：它由仍在更新的同一组参数产生，因此其在单个步骤中的预测可能编码了当前模型状态的瞬时错误。为了稳定这种自指的监督，遵循先前工作 [3, 7, 29]，PSD 将模型参数 θ 的指数移动平均 (EMA) 维护为 $\bar{\theta}$ 。在每个训练步骤中，EMA 通过以下递归公式更新：

$$\bar{\theta}^{(r)} = \alpha \bar{\theta}^{(r-1)} + (1 - \alpha) \theta^{(r)}, \quad (14)$$

其中， r 表示训练步， $\alpha \in [0, 1]$ 控制平滑程度，且 $\bar{\theta}^{(0)}$ 初始化为 $\theta^{(0)}$ 。随后，该平均模型在特权掩码下生成蒸馏目标，

$$\bar{p}_t^T = \text{softmax}(\bar{W} f_{\bar{\theta}}(\mathcal{S}; M^T)_t), \quad (15)$$

因此，式 (10) 始终是针对 $\bar{p}_t^T$ 而非瞬时的 p_t^T 进行计算。由于 $\bar{\theta}$ 聚合了整个优化轨迹，任一单步的瞬时错误都会随时间被平均掉，而不会被回写到共享权重中。平均参数的更新不使用梯度，它仅在训练期间存在，不会改变推理图。

算法 1 PSD 的训练流程

输入： 训练语料 $\mathcal{D}$ ；骨干网络 f_θ ；门控百分位数 δ ；EMA 比率 α

- 1: 初始化参数 θ ；EMA 参数 $\bar{\theta} \leftarrow \theta$
- 2: **当** 未收敛 **时**
- 3: 采样一个小批次 $\mathcal{B}$ ，其中包含序列-位置对 $(\mathcal{S}, t)$
- 4: $p_t^S \leftarrow$ 对 f_θ 在因果掩码 M^S 下进行前向传播 ▷ 式 (8)
- 5: $p_t^T \leftarrow$ 对 f_θ 在特权掩码 M^T 下进行前向传播
- 6: $\bar{p}_t^T \leftarrow$ 对 f_θ 在 M^T 下进行无梯度前向传播 ▷ 式 (15)
- 7: $d_t \leftarrow D_{\text{KL}}(\bar{p}_t^T \| p_t^S)$ ，对每个 $(\mathcal{S}, t) \in \mathcal{B}$
- 8: $\gamma_\delta \leftarrow$ 为 δ -th 百分位数，其对象为 $\{d_t\}$ ； $g_t \leftarrow \mathbb{I}(d_t \leq \gamma_\delta)$ ▷ 式 (12)
- 9: $\mathcal{L}_{\text{KD}}^S \leftarrow (\sum_t g_t d_t) / \sum_t g_t$
- 10: $\mathcal{L}_{\text{PSD}} \leftarrow \mathcal{L}_{\text{CE}}^T + \mathcal{L}_{\text{KD}}^S$
- 11: 更新 θ ，方式为沿 $\nabla_\theta \mathcal{L}_{\text{PSD}}$ 的下降方向
- 12: $\bar{\theta} \leftarrow \alpha \bar{\theta} + (1 - \alpha) \theta$ ▷ 式 (14)
- 13: **结束 当**
- 14: **返回** 因果学生 p_t^S ，在掩码 M^S 下用于服务

3.4 优化目标

本小节介绍整体训练目标，并说明 PSD 在推理时的行为。模型通过单一目标进行端到端优化：它使教师以已观测目标为根基，并通过门控蒸馏引导学生：

$$\mathcal{L}_{\text{PSD}} = \mathcal{L}_{\text{CE}}^T + \mathcal{L}_{\text{KD}}^S. \quad (16)$$

值得注意的是，该目标中没有学生交叉熵项：因果视图完全由教师的软化分布塑造，而不是由独热目标塑造。由于两项损失作用于同一组共享参数，教师和学生训练期间会**共同演进**：每次更新都会优化教师的特权视图，而这一优化结果将在下一轮蒸馏中传递给学生，因此指导信号能够跟上学生能力的变化，不会像冻结教师那样逐渐过时。

整个模型以单阶段方式训练，无需任何预训练或教师预热阶段；算法 1 概述了完整流程。在推理时，推荐结果仅由因果掩码下的学生分布 p_t^S 生成。因此，部署模型及其服务成本与原始骨干网络完全相同，不会增加额外参数或额外前向传播。

3.5 讨论

本节讨论 PSD 与推荐领域代表性蒸馏方法的差异，比较结果汇总于表 1。本质区别在于教师优势的来源。现有方法从部署模型之外引入这种优势：RD [28] 依赖单独预训练的排序模型，PFD [36] 依赖场景特定的特权特征，而这些特征的可获得性很难在不同场景间泛化；CSRec [34] 和 S⁴Rec [33] 则依赖附加到主干网络上的辅助教师模块。然而，这种外部教师至少会在以下三个方面之一付出代价：

- **额外参数：** 所有对比方法都需要维护部署模型永远不会使用的教师组件，而 PSD 的教师仅通过注意力掩码便可从部署主干网络中诱导得到，因此我们的自蒸馏框架不需要原始主干网络之外的额外参数。
- **辅助特征：** PFD 要求在生产环境中收集和维持特权特征，而我们所提方法的特权信号——用户序列的未来后缀——已存在于每个日志序列中。
- **训练流水线：** RD 在蒸馏前预训练其教师，CSRec 涉及多阶段优化，而 PSD 在单一阶段中联合优化两个损失项。

表 1: PSD 与代表性推荐蒸馏训练策略的比较。

方法	无需额外参数	无需辅助特征	单阶段训练
RD [28]	✗	✓	✗
PFD [36]	✗	✗	✓
CSRec [34]	✗	✓	✗
S ⁴ Rec [33]	✗	✓	✓
PSD (本文方法)	✓	✓	✓

这些特性的意义不仅是工程经济性。由于 PSD 的教师与学生共享参数空间，其指导会在每次更新时得以刷新，从而产生上文分析的共演化监督；此外，由于该构造除注意力掩码外不需要任何其他内容，PSD 无需修改或额外特征便可应用于任何序列主干网络，成为面向 Transformer 序列推荐器的通用训练策略。

4 实验**4.1 实验设置**

4.1.1 数据集。 我们在三个广泛使用的基准上开展实验：Amazon 评论语料库 [10] 的两个子集 **Video Games** 和 **CDs & Vinyl**，以及 **Yelp** 商家评论数据集。对于 Amazon 子集，我们剔除交互次数少于五次的用户；对于 Yelp，我们采用标准的 5-core 预处理，使每个用户和每个物品均至少保留五次交互。在所有数据集中，只有评分高于 3 的交互才被视为正反馈，其余交互均被移除。为避免时间泄漏，所有数据划分均遵循绝对时间戳：Amazon 子集采用官方发布的训练/验证/测试划分⁰，Yelp 则按时间顺序以 8:1:1 的比例划分。对于基于文本的推荐器，我们保留每个 Amazon 物品的标题、价格和描述，以及每个 Yelp 商家的名称、类别、城市和州，并使用 Qwen3-Embedding-8B [40] 对文本进行编码。表 2 汇总了处理后数据集的统计信息。

4.1.2 基线方法。 为检验 PSD 在不同架构上的通用性，我们将其应用于三种具有代表性的序列推荐骨干网络：SASRec [14]，一种采用下一物品预测训练的单向 Transformer；BERT4Rec [23]，一种采用掩码物品预测训练的双向 Transformer；以及 UniSRec [11]，一种建立在预训练语言表示之上的文本增强推荐器。在每个骨干网络上，我们将 PSD 与原始训练方案（记为 **Base**）以及若干密切相关的训练策略进行比较：Ranking Distillation (RD) [28]，它从单独训练的排序教师进行蒸馏；TCE 和 RCE [32]，它们通过截断或重加权训练损失来抵抗噪声交互；S⁴Rec [33]，一种面向序列推荐的在线自蒸馏策略；以及 CSRec [34] 的三个变体，分别记为 **CS-D**、**CS-M** 和 **CS-T**。为保证公平比较，所有策略均应用于与 PSD 相同的骨干网络，并在验证集上将各方法的超参数调至最佳性能。

4.1.3 评估指标。 遵循既有工作 [25, 26, 38]，我们使用两种标准指标评估 top-K 推荐质量，即命中率 (**HR@K**) 和归一化折损累计增益 (**NDCG@K**)，并报告 $K = 10$ 和 $K = 20$ 下的结果。HR@K 衡量真实物品是否出现在 top-K 列表中，而 NDCG@K 还会对其处于更高位置给予额外奖励。为避免采样偏差，我们将目标物品与完整物品库中的所有物品共同排序。

4.1.4 实现细节。 我们使用 PyTorch 框架实现所有方法。为保证公平比较，所有方法的学习率、批大小和嵌入维度分别固定为 1×10^{-3} 、2048 和 256。dropout 比率和权重衰减分别在 $\{0, 0.1, 0.2, 0.3, 0.4, 0.5\}$ 和 $\{0, 10^{-5}, 10^{-4}, 10^{-3}\}$ 上进行调优。对于

⁰https://amazon-reviews-2023.github.io/data_processing/5core.html

表 2: 基准数据集的统计信息。

数据集	# 用户	# 物品	# 交互	平均长度	稀疏度
Video Games	54,001	22,735	562,193	10.41	99.95%
CDs & Vinyl	89,590	88,462	1,347,178	15.04	99.98%
Yelp	120,827	71,819	1,880,704	15.57	99.98%

PSD, EMA 比率 α 的搜索范围为 $\{0.6, 0.7, 0.8, 0.9, 0.99\}$, 门控百分位数 δ 的搜索范围为 $\{0.6, 0.7, 0.8, 0.9, 0.99, 1.0\}$, 其中 $\delta = 1.0$ 表示禁用门控并对每个位置进行蒸馏。我们采用早停策略, 在验证集上监控 NDCG@20, 耐心值设为 10 个 epoch。需要注意的是, 应用 PSD 时, 无论骨干网络为何, 学生始终执行因果推理; 而教师前缀中的可见性模式 $\mathcal{R}_t$ 则遵循骨干网络自身的惯例, e.g., SASRec 为单向, BERT4Rec 为双向。

4.2 总体性能

总体性能比较见表 3。从表中可以观察到以下几个关键发现:

- 在三个主干模型中, 尽管 BERT4Rec 在训练期间观察到了更丰富的双向上下文, 但其性能通常不及 SASRec, 平均落后近 20%, 并且在 CDs & Vinyl 数据集上的 HR@10 指标最多落后 41.7%。原因在于, 它的掩码物品目标使每次预测都以目标两侧的信息为条件, 而这种上下文在部署时并不存在; 因此, 将未来信息作为输入使用并不能转化为因果排序能力, 除非泄漏的未来信号与部署模式一致, 否则其帮助很小。另一方面, UniSRec 得益于预训练文本表示所承载的丰富语义, 在三个主干模型中取得了最强的基础性能。
- 没有任何基线策略能够始终保持竞争力。RD 的监督来自单独预训练的静态教师, 它在 Video Games 数据集上将 SASRec 的 HR@10 从 0.0455 提高到 0.0509, 却使 UniSRec 从 0.0693 降至 0.0595, 这是因为当主干模型本身变得更强大时, 冻结教师所能提供的提升空间十分有限。去噪目标 TCE 和 RCE 依赖固定的损失重塑启发式方法, 因此仅偶尔有所帮助, 而且往往低于主干模型。配备辅助自蒸馏模块的 S⁴Rec 主要在 Yelp 上排名第二, 将 BERT4Rec 的 NDCG@20 从 0.0306 提高到 0.0358, 但这种优势并未扩展到其他设置; 同样, 三个 CSRec 变体中也没有任何一个相对于其他变体表现出稳定优势。因此, 这些方法的收益无法在不同主干模型和数据集之间可靠迁移, 更不用说它们还需要额外参数、辅助特征或多阶段流水线, 正如第 3.5 节所讨论的那样。
- PSD 在所有主干模型和数据集上均取得了更优性能, 平均比相应主干模型提高 19.8%, 并且在每种设置下平均比最强基线提高 9.9%; 与上述静态监督不同, 其共演化教师在整个训练过程中始终使指导与学生相匹配。BERT4Rec 上的提升最大, 平均达到 35.9%, 并在 CDs & Vinyl 数据集的 NDCG@10 上达到 75.4% 的峰值; 在这里, 与部署模式一致的监督纠正了最严重的不匹配。即便对于基础性能已经很强的文本增强模型 UniSRec, PSD 仍带来了 6.6% 到 13.1% 的平均增益, 这表明特权未来信号与丰富的物品语义具有互补性。值得注意的是, PSD 没有出现任何性能退化, 因为优势可达性门控会阻止传递因果视图尚无法吸收的信号, 而动量平均教师则保持自指监督的稳定性, 从而避免学生受到不可迁移指导的误导。

4.3 未来可见性的影响

我们首先考察特权教师究竟能从未来获益多少, 以及其中有多少收益能够传递给因果学生。在 SASRec 骨干网络上, 我们将训练期间教师可见的后缀比例从 0% 调整到 100%, 图 3 展示了




图 3: 在不同未来信息可见性下, 教师和学生相对于 SASRec 骨干网络的提升。




图 4: 在不同未来信息设置下比较 PSD 与其骨干网络的 Oracle 分析。

两个视图相对于骨干网络的相对提升。教师模型的提升随可见性稳步增长; 在完全可见时, 其在 Video Games 上的 HR@20 提升约达 20%, 这证实后缀包含大量预测信号。学生模型与教师模型同步提升, 获得了约一半的教师增益, 而且其曲线与教师曲线在相同的可见性水平上共同上升和回落; 这种协同变化表明, 学生模型的增益确实继承自特权知识。尽管如此, 各个可见性水平下始终存在明显差距, 且暴露的未来上下文越多, 差距越大。这表明特权优势的一部分完全建立在后缀之上, 永远无法从前缀复现, 而这正是我们的优势可达性门控旨在屏蔽的部分。

4.4 预言机分析

本节进一步量化 PSD 将多少特权知识内化到了因果视图中。对于每个训练好的模型, 我们还评估了一个测试时被赋予特权掩码的预言机变体, 并依据目标在日志中是否记录有未来交互来划分测试样例。图 4 展示了采用 SASRec 骨干网络时在 Video Games 和 Yelp 上的结果, 由此得到以下三点观察:

- 预言机评估仅在未来可用组上显著提升了骨干网络, 而未来自来缺失组保持不变, 这验证了预言机的优势确实来自未来上下文, 而非额外的掩码本身。

表 3: 在三个推荐基准上使用不同主干模型的总体性能。最优和次优结果分别以粗体和下划线 标出。

数据集	主干模型	指标	基础模型	RD	TCE	RCE	S ⁴ Rec	CS-D	CS-M	CS-T	PSD
Video Games	SASRec	HR@10	0.0455	<u>0.0509</u>	0.0479	0.0455	0.0464	0.0485	0.0497	0.0458	0.0538
		HR@20	0.0747	<u>0.0785</u>	0.0741	0.0678	0.0720	0.0735	0.0711	0.0758	0.0818
		NDCG@10	0.0203	<u>0.0230</u>	0.0212	0.0227	0.0222	0.0214	0.0222	0.0209	0.0238
		NDCG@20	0.0276	<u>0.0299</u>	0.0278	0.0283	0.0287	0.0277	0.0276	0.0284	0.0308
	Bert4Rec	HR@10	0.0390	<u>0.0416</u>	0.0360	0.0348	0.0402	0.0396	0.0402	0.0407	0.0476
		HR@20	0.0601	0.0631	0.0577	0.0500	0.0619	<u>0.0645</u>	0.0634	0.0634	0.0690
		NDCG@10	0.0211	0.0218	0.0184	0.0184	0.0219	<u>0.0222</u>	0.0215	0.0221	0.0250
		NDCG@20	0.0264	0.0271	0.0239	0.0222	0.0273	<u>0.0285</u>	0.0273	0.0277	0.0304
	UniSRec	HR@10	0.0693	0.0595	0.0654	0.0574	0.0675	<u>0.0699</u>	0.0696	0.0660	0.0753
		HR@20	0.1044	0.0964	0.1014	0.0925	0.0996	<u>0.1068</u>	0.1032	0.1020	0.1112
		NDCG@10	0.0330	0.0288	0.0308	0.0284	0.0316	<u>0.0335</u>	0.0330	0.0307	0.0350
		NDCG@20	0.0419	0.0380	0.0398	0.0372	0.0397	<u>0.0427</u>	0.0415	0.0397	0.0440
CDs & Vinyl	SASRec	HR@10	0.0415	0.0463	0.0431	0.0418	0.0411	0.0438	<u>0.0464</u>	0.0454	0.0485
		HR@20	0.0582	<u>0.0649</u>	0.0580	0.0560	0.0646	0.0628	0.0631	0.0639	0.0697
		NDCG@10	0.0189	0.0211	0.0196	0.0212	0.0189	0.0208	<u>0.0214</u>	0.0212	0.0226
		NDCG@20	0.0231	0.0258	0.0234	0.0248	0.0249	0.0256	0.0256	<u>0.0259</u>	0.0280
	Bert4Rec	HR@10	0.0242	0.0253	0.0238	<u>0.0296</u>	0.0293	0.0261	0.0251	0.0232	0.0406
		HR@20	0.0380	0.0376	0.0379	<u>0.0448</u>	0.0446	0.0395	0.0392	0.0398	0.0566
		NDCG@10	0.0134	0.0132	0.0127	0.0154	<u>0.0157</u>	0.0141	0.0131	0.0114	0.0235
		NDCG@20	0.0168	0.0163	0.0163	0.0192	<u>0.0196</u>	0.0174	0.0167	0.0156	0.0275
	UniSRec	HR@10	0.0386	0.0392	0.0386	0.0373	0.0398	<u>0.0424</u>	0.0405	0.0405	0.0438
		HR@20	0.0633	0.0607	0.0643	0.0588	<u>0.0652</u>	0.0649	0.0637	0.0631	0.0666
		NDCG@10	0.0188	0.0190	0.0194	0.0183	0.0191	<u>0.0202</u>	0.0199	0.0197	0.0207
		NDCG@20	0.0250	0.0245	<u>0.0259</u>	0.0237	0.0255	0.0258	0.0258	0.0255	0.0264
Yelp	SASRec	HR@10	0.0556	0.0565	0.0550	0.0551	0.0570	<u>0.0574</u>	0.0574	0.0573	0.0608
		HR@20	0.0853	0.0870	0.0849	0.0850	<u>0.0902</u>	0.0877	0.0892	0.0885	0.0931
		NDCG@10	0.0311	0.0307	0.0307	0.0303	0.0307	0.0316	0.0312	<u>0.0317</u>	0.0338
		NDCG@20	0.0386	0.0383	0.0382	0.0378	0.0390	0.0392	0.0392	<u>0.0395</u>	0.0419
	Bert4Rec	HR@10	0.0474	0.0465	0.0457	0.0460	0.0554	0.0483	0.0468	0.0487	0.0578
		HR@20	0.0769	0.0765	0.0754	0.0755	<u>0.0882</u>	0.0804	0.0788	0.0812	0.0917
		NDCG@10	0.0233	0.0232	0.0224	0.0227	<u>0.0276</u>	0.0241	0.0232	0.0249	0.0311
		NDCG@20	0.0306	0.0307	0.0298	0.0301	<u>0.0358</u>	0.0321	0.0312	0.0330	0.0396
	UniSRec	HR@10	0.0596	0.0595	0.0595	0.0600	<u>0.0625</u>	0.0615	0.0620	0.0590	0.0679
		HR@20	0.0971	0.0951	0.0956	0.0956	<u>0.0982</u>	0.0971	0.0982	0.0968	0.1049
		NDCG@10	0.0300	0.0299	0.0304	0.0306	<u>0.0317</u>	0.0311	0.0314	0.0297	0.0352
		NDCG@20	0.0394	0.0388	0.0395	0.0396	<u>0.0407</u>	0.0401	0.0405	0.0392	0.0445

(ii) 因果 PSD 模型无需访问任何未来输入便弥合了这一差距的大部分：其性能接近以预言机方式评估的骨干网络，而且即使在任何模型都没有未来上下文可利用的未来缺失组上，它也优于骨干网络。因此，蒸馏得到的偏好结构能够泛化，而不是依赖测试时未来信息是否可用。

(iii) PSD 的预言机变体同样优于以预言机方式评估的骨干网络，这揭示了共同演化的收益是双向流动的：蒸馏不仅使学生模型获得特权知识，而且改进后的学生模型还会通过共享参数反过来强化特权视图，使其超越单独训练的教师模型所能达到的水平。因此，两个视图通过我们提出的单模型双模式蒸馏相互增强。

4.5 进一步分析

4.5.1 训练动态。 为考察师生交互如何演化，我们跟踪训练期间两个视图的胜率，*i.e.*，其中一个视图将目标排序高于另一个视图的验证位置所占比例。如图 5 所示，教师模型在最初几百步内便升至 50% 的持平线之上，因此特权优势很早就出现，蒸馏信号从一开始便具有信息量。随着训练推进，学生模型在 Video Games 和 Yelp 上逐渐缩小差距，这反映出特权知识中可达的部分正被逐步吸收；在 CDs & Vinyl 上，教师模型始终保持明显领先，这与 PSD 在该数据集上取得最大总体增益相符，说明仍有更多特权信号有待利用。我们还观察到，教师模型的胜率在早期阶段剧烈波动，*e.g.*，在 Yelp 上一度飙升至接近 70%，




图 5: 训练期间特权教师与因果学生的胜率动态。

随后才趋于稳定，这进一步印证了使用动量平均教师来平滑这种瞬态行为的必要性。

4.5.2 参数敏感性。图 6 报告了 PSD 对两个超参数的敏感性。(i) 对于门控百分位数 δ ，Video Games 在 $\delta = 0.8$ 处达到峰值，此时 HR@20 比无门控变体 ($\delta = 1.0$) 高约 7%；而 Yelp 在整个取值范围内的变化都较为温和。这一差异与图 3 一致：Video Games 上的师生差距更大，因此过滤不可达信号在该数据集上收益更明显。(ii) 对于 EMA 速率 α ，中高水平的动量表现最佳，Video Games 和 Yelp 上的最优值分别为 0.8 和 0.99；将 α 推向任一极端都会损害性能，因为较小的 α 会使目标继承瞬时教师的噪声，而 $\alpha = 1.0$ 则会将教师冻结在初始化状态。在整个参数网格中，PSD 始终优于骨干网络，表明这两个超参数在实践中都易于调节。


5 相关工作

5.1 序列推荐

序列推荐根据用户过往行为的时间顺序推断其下一次交互。早期研究使用马尔可夫链对物品转移建模，其中 FPMC 将矩阵分解与个性化转移矩阵相结合 [21]。随后，深度架构占据主导：GRU4Rec 使用循环网络对会话建模 [8]，Caser 将近期行为视为图像并进行卷积 [27]，而自注意力最终成为主流选择，其中 SASRec 进行自回归的下一物品预测 [14]，BERT4Rec 则从双向上下文中重建被掩码的物品 [23]。后续工作从不同角度丰富了这一范式：S³-Rec [42]、CL4SRec [35] 和 DuoRec [19] 引入自监督或对比学习目标，FMLP-Rec 通过滤波增强的 MLP 简化架构 [43]，UniSRec 从物品文本中学习可迁移表征 [11]，TIGER 则在语义标识符上执行生成式检索 [20]。尽管架构多种多样，这些模型却采用相同的监督方式：以给定前缀的独热下一物品标签为监督，而日志中记录的未来信息并未得到利用。我们的工作与这条研究路线正交，因为它利用仅训练时可用的未来上下文来升级监督本身，并且无需修改这些骨干网络即可应用于其上。

5.2 知识蒸馏

知识蒸馏将教师模型的软化预测传递给学生模型 [9]，随后又扩展到中间表征 [22]。后续研究超越了模型压缩的范畴：Born-Again Networks 表明，容量相同的学生模型能够超越其教师模型 [4]；深度互学习训练同伴模型相互教学 [41]；自蒸馏则让单个网络成为自己的教师 [39]。另一条研究路线通过参数平均来稳定持续更新的教师模型，如 Mean Teacher [29]、MoCo [7] 和 DINO [3]；近期针对大语言模型的蒸馏研究还进一步揭示，静态教师难以有效服务于持续演化的学生模型 [1, 6]。在推荐领域，蒸馏主要用于排序器压缩，包括 Ranking Distillation [28] 以及协同和关系变体 [12, 13, 15]；PFD [36] 传递仅在训练期间可用的特权特征，而 S⁴Rec [33] 和 CSRec [34] 则采用辅助蒸馏来增强同等规模的模型。与这些方法均不同，PSD 中教师模型的独特之处在于其信息集，而非容量或额外特征：它与学生

图 6: 采用 SASRec 时，PSD 在 Video Games 和 Yelp 上对门控百分位数 δ 和 EMA 速率 α 的敏感性。

模型共享相同参数，优势来自未来后缀，并利用优势可达性特权信息仅传递其中可达的部分。

6 结论

本文将日志序列中的未来交互识别为序列推荐中仅训练时可用的特权信息，并提出 PSD，在不违反因果服务约束的前提下利用这些信息。PSD 在特权掩码和因果掩码下评估同一个骨干网络，使教师模型以观测到的目标为依据，并通过门控蒸馏引导学生模型。其中，优势可达性门控屏蔽不可达的暗知识，动量平均教师则稳定自指监督。整个框架无需引入额外参数、辅助特征或多阶段训练，并且保持骨干网络的服务成本不变。大量实验表明，该方法能够持续取得显著提升；诊断分析也验证了特权知识确实被传递到了因果视图中。我们相信，这种简单而有效的“从未来学习”思想具有足够的通用性，能够惠及推荐之外广泛的序列预测与决策任务。

参考文献

- [1] Rishabh Agarwal, Nino Vieillard, Yongchao Zhou, Piotr Stanczyk, Sabela Ramos, Matthieu Geist, and Olivier Bachem. 2024. On-Policy Distillation of Language Models: Learning from Self-Generated Mistakes. In *International Conference on Learning Representations (ICLR)*.
- [2] Tesfaye Fenta Boka, Zhendong Niu, and Rama Bastola Neupane. 2024. A survey of sequential recommendation systems: Techniques, evaluation, and future directions. *Information Systems* 125 (2024), 102427.
- [3] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. 2021. Emerging properties in self-supervised vision transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 9650–9660.
- [4] Tommaso Furlanello, Zachary Lipton, Michael Tschannen, Laurent Itti, and Anima Anandkumar. 2018. Born again neural networks. In *International Conference on Machine Learning (ICML)*. PMLR, 1607–1616.
- [5] Jianping Gou, Baosheng Yu, Stephen J Maybank, and Dacheng Tao. 2021. Knowledge distillation: A survey. *International Journal of Computer Vision (IJCV)* 129, 6 (2021), 1789–1819.
- [6] Yuxian Gu, Li Dong, Furu Wei, and Minlie Huang. 2024. MiniLLM: Knowledge Distillation of Large Language Models. In *International Conference on Learning Representations (ICLR)*.
- [7] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. 2020. Momentum contrast for unsupervised visual representation learning. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 9729–9738.
- [8] Balázs Hidasi, Alexandros Karatzoglou, Linas Baltrunas, and Domonkos Tikk. 2016. Session-based recommendations with recurrent neural networks. In *International Conference on Learning Representations (ICLR)*.
- [9] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. 2015. Distilling the knowledge in a neural network. *arXiv preprint arXiv:1503.02531* (2015).

- [10] Yupeng Hou, Jiacheng Li, Xiangjun Fu, Zhankui He, An Yan, Xiusi Chen, and Julian McAuley. 2026. Bridging language and items for retrieval and recommendation: Benchmarking LLMs as semantic encoders. In *Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (ACL)*. 3251–3265.
- [11] Yupeng Hou, Shanlei Mu, Wayne Xin Zhao, Yaliang Li, Bolin Ding, and Ji-Rong Wen. 2022. Towards universal sequence representation learning for recommender systems. In *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)*. 585–593.
- [12] SeongKu Kang, Junyoung Hwang, Wonbin Kweon, and Hwanjo Yu. 2020. DE-RRD: A knowledge distillation framework for recommender system. In *Proceedings of the 29th ACM International Conference on Information and Knowledge Management (CIKM)*. 605–614.
- [13] SeongKu Kang, Junyoung Hwang, Wonbin Kweon, and Hwanjo Yu. 2021. Topology distillation for recommender system. In *Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)*. 829–839.
- [14] Wang-Cheng Kang and Julian McAuley. 2018. Self-Attentive Sequential Recommendation. In *2018 IEEE International Conference on Data Mining (ICDM)*. 197–206.
- [15] Jae-won Lee, Minjin Choi, Jongwuk Lee, and Hyunjung Shim. 2019. Collaborative distillation for top-N recommendation. In *2019 IEEE International Conference on Data Mining (ICDM)*. IEEE, 369–378.
- [16] David Lopez-Paz, Léon Bottou, Bernhard Schölkopf, and Vladimir Vapnik. 2016. Unifying Distillation and Privileged Information. In *International Conference on Learning Representations (ICLR)*.
- [17] Amir M Mansourian, Rozhan Ahmadi, Masoud Ghafouri, Amir Mohammad Babaei, Elaheh Badali Golezani, Zeynab Yasamani Ghamchi, Vida Ramezani, Alireza Taherian, Kimia Dinashi, Amirali Miri, et al. 2025. A comprehensive survey on knowledge distillation. *arXiv preprint arXiv:2503.12067* (2025).
- [18] Li-Wei Pan, Wei-Ke Pan, Mei-Yan Wei, Hong-Zhi Yin, and Zhong Ming. 2026. A survey on sequential recommendation. *Frontiers of Computer Science* 20, 3 (2026), 2003606.
- [19] Ruihong Qiu, Zi Huang, Hongzhi Yin, and Zijian Wang. 2022. Contrastive Learning for Representation Degeneration Problem in Sequential Recommendation. In *Proceedings of the 15th ACM International Conference on Web Search and Data Mining (WSDM)*. 813–823.
- [20] Shashank Rajput, Nikhil Mehta, Anima Singh, Raghunandan Hulikal Keshavan, Trung Vu, Lukasz Heldt, Lichan Hong, Yi Tay, Vinh Q. Tran, Jonah Samost, Maciej Kula, Ed H. Chi, and Maheswaran Sathiamoorthy. 2023. Recommender Systems with Generative Retrieval. In *Advances in Neural Information Processing Systems (NeurIPS)*.
- [21] Steffen Rendle, Christoph Freudenthaler, and Lars Schmidt-Thieme. 2010. Factorizing personalized Markov chains for next-basket recommendation. In *Proceedings of the 19th International Conference on World Wide Web (WWW)*. 811–820.
- [22] Adriana Romero, Nicolas Ballas, Samira Ebrahimi Kahou, Antoine Chassang, Carlo Gatta, and Yoshua Bengio. 2015. FitNets: Hints for thin deep nets. In *International Conference on Learning Representations (ICLR)*.
- [23] Fei Sun, Jun Liu, Jian Wu, Changhua Pei, Xiao Lin, Wenwu Ou, and Peng Jiang. 2019. BERT4Rec: Sequential Recommendation with Bidirectional Encoder Representations from Transformer. In *Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM)*. 1441–1450.
- [24] Christian Szegedy, Vincent Vanhoucke, Sergey Ioffe, Jon Shlens, and Zbigniew Wojna. 2016. Rethinking the inception architecture for computer vision. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2818–2826.
- [25] Jiakai Tang, Xu Chen, Wen Chen, Jian Wu, Yuning Jiang, and Bo Zheng. 2026. Parallel Latent Reasoning for Sequential Recommendation. *arXiv preprint arXiv:2601.03153* (2026).
- [26] Jiakai Tang, Sunhao Dai, Teng Shi, Jun Xu, Xu Chen, Wen Chen, Jian Wu, and Yuning Jiang. 2026. Think before recommend: Unleashing the latent reasoning power for sequential recommendation. *IEEE Transactions on Knowledge and Data Engineering (TKDE)* (2026).
- [27] Jiayi Tang and Ke Wang. 2018. Personalized top-N sequential recommendation via convolutional sequence embedding. In *Proceedings of the 11th ACM International Conference on Web Search and Data Mining (WSDM)*. 565–573.
- [28] Jiayi Tang and Ke Wang. 2018. Ranking Distillation: Learning Compact Ranking Models With High Performance for Recommender System. In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD)*. 2289–2298. doi:10.1145/3219819.3220021
- [29] Antti Tarvainen and Harri Valpola. 2017. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results. In *Advances in Neural Information Processing Systems (NeurIPS)*.
- [30] Vladimir Vapnik and Akshay Vashist. 2009. A New Learning Paradigm: Learning Using Privileged Information. *Neural Networks* 22, 5–6 (2009), 544–557.
- [31] Shoujin Wang, Liang Hu, Yan Wang, Longbing Cao, Quan Z Sheng, and Mehmet Orgun. 2019. Sequential recommender systems: challenges, progress and prospects. *arXiv preprint arXiv:2001.04830* (2019).
- [32] Wenjie Wang, Fuli Feng, Xiangnan He, Liqiang Nie, and Tat-Seng Chua. 2021. Denoising Implicit Feedback for Recommendation. In *Proceedings of the 14th ACM International Conference on Web Search and Data Mining (WSDM)*. 373–381. doi:10.1145/3437963.3441800
- [33] Shaowei Wei, Zhengwei Wu, Xin Li, Qintong Wu, Zhiqiang Zhang, Jun Zhou, Lihong Gu, and Jinjie Gu. 2024. Leave No One Behind: Online Self-Supervised Self-Distillation for Sequential Recommendation. In *Proceedings of the ACM Web Conference (WWW)*. doi:10.1145/3589334.3645590
- [34] Shiguang Wu, Xin Xin, Pengjie Ren, Zhumin Chen, Jun Ma, Maarten de Rijke, and Zhaochun Ren. 2024. Learning Robust Sequential Recommenders through Confident Soft Labels. *ACM Transactions on Information Systems (TOIS)* (2024). doi:10.1145/3700876
- [35] Xu Xie, Fei Sun, Zhaoyang Liu, Shiwen Wu, Jinyang Gao, Jiandong Zhang, Bolin Ding, and Bin Cui. 2022. Contrastive Learning for Sequential Recommendation. In *Proceedings of the 38th IEEE International Conference on Data Engineering (ICDE)*. 1259–1273.
- [36] Chen Xu, Quan Li, Junfeng Ge, Jinyang Gao, Xiaoyong Yang, Changhua Pei, Fei Sun, Jian Wu, Hanxiao Sun, and Wenwu Ou. 2019. Privileged Features Distillation at Taobao Recommendations. *arXiv preprint arXiv:1907.05171* (2019). doi:10.48550/arXiv.1907.05171
- [37] Xiaohan Xu, Ming Li, Chongyang Tao, Tao Shen, Reynold Cheng, Jinyang Li, Can Xu, Dacheng Tao, and Tianyi Zhou. 2024. A survey on knowledge distillation of large language models. *arXiv preprint arXiv:2402.13116* (2024).
- [38] Zheng Yuan, Fajie Yuan, Yu Song, Youhua Li, Junchen Fu, Fei Yang, Yunzhu Pan, and Yongxin Ni. 2023. Where to go next for recommender systems? id-vs. modality-based recommender models revisited. In *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR)*. 2639–2649.
- [39] Linfeng Zhang, Jiebo Song, Anni Gao, Jingwei Chen, Chenglong Bao, and Kaisheng Ma. 2019. Be your own teacher: Improve the performance of convolutional neural networks via self distillation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 3713–3722.
- [40] Yanzhao Zhang, Mingxin Li, Dingkun Long, Xin Zhang, Huan Lin, Baosong Yang, Pengjun Xie, An Yang, Dayiheng Liu, Junyang Lin, Fei Huang, and Jingren Zhou. 2025. Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models. *arXiv preprint arXiv:2506.05176* (2025).
- [41] Ying Zhang, Tao Xiang, Timothy M Hospedales, and Huchuan Lu. 2018. Deep mutual learning. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 4320–4328.
- [42] Kun Zhou, Hui Wang, Wayne Xin Zhao, Yutao Zhu, Sirui Wang, Fuzheng Zhang, Zhongyuan Wang, and Ji-Rong Wen. 2020. S3-Rec: Self-supervised learning for sequential recommendation with mutual information maximization. In *Proceedings of the 29th ACM International Conference on Information and Knowledge Management (CIKM)*. 1893–1902.
- [43] Kun Zhou, Hui Yu, Wayne Xin Zhao, and Ji-Rong Wen. 2022. Filter-enhanced MLP is all you need for sequential recommendation. In *Proceedings of the ACM Web Conference (WWW)*. 2388–2399.