

扩展更多，收缩更少：塑造推荐模型稠密扩展中的有效秩动态

Guoming Li*

香港科技大学（广州）
广州，中国

paskardli@outlook.com

Shangyu Zhang*

腾讯公司
深圳，中国

bitosyzhang@tencent.com

Junwei Pan

腾讯公司
深圳，中国

jonaspan@tencent.com

Wentao Ning

腾讯公司
深圳，中国

wentaoning@tencent.com

Jin Chen

腾讯公司
深圳，中国

elinjinchen@tencent.com

Gengsheng Xue

腾讯公司
深圳，中国

eddiegsxue@tencent.com

Chao Zhou

腾讯公司
深圳，中国

derekczhou@tencent.com

Shudong Huang

腾讯公司
深圳，中国

ericdhuang@tencent.com

Haijie Gu

腾讯公司
深圳，中国

jerrickgu@tencent.com

Menglin Yang[†]

香港科技大学（广州）
广州，中国

menglinyang@hkust-gz.edu.cn

摘要

扩展推荐模型是推荐系统中的核心挑战。近年来，*RankMixer* 已成为一种有效的解决方案：它在统一的 token 表示

上运行，并在 token 混合与逐 token 前馈网络 (P-FFN) 之间交替，以实现可扩展的性能。然而，*RankMixer* 存在嵌入坍塌问题，即学习到的表示具有较低的有效秩，从而限制了表达能力，并且未能充分利用扩展后的表示空间。通过实证分析与理论洞察，我们发现刚性的 token 混合和 P-FFN 模块是造成这一现象的主要原因，二者共同导致有效秩在各层间的演化呈现**阻尼振荡轨迹**。为解决这一问题，我们提出了 **RankElastor**，这是一种可生成谱稳健表示、并可证明缓解坍塌的新型架构。RankElastor 引入了两个组件：(i) **参数化全混合**，以更强的谱稳健性实现富有表达力的 token 混合；(ii) **GLU 改进的 P-FFN**，通过 GLU 风

*贡献相同。

[†] 通讯作者



This work is licensed under a Creative Commons Attribution 4.0 International License.

KDD '26, 韩国济州岛

© 2026 Copyright held by the owner/author(s).

ACM ISBN 979-8-4007-2259-2/2026/08

<https://doi.org/10.1145/3770855.3818049>

格的 FFN 模块稳定表示谱。在大规模工业数据集上的大量实验表明, RankElastor 能够持续提升推荐性能、缓解嵌入坍塌, 并展现出稳健的扩展行为。代码可从以下 GitHub 仓库获取: <https://github.com/vasile-paskardlgm/RankElastor>

CCS Concepts

• 计算方法 → 机器学习.

Keywords

推荐系统, CTR 预测, 维度坍塌

ACM Reference Format:

Guoming Li, Shangyu Zhang, Junwei Pan, Wentao Ning, Jin Chen, Gengsheng Xue, Chao Zhou, Shudong Huang, Haijie Gu, and Menglin Yang. 2026. 扩展更多, 收缩更少: 塑造推荐模型稠密扩展中的有效秩动态. In 第 32 届 ACM SIGKDD 知识发现与数据挖掘会议论文集 V.2 (KDD '26), 2026 年 8 月 09–13 日, 韩国济州岛. ACM, New York, NY, USA, 22 pages. <https://doi.org/10.1145/3770855.3818049>

资源可用性:

本文源代码已公开于 <https://doi.org/10.5281/zenodo.20252036>.

1 引言

推荐系统是机器学习的核心应用之一, 旨在从海量多字段类别数据中预测用户—物品交互 [42]。它们已成为现代数字平台不可或缺的组成部分, 为电子商务、社交媒体和内容推荐等应用提供支撑。近年来, 基于深度学习的推荐模型取得进展, 能够灵活学习特征表示并建模复杂的特征交互, 从而在大规模工业部署中展现出强劲性能。

受大型基础模型成功经验的启发 [1, 19, 25, 27], 扩展模型容量已成为推荐系统的一个自然发展方向 [8, 35, 40, 41]。在近期面向缩放的架构中, RankMixer [45] 受到广泛关注。RankMixer 架构可理解为三个核心组件: (i) 分词模块, 将来自多个字段的异构嵌入映射到统一的 token 表示空间; (ii) token 混合模块, 通过将

原始 token 矩阵与其分块转置视图结合起来增强 token 表示; 以及 (iii) 逐 token FFN (P-FFN) 模块, 利用独立应用于每个 token 的前馈网络对特征交互进行建模 [4, 18]。通过迭代交替使用 token 混合模块和 P-FFN 模块, RankMixer 构成一种深度且可扩展的推荐架构, 在多个基准以及实际部署中取得了最先进的性能。

尽管 RankMixer 在经验上取得了成功, 但尚未从嵌入坍塌 [9] 的角度对其进行研究。嵌入坍塌最近被认为是扩展推荐系统时的一个根本障碍 [5, 9, 24, 39, 43]: 学习到的表示集中于低秩子空间, 从而限制表示多样性, 并削弱模型缩放所带来的收益。尽管先前工作尝试通过架构修改 [9] 或优化策略 [21, 36] 缓解坍塌, 但这些解决方案通常针对特定推荐模型设计。目前仍缺乏对 RankMixer 中嵌入坍塌的系统性理解。

本文从有效秩 [28, 34] 的视角研究 RankMixer。有效秩是一种谱度量, 能够刻画超越代数秩的表示容量, 并推广了推荐系统中先前的坍塌分析工具 [9, 39]。在经验上, 我们观察到 RankMixer 的秩随层演化呈现独特的阻尼振荡轨迹: token 混合模块会略微提高有效秩, 而 P-FFN 模块则使其收缩。尽管这种交替行为相较通常呈现单调秩衰减的传统推荐模型 (如 DCNv2 [37]) 带来了一定改善, 但其收益仍然有限, 且随着模型深度增加, 无法可靠地防止表示坍塌。作为对上述观察的补充, 我们的理论分析表明, RankMixer 中原始的 token 混合模块和 P-FFN 模块共同限制了谱鲁棒性, 从而解释了为何其对坍塌的缓解仍不充分。

为解决这一缺陷并释放基于 token 变换的推荐模型的潜力, 我们提出 RankElastor, 这是一种旨在生成谱鲁棒表示、并能以可证明方式缓解坍塌的新颖架构。RankElastor 引入两个关键组件: (i) 参数化完整混合, 对 token 执行可学习的细粒度混合, 以提高谱表达能力; 以及 (ii) 经 GLU 改进的 P-FFN, 利用门控激活 [29] 防止原始 RankMixer P-FFN 所引发的坍塌放大。两者共同产生更稳定的表示谱与更优的缩放行为。

我们在工业规模基准 Criteo [14] 和 Avazu [32] 上, 将 RankElastor 与包括 RankMixer 在内的强推荐

基线进行比较，从而实现与实际应用一致的对比。实验结果表明，RankElastor 持续提升下游 CTR 预测性能，相较最强基线获得超过 **0.001 的 AUC 增益**——根据 [44]，这是一项显著的改进。除准确率提升外，RankElastor 还生成具有明显更高有效秩的表示，表明其对表示坍塌具有更强的缓解能力。此外，RankElastor 呈现出显著优于 RankMixer 的参数缩放行为，证实了其作为可扩展推荐架构的优势。我们的贡献总结如下：

- 我们从嵌入坍塌的角度分析 RankMixer，并提供经验证据与理论论证，说明该架构仍未充分解决坍塌问题。
- 我们提出 RankElastor，这是一种通过参数化完整混合与经 GLU 改进的 P-FFN 缓解表示坍塌的新型深度推荐架构，并为其谱鲁棒性提供理论保证。
- 我们在工业规模基准上开展广泛实验，证明 RankElastor 能够提升推荐性能、表示多样性和参数缩放行为，为推荐架构的规模化提供了新方向。

2 研究背景

2.1 符号与预备知识

推荐模型旨在基于来自多个字段的特征预测用户行为 [42]。与本文考虑的应用场景，即 CTR/排序预测 [23] 一致，我们考虑 n 个字段，其中第 i 个字段记为 $\mathcal{X}_i$ ，并将联合特征空间定义为 $\mathcal{X} = \mathcal{X}_1 \times \mathcal{X}_2 \times \dots \times \mathcal{X}_n$ 。令 $\mathcal{Y}$ 表示预测空间；推荐模型的目标是学习从 $\mathcal{X}$ 到 $\mathcal{Y}$ 的映射。

我们关注采用“嵌入-交互”架构的推荐模型。此类模型首先将输入样本 $X \in \mathcal{X}$ 转换为**特征嵌入** $E \in \mathbb{R}^{n \times k}$ ，其中 k 为嵌入维度，第 i 行 E_i 表示字段 i 的嵌入向量。随后，嵌入矩阵由**特征交互**模块 [4, 18] 处理，该模块对跨字段相关性进行建模，并生成用于预测的信息丰富的表示。由于具有出色的实证性能，这种架构被真实世界的推荐系统广泛采用 [20, 26, 30, 37]。

嵌入坍塌 [9]。在一般机器学习场景中，维度坍塌是指模型退化为将输入映射至近似常数输出的平凡表示 [13]；

该现象可通过对学习所得表示进行谱分析来刻画 [15]。在推荐系统中，近期发现了一种称为**嵌入坍塌**的相关现象：嵌入矩阵变为近似低秩，且具有多个接近于零的奇异值 [5, 9, 24, 43]。

这一现象通常使用有效秩 [28] 来度量；与代数秩相比，有效秩能够刻画矩阵的谱分布。在多种定义中，我们采用一种广泛使用的基于范数的定义 [2, 3, 34]，也称为稳定秩 [6]：

$$\text{erank}(X) = \frac{\sum_i \sigma_i^2}{\max_i \sigma_i^2} = \frac{\|X\|_F^2}{\|X\|_2^2}, \quad (1)$$

其中 σ_i 表示 X 的奇异值。

RankMixer [45]。作为一种较新的深度推荐架构，RankMixer 凭借其精简设计、出色实证性能和良好缩放特性而受到广泛关注。其架构由三个模块组成：(i) *tokenization*；(ii) *token mixing*；以及 (iii) 逐 *token* *FFN* (P-FFN)。下面对它们作简要介绍：

- **Tokenization**。Tokenization 模块接收嵌入矩阵 E ，并将嵌入向量分为 T 个簇；随后通过统一投影（例如线性映射或 MLP）将它们投影至共享的 D 维空间，从而生成 token 矩阵 $X^{(0)} \in \mathbb{R}^{T \times D}$ 。每一行 $X_i^{(0)} \in \mathbb{R}^D$ 称为一个 token 嵌入。该模块主要用于对齐来自异构来源的嵌入。本文重点关注后续的核心模块。
- **Token mixing**。Token mixing 模块将列维度 D 划分为 H 个大小为 $d = D/H$ 的等长片段，形成一个 $T \times T$ 块网格，其中每个块均属于 $\mathbb{R}^{1 \times d}$ 。在第 l 个 RankMixer 块中，首先对输入 $X^{(l)}$ 应用块转置操作，交换块对 $X_{i,j}^{(l)}$ 与 $X_{j,i}^{(l)}$ 。随后通过残差连接将变换后的表示与原始 token 矩阵结合，再应用输出层归一化，从而生成融合了跨 token 信息的增强 token 表示。
- **P-FFN**。随后，RankMixer 将混合后的 token 输入 token 专属 FFN 模块，该模块称为 P-FFN。与典型“嵌入-交互”型推荐模型中的相应模块一样，该模块用于执行特征交互。在 RankMixer 中，P-FFN 被配置为以 GELU [11] 为激活函数的两层网络。

堆叠 token mixing 和 P-FFN 模块即可得到一种深且可扩展的推荐架构。图 3(a) 展示了 RankMixer 的整体架构。

2.2 RankMixer 中的嵌入坍塌

尽管 RankMixer 展现出很强的可扩展性和有效性, 但其在嵌入坍塌下的行为尚未得到系统研究。现有坍塌分析主要聚焦于传统推荐模型 [9, 39], 例如 DCNv2 [37] 和 xDeepFM [20]。本节结合经验观察与理论论证, 分析 RankMixer 表示在其核心模块 (token 混合与 P-FFN) 之间的有效秩动态。

经验展示. 我们使用 FuxiCTR 框架 [46], 在两个工业规模基准 Criteo [14] 和 Avazu [32] 上开展 CTR 预测实验。我们将包含两个 token 混合块和两个 P-FFN 块的 RankMixer, 与配置为相近深度的 DCNv2 和 xDeepFM 进行比较; 由此得到四层推荐模型, 以确保公平比较。随后, 我们对测试样本中各模块输出的平均有效秩进行可视化。其余所有实验设置均遵循第 4 节的描述。

完整的推荐性能结果见第 4 节, 此处重点关注有效秩动态。如图 2 所示, 传统模型的有效秩随深度呈**单调衰减**; 相比之下, RankMixer 呈现交替模式: token 混合提高有效秩, 而 P-FFN 使其收缩, 从而形成**阻尼振荡轨迹**。尽管这种锯齿模式使 RankMixer 能够维持略高于传统模型的有效秩, 但改善幅度仍然有限, 且无法消除坍塌。

在 Criteo 上, 最终层的有效秩仅略高于原始嵌入, 表明 token 混合在实践中的秩增强效果较为有限。在 Avazu 上 (图 2b), 这一局限更加明显: P-FFN 引入的收缩在各层占据主导, 即使存在 token 混合, 坍塌仍会重新出现。

由于更高的有效秩通常意味着对表示容量的利用更充分, 并且与更好的推荐性能相关 [9, 39], 这些结果从嵌入坍塌的角度揭示了 RankMixer 的优势与局限: 尽管该架构相较传统推荐模型提高了表示秩, 但并未从根本上防止坍塌。

理论论证. 我们进一步以理论论证补充经验分析。RankMixer 的有效秩提升及其仍然存在的坍塌局限, 均可追溯到其两个模块: token 混合和 P-FFN。以下定理为这些效应提供理论依据。

THEOREM 2.1 (分块转置混合下的有效秩). 令 $X \in \mathbb{R}^{T \times D}$ 为表示矩阵, 其中 $D = Td$ 且 $d \geq 1$ 。将 X 划分为由分块 $X_{ij} \in \mathbb{R}^{1 \times d}$ 构成的 $T \times T$ 网格。通过 $(\mathcal{T}(X))_{ij} = X_{ji}$ 定义分块转置算子 $\mathcal{T}$, 并令 $Y = \mathcal{T}(X)$ 。用 $\text{rank}(X) = r$ 和 $\text{erank}(X) = k$ 分别表示 X 的代数秩和有效秩。假设 X 与其分块转置满足 *Frobenius* 正交性和谱非相干性:

$$\langle X, Y \rangle_F \approx 0 \quad \text{and} \quad \|X + Y\|_2^2 \approx \max(\|X\|_2^2, \|Y\|_2^2).$$

令 $M = X + Y$, 并定义 $\mu = \text{erank}(Y)$ 。则

$$\frac{2k\mu}{(\sqrt{k} + \sqrt{\mu})^2} \leq \text{erank}(M) \leq 2(k + \mu),$$

其中 $\mu \leq \text{rank}(Y) \leq \min\{T, rd\}$ 。

THEOREM 2.2 (标准 FFN 的有效秩失效). 令 $X \in \mathbb{R}^{T \times D}$ 为表示矩阵, 其有效秩为 $\text{erank}(X) = k$ and $\frac{k}{D} \leq \gamma$, 其中固定常数 $\gamma \in (0, 1)$ 与 D 无关。考虑逐行前馈网络 $\mathcal{F}(X) = \phi(XA)B$, 其中 $A \in \mathbb{R}^{D \times m}$ 和 $B \in \mathbb{R}^{m \times D}$ 的元素为方差为 $1/D$ 的独立同分布次高斯随机变量, 且 ϕ 是正齐次的。则:

- **(确定性坍塌)** 若 X 的代数秩为 1, 则 $\text{rank}(\mathcal{F}(X)) \leq 2$, 且 $\text{erank}(\mathcal{F}(X)) \leq 2$; 当 X 的所有行符号相同时, $= 1$ 取等号。
- **(概率收缩)** 若预激活满足非平凡的响应间隙条件 (见附录 B), 则以至少 $1 - \exp(-ck)$ 的概率, $\text{erank}(\mathcal{F}(X)) \leq \alpha \text{erank}(X)$, 其中常数 $\alpha \in (0, 1)$ 仅依赖于 γ 和激活函数 ϕ 。

定理 2.1 解释了 token mixing 能够提升有效秩的原因。块转置混合生成的表示, 其有效秩具有如下下界 $\frac{2k\mu}{(\sqrt{k} + \sqrt{\mu})^2}$ 。这表明混合引入了秩扩张效应。然而, 该定理也揭示了一个内在限制: 可实现的提升受限于 $\text{erank}(X + Y) \leq 2(k + \mu)$ 。由于推荐模型的嵌入在初始化阶段往往已经发生谱坍塌 [9, 16, 24], 这种受限




图 1: RankMixer 各表示阶段的有效秩分布偏移。展示 Criteo (上图) 和 Avazu (下图) 上从原始嵌入到后续模块输出的逐样本有效秩分布。

的扩张在实践中通常只能带来较小的秩提升。这解释了图 1a 和图 1c 中 token mixing 后观察到的微小秩提升。

定理 2.2 刻画了 P-FFN 的互补效应。当输入表示已经是低秩时，FFN 模块会进一步收缩有效秩，无论是在秩为 1 情形下的确定性收缩，还是在一般秩为 k 情形下的概率收缩。这解释了图 1b 和图 1d 中反复出现的有效秩下降。

总结。 综合来看，实证分析与理论分析共同揭示了 RankMixer 中一致的谱动态规律。尽管 RankMixer 比传统推荐模型保持了更高的有效秩，但这种提升在本质上是有限的，无法可靠地阻止坍塌在层间重新出现。这一限制源于架构本身：token mixing 提供有界的秩扩张，而 P-FFN 表现出秩收缩行为，二者共同形成了随深度变化的特征性阻尼振荡轨迹。

重要的是，这一诊断为架构改进指明了一个原则性方向——**扩张更多、收缩更少**，即让 token mixing 产生更强的谱扩张，同时降低 P-FFN 对谱的压缩程度。受这一洞见启发，我们将在下一节提出 RankElastor。

3 方法：RankElastor

本节介绍 RankElastor，这是一种新颖的深度推荐架构，通过建立对坍塌具有鲁棒性的 token 变换，对 RankMixer 的 token mixing 和 P-FFN 模块进行了推广。我们重点介绍 RankElastor 中的两个核心架构组件：(i) 参数化全 *Token Mixing* 和 (ii) 经 *GLU* 改进的 *P-FFN*，二者均有理论依据支持。图 3(b) 展示了 RankElastor 的整体结构。


3.1 参数化全 token 混合

在 RankMixer 中，token 混合通过一种非参数化的分块转置操作实现。该操作等价于


$$\text{vec}(M^T) = \text{LN}((P \otimes I) \text{vec}(X^T) + \text{vec}(X^T)), \quad (2)$$

其中， $P \in \mathbb{R}^{T^2 \times T^2}$ 是一个具有交换矩阵 [22] 结构的置换算子， $I \in \mathbb{R}^{\frac{D}{T} \times \frac{D}{T}}$ 表示单位矩阵， vec 表示 *vec* 算子 [10]， LN 表示层归一化，而 $\otimes$ 是 *Kronecker* 积 [12]。

这一表示揭示了一个重要的结构性质：token 混合由置换算子 P 和网格尺度 $d = \frac{D}{T}$ 共同控制。修改置换算子或网格尺度中的任意一个，都会产生不同的 token 混合行为。受此观察启发，我们通过引入可



(a) Criteo 上的比较。



(b) Avazu 上的比较。

图 2: RankMixer (阻尼振荡轨迹) 与基线 (单调衰减) 在各表示阶段的平均有效秩比较。

学习混合算子并将网格尺度缩小到最精细分辨率, 对式 2 进行推广。由此得到所提出的参数化全混合:

$$\text{vec}(M^\top) = \text{LN}((W + I) \text{vec}(X^\top)), \quad (3)$$

其中 $W \in \mathbb{R}^{TD \times TD}$ 是可学习的混合矩阵, I 用于保留残差信息流。

该形式对应于采用完全参数化混合权重的细粒度情形 $d = 1$, 能够在所有 token-特征坐标之间进行交互。这种推广通过允许模型细化那些在受限逐块变换下可能导致谱坍塌的表示, 增强了 token mixing 模块。我们在下面的定理中对这一表达能力优势进行形式化说明。

THEOREM 3.1 (参数化全混合的表达能力). 令 $X \in \mathbb{R}^{T \times D}$ 为输入表示矩阵, 且 $x = \text{vec}(X) \in \mathbb{R}^N$ 满足 $N = TD$. 对于 N 的一个因子 d^* , 将 x 划分为 $K = N/d^*$ 个块 $\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_K\}$, 其中 $\mathbf{b}_k \in \mathbb{R}^{d^*}$. 具有可学习权重 $\mathbf{W} \in \mathbb{R}^{K \times K}$ 的参数化块混合方案产

生 $\mathbf{y} = (\mathbf{W} \otimes \mathbf{I}_{d^*})\mathbf{x}$ 和残差输出 $\mathbf{C} = \Phi_{d^*}(\mathbf{X}; \mathbf{W}) \triangleq \mathbf{X} + \text{reshape}((\mathbf{W} \otimes \mathbf{I}_{d^*}) \text{vec}(\mathbf{X}))$. 则对于任意 $d^* > 1$, Φ_{d^*} 可实现的线性变换集合严格包含于参数化全混合情形 ($d^* = 1$) 所能实现的集合中。具体而言, *Kronecker* 约束 $(\mathbf{W} \otimes \mathbf{I}_{d^*})$ 阻碍了对细粒度、高秩坐标交互的表达, 而当 $d^* = 1$ 时此类交互是可以实现的。

该定理的论证见附录 C. 该定理表明, 当网格尺度满足 $d^* > 1$ 时, 始终存在非平凡输入, 使其 token mixing 输出仍受到谱约束。相比之下, 与我们的参数化全混合对应的细粒度情形 $d^* = 1$ 消除了 *Kronecker* 约束, 并支持更丰富的坐标交互, 从而提升了抵抗表示坍塌的鲁棒性。

3.2 经 GLU 改进的 P-FFN

尽管参数化完整混合从有效秩的角度提高了矩阵层面 token 表示的表达能力, 但其缓解坍塌的效果主要是统计性的, 而非确定性的。在实际推荐场景中, 高度偏斜或退化的输入仍可能导致表示质量下降。为进一步提高鲁棒性, 我们改进了 RankMixer 的第二个核心模块, 即 P-FFN。

我们将基于 GELU 的 FFN 替换为 GLU 风格的门控前馈模块 (为清晰起见省略偏置):

$$Z_t = (\text{GELU}(M_t W_1) \odot (M_t W_2)) W_3 + M_t W_r, \quad (4)$$

其中, $W_1, W_2 \in \mathbb{R}^{D \times rD}$ 为升维投影, $W_3 \in \mathbb{R}^{rD \times D}$ 为压缩投影, r 为扩展比, W_r 为可学习残差映射, $\odot$ 表示 *Hadamard* 积 [33]. 该设计遵循 GLU [29] 的门控激活原则; 已有研究表明, 这一原则能够提升现代深度架构的表达能力和表示质量 [7, 31, 38].

接下来, 我们证明经 GLU 改进的 P-FFN 比 RankMixer 中使用的基于 GELU 的 FFN 具有更强的有效秩恢复能力。

THEOREM 3.2 (经 GLU 改进的 P-FFN 实现有效秩恢复). 令 $X \in \mathbb{R}^{T \times D}$ 满足 $\text{erank}(X) = k$, 其中对于固定常数 $\gamma \in (0, 1)$ 有 $k/D \leq \gamma$. 考虑带残差




图 3: (a) RankMixer 与 (b) RankElastor 的架构概览。紫色模块表示可训练组件，灰色模块表示非参数组件。两个模型的关键区别在于 token 混合与 P-FFN。

的 GLU 改进 P-FFN

$$\mathcal{G}(X) = (\phi(XA) \odot (XC))B + XD,$$

其中 $A, C \in \mathbb{R}^{D \times m}$ 和 $B \in \mathbb{R}^{m \times D}$ 的元素独立同分布、服从方差为 $1/D$ 的次高斯分布, $\odot$ 表示 Hadamard 积。若隐藏层宽度满足 $m \geq Ck \log D$, 则以至少 $1 - \exp(-ck)$ 的概率:

- (代数提升) 乘性项引入二次交互, 并且 $\text{rank}(\phi(XA) \odot (XC)) \geq \min\left(D, \frac{k(k+1)}{2}\right)$.
- (有效秩增加) 输出满足 $\text{erank}(\mathcal{G}(X)) \geq \text{erank}(X) + \delta$, 其中某个 $\delta > 0$ 仅依赖于 γ 和初始化常数。

该定理的论证见附录 D。这一结果表明, GLU 改进的 P-FFN 可通过乘性特征交互在统计意义上维持谱稳健性, 而传统基于激活的 FFN 仍可能出现导致有效秩坍塌的非平凡失败情形。因此, 所提出的 P-FFN 在保持 RankMixer 所用标准前馈计算结构的同时, 增强了抵抗表示坍塌的稳健性。

3.3 复杂度分析

我们通过 token 混合模块和 P-FFN 模块的计算复杂度与参数复杂度, 对 RankMixer 和 RankElastor 进行比较。

关于 token 混合。RankMixer 中的 token 混合模块以分块转置置换实现, 其计算量为 $\mathcal{O}(TD)$, 且不引入额外参数。相比之下, RankElastor 采用**参数化完整混合**, 对展平后的表示施加稠密线性变换。这会产生 $\mathcal{O}(T^2 D^2)$ 的计算量和 $\mathcal{O}(T^2 D^2)$ 个参数。

关于 P-FFN。RankMixer 中 P-FFN 模块的计算复杂度为 $\mathcal{O}(TrD^2)$, 参数复杂度为 $\mathcal{O}(rD^2)$ 。RankElastor 的 P-FFN 采用经 GLU 改进的 P-FFN, 将前馈计算开销提高到 $\mathcal{O}(T(3rD^2 + D^2))$, 参数复杂度为 $(3r + 1)D^2$ 。与 RankMixer 中的 P-FFN 相比, 这引入了常数倍的开销增长。

总体而言, RankMixer 与 RankElastor 的主要复杂度差异来自 token 混合模块, 其中 RankElastor 通过参数化完整混合引入了额外参数与计算。经 GLU 改进的 P-FFN 所带来的复杂度增长较小, 且仅为常数倍。

表 1: 基准数据集的统计信息。

数据集	# 训练集大小	# 验证集大小	# 测试集大小	# 字段数
Criteo	33.0M	8.3M	4.6M	39
Avazu	32.3M	4.0M	4.0M	24

4 实验

本节通过大量基准实验回答以下研究问题:

- **RQ1:** RankElastor 在标准 CTR 预测基准上是否优于现有基线?
- **RQ2:** 与 RankMixer 相比, RankElastor 缓解嵌入坍塌的效果如何?
- **RQ3:** 与 RankMixer 相比, RankElastor 的扩展表现如何?
- **RQ4:** RankElastor 在 CTR 预测任务之外的泛化程度如何?

4.1 实验设置

数据集。我们在两个工业规模的 CTR 预测基准 Criteo [14] 和 Avazu [32] 上开展实验, 它们被广泛用于评估推荐模型在实际场景中的表现。数据集统计信息汇总于表 1。

指标。按照 CTR 预测的标准评估协议 [9, 20, 30, 37, 39], 我们报告 AUC 和 LogLoss。为评估表示坍塌, 我们报告式 1 中定义的有效秩。

基线。我们将 RankElastor 与 RankMixer 以及若干在真实 CTR 系统中表现优异的代表性特征交互模型进行比较, 包括 xDeepFM [20]、DCNv2 [37]、AutoInt [30] 和标准 DNN (MLP)。对于 RankElastor 和 RankMixer, 我们均采用两层架构 (即堆叠两个块)。在 Criteo 上设置 $(T, D) = (15, 26)$, 在 Avazu 上设置 $(T, D) = (16, 24)$ 。P-FFN 的隐藏维度设为 D , RankElastor 中经 GLU 改进的 P-FFN 使用扩展比 $r = 3$ 。其余基线采用开源 FuxiCTR 库 [46] 提供的推荐配置。

表 2: RankElastor 与基线模型在 Criteo 和 Avazu 上的整体 CTR 预测性能。

模型	Criteo		Avazu	
	AUC $\uparrow$	LogLoss $\downarrow$	AUC $\uparrow$	LogLoss $\downarrow$
MLP	0.81307	0.43927	0.79226	0.37247
xDeepFM	0.81334	0.43849	0.79242	0.37236
DCNv2	0.81365	0.43816	0.79258	0.37227
AutoInt	0.81331	0.43853	0.79072	0.37430
RankMixer	0.81375	0.43799	0.79270	0.37218
RankElastor	0.81482	0.43730	0.79323	0.37196

表 3: RankElastor 与 RankMixer 中 token mixing 和 P-FFN 的逐模块消融研究。

模型	Criteo		Avazu	
	AUC $\uparrow$	LogLoss $\downarrow$	AUC $\uparrow$	LogLoss $\downarrow$
RankElastor	0.81482	0.43730	0.79323	0.37196
无完整混合	0.81413	0.43785	0.79289	0.37210
基于 ReLU 的 FFN	0.81326	0.43869	0.79241	0.37229
基于 GELU 的 FFN	0.81349	0.43851	0.79288	0.37212
RankMixer	0.81375	0.43799	0.79270	0.37218
GLU 风格 FFNon	0.81393	0.43802	0.79286	0.37212
基于 ReLU 的 FFN	0.81284	0.43917	0.79227	0.37238

实验协议。所有模型均使用开源 FuxiCTR 基准库 [46] 实现, 并遵循其官方推荐的训练流程。Criteo 的嵌入维度设为 20, Avazu 的嵌入维度设为 16。模型最多训练 100 个 epoch; 若验证损失连续两个 epoch 未改善, 则触发早停。Criteo 和 Avazu 的批大小分别设为 4096 和 10000。为确保统计可靠性, 每项报告结果均为采用不同随机初始化进行 10 次运行后的平均值。

4.2 RQ1: CTR 预测性能

定量比较。我们首先给出 RankElastor 与基线模型之间的定量性能比较。如表 2 所示, 在 AUC 和 LogLoss




图 4: RankElastor 与 RankMixer 的效率比较, 并列出其他基线作为参考。

两项指标上, RankElastor 在两个数据集上均持续优于包括 RankMixer 在内的所有基线。具体而言, 相较于最强的竞争模型, RankElastor 将 AUC 最多提升了 **0.001**; 在工业规模 CTR 基准上, 这被认为是具有统计意义的提升 [44]。这些结果验证了所提改进及由此形成的 RankElastor 架构的有效性。值得注意的是, RankElastor 的参数规模仍与其他基线相当, 表明这种性能提升并未引入过高的模型复杂度。

模块贡献分析。 我们进一步进行消融实验, 以评估 RankElastor 中所提模块的贡献, 同时也对 RankMixer 应用相应的消融设置。如表 3 所示, 参数化全混合和经 GLU 改进的 P-FFN 均对 RankElastor 的性能有显著贡献, 移除其中任一组件都会导致性能持续下降。此外, 这两个模块呈现出明确的协同效应: 将二者结合所带来的提升明显大于单独使用任一模块。对 RankMixer 应用类似修改 (例如用 GLU 风格的激活替换 FFN) 仅带来微小的性能增益, 这表明经 GLU 改进的 P-FFN 所带来的收益依赖于参数化全混合所引入的更强 token mixing 能力。这些观察结果与我们的理论分析一致; 该分析强调了两个模块在缓解嵌入坍塌方面的互补作用。

效率比较。 我们从每轮训练时间和 GPU 内存使用量两方面评估 RankElastor 相对于 RankMixer 的效率, 结果如图 4 所示。与 RankMixer 相比, RankElastor 的运行时间仅增加 10%–15%, 同时保持相近的 GPU 内存需求, 并且与 DCNv2 等其他高效基线相比仍具竞争力。这与第 3.3 节给出的复杂度分析一致, 表明对于大规模推荐而言, 额外计算成本在实践中可以忽略不计。总体而言, RankElastor 实现了良好的权衡: 仅付出很小的效率开销, 便获得更优的推荐性能。

4.3 RQ2: 嵌入坍塌缓解

下面考察 RankElastor 中有效秩相较于 RankMixer 的演化方式。具体而言, 我们同时分析 (i) 有效秩分布偏移和 (ii) 各表示阶段的平均有效秩, 从而全面呈现模型内部表示的多样性。

有效秩分布偏移。 如图 5 所示, 我们可视化了 Criteo (上图) 和 Avazu (下图) 上从原始嵌入到后续模块输出的逐样本有效秩分布。与图 1 中 RankMixer 的相应结果相比, RankElastor 的内部表示呈现出明显更大的有效秩分布偏移。尽管两个模型在原始嵌入阶段的有效秩分布几乎相同, 但随着表示在网络中传播, 其行为开始分化。具体而言, RankElastor 中的参数化全混合带来的有效秩增益明显大于 RankMixer 中的分块转置混合; 与 RankMixer 使用的 P-FFN 相比, GLU 增强的 P-FFN 也能更好地保持秩。

“扩展更多，收缩更少”。 图 6 展示了两个模型逐层的平均有效秩, 对应于图 2。我们观察到, RankElastor 的谱动态遵循此前在 RankMixer 中发现的同一特征性交替行为: token 混合层倾向于扩展表示谱并提高有效秩, 而 P-FFN 层则会引起秩收缩。然而, 与 RankMixer 相比, RankElastor 始终表现出明显更强的扩展效应, 并且每个 P-FFN 阶段后的收缩显著更温和。这种行为使各层间的谱演化更加稳定, 让 RankElastor 能够在不同数据集和表示阶段始终保持比 RankMixer 更高的平均有效秩。值得注意的是, 在




图 5: RankElastor 中逐样本有效秩从原始嵌入到后续模块的各表示阶段分布偏移, 其中上图为 Criteo, 下图为 Avazu。结果对应图 1 中的示意。


RankMixer 呈现明显坍塌倾向的 Avazu 上, RankElastor 在整个网络中保持了稳定的有效秩增长, 表明其抵抗表示坍塌的稳健性有所提升。

总体而言, 这些结果证实 RankElastor 比 RankMixer 更有效地缓解了坍塌, 并在各层生成更稳定、更富表达力的内部表示。


4.4 RQ3: 稠密参数缩放分析

为评估 RankElastor 作为可扩展深度推荐范式的缩放行为, 我们针对其稠密参数开展缩放定律实验, 包括参数化完整混合和经 GLU 改进的 P-FFN 中的参数。我们改变 (i) 深度 (块数) 与 (ii) 宽度 (FFN 的隐藏维度), 考察单独缩放与联合缩放方案, 并与 RankMixer 进行比较。

图 7 展示按宽度 (左) 和按深度 (右) 缩放的结果, 图 8 则给出深度与宽度联合缩放的结果。在所有



(a) Criteo 上的比较。



(b) Avazu 上的比较。

图 6: 在测试样本上, 从原始嵌入到模块输出, 对 RankElastor 和 RankMixer 的平均有效秩进行逐层比较。结果与图 2 一致。

配置下, RankElastor 均表现出显著优于 RankMixer 的缩放行为: 随着模型参数增加, 其 AUC 提升更大且 LogLoss 更低。这些结果表明, RankElastor 可作为一种更有效的深度推荐系统范式; 其具有理论依据的设计在缓解嵌入坍塌的同时提升了下游性能。

此外, 将联合缩放 (图 8) 与单独的深度或宽度缩放 (图 7) 相比, 我们观察到, 同时增加深度和宽度所带来的性能增益始终大于仅缩放单一维度。这一行为与语言模型中的发现 [17] 以及 RankMixer 中先前的观察 [45] 一致, 说明 RankElastor 具有一致但更为显著的缩放特性。

4.5 RQ4: 行为序列建模泛化

为进一步评估 RankElastor 在标准 CTR 预测之外的泛化能力, 我们还在行为序列建模任务上评估了本方法。具体而言, 我们在 FuxiCTR 基准的两个数据集

表 4: RankElastor 与 RankMixer 在行为序列建模任务上的比较。(K) 和 (T) 分别表示 KuaiVideo 与 TaobaoAd 数据集上的结果。

模型	gAUC (K)	AUC (K)	gAUC (T)	AUC (T)
AutoInt	0.6667	0.7469	0.5744	0.6486
DCNv2	0.6675	0.7470	0.5749	0.6495
xDeepFM	0.6696	0.7471	0.5729	0.6393
RankMixer	0.6691	0.7482	0.5763	0.6508
RankElastor	0.6731	0.7514	0.5778	0.6522

上开展实验: KuaiVideo (K) 用于预测用户对短视频的点击概率, TaobaoAd (T) 用于建模用户购物行为。按照基准协议, 我们同时报告 AUC 和 Group-AUC (gAUC), 并将 RankElastor 与包括 RankMixer 在内的若干强基线进行比较。

如表 4 所示, RankElastor 在两个数据集和各项评估指标上均稳定取得最佳性能, 展现出相较所有竞争方法的明显优势。此外, 我们还观察到与图 6 所示相似的谱动态改善, 这表明我们的分析框架与所提出的统一混合设计均能有效泛化到标准 CTR 估计任务之外。这些结果凸显了本方法在更广泛推荐场景中的潜力。

5 结论

论文总结。 本文从嵌入坍塌的视角分析了 RankMixer, 并表明: 尽管与传统推荐模型相比, 它能适度提升有效秩, 但这些增益通常不足以阻止坍塌, 凸显了其核心 token 混合模块和逐 token FFN 模块的局限性。受这些洞察启发, 我们提出了 RankElastor, 这是一种新型深度推荐模型, 通过 (i) 参数化全混合和 (ii) GLU 改进的逐 token FFN 增强 RankMixer; 二者均可证明能够实现更富表达力的表示变换, 并生成谱稳健的 token 嵌入。在工业规模基准上的大量实验表明, RankElastor 始终优于包括 RankMixer 在内的强基线, 同时保持更高的有效秩以及更富表达力、非坍塌的表示。此外, 扩展定律分析证实 RankElastor 具




图 7: RankMixer 与 RankElastor 在宽度缩放 (左) 和深度缩放 (右) 下的稠密参数缩放趋势。横轴表示相对于基础模型的参数缩放因子。标记表示实测结果, 虚线表示拟合的缩放曲线, 用于刻画性能与参数缩放之间的关系。




图 8: RankMixer 与 RankElastor 在宽度和深度联合缩放下的稠密参数缩放趋势。

有更优的扩展行为, 凸显了其作为大规模推荐系统稳健且可扩展范式的潜力。

局限性与未来工作。 本文发现的有效秩动态——尤其是 RankMixer 和 RankElastor 等基于 token 变换的推荐模型中观察到的阻尼振荡轨迹——本质上依赖

于架构, 而我们的理论分析聚焦于这一类模型。尽管如此, RankMixer 风格架构强劲的实证表现表明, 仍有广阔的进一步探索空间。本研究从谱视角审视深度推荐模型中的表示坍塌, 并指出了若干有前景的未来方向, 包括更富表达力的 token 混合机制、保持谱特性的非线性模块, 以及对该架构中谱动态的更深入研究。

致谢

本工作得到腾讯犀牛鸟专项研究计划(项目编号 P00660)的支持。我们感谢匿名审稿人提出的宝贵反馈和建设性建议。我们也感谢开源社区与基准维护者, 他们提供的资源为本研究提供了支持。

References

- [1] Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Al-tenschmidt, Sam Altman, Shyamal Anadkat, et al. 2023. Gpt-4 technical report. *arXiv preprint arXiv:2303.08774* (2023).
- [2] David Balduzzi, Marcus Frean, Lennox Leary, J. P. Lewis, Kurt Wan-Duo Ma, and Brian McWilliams. 2017. The Shattered Gradients Problem: If resnets are the answer, then what is the question?. In *Proceedings of the 34th International Conference on*

- Machine Learning (Proceedings of Machine Learning Research, Vol. 70)*, Doina Precup and Yee Whye Teh (Eds.). PMLR, 342–350. <https://proceedings.mlr.press/v70/balduzzi17b.html>
- [3] Peter L. Bartlett, Philip M. Long, Gábor Lugosi, and Alexander Tsigler. 2020. Benign overfitting in linear regression. *Proceedings of the National Academy of Sciences* 117, 48 (2020), 30063–30070. arXiv:<https://www.pnas.org/doi/pdf/10.1073/pnas.1907378117> doi:10.1073/pnas.1907378117
 - [4] Don Batory, Peter Höfner, and Jongwook Kim. 2011. Feature interactions, products, and composition. In *Proceedings of the 10th ACM International Conference on Generative Programming and Component Engineering* (Portland, Oregon, USA) (GPCE '11). Association for Computing Machinery, New York, NY, USA, 13–22. doi:10.1145/2047862.2047867
 - [5] Huiyuan Chen, Vivian Lai, Hongye Jin, Zhimeng Jiang, Mahashweta Das, and Xia Hu. 2024. Towards Mitigating Dimensional Collapse of Representations in Collaborative Filtering. In *Proceedings of the 17th ACM International Conference on Web Search and Data Mining* (Merida, Mexico) (WSDM '24). Association for Computing Machinery, New York, NY, USA, 106–115. doi:10.1145/3616855.3635832
 - [6] Michael B. Cohen, Jelani Nelson, and David P. Woodruff. 2016. Optimal approximate matrix product in terms of stable rank. arXiv:1507.02268 [cs.DS] <https://arxiv.org/abs/1507.02268>
 - [7] Maxim Fishman, Brian Chmiel, Ron Banner, and Daniel Soudry. 2025. Scaling FP8 training to trillion-token LLMs. arXiv:2409.12517 [cs.LG] <https://arxiv.org/abs/2409.12517>
 - [8] Wei Guo, Hao Wang, Luankang Zhang, Jin Yao Chin, Zhongzhou Liu, Kai Cheng, Qiushi Pan, Yi Quan Lee, Wanqi Xue, Tingjia Shen, Kenan Song, Kefan Wang, Wenjia Xie, Yuyang Ye, Huifeng Guo, Yong Liu, Defu Lian, Ruiming Tang, and Enhong Chen. 2024. Scaling New Frontiers: Insights into Large Recommendation Models. arXiv:2412.00714 [cs.IR] <https://arxiv.org/abs/2412.00714>
 - [9] Xingzhuo Guo, Junwei Pan, Ximei Wang, Baixu Chen, Jie Jiang, and Mingsheng Long. 2024. On the Embedding Collapse when Scaling up Recommendation Models. In *Forty-first International Conference on Machine Learning*. <https://openreview.net/forum?id=aPVwOAr1aW>
 - [10] Harold V. Henderson and S. R. Searle. 1981. The vec-permutation matrix, the vec operator and Kronecker products: a review. *Linear and Multilinear Algebra* 9, 4 (1981), 271–288. arXiv:<https://doi.org/10.1080/03081088108817379> doi:10.1080/03081088108817379
 - [11] Dan Hendrycks and Kevin Gimpel. 2023. Gaussian Error Linear Units (GELUs). arXiv:1606.08415 [cs.LG] <https://arxiv.org/abs/1606.08415>
 - [12] Roger A Horn and Charles R Johnson. 2012. *Matrix analysis*. Cambridge university press.
 - [13] Tianyu Hua, Wenxiao Wang, Zihui Xue, Sucheng Ren, Yue Wang, and Hang Zhao. 2021. On Feature Decorrelation in Self-Supervised Learning. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 9598–9608.
 - [14] Olivier Chapelle Jean-Baptiste Tien, joycenv. 2014. Display Advertising Challenge. <https://kaggle.com/competitions/criteo-display-ad-challenge>
 - [15] Li Jing, Pascal Vincent, Yann LeCun, and Yuandong Tian. 2022. Understanding Dimensional Collapse in Contrastive Self-supervised Learning. In *International Conference on Learning Representations*. <https://openreview.net/forum?id=YevsQ05DEN7>
 - [16] Yu Kang, Junwei Pan, Jipeng Jin, Shudong Huang, Xiaofeng Gao, and Lei Xiao. 2026. Towards Unifying Feature Interaction Models for Click-Through Rate Prediction. In *Machine Learning and Knowledge Discovery in Databases. Research Track*, Rita P. Ribeiro, Bernhard Pfahringer, Nathalie Japkowicz, Pedro Larrañaga, Alípio M. Jorge, Carlos Soares, Pedro H. Abreu, and João Gama (Eds.). Springer Nature Switzerland, Cham, 451–467.
 - [17] Jared Kaplan, Sam McCandlish, Tom Henighan, Tom B. Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu, and Dario Amodei. 2020. Scaling Laws for Neural Language Models. arXiv:2001.08361 [cs.LG] <https://arxiv.org/abs/2001.08361>
 - [18] Kenji Kira and Larry A. Rendell. 1992. The feature selection problem: traditional methods and a new algorithm. In *Proceedings of the Tenth National Conference on Artificial Intelligence* (San Jose, California) (AAAI'92). AAAI Press, 129–134.
 - [19] Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead, Alexander C. Berg, Wan-Yen Lo, Piotr Dollar, and Ross Girshick. 2023. Segment Anything. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 4015–4026.
 - [20] Jianxun Lian, Xiaohuan Zhou, Fuzheng Zhang, Zhongxia Chen, Xing Xie, and Guangzhong Sun. 2018. xDeepFM: Combining Explicit and Implicit Feature Interactions for Recommender Systems. In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining* (London, United Kingdom) (KDD '18). Association for Computing Machinery, New York, NY, USA, 1754–1763. doi:10.1145/3219819.3220023
 - [21] Zhutian Lin, Junwei Pan, Haibin Yu, Xi Xiao, Ximei Wang, Zhixiang Feng, Shifeng Wen, Shudong Huang, Dapeng Liu, and Lei Xiao. 2025. Crocodile: Cross Experts Covariance for Disentangled Learning in Multi-Domain Recommendation. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management* (Seoul, Republic of Korea) (CIKM '25). Association for Computing Machinery, New York, NY, USA, 1839–1849. doi:10.1145/3746252.3761332
 - [22] Jan R. Magnus and H. Neudecker. 1979. The Commutation Matrix: Some Properties and Applications. *The Annals of Statistics* 7, 2 (1979), 381 – 394. doi:10.1214/aos/1176344621
 - [23] H. Brendan McMahan, Gary Holt, D. Sculley, Michael Young, Dietmar Ebner, Julian Grady, Lan Nie, Todd Phillips, Eugene Davydov, Daniel Golovin, Sharat Chikkerur, Dan Liu, Martin Wattenberg, Arnar Mar Hrafnkelsson, Tom Bouslos, and Jeremy

- Kubica. 2013. Ad click prediction: a view from the trenches. In *Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (Chicago, Illinois, USA) (*KDD '13*). Association for Computing Machinery, New York, NY, USA, 1222–1230. doi:10.1145/2487575.2488200
- [24] Junwei Pan, Wei Xue, Ximei Wang, Haibin Yu, Xun Liu, Shijie Quan, Xueming Qiu, Dapeng Liu, Lei Xiao, and Jie Jiang. 2024. Ads Recommendation in a Collapsed and Entangled World. In *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining* (Barcelona, Spain) (*KDD '24*). Association for Computing Machinery, New York, NY, USA, 5566–5577. doi:10.1145/3637528.3671607
- [25] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. 2021. Learning Transferable Visual Models From Natural Language Supervision. In *Proceedings of the 38th International Conference on Machine Learning (Proceedings of Machine Learning Research, Vol. 139)*, Marina Meila and Tong Zhang (Eds.). PMLR, 8748–8763. <https://proceedings.mlr.press/v139/radford21a.html>
- [26] Steffen Rendle. 2010. Factorization Machines. In *2010 IEEE International Conference on Data Mining*. 995–1000. doi:10.1109/ICDM.2010.127
- [27] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. 2022. High-Resolution Image Synthesis With Latent Diffusion Models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 10684–10695.
- [28] Olivier Roy and Martin Vetterli. 2007. The effective rank: A measure of effective dimensionality. In *2007 15th European Signal Processing Conference*. 606–610.
- [29] Noam Shazeer. 2020. GLU Variants Improve Transformer. arXiv:2002.05202 [cs.LG] <https://arxiv.org/abs/2002.05202>
- [30] Weiping Song, Chence Shi, Zhiping Xiao, Zhijian Duan, Yewen Xu, Ming Zhang, and Jian Tang. 2019. AutoInt: Automatic Feature Interaction Learning via Self-Attentive Neural Networks. In *Proceedings of the 28th ACM International Conference on Information and Knowledge Management* (Beijing, China) (*CIKM '19*). Association for Computing Machinery, New York, NY, USA, 1161–1170. doi:10.1145/3357384.3357925
- [31] Yixin Song, Haotong Xie, Zhengyan Zhang, Bo Wen, Li Ma, Zeyu Mi, and Haibo Chen. 2024. Turbo Sparse: Achieving LLM SOTA Performance with Minimal Activated Parameters. arXiv:2406.05955 [cs.LG] <https://arxiv.org/abs/2406.05955>
- [32] Will Cukierski Steve Wang. 2014. Click-Through Rate Prediction. <https://kaggle.com/competitions/avazu-ctr-prediction>
- [33] Gilbert Strang. 2022. *Introduction to linear algebra*. SIAM.
- [34] Roman Vershynin. 2011. Introduction to the non-asymptotic analysis of random matrices. arXiv:1011.3027 [math.PR] <https://arxiv.org/abs/1011.3027>
- [35] Chunqi Wang, Bingchao Wu, Zheng Chen, Lei Shen, Bing Wang, and Xiaoyi Zeng. 2025. Scaling Transformers for Discriminative Recommendation via Generative Pretraining. In *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V.2* (Toronto ON, Canada) (*KDD '25*). Association for Computing Machinery, New York, NY, USA, 2893–2903. doi:10.1145/3711896.3737117
- [36] Jiancheng Wang, Mingjia Yin, Hao Wang, and Enhong Chen. 2025. Enhancing CTR Prediction with De-correlated Expert Networks. arXiv:2505.17925 [cs.IR] <https://arxiv.org/abs/2505.17925>
- [37] Ruoxi Wang, Rakesh Shivanna, Derek Cheng, Sagar Jain, Dong Lin, Lichan Hong, and Ed Chi. 2021. DCN V2: Improved Deep & Cross Network and Practical Lessons for Web-scale Learning to Rank Systems. In *Proceedings of the Web Conference 2021* (Ljubljana, Slovenia) (*WWW '21*). Association for Computing Machinery, New York, NY, USA, 1785–1797. doi:10.1145/3442381.3450078
- [38] Jaewoo Yang, Hayun Kim, and Younghoon Kim. 2024. Mitigating Quantization Errors Due to Activation Spikes in GLU-Based LLMs. arXiv:2405.14428 [cs.CL] <https://arxiv.org/abs/2405.14428>
- [39] Mingjia Yin, Junwei Pan, Hao Wang, Ximei Wang, Shangyu Zhang, Jie Jiang, Defu Lian, and Enhong Chen. 2025. From Feature Interaction to Feature Generation: A Generative Paradigm of CTR Prediction Models. In *Forty-second International Conference on Machine Learning*. <https://openreview.net/forum?id=DataXrGzlc>
- [40] Buyun Zhang, Liang Luo, Yuxin Chen, Jade Nie, Xi Liu, Shen Li, Yanli Zhao, Yuchen Hao, Yantao Yao, Ellie Dingqiao Wen, Jongsoo Park, Maxim Naumov, and Wenlin Chen. 2024. Wukong: Towards a Scaling Law for Large-Scale Recommendation. In *Forty-first International Conference on Machine Learning*. <https://openreview.net/forum?id=8iUgr2nuwo>
- [41] Gaowei Zhang, Yupeng Hou, Hongyu Lu, Yu Chen, Wayne Xin Zhao, and Ji-Rong Wen. 2024. Scaling Law of Large Sequential Recommendation Models. In *Proceedings of the 18th ACM Conference on Recommender Systems* (Bari, Italy) (*RecSys '24*). Association for Computing Machinery, New York, NY, USA, 444–453. doi:10.1145/3640457.3688129
- [42] Weinan Zhang, Tianming Du, and Jun Wang. 2016. Deep Learning over Multi-field Categorical Data. In *Advances in Information Retrieval*, Nicola Ferro, Fabio Crestani, Marie-Francine Moens, Josiane Mothe, Fabrizio Silvestri, Giorgio Maria Di Nunzio, Claudia Hauff, and Gianmaria Silvello (Eds.). Springer International Publishing, Cham, 45–57.
- [43] Yabin Zhang, Jiakai Tang, and Xu Chen. 2025. Alleviating Dimensional Collapse Problem in Deep Recommender Models by Designing Uniformity Layers. In *Database Systems for Advanced Applications*, Makoto Onizuka, Jae-Gil Lee, Yongxin Tong, Chuan Xiao, Yoshiharu Ishikawa, Sihem Amer-Yahia, H. V. Jagadish, and Kejing Lu (Eds.). Springer Nature Singapore, Singapore, 148–163.
- [44] Guorui Zhou, Xiaoqiang Zhu, Chenru Song, Ying Fan, Han Zhu, Xiao Ma, Yanghui Yan, Junqi Jin, Han Li, and Kun Gai. 2018.

Deep Interest Network for Click-Through Rate Prediction. In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining* (London, United Kingdom) (KDD '18). Association for Computing Machinery, New York, NY, USA, 1059–1068. doi:10.1145/3219819.3219823

- [45] Jie Zhu, Zhifang Fan, Xiaoxie Zhu, Yuchen Jiang, Hangyu Wang, Xintian Han, Haoran Ding, Xinmin Wang, Wenlin Zhao, Zhen Gong, Huizhi Yang, Zheng Chai, Zhe Chen, Yuchao Zheng, Qiwei Chen, Feng Zhang, Xun Zhou, Peng Xu, Xiao Yang, Di Wu, and Zuotao Liu. 2025. RankMixer: Scaling Up Ranking Models in Industrial Recommenders. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management* (Seoul, Republic of Korea) (CIKM '25). Association for Computing Machinery, New York, NY, USA, 6309–6316. doi:10.1145/3746252.3761507

- [46] Jieming Zhu, Jinyang Liu, Shuai Yang, Qi Zhang, and Xiuqiang He. 2021. Open Benchmarking for Click-Through Rate Prediction. In *Proceedings of the 30th ACM International Conference on Information & Knowledge Management* (Virtual Event, Queensland, Australia) (CIKM '21). Association for Computing Machinery, New York, NY, USA, 2759–2769. doi:10.1145/3459637.3482486

A 定理 2.1 的论证

本节对定理 2.1 进行论证。为完整起见，我们先重述设定与结论，再给出推导。

定理重述。 设 $X \in \mathbb{R}^{T \times D}$ ，其中 $D = Td$ 且 $d \geq 1$ 。将 X 划分为由行块 $X_{ij} \in \mathbb{R}^{1 \times d}$ 构成的 $T \times T$ 网格。定义块转置算子 $\mathcal{T}$ 为

$$(\mathcal{T}(X))_{ij} = X_{ji},$$

并令 $Y = \mathcal{T}(X)$ 。记

$$\text{rank}(X) = r, \quad \text{erank}(X) = k, \quad \mu = \text{erank}(Y).$$

假设 Frobenius 正交性与谱非相干性：

$$\langle X, Y \rangle_F \approx 0, \quad \|X + Y\|_2^2 \approx \max\{\|X\|_2^2, \|Y\|_2^2\}.$$

令 $M = X + Y$ 。该定理断言

$$\frac{2k\mu}{(\sqrt{k} + \sqrt{\mu})^2} \leq \text{erank}(M),$$

$$\text{erank}(M) \leq 2(k + \mu),$$

$$\mu \leq \text{rank}(Y) \leq \min\{T, rd\}.$$

我们分两步证明这一结果：首先界定 $Y = \mathcal{T}(X)$ 的代数秩，然后分析 $M = X + \mathcal{T}(X)$ 的有效秩。

A.1 块转置算子的秩性质

我们首先给出块转置映射的秩刻画。

设定。 写出秩为 r 的分解

$$X = \sum_{\ell=1}^r \sigma_{\ell} \mathbf{u}_{\ell} \mathbf{v}_{\ell}^{\top},$$

其中 $\mathbf{u}_{\ell} \in \mathbb{R}^T$ 且 $\mathbf{v}_{\ell} \in \mathbb{R}^{Td}$ 。将每个 $\mathbf{v}_{\ell}$ 划分为 T 个连续片段 $\mathbf{v}_{\ell}^{(j)} \in \mathbb{R}^{1 \times d}$ 。

秩为 1 的情形。 令 $X = \mathbf{u} \mathbf{v}^{\top}$ 。则 $X_{ij} = u_i \mathbf{v}^{(j)}$ ，并且

$$Y_{ij} = X_{ji} = u_j \mathbf{v}^{(i)}.$$

对于 Y 的第 j 个块列，

$$C_j = \begin{bmatrix} Y_{1j} \\ \vdots \\ Y_{Tj} \end{bmatrix} = u_j \begin{bmatrix} \mathbf{v}^{(1)} \\ \vdots \\ \mathbf{v}^{(T)} \end{bmatrix}.$$

定义

$$V_{\text{stack}} = \begin{bmatrix} \mathbf{v}^{(1)} \\ \vdots \\ \mathbf{v}^{(T)} \end{bmatrix} \in \mathbb{R}^{T \times d}.$$

则 $C_j = u_j V_{\text{stack}}$ ，因此 Y 的所有块列均位于 V_{stack} 的列空间中。故

$$\text{rank}(Y) = \text{rank}(V_{\text{stack}}) \leq \min\{T, d\}.$$

一般秩为 r 的情形。 由 $\mathcal{T}$ 的线性性，

$$Y = \sum_{\ell=1}^r \sigma_{\ell} \mathcal{T}(\mathbf{u}_{\ell} \mathbf{v}_{\ell}^{\top}).$$

每一项至多为 $\mathbb{R}^T$ 贡献 d 个独立方向，因此 Y 的列空间包含于一个维数至多为 rd 的子空间中。由于 $Y \in \mathbb{R}^{T \times Td}$ ，可得

$$\text{rank}(Y) \leq \min\{T, rd\}.$$

A.2 初始化之和的有效秩

下面分析

$$M = X + \mathcal{T}(X) = X + Y.$$

的有效秩。

谱非相干性假设。 我们假设初始化产生近似 Frobenius 正交性 $\langle X, Y \rangle_F \approx 0$ ，以及非相干的主导奇异方向，

$$\|X + Y\|_2^2 \approx \max\{\|X\|_2^2, \|Y\|_2^2\}.$$

由于 $\mathcal{T}$ 对元素进行置换，

$$\|Y\|_F = \|X\|_F.$$

下界。 Frobenius 正交性意味着

$$\|M\|_F^2 \approx \|X\|_F^2 + \|Y\|_F^2 \approx 2\|X\|_F^2.$$

利用 $\|M\|_2 \leq \|X\|_2 + \|Y\|_2$ 以及

$$\|X\|_2 = \frac{\|X\|_F}{\sqrt{k}}, \quad \|Y\|_2 = \frac{\|X\|_F}{\sqrt{\mu}},$$

可得

$$\text{erank}(M) = \frac{\|M\|_F^2}{\|M\|_2^2} \geq \frac{2\|X\|_F^2}{\left(\frac{\|X\|_F}{\sqrt{k}} + \frac{\|X\|_F}{\sqrt{\mu}}\right)^2} = \frac{2k\mu}{(\sqrt{k} + \sqrt{\mu})^2}.$$

上界。 在谱非相干性条件下，

$$\|M\|_2^2 \approx \max\{\|X\|_2^2, \|Y\|_2^2\}, \quad \|M\|_F^2 \approx \|X\|_F^2 + \|Y\|_F^2.$$

因此，

$$\text{erank}(M) \approx \frac{\|X\|_F^2 + \|Y\|_F^2}{\max\{\|X\|_2^2, \|Y\|_2^2\}} \leq \frac{\|X\|_F^2}{\|X\|_2^2} + \frac{\|Y\|_F^2}{\|Y\|_2^2} = k + \mu.$$

为近似误差留出常数松弛量，可得

$$\text{erank}(M) \leq 2(k + \mu).$$

结合 Y 的代数秩界与上述有效秩界，即完成对定理 2.1 的论证。

B 定理 2.2 的论证

本节旨在对构成定理 2.2 的两个论断给出简洁且自洽的论证。直观而言，第一个论断是由激活函数的正齐次性导出的**代数限制**；第二个论断是在主方向与尾部方向之间存在可度量响应差距时发生的有效秩**概率性收缩**。下面我们先陈述结果及所需的概率假设，再分两个小节给出证明。每个证明均为显式推导，并包含必要的集中性论证。

定理重述。 设 $X \in \mathbb{R}^{T \times D}$ 满足 $\text{erank}(X) = k$ ，其中对某个固定的 $\gamma \in (0, 1)$ 有 $\frac{k}{D} \leq \gamma$ 。考虑逐行映射 $\mathcal{F}(X) = \phi(XA)B$ ，其中 $A \in \mathbb{R}^{D \times m}$ 和 $B \in \mathbb{R}^{m \times D}$ 的元素独立同分布、服从方差为 $1/D$ 的次高斯分布，且 ϕ 是一阶正齐次函数。下面两个论断将在后续小节中完整证明：

- **确定性齐次障碍：**当 X 的代数秩为 1 时，输出秩至多为 2（并且在单一符号条件下等于 1）。
- **概率性收缩：**在“谱集中 & 响应差距”条件以及关于预激活值和 ϕ 的标准集中性假设下，有效秩以高概率按常数因子 $\alpha \in (0, 1)$ 收缩。

假设（谱集中 & 响应差距）。 设 $H = XA$ 和 $\Sigma_H = \frac{1}{T}H^\top H$ ，其特征值为 $\lambda_1 \geq \lambda_2 \geq \dots$ 。固定整数 $r \geq 1$ 和 $\eta \in (0, 1]$ ，使得前 r 个特征值捕获总能量的 η 比例：

$$\sum_{i=1}^r \lambda_i \geq \eta \text{tr}(\Sigma_H).$$

对于单位方向 u ，定义方向响应比

$$\rho(u) = \frac{\mathbb{E}[\phi(\langle u, h \rangle)^2]}{\mathbb{E}[\langle u, h \rangle^2]}.$$

假设存在互不相交的单位方向集合 $\mathcal{U}_{\text{top}}$ 和 $\mathcal{U}_{\text{low}}$ ，以及常数 $0 \leq c_{\text{low}} < c_{\text{top}}$ ，使得

$$\inf_{u \in \mathcal{U}_{\text{top}}} \rho(u) \geq c_{\text{top}}, \quad \sup_{u \in \mathcal{U}_{\text{low}}} \rho(u) \leq c_{\text{low}}.$$

该条件刻画了如下经验现象：激活函数对低方差（尾部）方向的衰减强于对主方向的衰减。

B.1 确定性齐次障碍

我们首先讨论代数限制：正齐次性使逐行 FFN 无法从秩一输入中产生两个以上线性无关的输出方向。这是一个精确且基础的论证。

THEOREM B.1 (齐次性障碍——带符号输入). 令 $X = \mathbf{c}\mathbf{v}^\top \in \mathbb{R}^{T \times D}$ （代数秩为 1）。若 ϕ 是 1 次正齐次的，则对任意 A, B ，

$$\text{rank}(\mathcal{F}(X)) \leq 2, \quad \text{erank}(\mathcal{F}(X)) \leq 2.$$

若 $\mathbf{c}$ 的所有元素同号，则 $\text{rank}(\mathcal{F}(X)) = 1$ 。

直观解释。当 X 的每一行都是同一向量的标量倍数时，每个预激活都是 $\mathbb{R}^m$ 中某个固定向量的标量倍数。正齐次性将这些经缩放的预激活映射为至多两个激活向量（一个对应正标量，一个对应负标量），而线性读出至多产生两个输出方向。

证明. 记 $X = \mathbf{c}\mathbf{v}^\top$ 。对于每一行 i ,

$$x_i = c_i \mathbf{v}^\top, \quad h_i = x_i A = c_i (\mathbf{v}^\top A) = c_i u,$$

其中 $u := \mathbf{v}^\top A \in \mathbb{R}^m$ 。正齐次性意味着

$$\phi(c_i u) = |c_i| \phi(\text{sign}(c_i) u).$$

令

$$w_+ := \phi(u)B, \quad w_- := \phi(-u)B \in \mathbb{R}^D,$$

并记 $c_i^+ := \max(c_i, 0)$ 、 $c_i^- := \max(-c_i, 0)$ 。则第 i 个输出行等于

$$y_i = \phi(h_i)B = c_i^+ w_+ + c_i^- w_-.$$

将各行堆叠起来，有

$$\mathcal{F}(X) = \mathbf{c}^+ w_+^\top + \mathbf{c}^- w_-^\top,$$

它是至多两个秩一外积之和。因此 $\text{rank}(\mathcal{F}(X)) \leq 2$ 且 $\text{erank}(\mathcal{F}(X)) \leq 2$ 。若 $\mathbf{c}$ 的所有元素同号，则 $\mathbf{c}^\pm$ 中有一个为零，输出退化为秩 1。□

B.2 一般有效秩的概率收缩

下面证明收缩结论。该论证对激活并经读出后的矩阵的 Frobenius 能量及最大算子范数进行界定，并通过有效秩恒等式将二者结合起来。为使表述模块化且易于阅读，我们在本小节中明确给出标准的集中步骤。为提升清晰度与可读性，我们按照如下提纲组织证明。

- 证明所有预激活以高概率落在有界区间 $[-R, R]$ 内。
- 利用 ϕ 在 $[-R, R]$ 上的 Lipschitz 性质以及 Hanson–Wright 不等式，证明 $\|\phi(H)\|_F^2$ 集中。
- 利用矩阵 Bernstein 不等式证明 $\hat{\Sigma}_\phi = \frac{1}{T} \phi(H)^\top \phi(H)$ 集中。

- 通过响应间隙将期望与 Σ_H 联系起来，以界定 $\mathbb{E}\|\phi(H)\|_F^2$ 和 $\lambda_{\max}(\mathbb{E}\hat{\Sigma}_\phi)$ 。
- 将这些界通过线性读出 B 传播，并结合得到 $\text{erank}(\phi(H)B) \leq \alpha \text{erank}(X)$ 。

证明. 令 $H = XA \in \mathbb{R}^{T \times m}$ 、 $Z := \phi(H)$ 和 $Y := ZB = \phi(H)B$ 。记 $\Sigma_H = \frac{1}{T} H^\top H$ 的特征值为 $\lambda_1 \geq \lambda_2 \geq \dots$ ，并令 $\hat{\Sigma}_Z = \frac{1}{T} Z^\top Z$ 。

(i) 有界预激活窗口。假设每个输入行 x 均满足 $\|x\|_2^2 \leq E_{\max}$ 。由于 A 的元素是方差为 $1/D$ 、 ψ_2 -范数为 $\leq K/\sqrt{D}$ 的独立同分布次高斯随机变量，因此每个坐标 $h_{t,j}$ 均为次高斯变量，且

$$\|h_{t,j}\|_{\psi_2} \leq CK \sqrt{E_{\max}/D}.$$

对 Tm 个坐标应用并合界可知，对于任意 $\delta \in (0, 1)$ ，以至少 $1 - \delta$ 的概率，所有预激活均位于

$$[-R, R], \quad R = C' K \sqrt{\frac{E_{\max} \log(mT/\delta)}{D}},$$

之内，其中 C, C' 为绝对常数。固定一个多项式级小的 δ ，并以该高概率事件为条件。

(ii) Frobenius 集中 (Hanson–Wright)。由于 ϕ 在 $[-R, R]$ 上是 L -Lipschitz 的，每个 $\phi(h_{t,j})$ 都是参数为 $\tilde{K} = O(KL\sqrt{E_{\max}/D})$ 的次高斯变量。对二次和应用 Hanson–Wright 不等式（或 Bernstein 型界），可得：对于任意 $t \geq 0$ ，

$$\Pr(|\|Z\|_F^2 - \mathbb{E}\|Z\|_F^2| \geq t) \leq 2 \exp\left(-c \min\left\{\frac{t^2}{K^4 L^4 T m}, \frac{t}{K^2 L^2}\right\}\right),$$

其中 $c > 0$ 为绝对常数。因此， $\|Z\|_F^2$ 在 $\mathbb{E}\|Z\|_F^2$ 附近高度集中。

(iii) 谱集中 (矩阵 Bernstein)。用行 z_t 表示 $\hat{\Sigma}_Z = \frac{1}{T} \sum_{t=1}^T z_t z_t^\top$ 。每个求和项的算子范数与方差代理量均由 $K^2 L^2 E_{\max}/D$ 控制。矩阵 Bernstein 不等式给出：对于任意 $\tau > 0$ ，

$$\Pr(\|\hat{\Sigma}_Z - \mathbb{E}\hat{\Sigma}_Z\|_{\text{op}} \geq \tau) \leq 2m \exp\left(-c \frac{T\tau^2}{(K^2 L^2 E_{\max}/D)^2 r^2}\right).$$

取

$$\tau = \Theta\left(\frac{K^2 L^2 E_{\max}}{D} \sqrt{\frac{r^2 \log m}{T}}\right)$$

在所述尺度条件下, 可得 $\|\widehat{\Sigma}_Z - \mathbb{E}\widehat{\Sigma}_Z\|_{\text{op}} \leq \tau$, 其失败概率为 $O(\exp(-\Theta(r)))$ 。

(iv) 期望与响应间隙。 令 $\{u_j\}_{j=1}^m$ 为 Σ_H 的一组标准正交特征基。则

$$\mathbb{E}\|Z\|_F^2 = T \sum_{j=1}^m \rho(u_j) \lambda_j.$$

将其拆分为顶部 ($j \leq r$) 与尾部 ($j > r$) 分量, 并应用响应间隙界, 可得

$$\begin{aligned} \mathbb{E}\|Z\|_F^2 &\leq T(c_{\text{top}} \sum_{j=1}^r \lambda_j + c_{\text{low}} \sum_{j=r+1}^m \lambda_j) \\ &= T(c_{\text{top}}\eta + c_{\text{low}}(1-\eta)) \text{tr}(\Sigma_H) \\ &=: TM_F \text{tr}(\Sigma_H). \end{aligned} \quad (5)$$

Moreover,

$$\lambda_{\max}(\mathbb{E}\widehat{\Sigma}_Z) \geq c_{\text{top}}\lambda_1(\Sigma_H).$$

(v) 线性读出 B 的影响。 令 $Y = ZB$ 。由于 B 的元素独立同分布且方差为 $1/D$, 标准矩计算表明, 应用 B 会以乘性因子 $\kappa_F, \kappa_{\text{op}} > 0$ 缩放 Frobenius 范数和算子范数 (在随机矩阵缩放机制下, 这些因子为 $1 \pm o(1)$)。应用 B 后, (ii)–(iv) 中的集中界和期望界可转移至 $\|Y\|_F^2$ 和 $\|Y\|_2^2$, 仅相差这些乘性修正与较小的加性波动。

(vi) 合并结果以界定有效秩。 利用 $\text{erank}(Y) = \|Y\|_F^2 / \|Y\|_2^2$ 前述界意味着, 以至少 $1 - O(\exp(-\Theta(r)))$ 的概率有

$$\|Y\|_F^2 \leq \kappa_F \cdot TM_F \text{tr}(\Sigma_H) + \delta_F, \quad \|Y\|_2^2 \geq \kappa_{\text{op}} \cdot (c_{\text{top}}\lambda_1(\Sigma_H) - \tau) \text{tr}(\Sigma_H).$$

其中 $\tau, \delta_F, \delta_{\text{op}}$ 是来自 (ii)、(iii) 以及 B 随机性的较小集中误差。因此

$$\text{erank}(Y) \leq \frac{\kappa_F M_F + o(1)}{\kappa_{\text{op}}(c_{\text{top}} - o(1))} \cdot \frac{\text{tr}(\Sigma_H)}{\lambda_1(\Sigma_H)}.$$

定义

$$\alpha := \frac{\kappa_F M_F + o(1)}{\kappa_{\text{op}}(c_{\text{top}} - o(1))},$$

并注意到 $M_F = c_{\text{top}}\eta + c_{\text{low}}(1-\eta) < c_{\text{top}}$, 因为 $c_{\text{low}} < c_{\text{top}}$ 且 $\eta \in (0, 1]$, 于是对于足够小的集中误差, 可得 $\alpha \in (0, 1)$ 。因此, 以至少 $1 - O(\exp(-\Theta(r)))$ 的概率,

$$\text{erank}(Y) \leq \alpha \text{erank}(X),$$

由此证明概率收缩结论。 $\square$

C 定理 3.1 的论证

在本附录中, 我们论证定理 3.1。我们说明, 块粒度参数 d^* 控制着计算效率与表示能力之间的权衡: 细粒度情形 $d^* = 1$ 的表达能力严格强于任意粗粒度情形 $d^* > 1$, 且当输入具有较低有效秩时, 这一表达能力差距尤为显著。

定理重述。 设 $X \in \mathbb{R}^{T \times D}$ 和 $\mathbf{x} = \text{vec}(X) \in \mathbb{R}^N$, 其中 $N = TD$ 。固定 N 的一个因子 d^* , 并记 $K = N/d^*$ 。将 $\mathbf{x}$ 划分为 K 个连续块 $\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_K\}$, 其中 $\mathbf{b}_k \in \mathbb{R}^{d^*}$ 。带权重矩阵 $\mathbf{W} \in \mathbb{R}^{K \times K}$ 的参数化块混合层产生

$$\mathbf{y} = (\mathbf{W} \otimes \mathbf{I}_{d^*}) \mathbf{x},$$

其残差输出为

$$\mathbf{C} = \Phi_{d^*}(X; \mathbf{W}) \triangleq X + \text{reshape}((\mathbf{W} \otimes \mathbf{I}_{d^*}) \text{vec}(X)).$$

当 $d^* = 1$ 时, 该形式退化为坐标上的完整可学习线性混合。

C.1 表达能力差距定理

我们对粗粒度分块的表达能力限制进行形式化描述。

THEOREM C.1 (细粒度表达能力与子空间约束).

定义可达集

$$\mathcal{R}_{d^*}(X) = \{C \in \mathbb{R}^{T \times D} \mid \exists \mathbf{W}, C = \Phi_{d^*}(X; \mathbf{W})\}.$$

假设 $X \neq 0$ 。则:

(i) ($d^* = 1$ 时的普适可达性) $\mathcal{R}_1(X) = \mathbb{R}^{T \times D}$ 。

(ii) ($d^* > 1$ 时的严格缺失) 对每个 $d^* > 1$, 均有 $\mathcal{R}_{d^*}(X) \subsetneq \mathcal{R}_1(X)$ 。

(iii) (对有效秩的依赖) 令 $V_{\text{blocks}} = \text{span}\{\mathbf{b}_1, \dots, \mathbf{b}_K\} \subset \mathbb{R}^{d^*}$ 。由 Φ_{d^*} 产生的所有扰动，其每个块均位于 V_{blocks} 中。若 $\text{erank}(X) \ll \min\{T, D\}$ ，则 $\mathbf{b}_k$ 近似局限于 $\mathbb{R}^{d^*}$ 的一个低维子空间，因此存在 Φ_{d^*} 无法表达的细粒度变化（与 V_{blocks} 正交的方向）。

证明. 我们将证明分成两部分：(i) $d^* = 1$ 的情形；以及 (ii)–(iii) $d^* > 1$ 的情形。

第 (i) 部分. 对于 $d^* = 1$ ，当 $d^* = 1$ 时，每个块都是标量，且 $K = N$ 。更新项变为 $\mathbf{W}\mathbf{x}$ ，并且 $\text{vec}(C) = \mathbf{x} + \mathbf{W}\mathbf{x} = (\mathbf{I} + \mathbf{W})\mathbf{x}$ 。由于 $\mathbf{x} \neq 0$ ，对于任意目标向量 $\mathbf{z} \in \mathbb{R}^N$ ，都可选择 $\mathbf{W}$ （例如通过外积构造 $\mathbf{W} = (\mathbf{z} - \mathbf{x})\mathbf{x}^\top / (\mathbf{x}^\top \mathbf{x})$ ），使得 $(\mathbf{I} + \mathbf{W})\mathbf{x} = \mathbf{z}$ 。故 $\mathcal{R}_1(X) = \mathbb{R}^{T \times D}$ 。

第 (ii) 和 (iii) 部分. 对一般的 $d^* > 1$ ，写出扰动 $\mathbf{p} = \text{vec}(C - X) = (\mathbf{W} \otimes \mathbf{I}_{d^*})\mathbf{x}$ ，并将 $\mathbf{p}$ 划分为块 $\mathbf{p}_1, \dots, \mathbf{p}_K$ 。由块 Kronecker 结构，第 k 个块满足

$$\mathbf{p}_k = \sum_{j=1}^K W_{kj} \mathbf{b}_j,$$

因此对每个 k 都有 $\mathbf{p}_k \in V_{\text{blocks}}$ 。于是，每个可达扰动均逐块受限于子空间 $V_{\text{blocks}} \subseteq \mathbb{R}^{d^*}$ ；等价地，只要 $\dim(V_{\text{blocks}}) < d^*$ ， $\mathcal{R}_{d^*}(X)$ 就位于 $\mathbb{R}^{T \times D}$ 中一个维数严格更小的线性子流形内。因此，只要 $V_{\text{blocks}} \neq \mathbb{R}^{d^*}$ ，就存在所需块扰动含有与 V_{blocks} 正交分量的目标矩阵；此类目标不属于 $\mathcal{R}_{d^*}(X)$ ，所以 $\mathcal{R}_{d^*}(X) \subsetneq \mathcal{R}_1(X)$ 。

关于低有效秩为何使这种缺失具有一般性，注意到 $\text{erank}(X) = \|\mathbf{X}\|_F^2 / \|\mathbf{X}\|_2^2 \ll \min\{T, D\}$ 意味着 X 的大部分能量集中于少数全局奇异方向。在标准向量化（按行或按列）下，连续的局部块 $\mathbf{b}_k$ 因此会继承强相关性，并通常张成 $\mathbb{R}^{d^*}$ 的一个低维子空间。具体而言，在该情形下 $\dim(V_{\text{blocks}}) \ll d^*$ ，所以存在许多与 V_{blocks} 正交的细粒度方向，而 Kronecker 约束算子无法生成这些方向。这就确立了对有效秩的依赖，并完成证明。□

备注. 该论证表明， $d^* > 1$ 时的表达能力损失是结构性的：Kronecker 因子 $\mathbf{W} \otimes \mathbf{I}_{d^*}$ 强制所有逐块更新均位于同一块张成空间中。如有需要，可以根据 X 的

奇异值衰减以及块样本间的主角，对选定细粒度目标与子空间 $\mathcal{R}_{d^*}(X)$ 之间的距离给出下界，从而使结论定量化；为简洁起见，我们略去这些技术性细化。

D 定理 3.2 的论证

本节对定理 3.2 给出完整且自包含的论证。为便于阅读，我们首先重述结论，然后证明：(i) **代数提升**，即基于 GLU 的乘法项会生成潜在坐标间的二次交互；以及 (ii) 定量的高概率**有效秩提升**，具体通过将 Frobenius/算子集中与 Jacobian / 迹下界相结合，验证新方向在数值上的有效性。全文用 $\odot$ 表示 Hadamard 积，并假设逐行能量为 $\|\mathbf{x}\|_2^2 \leq E_{\max}$ 。

定理重述. 设 $X \in \mathbb{R}^{T \times D}$ 满足 $\text{erank}(X) = k$ ，且 $k/D \leq \gamma \in (0, 1)$ 。考虑

$$\mathcal{G}(X) = (\phi(XA) \odot (XC))B + XD,$$

其中 $A, C \in \mathbb{R}^{D \times m}$ 和 $B \in \mathbb{R}^{m \times D}$ 的元素为独立同分布的次高斯随机变量，其方差为 $1/D$ ， ψ_2 -范数为 $\leq K/\sqrt{D}$ 。若隐藏层宽度满足 $m \geq C_0 k \log D$ ，其中 C_0 为普适常数，则以至少 $1 - \exp(-ck)$ 的概率：

- (代数提升) $\text{rank}(\phi(XA) \odot (XC)) \geq \min(D, \frac{k(k+1)}{2})$ 。
- (有效秩提升) 存在 $\delta > 0$ （依赖于 $\gamma, K, E_{\max}$ ），使得

$$\text{erank}(\mathcal{G}(X)) \geq \text{erank}(X) + \delta.$$

本节余下部分依次证明这两个结论，然后给出 Jacobian / 迹分析，以说明新增的代数方向为何具有显著数值意义（对应非消失奇异值）。

D.1 代数提升：二次多项式张成空间

我们首先证明，GLU 风格的乘性项能够实现 X 的 k 维潜在系数中的二次单项式；随后，随机投影以高概率将这些单项式转化为新的独立代数方向。

潜在因子分解. 由于 $\text{erank}(X) = k$ ，存在分解

$$X = SV^\top, \quad S \in \mathbb{R}^{T \times k}, \quad V \in \mathbb{R}^{D \times k}, \quad V^\top V = I_k,$$

因此对 $s_t \in \mathbb{R}^k$, 每一行 $x_t = V s_t$ 。定义

$$U := V^\top A \in \mathbb{R}^{k \times m}, \quad W := V^\top C \in \mathbb{R}^{k \times m},$$

并令 $u_j, w_j \in \mathbb{R}^k$ 分别表示 U, W 的第 j 列。于是乘性预特征的元素为

$$z_{t,j} = \phi(\langle u_j, s_t \rangle) \langle w_j, s_t \rangle.$$

二次分量。 在零点附近展开 ϕ (这在小方差预激活机制下成立; 更一般地, 在有界区间上采用单变量 Taylor 展开/多项式逼近也可得到相同论证):

$$\phi(z) = a_1 z + a_2 z^2 + O(z^3).$$

因此, $z_{t,j}$ 的主导二次分量为

$$q_{t,j} := a_1 \cdot \langle u_j, s_t \rangle \langle w_j, s_t \rangle.$$

记对称二次单项式向量为

$$\zeta_t := \text{vecs}(s_t s_t^\top) \in \mathbb{R}^q, \quad q = \frac{k(k+1)}{2},$$

于是存在确定性线性泛函 $r_j \in \mathbb{R}^q$ (矩阵 $u_j w_j^\top$ 的对称向量化), 使得

$$q_{t,j} = a_1 \langle r_j, \zeta_t \rangle.$$

到隐藏单元的随机线性映射。 将 ζ_t 堆叠为 $\mathcal{Z} \in \mathbb{R}^{T \times q}$ (行为 $\zeta_t^\top$)。所有隐藏单元上的二次部分为

$$Z_{\text{quad}} = \mathcal{Z} R^\top, \quad R := [r_1, \dots, r_m]^\top \in \mathbb{R}^{m \times q}.$$

由于 A, C 是随机次高斯的, 且 V 是固定的正交归一矩阵, 因此 R 的行 r_j 是 $\mathbb{R}^q$ 中独立同分布的次高斯向量, 其方差尺度为 $1/D$ (相差 K 因子)。标准非渐近结果 (见 Vershynin) 表明, 对于任意固定的 q 维子空间, 只要 $m \gtrsim q$ (并满足一个温和的 $\log D$ 因子以承接后续读出), 随机矩阵 R 就以高概率为单射。具体而言, 若

$$m \geq C_0 q \log D = C_0 \frac{k(k+1)}{2} \log D,$$

则以至少 $1 - \exp(-cq)$ 的概率有 $\text{rank}(R) = \min\{m, q\}$ 。

通过读出 B 。 读出前乘性项在应用 $R^\top$ 后, 其行空间等于 $\mathcal{Z}$ 的列张成空间。应用线性读出 $B \in \mathbb{R}^{m \times D}$ (元素独立同分布、方差为 $1/D$) 会将 $\mathbb{R}^m$ 映射到 $\mathbb{R}^D$ 。以高概率, B 的秩为 $\min\{m, D\}$ 。合并这些秩下界可得

$$\text{rank}((\phi(XA) \odot (XC))B) \geq \min\{D, q\} = \min\left(D, \frac{k(k+1)}{2}\right)$$

其成立概率至少为 $1 - \exp(-c'k)$ 。这证明了代数提升结论。

D.2 有效秩的定量增加与 Jacobian 谱

在确立代数提升之后, 我们进一步证明: 乘性项会在与原始线性路径正交的方向注入非平凡的 Frobenius 能量, 并且在宽度条件下, GLU 改进的 P-FFN 的 Jacobian 具有较大的迹 (奇异值平方和)。结合残差 XD , 这些观察意味着数值意义上的 (有效秩) 提升。

记号与分解。 将乘性特征记为 $Z \in \mathbb{R}^{T \times m}$, 其元素为 $z_{t,j} = \phi(\langle u_j, s_t \rangle) \langle w_j, s_t \rangle$ 。经过读出 B 并加入残差 XD 后, 网络输出为

$$Y = ZB + XD.$$

令 $P_{\parallel}$ 表示到 X 行空间 (维数为 $\leq k$) 的正交投影算子, 并令 $P_{\perp} = I - P_{\parallel}$ 。我们的目标是给出 $\mathbb{E}\|P_{\perp} Y\|_F^2$ 的下界, 并证明在所述缩放下它为 $\Omega(m^{-1} k \log D)$; 这足以使有效秩增加一个正的 δ 。

正交能量通过随机读出时在期望意义下得到保持。 由于 B 的元素独立同分布、方差为 $1/D$, 且与 Z 独立,

$$\begin{aligned} \mathbb{E}_B \|P_{\perp}(ZB)\|_F^2 &= \mathbb{E}_B \text{tr}(B^\top Z^\top P_{\perp} Z B) \\ &= \text{tr}(\mathbb{E}_B [B B^\top] \mathbb{E}[Z^\top P_{\perp} Z]) \\ &= \mathbb{E}\|P_{\perp} Z\|_F^2. \end{aligned} \quad (7)$$

因此, 只需给出 $\mathbb{E}\|P_{\perp} Z\|_F^2$ 的下界。

逐列贡献源自二次特征。 将 $Z = [z^{(1)} | \dots | z^{(m)}]$ 按列 $z^{(j)} \in \mathbb{R}^T$ 分解 (元素为 $z_t^{(j)}$)。使用二次分解 $z^{(j)} = q^{(j)} + r^{(j)}$, 其中 $q_t^{(j)} = a_1 \langle u_j, s_t \rangle \langle w_j, s_t \rangle$ 是二次分量, $r^{(j)}$ 汇集高阶/较小项, 可得

$$\mathbb{E} \|P_{\perp} Z\|_F^2 \geq \sum_{j=1}^m \mathbb{E} \|P_{\perp} q^{(j)}\|_2^2 - \sum_{j=1}^m \mathbb{E} \|r^{(j)}\|_2^2.$$

在小方差机制下, 或通过截断 (预激活的有界区间), 余项 $\sum_j \mathbb{E} \|r^{(j)}\|_2^2$ 为低阶项; 因此我们聚焦于占主导的 $q^{(j)}$ 项。

与提升论证中一样, $q^{(j)} = \mathcal{Z} Q_j$, 其中 $\mathcal{Z} \in \mathbb{R}^{T \times q}$ 汇集对称二次单项式 ζ_t , 而 $Q_j \in \mathbb{R}^q$ 是 $u_j w_j^\top$ 的对称向量化。因此

$$\mathbb{E} \|P_{\perp} q^{(j)}\|_2^2 = \mathbb{E}_{Q_j} Q_j^\top (\mathcal{Z}^\top P_{\perp} \mathcal{Z}) Q_j.$$

对随机 Q_j (次高斯行) 取平均可得

$$\mathbb{E}_{Q_j} \mathbb{E}_S \|P_{\perp} q^{(j)}\|_2^2 = \text{tr} (\mathcal{Z}^\top P_{\perp} \mathcal{Z} \cdot \mathbb{E}[Q_j Q_j^\top]).$$

由于 $\mathbb{E}[Q_j Q_j^\top]$ 在 q 维单项式空间上与单位阵成比例 (相差依赖于 $K, E_{\max}$ 的常数), 可得

$$\mathbb{E} \|P_{\perp} q^{(j)}\|_2^2 \geq c_0 \cdot \text{tr} (\mathcal{Z}^\top P_{\perp} \mathcal{Z}) = c_0 \sum_{t=1}^T \|P_{\perp} \zeta_t\|_2^2,$$

其中某个 $c_0 > 0$ 。对 $j = 1, \dots, m$ 求和得到

$$\mathbb{E} \|P_{\perp} Z\|_F^2 \geq m c_0 \sum_{t=1}^T \|P_{\perp} \zeta_t\|_2^2 - (\text{small remainders}).$$

二次能量中有非平凡比例位于线性张成空间之外。 投影算子 $P_{\perp}$ 仅移除位于 S 各行的线性张成空间 (维数为 $\leq k$) 中的分量。向量 ζ_t 位于 $q = \frac{k(k+1)}{2}$ 维二次特征空间中。除非数据 $\{s_t\}$ 在代数意义上退化 (对典型数据而言这是零测事件, 加入微小扰动时亦然), 否则二次能量中有恒定比例位于线性张成空间之外。形式化地, 令 $\mathcal{P}_{\text{quad}, \parallel}$ 表示二次特征空间到由 s 的线性函数所张成子空间的投影; 该子空间维数至多为 k 。因此, 在随机设计假设及 $m \gtrsim k \log D$ 条件下,

$$\sum_{t=1}^T \|P_{\perp} \zeta_t\|_2^2 \geq c_1 T \cdot \frac{k \log D}{m},$$

其中常数 $c_1 > 0$ 。与前一公式结合可得

$$\mathbb{E} \|P_{\perp} Z\|_F^2 \geq c' m T \cdot \frac{k \log D}{m} = c' T k \log D,$$

因此 (以 T 归一化后), 逐行平均正交能量至少为 $c' k \log D$ 。除以读出缩放 (方差 $1/D$) 并按上述方式追踪常数, 可得

$$\mathbb{E} \|P_{\perp} Y_{\text{mult}}\|_F^2 \geq c'' m^{-1} k \log D,$$

其中某个 $c'' > 0$ 依赖于 $K, E_{\max}$ 。

Jacobian 迹下界可证实数值有效性。 为了说明新方向不仅在代数上存在, 而且在数值上有效 (即对应非消失奇异值), 我们考察 GLU 改进的 P-FFN 块的逐行 Jacobian, 并给出其迹 $\text{tr}(J_g(x)^\top J_g(x))$ (奇异值平方和) 的下界。

对于单行 x , GLU 改进的 P-FFN 块关于输入行的 Jacobian 为

$$J_g(x) = D^\top + B^\top \text{diag}(C^\top x) \text{diag}(\phi'(A^\top x)) A^\top + B^\top \text{diag}(\phi(A^\top x)) C^\top. \quad (8)$$

乘性项贡献其中间两项。对 A, C, B (并在需要时对输入 x) 取期望, 并利用 A, C, B 的元素是方差为 $1/D$ 的独立次高斯变量, 非渐近奇异值界给出了期望迹的 $c_2 k \log D$ 阶下界, 同时需减去由激活响应常数引起的纯加性 FFN 上界项 $C_K(c_{\text{top}} \mathcal{E}_{\text{top}} + c_{\text{low}} \mathcal{E}_{\text{low}})$ 。直观而言, 乘性 Jacobian 从随机二次提升中汇集了价值为 $k \log D$ 的奇异值平方质量 ($\log D$ 因子反映了 D 个输出所需的 Johnson–Lindenstrauss 风格嵌入稳定性)。残差 $D^\top$ 保留原始方向, 因此不会抵消这一新增质量。

集中性与论证的完成。 将 Hanson–Wright 和 Matrix Bernstein 集中不等式应用于迹项, 可以证明经验逐行平均值 $\frac{1}{T} \sum_{t=1}^T \text{tr}(J_g(x_t)^\top J_g(x_t))$ 以高概率集中在其期望附近。因此, 逐行平均迹以 $1 - O(\exp(-ck))$ 的概率为 $\Omega(k \log D)$ 。

将正交 Frobenius 能量下界与 Jacobian 迹下界结合起来, 并注意到残差 XD 保留了原始线性子空间中的能量, 我们得出: 输出 Y 在正交方向上具有 $\Theta(m^{-1} k \log D)$ 阶的额外 Frobenius 质量, 而其最大

奇异值平方仍与 XD 的相当。因此, 有效秩以高概率增加一个加性 $\delta = \Theta(k \log D / \sigma_{\max}^2(XD)) > 0$, 即

$$\text{erank}(\mathcal{G}(X)) \geq \text{erank}(X) + \delta,$$

其成立概率至少为 $1 - \exp(-ck)$, 证明完毕。