

RecHarness: 面向自进化推荐系统的多臂老虎机路由智能体框架

Haoran Ling^{*†1}, Yuecheng Li^{*2}, Zeyu Song^{*2}, Jing Yao², Shuwen Kang², Chi Lu^{‡2},
Wenjin Wu², Peng Jiang²

¹佐治亚理工学院, ²快手科技, 中国

hling34@gatech.edu, {liyuecheng, songzeyu, yaojing03, kangshuwen, luchi, wuwenjin, jiangpeng}@kuaishou.com

Abstract

现代推荐模型的优化仍高度依赖工程师手动迭代架构、目标函数和训练策略。尽管基于 LLM 的智能体可以自动化这一反复试验过程, 但让 LLM 同时选择修改方向并生成具体假设, 在实验预算有限时往往会导致搜索不稳定。针对这一挑战, 我们提出 **RecHarness**, 一种用于自动优化推荐系统的多臂老虎机路由智能体框架。RecHarness 将优化过程分为两个步骤: 多臂老虎机路由根据历史验证反馈选择下一修改方向, LLM 则在所选方向内生成具体优化假设与可执行的代码修改。为维持长程探索, RecHarness 使用跳出盆地机制, 在局部修改陷入停滞时激活结构跳跃臂。在多种推荐任务、数据集和模型骨干网络上, RecHarness 相较于基于 LLM 推理的搜索取得了更稳定的性能提升, 并能更有效地利用有限试验预算。在某大型短视频广告平台为期 7 天的线上 A/B 测试中, 所选候选方案将 ADVV 提升 2.084%、Revenue 提升 0.534%、Exposure 提升 0.559%。代码可在 <https://github.com/6lyc/RecHarness> 获取。

引言

基于 LLM 的机器学习工程 (MLE) 智能体在自动化模型开发方面取得了显著进展。给定数据集、评估指标和初始代码库后, 这些智能体能够检查任务描述、编写或修改训练代码、执行实验, 并利用验证结果与执行日志迭代改进候选方案 (Huang et al. 2023; Chan et al. 2025; Jiang et al. 2025; Nam et al. 2026)。现有方法通常将这一过程表述为候选程序搜索, 使用多分支搜索、树搜索或图搜索探索可能的方案, 并通过验证分数选择有潜力的分支。Reasoning-as-Gradient (Zhang et al. 2026) 等近期工作指出, 执行反馈不应仅被压缩为标量分数: 错误日志、训练动态和验证结果也可以作为文本优化信号, 引导更具方向性的代码更新 (Pryzant et al. 2023; Shinn et al. 2023; Madaan et al. 2023; Yuksekgonul et al. 2025; Zhang et al. 2026)。这类工作表明, LLM 推理的价值不仅在于生成代码, 还在于解释实验反馈并形成下一项改进假设。

推荐系统 (RecSys) 优化 (Sun et al. 2019; He et al. 2020; Yang et al. 2026; Li et al. 2026a,b) 是基于 LLM 的 MLE 智能体一个自然而且具有重要实践意义的应用场景。推荐系统开发不同于一次性模型构建, 往往是一个持续迭代训练代码的过程。在序列推荐、排序与点击

预测以及观看时长预测中, 模型质量会受到骨干架构、训练目标、优化策略、正则化、特征交互设计、序列建模选择和实现细节的影响。因此, 优化目标并非单个固定的推荐模型模板, 而是一个更广泛的工程搜索空间, 其最佳方案取决于数据集、任务表述、模型族与评估目标。近期智能体推荐研究同样强调, 现代推荐优化仍然高度依赖迭代式工程, 而基于智能体的系统可以借助持久记忆和不断演化的优化方法论实现这一循环的自动化 (Cheng et al. 2026; Ou et al. 2026; Mu et al. 2026)。因此, 我们的目标并非优化单个推荐模型模板, 而是构建一个由验证结果引导的框架, 使其能够适应不同的推荐场景、模型族和评估目标。

然而, 直接将通用 MLE 智能体用于推荐优化, 会面临一个重要的系统挑战。每次候选修改通常都需要代码生成、执行、训练和验证, 因此每次试验都会消耗不可忽略的预算。此外, 推荐模型优化并不是一组彼此独立的一次性实验, 而是持续的模型迭代过程。每次试验除了最终验证分数外, 还会提供与优化相关的证据, 例如收敛行为、训练稳定性, 以及暴露出的失败模式或瓶颈。必须结合当前模型状态、训练动态和此前修改来解释这些信号。因此, 自动优化器不能只依赖标量验证反馈: 它必须解释每一轮的日志、趋势和失败信号, 同时积累跨轮次证据, 以判断哪些优化方向有效。近期关于基于 LLM 的序列决策研究为这一设计提供了有益启发。上下文多臂老虎机实验表明, 通用 LLM 可能需要外部摘要或算法支持才能可靠探索 (Krishnamurthy et al. 2024); 而 LLM 增强的多臂老虎机方法则表明, 将 LLM 推理或预测与经典多臂老虎机机制相结合, 可能比由 LLM 直接选择臂更有效 (Sun et al. 2026)。这些发现与我们的场景一致: 验证反馈既应作为供 LLM 推理使用的文本反馈, 也应作为指导后续试验的显式后验状态。

基于上述发现, 我们提出 **RecHarness**, 一种面向自进化推荐系统、由验证结果引导的优化框架。RecHarness 将优化组织为一系列相互隔离的训练—验证试验。每一轮中, 它维护针对目标推荐场景定义的候选优化臂, 使用验证反馈更新这些臂的后验状态, 并采用 Thompson 风格的路由, 在有限试验预算下选择有潜力的臂。给定选中的臂后, LLM 利用当前最佳方案、执行日志、验证趋势以及从实验记忆中提炼并动态更新的 Experiment Skill, 形成具体改进假设并生成可执行的代码修改。对于架构或损失函数变更等影响较大的修改, RecHarness 还支持重新调优窗口, 使系统能够评估结构跳跃在局部适配后是否变得有益。因此, **RecHar-**

^{*}These authors contributed equally.

[†]本工作完成于快手科技实习期间。

[‡]Corresponding author.

ness 将 LLM 推理与验证驱动的后验路由相结合：标量验证证据跨试验累积，用于决定下一步尝试哪些优化方向；文本反馈则帮助 LLM 在所选方向内生成具体假设和可执行的代码变异。

我们的贡献如下：

- 我们提出 RecHarness，这是首个面向自进化推荐系统的优化框架，旨在支持多样化的推荐场景。
- 我们设计了一种多臂老虎机路由优化机制，通过多臂老虎机路由与 LLM 推理联合利用标量分数和文本反馈。
- 我们跨推荐任务、数据集和模型模板开展实证研究，证明 RecHarness 能够在有限试验次数下有效提升推荐性能；线上 A/B 测试进一步证实了其在业务指标上的增益。

相关工作

LLM 驱动的 MLE 智能体

长期以来，自动化机器学习 (AutoML) (Thornton et al. 2013; Feurer et al. 2015; Zheng et al. 2023) 开发主要通过超参数优化 (HPO) (Feurer and Hutter 2019; Akiba et al. 2019) 和神经架构搜索 (NAS) (Luo et al. 2018; Liu, Simonyan, and Yang 2019; Ren et al. 2021) 实现，但这些方法只能在预定义配置空间内运行。它们调整标量超参数，或在固定架构模板内搜索，因而难以处理任何可枚举网格之外的代码级修改，例如重新设计损失函数、切换架构模块或改变池化策略。基于推理与行动交错的范式 (Yao et al. 2023)，基于 LLM 的 MLE 智能体读取任务描述、生成训练代码、运行实验，并利用验证结果与执行日志迭代改进候选方案 (Chan et al. 2025)。一条主流研究路线将其建模为候选程序上的搜索问题。AIDE (Jiang et al. 2025) 将方案组织成树，并采用贪心策略，对最佳节点进行起草、调试或改进。AIRA (Toledo et al. 2026) 则将这类智能体形式化为在算子集合上运行的搜索策略。这些方法基本上无需梯度，它们将执行反馈压缩为标量验证分数，仅用于对分支进行排序和剪枝。较新的工作认为，这种做法丢弃了宝贵信号：Reasoning-as-Gradient (Zhang et al. 2026) 将错误日志、训练动态和验证结果视为文本梯度，用于引导定向更新，并表明随着底层模型推理能力增强，这种定向优化会日益超越穷举式树搜索。

作为 ML 应用最广泛的领域之一，推荐自然是这类智能体的目标场景 (Zheng et al. 2023; Wang et al. 2022; Zhao et al. 2021; Lyu et al. 2022)。推荐系统开发本质上是迭代式的：序列推荐、排序/CTR 预测和观看时长建模都会受到训练目标、优化策略、特征交互和结构选择的影响，而工程师会逐轮调整这些因素，因此该领域非常适合将经验驱动的代码级迭代转化为可执行的自动搜索。

自进化智能体推荐系统

由于推荐系统开发本质上具有迭代性，越来越多的工作将基于 LLM 的智能体视为自动化推荐工程师，通过闭环生成、实现和评估模型改进。在工业规模下，Google 的双循环框架 (Wang et al. 2026) 在内循环中通过低成本代理指标筛选假设，在外循环中依据延迟业务指标验证候选方案。GEARS (Yun et al. 2026) 将排序专业知识封装为由高层意图引导的可复用智能体

技能。AgentX (Lao et al. 2026) 运行四阶段闭环，并将执行轨迹提炼为语义梯度更新，以增强智能体自身。EvoRec (Mu et al. 2026) 通过从持久实验记忆中提炼可复用策略，使模型与其方法共同演化。NOVA (Liu et al. 2026) 使用受 SGD 启发的架构梯度聚合先前修改、诊断结果和指标反馈，从而指导架构演化。

然而，让 LLM 自由决定探索方向会导致探索过度发散：候选方案在开放空间中被提出，却缺少有原则的试验分配，而每次修改都要付出昂贵且有噪声的训练-验证试验成本，最终导致成功率和优化效率都较低 (Krishnamurthy et al. 2024; Sun et al. 2026; Bouneffouf and Feraud 2026)。因此，关键在于将推荐领域先验与后验探索概率结合起来，构建一个约束下一步探索方向的框架。

方法

RecHarness 将推荐模型迭代组织为三级控制过程。首先，人类专家定义优化目标、验证指标和候选编辑臂。其次，多臂老虎机路由利用标量验证反馈，在候选臂之间分配有限的试验预算，决定下一轮应搜索哪些编辑维度。第三，Experiment Skill 与 LLM 推理共同形成下一步改进假设。简而言之，人类定义优化什么以及考虑哪些臂；RecHarness 决定将试验分配到何处，以及如何形成下一步改进假设。图 1 给出了该框架的概览。

将推荐器优化视为多臂老虎机问题

我们研究有限时间预算下的推荐器优化。输入包括初始推荐器实现 f_0 、训练-验证划分 $\mathcal{D} = (\mathcal{D}_{\text{train}}, \mathcal{D}_{\text{val}})$ 、验证指标 M 以及试验运行时预算。每次试验包括应用一次模型变异、训练变异后的推荐器，并使用验证指标对其评估。指标 M 取决于任务；在序列推荐实验中，我们使用目标数据集上的验证 HR@10。我们将实现 f 所诱导的可执行训练过程记为

$$\omega_f = \text{Train}(f, \mathcal{D}_{\text{train}}), \quad M(f) = M(\omega_f; \mathcal{D}_{\text{val}}), \quad (1)$$

其中， ω_f 表示该实现产生的已训练参数或检查点。

形式化地，给定任务 T 和有效模型实现空间 $\mathcal{S}$ ，我们的目标是在资源预算 B 下找到最佳实现：

$$s^* = \arg \max_{s \in \mathcal{S}} h(T, s) \quad \text{s.t.} \quad C(s) \leq B, \quad (2)$$

其中， $h(T, s)$ 在任务 T 上评估实现 s ， $C(s)$ 表示生成、训练和验证该实现的成本。RecHarness 将这一预算约束目标具体化为序贯试验分配：每轮仅评估预算允许的一组候选变异，并利用其验证结果指导后续搜索。对于试验组 G_t ，消耗的预算为

$$C_t = \sum_{a \in G_t} c(f_{t,a}), \quad \sum_t C_t \leq B, \quad (3)$$

其中， $c(f_{t,a})$ 包括在臂 a 下生成的候选方案所产生的代码生成、执行、训练和验证成本。

RecHarness 将搜索空间表示为预定义的编辑臂集合：

$$\mathcal{A} = \{a_1, a_2, \dots, a_K\}. \quad (4)$$

臂集合由目标任务、待优化模型以及人类定义的候选臂共同决定，因此该形式化方法适用于广泛的推荐模型优化场景。每个臂表示一个可解释的编辑维度，而不是一个确切的代码补丁或标量超参数。对于序列推荐




Figure 1: RecHarness 概览。RecHarness 在三个层级上运行：层级 1 定义由人指定的优化上下文，包括目标、验证指标和候选修改臂；层级 2 使用标量验证反馈执行基于多臂老虎机的试验分配；层级 3 应用 Experiment Skill 与 LLM 推理，生成假设、可执行变异、验证分数和文本经验。通过验证的改进方案会被晋升为下一次迭代的最新最佳方案。

器，示例包括调节学习率计划、调整 dropout 或权重衰减、改变嵌入维度、修改层数或注意力头数、改变序列池化策略、添加特征或改变损失函数。根据编辑粒度，RecHarness 将臂分为用于细化的局部臂和用于非局部吸引域跃迁的跳跃臂：

$$\mathcal{A} = \mathcal{A}_{\text{local}} \cup \mathcal{A}_{\text{jump}}, \quad \mathcal{A}_{\text{local}} \cap \mathcal{A}_{\text{jump}} = \emptyset. \quad (5)$$

搜索以当前最优方案为基础。令 f_t^* 表示第 t 轮之前经过验证的最佳实现，其验证得分为 $s_t^* = M(f_t^*)$ 。在第 t 轮，RecHarness 选择一个或多个臂，并相对于 f_t^* 生成候选模型变异，而不是独立地修改原始模板。我们将以 LLM 为条件的变异算子记为

$$f_{t,a} = \mu_\phi(f_t^*, a, m_t, \ell_t), \quad (6)$$

其中， m_t 是 Experiment Skill， ℓ_t 汇总近期日志和验证轨迹， ϕ 表示用于代码生成的冻结 LLM。执行所得试验后，只有当候选方案优于当前最优方案时才会晋级：

$$f_{t+1}^* = \begin{cases} \arg \max_{f \in \mathcal{V}_t} M(f), & \text{if } \max_{f \in \mathcal{V}_t} M(f) > s_t^*, \\ f_t^*, & \text{otherwise,} \end{cases} \quad (7)$$

其中， $\mathcal{V}_t$ 是第 t 轮中的有效候选集合。否则，当前最优方案保持不变。

对于第 t 轮选中的臂 a ，标量反馈由其验证结果导出。令相对于当前最优方案的验证提升为

$$\Delta_t(a) = M(f_{t,a}) - s_t^*. \quad (8)$$

为了比较同一并行组内产生的候选方案，我们使用组统计量对提升进行归一化：

$$\hat{A}_t(a) = \frac{\Delta_t(a) - \text{mean}_{b \in \mathcal{G}_t} \Delta_t(b)}{\text{std}_{b \in \mathcal{G}_t} \Delta_t(b) + \epsilon}, \quad (9)$$

其中， ϵ 是用于保证数值稳定性的小常数。后验更新使用二元成功信号。普通局部试验仅在其有效、优于同一试验组的平均候选方案且不低于历史最优方案时才被视为成功：

$$r_t(a) = \mathbb{I} \left[f_{t,a} \text{ is valid} \wedge \hat{A}_t(a) > 0 \wedge M(f_{t,a}) \geq s_t^* \right], \quad (10)$$

该抽象被视为一个黑盒的、以当前最优方案为条件的多臂老虎机问题。奖励 $r_t(a) \in \{0, 1\}$ 是编辑臂 a 的二元成功信号，仅在其候选方案完成生成、执行、训练和验证后才能观测。该奖励的实现值取决于当前最优方案、先前编辑和实现上下文。因此，RecHarness 不假设每个臂都具有固定的全局成功概率。相反，每个臂的后验统计量作为局部证据，用于在有限预算下分配后续试验。

用于探索—利用的 Thompson 采样

多臂老虎机路由器回答了有限试验预算下接下来应在哪里搜索这一试验分配问题。RecHarness 使用 Thompson 采样在编辑臂之间分配试验。对于每个臂 a ，系统维护一个 Beta 后验

$$\theta_a \sim \text{Beta}(\alpha_a, \beta_a), \quad (11)$$

其中， α_a 和 β_a 汇总先前成功和失败的结果。每轮开始时，RecHarness 从每个可用臂的 Beta 后验中采样 θ_a 。该值是当前后验下采样得到的成功概率，RecHarness 选择采样值最大的臂。所选臂并不规定确切的代码编辑，而是定义下一轮模型迭代的语义方向。

每轮结束后, RecHarness 使用上述定义的二元验证结果更新相应臂的后验:

$$\alpha_a \leftarrow \alpha_a + r_t(a), \quad \beta_a \leftarrow \beta_a + 1 - r_t(a). \quad (12)$$

对于成组并行试验, 所选组为

$$\mathcal{G}_t = \text{TopG}_{a \in \mathcal{A}_t}(\tilde{\theta}_a), \quad \tilde{\theta}_a \sim \text{Beta}(\alpha_a, \beta_a), \quad (13)$$

其中, $\mathcal{A}_t$ 是当前可用臂集合。该路由机制同时支持利用和探索: 它倾向于将试验分配给过去曾带来验证提升的编辑维度, 同时仍为证据有限、具有不确定性的臂分配概率质量。RecHarness 还支持成组并行试验。在普通搜索轮中, 它选择 G 个臂, 并行执行 G 个候选变异, 从而在同一当前最优方案下比较多个候选方向。这一设计也遵循近期研究证据: 直接让 LLM 选择多臂老虎机的臂可能并不可靠, 而将 LLM 推理与显式多臂老虎机结构结合, 可以形成更可控的探索—利用机制 (Krishnamurthy et al. 2024; Sun et al. 2026)。

Experiment Skill 与反馈

在多臂老虎机路由选择臂后, RecHarness 使用 Experiment Skill 和 LLM 推理, 在每个选中臂内形成下一步改进假设。Experiment Skill 是一份紧凑的文本指南, 记录当前最优方案、近期成功编辑、无效或被拒绝的方向、失败原因以及验证趋势的简短摘要。它不对臂排序, 也不取代 Thompson 采样; 它在臂选定后为 LLM 提供条件, 使下一步改进假设能够反映先前证据。

每轮验证后, Experiment Skill 都会自动更新。对于成功或晋级的试验, RecHarness 将臂、补丁摘要、验证得分和提升模式提炼为可复用经验, 并将其追加到近期文本梯度中。对于失败、无效或有害的试验, 系统会将规避规则提取到失败反馈部分, 例如避免重复的接口不匹配、训练崩溃或已知的低收益编辑。随后, 系统根据当前最优方案、得分历史和近期试验摘要, 生成更新后的 Experiment Skill 文档。

形式化地, Experiment Skill 状态由汇总算子更新:

$$m_{t+1} = \text{Summarize}(m_t, \{a, f_{t,a}, M(f_{t,a}), e_{t,a}\}_{a \in \mathcal{G}_t}), \quad (14)$$

其中, m_t 表示文本形式的 Experiment Skill 状态, $e_{t,a}$ 表示执行状态、错误消息和紧凑训练日志。Experiment Skill 会影响变异算子 μ_ϕ , 但不会影响上述后验更新, 从而防止文本摘要悄然覆盖路由积累的标量证据。

因此, 两条反馈通道承担不同职责。标量验证反馈更新多臂老虎机后验, 用于决定接下来搜索哪些臂; 文本形式的 Experiment Skill 反馈则帮助 LLM 在选定臂内推理下一步改进假设、应复用哪些模式以及应避免哪些失败模式。

感知吸引域的跳跃与重新调优

以当前最优方案为基础的搜索具有较高的样本效率, 但最终可能在局部吸引域内饱和。因此, RecHarness 引入了一种轻量级的感知吸引域跳跃机制。我们将臂集合划分为局部臂 $\mathcal{A}_{\text{local}}$ 和跳跃臂 $\mathcal{A}_{\text{jump}}$; 前者在当前吸引域内执行增量细化, 后者执行更高层次的结构变化, 可能将搜索转移到不同吸引域。

令 s_t^* 表示第 t 轮之前当前最优方案的验证得分。我们将最近 W 轮窗口内的近期提升率衡量为

$$\hat{v}_t = \frac{s_t^* - s_{t-W}^*}{W}. \quad (15)$$

数据集	# 用户	# 物品	# 交互
Movies	11,947	17,490	144,071
Scientific	23,627	25,764	266,164
Electronics	27,601	31,533	292,308
CDs	18,481	30,951	284,695

Table 1: Amazon Reviews 数据集的统计信息。

划分	交互数	用户数	物品数	平均交互数/用户
训练	12,530,806	7,176	10,728	$\sim 1,746$
测试	4,676,570	1,411	3,327	$\sim 3,314$

Table 2: KuaiRec 数据集的统计信息。

当近期提升率低于阈值 τ 时, 认为当前吸引域已饱和, 跳跃臂变为可用:

$$J_t = \mathbb{I}[\hat{v}_t \leq \tau], \quad \mathcal{A}_t = \begin{cases} \mathcal{A}_{\text{local}} \cup \mathcal{A}_{\text{jump}}, & J_t = 1, \\ \mathcal{A}_{\text{local}}, & J_t = 0. \end{cases} \quad (16)$$

这里, $J_t = 1$ 允许跳跃臂参与臂选择, 但不一定要求执行跳跃。对于跳跃臂 $a \in \mathcal{A}_{\text{jump}}$, 令 $f_{t,r}^{(a)}$ 表示从其跳跃候选方案出发, 经过 r 轮局部重新调优后得到的最佳实现。如果重新调优后的分支相对于跳跃前的当前最优方案提升幅度达到 $\delta_{\text{jump}} > 0$, 则接受该跳跃:

$$\text{AcceptJump}(a, t) = \mathbb{I}\left[\max_{0 \leq r \leq R} M(f_{t,r}^{(a)}) - s_t^* > \delta_{\text{jump}}\right]. \quad (17)$$

这一延迟判据使结构变化能够在经过局部适配后得到评估, 而不是仅依据其即时验证得分。

实验

实验设置

任务与数据集。我们在两类推荐任务上评估 RecHarness。第一种设置是在四个 Amazon Reviews 数据集 (Hou et al. 2026) 上进行序列推荐: Movies、Scientific、Electronics 和 CDs。每个用户和物品至少有五次交互, 模型根据用户历史预测下一个物品。第二种设置是在 KuaiRec (Gao et al. 2022) 上进行观看时长和排序预测; KuaiRec 是一个用于观看时长、观看比例和排序目标的稠密用户—视频交互数据集。表 1 和表 2 汇总了预处理后的统计信息。

指标。对于序列推荐, 我们采用留一法评估: 最后一个物品用于测试, 倒数第二个用于验证, 更早的交互用于训练。每个评估集包含一个正物品和 99 个采样负物品。我们报告命中率 (HR@N) 和归一化折损累计增益 (NDCG@N), 其中 N 取 10 和 20。为简洁汇总 Amazon 结果, 我们使用各数据集平均 $HR@10$:

$$\text{AvgHR@10}(m) = \frac{1}{|\mathcal{D}_A|} \sum_{d \in \mathcal{D}_A} \text{HR@10}(m, d), \quad (18)$$

其中, m 是一种方法或模型变体, $\mathcal{D}_A$ 是 Amazon 数据集集合。各数据集指标仍是主要证据。

数据集	指标	GRU4Rec			BERT4Rec			NextItNet			SASRec			HSTU	
		基线	本文	论文	基线	本文	论文	基线	本文	论文	基线	本文	论文	基线	本文
Movies	N@10	0.1267	0.3349	0.3152	0.2585	0.3393	0.2959	0.1347	0.3326	0.2538	0.3688	0.4023	0.3459	0.3253	0.3794
	N@20	0.1570	0.3709	0.3494	0.2943	0.3734	0.3303	0.1661	0.3666	0.2879	0.4039	0.4348	0.3745	0.3611	0.4121
	H@10	0.2317	0.5179	0.4883	0.4302	0.5269	0.4785	0.2617	0.5168	0.4221	0.5335	0.5923	0.5180	0.5038	0.5634
	H@20	0.3525	0.6606	0.6245	0.5723	0.6620	0.6213	0.3868	0.6516	0.5522	0.7034	0.7210	0.6310	0.6460	0.6932
Scientific	N@10	0.1663	0.3017	0.2642	0.2379	0.2880	0.2576	0.2179	0.2870	0.2263	0.2805	0.3311	0.2918	0.2804	0.3265
	N@20	0.1950	0.3377	0.2974	0.2728	0.3246	0.2913	0.2482	0.3243	0.2657	0.3195	0.3645	0.3245	0.3184	0.3615
	H@10	0.2831	0.4970	0.4313	0.4081	0.4763	0.4437	0.3632	0.4749	0.3908	0.4701	0.5381	0.4691	0.4690	0.5220
	H@20	0.3979	0.6396	0.5524	0.5471	0.6216	0.5822	0.4833	0.6227	0.5356	0.6242	0.6700	0.5987	0.6193	0.6604
Electronics	N@10	0.1789	0.2442	0.2364	0.1870	0.2277	0.1867	0.2293	0.2441	0.1712	0.2614	0.2635	0.2267	0.2424	0.2682
	N@20	0.2077	0.2774	0.2743	0.2170	0.2613	0.2172	0.2579	0.2750	0.2069	0.2981	0.2991	0.2606	0.2804	0.3038
	H@10	0.3005	0.3940	0.3843	0.3186	0.3745	0.3325	0.3833	0.3965	0.3017	0.4271	0.4336	0.3749	0.4038	0.4335
	H@20	0.4148	0.5257	0.5196	0.4377	0.5081	0.4740	0.4967	0.5194	0.4324	0.5729	0.5750	0.5096	0.5547	0.5744
CDs	N@10	0.1394	0.3764	0.2155	0.2872	0.3789	0.3019	0.1367	0.3768	0.2207	0.2614	0.4465	0.3451	0.3192	0.4046
	N@20	0.1733	0.4127	0.2530	0.3255	0.4152	0.3386	0.1678	0.4118	0.2562	0.2981	0.4770	0.3795	0.3553	0.4382
	H@10	0.2586	0.5872	0.3712	0.4693	0.5908	0.5018	0.2544	0.5853	0.3842	0.5833	0.6593	0.5278	0.5124	0.6080
	H@20	0.3936	0.7310	0.5092	0.6213	0.7345	0.6605	0.3781	0.7233	0.5422	0.7309	0.7793	0.6635	0.6551	0.7409
各数据集平均 H@10		0.2685	0.4990	0.4188	0.4066	0.4921	0.4391	0.3156	0.4934	0.3747	0.5035	0.5558	0.4725	0.4723	0.5317

Table 3: Amazon Reviews 上的性能，为三次运行的平均结果。Base 表示冷启动基线，Ours 表示 RecHarness，Paper 表示文献 (Kim et al. 2025) 报告的结果。N 和 H 分别表示 NDCG 和 HR。粗体表示每个模型和数据集上的最佳结果，最后一行报告平均 HR@10。

对于 KuaiRec，我们报告 WT-XAUC、WT-MAE、WR-XAUC 和 WR-MAE。WT 和 WR 分别表示观看时长和观看比例。MAE 越低、XAUC 越高越好 (Ma et al. 2026)。

搜索协议。 RecHarness 仅使用验证反馈进行候选选择、路由更新和版本晋级。测试集仅在搜索结束后用于一次最终评估。每次运行从冷启动模板开始，先进行一次基线试验，然后在多臂老虎机臂下搜索候选修改（更多细节见补充材料）。

试验执行与预算。 每个候选方案都在隔离工作空间中运行，每轮通常并行评估多次试验。试验返回验证得分、日志、错误和状态。RecHarness 只晋级可执行且优于当前最优方案的候选方案，并在剩余预算不足以支持另一个试验组时停止。对每个模型，我们设置 43,200 s 的 GPU 总时间预算。

优化的推荐模型。 接下来，我们说明 RecHarness 使用的优化目标。(1) **Amazon Reviews** 模型。对于序列推荐，我们评估覆盖不同序列建模范式的五类模型：GRU4Rec (Hidasi et al. 2015)、BERT4Rec (Sun et al. 2019)、NextItNet (Yuan et al. 2019)、SASRec (Kang and McAuley 2018) 和 HSTU (Zhai et al. 2024)。(2) **KuaiRec** 模型。对于 KuaiRec，我们评估覆盖不同反馈建模设计的三个模型：D2Q (Zhan et al. 2022)、TPM (Lin et al. 2023) 和 GR (Ma et al. 2026)。

总体性能

表 3 显示，五个模型均获得一致提升。RecHarness 使较弱的 GRU4Rec 基线的平均 HR@10 提升 85.85%，并使较强的 HSTU 基线提升 12.58%。它还优于 Kim et al. (2025) 中相匹配的结果。

表 4 证实，这些增益可以跨场景和目标迁移。在较弱的 TPM 基线上，RecHarness 将两个 MAE 指标均

模型	指标	基线	本文	论文
D2Q	WT-XAUC $\uparrow$	0.5310	0.5947 (+12.00%)	0.5650
	WT-MAE $\downarrow$	3.4129	3.3107 (-2.99%)	5.4260
	WR-XAUC $\uparrow$	0.7307	0.7444 (+1.87%)	0.7120
	WR-MAE $\downarrow$	0.3558	0.3451 (-3.01%)	0.3710
TPM	WT-XAUC $\uparrow$	0.5342	0.5808 (+8.72%)	0.5710
	WT-MAE $\downarrow$	4.5372	3.3406 (-26.37%)	3.4560
	WR-XAUC $\uparrow$	0.7012	0.7418 (+5.79%)	0.7340
	WR-MAE $\downarrow$	0.4730	0.3481 (-26.41%)	0.3610
GR	WT-XAUC $\uparrow$	0.6161	0.6176 (+0.24%)	0.6140
	WT-MAE $\downarrow$	3.1901	3.1851 (-0.16%)	3.1960
	WR-XAUC $\uparrow$	0.7528	0.7535 (+0.09%)	0.7530
	WR-MAE $\downarrow$	0.3323	0.3319 (-0.12%)	0.3330

Table 4: KuaiRec 上的性能。Base、Ours 和 Paper 分别表示基线、RecHarness 以及 Ma et al. (2026) 报告的结果。括号中给出 Ours 相对于 Base 的相对变化。

降低超过 26%；在较强的 GR 基线上，它仍能持续改善全部四个指标。它还超越了 Ma et al. (2026)，说明 RecHarness 不只是针对单一模板的调优器，还能够跨推荐场景、模型类型和评估目标迁移。

消融实验

为分离 RecHarness 中各模块的贡献，我们在四个 Amazon 数据集上开展消融实验，并固定以 SASRec 作为底层推荐模板。所有比较变体均采用相同的验证集驱动更新规则、GPU 时间预算，以及每轮四次并行试验。

消融设置定义如下：

- **RecHarness** 是完整方法，包含 Thompson 风格路由、Experiment Skill 和验证集驱动更新。




Figure 2: 基于 SASRec 的消融实验中，三次运行平均得到的验证集历史最佳 HR@10。

- **TR w/ Random** 使用均匀随机的臂选择替代 Thompson Routing (TR)。
- **TR w/ LLM** 让 LLM 根据历史文本反馈选择臂，不使用 Thompson Posterior Routing。
- **w/o Bandit** 移除预定义的编辑维度，让 LLM 自由提出修改。

图 2 展示了验证集上的历史最佳轨迹。RecHarness 从 0.5050 出发，在第 2 轮达到 0.6125，在第 4 轮达到 0.6342，比所有消融变体提升得更快。这表明路由能够在早期将有限试验集中到高回报方向。

RecHarness 在每个验证检查点和最终测试指标上均表现最佳。TR w/ LLM 优于随机路由，说明文本反馈有所帮助，但其表现仍低于 RecHarness。w/o Bandit 能找到有用的局部修改，但泛化较差，表明结构化编辑维度能够稳定搜索过程。

分析实验

如表 5 所示，我们衡量非基线试验改善每轮起始时最佳验证分数的频率，以及改善幅度。结果体现了 RecHarness 路由设计的两点作用。第一，RecHarness 寻找改进的准确性高于两个路由消融变体：其非基线试验中有 47.92% 刷新了每轮起始时的最佳分数，而采用 TR w/ Random 替代方案和 TR w/ LLM 时，这一比例分别仅为 22.45% 和 21.74%。这表明 RecHarness 不只是记录过去的结果，还会利用累积的验证反馈，将未来试验分配到经验上更可能改善当前最佳模型的编辑方向。第二，RecHarness 找到的改进质量高于 w/o Bandit。尽管 w/o Bandit 仍能改善 41.67% 的试验，但其平均增益和最大增益均低于 RecHarness，最大增益的差距尤其明显 (10.16% 对 24.00%)。这说明不受约束的 LLM 搜索仍可发现有用方向，但相比 bandit 路由，它将试验分配到高潜在收益方向的可能性更低。

因此，RecHarness 的改进主要源于更有效地分配有限试验。LLM 在选定方向内提出假设，而 bandit 路由则使有限试验更有可能产生较大增益。

在线 A/B 测试

我们将 RecHarness 部署在一个大规模短视频广告排序系统中。在线基线是一个成熟的生产排序模型，采用共

方法	改进试验 / 全部试验	比例	平均增益	最大增益
RecHarness	23 / 48	47.92%	5.06%	24.00%
TR w/ Random	11 / 49	22.45%	4.94%	16.63%
TR w/ LLM	10 / 46	21.74%	5.04%	15.11%
w/o Bandit	20 / 48	41.67%	4.05%	10.16%

Table 5: 相对于每轮起始时最佳验证分数的试验级增益。

场景	ADV V	Revenue	Exposure
短视频广告	+2.084%	+0.534%	+0.559%

Table 6: 短视频广告场景中的在线 A/B 测试。

享底层 DNN 和多特征融合，以用户侧、物品侧和组合侧特征，以及六组实时用户商业行为序列作为输入。

在离线生产环境中，人类专家定义优化目标、验证指标和候选臂。局部臂涵盖特征注入、融合位置调整和训练配置调优；跳跃臂涵盖序列编码器升级等更高层次的结构变化。随后，RecHarness 在这些臂上进行自我迭代。在多次尝试局部臂均未取得稳定增益后，路由器估计搜索已接近局部盆地上限，于是允许使用跳跃臂，并选择 `sequence_encoder_upgrade` 臂。在该臂内，LLM 基于 Experiment Skill 和历史试验进行推理。记忆表明，现有 HSTU 相关模块主要处理压缩后的虚拟 Token，而非对原始行为序列内的物品间交互进行建模；先前对特征交叉和融合结构的尝试也未取得稳定增益。因此，RecHarness 将主要结构缺口归因于缺少序列内部关系建模，并生成一个序列内自注意力候选方案。该候选方案对六个实时行为序列分别应用自注意力，通过 MLP 将每个序列压缩为 32 维向量，再将它们拼接成一个 192 维表示并注入共享底层排序器。离线实验中，该方案使生产 AUC 提升 0.09%。

在覆盖 10% 流量、持续 7 天的在线 A/B 测试中 (表 6)，该候选方案使 ADVV (广告主价值) (Chai et al. 2025) 提升 2.084%，Revenue 提升 0.534%，Exposure 提升 0.559%。这表明 RecHarness 能够在人类定义的臂空间内发现可部署的结构改进，并将离线增益转化为在线业务指标提升。

结论

我们提出了 RecHarness，一种在有限预算下用于自动化推荐模型迭代、由 bandit 路由的智能体框架。其关键设计将编辑方向选择与具体代码修改解耦：验证集驱动的 Thompson 路由在结构化优化维度上积累跨试验证据，而 LLM 推理则解释反馈，并在选定方向内提出可执行的修改。在两个推荐场景和八个模型上，RecHarness 均能稳定提升性能。此外，在某大型短视频广告平台上，RecHarness 发现的候选方案带来了显著增益，证实了其在工业推荐中的实用价值。

References

Akiba, T.; Sano, S.; Yanase, T.; Ohta, T.; and Koyama, M. 2019. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th*

ACM SIGKDD international conference on knowledge discovery & data mining, 2623–2631.

Bouneffouf, D.; and Feraud, R. 2026. Multi-armed bandits meet large language models. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 40, 39682–39690.

Chai, Z.; Ren, Q.; Xiao, X.; Yang, H.; Han, B.; Zhang, S.; Chen, D.; Lu, H.; Zhao, W.; Yu, L.; et al. 2025. Longer: Scaling up long sequence modeling in industrial recommenders. In *Proceedings of the Nineteenth ACM Conference on Recommender Systems*, 247–256.

Chan, J. S.; Chowdhury, N.; Jaffe, O.; Aung, J.; Sherburn, D.; Mays, E.; Starace, G.; Liu, K.; Maksin, L.; Patwardhan, T.; et al. 2025. Mle-bench: Evaluating machine learning agents on machine learning engineering. In *International Conference on Learning Representations*, volume 2025, 50466–50494.

Cheng, Y.; Zhou, L.; Liang, X.; Luo, D.; Lee, T.; Zheng, K.; Zhang, W.; Cai, M.; Dong, J.; and Zhang, A. 2026. Let the Agent Steer: Closed-Loop Ranking Optimization via Influence Exchange. *arXiv preprint arXiv:2603.27765*.

Feurer, M.; and Hutter, F. 2019. Hyperparameter optimization. In *Automated machine learning: Methods, systems, challenges*, 3–33. Springer.

Feurer, M.; Klein, A.; Eggenberger, K.; Springenberg, J.; Blum, M.; and Hutter, F. 2015. Efficient and robust automated machine learning. *Advances in neural information processing systems*, 28.

Gao, C.; Li, S.; Lei, W.; Chen, J.; Li, B.; Jiang, P.; He, X.; Mao, J.; and Chua, T.-S. 2022. KuaiRec: A fully-observed dataset and insights for evaluating recommender systems. In *Proceedings of the 31st ACM International Conference on Information & Knowledge Management*, 540–550.

He, X.; Deng, K.; Wang, X.; Li, Y.; Zhang, Y.; and Wang, M. 2020. Lightgcn: Simplifying and powering graph convolution network for recommendation. In *Proceedings of the 43rd International ACM SIGIR conference on research and development in Information Retrieval*, 639–648.

Hidasi, B.; Karatzoglou, A.; Baltrunas, L.; and Tikk, D. 2015. Session-based recommendations with recurrent neural networks. *arXiv preprint arXiv:1511.06939*.

Hou, Y.; Li, J.; Fu, X.; He, Z.; Yan, A.; Chen, X.; and McAuley, J. 2026. Bridging Language and Items for Retrieval and Recommendation: Benchmarking LLMs as Semantic Encoders. In *Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 3251–3265.

Huang, Q.; Vora, J.; Liang, P.; and Leskovec, J. 2023. MAgentbench: Evaluating language agents on machine learning experimentation. *arXiv preprint arXiv:2310.03302*.

Jiang, Z.; Schmidt, D.; Srikanth, D.; Xu, D.; Kaplan, I.; Jacenko, D.; and Wu, Y. 2025. Aide: Ai-

driven exploration in the space of code. *arXiv preprint arXiv:2502.13138*.

Kang, W.-C.; and McAuley, J. 2018. Self-attentive sequential recommendation. In *2018 IEEE international conference on data mining (ICDM)*, 197–206. IEEE.

Kim, S.; Kang, H.; Kim, K.; Kim, J.; Kim, D.; Yang, M.; Oh, K.; McAuley, J.; and Park, C. 2025. Lost in Sequence: Do Large Language Models Understand Sequential Recommendation? In *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V. 2*, 1160–1171.

Krishnamurthy, A.; Harris, K.; Foster, D. J.; Zhang, C.; and Slivkins, A. 2024. Can large language models explore in-context? *Advances in Neural Information Processing Systems*, 37: 120124–120158.

Lao, C.; Pan, F.; Ma, G.; Li, H.; Lin, H.; Shi, J.; Zhao, K.; Gai, K.; Zhou, M.; Zhou, Q.; et al. 2026. AgentX: Towards Agent-Driven Self-Iteration of Industrial Recommender Systems. *arXiv preprint arXiv:2606.26859*.

Li, Y.; Ju, H.; Song, Z.; Yang, W.; Lu, C.; Jiang, P.; and Gai, K. 2026a. RecGOAT: Graph Optimal Adaptive Transport for LLM-Enhanced Multimodal Recommendation with Dual Semantic Alignment. *arXiv preprint arXiv:2602.00682*.

Li, Y.; Song, Z.; Yao, J.; Lu, C.; Jiang, P.; and Gai, K. 2026b. Taiji: Pareto Optimal Policy Optimization with Semantics-IDs Trade-off for Industrial LLM-Enhanced Recommendation. *arXiv preprint arXiv:2606.03866*.

Lin, X.; Chen, X.; Song, L.; Liu, J.; Li, B.; and Jiang, P. 2023. Tree based progressive regression model for watch-time prediction in short-video recommendation. In *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 4497–4506.

Liu, H.; Simonyan, K.; and Yang, Y. 2019. DARTS: Differentiable Architecture Search. In *International Conference on Learning Representations*.

Liu, S.; Fang, L.; Sun, Y.; Huang, S.; Luo, Q.; Chen, X.; Liu, D.; Ma, C.; Chai, Z.; Wang, H.; et al. 2026. NOVA: A Verification-Aware Agent Harness for Architecture Evolution in Industrial Recommender Systems. *arXiv preprint arXiv:2606.27243*.

Luo, R.; Tian, F.; Qin, T.; Chen, E.; and Liu, T.-Y. 2018. Neural architecture optimization. *Advances in neural information processing systems*, 31.

Lyu, F.; Tang, X.; Guo, H.; Tang, R.; He, X.; Zhang, R.; and Liu, X. 2022. Memorize, factorize, or be naive: Learning optimal feature interaction methods for CTR prediction. In *2022 IEEE 38th International Conference on Data Engineering (ICDE)*, 1450–1462. IEEE.

Ma, H.; Tian, K.; Zhang, T.; Zhang, X.; Zhou, H.; Jin, C.; Chen, C.; Li, H.; Guan, J.; and Zhou, S. 2026. Generative regression based watch time prediction for short-video recommendation. In *Proceedings of the ACM Web Conference 2026*, 6183–6193.

Madaan, A.; Tandon, N.; Gupta, P.; Hallinan, S.; Gao, L.; Wiegrefe, S.; Alon, U.; Dziri, N.; Prabhunoye, S.;

- Yang, Y.; et al. 2023. Self-refine: Iterative refinement with self-feedback. *Advances in neural information processing systems*, 36: 46534–46594.
- Mu, L.; Deng, H.; Xing, H.; Hu, J.; Zhang, Y.; and Zeng, X. 2026. EvoRec: Self Evolving Agentic Recommender Systems. *arXiv preprint arXiv:2606.28368*.
- Nam, J.; Yoon, J.; Chen, J.; Shin, J.; Arik, S.; and Pfister, T. 2026. Mle-star: Machine learning engineering agent via search and targeted refinement. *Advances in Neural Information Processing Systems*, 38: 116692–116712.
- Ou, K.; Wu, C.; Wang, X.; Zheng, B.; Zhao, W. X.; Li, W.; Zhang, L.; Chen, S.; and Wen, J.-R. 2026. Deep Research for Recommender Systems. *arXiv preprint arXiv:2603.07605*.
- Pryzant, R.; Iter, D.; Li, J.; Lee, Y.; Zhu, C.; and Zeng, M. 2023. Automatic prompt optimization with “gradient descent” and beam search. In *Proceedings of the 2023 conference on empirical methods in natural language processing*, 7957–7968.
- Ren, P.; Xiao, Y.; Chang, X.; Huang, P.-Y.; Li, Z.; Chen, X.; and Wang, X. 2021. A comprehensive survey of neural architecture search: Challenges and solutions. *ACM Computing Surveys (CSUR)*, 54(4): 1–34.
- Shinn, N.; Cassano, F.; Gopinath, A.; Narasimhan, K.; and Yao, S. 2023. Reflexion: Language agents with verbal reinforcement learning. *Advances in neural information processing systems*, 36: 8634–8652.
- Sun, F.; Liu, J.; Wu, J.; Pei, C.; Lin, X.; Ou, W.; and Jiang, P. 2019. BERT4Rec: Sequential recommendation with bidirectional encoder representations from transformer. In *Proceedings of the 28th ACM international conference on information and knowledge management*, 1441–1450.
- Sun, J.; Wang, Z.; Yang, R.; Xiao, C.; Lui, J. C.; and Dai, Z. 2026. Large language model-enhanced multi-armed bandits. In *Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 8130–8145.
- Thornton, C.; Hutter, F.; Hoos, H. H.; and Leyton-Brown, K. 2013. Auto-WEKA: Combined selection and hyperparameter optimization of classification algorithms. In *Proceedings of the 19th ACM SIGKDD international conference on Knowledge discovery and data mining*, 847–855.
- Toledo, E.; Hambardzumyan, K.; Josifoski, M.; Hazra, R.; Baldwin, N.; Audran-Reiss, A.; Kuchnik, M.; Magka, D.; Jiang, M.; Lupidi, A.; et al. 2026. Ai research agents for machine learning: Search, exploration, and generalization in mle-bench. *Advances in Neural Information Processing Systems*, 38: 35309–35348.
- Wang, H.; Wu, Y.; Chang, D.; Wei, L.; and Heldt, L. 2026. Self-evolving recommendation system: End-to-end autonomous model optimization with LLM agents. *arXiv preprint arXiv:2602.10226*.
- Wang, Y.; Zhao, X.; Xu, T.; and Wu, X. 2022. Autofield: Automating feature selection in deep recommender systems. In *Proceedings of the ACM Web Conference 2022*, 1977–1986.
- Yang, W.; Zhong, R.; Chen, Y.; Lu, C.; and Jiang, P. 2026. Structured Spectral Reasoning for Frequency-Adaptive Multimodal Recommendation. *Advances in Neural Information Processing Systems*, 38: 28122–28143.
- Yao, S.; Zhao, J.; Yu, D.; Du, N.; Shafran, I.; Narasimhan, K. R.; and Cao, Y. 2023. ReAct: Synergizing Reasoning and Acting in Language Models. In *The Eleventh International Conference on Learning Representations*.
- Yuan, F.; Karatzoglou, A.; Arapakis, I.; Jose, J. M.; and He, X. 2019. A simple convolutional generative network for next item recommendation. In *Proceedings of the twelfth ACM international conference on web search and data mining*, 582–590.
- Yuksekgonul, M.; Bianchi, F.; Boen, J.; Liu, S.; Lu, P.; Huang, Z.; Guestrin, C.; and Zou, J. 2025. Optimizing generative ai by backpropagating language model feedback. *Nature*, 639(8055): 609–616.
- Yun, L.; Wu, Y.; Liu, H.; Liu, X.; Xu, Z.; Wang, Y.; Xia, Y.; Wang, P.; Gao, M.; Wang, Y.; et al. 2026. Decoding ML Decision: An Agentic Reasoning Framework for Large-Scale Ranking System. *arXiv preprint arXiv:2602.18640*.
- Zhai, J.; Liao, L.; Liu, X.; Wang, Y.; Li, R.; Cao, X.; Gao, L.; Gong, Z.; Gu, F.; He, M.; et al. 2024. Actions speak louder than words: Trillion-parameter sequential transducers for generative recommendations. *arXiv preprint arXiv:2402.17152*.
- Zhan, R.; Pei, C.; Su, Q.; Wen, J.; Wang, X.; Mu, G.; Zheng, D.; Jiang, P.; and Gai, K. 2022. Deconfounding duration bias in watch-time prediction for video recommendation. In *Proceedings of the 28th ACM SIGKDD conference on knowledge discovery and data mining*, 4472–4481.
- Zhang, Y.; Yang, X.; Yang, X.; Xian, B.; Li, Q.; Fang, S.; Li, J.; Wang, J.; Xu, M.; Zhang, Y.; et al. 2026. Reasoning as Gradient: Scaling MLE Agents Beyond Tree Search. In *Findings of the Association for Computational Linguistics: ACL 2026*, 9013–9038.
- Zhao, X.; Liu, H.; Fan, W.; Liu, H.; Tang, J.; and Wang, C. 2021. Autoloss: Automated loss function search in recommendations. In *Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining*, 3959–3967.
- Zheng, R.; Qu, L.; Cui, B.; Shi, Y.; and Yin, H. 2023. Automl for deep recommender systems: A survey. *ACM Transactions on Information Systems*, 41(4): 1–38.