

TOKENMINDS：面向大规模推荐系统用户理解的预训练用户 Token 与嵌入

Qingyun Liu*
Google DeepMind

Bo Yan
YouTube

Yang Liu
YouTube

Yuji Roh
Google DeepMind

Ekansh Sharma
YouTube

Likang Yin
YouTube

Emma Olowo
YouTube

Min-hsuan Tsai
Google DeepMind

Yuxuan Li
YouTube

Diego Uribe
YouTube

Saksham Aggarwal
YouTube

Siqi Wu
YouTube

Yuan Hao
Google DeepMind

Vikas Kedigehalli
YouTube

Lukasz Heldt
YouTube

Lichan Hong*
Google DeepMind

Li Wei*
YouTube

Xinyang Yi*
Google DeepMind

摘要

工业推荐系统中的用户建模通常生成稠密嵌入，但这种表示受到固定维度向量固有表达能力的限制。一种新兴的离散用户表示方案是使用 LLM 生成基于文本的用户 Token；然而，它捕捉的更多是主题共现，而非深层的序列行为动态，并且其输出难以锚定到物品属性。与此同时，基于语义 ID (SID) 的物品 Token 化已被证明能够有效提升生成式推荐的泛化能力，但面向用户的离散 SID 表示仍鲜有探索。我们提出 TOKENMINDS，这是一个工业规模的系统，它将 PLUM 框架 [9] 从物品检索扩展到用户建模，通过基于预训练 LLM 改造的编码器—解码器架构，同时生成基于 SID 的离散用户 Token 和稠密用户嵌入。这种双输出设计既提供了离散、具有语义锚定的用户表示所带来的互补优势，又保持了与依赖稠密嵌入的现有下游模型的兼容性。此外，共享的 SID 词表可自然扩展至跨场景建模：通过在单个模型中统一长视频和短视频行为，我们显著降低了训练与服务成本。我们通过广泛的离线实验以及在多个 YouTube 场景中的线上发布验证了 TOKENMINDS；借助将表示生成与下游打分解耦的异步基础设施，该系统面向全量用户流量（数十亿用户）提供服务。本文将排序作为主要下游用例，实验结果证实了基于 SID 的用户 Token 在工业规模下的实际可行性，并表明 Token 与稠密嵌入在不同生产排序系统中能够提供互补价值。

1 引言

推荐系统已经从早期的因子分解机演进到现代深度学习架构，并且正日益从多阶段级联架构转向端到端方法。序列用户建模着眼于利用用户曾经交互过的历史，长期以来一直是实现推荐

系统个性化的关键环节 [4, 5, 21]。大嵌入模型 (LEM) [6, 7] 是当前占主导地位的工业范式，它依赖海量嵌入表来表示高基数的物品 ID。尽管这种方式能够有效记忆用户—物品交互，但 LEM 往往限制模型在复杂网络上的泛化能力 [25]。

相较之下，大语言模型 (LLM) 主要将参数预算分配给神经网络，而不是海量嵌入表，因此在推荐领域展现出巨大潜力。近期工作利用其推理和上下文理解能力来进行特征提取、LEM 集成 [42] 和端到端序列建模 [19, 40, 41]。然而，将 LLM 应用于特定领域的推荐会暴露出两个关键瓶颈。第一，在自然语言上预训练的模型处理海量非文本 ID 空间（例如，数十亿个视频）时存在根本性的模态鸿沟。第二，通过将 LLM 与传统大型嵌入表耦合来弥合这一鸿沟，会继承 LLM 原本旨在超越的那些限制：扩展约束、词表频繁变动以及表达能力受限 [25, 29]。为克服这些瓶颈，语义 ID [24] 将物品 Token 化为根据内容语义得到的分层离散码字，从而消除对嵌入表的依赖，并通过有意义的碰撞提升泛化能力 [25]。SID 解决了传统表示在扩展性和表达能力方面的限制，而 PLUM 框架 [9] 则通过持续预训练 (CPT) 和任务特定的后训练，将新的 SID 词表与 LLM 既有知识对齐，从而弥合剩余的模态鸿沟。

尽管 PLUM 框架已被证明对物品检索有效，但其在序列用户建模 (SUM) 中的潜力仍未得到探索。本文提出 TOKENMINDS，将 PLUM 扩展为以基于 SID 的用户 Token 形式生成用户表示。基于 SID 的表示有别于常见的稠密用户嵌入方法 [21, 23]；后者将用户完整的兴趣谱压缩到一个或少数几个固定维度向量中，可能会丢失细粒度信号。使用 LLM 生成基于文本的用户画像也正受到越来越多关注 [8, 26, 32]。虽然文本画像可被视为另一种离散用户表示，但它们存在若干关键局限：未在用户行为信号上进行预训练的 LLM 往往捕捉主题共现，而非深层的序列行为动态 [15]；其文本输出难以与任何目标领域中的物品属性建立锚定；集成到非文本下游系统时还会引入模态鸿沟 [28]。在 TOKENMINDS 中，我们通过利用 PLUM 的 CPT 方法 [9]，并将模型输出锚定到具有语义且扎根于推荐语料库的 SID Token，克服了这些挑战。

具体而言，TOKENMINDS 采用编码器—解码器架构——这是生成式检索中广泛使用的范式 [24, 40]——但将其重新用于一种新颖的双输出设计：解码器生成基于 SID 的用户 Token，而编码器处理序列用户特征并同时产生稠密用户嵌入，从而确保

*通讯作者：{qyl, lichan, liwei, xinyang}@google.com。

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org. Conference'17, Washington, DC, USA

© 2026 Copyright held by the owner/author(s). Publication rights licensed to ACM. ACM ISBN 978-x-xxxx-xxxx-x/YYYY/MM <https://doi.org/10.1145/nnnnnnnn.nnnnnnn>

与使用稠密嵌入的现有下游模型兼容（第 3.2 节）。本文将排序作为主要下游用例，研究如何将基于 SID 的用户 Token 恰当地集成到生产排序模型中（第 3.4 节）。为在严格延迟约束下向数十亿用户提供该模型，我们将 TOKENMINDS 部署在异步服务基础设施 [17] 之上，将计算密集表示生成与实时打分解耦（第 3.5 节）。

除单场景用户建模外，由于 TOKENMINDS 在继承自预训练 LLM 的共享 Token 空间中运行，它还能自然支持两项进一步扩展。第一，可将文本搜索查询等异构信号直接与观看历史交错编排在输入序列中（第 4.2 节）。第二，共享 SID 词表为长视频（LFV）和短视频（SFV）之间的跨场景建模提供了自然桥梁；这两个场景拥有互不相交的视频 ID 空间和不同的消费模式 [18]。我们在每次观看行为前添加场景特定的条件 Token（LFV/SFV），使单个模型能够在按时间顺序交错的跨场景序列上训练。推理时，我们引入多上下文解码：编码器通过一次前向传播产生共享用户表示，解码器则以不同场景前缀为条件生成场景特定的用户 Token，从而在无需多模型开销的情况下有效实现感知场景的输出（第 3.3 节）。

我们的贡献总结如下：

- **双输出架构：**我们提出 TOKENMINDS，这是一种面向大规模工业推荐系统的统一用户建模架构。其新颖的双输出机制能够联合生成标准的稠密连续嵌入和基于 SID 的离散用户 Token。
- **Token 化用户表示 & 适配：**我们提出将基于 SID 的离散 Token 用于用户表示这一新应用，并确定了在下游模型中适配这些 Token 的最佳策略。尽管 TOKENMINDS 支持多种下游任务，本文聚焦于排序集成；我们展示了 Token 化表示在工业规模下的实际可行性，并证明稠密嵌入与离散 Token 能够捕捉互补信号，从而带来更大的性能增益。
- **跨场景建模：**我们提出一种高效的建模范式，原生整合跨场景内容的训练与服务。通过在单一框架内联合建模本质上不同的场景（LFV 和 SFV），与维护独立模型相比，我们将上游训练计算量降低 50%，服务计算量降低 31%，同时保持核心互动质量，并显著改善两个场景中的新鲜内容指标。
- **工业规模部署：**我们通过广泛的离线评估以及生产排序系统上的线上 A/B 测试验证了 TOKENMINDS，在核心用户指标上取得最高 +0.11%、在核心互动指标上取得最高 +0.62% 的统计显著增益。TOKENMINDS 已部署到多个主要 YouTube 场景的生产环境中，在全量用户流量上同时服务 LFV 和 SFV 推荐。

2 相关工作

序列用户建模。序列推荐已经从 RNN [10] 和 CNN [27]，发展到 SASRec [14] 等强大的 Transformer 模型以及 HSTU [37] 等万亿参数转换器。尽管这些模型在架构上十分精巧，但它们从根本上依赖于原子物品 ID 的海量连续嵌入表。近年来，语义 ID（SID）已成为一种颇具吸引力的物品表示替代方案，能够增强泛化能力 [24, 25] 并提高样本效率 [9]。在用户侧，稠密连续嵌入是工业界普遍采用的用户表示标准 [4, 23, 31]。近期基于 LLM 的方法尝试将偏好总结为自然语言画像 [8, 26, 32]，但这些方法往往捕捉主题共现，而非用户的序列动态 [15]，并且在非文本下游系统中面临模态鸿沟的挑战 [28]。面向用户、基于 SID 的离散 Token 表示仍鲜有探索。我们的工作通过将 SID




图 1: TOKENMINDS 框架概览。编码器—解码器架构处理异构用户信号，包括长视频和短视频的观看行为、搜索查询以及相关互动特征。它同时从编码器产生稠密用户嵌入，并从解码器产生基于 SID 的离散用户 Token，随后将二者提供给下游模型。

范式从物品扩展到用户来填补这一空白，在生成紧凑的离散用户 Token 的同时，继续输出稠密嵌入，以兼容现有下游系统。

生成式推荐。生成式推荐将传统的基于嵌入表的范式重新构造为序列到序列任务，例如 PLUM [9]、GenRank [12] 和 GPR [38]。我们的工作将 PLUM 框架从检索扩展到用户建模。检索模型受限于预测紧接着出现的下一个物品，而用户建模则在更长时间窗口内捕捉更广泛的意图谱。它利用粒度更粗的语义来识别不同兴趣领域，避免了必须严格映射回特定单个物品的要求。GPR 将用户表示与下游任务指标和策略优化对齐；与之不同，我们将用户表示学习与特定下游训练目标解耦，以提供对用户兴趣的通用理解。

与此同时，LIGER [33] 和 COBRA [34] 表明，稀疏语义 ID 与稠密嵌入能够为检索提供互补的物品表示。然而，二者都仅在物品层面运行。TOKENMINDS 将这种稀疏—稠密互补性从物品扩展到用户，通过统一的编码器—解码器架构，同时生成基于 SID 的离散用户 Token 和连续嵌入。

在线部署计算密集的生成模型会面临真实系统的扩展瓶颈。近期工作通过优化在线架构本身来解决这一问题，例如 HSTU [37] 的高效转换器、LONGER [4] 的优化表示以及并行生成方法 [11]。由于这些模型在实时打分期间执行密集计算，严格的计算预算往往会将其限制在广告等子领域 [30, 38]，而无法用于核心自然流量。为服务数十亿用户，TOKENMINDS 采用了不同的基础设施方案：利用异步用户行为服务（UBS）框架 [17]，将表示生成与打分解耦。

跨场景建模。对不同场景中的用户行为进行建模，仍是真实世界推荐系统中的一项关键挑战 [36]。早期方法利用多源用户历史来提升 CTR 预测等特定场景中的性能 [22, 35]。近年来，采用基础模型范式的工业框架在统一多场景行为方面展现出可喜的结果 [30, 38]。这些方法通常将不同场景中的用户行为投影到共享连续空间；而 TOKENMINDS 更进一步，同时生成统一的意图嵌入和场景特定的离散 Token 表示，使下游模型能够利用场景感知的用户信号。

3 TOKENMINDS 框架

我们首先概述 TOKENMINDS，包括其设计背后的直觉。随后详细介绍如何同时生成基于 SID 的离散用户 Token 和稠密用户嵌入。接下来，我们考虑数据格式不同的跨场景情形，然后讨论下游模型对基于 SID 的用户 Token 的适配，并在本节末介绍服务系统。




图 2: 单场景用户样例的训练示意图。编码器接收由 SID 词元和自定义特征交错组成的序列。解码器通过交叉注意力关注编码器的完整输出, 并以自回归方式为多个近期未来的目标观看行为生成 SID 词元。两者均从持续预训练 (CPT) [9] 开始初始化。

3.1 系统概述

如图 1 所示, 我们为 TOKENMINDS 采用序列到序列 (seq2seq) 框架。用户行为信号被词元化为序列输入, 并由预训练基础模型处理, 以同时生成稠密用户嵌入和基于 SID 的离散用户词元。由于基础模型此前未接触过我们的视频语料库, 我们沿用 PLUM [9], 通过持续预训练 (CPT) 使新的 SID 模式与模型的既有知识对齐 (消融实验见第 4.2 节), 随后进行用于用户建模的监督微调 (SFT)。下面介绍输入、表示和架构。

用户数据。 我们整合多种不同的用户行为信号, 包括文本搜索查询, 以及来自多个推荐应用的观看历史 (例如, 从主页直接推荐, 或由“接下来观看什么”等功能推荐 [39])。这些行为数据包含用户历史中的时间和参与度信号, 例如交互时间戳以及喜欢或不喜欢。

视频表示。 我们不使用随机分配的视频 ID (VID), 而是用语义 ID (SID) [24] 表示每个视频: SID 是通过残差量化变分自编码器 (RQ-VAE) [9] 从视频内容特征中提取的离散码字层次序列。SID 为用户建模带来两项关键优势: 对头部和尾部视频具有更好的泛化能力 [25]; 同时具有更强的时间稳定性, 因为随着语料库演化, VID 会面临词表频繁变动, 而在建模长程用户历史时, 这一问题会进一步放大。

基础模型架构。 尽管仅解码器模型在生成式推荐中很流行 [9, 38, 41], 我们仍出于两个原因采用编码器-解码器架构。首先, 众所周知, 编码器能够从完整用户历史中捕获更全面的序列模式 [13]; 稠密用户嵌入可以自然地这类上下文文化表示中提取, 而解码器则以自回归方式生成基于 SID 的离散用户词元。其次, 该架构具有部署灵活性: 编码器和解码器可以在服务时解耦 [21, 40], 以低频、重量级编码器压缩历史, 并以高频、轻量级解码器处理较新的行为。

训练期间, 解码器通过交叉注意力关注编码器的完整输出, 并学习为目标观看行为生成 SID 词元 (详见第 3.2 节)。服务时会提取双重输出: 稠密用户嵌入通过对编码器输出执行池化 (例如, 末词元池化或平均池化) 获得; 离散用户词元则通过在解码器上应用束搜索、生成多个 SID 序列来产生, 每个序列都被截断为一个粗粒度前缀, 作为单个用户词元 (详见第 3.2 节)。我们还可以通过仅允许解码器关注编码器的少量输出嵌入 (例如, 学习得到或经注意力池化的嵌入) 来约束解码器的交叉注意力。然而, 这会限制模型的表达能力, 并可能降低解码性能。为缓解这一问题, 可以引入带受限交叉注意力的辅助解码任务。

3.2 模型训练

在图 2 中, 我们可视化了一个用户样例的训练过程, 其中用户的观看行为按时间顺序排列并输入模型, 以预测多个近期未来的观看行为。为清晰起见, 图中展示的是基础的单场景情形; 跨场景条件词元和搜索查询整合的扩展见第 3.3 节。例如, 输入序列 “A12 B278 C23 D77” 表示某视频层次化 SID 截断后的 L 词元前缀 ($L=4$), 后续的 “100.0s” “20%” 和 “IOS” 等词元则编码数值和文本特征 (例如观看时长比例和设备平台)。

符号。 令 $W_1, \dots, W_n$ 表示用户按时间顺序排列的观看序列。截断时间戳 T 将其划分为历史 $[W_1, \dots, W_t]$ (T 之前的观看行为) 和未来窗口 $\{W_{t+1}, \dots, W_n\}$ ($[T, T+24h]$ 中的观看行为)。每次观看 W_k 均由 SID 表示: 给定其内容嵌入, 具有 $L_{full}=8$ 个码本层级的 RQ-VAE 会生成完整码字序列 $[SID_{k,1}, \dots, SID_{k,L_{full}}]$; 我们仅保留前缀 L 码 ($L < L_{full}$), 利用 SID 的层次结构以更粗粒度表示视频, 从而鼓励多样性并缓解记忆问题 [40] (消融实验见第 4.2 节)。

输入词元化。 每次观看 W_k 都将其前缀 L SID 作为硬词元, 并结合编码为硬词元或软词元的非 SID 特征。硬词元通过对稠密特征分桶, 或将类别/文本特征映射到词表来获得。软词元则通过分别嵌入各项特征、拼接所得表示, 再使用 MLP 将拼接结果投影为 M 个嵌入来生成。

训练目标。 与标准的下一观看行为预测相比, 我们采用两项关键改动, 二者均在第 4.2 节的消融实验中得到验证。首先, 我们采用前瞻采样 [30]: 不预测紧邻的下一观看 W_{t+1} , 而是从未来窗口 $\{W_{t+1}, \dots, W_n\}$ 中随机选择至多 N 个目标, 从而防止对紧邻观看行为过拟合, 并通过近似近期未来兴趣来提升泛化能力。其次, 同时预测多个目标比单目标训练具有更高的训练效率。形式化地, TOKENMINDS 最小化:

$$\mathcal{L} = - \sum_{i=1}^N r(W_i) \cdot \sum_{j=1}^L \log P(SID_{i,j} | W_1, \dots, W_t, W_{<i}, SID_{i,<j}). \quad (1)$$

这里, i 对 N 个采样目标进行索引, 而 $\mathcal{L}$ 仅在前缀 L SID 词元上计算。参与度奖励 $r(W_i)$ 鼓励多样化且高价值的消费行为, 它由多种用户信号组合而成。与应用不同权重相比, 按照奖励的比例 [9] 采样训练样例, 并在式 1 中赋予它们相同权重, 在计算上更高效。

请注意, 式 1 仅适用于解码器输出; 编码器仅通过解码器的交叉注意力层接收梯度, 这会隐式监督编码器生成有助于准确生成 SID 的表示。

3.3 跨场景建模

上述架构针对每个内容场景分别训练和提供服务。为了将这些模型整合为单一模型, 我们需要考虑长视频 (LFV) 与短视频 (SFV) 消费之间的关键差异。SFV 以连续浏览的方式消费, 无需显式点击启动 [18], 因此相比 LFV 会形成更强的反馈循环。此外, 用户兴趣并不会按格式彼此隔离; 近一半用户同时接触 SFV 和 LFV, 而且二者的 SID 词表具有显著重叠 (例如, 前两个前缀约有 40% 重叠)。这表明用户对 LFV 和 SFV 的兴趣存在交集。开发统一模型可以提高计算效率、促进迁移学习, 并更全面地捕获用户偏好。

3.3.1 统一训练。 为构建统一输入序列, 我们在每次观看之前添加离散条件词元 (例如, $\langle LFV \rangle$, $\langle SFV \rangle$), 以区分内容场景。由于 TOKENMINDS 运行在继承自预训练 LLM 的共享词元




图 3: 分别按上下文推理 (左) 与多上下文解码 (右) 的比较。多上下文解码引入一个上下文阶段, 通过一次共享编码器前向传播创建并行子批次, 从而在完整复用编码器隐藏状态的同时, 并发执行场景特定的解码。

空间中, 文本信号可以自然地与基于 SID 的观看词元交错排列。我们利用这一特性, 在最近的 S 条搜索查询前分别添加一个 $\langle \text{Search} \rangle$ 词元, 并按时间顺序将其交错插入观看序列中 (消融实验见第 4.2 节)。

对于训练目标, 我们扩展了对未来目标观看行为的随机采样 (第 3.2 节), 使其均匀包含 SFV 和 LFV。条件词元不计入损失, 因为预测它们非常容易, 而将其纳入损失会降低 SID 预测质量。

3.3.2 多上下文解码。 统一模型应在服务时为每个上下文生成场景特定的用户词元。朴素方法需要针对每个上下文分别运行推理, 重复处理用户历史, 从而抵消统一模型的效率收益。我们提出多上下文解码来消除这种冗余。给定对用户历史的一次共享编码器前向传播, 我们引入一个上下文阶段, 将解码分支为并行子批次, 每个目标上下文对应一个子批次。每个子批次均以相应的条件词元初始化, 并通过束搜索独立解码, 同时所有子批次完整共享单次编码器前向传播所得的隐藏状态。如图 3 所示, 这使一次预填充即可执行并发的上下文特定解码——从同一缓存用户表示中同时生成 LFV 和 SFV 用户词元。

3.4 下游适配

将基于 SID 的用户词元集成到下游模型中——尤其是需要稠密向量的传统 LEM——需要把离散词元投影到连续嵌入空间。我们评估了三种词元到嵌入的方法 [25]: (1) 前缀嵌入映射: 将每个预测的 L -前缀 SID (第 3.2 节) 映射回生成它时使用的原始内容嵌入。由于多个视频可能归并到同一个粗粒度前缀, 我们对共享预测前缀的所有视频的原始嵌入进行平均池化, 以获得 SID 嵌入。(2) N -gram 嵌入: 将每个预测 SID 序列切分为固定长度的 N -gram 子词 (例如, 当 $N=2$ 时采用连续码字对), 并将每个子词映射到一个可学习嵌入; SID 表示为其子词嵌入之和。(3) SPM 嵌入 [16]: 与 N -gram 类似, 但使用 SentencePiece 从物品分布中学习变长子词。我们将 (2) 和 (3) 统称为可学习嵌入 (LE), 因为两者都使用随机初始化的嵌入表, 并与下游模型进行端到端训练; 这与 (1) 的静态映射形成对比 (比较见第 4.3 节)。

服务时, 束搜索为每个用户生成 B 个 SID 序列, 每个序列代表一个预测的未来兴趣。为了形成单一用户向量, 我们通过池化 (例如, 注意力加权、平均、最大值或前- k 拼接) 聚合对应的 B 个 SID 嵌入。所有策略都取得了相近的下游性能, 这表明增益主要来自词元本身所含的信息, 而非聚合方式。上述编码器生成的稠密嵌入和词元生成的 SID 嵌入都可作为下游模型的直接输入特征, 也可作为交叉注意力层中的键值对, 让候选物品关注用户表示。




图 4: TokenMinds 的服务基础设施。用户表示以异步方式生成并缓存于键值存储中。实时评分直接获取缓存表示; 若表示已过期或缺失, 后台刷新服务会依据用户最新历史重新生成表示 (步骤 4.1-4.3)。

3.5 服务系统

为解决十亿用户规模下高昂的服务成本和延迟问题, 如图 4 所示, 我们将用户表示生成与实时下游推理解耦。TokenMinds 构建于用户行为服务 (UBS) 框架 [17] 之上, 以异步方式生成用户嵌入和词元, 并将其缓存于快速键值存储中。实时模型在评分期间获取这些缓存表示, 无论底层 TokenMinds 的复杂度如何, 都能保持恒定的延迟和成本。当评分请求到达时, 客户端会检查是否存在有效且未过期的表示; 若存在, 则直接获取并输入下游模型。否则, 会立即触发后台刷新: 表示刷新服务读取用户最新的观看历史, 通过已导出的 TokenMinds 模型运行推理, 并将更新后的表示写回缓存。

4 实验

我们首先详述 TokenMinds 的实验设置 (第 4.1 节), 随后从离线指标 (第 4.2 节) 和下游集成的在线评估 (第 4.3 节) 考察推荐质量。最后, 我们分享其他研究所得的经验 (第 4.4 节)。我们尝试回答以下问题:

RQ1 (词元适配 & 可行性): 如何将基于 SID 的离散用户词元以最佳方式适配到下游连续模型中? 当其部署于工业规模的推荐界面时, 能否带来可度量的提升?

RQ2 (互补价值): TokenMinds 同时生成连续嵌入和离散词元的双输出特性是否能提供互补价值?

RQ3 (跨场景建模影响): 统一的跨场景建模范式 (联合训练 LFV 和 SFV) 能否在不损害下游推荐质量的情况下提高计算效率?

4.1 实验设置

模型。 TokenMinds 采用基于 Gemini V1.5 的编码器—解码器架构, 包括一个拥有 370M 参数的混合专家 (MoE) 编码器和一个拥有 370M 参数的稠密解码器。二者均从持续预训练 (CPT) 检查点 [9] 初始化。

训练。 TokenMinds 在交错插入文本搜索查询的 YouTube LFV 和 SFV 观看历史上训练, 使用为 Gemini 生态系统开发的内部 JAX [2] 和 Pathways [1] 框架。我们采用基于最新每日数据的持续训练来捕获新鲜的参与度信号, 每天处理数百万个样例; 相比通常需要数十亿次交互的传统 LEM, 这种方式具有更高的样本效率。对于每个用户样本, 我们使用最近 1,200 次观看, 并交错插入 $S=10$ 条搜索查询 (第 3.3 节), 最大输入序列长度为 1,024 个词元 (进一步分析见第 4.4 节)。每次观看由一个条件词元、前缀- $L=4$ SID 词元和 $M=1$ 个用于非 SID 特征的软词元组成 (第 3.2 节); 使用单个软词元会以约 5% 的离线召

表 1: 训练目标的消融研究。Recall@10 在 SID 前缀- L 预测上评估。

模型	会话召回率	冷启动召回率
TOKENMINDS (本文)	0.291	0.210
无多目标	0.265 (-8.9%)	0.203 (-3.3%)
无前瞻窗口	0.278 (-4.5%)	0.189 (-10.0%)
无 SID 截断	0.247 (-15.1%)	0.174 (-17.1%)

表 2: 初始化策略和搜索查询的影响。指标表示相对于不使用搜索的随机初始化基线的相对百分比提升 ($\Delta\%$)。

初始化策略	+ 搜索查询	$\Delta\%$ Recall@10	
		会话	冷启动
预训练	否	+3.3%	+5.7%
CPT	否	+5.3%	+8.7%
随机初始化	是	+12.5%	+16.9%
预训练	是	+18.5%	+25.1%
CPT	是	+23.5%	+31.5%

回率为代价, 显著缩短序列长度。目标选择从 24 小时前瞻窗口中采样至多 $N=15$ 次观看。通过在 $[10^{-6}, 10^{-3}]$ 范围内网格搜索学习率, 我们发现采用余弦衰减和周期性重启 [3, 20] 的线性预热可达到当天的峰值性能, 但在持续训练下, 恒定学习率对逐日分布偏移更稳健。

服务。TOKENMINDS 通过异步处理基础设施 (第 3.5 节) 提供服务, 刷新周期为 24 小时。对于每个用户, 我们从编码器提取一个 1,152 维稠密嵌入, 并通过束搜索解码 $B=40$ 个 SID 序列 (20 个 LFV、20 个 SFV), 所有序列均采用前缀长度 L , 以形成用户的离散词元表示。

4.2 表示质量

本节中的所有模型均在相同数据上训练至收敛, 以确保公平比较。

Token 准确率与训练消融实验。我们评估了 TOKENMINDS 所生成 Token 的预测准确率, 并对关键训练设计决策进行消融。我们采用两种协议评估 Token 准确率: 会话召回以近乎完整的历史 $[W_1, \dots, W_{n-1}]$ 为输入, 并预测最后一次观看 W_n ; 冷启动召回使用截断的历史 $[W_1, \dots, W_t]$, 并预测从未来窗口 $\{W_{t+1}, \dots, W_n\}$ 中随机采样的一次观看。所有变体均在两种协议下评估, 以确保可比性。在这两种情况下, 我们都生成 top-10 SID 序列 (前缀长度 L), 并计算 Recall@10。

表 1 同时报告了三项消融实验的结果; 每项实验均移除一种训练创新, 同时保持评估方式不变: (1) 无多目标: 将采样目标数从 $N=15$ 减少至 1; (2) 无前瞻窗口: 以标准的下一次观看预测取代前瞻采样 (输入 $[W_1, \dots, W_t]$, 目标 W_{t+1}); (3) 无 SID 截断: 使用全长 SID (L_{full}) 而非长度为 L 的前缀来训练和编码输入; 评估时, 预测结果仍以长度为 L 的前缀粒度进行比较, 以确保指标可比。三项消融均会降低准确率, 其中移除前瞻机制和使用全长 SID 对冷启动性能的损害尤为明显 (相对降幅分别为 -10% 和 -17%), 这证实时间前瞻采样与粗粒度前缀对于泛化到即时会话之外至关重要。




图 5: 生成的用户 Token 与真实用户观看记录的多样性。CDF 表明, 束搜索能够产生多样化预测, 而不会坍塌为冗余输出。(左) SID 前缀重复率: 相同前缀所占的比例。(右) SID Token 冲突率: 每个位置上相同 Token 所占的比例。

初始化策略。为验证从 CPT 检查点 [9] 初始化这一选择, 我们与两个基线进行比较: 通用预训练 Gemini 检查点 (不含 SID 特定的语义锚定) 和随机初始化。表 2 展示了有搜索查询和无搜索查询配置下的比较结果。我们观察到, CPT 始终优于预训练 Gemini, 而预训练 Gemini 又优于随机初始化。这证实了 CPT [9] 期间对 SID 的语义锚定有益于下游任务特定微调, 其收益超越了基础 LLM 本身的一般序列建模能力。

搜索查询的影响。为量化搜索查询的贡献, 我们将完整模型与一个不使用搜索信号训练的变体进行比较。如表 2 所示, 加入 $S=10$ 个交错查询能够在所有初始化策略下稳定提升召回率, 证实显式文本意图在仅使用观看历史之外提供了互补信号。此外, 搜索带来的收益会随初始化增强而放大, 这表明具备对齐 SID 表示的 LLM 骨干网络能够更有效地结合行为观看历史利用文本搜索信号。

Token 多样性。在确认预测准确率并识别出驱动准确率的一些关键因素之后, 我们进一步验证这一性能并非通过冗余的束获得。由于每个解码出的 SID 都会作为下游模型的一种独立兴趣信号, 束坍塌——即多个束收敛到近乎相同的输出——会严重限制表示能力。我们采用两个指标评估多样性: SID Token 冲突率 (衡量位置 x 上相同 Token 的频率, 其中高冲突率表示语义束坍塌) 和 SID 前缀重复率 (统计截至 x 的相同前缀, 其中高重复率表示仅沿单个分支进行孤立探索)。我们在 5K 名用户的样本上评估这些指标, 并将生成的 Token 与同一前瞻 24 小时窗口内的真实观看记录进行比较。为在集合大小不同的情况下确保公平比较, 我们对较大的集合 (真实观看记录或生成的 SID) 进行下采样, 使其大小与较小集合一致。为降低下采样带来的方差, 对于每次比较, 我们将较大集合的下采样重复 10 次, 并报告平均相似度分数。图 5 绘制了不同 Token 索引下所得的 CDF, 结果表明 TOKENMINDS 实现了与真实分布相当的预测多样性, 证实束搜索能够生成多样化的兴趣信号, 而不会坍塌为冗余输出。

嵌入质量。我们在随机采样的 2K 名用户上评估嵌入一致性。对于每名用户, 我们根据其完整历史生成嵌入 E_A , 再通过随机丢弃观看记录生成一个扰动变体 E_{A^*} , 随后将其与随机用户的嵌入 E_B 进行比较。平均余弦相似度 $\text{Sim}(E_A, E_{A^*}) = 0.993$ 远高于 $\text{Sim}(E_A, E_B) = 0.761$, 表明嵌入在轻微历史扰动下保持稳定, 同时仍能区分不同用户。

4.3 在线性能

我们通过在在线 A/B 实验评估 TOKENMINDS 的实际影响, 将用户嵌入和 Token 集成到多个生产排序模型中。尽管 TOKENMINDS 已部署于 YouTube 的排序、检索和基于 LLM 的生产系统中, 本文聚焦于排序集成。所有实验均持续七天。我们在 LFV 和 SFV 上报告两个关键质量指标的表现: 参与用户和满意参与度。在

表 3: 在线转向研究 (110M 模型, SFV), 比较 Token 适配策略: 前缀嵌入映射 (EM) vs. 可学习嵌入 (LE, Unigram)。

策略	参与用户	满意参与度
EM	+0.07%	-0.02%
LE	+0.08%	+0.22%

表 4: 在下游客户端采用不同用户表示时, 加入 TOKENMINDS 的在线评估结果。

场景	表示	参与用户	满意参与度
SFV	仅嵌入	0.00%	+0.05%
	仅 Token	+0.04%	+0.40%
	嵌入 +Token	+0.11%	+0.62%
LFV	仅嵌入	+0.04%	+0.03%
	仅 Token	+0.01%	+0.04%
	嵌入 +Token	+0.02%	+0.08%

表 5: 下游集成开销 (同一场景)。

指标	仅 Token	嵌入 + Token
训练成本	+2.85%	+3.05%
训练速度	-0.7%	-4.2%
服务吞吐量 (最大 QPS)	-1.3%	-7.4%

本节中, 表格中的**粗体数字**表示在 95% 置信水平上具有统计显著性。

Token 适配转向研究. 在投入大量算力构建完整规模的双输出架构之前, 我们在 SFV 场景上使用轻量级 110M 模型开展了在线转向研究, 以确定最优 Token 适配策略。如表 3 所示, 我们比较了静态前缀嵌入映射 (EM) 与可学习嵌入 (LE) ——具体而言, SFV 使用 Unigram ($N=1$), 以匹配该场景现有的物品 Token 化方式。LE 始终优于 EM, 证实允许下游模型学习专用嵌入空间能够实现更好的任务适配 [25]。在 LFV 平台上使用基于 SPM 的 LE 进行辅助评估也呈现相同趋势。因此, 在后续所有完整规模评估中, 我们仅使用 LE, 从而回答 RQ1 的前半部分。

下游质量. 为评估 TOKENMINDS 的独立影响与互补影响, 我们比较了仅加入连续嵌入、仅加入基于离散 SID 的 Token (通过 LE), 以及同时加入两者。表 4 报告了主要 SFV 和 LFV 场景上的结果。我们得出两个关键发现。第一, 基于 SID 的用户 Token 能够在各生产系统中提供增量价值, 直接回答了 RQ1 的后半部分。除表 4 中的主要场景外, 仅 Token 集成在另外两个 LFV 场景上线后, 参与用户分别取得 **+0.04%/+0.16%** 的统计显著提升, 满意参与度分别取得 **+0.07%/+0.11%** 的统计显著提升, 进一步证实了其泛化能力。第二, 同时部署嵌入和 Token 能够放大收益, 验证了 RQ2 所提出的这两种模态具有互补性, 也验证了我们的双输出架构。

下游成本. TOKENMINDS 联合生成每名用户的 Token 和嵌入约需 339ms, 该开销完全由后台处理吸收。每名用户的离散 Token 表示仅需 1,280 字节, 而稠密嵌入需要 4,608 字节, 存储空间减少 72%。在服务阶段, 系统面对来自多个生产场景、每

表 6: LFV 和 SFV 上跨场景建模的在线评估。面板 A 报告质量, 面板 B 详述效率。

面板 A: 质量 (相对于仅 LFV)		
指标	SFV	LFV
参与用户	+0.02%	+0.00%
满意参与度	+0.03%	+0.03%
新鲜内容参与度	+0.33%	+0.19%
面板 B: 资源影响 (相对于 2 个独立模型)		
阶段	资源影响	
上游训练	-50% 计算量	
上游服务	-31% 计算量	




图 6: 不同模型架构变体的训练 Recall@10 和第 8 天 Recall@10 与训练 Iso-FLOPS 的关系。所有坐标轴均采用对数尺度。

秒 1.44M 次的读取请求时, 缓存命中率达到 96.4%。将预计算嵌入作为特征引入只会产生可忽略的计算成本; Token 集成开销详见表 5。

跨场景建模. 我们将统一的跨场景模型与两个基线进行比较: 用于质量比较的仅使用 LFV 数据训练的 LFV-only 模型, 以及用于效率比较的分别训练的 LFV 和 SFV 模型。由表 6 (面板 B) 可见, 将 LFV 和 SFV 整合进单一框架能够显著节省成本。一个模型取代两个模型, 使训练计算量减少 50%。多上下文解码 (第 3.3 节) 在不同场景间共享单次编码器前向传播 (481 个芯片), 而不是运行两次完整模型前向传播 (总计 698 个芯片), 使上游服务成本降低 31%。由于统一模型产生的输出形状与 LFV-only 基线相同, 下游集成成本保持不变。

从质量来看, 面板 A 表明, 以统一表示替代 LFV-only 基线能够稳定提升新鲜度指标 (新鲜内容参与度衡量用户与新视频的交互), 同时不会降低核心参与度指标。值得注意的是, 统一模型在同一个固定长度的输入序列中同时处理 LFV 和 SFV 观看记录, 导致可用的 LFV 历史几乎减半。尽管如此, 核心指标仍保持不变, 这表明来自 SFV 交互的跨场景信号弥补了 LFV 上下文的减少——证实统一范式能够在不牺牲质量的情况下取得显著效率收益。

4.4 缩放研究

为优化计算效率, 这些研究采用加速的离线评估协议 [9]: 模型在随机打乱的 7 天数据上训练, 并在随后第 8 天的数据上评估。

模型变体 & 容量分配. 我们探究架构设计与容量分配对模型质量的影响。受限于预训练 Gemini 检查点的可用性, 我们研究了三种热启动变体: 均衡 MoE (370M 编码器 / 370M MoE 解码器)、均衡稠密 (370M 编码器 / 370M 稠密解码器) 和非均衡稠密模型 (420M 编码器 / 110M 稠密解码器)。我们以均衡稠密




图 7: 扩大用户历史长度 (HL) 时, LFV 和 SFV 的第 8 天 Recall@10 与训练步数的关系。

模型为锚点, 在其周围的 $[0.1\times, 10\times]$ 范围内对学习率进行网格搜索。

图 6 展示了 LFV 的训练 Recall 和第 8 天 Recall 与 Iso-FLOPS 的关系 (SFV 因趋势相似而省略)。尽管非均衡模型的训练 Recall 低于均衡稠密基线, 但其第 8 天 Recall 与后者相当。这为非对称服务策略提供了可能: 采用刷新频率较低的较重编码器来生成稳定的用户嵌入, 同时采用刷新更频繁的较轻解码器来捕捉近期行为。此外, 在 FLOPS 相同的情况下, 均衡 MoE 解码器的第 8 天 Recall 优于对应的稠密解码器, 证实稀疏专家路由在泛化到未来用户行为方面具有切实优势。

输入长度缩放. 尽管现代用户建模通常受益于长期观看历史 [21], 但开发计算最优模型需要理解缩放规律。我们分析了用户历史长度 (HL) 的影响。如图 7 所示, 当观看记录约为 1K 时, LFV 和 SFV 的第 8 天 Recall@10 均开始趋于饱和。将其扩展至 2K 次观看时, SFV 上的性能相当或略有下降。

批大小缩放. 我们评估了 4K、8K 和 16K 的批大小, 其中将经过充分学习率调优的 8K 作为锚点配置, 并通过标准 $\sqrt{N}$ 规则 [3] 缩放至其他批大小。相对于 4K 基线, 8K 时第 8 天 Recall@10 提升 +2.5%/+5.5% (SFV/LFV), 16K 时提升 +7.6%/+13.7%。与 PLUM [9] 的发现一致, 更大的批次能够加速收敛, 并在相同训练窗口内产生更强的表示。这凸显了在硬件容量范围内尽可能增大批大小对于计算最优训练的重要性。

5 结论

我们提出了 TOKENMINDS, 这是一个基于预训练 LLM 改造的统一编码器-解码器架构, 用于生成基于离散 SID 的用户 Token 和稠密用户嵌入。跨场景建模进一步在共享 SID 词表与多上下文解码机制下统一 LFV 和 SFV, 从而显著减少上游计算量。

作为一个已部署于 YouTube 的系统, TOKENMINDS 表明, 基于 SID 的用户 Token 是生产排序系统中一种可行的表示。将这些 Token 与稠密嵌入相结合可带来更大的性能收益, 证实双输出设计具有互补价值。我们的消融实验还进一步验证了 CPT 初始化的重要性, 以及搜索查询信号对基于 SID 的用户建模所带来的协同收益。

这些结果表明, 离散且具有语义锚定的用户表示为突破仅依赖稠密嵌入的表示约束、扩展用户建模提供了一条富有前景的方向。

参考文献

- [1] Paul Barham, Aakanksha Chowdhery, Jeff Dean, Sanjay Ghemawat, Suyog Joshi, Manjunath Kudlur, Brian Levenstein, Claire Lloyd, Xinyuan Liu, Hao Mao, et al. 2022. Pathways: Asynchronous Distributed Dataflow for ML. In *Proceedings of the 5th Conference on Machine Learning and Systems (MLSys)*.
- [2] James Bradbury, Roy Frostig, Peter Hawkins, Matthew James Johnson, Chris Leary, Dougal Maclaurin, George Necula, Adam Paszke, Jake VanderPlas, Skye Wanderman-Milne, and Qiao Zhang. 2018. *JAX: composable transformations of Python+NumPy programs*. <http://github.com/google/jax>
- [3] Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. 2020. Language models are few-shot learners. *Advances in neural information processing systems* 33 (2020), 1877–1901.
- [4] Zheng Chai, Qin Ren, Xijun Xiao, Huizhi Yang, Bo Han, Sijun Zhang, Di Chen, Hui Lu, Wenlin Zhao, Lele Yu, et al. 2025. Longer: Scaling up long sequence modeling in industrial recommenders. In *Proceedings of the Nineteenth ACM Conference on Recommender Systems*. 247–256.
- [5] Bo Chang, Alexandros Karatzoglou, Yuyan Wang, Can Xu, Ed H Chi, and Minmin Chen. 2023. Latent user intent modeling for sequential recommenders. In *Companion Proceedings of the ACM Web Conference 2023*. 427–431.
- [6] Benjamin Coleman, Wang-Cheng Kang, Matthew Fahrback, Ruoxi Wang, Lichan Hong, Ed Chi, and Derek Cheng. 2023. Unified embedding: Battle-tested feature representations for web-scale ML systems. *Advances in Neural Information Processing Systems* 36 (2023), 56234–56255.
- [7] Paul Covington, Jay Adams, and Emre Sargin. 2016. Deep neural networks for youtube recommendations. In *Proceedings of the 10th ACM conference on recommender systems*. 191–198.
- [8] Shijie Geng, Shuchang Liu, Zuohui Fu, Yingqiang Ge, and Yongfeng Zhang. 2022. Recommendation as language processing (rlp): A unified pretrain, personalized prompt & predict paradigm (p5). In *Proceedings of the 16th ACM conference on recommender systems*. 299–315.
- [9] Ruining He, Lukasz Heldt, Lichan Hong, Raghunandan Keshavan, Shifan Mao, Nikhil Mehta, Zhengyang Su, Alicia Tsai, Yueqi Wang, Shao-Chuan Wang, et al. 2025. Plum: Adapting pre-trained language models for industrial-scale generative recommendations. *arXiv preprint arXiv:2510.07784* (2025).
- [10] Balázs Hidasi, Alexandros Karatzoglou, Linas Baltrunas, and Domonkos Tikk. 2016. Session-based Recommendations with Recurrent Neural Networks. In *International Conference on Learning Representations (ICLR)*.
- [11] Yupeng Hou, Jiacheng Li, Ashley Shin, Jinsung Jeon, Abhishek Santhanam, Wei Shao, Kaveh Hassani, Ning Yao, and Julian McAuley. 2025. Generating long semantic ids in parallel for recommendation. In *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V. 2*. 956–966.
- [12] Yanhua Huang, Yuqi Chen, Xiong Cao, Rui Yang, Mingliang Qi, Yinghao Zhu, Qingchang Han, Yaowei Liu, Zhaoyu Liu, Xuefeng Yao, et al. 2025. Towards large-scale generative ranking. *arXiv preprint arXiv:2505.04180* (2025).
- [13] Clark Mingxuan Ju, Liam Collins, Leonardo Neves, Bhuvish Kumar, Louis Yufeng Wang, Tong Zhao, and Neil Shah. 2025. Generative Recommendation with Semantic IDs: A Practitioner’s Handbook. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management*. 6420–6425.
- [14] Wang-Cheng Kang and Julian McAuley. 2018. Self-Attentive Sequential Recommendation. In *IEEE International Conference on Data Mining (ICDM)*. IEEE, 197–206.
- [15] Sein Kim, Hongseok Kang, Kibum Kim, Jiwan Kim, Donghyun Kim, Minchul Yang, Kwangjin Oh, Julian McAuley, and Chanyoung Park. 2025. Lost in Sequence: Do Large Language Models Understand Sequential Recommendation?. In *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V. 2*. 1160–1171.
- [16] Taku Kudo. 2018. Subword regularization: Improving neural network translation models with multiple subword candidates. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. 66–75.
- [17] Yuening Li, Diego Uribe, Chuan He, Jiaxi Tang, Qingyun Liu, Junjie Shan, Ben Most, Kaushik Kalyan, Shuchao Bi, Xinyang Yi, et al. 2024. Short-form Video Needs Long-term Interests: An Industrial Solution for Serving Large User Sequence Models. In *Proceedings of the 18th ACM Conference on Recommender Systems*. 832–834.
- [18] Qingyun Liu, Zhe Zhao, Liang Liu, Zhen Zhang, Junjie Shan, Yuening Li, Shuchao Bi, Lichan Hong, and Ed H Chi. 2023. Multitask Ranking System for Immersive Feed and No More Clicks: A Case Study of Short-Form Video Recommendation. In *Proceedings of the 32nd ACM International Conference on Information and Knowledge Management*. 4709–4716.
- [19] Zhanyu Liu, Shiyao Wang, Xingmei Wang, Rongzhou Zhang, Jiaxin Deng, Honghui Bao, Jinghao Zhang, Wuchao Li, Pengfei Zheng, Xiangyu Wu, et al. 2025. Onerec-think: In-text reasoning for generative recommendation. *arXiv preprint arXiv:2510.11639* (2025).
- [20] Ilya Loshchilov and Frank Hutter. 2016. Sgdr: Stochastic gradient descent with warm restarts. *arXiv preprint arXiv:1608.03983* (2016).
- [21] Wenhan Lyu, Devashish Tyagi, Yihang Yang, Zawei Li, Ajay Somani, Karthikeyan Shanmugasundaram, Nikola Andrejevic, Ferdi Adeputra, Curtis Zeng, Arun K Singh, et al. 2025. DV365: Extremely Long User History Modeling at Instagram. *arXiv preprint arXiv:2506.00450* (2025).
- [22] Muyang Ma, Pengjie Ren, Zhumin Chen, Zhaochun Ren, Lifan Zhao, Peiyu Liu, Jun Ma, and Maarten de Rijke. 2022. Mixed information flow for cross-domain recommendations. *ACM Transactions on Knowledge Discovery from Data (TKDD)* 16, 4 (2022), 1–32.
- [23] Nikil Pancha, Andrew Zhai, Jure Leskovec, and Charles Rosenberg. 2022. Pinnerformer: Sequence modeling for user representation at pinterest. In *Proceedings of the 28th ACM SIGKDD conference on knowledge discovery and data mining*. 3702–3712.
- [24] Shashank Rajput, Nikhil Mehta, Anima Singh, Raghunandan Keshavan, Trung Vu, Lukasz Heldt, Lichan Hong, Yi Tay, Vinh Q. Tran, Jonah Samost, Maciej Kula, Ed H. Chi, and Maheswaran Sathiamoorthy. 2023. Recommender systems with generative retrieval. In *Proceedings of the 37th International Conference on Neural Information Processing Systems (NIPS '23)*. Curran Associates Inc., Red Hook, NY, USA, Article 452.
- [25] Anima Singh, Trung Vu, Nikhil Mehta, Raghunandan Keshavan, Maheswaran Sathiamoorthy, Yilin Zheng, Lichan Hong, Lukasz Heldt, Li Wei, Devansh Tandon, Ed Chi, and Xinyang Yi. 2024. Better Generalization with Semantic IDs: A Case Study in Ranking for Recommendations. In *Proceedings of the 18th ACM Conference on Recommender Systems (RecSys '24)*. Association for Computing Machinery, New York, NY, USA.
- [26] Juntao Tan, Shuyuan Xu, Wenyue Hua, Yingqiang Ge, Zelong Li, and Yongfeng Zhang. 2024. Idgenrec: Llm-recsys alignment with textual id learning. In *Proceedings of the 47th international ACM SIGIR conference on research and development in information retrieval*. 355–364.
- [27] Jiaxi Tang and Ke Wang. 2018. Personalized Top-N Sequential Recommendation via Convolutional Sequence Embedding. In *Proceedings of the Eleventh ACM International Conference on Web Search and Data Mining (WSDM)*. ACM, 565–573.
- [28] Yuhao Wang, Yichao Wang, Zichuan Fu, Xiangyang Li, Wanyu Wang, Yuyang Ye, Xiangyu Zhao, Huifeng Guo, and Ruiming Tang. 2024. Llm4msr: An llm-enhanced paradigm for multi-scenario recommendation. In *ACM International Conference on Information and Knowledge Management*.
- [29] Orion Weller, Michael Boratko, Iftekhar Naim, and Jinhyuk Lee. 2025. On the theoretical limitations of embedding-based retrieval, 2025. [URL https://arxiv.org/abs/2508.21038](https://arxiv.org/abs/2508.21038) (2025).
- [30] Manjie Xu, Cheng Chen, Xin Jia, Jingyi Zhou, Yongji Wu, Zejian Wang, Chi Zhang, Kai Zuo, Yibo Chen, Xu Tang, et al. 2025. Cross-Scenario Unified Modeling of User Interests at Billion Scale. *arXiv preprint arXiv:2510.14788* (2025).
- [31] Bei Yang, Jie Gu, Ke Liu, Xiaoxiao Xu, Renjun Xu, Qinghui Sun, and Hong Liu. 2023. Empowering General-purpose User Representation with Full-life Cycle Behavior Modeling. In *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)*. ACM, 5364–5374.
- [32] Fan Yang, Zheng Chen, Ziyang Jiang, Eunah Cho, Xiaojiang Huang, and Yanbin Lu. 2023. Palr: Personalization aware llms for recommendation. *arXiv preprint arXiv:2305.07622* (2023).
- [33] Liu Yang, Fabian Paischer, Kaveh Hassani, Jiacheng Li, Shuai Shao, Zhang Gabriel Li, Yun He, Xue Feng, Nima Noorshams, Sem Park, et al. 2024. Unifying generative and dense retrieval for sequential recommendation. *arXiv preprint arXiv:2411.18814* (2024).
- [34] Yuhao Yang, Zhi Ji, Zhaopeng Li, Yi Li, Zhonglin Mo, Yue Ding, Kai Chen, Zijian Zhang, Jie Li, LIU LIN, et al. 2026. Sparse meets dense: Unified generative recommendations with cascaded sparse-dense representations. *Advances in Neural Information Processing Systems* 38 (2026), 93746–93770.
- [35] Zhiming Yang, Haining Gao, Dehong Gao, Luwei Yang, Libin Yang, Xiaoyan Cai, Wei Ning, and Guannan Zhang. 2024. Mlora: Multi-domain low-rank adaptive network for ctr prediction. In *ACM Conference on Recommender Systems*.
- [36] Tianzi Zang, Yanmin Zhu, Haobing Liu, Ruohan Zhang, and Jiadi Yu. 2022. A survey on cross-domain recommendation: taxonomies, methods, and future directions. *ACM Transactions on Information Systems* 41, 2 (2022), 1–39.
- [37] Jiaqi Zhai, Lucy Liao, Xing Liu, Yueming Wang, Rui Li, Xuan Cao, Leon Gao, Zhaojie Gong, Fangda Gu, Michael He, et al. 2024. Actions Speak Louder than Words: Trillion-Parameter Sequential Transducers for Generative Recommendations. In *International Conference on Machine Learning (ICML)*.
- [38] Jun Zhang, Yi Li, Yue Liu, Changping Wang, Yuan Wang, Yuling Xiong, Xun Liu, Haiyang Wu, Qian Li, Enming Zhang, et al. 2025. GPR: Towards a Generative Pre-trained One-Model Paradigm for Large-Scale Advertising Recommendation. *arXiv preprint arXiv:2511.10138* (2025).
- [39] Zhe Zhao, Lichan Hong, Li Wei, Jilin Chen, Anirudh Nath, Shawn Andrews, Aditee Kumbhakar, Maheswaran Sathiamoorthy, Xinyang Yi, and Ed Chi. 2019. Recommending what video to watch next: a multitask ranking system. In *Proceedings of the 13th ACM conference on recommender systems*. 43–51.
- [40] Guorui Zhou, Jiaxin Deng, Jinghao Zhang, Kuo Cai, Lejian Ren, Qiang Luo, Qianqian Wang, Qigen Hu, Rui Huang, Shiyao Wang, et al. 2025. OneRec Technical

- Report. *arXiv preprint arXiv:2506.13695* (2025).
- [41] Guorui Zhou, Hengrui Hu, Hongtao Cheng, Huanjie Wang, Jiaxin Deng, Jinghao Zhang, Kuo Cai, Lejian Ren, Lu Ren, Liao Yu, et al. 2025. Onerec-v2 technical report. *arXiv preprint arXiv:2508.20900* (2025).
- [42] Jingyi Zhou, Cheng Chen, Kai Zuo, Manjie Xu, Zhendong Fu, Yibo Chen, Xu Tang, and Yao Hu. 2025. HyMiRec: A Hybrid Multi-interest Learning Framework for LLM-based Sequential Recommendation. *arXiv preprint arXiv:2510.13738* (2025).