

TransRetrieval: 面向工业推荐的可扩展 Transformer 召回

Zhifei Zheng^{*†}
zhifei.zheng@ruc.edu.cn
中国人民大学高瓴人工智能学院
北京, 中国

Yunfei Liu^{*}
Bin Liu^{*}
lyf327482@alibaba-inc.com
zhuoli.lb@alibaba-inc.com
阿里巴巴淘宝 & 天猫集团
北京, 中国

Qiren Zhu[†]
Hanbing Liu[†]
qiren_zhu@163.com
liuhanbing@ruc.edu.cn
中国人民大学高瓴人工智能学院
北京, 中国

Ziru Xu
Han Zhu
Jian Xu
ziru.xzr@alibaba-inc.com
zhuhan.zh@alibaba-inc.com
xiyu.xj@alibaba-inc.com
阿里巴巴淘宝 & 天猫集团
北京, 中国

Qi Qi^{‡§}
qi.qi@ruc.edu.cn
中国人民大学高瓴人工智能学院
北京, 中国

Bo Zheng[‡]
bozheng@alibaba-inc.com
阿里巴巴淘宝 & 天猫集团
北京, 中国

摘要

将缩放定律应用于推荐召回受到特征异质性的阻碍: 简单堆叠 Transformer 层会带来收益递减, 因为异质字段会导致严重的 token 范数分化。我们提出 **TransRetrieval**, 一个可随计算预算和跨域数据共同扩展的基于 Transformer 的召回框架。实现这一点的关键首先是 (1) 加权平均聚合, 它恢复了 Transformer 所依赖的同质 token 假设。在此基础上, 我们进一步提出 (2) 目标 token 压缩, 在保留交叉注意力表达能力的同时将单候选 FLOPs 降低 85%; 以及 (3) 位置式域嵌入, 以几乎可忽略的额外成本统一多个域, 将跨域数据转化为缩放资产。在包含 400 亿次交互的工业数据集和公开 KuaiRand 基准上, 将每个目标的计算量从 0.1 扩展至 2 MFLOPs, Recall@2000 分别提升 +19.3 / +22.2 pt, 验证了稳健的对数线性缩放规律。在线 A/B 测试中, 在与生产基线相同的端到端延迟约束下, TransRetrieval 使平台收入提升 2.53%。

CCS Concepts

• 信息系统 → 搜索引擎架构与可扩展性; 推荐系统; • 计算方法 → 学习范式。

Keywords

大规模召回, Transformer, 缩放定律, 嵌入归一化, 多域建模, 推荐系统

^{*}对本研究贡献相同。

[†]本工作于阿里巴巴集团实习期间完成。

[‡]通讯作者。

[§]Also with 北京市大型模型与智能治理研究重点实验室; 教育部下一代智能搜索与推荐工程研究中心。



This work is licensed under a Creative Commons Attribution 4.0 International License.
CIKM '26, 意大利罗马

© 2026 Copyright held by the owner/author(s).

ACM ISBN 979-8-4007-2539-5/2026/11

<https://doi.org/10.1145/3799682.3840118>

ACM Reference Format:

Zhifei Zheng, Yunfei Liu, Bin Liu, Qiren Zhu, Hanbing Liu, Ziru Xu, Han Zhu, Jian Xu, Qi Qi, and Bo Zheng. 2026. TransRetrieval: 面向工业推荐的可扩展 Transformer 召回. In 第 35 届 ACM 信息与知识管理国际会议 (CIKM '26) 论文集, 2026 年 11 月 07–11 日, 意大利罗马. ACM, New York, NY, USA, 8 pages. <https://doi.org/10.1145/3799682.3840118>

1 引言

缩放定律一直是大语言模型快速发展的驱动力: 模型性能会随模型规模、数据和计算量的增加而可预测地提升 [8]。推荐系统尽管拥有海量数据集和不断增长的计算预算, 却大多未能展现出类似的缩放行为。近期研究证实了这一差距: 传统深度推荐模型在简单扩大规模时会出现收益递减, 甚至负收益 [22, 24]。Transformer 在 NLP 和视觉领域的幂律缩放特性已得到充分验证, 因此自然成为弥合这一差距的候选方案。

然而, 在大规模召回中扩展 Transformer 面临若干挑战: 此时的候选池规模可达 10^8 个物品, 而延迟预算仅为数十毫秒: (1) 异质特征尺度失配。标准 Transformer 处理同质输入 token: 在 NLP 中, 每个词嵌入都来自同一张查找表 [20]; 在视觉中, 每个图像块都经过相同的投影 [5]。然而, 推荐特征天然具有异质性 (用户画像、行为序列和物品属性), 将它们映射为 Transformer token 会产生严重的尺度失配 [27]。这种失配会在结构上扭曲嵌入空间, 悄然降低表示质量。(2) 紧张的计算预算与延迟约束之间的矛盾。召回必须在严格的每秒查询数 (QPS) 要求下服务规模高达 10^8 个物品的语料库 [4, 9], 其约束比排序阶段严苛数个数量级 [2]。(3) 跨域扩展带来的成本倍增。工业系统通常要服务多个业务域 (例如首页、搜索、详情页), 各域具有不同的行为分布 [10]。为每个域分别维护一个深层模型, 会使训练和服务成本成倍增加, 而稀疏域又缺少足够数据, 无法仅靠扩大规模获益。然而, 简单合并多个域也会因其分布冲突而失败。

近期已有若干工作推动推荐系统的规模化, 包括 HSTU [23]、RankMixer [27]、MARM [14]、Climber [22] 和 MTGR [7]。它们要么将异质特征集展平, 要么预先分组, 而且都面向排序阶段, 即只对召回已经筛选出的候选进行打分。因此, 如何在严格延

迟预算下保留异质特征, 并将 Transformer 扩展到规模高达 10^8 个物品的语料库召回, 仍然鲜有研究。

我们提出 **TransRetrieval**, 这是一个已部署于阿里巴巴展示广告平台、服务于 4 个业务域的基于 Transformer 的召回框架。三个设计选择分别应对上述三项挑战, 并共同实现规模化: (1) 加权平均聚合从源头解决尺度失配, 它将嵌入范数与特征基数解耦, 恢复 Transformer 所依赖的同质 token 假设。(2) 目标 token 压缩通过轻量级多层感知机 (MLP), 将目标侧的全部特征投影为单个 D 维 token, 使单候选 FLOPs 降低 85%, 并支持基于分层可导航小世界 (HNSW) 的次线性召回。通过在目标之间共享同一份 KV 缓存, 推理成本得到进一步降低: 由于一次请求中的所有候选都针对同一用户打分, 用户侧的键和值只需为每个请求计算一次, 随后由所有候选复用。(3) 位置式域嵌入通过逐元素相加注入域信息, 方式与位置编码类似。它以几乎可忽略的额外 FLOPs 将 4 个域统一到单一模型中, 并把多域数据转化为缩放资产, 使稀疏域能够受益于跨域迁移。

这三项设计都只采用标准算子, 无需额外基础设施, 为在召回中部署 Transformer 提供了一套可迁移的方法。TransRetrieval 已部署于阿里巴巴展示广告平台, 在线 A/B 测试中使平台收入提升 2.53%; 将每个目标的计算量从 0.1 扩展到 2 MFLOPs 后, 工业数据集上的 Recall@2000 提升 +19.3 pt, 公开 KuaiRand 基准上提升 +22.2 pt, 验证了稳健的对数线性缩放规律。据我们所知, 这是推荐架构召回阶段中最早对缩放定律进行系统验证的工作之一, 并与 Climber [22] 展示的近期排序阶段结果形成互补。

2 相关工作

推荐系统中的规模化与异质特征障碍。Wukong [24] 首次系统诊断了深度推荐模型的缩放低效问题, 并将其归因于只扩展嵌入表、却未增强特征交互的扩容机制。后续工作并未解决异质性障碍, 而是选择绕过它: HSTU [23] 将所有特征展平为单行为序列, 牺牲了不同特征类型之间的结构区分; RankMixer [27] 将特征预先分组为固定语义通道, 再通过无参数 token mixing 处理; 而 MARM [14] 只有借助 60 TB 缓存基础设施才能取得相当的收益; Climber [22] 聚焦于多尺度序列提取, 其输入是来自同一嵌入表的行为 token; MTGR [7] 则在生成式范式下保留丰富特征。这些工作都只在排序阶段验证了缩放; 如何在保留完整异质特征集的同时, 实现召回阶段中深层 Transformer 的稳定缩放, 仍未得到解决。

基于模型的召回与 Transformer 效率。NANN [3] 建立了基于模型的召回范式: 深度神经网络 (DNN) 打分函数驱动在 HNSW 图 [16] 上的束搜索, 因此只需对语料库中很小一部分物品进行打分——由模型本身决定评估哪些候选。作为我们的生产基线, BAR [12] 通过竞价感知扩展了这一范式, 以保持多阶段一致性, 但其打分网络仍然很小。在用户侧, 从双塔架构 [4] 到序列 Transformer (SASRec [11]、BERT4Rec [18]) 的发展丰富了用户表示; KuaiFormer [13] 则在生成式范式下将召回重新表述为下一动作预测。然而, 在基于模型的范式下, 每个候选仍需通过目标网络完成一次前向计算, 因此单候选 FLOPs 成为主要瓶颈, 这也是打分网络规模一直较小的原因。TransRetrieval 仍沿用该范式, 但缓解了这一瓶颈: 将每个候选压缩为单个 token, 使单候选前向计算足够低廉, 从而可以扩展打分网络本身。

多域推荐与跨域数据缩放。基于专家的方法 (MMoE [15]、PLE [19]) 在不同域之间共享专家参数, 但基于门控的软路由意味着稀疏域的门控因数据有限而训练不足, 无法充分利用共享容量实现有效的数据缩放。STAR [17] 通过共享组件和域专

属组件统一服务, 但其星型拓扑尚未被证明能够实现有利于数据稀缺域的跨域迁移。

3 TransRetrieval: 方法

我们首先在第 3.1 节形式化召回范式并概述整体架构, 随后在第 3.2–3.4 节详细介绍三项核心设计。

3.1 预备知识

基于模型的召回。TransRetrieval 采用 NANN [3] 建立的基于模型的召回范式: DNN 打分函数 $s(u, i) = F_\theta(u, i)$ 驱动在 HNSW 图 [16] 上的束搜索, 每次请求仅访问语料库的一小部分 ρ 。我们用这一比例而不是绝对数量表示打分预算, 因为决定单次请求成本的是 ρ , 而非语料库规模: 对于包含 N 个物品的语料库, 模型执行 ρN 次而不是 N 次前向计算。实际设置中, ρ 通常约为 0.1%–1%; 我们的部署在包含 52 M 个物品的语料库上 ($\rho \approx 0.08\%$) 对 $\sim 4 \times 10^4$ 个候选打分, 同一流水线可服务规模高达 10^8 的语料库。与由 $s(u, i) = \langle f(u), g(i) \rangle$ 将交互限制为内积的双塔模型不同, 基于模型的召回允许任意的跨特征交互, 代价是每个候选都要进行一次前向计算, 因此单候选 FLOPs 成为主要瓶颈。

特征表示。每个特征字段 f 表示为一组 (键, 权重) 对 $\{(k_i, v_i)\}_{i=1}^{n_f}$, 其中 k_i 用于索引嵌入表 $h: \mathcal{K} \rightarrow \mathbb{R}^D$, $v_i \in \mathbb{R}$ 是其权重。

架构概览。如图 1 所示, TransRetrieval 分四个阶段处理特征: (1) 通过加权平均聚合每个特征字段 (第 3.2 节), 生成适合 Transformer 的 token; (2) 通过轻量级 MLP 将目标 token 压缩为单个 D 维 token (第 3.3 节), 而每个用户侧特征形成 1 个 token; (3) 将可学习的域嵌入逐元素加到所有 token 上 (第 3.4 节); (4) 所得 token 进入一个含 N_{layer} 层、采用 ReLU 前馈网络 (FFN) 的 Pre-LN Transformer, 其中一次请求的用户侧键值 (KV) 对仅缓存一次, 并由该请求的所有目标候选复用。

3.2 通过加权平均聚合衔接异质特征

在传统的加权求和聚合方式下对模型进行性能剖析, 结果显示存在严重的尺度失配: 用户侧 token 范数最高可达目标侧 token 范数的 $10\times$ 。这种不平衡会导致注意力权重被高范数 token 主导。根本原因在于, 加权求和聚合的输出范数会随特征基数 n_f 增长: 包含多值特征的用户侧字段天然会累积出远大于目标侧字段的范数。

我们使用加权平均聚合解决这一问题:

$$\mathbf{e}_f = \frac{\sum_{i=1}^{n_f} v_i \cdot h(k_i)}{\sum_{i=1}^{n_f} v_i + \epsilon} \quad (1)$$

除以 $\sum_i v_i$ 会同时抵消依赖于 n_f 的累积效应和异质权重幅值, 使输出范数仅由嵌入表的分布限定, 而与字段基数无关。

为什么不采用其他聚合器? 最大池化会引入一个随 $O(\sqrt{\ln n_f})$ 增长的极值偏差, 并丢弃大部分特征信息。在聚合后应用 LayerNorm [1] 的实证表现较差 (第 4.4.1 节): 它的中心化和重缩放会抹去用于区分异质字段的逐字段幅值信号。加权平均是一种能够同时满足以下两点的算子: (a) 输出尺度的上界与 n_f 无关; (b) 无需学习或估计统计量。它是一种闭式线性组合, 无论 D 如何都能保持稳定。




Figure 1: TransRetrieval 的整体架构。三大支柱均采用轻量级设计：(i) 首先通过加权平均聚合异质特征；(ii) 通过 MLP 将目标特征压缩为单个 token；(iii) 通过位置式嵌入注入域上下文（加到所有 token 上）。随后，共享 Transformer 使用一份仅计算一次、供所有目标复用的用户侧 KV 缓存，对一次请求中的每个候选进行打分。

3.3 通过目标 Token 压缩实现高效召回

由于一次请求中的所有候选共享同一用户，用户侧 K/V 每次请求只计算一次，并由所有目标复用；随后，每个目标候选只需计算自身的 Q/K/V 输出投影和 FFN（每层 $16L_t D^2$ ），再对长度为 L_u 的完整用户序列执行交叉注意力（每层 $4L_t L_u D$ ）。对 N_{layer} 层和 N_{target} 个候选求和：

$$\text{FLOPs}_{\text{total}} \approx 4D \cdot N_{\text{target}} \cdot L_t \cdot (4D + L_u) \cdot N_{\text{layer}} \quad (2)$$

其中， L_t 为目标 token 数量， L_u 为用户序列长度。在这些因素中， D 和 N_{layer} 是我们希望尽可能扩大的缩放参数； $N_{\text{target}} = \rho N$ 已由 HNSW 缩减至语料库的一小部分；而 L_u 主要由 $4D$ 项决定。因此，只有 L_t 仍有显著的缩减空间。在未压缩模型中， L_t 随目标特征字段数量增长，因此自然成为压缩对象。

我们引入一个目标压缩器：它是一个隐藏层大小为 $[8D, 4D, D]$ 的 3 层 MLP，层间采用 Parametric ReLU 激活和 LayerNorm（最后一层为普通线性投影），将所有目标侧聚合嵌入的拼接映射为单个 token：

$$\mathbf{t} = \text{MLP}([\mathbf{e}_{f_1}, \mathbf{e}_{f_2}, \dots, \mathbf{e}_{f_M}]) \in \mathbb{R}^D \quad (3)$$

关键在于，这种压缩并非妥协，而是一种策略性的资源重分配：释放出的 FLOPs 被重新投入到扩大 D 和 N_{layer} 中，从而在相同的延迟预算内支持更深、更宽的架构，以冗余的逐候选 token 换取更丰富的跨特征交互。

这个压缩后的单 token 也可自然地作为固定维度向量直接用于 HNSW 索引，无需进一步处理。

3.4 通过位置式域嵌入实现跨域数据扩展

如第 1 节所述，需要一个统一的多域模型来避免成本按域成倍增加。剩余的设计问题是如何注入域身份。一种直接的策略是在输入序列后附加 N_t 个用于编码域的额外 token，但这会使注意力开销从 $O(L^2)$ 增加到 $O((L+N_t)^2)$ 。

我们改为引入一种位置式域嵌入：由域 d 索引的可学习向量 $\mathbf{s}_d \in \mathbb{R}^D$ ，并将其逐元素加到每个 token 上：

$$\tilde{\mathbf{e}}_f = \mathbf{e}_f + \mathbf{s}_d \quad (4)$$

与位置编码 [20] 类似，域身份的注入不会增加序列长度或注意力复杂度。

核心洞见在于，该设计能够实现跨域数据扩展：由于域信息仅通过逐元素相加进入模型，所有 Transformer 参数，包括每个注意力头和 FFN 层，都会在各域之间无条件共享。来自每个域的所有训练样本都会对同一组参数贡献梯度，因此稀疏域不再面临数据不足的问题。这与 MMoE/PLE 不同，后者的门控路由会隐式地分割梯度流。

3.5 系统实现

要将 TransRetrieval 部署到生产环境中，需要协同设计推理系统与模型架构，以满足严格的延迟约束。

硬件感知的推理优化。一个请求的用户侧 KV 对只需计算一次，并在其所有候选的打分过程中共享。标准 LLM 推理框架会为每个候选序列复制一次该缓存；我们则用 expand 算子替换缓存管理器，将单份用户缓存无复制地广播到每个候选，使

单轮延迟降低 30%。完成目标压缩后, 每个候选都成为一个关注完整用户上下文的单查询 token。这种极端的长宽比会严重降低现代 GPU 硬件的利用率, 因为现代 GPU 针对大型矩阵运算而非单行查询进行了优化。我们将多个候选打包到一次带掩码的批处理计算中, 同时保持候选之间彼此隔离, 从而显著提高硬件利用率。结合跨 LayerNorm、残差层和激活层的算子融合, 模型前向延迟相较朴素实现 (vs. naive implementation) 降低了 11 $\times$ 。

GPU 检索。基于模型的检索在多线程搜索迭代中交替执行打分与图搜索。当索引位于 CPU 上时, 每轮迭代都会产生多次主机与设备间的往返传输, 从而割裂 GPU 计算图。我们将所有检索算子 (邻居查找、距离计算和候选选择) 迁移到 GPU, 把打分与搜索统一为一条驻留设备的流水线, 使检索延迟相较 CPU 检索 (vs. CPU retrieval) 降低 89%。然而, 将完整索引与模型共同放置在 GPU 上会带来显存压力。我们通过跨请求共享推理引擎并量化静态索引数据来降低 GPU 显存占用, 使服务并发度提高 3 $\times$ 。

近线更新。目标压缩器 (第 3.3 节) 在架构上与 Transformer 解耦, 并被部署为独立子图。在全量部署期间, 该子图计算所有目标的表示, 用于构建检索索引。为保持数据新鲜度, 一个事件驱动的近线服务会监控目标特征的变化, 并调用同一个子图, 仅重新计算受影响的表示, 再将更新异步传播到在线索引。

4 实验

我们重点研究以下问题:

- **RQ1:** 在相近的计算预算下, TransRetrieval 与当前最先进的基线相比表现如何? (第 4.2 节)
- **RQ2:** 随着模型容量增加, TransRetrieval 是否呈现可预测的缩放行为? (第 4.3 节)
- **RQ3:** 三个设计支柱分别对性能有何贡献? (第 4.4 节)
- **RQ4:** TransRetrieval 在真实部署中能否带来显著提升? (第 4.5 节)

4.1 实验方案

4.1.1 数据集。我们在来自两种不同推荐系统场景的两个多域数据集上开展实验: 展示广告和短视频推荐。

- **Industrial。**这是从阿里巴巴展示广告平台生产环境中采样的大规模工业数据集, 包含覆盖 52 M 个广告物品语料库的 40 十亿次交互。该数据集涵盖 4 个不同的业务域 (匿名记为域 A、B、C 和 D), 反映了多样的用户-物品交互模式。它包含丰富的用户行为历史、详细的物品属性以及实时上下文信号。
- **KuaiRand [6]。**这是来自快手 App 的公开序列推荐数据集, 包含 12 种用户反馈信号和全面的交互历史。遵循以往的检索工作 [21, 25], 我们使用频次阈值对数据集进行过滤: 用户至少有 1000 条点击记录, 物品至少有 100 条曝光记录。实验采用前 4 个域 (tab=0、1、2、3)。

表 1 给出了数据集统计信息。两个数据集均覆盖四个具有多样用户行为的域。在 Industrial 中, 域 C 汇集了多个用户行为模式异质的小型子域, 因而具有显著的内部分布差异。KuaiRand 包含一个极度稀疏的域 (Tab 3), 为数据稀缺条件下的泛化提供了颇具挑战性的测试平台。此外, 两个数据集的属性数量不同, 这导致了后续实验中观察到的计算成本差异。对于两个数据集, 我们都采用时间切分策略来确保不发生数据泄漏, 以模拟模型在历史数据上训练、并在未来交互上评估的真实部署场景。

4.1.2 评估指标。我们重点关注 Recall@2000 (空间有限时简称为 R@2000), 即出现在前 2000 个检索候选中的真正样本物品所占比例。

4.1.3 基线。我们纳入以下基线:

- **Production Baseline [12]。**在本工作之前服务于阿里巴巴展示广告平台的出价感知型模型检索系统: 这是一个经过高度优化的工业标准系统, 也是 TransRetrieval 在线 A/B 测试中所替代的系统。
- **KuaiFormer [13]。**一个简单的双塔检索基线, 使用 Transformer 编码用户侧, 并通过内积搜索为候选打分。
- **HSTU [23]。**将所有特征展平为单一行序列, 以实现 token 同质性, 同时舍弃结构化特征差异。
- **RankMixer [27]。**一种适配于检索的可扩展排序架构; 以无参数 token mixing 替代注意力, 并将计算集中在逐 token FFN 中。

为公平比较, 我们在同一框架内实现所有基线, 并共享相同的预处理流水线。每个基线均保留其原始的特征处理设计。

4.1.4 实现细节。所有实验均在 NVIDIA H20 GPU 集群上使用 PyTorch 和 RecIS [28] 完成。所有模型和两个数据集共享一组调优后的超参数: AdamW、学习率 1e-3、权重衰减 3e-5, 以及生产基线的成对学习排序 (LTR) 损失 [12, 26]。负采样比率因数据集而异: Industrial 中每个正样本对应 5 个负样本, KuaiRand 中对应 200 个, 以反映训练数据规模: 规模大得多的 Industrial (40 B vs. 152 M) 在较低比率下即可提供充足的负样本信号, 而 KuaiRand 则需要更高的比率来弥补正样本有限的问题。所有训练均运行至收敛, 并对最终检查点进行评估。

4.2 整体性能 (RQ1)

我们比较了两个数据集所有域上采用相近骨干配置时的整体检索性能。对于模型配置, 我们使用记号 $x\text{D}-y\text{L}$, 其中 x 表示嵌入维度, y 表示 Transformer 层数。表 2 给出了 TransRetrieval (128D-5L、64D-3L) 与 Production Baseline、HSTU (128D-5L)、KuaiFormer (128D-5L) 及 RankMixer (128D-8T, 其中 T 表示 token mixing 块数量) 的比较结果。MFLOPs 衡量目标侧每个候选的计算量 (每个目标的百万次 FLOPs)。

在相近的逐候选预算下, TransRetrieval-64D3L (0.45 MFLOPs') 已在所有域上超过经过高度优化的 Production Baseline (0.69 MFLOPs'), 以少 35% 的 FLOPs 达到 0.603 vs. 0.576 的 Overall Recall@2000。进一步扩展到 TransRetrieval-128D5L (1.91 MFLOPs') 后, 性能提升至 0.657, 比小型配置高 +5.4 pt, 表明额外计算可以可靠地转化为检索质量。与逐候选预算相近 (~1.7–2.1 MFLOPs') 的可扩展基线 HSTU 和 RankMixer 相比, TransRetrieval-128D5L 创造了新的最先进结果, 甚至 TransRetrieval-64D3L 也能以约四分之一的成本超过二者。KuaiFormer 以表达能力换取摊销成本; 第 4.3 节将考察其缩放行为。

4.3 缩放行为 (RQ2)

TransRetrieval 为检索模型实现了可预测的缩放。我们遍历嵌入维度 (32D、64D、128D) 和层数 (1L、3L、5L), 并在图 2 中绘制 Recall@2000 与逐目标 FLOPs 的关系。两个数据集都呈现清晰的线性缩放规律: 当骨干从 32D-1L 增长到 128D-5L 时, Industrial 上的 Recall@2000 从 0.464 提升至 0.657 (+19.3 pt), KuaiRand 上则从 0.251 提升至 0.473 (+22.2 pt); 较高的 R^2 (0.82/0.88) 证实这一趋势具有一致性和可预测性。

Table 1: 两个数据集的统计信息。#f_user 和 #f_target 分别表示用户侧和目标侧特征的数量；Len_seq 表示用户行为序列的长度。

数据集	# 域	# 用户	# 目标	# 交互	#f_user	#f_target	Len_seq	域分布 (%)			
								域 A/0	域 B/1	域 C/2	域 D/3
Industrial	4	250M	52M	40B	75	87	100	32%	20%	26%	22%
KuaiRand	4	24,943	536,491	152M	37	63	100	11.7%	84.8%	3.32%	0.13%

Table 2: 两个数据集各域上的整体检索性能 (Recall@2000)。Overall 为按照各域在评估交互中的占比加权得到的逐域 Recall。在各基线和 TransRetrieval-128D5L 中，最佳结果以粗体标示，次优结果以下划线标示。

方法	Industrial (Recall@2000)						KuaiRand (Recall@2000)					
	域 A	域 B	域 C	域 D	Overall	MFLOPs'	Tab 0	Tab 1	Tab 2	Tab 3	Overall	MFLOPs'
KuaiFormer-128D5L ¹	0.496	0.466	0.470	0.548	0.495	0.011	0.371	<u>0.415</u>	0.379	0.463	<u>0.409</u>	0.012
Production Baseline	<u>0.572</u>	<u>0.586</u>	<u>0.548</u>	0.608	<u>0.576</u>	0.69	0.401	0.378	0.299	0.500	0.378	0.64
HSTU-128D5L	0.518	0.490	0.474	<u>0.636</u>	0.527	1.72	0.315	0.394	0.312	0.611	0.382	1.72
RankMixer-128D8T	0.445	0.419	0.437	0.512	0.452	2.10	<u>0.406</u>	0.357	<u>0.384</u>	0.518	0.364	2.10
TransRetrieval-64D3L	0.593	0.590	0.575	0.663	0.603	0.45	0.460	0.413	0.413	0.481	0.419	0.42
TransRetrieval-128D5L	0.644	0.641	0.634	0.719	0.657	1.91	0.526	0.465	0.479	<u>0.537</u>	0.473	1.81


**Figure 2:** TransRetrieval 的缩放曲线。每个点对应一种 (D, N_layer) 配置；阴影区域表示对数线性拟合的 95% 置信区间。

表 3 给出了不同模型规模下的详细结果。最引人注目的是，我们的 128D-5L (1.91 MFLOPs') 在 Industrial 上以近两个数量级更少的计算量 (1.91 vs. 150.99 MFLOPs') 超过 RankMixer-768D-16T 12.6 pt。

KuaiFormer 呈现近乎平坦的缩放趋势(维度翻倍时为 0.485→0.495)，证实仅扩大编码器无法克服双塔内积瓶颈。

4.4 消融实验 (RQ3)

4.4.1 加权平均聚合的效果 我们在表 4 中将本文的加权平均聚合与其他特征融合策略进行比较，所有方法均采用相同的 64D-5L 配置。如表 4 所示，加权平均在每个域上都始终优于所有替代方案。普通加权求和表现落后 (0.608 vs. 0.618)，原

¹KuaiFormer 是双塔模型；这里我们将其 MFLOPs' 报告为用户编码成本在 HNSW 图遍历期间实际打分的 ~40k (Industrial) / ~28k (KuaiRand) 个候选上的摊销值。

Table 3: 所有方法在两个数据集不同配置下的缩放性能 (R@2000)。MFLOPs' 表示各数据集上的逐候选打分成本。

模型	配置	Industrial		KuaiRand	
		R@2000	MFLOPs'	R@2000	MFLOPs'
KuaiFormer ¹	64D5L	0.485	0.003	0.357	0.004
	128D5L	0.495	0.011	0.409	0.012
HSTU	32D1L	0.380	0.13	0.269	0.13
	64D2L	0.437	0.30	0.298	0.30
	128D3L	0.509	1.09	0.328	1.09
	128D5L	0.527	1.72	0.382	1.72
RankMixer	128D8T	0.452	2.10	0.364	2.10
	768D8T	0.468	75.50	0.420	75.50
	768D16T	0.531	150.99	0.453	150.99
TransRetrieval	32D1L	0.464	0.14	0.251	0.13
	64D3L	0.603	0.45	0.419	0.42
	128D5L	0.657	1.91	0.473	1.81

Table 4: 不同特征聚合策略的 Recall@2000。加权平均取得最佳性能。

方法	域 A	域 B	域 C	域 D	Overall
加权平均 (本文方法)	0.610	0.598	0.589	0.681	0.618
加权求和	0.600	0.594	0.572	0.674	0.608
LN + 加权求和	0.582	0.575	0.568	0.656	0.593
最大池化	0.563	0.554	0.533	0.644	0.571

因是特征数量增加时其范数会无界增长。在加权求和后加入 LayerNorm (LN + Weighted Sum) 同样会显著损害性能 (0.593 vs. 0.618)，因为其中心化和重新缩放会抹去 Transformer 用来区分异质字段的逐字段幅度信号。最大池化的性能下降最为严重 (0.571 vs. 0.618)，因为其极值选择丢弃了大部分特征信息。

Table 5: 目标 token 压缩对检索性能和计算成本的影响。

配置	# Token	R@2000	MFLOPs
64D-3L	8 tokens	0.624	3.04
64D-3L	4 tokens	0.615	1.55
64D-3L	1 token	0.603	0.45
128D-5L	1 token	0.657	1.91

Table 6: 多域建模策略的消融实验(Industrial, 各域 R@2000)。由于各变体的目标侧处理相同, 此处 FLOPs 仅计算用户侧。

方法	A	B	C	D	整体	MFLOPs
单域训练 (仅使用特定域数据)						
单域数据	0.591	0.539	0.537	0.647	0.579	41.3
统一训练 (合并所有域的数据)						
0 个域 Token	0.254	0.276	0.251	0.289	0.265	41.3
1 个域 Token	0.321	0.349	0.339	0.345	0.337	41.8
20 个域 Token	0.431	0.451	0.460	0.473	0.452	49.8
TransRetrieval (本文方法)	0.593	0.590	0.575	0.663	0.603	41.3

Table 7: TransRetrieval 的在线 A/B 测试结果。

	各域提升				整体		
	A	B	C	D	提升幅度	95% 置信区间	p 值
收入	1.72%	2.51%	5.39%	0.87%	2.53%	[2.22%, 2.70%]	< 0.0001
RPM	1.22%	2.18%	3.69%	0.43%	1.28%	[1.14%, 1.56%]	< 0.0001

4.4.2 目标 Token 压缩的效果. 表 5 给出了 64D-3L 和 128D-5L 配置下的结果。在 64D-3L 内, 将 8 个 token 压缩为 1 个, 可使 MFLOPs 降低 ~85% (3.04 → 0.45), 而 Recall 仅下降 2.1 pt (0.624 → 0.603); 当每个检索到的候选都必须由模型打分时, 这是一项有利的权衡。将释放的预算重新投入到带有单 token 压缩的 128D-5L 骨干后, 可以得到严格更优的工作点: 其成本低于使用 8 个 token 的 64D-3L (1.91 vs. 3.04 MFLOPs), 同时 Recall 更高 (0.657 vs. 0.624), 证实“先压缩、再扩展”优于“更多 token 搭配更小骨干”。

4.4.3 多域建模的效果. 在延迟约束下, 有效的多域建模需要捕获域上下文。表 6 使用 64D-3L 配置评估不同策略, 并报告用户侧 FLOPs, 以明确量化序列扩展所引入的开销。结果表明, 仅混合多域数据而不提供任何域信号 (0 个域 Token) 会导致性能严重下降。添加单个域 Token (1 个域 Token) 只能带来有限改善, 却会引入额外计算。将域 Token 重复 20 次 (20 个域 Token) 可进一步增强域信号并提升性能, 但计算成本显著增大 (49.8 MFLOPs), 这对于大规模部署而言难以承受。我们提出的方法将域信息作为位置式嵌入注入, 在保持与 0 个域 Token 基线完全相同的推理成本的同时, 取得了最佳整体性能 (0.603 Recall@2000)。此外, 单域数据这一行进一步验证了我们的多域策略: 仅在单个域的数据上训练得到的 Recall 明显低于统一模型, 证实跨域数据共享能够带来净收益。

4.5 在线 A/B 测试结果 (RQ4)

我们在阿里巴巴展示广告系统的 5% 生产流量上开展了为期一个月的在线 A/B 测试, 其中唯一改变的变量是召回模型。

TransRetrieval-128D5L 以 230 QPS 提供服务, P99 延迟低于 40 ms, 与生产基线完全相同, 因此性能增益未增加端到端延迟。较低的单引擎 QPS (230 vs. 300) 源于更高的单目标计算成本 (1.91 vs. 0.69 MFLOPs), 并通过水平扩展予以消化。

如表 7 所示, 相较于高度优化的生产基线, TransRetrieval 使平台收入显著提升 2.53%, 千次展示收入提升 1.28%。在整个月内, 每日增益保持稳定, 未出现系统性衰减。在实现这些经济收益的同时, 生态系统仍保持健康: 用户体验指标保持稳定, 广告主的投资回报率 (ROI) 也维持在相当水平 (+0.06%)。

5 讨论与结论

经验总结. (i) 先进行输入调节, 再重新设计架构: 扩展性突破并非来自架构创新, 而是来自一种无参数的一行式修正 (加权平均), 它恢复了 Token 范数的同质性。(ii) 压缩是资源重分配, 而非性能牺牲: 将 8 个目标 Token 压缩为 1 个可释放 85% 的 FLOPs, 将其重新投入深度/宽度扩展 (64D-3L→128D-5L), 能够在更低总成本下将 Recall 提升 +3.3 pt。(iii) 域统一是一项扩展性资产: 除了避免成本随域数量成倍增长外, 位置式域嵌入还使稀疏域能够受益于跨域迁移, 而非因隔离而缺乏数据。

结论. 这三项设计共同释放了召回阶段的扩展定律: 在包含 400 亿次交互的工业数据集和公开 KuaiRand 基准上, TransRetrieval 展现出对数线性扩展 ($R^2=0.82/0.88$)、最先进的召回率, 并在为期一个月的在线 A/B 测试中使平台收入提升 2.53%。

Acknowledgments

本研究得到国家自然科学基金 (编号 62472428)、中国人民大学公共计算云、中国人民大学世界一流大学 (学科) 建设经费、阿里巴巴集团创新研究计划以及中国人民大学求是学术项目 (RUC25QSDL123) 的支持。我们衷心感谢 Cheng Chen、Fei Wang、Houyuan Xiang、Huimin Yi、Jianan Chen、Jiawen Liao、Junchen Dong、Mingjie Liu、Rui Wang、Wei He、Wenchao Wang、Xingyu Wen、Yan Jiang、Yan Zhang、Yunlong Xu、Zhengxiong Zhou、Zhengyu Liu、Zhensong Yan 和 Zhenyuan Lai 对数据、训练与推理基础设施关键组件的实现所作出的贡献。

生成式 AI 使用披露

在本稿件的撰写过程中，作者使用生成式 AI 工具进行文本润色和语言编辑。作者审阅并编辑了所有由 AI 生成的建议，并对本出版物的内容承担全部责任。

参考文献

- [1] Lei Jimmy Ba, Jamie Ryan Kiros, and Geoffrey E. Hinton. 2016. Layer Normalization. CoRR abs/1607.06450 (2016). arXiv:1607.06450 <http://arxiv.org/abs/1607.06450>
- [2] Fedor Borisov, Qingquan Song, Mingzhou Zhou, Ganesh Parameswaran, Madhu Arun, Siva Popuri, Tugrul Bingol, Zhuotao Pei, Kuang-Hsuan Lee, Lu Zheng, Qizhan Shao, Ali Naqvi, Sen Zhou, and Aman Gupta. 2024. LiNR: Model Based Neural Retrieval on GPUs at LinkedIn. In *Proceedings of the 33rd ACM International Conference on Information and Knowledge Management, CIKM 2024, Boise, ID, USA, October 21–25, 2024*, Edoardo Serra and Francesca Spezzano (Eds.). ACM, 4366–4373. doi:10.1145/3627673.3680091
- [3] Rihan Chen, Bin Liu, Han Zhu, Xiaoxuan Wang, Qi Li, Buting Ma, Qingbo Hua, Jun Jiang, Yunlong Xu, Hongbo Deng, and Bo Zheng. 2022. Approximate Nearest Neighbor Search under Neural Similarity Metric for Large-Scale Recommendation. In *Proceedings of the 31st ACM International Conference on Information & Knowledge Management, Atlanta, GA, USA, October 17–21, 2022*, Mohammad Al Hasan and Li Xiong (Eds.). ACM, 3013–3022. doi:10.1145/3511808.3557098
- [4] Paul Covington, Jay Adams, and Emre Sargin. 2016. Deep Neural Networks for YouTube Recommendations. In *Proceedings of the 10th ACM Conference on Recommender Systems, Boston, MA, USA, September 15–19, 2016*, Shilad Sen, Werner Geyer, Jill Freyne, and Pablo Castells (Eds.). ACM, 191–198. doi:10.1145/2959100.2959190
- [5] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xi-aohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. 2020. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. CoRR abs/2010.11929 (2020). arXiv:2010.11929 <https://arxiv.org/abs/2010.11929>
- [6] Chongming Gao, Shijun Li, Yuan Zhang, Jiawei Chen, Biao Li, Wenqiang Lei, Peng Jiang, and Xiangnan He. 2022. KuaiRand: An Unbiased Sequential Recommendation Dataset with Randomly Exposed Videos. In *Proceedings of the 31st ACM International Conference on Information & Knowledge Management, Atlanta, GA, USA, October 17–21, 2022*, Mohammad Al Hasan and Li Xiong (Eds.). ACM, 3953–3957. doi:10.1145/3511808.3557624
- [7] Ruidong Han, Bin Yin, Shangyu Chen, He Jiang, Fei Jiang, Xiang Li, Chi Ma, Mincong Huang, Xiaoguang Li, Chunzhen Jing, Yueming Han, MengLei Zhou, Lei Yu, Chuan Liu, and Wei Lin. 2025. MTGR: Industrial-Scale Generative Recommendation Framework in Meituan. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management, CIKM 2025, Seoul, Republic of Korea, November 10–14, 2025*, Meeyoung Cha, Chanyoung Park, Noseong Park, Carl Yang, Senjuti Basu Roy, Jessie Li, Jaap Kamps, Kijung Shin, Bryan Hooi, and Lifang He (Eds.). ACM, 5731–5738. doi:10.1145/3746252.3761565
- [8] Jordan Hoffmann, Sebastian Borgeaud, Arthur Mensch, Elena Buchatskaya, Trevor Cai, Eliza Rutherford, Diego de Las Casas, Lisa Anne Hendricks, Johannes Welbl, Aidan Clark, Tom Hennigan, Eric Noland, Katie Millican, George van den Driessche, Bogdan Damoc, Aurelia Guy, Simon Osindero, Karen Simonyan, Erich Elsen, Jack W. Rae, Oriol Vinyals, and Laurent Sifre. 2022. Training Compute-Optimal Large Language Models. CoRR abs/2203.15556 (2022). arXiv:2203.15556 doi:10.48550/ARXIV.2203.15556
- [9] Junjie Huang, Jizheng Chen, Jianghao Lin, Jiarui Qin, Ziming Feng, Weinan Zhang, and Yong Yu. 2024. A Comprehensive Survey on Retrieval Methods in Recommender Systems. CoRR abs/2407.21022 (2024). arXiv:2407.21022 doi:10.48550/ARXIV.2407.21022
- [10] Yuchen Jiang, Qi Li, Han Zhu, Jinbei Yu, Jin Li, Ziru Xu, Huihui Dong, and Bo Zheng. 2022. Adaptive Domain Interest Network for Multi-domain Recommendation. In *Proceedings of the 31st ACM International Conference on Information & Knowledge Management, Atlanta, GA, USA, October 17–21, 2022*, Mohammad Al Hasan and Li Xiong (Eds.). ACM, 3212–3221. doi:10.1145/3511808.3557137
- [11] Wang-Cheng Kang and Julian J. McAuley. 2018. Self-Attentive Sequential Recommendation. In *IEEE International Conference on Data Mining, ICDM 2018, Singapore, November 17–20, 2018*. IEEE Computer Society, 197–206. doi:10.1109/ICDM.2018.00035
- [12] Bin Liu, Yunfei Liu, Ziru Xu, Zhi Kou, Yeqiu Yang, Han Zhu, and Jian Xu. 2026. Bidding-Aware Retrieval for Multi-Stage Consistency in Online Advertising. In *Proceedings of the 35th ACM International Conference on Information and Knowledge Management (CIKM '26)*. ACM, New York, NY, USA. doi:10.1145/3799682.3840091
- [13] Chi Liu, Jiangxia Cao, Rui Huang, Kai Zheng, Qiang Luo, Kun Gai, and Guorui Zhou. 2024. KuaiFormer: Transformer-Based Retrieval at Kuaishou. CoRR abs/2411.10057 (2024). arXiv:2411.10057 doi:10.48550/ARXIV.2411.10057
- [14] Xiao Lv, Jiangxia Cao, Shijie Guan, Xiaoyou Zhou, Zhiguang Qi, Yaqiang Zang, Ben Wang, and Guorui Zhou. 2025. MARM: Unlocking the Recommendation Cache Scaling-Law through Memory Augmentation and Scalable Complexity. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management, CIKM 2025, Seoul, Republic of Korea, November 10–14, 2025*, Meeyoung Cha, Chanyoung Park, Noseong Park, Carl Yang, Senjuti Basu Roy, Jessie Li, Jaap Kamps, Kijung Shin, Bryan Hooi, and Lifang He (Eds.). ACM, 2022–2031. doi:10.1145/3746252.3761015
- [15] Jiaqi Ma, Zhe Zhao, Xinyang Yi, Jilin Chen, Lichan Hong, and Ed H. Chi. 2018. Modeling Task Relationships in Multi-task Learning with Multi-gate Mixture-of-Experts. In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, KDD 2018, London, UK, August 19–23, 2018*, Yike Guo and Faisal Farooq (Eds.). ACM, 1930–1939. doi:10.1145/3219819.3220007
- [16] Yury A. Malkov and Dmitry A. Yashunin. 2020. Efficient and Robust Approximate Nearest Neighbor Search Using Hierarchical Navigable Small World Graphs. *IEEE Trans. Pattern Anal. Mach. Intell.* 42, 4 (2020), 824–836. doi:10.1109/TPAMI.2018.2889473
- [17] Xiang-Rong Sheng, Liqin Zhao, Guorui Zhou, Xinyao Ding, Binding Dai, Qiang Luo, Siran Yang, Jingshan Lv, Chi Zhang, Hongbo Deng, and Xiaoqiang Zhu. 2021. One Model to Serve All: Star Topology Adaptive Recommender for Multi-Domain CTR Prediction. In *CIKM '21: The 30th ACM International Conference on Information and Knowledge Management, Virtual Event, Queensland, Australia, November 1–5, 2021*, Gianluca Demartini, Guido Zuccon, J. Shane Culpepper, Zi Huang, and Hanghang Tong (Eds.). ACM, 4104–4113. doi:10.1145/3459637.3481941
- [18] Fei Sun, Jun Liu, Jian Wu, Changhua Pei, Xiao Lin, Wenwu Ou, and Peng Jiang. 2019. BERT4Rec: Sequential Recommendation with Bidirectional Encoder Representations from Transformer. In *Proceedings of the 28th ACM International Conference on Information and Knowledge Management, CIKM 2019, Beijing, China, November 3–7, 2019*, Wenwu Zhu, Dacheng Tao, Xueqi Cheng, Peng Cui, Elke A. Rundensteiner, David Carmel, Qi He, and Jeffrey Xu Yu (Eds.). ACM, 1441–1450. doi:10.1145/3357384.3357895
- [19] Hongyan Tang, Junling Liu, Ming Zhao, and Xudong Gong. 2020. Progressive Layered Extraction (PLE): A Novel Multi-Task Learning (MTL) Model for Personalized Recommendations. In *RecSys 2020: Fourteenth ACM Conference on Recommender Systems, Virtual Event, Brazil, September 22–26, 2020*, Rodrygo L. T. Santos, Leandro Balby Marinho, Elizabeth M. Daly, Li Chen, Kim Falk, Noam Koenigstein, and Edleno Silva de Moura (Eds.). ACM, 269–278. doi:10.1145/3383313.3412236
- [20] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is All you Need. In *Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems 2017, December 4–9, 2017, Long Beach, CA, USA*, Isabelle Guyon, Ulrike von Luxburg, Samy Bengio, Hanna M. Wallach, Rob Fergus, S. V. N. Vishwanathan, and Roman Garnett (Eds.). 5998–6008. <https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>
- [21] Yihan Wang, Fei Xiong, Zhexin Han, Qi Song, Kaiqiao Zhan, and Ben Wang. 2025. Unleashing the Potential of Two-Tower Models: Diffusion-Based Cross-Interaction for Large-Scale Matching. In *Proceedings of the ACM on Web Conference 2025, WWW 2025, Sydney, NSW, Australia, 28 April 2025– 2 May 2025*, Guodong Long, Michale Blumstein, Yi Chang, Liane Lewin-Eytan, Zi Helen Huang, and Elad Yom-Tov (Eds.). ACM, 304–312. doi:10.1145/3696410.3714829
- [22] Songpei Xu, Shijia Wang, Da Guo, Xianwen Guo, Qiang Xiao, Bin Huang, Guanlin Wu, and Chuanjiang Luo. 2025. Climber: Toward Efficient Scaling Laws for Large Recommendation Models. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management, CIKM 2025, Seoul, Republic of Korea, November 10–14, 2025*, Meeyoung Cha, Chanyoung Park, Noseong Park, Carl Yang, Senjuti Basu Roy, Jessie Li, Jaap Kamps, Kijung Shin, Bryan Hooi, and Lifang He (Eds.). ACM, 6193–6200. doi:10.1145/3746252.3761561
- [23] Jiaqi Zhai, Lucy Liao, Xing Liu, Yueming Wang, Rui Li, Xuan Cao, Leon Gao, Zhaojie Gong, Fangda Gu, Jiayuan He, Yinghai Lu, and Yu Shi. 2024. Actions Speak Louder than Words: Trillion-Parameter Sequential Transducers for Generative Recommendations. In *Forty-first International Conference on Machine Learning, ICML 2024, Vienna, Austria, July 21–27, 2024*. OpenReview.net. <https://openreview.net/forum?id=xye7iNsgXn>
- [24] Buyun Zhang, Liang Luo, Yuxin Chen, Jade Nie, Xi Liu, Shen Li, Yanli Zhao, Yuchen Hao, Yantao Yao, Ellie Dingqiao Wen, Jongsoo Park, Maxim Naumov, and Wenlin Chen. 2024. Wukong: Towards a Scaling Law for Large-Scale Recommendation. In *Forty-first International Conference on Machine Learning, ICML 2024, Vienna, Austria, July 21–27, 2024*. OpenReview.net. <https://openreview.net/forum?id=8iUgr2nuwo>
- [25] Yuan Zhang, Xue Dong, Weijie Ding, Biao Li, Peng Jiang, and Kun Gai. 2023. Divide and Conquer: Towards Better Embedding-based Retrieval for Recommender Systems from a Multi-task Perspective. In *Companion Proceedings of the ACM Web Conference 2023, WWW 2023, Austin, TX, USA, 30 April 2023 – 4 May 2023*, Ying Ding, Jie Tang, Juan F. Sequeda, Lora Aroyo, Carlos Castillo, and

- Geert-Jan Houben (Eds.). ACM, 366–370. doi:10.1145/3543873.3584629
- [26] Zhishan Zhao, Jingyue Gao, Yu Zhang, Shuguang Han, Siyuan Lou, Xiang-Rong Sheng, Zhe Wang, Han Zhu, Yuning Jiang, Jian Xu, and Bo Zheng. 2023. COPR: Consistency-Oriented Pre-Ranking for Online Advertising. *Proceedings of the 32nd ACM International Conference on Information and Knowledge Management* (Oct. 2023), 4974–4980. doi:10.1145/3583780.3615465
- [27] Jie Zhu, Zhifang Fan, Xiaoxie Zhu, Yuchen Jiang, Hangyu Wang, Xintian Han, Haoran Ding, Xinmin Wang, Wenlin Zhao, Zhen Gong, Huizhi Yang, Zheng Chai, Zhe Chen, Yuchao Zheng, Qiwei Chen, Feng Zhang, Xun Zhou, Peng Xu, Xiao Yang, Di Wu, and Zuotao Liu. 2025. RankMixer: Scaling Up Ranking Models in Industrial Recommenders. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management, CIKM 2025, Seoul, Republic of Korea, November 10–14, 2025*, Meeyoung Cha, Chanyoung Park, Noseong Park, Carl Yang, Senjuti Basu Roy, Jessie Li, Jaap Kamps, Kijung Shin, Bryan Hooi, and Lifang He (Eds.). ACM, 6309–6316. doi:10.1145/3746252.3761507
- [28] Hua Zong, Qingtao Zeng, Zhengxiong Zhou, Zhihua Han, Zhensong Yan, Mingjie Liu, Hechen Sun, Jiawei Liu, Yiwen Hu, Qi Wang, et al. 2025. RecIS: Sparse to Dense, A Unified Training Framework for Recommendation Models. *arXiv preprint arXiv:2509.20883* (2025).