

告别物品 ID：通过语义 Token 释放大规模排序模型的扩展潜力

Zhen Zhao*, Tong Zhang*, Jie Xu, Qingliang Cai, Qile Zhang, Leyuan Yang,
Daorui Xiao†, Xiaojia Chang

ByteDance

{zhaozhen.0718, zhangtong.z, xiaodaorui}@bytedance.com

摘要

近期关于扩大排序模型规模的研究已为推荐系统和搜索引擎带来显著提升。然而，大多数大规模排序系统依赖物品 ID，将每个物品视为独立的类别符号并映射为学习得到的嵌入。随着物品快速出现和消失，这些嵌入变得难以训练和维护。这种不稳定性阻碍了神经网络参数的有效学习，并限制了排序模型的可扩展性。本文表明，与物品 ID 相比，语义 token 具有更大的规模扩展潜力。我们提出的框架 TRM 改进了 token 的生成与应用流程，在稀疏存储减少 33% 的同时，实现了 0.85% 的 AUC 提升。大量实验进一步表明，随着模型容量扩大，TRM 能够持续优于最先进的模型。最后，TRM 已成功部署于大规模个性化搜索引擎；A/B 测试显示，用户活跃天数和改搜率分别提升 0.26% 和 0.75%。

1. 引言

大规模排序模型 (Large Ranking Models, LRMs) 是现代推荐系统 (Zhang et al., 2024a; Zhu et al., 2025; Zhang et al., 2022) 和搜索引擎 (Chen et al., 2025; Zhou et al., 2024) 的支柱，在高效的信息分发中发挥着关键作用。

近年来，扩大 LRM 的模型参数规模已成为构建排序模型的一种颇具前景的方法 (Zhu et al., 2025; Zhang et al., 2022; 2024b; Zivic et al., 2024)。受 LLM 中扩展定律成功经验的启发 (Kaplan et al., 2020)，近期工作致力于构建最完备的模型架构，以扩展稠密参数规模 (Zhang et al., 2022; Zhu et al., 2025)。然而，物品 ID 类别特征的动态性和不稳定性妨碍了高效的知识共享：新引入的 ID 往往面临冷启动问题，而已退役的旧 ID 则会丢弃此前学到的全部知识 (Zhu et al., 2021)。因此，基于 ID 的特征分布快速而剧烈的变化阻碍了稠密参数的学习，在大规模排序系统中尤为如此 (Zheng




图 1. 物品 ID 和语义 token 对排序模型规模扩展产生不同影响的示意图。随着参数规模扩大，语义 token 呈现出更稳定的分布。

et al., 2025a)。由此，扩大稠密参数规模的有效性和能力受到削弱。

相较之下，我们提出用语义 token 替代物品 ID，以实现稠密参数的规模扩展 (Rajput et al., 2023; Zheng et al., 2025b)。我们的一个关键观察是，语义 token 构成了一个结构化的闭合集，其分布在训练过程中相对更加稳定、平滑。如图 1 所示，我们使用范数方差 (Chen et al., 2024) 来衡量 ID 嵌入与 token 嵌入的分布变化。可以清楚地看到，随着参数规模扩大，语义 token 在训练过程中具有更稳定的分布。在第 A.1 节中，我们基于 1) 著名的扩展定律 (Kaplan et al., 2020) $L \propto N^{-\beta}$ ，以及 2) 扩展定律的功效分析 (Siegel & Xu, 2023)，对语义 token 与规模扩展性能之间的联系进行了理论分析。

与最初预期相反，实验表明，在现有排序模型中直接使用当前的语义 token 替换物品 ID 会立即导致性能下降，尽管这种退化会随稠密参数增加而减弱。我们对此现象给出三点基本认识。首先，当前语义 token 通常利用多模态信息（物品的图像、文本、etc）进行残差聚类，却忽略了用户行为域；后者包含与视觉、语言和音频域根本不同的结构信息。其次，我们的实验表明，由于采用粗粒度聚类，现有语义 token 以牺牲记忆能

*: 同等贡献。†: 通讯作者。

力为代价换取了更好的泛化性能。因此，排序模型无法捕获细粒度的组合知识，导致对频繁出现的旧物品性能下降。第三，现有方法直接组合物品的语义 token 作为输入特征，忽略了 token 序列内部的结构信息。

为解决上述问题，我们提出了一种新颖的基于 token 的排序模型规模扩展框架，称为 TRM (Token-based Recommendation Model)。具体而言，我们设计了一种协同过滤方法，将用户行为信息融入原始视觉—语言嵌入模型，使语义 token 能够同时在多模态域和个性化域中聚类。为解决记忆问题，我们提出独立学习每个物品的组合知识，从而更好地平衡语义 token 的泛化与记忆能力。最后，我们开发了一种联合优化判别目标和生成目标的新型训练框架。该框架不仅利用判别式预测的准确性，还挖掘 token 序列内部的结构信息。

在实验中，我们在一个依赖大规模排序模型提供在线服务的个性化搜索引擎中评估了 TRM。将 TRM 应用于 RankMixer 等最先进的排序模型后，我们的方法展现出显著的性能提升和资源节省。在真实用户日志上进行的离线实验表明，AUC 提升了 0.65%，稀疏存储减少了 33%。此外，通过扩大排序模型的稠密部分，TRM 持续优于基于 ID 的模型和其他基于 token 的模型，相对 QAUC 增益由 0.54% 逐步提高至 0.85%。

我们的主要贡献可概括如下：

- 我们从理论和实验两方面进行分析，证明了基于 token 的模型相较于基于 ID 的模型具有更优的规模扩展性能。
- 我们开发了基于 token 的规模扩展框架 TRM，有效解决了传统语义 token 中用户行为未对齐、记忆能力受损以及结构信息缺失的问题，从而获得更优的规模扩展性能。
- TRM 已成功部署于大规模搜索引擎，实现稀疏存储减少 33%、用户活跃天数增加 0.26%，以及改搜率降低 0.75%。

2. 相关工作

基于 ID 的大规模排序模型与嵌入瓶颈。 传统的大规模排序模型主要由稀疏类别特征（例如物品 ID）主导，其中每个物品都映射到大型表中的一个可学习嵌入，DLRM 风格的架构便是典型代表 (Naumov et al., 2019; Zhou et al., 2018; Chang et al., 2021; Zhang et al., 2025; Huang et al., 2026)。在这种范式下，新 ID 持续出现，而旧 ID 不断退役。这种特征漂移问题使长期知识积累复杂化，也使通过扩大嵌入表进行朴素的规模扩展变得低效 (Coleman et al., 2023)。

语义 ID 与离散物品 token 化。 为缓解原始 ID 或哈希 ID 的不稳定性与泛化能力不足，越来越多的研究开始探索语义 ID：通过向量量化从内容嵌入中得到的紧凑离散编码。Singh et al. (2023) 表明，语义 ID 能

够提升工业级排序模型对新物品和长尾物品的泛化能力，并提出子片段 token 化（包括 SentencePiece 风格的分词）以促进适应 (Kudo & Richardson, 2018)。在广告排序中，Zhao et al. (2023) 进一步分析了 ID 漂移和嵌入不稳定性，Zheng et al. (2025b) 则提出基于前缀的参数化方法，以产生具有语义意义的碰撞。近期的一篇综合性综述 (Huang et al., 2024) 将推荐系统中的 VQ 方法划分为面向效率和面向质量两类，并强调了它们在衔接内容信号与协同信号方面的作用。

排序模型的扩展定律。 一项广泛的实证研究考察了多种大型推荐骨干网络中的扩展现象 (Guo et al., 2024)，而 Yan et al. (2025) 则提供了一条在生产环境中释放规模扩展特性的实用路径。近期工作开始揭示排序与推荐模型中的类似规律 (Zhang et al., 2024b; Ardalani et al., 2022)。Fang et al. (2024) 在使用连续替代指标评估稠密检索时给出了幂律扩展的证据，为计算量与数据量的权衡分析奠定了基础。在工业规模上，生成式推荐模型进一步验证了这些趋势：OneRec 报告称，随着训练 FLOPs 大幅增加，性能持续提升 (Deng et al., 2025; Zhou et al., 2025)；OneSearch 则探索了使用量化物品编码的电商搜索统一端到端生成方案 (Chen et al., 2025)。

3. 方法

我们提出了一个统一的基于 token 化的排序框架。该框架将物品建模、表示离散化和排序优化重构为一条统一流水线。如图 2 所示，首先，我们联合利用多模态内容信号和大规模用户交互数据，学习稠密的物品表示。由此产生的协同过滤感知嵌入能够同时捕获语义属性和行为相关性。其次，我们采用混合 token 化策略，从这些嵌入中构造结构化语义 token。该策略将粗粒度层次聚类与细粒度子词组合相结合，在泛化与记忆之间取得平衡。最后，我们重新设计排序模型，使其完全基于语义 token 而非物品 ID 运行。该模型将判别式排序目标与辅助生成式建模相结合，以更好地捕获层次化 token 依赖关系和用户—物品交互。

3.1. 协同感知的多模态物品表示

为学习既具有语义基础又与行为对齐的物品表示，我们采用两阶段表示对齐策略。第一阶段引入短视频的域内知识，第二阶段则利用来自用户行为的协同信号对表示进行对齐。在第一阶段，我们执行域内多模态描述生成，使模型适应搜索系统的短视频领域。每个物品由视觉输入及文本元数据共同表示，例如标题、ASR（语音转文本）、OCR（图像转文本）和描述。这些输入被送入多模态大语言模型 (MLLM)，并以自回归方式训练该模型生成视频描述。训练数据从真实曝光日志中自行收集，反映了搜索系统中短视频的视觉风格、内容多样性和语义密度。该阶段向模型注入特定领域知识，并提升其在目标场景中联合理解视觉与文本信息的能力。我们使用标准的下一 token 预测损失，在




图 2. TRM 框架。

描述 token 上优化 MLLM:

$$\mathcal{L}_{\text{cap}} = -\mathbb{E}_{(V,T)} \sum_{k=1}^{|T|} \log P(t_k | t_{<k}, V; \theta), \quad (1)$$

其中, V 表示视觉输入, $T = t_1, \dots, t_{|T|}$ 为目标描述, θ 表示模型参数。

在第二阶段, 我们通过显式地将嵌入与协同信号对齐, 使 MLLM 适用于表示学习。对于每个输入样本, 我们从 MLLM 的最后一层提取 token 表示, 并应用平均池化以获得单个稠密表示:

$$\mathbf{h} = \frac{1}{N} \sum_{i=1}^N \mathbf{z}_i, \quad (2)$$

其中, $\{\mathbf{z}_i\}_{i=1}^N$ 是最后一层的 token 嵌入。为使多模态表示与用户行为对齐, 我们从交互日志中构造两类训练对。第一类是根据用户正向反馈得到的查询—物品对。第二类是因频繁共同点击而具有较高协同相似度的物品—物品对。我们对两类样本对均采用对比学习, 使协同相似的查询与物品的表示相互对齐, 同时分离无关样本。对比对齐损失定义为:

$$\mathcal{L}_{\text{align}} = -\mathbb{E}_{(a,b) \in \mathcal{P}} \log \frac{\exp(\text{sim}(\mathbf{h}_a, \mathbf{h}_b)/\tau)}{\sum_{b' \in \mathcal{B}} \exp(\text{sim}(\mathbf{h}_a, \mathbf{h}_{b'})/\tau)}, \quad (3)$$

其中, (a, b) 表示正查询—物品对或物品—物品对, $\mathcal{B}$ 是批内样本集合, τ 是温度超参数, $\text{sim}(\cdot, \cdot)$ 表示余弦相似度。协同感知表示学习的最终训练目标为:

$$\mathcal{L}_{\text{rep}} = \mathcal{L}_{\text{cap}} + \lambda_{\text{align}} \mathcal{L}_{\text{align}}, \quad (4)$$

其中, λ 控制协同对齐的强度。通过这一两阶段优化, 学习到的表示同时编码域内多模态语义和协同结构, 为语义 token 化奠定了稳健基础。

3.2. 兼顾泛化—记忆权衡的混合 token 化

给定协同感知的物品表示后, 我们使用 RQ-Kmeans(Chen et al., 2025) 进行残差量化, 以获得离散语义 token。这些 token 保留了物品之间共享的语义结构, 并展现出较强的泛化能力。如图 3 所示, 用这类语义 token 替换物品 ID 能够提升对新出现物品或低曝光物品的排序性能。

然而, 我们的实验结果表明, OneRec(Deng et al., 2025)、Tiger(Rajput et al., 2023) 和 Semid(Zheng et al., 2025b) 等一系列基于 token 的模型所采用的基于 RQ-Kmeans/RQ-VAE 的 token 化方法, 在整体排序性能上无法优于基于 ID 的基线。图 3 表明, 随着物品曝光频率增加, 模型性能持续下降; 随着物品变旧, 甚至会产生负面影响。这说明在大规模推荐场景中, 语义 token 无法保留物品特有的知识。因此, 基于 token 的模型在实际部署中通常需要额外的基于 ID




图 3. 用不同类型的语义 token 替换物品 ID 后，相对于 ID 基线的 AUC 增益。我们按照查询请求发生时的物品生命周期分组报告结果。

的奖励系统 (Deng et al., 2025; Chen et al., 2025)。

我们发现，这一现象的根本原因在于残差量化以粗粒度方式执行聚类，导致物品描述存在语义缺失。从本质上说，残差量化将物品投影为 token 序列 $s = [s_1, s_2, \dots, s_n]$ ，其中每个 token s_i 都可以表示某种特定语义。然而，对这些语义进行简单聚合（求和、拼接、etc）并不能替代语义之间的组合。例如，假设有两个 token 分别指向“蛋糕”和“蜡烛”的语义，它们的组合可能暗含“生日”的含义，但“蛋糕”或“蜡烛”这两个语义 token 中的任何一个都无法有效学习这种含义。因此，语义 token 无法学习特定物品的组合知识，从而导致推荐中的记忆能力不足。

为解决这一问题，我们提出分配独立的可学习 token，以学习语义 token 的组合知识。如图 2 所示，我们选取高频 token 组合（即，高频 k-gram）来生成新的 token ID，用于保留细粒度的组合式物品知识。鉴于语义 token 序列中的结构化信息，我们将每个 token 视为描述对应物品的子词，并使用字节对编码 (BPE) (Sennrich et al., 2016) 算法寻找最具代表性的子词组合。

我们将原始语义 token 称为用于粗粒度知识共享的“泛化 token”(gen-token)，将 BPE 生成的组合 token 称为用于保留细粒度组合知识的“记忆 token”(mem-token)。在实践中，gen-token 和 mem-token 在哈希系统下分别经过不同的嵌入模块，生成的嵌入作为模型输入。为进一步平衡泛化与记忆，我们采用 Wide&Deep 网络 (Cheng et al., 2016) 生成混合 token，其中深侧输入为 gen-token，宽侧输入为 mem-token。我们还在深侧应用随机 dropout 以避免过拟合。如图 3 所示，混合 token 提升了模型保留细粒度知识的能力，因此随着曝光频次增加，相较于物品 ID 始终表现出更好的性能。

3.3. 判别式目标与生成式目标的联合优化

以往工作通常将语义 token 用于判别式预测 (Singh et al., 2023) 或生成式检索 (Deng et al., 2025)。尽管

两种范式在大规模推荐系统中均表现良好，但它们未能充分挖掘语义 token 的潜力。具体而言，判别式目标以相同方式处理每个语义 token s_i ，忽略了语义 token 序列的结构信息。而生成式目标在整合用户目标方面存在局限，且通常需要判别式模型充当辅助奖励模型 (Deng et al., 2025; Chen et al., 2025)。为充分挖掘语义 token 的潜力，我们提出直接联合优化判别式目标与生成式目标。如图 2 所示，在我们的搜索系统中，个性化排序模型的输入集合由三部分组成：(1) 查询特征 X_Q ；(2) 物品特征 X_I ，包括多模态信息和我们的混合 token；(3) 用户特征 X_U ，包括用户交互历史。对于判别式目标，使用 X_Q 、 X_I 和 X_U 的全部信息来预测用户对实际物品 X_U 的行为（点击率、点赞、有效播放、等）。我们使用 BCE 损失优化判别式目标：

$$\mathcal{L}_d = \mathbb{E}_{(X_{Q,U,I}^i, Y^i)} \text{BCE}(Y^i, P(\hat{Y}|X_{Q,U,I}^i, \theta_d)), \quad (5)$$

其中， θ_d 是用于判别式预测的可学习稠密参数， $Y^i \in \{0, 1\}$ 是用户对该物品的真实行为标签。对于生成式目标，我们以 X_Q 和 X_U 为输入，依次生成用户发生正向交互的物品语义 token。采用下一 token 预测 (NTP) 损失优化生成式目标：

$$\mathcal{L}_g = \mathbb{E}_{(X_{Q,U}^i, Y^i)} [Y^i = 1] \cdot \sum_{j=1}^L \text{CE}(s_j^i, P(\hat{s}_j|X_{Q,U}^i, s_{<j}^i, \theta_g)), \quad (6)$$

其中， s_j^i 是物品的第 j 层语义 token (gen-token)， L 是该物品 gen-token 的长度， θ_g 是用于生成式优化的可学习稠密参数。在实践中， X_Q 和 X_U 分别被投影为 N_q 和 N_u 个 token（称为上下文 token）。在因果预测过程中，我们采用半因果掩码：上下文 token 彼此可见，而后续的起始 token 和语义 token 遵循因果掩码。TRM 的最终学习目标如下：

$$\mathcal{L} = \mathcal{L}_d + \lambda \cdot \mathcal{L}_g, \quad (7)$$

其中， λ 是用于平衡判别式损失与生成式损失的超参数。

4. 实验

4.1. 实验设置

数据集与环境。 离线实验采用一个大规模视频搜索排序数据集。该数据集从三个方面描述搜索引擎。(1) 物品。每个物品包含视频的帧、标题、音频和字幕，且已移除个人身份信息。(2) 查询与用户，包含用户查询的文本内容和用户历史交互。(3) 交互。对于每个查询，数据集记录用户是否与各物品发生正向交互。

对比模型。 我们将 TRM 与其他 SOTA 排序模型进行了充分比较。基于物品 ID 的方法包括 DCN(Wang et al., 2017)、DHEN(Zhang et al., 2022)、WuKong(Zhang et al., 2024a) 和 RankMixer(Zhu et al., 2025)。对于基于语义 token 的方法，我们复现

模型		CTR		有效播放		效率		
		AUC	QAUC	AUC	QAUC	稠密参数	稀疏参数	FLOPs (bs=4096)
ID 基线	DLRM-MLP	0.8662	0.8826	0.8413	0.8604	7M	7.52T	0.13T
基于 ID	DCN-v2	+0.08%	+0.06%	+0.15%	+0.10%	78M	7.52T	1.92T
	DHEN	+0.29%	+0.23%	+0.33%	+0.31%	242M	7.52T	8.42T
	WuKong	+0.44%	+0.38%	+0.59%	+0.45%	355M	7.52T	18.96T
	Pure Transformer	+0.56%	+0.46%	+0.69%	+0.56%	326M	7.52T	11.05T
	RankMixer	+0.58%	+0.48%	+0.76%	+0.63%	335M	7.52T	13.20T
基于 Token	Tiger-token	+0.45%	+0.40%	+0.58%	+0.45%	338M	5.06T	13.89T
	OneRec-token	+0.53%	+0.45%	+0.64%	+0.54%	342M	5.06T	13.98T
	SEMID	+0.56%	+0.47%	+0.75%	+0.61%	345M	5.08T	14.23T
	TRM-Pure Transformer	+0.61%	+0.53%	+0.81%	+0.68%	341M	5.07T	12.17T
	TRM-RankMixer	+0.65%	+0.54%	+0.85%	+0.70%	352M	5.07T	14.66T

表 1. 主要结果。除 TRM-Pure Transformer 外，基于 token 的方法均使用相同的 RankMixer 架构进行训练。对于 Tiger-token、OneRec-token 和 Semid，我们使用其语义 token 替换 RankMixer 中的物品 ID。

了 TIGER(Rajput et al., 2023)、OneRec(Deng et al., 2025) 和 SemID(Zheng et al., 2025b) 中提出的语义 token。上述所有语义 token 均作为 RankMixer 的输入进行训练，并且在所有基于语义 token 的方法中保持网络超参数一致。我们还训练了一个具有 7M 稠密参数的 MLP 排序基线用于比较。

TRM 的详细设置。在协同对齐中，我们使用 200 万个物品对及其多模态信息。对于混合 token 化，gen-token 使用 5 层、每个码本 4096 个嵌入的 RQ-Kmeans 生成，共得到 20480 个 token。BPE 算法最多生成 2×10^7 个 token，与基于物品 ID 的方法所使用、规模为 1.3×10^{10} 的物品 ID 集合相比可忽略不计。对于 TRM 的联合训练， X_Q 和 X_U 均被投影为 2 个 token (即， $N_q = N_u = 2$)，并使用一个 4 层 transformer 网络进行因果预测。我们设置 $\lambda = 0.1$ 以平衡联合训练。

评估指标。我们使用 AUC (曲线下面积) 和 QAUC (查询级 AUC) 评估不同模型的性能，使用稠密/稀疏参数量和 FLOPs 评估模型效率。离线实验主要关注 CTR 和有效播放，其中，若用户在相应查询下观看某物品超过 10 秒，则有效播放记为 1。

4.2. 主要结果

如表 1 所示，我们比较了 TRM 与其他 SOTA 方法的性能和效率，其中包括基于物品 ID 的模型和基于语义 token 的模型。

可以看到，我们提出的 TRM 框架相较于基于 ID 和基于 token 的 SOTA 方法均展现出更优的性能与效率。TRM-RankMixer 变体在所有指标上取得最高性能增益：CTR AUC 和 QAUC 分别提升 +0.65% 和 +0.54%，有效播放 AUC 和 QAUC 分别提升 +0.85%

设置	AUC	QAUC
不使用 Col-Align	-0.05%	-0.03%
不使用混合 Token	-0.09%	-0.07%
不使用辅助 NTP	-0.05%	-0.05%

表 2. TRM 不同组件的消融研究。我们报告 CTR AUC 和 QAUC 的评估结果。

和 +0.70%。我们方法的一项关键优势在于参数效率：TRM 将稀疏参数量从基于 ID 方法的 7.52T 降至 5.07T (减少 32.6%)，同时提升了模型性能。稀疏参数的显著减少缓解了传统基于 ID 的推荐模型固有的可扩展性挑战。

除传统特征交叉架构外，我们还尝试将 TRM 引入排序模型中纯 transformer 的训练 (仅使用 transformer 网络，不含任何特征交叉模块)。可以看到，TRM-Pure Transformer 在保持最佳计算效率 (仅 12.17T FLOPs) 的同时取得了有竞争力的性能 (CTR AUC +0.61%，有效播放 AUC +0.81%)，表明大规模推荐系统中存在采用全 token 架构的潜力。

此外，TRM 模型在所有评估指标上始终优于现有的基于 token 的方法 (TIGER-token、OneRec-token、Meta-token)，验证了我们语义 token 架构的有效性。结果表明，TRM 成功弥合了性能与效率之间的差距，为在排序模型中移除低效 ID 提供了一种实用方案。

4.3. 扩展定律比较

如图 4 所示，随着稠密网络容量增加，TRM-RankMixer 持续带来增益，并在参数量和 FLOPs 两个坐标轴上均保持领先曲线。在我们的最大测试规模下，TRM-RankMixer 的 qAUC 增益达到 +0.75%




图 4. 稠密参数与计算预算下的扩展行为。我们绘制了相对于 7M MLP 基线的 CTR qAUC 增益随稠密参数量（左）及每批训练 FLOPs (bs=4096, 右) 的变化。TRM-RankMixer (基于 token) 在各个规模下始终优于其他 token/ID 基线，并且 qAUC 增益差距随模型容量增加而进一步扩大，展现出更陡峭、更有利的扩展趋势。




图 5. 改变 mem-token 数量时，不同生命周期物品的 AUC 增益变化。我们报告相较于仅使用 gen-token 的 CTR AUC 评估结果。

辅助 Transformer 设置	2 个块		4 个块	
	使用 NTP 损失	不使用 NTP 损失	使用 NTP 损失	不使用 NTP 损失
额外参数	+32M	+27M	+54M	+48M
额外 FLOPs/批次	+0.73T	+0.68T	+1.26T	+1.19T
QAUC 增益	+0.03%	+0.00%	+0.05%	+0.01%

表 3. 生成式目标的消融研究。我们报告 CTR QAUC 增益的评估结果。

(1888M)，而 SEMID 和基于 ID 的 RankMixer 分别达到 +0.68% (1843M) 和 +0.60% (1768M)。不断扩大的差距表明，TRM 能够更有效地利用新增的稠密容量，这与改进的语义参数共享以及对稀疏 ID 记忆依赖的降低相一致。

相比之下，强大的基于 ID 的基线表现出明显的收益递减：即使扩展至 ~1.9B 稠密参数，WuKong 也在约 +0.55% 处趋于饱和，并且其计算量显著更高（最高达 124.64T FLOPs）。DHEN 更早出现饱和，在 1.17B 稠密参数 (49.75T FLOPs) 时仅达到 +0.42%。这种瓶颈行为符合如下直觉：纯粹以 ID 为中心的建模受长尾稀疏性和 ID 变动限制，仅扩展稠密塔无法充分弥补不

稳定且低效的稀疏记忆。

总体而言，图 4 表明，语义 token 排序器不仅提升了绝对 qAUC，还在参数预算和计算预算下呈现更优的扩展定律；在所有对比方法中，TRM 始终实现最佳的质量-效率前沿。

4.4. 消融研究

TRM 不同策略的效果。如表 2 所示，我们对 TRM 框架中提出的不同策略进行了消融。可以看到，三种策略均显著提升了 TRM 的性能。值得注意的是，混合 Token 化带来的 AUC 增益最大，表明平衡语义 token 的泛化能力与记忆能力十分必要。

泛化与记忆之间的权衡。为研究 TRM 中 mem-token 的影响，我们改变 mem-token 的数量，并比较其相对于 gen-token 的 AUC 增益。如图 5 所示，引入 mem-token 提升了所有生命周期物品的 AUC 预测性能。我们可以从结果中得出两点结论。第一，增加 mem-token 数量可以持续带来更多 AUC 增益，但当 token 数量增至 20M 时，额外增益趋于饱和。可以看到，对于存在时间超过 7 天的物品，将 mem-token 数量从 5M 增至 10M 可额外带来 0.04% 的 AUC 增益；但将数量从 15M 增至 20M 时，额外 AUC 增益仅为 0.02%。第二，相比于泛化，mem-token 对记忆的贡献更大。对于新物品（即，生成时间在 1 天以内的物品），AUC 提升 0.06%；而对于较旧物品（即，生成时间超过 7 天的物品），提升达到 0.11%。这一现象验证了我们利用 mem-token 提升记忆能力的洞见。

最后，我们将用于增强记忆的 BPE 策略与 SEMID(Zheng et al., 2025b) 所采用的 prefix-ngram 进行比较。如表 5 所示，得益于 BPE 捕获组合表示的动态合并机制，BPE 相较于 2-gram 和 prefix-ngram 展现出最佳的 AUC/QAUC 增益。

NTP 损失的效果。由于优化生成式目标需要额外的稠

	搜索活跃天数 (↑)	更换查询比例 (↓)	严格 CTR (↑)	点赞 (↑)	评论 (↑)
整体	+0.26%	-0.75%	+0.39%	+1.51%	+1.80%
低活跃	+0.27%	-0.81%	+0.36%	+1.83%	+2.02%
中活跃	+0.26%	-0.68%	+0.31%	+1.21%	+1.69%
高活跃	+0.22%	-0.69%	+0.40%	+1.20%	+1.59%

表 4. TRM 在搜索引擎中的在线性能。所有报告数值均具有显著性 (t 检验的 p 值小于 0.05)。

方法	AUC	QAUC
BPE	+0.09%	+0.07%
2-gram	+0.02%	+0.02%
Prefix-gram	+0.05%	+0.03%

表 5. 与 1-gram 基线的性能比较。

	AUC	QAUC
NTP 损失	+0.05%	+0.05%
PE	+0.02%	+0.01%
NTP 损失 + PE	+0.05%	+0.05%

表 6. NTP 损失与位置编码的比较。

密参数和 FLOPs, 我们对 NTP 损失进行消融, 以验证 QAUC 增益的来源。如表 3 所示, 相较于完整 TRM 模型, 引入 NTP 损失仅使稠密参数增加 1.7%, 每批次 FLOPs 增加 0.5%。但移除 NTP 损失会使 QAUC 从 +0.05% 显著下降至 +0.01%, 这表明性能提升来自生成式目标的优化, 而非额外 transformer 架构带来的参数量/FLOPs 增加。生成式目标能够利用语义 token 序列内部的结构信息。这里, 我们将 NTP 损失与同样可以向语义 token 人工注入序列信息的位置编码 (PE) 进行比较。如表 6 所示, 引入 PE 对语义 token 的性能提升非常有限。当 NTP 损失与 PE 结合时, PE 带来的提升甚至消失。该结果表明, NTP 损失不仅能提供更充分的结构信息, 还可以完全替代 PE 的作用。

4.5. 在线性能

为验证 TRM 框架在真实用户交互场景中的性能, 我们将排序模型应用于搜索引擎并开展在线实验。我们报告以下关键性能指标: 搜索活跃天数是每位用户主动使用搜索引擎的平均天数。改搜率是用户产生负向交互的查询页面占比。严格 CTR、点赞和评论分别是用户对所展示条目之一进行点击、点赞和评论的查询页面占比。

此前的基线是一个 7M 参数的 DLRM 排序模型。这里, 我们用 TRM-Rankmixer-352M 替换基线模型, 使 CTR 的 QAUC 提升了 0.54%。从表 4 可以看出, TRM 在所有指标上均取得了显著提升。值得注意的是, TRM 提升了所有活跃度水平用户的表现, 证明了 TRM 在改善用户在线体验方面的普适性。我们还开展了查询

	物品质量	查询-物品相关性	内容满意度
TRM	+0.86%	+0.34%	+0.92%

表 7. 用户评审中 TRM 的优势比例。

页面的用户评审: 在双盲设置下, 请 15 名真实用户对 462 个随机抽样的查询页面进行并排比较。如表 7 所示, 在真实用户反馈中, TRM 显著提升了条目质量、查询一条目相关性和内容满意度。

5. 结论

本文提出 TRM, 这是一种基于语义 token、用于扩展大规模排序模型的框架。我们进行了充分的理论与实验分析, 证明基于语义 token 的模型比基于条目 ID 的模型具有更强的扩展能力。通过整合所提出的策略 (即, 协同对齐、混合 token 化和联合优化), 我们在排序系统中取得了显著更好的性能。我们在大规模搜索系统中的在线测试进一步验证了 TRM 的有效性, 并揭示了利用语义 token 扩展排序模型这一颇具前景的方向。

参考文献

- Ardalani, N. et al. Understanding scaling laws for recommendation models. 2022. doi: 10.48550/arXiv.2208.08489.
- Bahri, Y., Dyer, E., Kaplan, J., Lee, J., and Sharma, U. Explaining neural scaling laws. *Proceedings of the National Academy of Sciences*, 121(27):e2311878121, 2024. doi: 10.1073/pnas.2311878121. URL <https://www.pnas.org/doi/10.1073/pnas.2311878121>.
- Chang, J., Gao, C., Zheng, Y., Hui, Y., Niu, Y., Song, Y., Jin, D., and Li, Y. Sequential recommendation with graph neural networks. In *Proceedings of the 44th international ACM SIGIR conference on research and development in information retrieval*, pp. 378–387, 2021.
- Chen, B., Guo, X., Wang, S., Liang, Z., Lv, Y., Ma, Y., Xiao, X., Xue, B., Zhang, X., Yang, Y., Dai, H., Xu, X., Zhao, T., Peng, M., Zheng, X., Wang, C., Zhao, Q., Zhai, Z., Zhao, Y., Liu, B., Lv, J., Liang, X., Ding, Y., Chen, J., Lei, C., Ou, W., Li, H., and Gai, K. Onesearch: A preliminary exploration of the unified end-to-end generative framework for e-commerce search. *arXiv preprint*, 2025. doi: 10.48550/arXiv.2509.03236. URL <https://arxiv.org/abs/2509.03236>.
- Chen, Y., Bu, J., and Yan, J. Unveiling the matthew effect across channels: Assessing layer width sufficiency via weight norm variance. *Advances in Neural Information Processing Systems*, 37:60040–60060, 2024.
- Cheng, H.-T., Koc, L., Harmsen, J., Shaked, T., Chandra, T., Aradhye, H., Anderson, G., Corrado, G., Chai, W., Ispir, M., et al. Wide & deep learning for recommender systems. In *Proceedings of the 1st workshop on deep learning for recommender systems*, pp. 7–10, 2016.
- Coleman, B. et al. Unified embedding: Battle-tested feature representations for web-scale systems. In *NeurIPS*, 2023. URL <https://arxiv.org/abs/2305.12102>.
- Deng, J., Wang, S., Cai, K., Ren, L., Hu, Q., Ding, W., Luo, Q., and Zhou, G. Onerec: Unifying retrieve and rank with generative recommender and iterative preference alignment. *arXiv preprint*, 2025. doi: 10.48550/arXiv.2502.18965. URL <https://arxiv.org/abs/2502.18965>.
- Fang, Y., Zhan, J., Ai, Q., Mao, J., Su, W., Chen, J., and Liu, Y. Scaling laws for dense retrieval. In *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '24)*, 2024. doi: 10.1145/3626772.3657743. URL <https://arxiv.org/abs/2403.18684>.
- Guo, W., Wang, H., Zhang, L., Chin, J. Y., Liu, Z., Cheng, K., Pan, Q., Lee, Y. Q., et al. Scaling new frontiers: Insights into large recommendation models. *arXiv preprint arXiv:2412.00714*, 2024. URL <https://arxiv.org/abs/2412.00714>.
- Hestness, J., Narang, S., Ardalani, N., Diamos, G., Jun, H., Kianinejad, H., Patwary, M. M. A., Yang, Y., and Zhou, Y. Deep learning scaling is predictable, empirically. *arXiv preprint*, 2017. URL <https://arxiv.org/abs/1712.00409>.
- Huang, C., Yu, T., Xie, K., Zhang, S., Yao, L., and McAuley, J. Foundation models for recommender systems: A survey and new perspectives. *arXiv preprint*, 2024. doi: 10.48550/arXiv.2406.10450. URL <https://arxiv.org/abs/2402.11143v1>.
- Huang, Y., Hong, S., Xiao, X., Jin, J., Luo, X., Wang, Z., Chai, Z., Wu, S., Zheng, Y., and Lin, J. Hyformer: Revisiting the roles of sequence modeling and feature interaction in ctr prediction. *arXiv preprint arXiv:2601.12681*, 2026.
- Kaplan, J., McCandlish, S., Henighan, T., Brown, T. B., Chess, B., Child, R., Gray, S., Radford, A., Wu, J., and Amodei, D. Scaling laws for neural language models. *arXiv preprint*, 2020. URL <https://arxiv.org/abs/2001.08361>.
- Kudo, T. and Richardson, J. Sentencepiece: A simple and language independent subword tokenizer and detokenizer for neural text processing. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pp. 66–71. Association for Computational Linguistics, 2018. doi: 10.18653/v1/D18-2012. URL <https://arxiv.org/abs/1808.06226>.
- Lu, J., Shen, Z., Yang, D., and Zhang, L. Deep neural networks and dynamic programming. *arXiv preprint*, 2021. URL <https://arxiv.org/abs/2001.03040>.
- Naumov, M., Mudigere, D., Shi, H. M., Huang, J., Sundaram, N., Park, J., Wang, X., Gupta, U., Wu, C., Azzolini, A. G., et al. Deep learning recommendation model for personalization and recommendation systems. In *Proceedings of the Workshop on Systems for ML (SysML)*, 2019. doi: 10.48550/arXiv.1906.00091. URL <https://arxiv.org/abs/1906.00091>.

- Rajput, S., Mehta, N., Singh, A., Keshavan, R. H., Vu, T., Heldt, L., Hong, L., Tay, Y., Tran, V. Q., Samost, J., Kula, M., Chi, E. H., and Sathiamoorthy, M. Recommender systems with generative retrieval. In *Advances in Neural Information Processing Systems*, 2023. URL <https://openreview.net/forum?id=BJ0fQUU32w>.
- Sennrich, R., Haddow, B., and Birch, A. Neural machine translation of rare words with subword units. In *Proceedings of the 54th annual meeting of the association for computational linguistics (volume 1: long papers)*, pp. 1715–1725, 2016.
- Siegel, J. W. and Xu, J. Optimal approximation rates for deep relu neural networks on sobolev and besov spaces. *Journal of Machine Learning Research*, 24(344):1–52, 2023. URL <https://jmlr.org/papers/volume24/344-2023/344-2023.pdf>.
- Singh, A., Vu, T., Mehta, N., Keshavan, R. H., Sathiamoorthy, M., Zheng, Y., Hong, L., Heldt, L., Wei, L., Tandon, D., Chi, E. H., and Yi, X. Better generalization with semantic ids: A case study in ranking for recommendations. arXiv preprint, 2023. doi: 10.48550/arXiv.2306.08121. URL <https://arxiv.org/abs/2306.08121>.
- Wang, R., Fu, B., Fu, G., and Wang, M. Deep & cross network for ad click predictions. In *Proceedings of the ADKDD’17*, pp. 1–7, 2017.
- Yan, B., Liu, S., Zeng, Z., Wang, Z., Zhang, Y., Yuan, Y., Liu, L., Liu, J., Wang, D., Su, W., Pengjie, W., Xu, J., and Zheng, B. Unlocking scaling law in industrial recommendation systems with a three-step paradigm based large user model. arXiv preprint arXiv:2502.08309, 2025. URL <https://arxiv.org/abs/2502.08309>.
- Yarotsky, D. Error bounds for approximations with deep relu networks. *Neural Networks*, 94:103–114, 2017. doi: 10.1016/j.neunet.2017.06.003.
- Zhang, B., Luo, L., Liu, X., Li, J., Chen, Z., Zhang, W., Wei, X., Hao, Y., Tsang, M., Wang, W., et al. Dhen: A deep and hierarchical ensemble network for large-scale click-through rate prediction. arXiv preprint arXiv:2203.11014, 2022.
- Zhang, B., Luo, L., Chen, Y., Nie, J., Liu, X., Guo, D., Zhao, Y., Li, S., Hao, Y., Yao, Y., et al. Wukong: Towards a scaling law for large-scale recommendation. arXiv preprint arXiv:2403.02545, 2024a.
- Zhang, G., Hou, Y., Lu, H., Chen, Y., Zhao, W. X., and Wen, J.-R. Scaling law of large sequential recommendation models. In *Proceedings of the 18th ACM Conference on Recommender Systems*, pp. 444–453, 2024b.
- Zhang, Z., Pei, H., Guo, J., Wang, T., Feng, Y., Sun, H., Liu, S., and Sun, A. Onetrans: Unified feature interaction and sequence modeling with one transformer in industrial recommender. arXiv preprint arXiv:2510.26104, 2025.
- Zhao, X., Wang, M., Zhao, X., et al. Embedding in recommender systems: A survey. arXiv preprint arXiv:2310.18608, 2023. URL <https://arxiv.org/abs/2310.18608>.
- Zheng, C., Huang, M., Pedchenko, D., Rangadurai, K., Wang, S., Nahum, G., Lei, J., Yang, Y., Liu, T., Luo, Z., Wei, X., Ramasamy, D., Yang, J., Han, Y., Yang, L., Xu, H., Jin, R., and Yang, S. Enhancing embedding representation stability in recommendation systems with semantic id. arXiv preprint arXiv:2504.02137, 2025a. URL <https://arxiv.org/abs/2504.02137>.
- Zheng, C., Huang, M., Pedchenko, D., Rangadurai, K., Wang, S., Nahum, G., Lei, J., Yang, Y., Liu, T., Luo, Z., Wei, X., Ramasamy, D., Yang, J., Han, Y., Yang, L., Xu, H., Jin, R., and Yang, S. Enhancing embedding representation stability in recommendation systems with semantic id. arXiv preprint, 2025b. doi: 10.48550/arXiv.2504.02137. URL <https://arxiv.org/abs/2504.02137>.
- Zhou, G., Zhu, X., Song, C., Fan, Y., Zhu, H., Ma, X., Yan, Y., Jin, J., Li, H., and Gai, K. Deep interest network for click-through rate prediction. In *Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining*, pp. 1059–1068, 2018.
- Zhou, G., Deng, J., Zhang, J., Cai, K., Ren, L., Luo, Q., Wang, Q., Hu, Q., Huang, R., Wang, S., Ding, W., Li, W., Luo, X., Wang, X., Cheng, Z., Zhang, Z., Zhang, B., Wang, B., Ma, C., Song, C., Wang, C., Wang, D., Meng, D., Yang, F., Zhang, F., Jiang, F., Zhang, F., Wang, G., Zhang, G., Li, H., Hu, H., Lin, H., Cheng, H., Cao, H., Wang, H., Huang, J., Chen, J., Liu, J., Jia, J., Gai, K., Hu, L., Zeng, L., Yu, L., Wang, Q., Zhou, Q., Wang, S., He, S., Yang, S., Yang, S., Huang, S., Wu, T., He, T., Gao, T., Yuan, W., Liang, X., Xu, X., Liu, X., Wang, Y., Wang, Y., Liu, Y., Song, Y., Zhang, Y., Wu, Y., Zhao, Y., and Liu, Z. Onerec technical report. arXiv preprint, 2025. doi: 10.48550/arXiv.2506.13695. URL <https://arxiv.org/abs/2506.13695>.
- Zhou, Y., Zhu, Q., Jin, J., and Dou, Z. Cognitive personalized search integrating large language models

with an efficient memory mechanism. In Proceedings of the ACM Web Conference 2024, pp. 1464–1473, 2024.

Zhu, J., Fan, Z., Zhu, X., Jiang, Y., Wang, H., Han, X., Ding, H., Wang, X., Zhao, W., Gong, Z., et al. Rankmixer: Scaling up ranking models in industrial recommenders. In Proceedings of the 34th ACM International Conference on Information and Knowledge Management, pp. 6309–6316, 2025.

Zhu, Y., Xie, R., Zhuang, F., Ge, K., Sun, Y., Zhang, X., Lin, L., and Cao, J. Learning to warm up cold item embeddings for cold-start recommendation with meta scaling and shifting networks. In Proceedings of SIGIR, 2021.

Zivic, P., Vazquez, H., and Sánchez, J. Scaling sequential recommendation models with transformers. In Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval, pp. 1567–1577, 2024.

A. 附录

A.1. 基于 token 与基于 ID 的缩放定律分析

A.1.1. 塔式网络的经验缩放定律

在扩展神经塔式网络（保持表示和训练协议不变）时，我们观察到标准的幂律行为：

$$\mathcal{L}(N) \approx \mathcal{L}_\infty + AN^{-\beta}, \quad (8)$$

其中， N 是塔式网络的参数数量， $\mathcal{L}_\infty$ 是不可约误差水平（下限）， $\beta > 0$ 是缩放指数 (Hestness et al., 2017; Kaplan et al., 2020; Bahri et al., 2024)。从经验上看，在一个非平凡范围内，基于 ID 和基于 token 的模型均在双对数图上呈现近似线性趋势，而 token 化会为塔式网络缩放带来更大的拟合指数（更陡的斜率）（第 4.3 节）。

A.1.2. β 的平滑性—维度解释

我们通过语义潜在空间上贝叶斯最优 CTR 函数的平滑性来解释 β 。令 $Z \in \mathcal{Z} \subset \mathbb{R}^{d^*}$ 为条目的连续语义表示， (U, Q) 为用户/查询上下文。定义贝叶斯最优 CTR 概率及其 logit：

$$p^*(u, q, z) = \mathbb{P}(Y = 1 \mid U = u, Q = q, Z = z), \quad \eta^*(u, q, z) = \log \frac{p^*(u, q, z)}{1 - p^*(u, q, z)}.$$

假设对于固定的 (u, q) ， η^* 关于 z 是 s -Hölder 连续的：

$$|\eta^*(u, q, z_1) - \eta^*(u, q, z_2)| \leq L_\eta \|z_1 - z_2\|^s, \quad \forall z_1, z_2 \in \mathcal{Z}. \quad (9)$$

令 d_{eff} 表示语义域的有效维度。

针对 Hölder/Sobolev 类的深度网络近似理论表明，可达到的近似误差衰减由平滑性 s 与维度 d_{eff} 之间的相互作用决定（忽略对数因子）(Yarotsky, 2017; Lu et al., 2021; Siegel & Xu, 2023)。一种便于与缩放规律兼容的参数化形式为：

$$\beta \approx \beta(s, d_{\text{eff}}) := \frac{2s}{2s + d_{\text{eff}}}, \quad (10)$$

因此，更高的平滑性 s 和更小的有效维度 d_{eff} 会带来更大的指数 β 。

A.1.3. 分解观测到的缩放规律：(s, d_{eff}) vs. 量化

对于基于 token 的模型，塔式网络在量化语义变量 $\tilde{Z} = Q(Z)$ (RQ-VAE / RQ-kmeans) 上运行。在塔式网络的缩放区间内，我们可以写为：

$$\mathcal{L}_{\text{tok}}(N) \approx \underbrace{\mathcal{L}_\infty}_{\text{贝叶斯下限 (理想 } Z)} + \underbrace{\Delta_{\text{quantRQ_VAE}}}_{\text{量化引起的下限偏移}} + \underbrace{AN^{-\beta_{\text{tok}}}}_{\text{塔式网络缩放项}}, \quad \beta_{\text{tok}} \approx \beta(s_{\text{tok}}, d_{\text{eff}, \text{tok}}). \quad (11)$$

因此， β 由该表示所诱导的平滑性—维度对 (s, d_{eff}) 决定，而量化会为下限贡献一个与 N 无关的偏移。

A.1.4. RQ-VAE 量化主要使下限发生偏移

CTR 损失在 logit 空间中是 Lipschitz 连续的。将二元交叉熵写成 logit 形式：

$$\ell(y, \eta) = \log(1 + e^\eta) - y\eta, \quad y \in \{0, 1\}.$$

由于 $\frac{\partial \ell}{\partial \eta} = \sigma(\eta) - y \in [-1, 1]$ ，可得：

$$|\ell(y, \eta) - \ell(y, \eta')| \leq |\eta - \eta'|, \quad \forall \eta, \eta' \in \mathbb{R}. \quad (12)$$

量化失真与下限偏移。令 $\tilde{Z} = Q(Z)$ ，并定义 s 阶矩失真

$$\delta_s := \mathbb{E}\|Z - \tilde{Z}\|^s. \quad (13)$$

定义具有完整语义信息和具有量化信息时的贝叶斯风险：

$$\mathcal{L}_\infty := \inf_h \mathbb{E}[\ell(Y, h(U, Q, Z))], \quad (14)$$

$$\mathcal{L}_{\infty, \text{tok}} := \inf_h \mathbb{E}[\ell(Y, h(U, Q, \tilde{Z}))]. \quad (15)$$

令 $\Delta_{\text{quantRQ_VAE}} := \mathcal{L}_{\infty, \text{tok}} - \mathcal{L}_\infty \geq 0$ 。

命题 A.1 (CTR 损失下的量化下限偏移). 假设贝叶斯 logit 满足 Hölder 条件 (9)。则

$$0 \leq \Delta_{\text{quantRQ_VAE}} \leq L_\eta \mathbb{E}\|Z - \tilde{Z}\|^s = L_\eta \delta_s. \quad (16)$$

在缩放区间内，量化不会改变塔式网络指数。令 $\mathcal{L}_{\text{tok}}(N)$ 为在 $(U, Q, \tilde{Z})$ 上运行、具有 N 个参数的塔式网络可达到的最佳总体损失：

$$\mathcal{L}_{\text{tok}}(N) := \inf_{\theta: \#\theta \leq N} \mathbb{E}[\ell(Y, g_\theta(U, Q, \tilde{Z}))].$$

则

$$\mathcal{L}_{\text{tok}}(N) - \mathcal{L}_\infty = \underbrace{(\mathcal{L}_{\text{tok}}(N) - \mathcal{L}_{\infty, \text{tok}})}_{\text{塔式网络缩放项}} + \underbrace{\Delta_{\text{quantRQ_VAE}}}_{\text{与 } N \text{ 无关}}. \quad (17)$$

因此，如果在 N 的某个范围内满足 $\mathcal{L}_{\text{tok}}(N) - \mathcal{L}_{\infty, \text{tok}} \approx AN^{-\beta_{\text{tok}}}$ ，那么在该区间中， $\Delta_{\text{quantRQ_VAE}}$ 只会改变渐近下限，而不会改变 β_{tok} 。

何时可以忽略量化？只要在实际缩放范围内， $\Delta_{\text{quantRQ_VAE}}$ 始终由塔式网络项 $AN^{-\beta_{\text{tok}}}$ 主导，量化就是可忽略的。一个简单的充分条件是 δ_s 足够小；对于 $0 < s \leq 2$ ，令 $D := \mathbb{E}\|Z - \tilde{Z}\|^2$ ，则

$$\delta_s = \mathbb{E}\|Z - \tilde{Z}\|^s \leq (\mathbb{E}\|Z - \tilde{Z}\|^2)^{s/2} = D^{s/2}. \quad (18)$$

A.1.5. 为何 token 化能够提高观测到的指数

基于 token 的 LRM 促进了语义参数共享：许多条目复用一组紧凑的多模态 token，这些 token 由丰富的头部流量训练而成，从而改善了向长尾/新条目的迁移。从经验上看，token 表示集中在复杂度更低的子空间中，并表现出更快的谱衰减，这与更小的有效维度 $d_{\text{eff}, \text{tok}}$ 和更稳定的语义（即在表示所诱导的度量下，有效的 s_{tok} 更大）相一致。相比之下，在长尾频率与条目更迭的情形下，开放集 ID 嵌入会引入表示噪声且共享性较弱，从而增大有效复杂度（更大的 $d_{\text{eff}, \text{id}}$ ），并降低塔式网络所感知的有效平滑性。结合 (10)，可得

$$\beta_{\text{tok}} \approx \beta(s_{\text{tok}}, d_{\text{eff}, \text{tok}}) > \beta_{\text{id}} \approx \beta(s_{\text{id}}, d_{\text{eff}, \text{id}}),$$

这解释了为何基于 token 的塔式网络缩放曲线在经验上比基于 ID 的基线更陡（第 4.3 节）。