

UniDot: 面向大规模推荐的序列建模与特征交互统一网络

Rongcheng Lin

Meta

门洛帕克, 美国

linrongc@meta.com

Yan Sun

Meta

门洛帕克, 美国

yansun@meta.com

Jamey Zhang

Meta

门洛帕克, 美国

jameyz@meta.com

Guanglei Xiong

Meta

门洛帕克, 美国

glx@meta.com

Ivan Ji

Meta

门洛帕克, 美国

ivanji@meta.com

Xianjie Chen

Meta

门洛帕克, 美国

cxj@meta.com

Shujian Bu

Meta

门洛帕克, 美国

shujian@meta.com

摘要

工业推荐系统依赖于两类长期以来基本独立演进的模型：面向多字段用户/物品特征的特征交互模型，以及面向用户行为历史的序列模型。生产系统仅以较为松散的方式将二者结合。为统一这两类模型，我们提出 **UniDot**，这是一种从因子分解机 (FM) 视角出发构建的点击后转化预测新架构：驱动协同过滤并使推荐器能够泛化到未见用户-物品对的嵌入内积，与注意力的 query-key 打分使用的是同一基本操作，因此单一的 **token 点积** 即可同时作为特征交互与序列建模的基础。UniDot 将非序列字段和多域行为序列 token 化到同一个共享 token 空间中，并堆叠一种统一宏块；在该宏块中，**token 混合总线** 与 **序列检索总线**（物品 token 对历史进行交叉注意力）并行运行，并在每一层通过 MLP-Mixer 融合交换状态；与此同时，**FM Highway** 将各层显式的点积交互绕过残差堆栈，直接传递给分类器。序列侧在每次前向传播中仅嵌入一次并由所有使用方共享，从而限制推理延迟。UniDot 采用稀疏/稠密双优化器 (Adagrad + Muon)、辅助转化延迟预测头和多路径互学习进行训练，最终获得 TAAC $\times$ KDD Cup 2026 工业赛道亚军。

关键词

推荐系统, 特征交互, 序列建模, CTR/CVR 预测, token mixing, 因子分解机

1 引言

大规模推荐系统实时地对海量候选集进行排序，是现代内容与广告平台的基础。其预测模型沿着两个基本独立的传统逐渐成熟。(1) **特征交互模型**—Wide&Deep [6]、DeepFM [8]、xDeepFM [17]、DCN/DCN-v2 [26, 27]、FiBiNet [11]、AutoInt [23]、Wukong [33]、DHEN [32]—学习宽广且大多静态的特征集合（用户画像 $\times$ 物品属性）之间的显式与隐式交叉。(2) **序列用户兴趣模型**，例如，DIN [37]、DIEN [36]、DSIN [7]、SIM [20]、ETA [4]、TWIN [3]、LONGER [2] 和 TIN [38]，对用户行为的动态性进行建模，通常在单一行为历史上使用目标感知注意力。

TAAC $\times$ KDD Cup 2026 (Tencent Uni-Rec Challenge) —“面向大规模推荐的序列建模与特征交互统一”—正是针对这一缺口，要求采用**统一的 token 化方案**和**同构、可堆叠的骨干网络**，在一个架构中对大规模推荐的序列与非序列

特征进行建模，并在推理延迟预算下按 AUC 排名 (§A 介绍数据)。遵循近期提出的 SlimPer 框架 [28]，我们设计了 UniDot。它直接回应了这一要求：一种可堆叠的块、一个共享 token 空间，将两类模型统一起来。其名称是 **Unified modeling via Dot-products Of Tokens** 的缩写—交叉注意力（序列检索）与因子分解机（特征交互）本质上都是 token 点积，而点积正是整个模型赖以构建的唯一基本操作。

这一视角是有意选择的。FM 内积 $\langle v_u, v_i \rangle$ 是协同过滤的引擎：用户与物品通过从所有观测到的共现中估计出的潜在因子相遇，因此分数可泛化到训练中从未共同出现的用户-物品对 [22]；而在广告转化数据中，面对庞大且快速变化的广告库存以及稀疏的正样本，在线服务时的大多数候选对实际上都是新的。以往的工作将这种内积变为隐式形式—使其成为深度交互堆栈或 transformer 的涌现属性。UniDot 在信号跨越用户-物品或候选-历史边界的每一处都保留显式内积，并利用更深层的机制（token 混合、门控 MLP、注意力）来细化这些点积的操作数，而不是替代点积运算本身。

UniDot 将一种同构块堆叠 L 次：两条总线—面向用户/物品画像 token 的 **token 混合总线**，以及物品 token 对行为历史执行交叉注意力的 **序列检索总线**—在每一层通过 **MLP-Mixer 融合器** 交换状态，而 **FM Highway** 则将显式点积交互直接传送到分类器。其余所有内容 (§4) 都在说明如何让这些组件具备低成本、候选感知与可扩展性。围绕这一设计以及支撑我们最终提交结果的训练方案，我们做出四项贡献。(1) **双路径、逐层并行的块**：不同于将序列模块串联到交互骨干网络中，每个块并发运行两条路径—非序列 **token 混合** 路径（可替换的混合器插槽：默认采用 Wukong 的并行 LCB + FMB，也可直接换入 TokenMixer 风格的块）和 **序列检索** 路径（物品 token 对行为序列执行交叉注意力）—二者通过规范的 MLP-Mixer 融合 (§4.4) 逐层交换状态，使画像与序列信号共同演化；这种交错方式受到 InterFormer [30] 和 Kunlun [10] 的启发，而 UniDot 与它们的区别在于始终将跨边界信号保持为显式点积。(2) **共享、候选感知的多域序列流水线**：所有行为域只嵌入一次，并通过逐位置的 fid 轴压缩重塑为统一的逐位置宽度 (§4.2)；DIN 风格的 **条件门控 SwiGLU** 仅向门控注入候选上下文，而按时间戳交错的 **合并流** 对跨域时间模式进行建模 (§4.3)。(3) **用于显式特征交互的 FM Highway**：逐域 query-key 点积、聚合 Gram 矩阵以及跨总线用户-物品点积在各层之间拼接，并被直接送入分类器 (§4.4)，绕过残差融合路径，以几乎可忽略的成本保留深层残差堆栈往往会冲淡的 FM 风格二阶信号。(4) **基于共享嵌入的多路径互学习**：我们在同一个共享（且占据主要参数量）的嵌入表上联合训练 **两条 UniDot 路径**，并让每条路径都以另一条路径的预测作为正则化目标 (§4.6)，从而使即便仅部署单条路径也能达到更优极小

KDD Cup 2026 Tencent UniRec Challenge Workshop, 2026 年 8 月 12 日, 韩国济州。
竞赛网站: <https://algo.qq.com/>。
所有实验、数据收集和处理活动均在竞赛主办方的基础设施上开展。未在 Meta 基础设施上开展任何实验、数据收集或处理活动。




图 1: UniDot 架构 (S4): 两条总线通过 L 个宏块共同演化, 经由逐层 MLP-Mixer 融合交换状态, FM Highway 则将各层的显式点积绕过融合器直接送至分类器。

表 1: 工业赛道最终排行榜 (第二轮, 前 10 名)。* 仅部署我们全数据 DML 模型的单条路径 ($1\times$ 推理成本) 仍可排名第二—多路径训练使单个模型也能达到更优极小值 (S4.6)。

排名	AUC $\uparrow$	与第 #1 名的差距
1	0.83254	—
2 (UniDot, 我们的方法)	0.83217	0.037%
(UniDot, 单路径) *	0.83184	0.070%
3	0.83145	0.109%
4	0.83080	0.174%
5	0.83073	0.181%
6	0.83036	0.218%
7	0.82915	0.339%
8	0.82888	0.366%
9	0.82881	0.373%
10	0.82854	0.400%

值—该模型推理成本为 $1\times$, 自身即可获得亚军 (表 1) 而双路径均值则可取得剩余的小幅增益。

UniDot 在 TAAC $\times$ KDD Cup 2026 挑战赛的官方 AUC 指标下获得工业赛道亚军, 最终排行榜 AUC 达到 **0.83217** (表 1)。这一结果源自架构与规模, 而非繁重的特征工程: 除已发布的数据模式外, 我们没有添加任何手工设计的交叉特征。

2 相关工作

特征交互。 隐因子协同过滤是推荐系统的历史核心: 矩阵分解将用户和物品表示为隐向量, 并用其内积预测亲密度 [16]; 因子分解机 [22] 则将其推广到任意多字段特征, 在保留对未见特征对进行因子化泛化能力的同时, 将 MF 及其变体纳入为特例; 域感知变体 [15] 进一步改进了这种因子分解。深度学习时代并未取代内积, 反而仍将其置于核心: DeepFM [8] 在共享嵌入上并行运行 FM 和 DNN, Wide&Deep [6], xDeepFM [17], DCN-v2 [27], AutoInt [23] 和 FiBiNet [11] 以更深层或基于注意力的形式扩展显式交叉。Wukong [33] 通过堆叠因子分解模块和线性压缩块来扩展交互建模, DHEN [32] 则组合异构交互专家。

序列用户兴趣建模。 DIN [37] 引入了目标感知注意力池化; DIEN, DSIN 和 BST [5] 加入兴趣演化与自注意力; SIM [20], ETA, TWIN [3] 和 LONGER [2] 等长序列方法对超长历史进

行检索或压缩。我们的条件门控 SwiGLU 是一种 DIN 风格机制: 候选上下文引导哪些位置重要, 但仅进入门控, 使值路径保持内容纯净——这一设计可以与位置局部压缩自然组合。

统一特征交互与序列建模。 一条快速发展的研究路线将两个分支纳入同一骨干网络。HSTU [31] 将排序/检索重塑为统一 Transformer 上的生成式序列任务。InterFormer [30] 交错执行序列学习与特征交互学习, 使二者逐层相互完善, 而非依次进行。HyFormer [12] 将特征交互模块与对行为历史进行交叉注意力的 Transformer 配对; 我们的序列总线将其扩展至多个域和一条合并的跨域流, 并将显式的逐序列点积路由到 FM Highway (S4.4)。OneTrans [35] 和 TokenFormer [39] 将所有属性、行为和目标融合进一条同质的 (仅解码器) 流; 后者必须应对序列坍塌, 而 UniDot 的双总线分离从结构上避免了这一问题。UniMixer [9] 和 TokenMixer [13] 追求单一、可堆叠的 token 混合骨干 (后者还探索扩展规律), Kunlun [10] 将这类思想扩展到生产环境, 而 TIGER [21] 等 Semantic-ID 方法则把协同信号与内容信号映射到共享的离散 token 空间。TAAC $\times$ KDD Cup 2026 挑战赛 [24] 将这一方向形式化。SlimPer [28] 将排序描述为对一个紧凑、固定大小的 (用户、物品) 知识库进行迭代优化; 每一层都会针对完整原始 token 集重新读取该知识库。UniDot 是这一框架在公开数据集上的初步测试。

UniDot 的独特之处在于其出发点。以往工作要么通过扩大特征混合规模并将行为视为更多特征来实现统一 [9, 13, 30], 要么把每个特征都嵌入为序列模型中的又一个 token [10, 31, 35]; 两者都会使协同过滤内积变得隐式。UniDot 则保持其显式性: 将交叉注意力理解为查询 token 与键 token 之间的 FM 评分, 并使用专门的 FM Highway (S4.4) 使这些低阶交互绕过残差混合器 [22]。

3 问题定义

我们研究点击后转化预测。一个样本为 $x = (u, i, S)$, 带有二元标签 $y \in \{0, 1\}$ ($y=1$ 表示转化), 其中 u 是用户画像 (user_int ID、逐位置对齐权重、预训练用户嵌入), i 是候选物品 (item_int ID、物品嵌入), $S = \{S_s\}_{s=1}^4$ 是四个行为域。模型预测转化概率, 并使用二元交叉熵训练。下面固定 S4 通篇使用的记号; 我们用 d 表示 d_{model} 。

(1) **Token 化**将原始输入映射为 d 维 token (§4.2–4.3):

$$\begin{aligned} \mathbf{U} &= \text{Tok}_u(u) \in \mathbb{R}^{T_u \times d}, \quad \mathbf{I} = \text{Tok}_i(i) \in \mathbb{R}^{T_i \times d}, \\ \mathbf{I}_h &= \text{Tok}_i^h(i) \in \mathbb{R}^{T_{ih} \times d}, \quad \mathbf{H}^{(s)} = \text{Seq}(S_s) \in \mathbb{R}^{L_s \times d}. \end{aligned} \quad (1)$$

(2) **可堆叠块**. 由 token 化器初始化两种 token 状态: $Z_{\text{mix}}^0 = [\mathbf{U}; \mathbf{I}]$ (token 混合总线) 和 $Z_{\text{seq}}^0 = \mathbf{I}_h$ (序列检索总线). 对于 $\ell = 1, \dots, L$ 个相同块:

$$(Z_{\text{mix}}^\ell, Z_{\text{seq}}^\ell, \phi^\ell) = \text{Block}_\ell(Z_{\text{mix}}^{\ell-1}, Z_{\text{seq}}^{\ell-1}, \{\mathbf{H}^{(s)}\}_{s=1}^S), \quad (2)$$

其中 ϕ^ℓ 是该层的 **FM Highway** 信号 (token 点积和 Gram; §4.4).

(3) **读出**. 分类器接收最终状态的压缩读出 ρ (§4.5)、每一层的 highway 信号, 以及跳跃嵌入信号 e_{skip} (§C.5):

$$\hat{y} = \sigma(\text{MLP}[\rho(Z_{\text{mix}}^L, Z_{\text{seq}}^L); \phi^1; \dots; \phi^L; e_{\text{skip}}]). \quad (3)$$

逐层 highway 信号采用拼接而非求和, 因此每一层的显式交互都能不经稀释地送达分类器.

(4) **目标函数**. 二元交叉熵加辅助延迟损失:

$$\mathcal{L} = -y \log \hat{y} - (1 - y) \log(1 - \hat{y}) + \lambda \mathcal{L}_{\text{delay}}, \quad (4)$$

其中 $\mathcal{L}_{\text{delay}}$ 是在所有存在下一次动作的行 (点击和转化, 而不仅是正样本) 上, 对距下一次动作时间的对数 $\log(1 + (t_{\text{label}} - t_{\text{event}}))$ 进行 MSE 回归, 详见 §C.6.

4 方法: UniDot

4.1 概述

统一 *Token 化*. 每一种输入——非序列用户/物品多字段特征以及逐位置行为序列事件——都被嵌入到相同的 d_{model} 空间并表示为 token (§4.2–4.3). 随后由单一的**可堆叠宏块**进行处理; 堆叠 L 个相同块是唯一的深度调节旋钮, 使该设计易于在深度和宽度上扩展.

两条总线经 L 个宏层共同演化 (每层包含 W 个 token 混合子层); **MLP-Mixer** 融合在每一层交换两者的信息, **FM Highway** 则并行运行 (图 1). 共享序列流水线 (§4.3) 同时为交叉注意力和逐层**多通道池化**提供输入, 后者将池化序列 token 注入非序列总线. 我们在 §4 中保留符号表示 $(L, W, T_u, T_i, T_{ih}, S, w, d)$; 具体取值见 §C (表 8).

4.2 Token 化器

Token 化将模型的异构输入 (类别 fid、多值 ID 列表、预训练嵌入和行为序列) 映射到统一的 d 维 token 空间, 使宏块能够一致处理. 每个多字段输入通过沿 token 轴压缩, 变为若干个 d 维 token ($\text{Tok}_u, \text{Tok}_i$, 见式 (1)). 模型中反复使用两种原语, 二者都映射 $\mathbb{R}^{T \times d} \rightarrow \mathbb{R}^{T' \times d}$ 并以 LayerNorm 收尾: **LCB** 是单层 token 轴 MLP-mixer (单个线性层), **NCB** 是其双层版本 (两个线性层, 中间使用 GELU).

类别 (*fid*) 特征. 每个 fid 都按位置嵌入, 并由沿 token 轴的单个可学习 **NCB** 将位置束压缩到 token 预算. 由于 NCB 是可学习的, 哪些特征组合构成每个 token 由数据决定, 而不是采用会平均掉位置级显著性的固定池化规则. 由此得到用户 token $\mathbf{U}$ (T_u), 以及从两个独立物品表得到的紧凑视图 $\mathbf{I}$ (T_i , token 混合总线) 和更丰富的 $\mathbf{I}_h$ (T_{ih} , 序列检索总线, 其 token 驱动交叉注意力查询). 行为序列也以相同方式 token 化 (先进行逐 fid 嵌入, 再通过位置局部的 fid 轴 NCB 得到统一的




图 2: 一条序列主干 (§4.3)。

逐位置宽度; §4.3), 每次前向传播仅计算一次, 并由所有使用方共享.

多值 *fid*: *FAFE*. 少数高价值 fid 是行为 ID 的列表, 其顺序不承载含义——它们具有**位置不变性**. 对于这些字段, 我们用面向候选、针对排序候选的 DIN 式注意力池化替代静态 NCB, 因此每个候选对应的字段 token 都是其各取值的不同组合 (**FAFE**, §C.3): 这仍是同一压缩为 token 步骤的特例, 只是池化权重依赖于候选.

预训练嵌入特征. 稠密预训练向量 (用户 SUM、LMF4Ads, ...; 物品嵌入) 先归一化, 再由一个小型 MLP 投影为额外 token, 并追加到匹配 token 集 (§C.4). 另外, 少数成对的 **user_dense** 数组并非特征, 而是 fid 嵌入上的逐位置乘数 (§C.2).

4.3 序列编码器

序列编码器 (式 (1) 中的 $\text{Seq}(\cdot)$) 接收来自 §4.2 的逐位置序列 token, 并将其转化为下游使用的视图 $\mathbf{H}^{(s)}$; 每次前向传播只计算一次, 并由所有使用方共享. 它由四个阶段组成, 每个阶段分别用于建模行为流中的一种不同结构: **跨域合并** (跨域形成一条时间线)、**深度卷积** (局部/N-gram 结构)、**DIN 式条件 SwiGLU** (候选感知的过滤与增强), 以及**因果 Transformer** (长程 token 依赖). 图 2 展示了一条主干.

合并跨域序列. 将部分域按时间戳交错合并为一条额外的跨域流, 使下游模块更容易学习跨域交互. 真实域加上合并流后, 下游序列数为 S .

局部混合: 逐深度 *Conv1d*. 轻量级逐深度 *Conv1d* 在局部窗口内混合每个通道, 以较低成本捕捉 **N-gram 模式** (突发行、相邻事件模式), 否则自注意力需要耗费容量重新学习这些模式.

信息过滤: *DIN* 风格条件 *SwiGLU*. 由用户、物品 LCB token 和 emb-cond 经 NCB 融合得到的逐样本复合**条件向量**, 仅进入 *SwiGLU* 的门控; 值路径仍是序列的纯函数. 该门控以 DIN 风格根据候选相关性选择位置, 而不改变其内容.

Token 依赖: 因果 *Transformer*. 全局编码器是带 RoPE 和因果窗口注意力 (窗口 w) 的浅层 **Transformer**, 通过融合




图 3: MultiChannelSeqPool (§4.4): 由独立的状态条件 sigmoid 权重将各位置门控到 C 个通道中。

注意力内核 (SDPA / FlashAttention) 按时间顺序建模 token 依赖。随后, 逐使用方的视图投影器 (Linear $\rightarrow$ LN $\rightarrow$ GELU) 输出 D 维视图 $\mathbf{H}^{(s)}$, 每隔 view-stride 层刷新一次。

4.4 逐层计算

每个宏层并行运行两条总线, 随后进行融合。

Token 混合总线。 总线状态 (拼接后的用户、物品与池化 token) 经过 W 个跨 token 块。该块是一个可替换槽位; 我们使用 **Wukong** (并行的 LCB + FMB 及残差, 其中 FMB 提供显式两两积)。我们也在该槽位评估了 TokenMixer 风格块 [13] 和 UniMixer [9], 但在我们的数据规模下均未超过 Wukong——二者可能都需要更多数据才能收敛。这是 UniDot 内部受控的槽位替换, 并非对这些架构进行匹配的端到端重训 (比赛预算下不在研究范围内), 因此我们仅将其视为当前规模下的指示性结果, 而非确定排名。层间会切除池化 token, 使持久状态保持为 $(T_u + T_i, D)$ 。

MultiChannelSeqPool。 对于 S 个序列视图中的每一个, 借鉴 NetVLAD / NeXtVLAD 多聚类软分配聚合 [1, 18] 的多通道池化器会生成 C 个池化 token。每个通道依据当前混合总线状态的摘要, 使用一个独立 sigmoid (而非 softmax) 对每个位置进行门控, 因此各通道可以独立激活, 而无需争夺固定的注意力质量; 每个池化 token 都是各位置的门控加权和。由于 sigmoid 门控会使幅值不受约束, 每个池化 token 都在 D 上进行 ℓ_2 归一化以恢复单位范数; 随后, $S \cdot C$ 个 token 在进入总线前经过一个 LayerNorm 尾部, 与带 NCB 尾部的画像 token 相匹配, 从而避免 token 混合系统性地降低其权重 (图 3)。

序列检索总线。 该总线的单历史、单层实例可还原为标准的单历史目标注意力 CTR 模块 [12]; 这里, 我们将其推广到 S 个域 (真实域 + 合并域)、逐层 query 和 FM-Highway 读出。对于包含 T_{ih} 个 token 的物品状态: (i) **逐序列交叉注意力—物品状态查询** S 个序列视图中的每一个 (无内部残差), 得到原始输出 $A_0, \dots, A_{S-1} \in \mathbb{R}^{B \times T_{ih} \times D}$; (ii) **LCB 聚合**— $\text{attn_agg} = \text{LCB}(\text{stack}(A_0, \dots))$, 采用线性形式, 因为下方的融合 FFN 已经提供非线性; (iii) **逐 token 融合 FFN**——一个小型 FFN 将每个物品 token 与该 token 从所有 S 个序列中检索到的向量进行混合, 产生施加在物品状态上的 D 维残差增量; 以及 (iv) **FM Highway 信号** (绕过融合, 在各层间拼接)——每一层贡献逐序列点积 $d_i[t] = \langle \text{item}[t], A_i[t] \rangle$ (候选与每个行为域之间的逐 token 亲和度)、一个学习得到的融合域点积 (在 S 个输出上执行 NCB, 再与物品状态点积)、聚合




图 4: FuseFFN (§4.4)。

$\text{Gram } G = \text{item} \cdot \text{attn_agg}^\top$ (完整的两两积矩阵), 以及在融合后计算的用户—物品交叉点积 (混合总线的用户 token 与检索总线的物品 token 之间的内积)。这些信号共同构成式 (2) 中的 ϕ^ℓ 。

总线级融合 (FuseFFN, 规范 MLP-Mixer [25])。 w_{out} 、池化结果和 h_{out} 三组沿 token 轴拼接, 随后依次经过一个 NCB token 混合 (跨 token 的非线性混合)、一个逐 token 的 SwiGLU 通道混合 (应用于每个 token, 权重在 token 间共享), 以及按侧设置、由逐层可学习门控缩放的零初始化投影, 从而在两条总线上产生残差增量 (图 4)。由于两侧投影为零初始化, 融合从恒等映射开始并通过学习逐步引入。

4.5 分类器读出

读出如式 (3) 所示。最终总线状态不会整体展平。压缩读出 ρ 包含两部分: (i) NCB 将拼接后的 $(T_u + T_i + T_{ih})$ 个总线 token 压缩为少量读出 token, 再将其展平; (ii) 追加一个交叉点积 Gram——在未压缩状态上计算混合总线 token 与检索总线 token 之间的全部两两内积——使压缩无法抹去显式二阶信号。分类器输入拼接 ρ 、跨层拼接的 FM Highway $[\phi^1; \dots; \phi^L]$ (逐序列点积、融合域点积、聚合 Gram、用户—物品交叉点积; 经 LayerNorm), 以及经 LayerNorm 的跳跃嵌入信号 e_{skip} (§C.5)。随后输入双层 MLP 和线性头; logit 截断至 $[-20, 20]$ 。一个辅助转化延迟头 (§C.6) 增加第二项损失。

4.6 多路径互学习

我们在同一批次上联合训练一个由两条 UniDot 路径组成的模型 [29, 34], 共享一套 (占主导的) 稀疏嵌入, 并在推理时平均两条路径的 logit (图 5)。其动机来自原始深度互学习工作 [34] 所揭示的正则化效应: 两条路径模仿彼此的预测并收敛到一个更宽、更平坦的极小值——即二者一致认可的稳健解; 这类平坦极小值对未见数据的泛化更好, 正符合我们的设置: 测试时段比训练时段向前一步, 且多数候选用户—物品对都是新的。我们在共享嵌入表上应用该方法。两条路径已能以 $2\times$ 的稠密成本获得大部分增益, 因此将其用于提交。

互学习目标。 令 z_n 为路径 n 的 logit, 并令 $p_n = \sigma(z_n)$ 。每条路径既由其自身预测上的任务损失监督, 也被拉向其他路


图 5: 多路径互学习 ($N=2$, §4.6)。

表 2: $d=128$, $N=2$ 多路径运行逐 epoch 的训练动态。
Eval/Test (sel.): 用于模型选择的运行(remote, 留出 10%)。
Test (final): 在全部数据上使用 EMA 重新训练的 final 提交。LL=LogLoss (训练时基于两条路径, 评估时基于二者均值); “—” = 未提交。

轮次	训练 AUC	评估 AUC	测试 (选择)	测试 (最终)	训练 LL	评估 LL
1	0.83193	0.84181	0.82772	—	0.43395	0.21259
2	0.84232	0.84441	0.83031	0.83036	0.42422	0.21113
3	0.84606	0.84558	0.83136	0.83143	0.42072	0.21058
4	0.84962	0.84607	0.83193	0.83195	0.41750	0.21029
5	0.85485	0.84629	0.83196	0.83217	0.41288	0.21048
6	0.86199	0.84568	—	0.83212	0.40679	0.21116

径停止梯度后的预测:

$$\mathcal{L} = \sum_{n=1}^N \left[\mathcal{L}_{\text{task}}(y, p_n) + \frac{\lambda}{N-1} \sum_{i \neq n} D(\text{sg}[p_i], p_n) \right], \quad (5)$$

其中, $\mathcal{L}_{\text{task}}$ 是 BCE (外加辅助延迟头, §C.6), $\text{sg}[\cdot]$ 表示停止梯度, D 是概率上的平方误差 $D(a, b) = (a - b)^2$ 。提交方案采用 $N=2$ 条路径, 互学习权重为 $\lambda=20$, 并在第一个 epoch 后启用互学习项。

服务。推理时, 我们对两条路径的 logit 取平均。若只部署单条路径, 成本仅为 $1\times$, 测试 AUC 已达 0.83184——仅比双路径均值 (0.83217) 低 0.033%——因此是一种可行的低成本部署方案, 而取均值可补回余下的小幅差距。

5 实验

数据集、实验设置和实现细节见附录 A–C; 此处报告结果。

5.1 主要结果

UniDot 最终获得亚军 (表 1), 测试 AUC 为 **0.83217**——这主要得益于带有 FM Highway (§4) 的统一双总线架构, 以及在深度、宽度和多路径互学习方面的扩展 (§5.4)。最终提交使用 EMA 权重在全部数据上重新训练, 并在 epoch 5 达到峰值 (表 2)。

5.2 增量改进

表 3 追踪了从竞赛基线到我们提交方案的测试 AUC, 每一行增加一项改动。最大的单次提升来自 UniDot 本身 (+1.10%); 后续改进 (FM-Highway 点积、深度卷积、辅助损失、FAFE、EMA)、稠密扩展以及多路径 DML 带来了其余提升, 总计 +1.82%。

表 3: 第二轮增量改进。

#	变更	测试 AUC	Δ
0	竞赛基线	0.81398	—
1	+ UniDot	0.82500	+1.102
2	+ 物品 ID 哈希嵌入	0.82565	+0.064
3	调整 token 数量	0.82609	+0.044
4	调整批量大小	0.82704	+0.095
5	+ 增加 FM-Highway 点积	0.82722	+0.018
6	+ 深度卷积前置主干	0.82736	+0.014
7	+ 辅助延迟损失	0.82812	+0.075
8	+ FAFE	0.82837	+0.026
9	调整学习率	0.82894	+0.056
10	+ EMA 权重	0.82993	+0.099
11	扩展 d_{model} 64→96	0.83024	+0.031
12	扩展 d_{model} 96→128	0.83043	+0.019
13	+ 多路径 DML ($d=64$)	0.83128	+0.085
14	多路径 DML ($d=128$)	0.83196	+0.068
15	+ 全数据重训练	0.83217	+0.021
相对基线的总增益			+1.818

表 4: 组件消融实验 (tiny 模式, 单路径, $d=64$; 同分布留出评估)。 Δ 表示相对于完整模型的 AUC。

变体	AUC $\uparrow$	LogLoss $\downarrow$	Δ AUC
完整 UniDot (6 层)	0.83657	0.2151	—
2 个宏层	0.83600	0.2157	−0.057%
4 个宏层	0.83603	0.2154	−0.054%
8 个宏层	0.83624	0.2152	−0.033%
10 个宏层	0.83615	0.2152	−0.042%
− FM Highway (全部)	0.83530	0.2159	−0.127%
− 仅跨总线点积	0.83570	0.2156	−0.087%
− 多通道序列池化	0.83624	0.2155	−0.033%
− token 混合总线 (恒等映射)	0.83590	0.2161	−0.067%
− FuseFFN (无总线融合)	0.83679	0.2154	+0.022%
− 序列交叉注意力	0.83604	0.2153	−0.053%
− 合并跨域流	0.83619	0.2152	−0.038%

5.3 组件消融实验

表 4 在 tiny 模式下移除各个组件 (单路径, $d=64$, 同分布留出集, 因此只有相对差距具有意义)。随着深度增加, 性能提升可持续到默认的 6 个宏层 (8–10 层在 4M 数据集上过拟合); 移除 FM Highway 的代价最大 (−0.127%); 移除序列交叉注意力的影响较小 (−0.053%), 因为多通道池化捕获了大量相同信号。

去除 FuseFFN 总线融合会使 AUC 略有上升 (+0.022%), 但 LogLoss 变差, 因此该模块的贡献尚无完全确定的结论。我们认为这并非否定跨总线交换的证据, 而是说明融合器设计尚不充分: 其静态路由是薄弱环节, 而输入条件化的 (二阶) 融合器是最明确的开放方向。

5.4 扩展研究

在本任务中, 有效的扩展轴是稠密容量, 而非稀疏容量 (表 5)。仅将嵌入宽度翻倍并未带来 A/B 收益——高基数表并非瓶颈。将稠密路径从 64 加宽到 96 再到 128, AUC 单调提升但收益递减 (累计 +0.050%)。在互蒸馏 (§4.6) 下加入第二条相同路径, 是利用稠密容量的更有效方式: 在 $d=64$ 处

表 5: 扩展研究。

配置	稠密参数	GFLOP	测试 AUC ↑	Δ
$d=64$, 稀疏 fold $\times 2$	18.8M	5.9	—	未胜出
$d=64$ (基线)	18.8M	5.9	0.82993	—
$d=96$	36.7M	12.4	0.83024	+0.031%
$d=128$	60.3M	21.2	0.83043	+0.050%
$d=64$, 双路径	37.6M	11.7	0.83128	+0.135%
$d=128$, 双路径	120.6M	42.5	0.83196	+0.203%

达到 +0.135%，超过整个宽度扫描的收益；它使稠密参数数量与 FLOPs 翻倍，但不增加嵌入表。两个轴可以组合：带两条路径的 $d=128$ 达到 0.83196（相比 $d=64$ 单路径基线提升 +0.203%），这是我们的提交方案；随后在全量数据上重训得到 0.83217。

6 结论

我们提出了 UniDot，这是一种新颖架构，可在单个可堆叠块中统一序列建模与特征交互：非序列字段与多域行为序列被转化为同一共享空间中的 token，并由并行的 token 混合总线和序列检索总线处理；两条总线共同演化，并在每一层通过规范的 MLP-Mixer 交换增量。其核心思想 **FM Highway** 绕过融合路径，将显式点积交互直接送往分类器，从而以可忽略的成本保留因子分解机式的二阶信号。UniDot 在 TAAC $\times$ KDD Cup 2026 挑战赛工业赛道中获得亚军，AUC 达到 **0.83217**——这一成绩来自统一架构、对该模块深度与宽度的扩展，以及基于共享嵌入的多路径互学习，而非特征工程。未来工作包括：在真实生产系统中部署 UniDot，并在该规模下系统研究统一模块的缩放定律。

参考文献

- [1] Relja Arandjelović, Petr Gronat, Akihiko Torii, Tomáš Pajdla, and Josef Sivic. 2016. NetVLAD: CNN Architecture for Weakly Supervised Place Recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*.
- [2] Zheng Chai, Qin Ren, Xijun Xu, Hua Chen, Xiao Zhang, Zhonggan Hu, Tianxiang Liang, Lei Wu, Lingzheng Zhou, Zhihao Yu, Yang Sun, and Junwei Pan. 2025. LONGER: Scaling Up Long Sequence Modeling in Industrial Recommenders. In *Proceedings of the 19th ACM Conference on Recommender Systems (RecSys)*. arXiv:2505.04421.
- [3] Jianxin Chang, Chenbin Zhang, Zhiyi Fu, Xiaoxue Zang, Lin Guan, Jing Lu, Yiqun Hui, Dewei Leng, Yanan Niu, Yang Song, and Kun Gai. 2023. TWIN: TTwo-stage Interest Network for Lifelong User Behavior Modeling in CTR Prediction at Kuaishou. In *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)*.
- [4] Qiwei Chen, Changhua Pei, Shanshan Lv, Chao Li, Junfeng Ge, and Wenwu Ou. 2021. End-to-End User Behavior Retrieval in Click-Through Rate Prediction Model. arXiv:2108.04468 [cs.IR].
- [5] Qiwei Chen, Huan Zhao, Wei Li, Pipei Huang, and Wenwu Ou. 2019. Behavior Sequence Transformer for E-commerce Recommendation in Alibaba. In *Proceedings of the 1st International Workshop on Deep Learning Practice for High-Dimensional Sparse Data (DLP-KDD)*.
- [6] Heng-Tze Cheng, Levent Koc, Jeremiah Harmsen, Tal Shaked, Tushar Chandra, Hrishikesh Aradhye, Glen Anderson, Greg Corrado, Wei Chai, Mustafa Ispir, et al. 2016. Wide & Deep Learning for Recommender Systems. In *Proceedings of the 1st Workshop on Deep Learning for Recommender Systems (DLRS)*.
- [7] Yufei Feng, Fuyun Lv, Weichen Shen, Menghan Wang, Fei Sun, Yu Zhu, and Keping Yang. 2019. Deep Session Interest Network for Click-Through Rate Prediction. In *Proceedings of the 28th International Joint Conference on Artificial Intelligence (IJCAI)*. arXiv:1905.06482.
- [8] Huifeng Guo, Ruiming Tang, Yunming Ye, Zhenguo Li, and Xiquiang He. 2017. DeepFM: A Factorization-Machine based Neural Network for CTR Prediction. In *Proceedings of the 26th International Joint Conference on Artificial Intelligence (IJCAI)*.
- [9] Mingming Ha, Guanchen Wang, Linxun Chen, Xuan Rao, Yuexin Shi, Tianbao Ma, Zhaojie Liu, Yunqian Fan, Zilong Lu, Yanan Niu, Han Li, and Kun Gai. 2026. UniMixer: A Unified Architecture for Scaling Laws in Recommendation Systems. arXiv:2604.00590.
- [10] Bojian Hou, Xiaolong Liu, Xiaoyi Liu, Jiaqi Xu, Yasmine Badr, Mengyue Hang, Sudhanshu Chanpuriya, et al. 2026. Kunlun: Establishing Scaling Laws for Massive-Scale Recommendation Systems through Unified Architecture Design. arXiv:2602.10016.
- [11] Tongwen Huang, Zhiqi Zhang, and Junlin Zhang. 2019. FiBi-Net: Combining Feature Importance and Bilinear Feature Interaction for Click-Through Rate Prediction. In *Proceedings of the 13th ACM Conference on Recommender Systems (RecSys)*.
- [12] Yunwen Huang, Shiyong Hong, Xijun Xiao, Jinqiu Jin, Xuan Luo, Zhe Wang, Zheng Chai, Shikang Wu, Yuchao Zheng, and Jingjian Lin. 2026. HyFormer: Revisiting the Roles of Sequence Modeling and Feature Interaction in CTR Prediction. arXiv:2601.12681.
- [13] Yuchen Jiang, Jie Zhu, Xintian Han, Hui Lu, Kunmin Bai, Mingyu Yang, Shikang Wu, Ruihao Zhang, Wenlin Zhao, Shipeng Bai, Sijin Zhou, Huizhi Yang, Tianyi Liu, Wenda Liu, Ziyang Gong, Haoran Ding, Zheng Chai, Deping Xie, Zhe Chen, Yuchao Zheng, and Peng Xu. 2026. TokenMixer-Large: Scaling Up Large Ranking Models in Industrial Recommenders. arXiv:2602.06563.
- [14] Keller Jordan, Yuchen Jin, Vlado Boza, Jiacheng You, Franz Cesista, Laker Newhouse, and Jeremy Bernstein. 2024. Muon: An optimizer for hidden layers in neural networks. Blog post. <https://kellerjordan.github.io/posts/muon/>
- [15] Yuchin Juan, Yong Zhuang, Wei-Sheng Chin, and Chih-Jen Lin. 2016. Field-aware Factorization Machines for CTR Prediction. In *Proceedings of the 10th ACM Conference on Recommender Systems (RecSys)*.
- [16] Yehuda Koren, Robert Bell, and Chris Volinsky. 2009. Matrix Factorization Techniques for Recommender Systems. *IEEE Computer* 42, 8 (2009), 30–37.
- [17] Jianxun Lian, Xiaohuan Zhou, Fuzheng Zhang, Zhongxia Chen, Xing Xie, and Guangzhong Sun. 2018. xDeepFM: Combining Explicit and Implicit Feature Interactions for Recommender Systems. In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD)*.
- [18] Rongcheng Lin, Jing Xiao, and Jianping Fan. 2018. NeXtVLAD: An Efficient Neural Network to Aggregate Frame-level Features for Large-scale Video Classification. In *Proceedings of the European Conference on Computer Vision (ECCV) Workshops*.
- [19] Jingyuan Liu, Jianlin Su, Xingcheng Yao, Zhejun Jiang, Guokun Lai, Yulun Du, Yidao Qin, Weixin Xu, Enzhe Lu, Junjie Yan, et al. 2025. Muon is Scalable for LLM Training. arXiv:2502.16982 [cs.LG].
- [20] Qi Pi, Quorui Zhou, Yujing Zhang, Zhe Wang, Lejian Ren, Ying Fan, Xiaoqiang Zhu, and Kun Gai. 2020. Search-based User Interest Modeling with Lifelong Sequential Behavior Data for Click-Through Rate Prediction. In *Proceedings of the 29th ACM International Conference on Information and Knowledge Management (CIKM)*.
- [21] Shashank Rajput, Nikhil Mehta, Anima Singh, Raghunandan Keshavan, Trung Vu, Lukasz Heldt, Lichan Hong, Yi Tay, Vinh Q. Tran, Jonah Samost, Maciej Kula, Ed H. Chi, and Maheswaran Sathiamoorthy. 2023. Recommender Systems with Generative Retrieval. In *Advances in Neural Information Processing Systems (NeurIPS)*.
- [22] Steffen Rendle. 2010. Factorization Machines. In *Proceedings of the 10th IEEE International Conference on Data Mining (ICDM)*.
- [23] Weiping Song, Chence Shi, Zhiping Xiao, Zhijian Duan, Yewen Xu, Ming Zhang, and Jian Tang. 2019. AutoInt: Automatic Feature Interaction Learning via Self-Attentive Neural Networks. In *Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM)*.
- [24] TAAC $\times$ KDD Cup 2026. 2026. Tencent Uni-Rec Challenge: Towards Unifying Sequence Modeling and Feature Interaction for Large-scale Recommendation. Competition website. <https://algo.qq.com>

- [25] Ilya Tolstikhin, Neil Houlsby, Alexander Kolesnikov, Lucas Beyer, Xiaohua Zhai, Thomas Unterthiner, Jessica Yung, Andreas Steiner, Daniel Keysers, Jakob Uszkoreit, Mario Lucic, and Alexey Dosovitskiy. 2021. MLP-Mixer: An all-MLP Architecture for Vision. In *Advances in Neural Information Processing Systems (NeurIPS)*.
- [26] Ruoxi Wang, Bin Fu, Gang Fu, and Mingliang Wang. 2017. Deep & Cross Network for Ad Click Predictions. In *Proceedings of the ADKDD'17*. arXiv:1708.05123.
- [27] Ruoxi Wang, Rakesh Shivanna, Derek Cheng, Sagar Jain, Dong Lin, Lichan Hong, and Ed Chi. 2021. DCN V2: Improved Deep & Cross Network and Practical Lessons for Web-scale Learning to Rank Systems. In *Proceedings of the Web Conference (WWW)*.
- [28] Siqi Wang, Xianjie Chen, Shaofeng Deng, Albert Chen, et al. 2026. SlimPer: Make Personalization Model Slim and Smart. arXiv:2607.12281 [cs.IR]
- [29] İbrahim Can Yılmaz and Said Aldemir. 2024. Mutual Learning for Finetuning Click-Through Rate Prediction Models. arXiv:2406.12087 [cs.IR]
- [30] Zhichen Zeng, Xiaolong Liu, Mengyue Hang, Xiaoyi Liu, et al. 2025. InterFormer: Effective Heterogeneous Interaction Learning for Click-Through Rate Prediction. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management (CIKM)*.
- [31] Jiaqi Zhai, Lucy Liao, Xing Liu, Yueming Wang, Rui Li, Xuan Cao, Leon Gao, Zhaojie Gong, Fangda Gu, Michael He, Yinghai Lu, and Yu Shi. 2024. Actions Speak Louder than Words: Trillion-Parameter Sequential Transducers for Generative Recommendations. In *Proceedings of the 41st International Conference on Machine Learning (ICML)*.
- [32] Buyun Zhang, Liang Luo, Xi Liu, et al. 2022. DHEN: A Deep and Hierarchical Ensemble Network for Large-Scale CTR Prediction. arXiv:2203.11014.
- [33] Buyun Zhang, Liang Luo, Xi Liu, Jay Li, Zeliang Chen, Weilin Zhang, Xiaohan Wei, Yuchen Hao, Michael Tsang, Wenjun Wang, Yang Liu, Huayu Li, Yasmine Badr, Jongsoo Park, Jiyan Yang, Dheevatsa Mudigere, and Ellie Wen. 2024. Wukong: Towards a Scaling Law for Large-Scale Recommendation. In *Proceedings of the 41st International Conference on Machine Learning (ICML)*.
- [34] Ying Zhang, Tao Xiang, Timothy M. Hospedales, and Huchuan Lu. 2018. Deep Mutual Learning. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. arXiv:1706.00384.
- [35] Zhaoqi Zhang, Haolet Pei, Jun Guo, Tianyu Wang, Yufei Feng, Hui Sun, Shaowei Liu, and Aixin Sun. 2025. OneTrans: Unified Feature Interaction and Sequence Modeling with One Transformer in Industrial Recommender. arXiv:2510.26104.
- [36] Guorui Zhou, Na Mou, Ying Fan, Qi Pi, Weijie Bian, Chang Zhou, Xiaoqiang Zhu, and Kun Gai. 2019. Deep Interest Evolution Network for Click-Through Rate Prediction. In *Proceedings of the 33rd AAAI Conference on Artificial Intelligence (AAAI)*. arXiv:1809.03672.
- [37] Guorui Zhou, Xiaoqiang Zhu, Chenru Song, Ying Fan, Han Zhu, Xiao Ma, Yanghui Yan, Junqi Jin, Han Li, and Kun Gai. 2018. Deep Interest Network for Click-Through Rate Prediction. In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD)*.
- [38] Haolin Zhou, Junwei Pan, Xinyi Zhou, Xihua Chen, Jie Jiang, Xiaofeng Gao, and Guihai Chen. 2024. Temporal Interest Network for User Response Prediction. In *Companion Proceedings of the ACM Web Conference (WWW Companion)*. arXiv:2308.08487.
- [39] Yifeng Zhou, Yuehong Hu, Zhixiang Feng, Junwei Pan, Kaihui Wu, Hanyong Li, Shangyu Zhang, Shudong Huang, Zhangbin Zhu, Chengguo Yin, Haijie Gu, and Jie Jiang. 2026. TokenFormer: Unify the Multi-Field and Sequential Recommendation Worlds. arXiv:2604.13737.

A 数据集

A.1 数据集

该挑战赛分两轮发布了一个由腾讯真实广告日志构建的大规模、完全匿名化的广告数据集；我们参加**工业赛道**。所有稀疏特征均为匿名整数 ID，所有稠密特征均为定长浮点向量；不发布任何原始内容或个人身份信息。表 6 汇总了数据模式。

表 6: 工业赛道数据集与模式（第二轮；括号内为第一轮）。

数量	工业赛道
训练 / 测试样本	35M / 12M (2M, r1)
列 (类别)	142 (7)
用户 Int / Dense fids	54 / 17
物品 Int / Dense fids	17 / 4
预训练嵌入 fids (u/i)	7 / 4
对齐的逐位置 fids	10
行为域	4 (9/14/12/10 fids)
高基数 ID (fid 116)	≈9.4M
标签 / 指标	转化 / AUC

表 7: 训练/评估模式。

模式	数据 (训练 / 评估)	GPU	用途
tiny	4M / 1M, 随机留出	1	快速设计 A/B
remote	35M / 10% 随机留出	4	全规模验证
final	35M / 无留出	4	提交 (EMA 权重)

每个样本都是一次用户-物品交互，包含两类输入：

- **非序列多字段特征**——**user_int** / **item_int** 类别 ID (单值与多值)，以及包含**预训练嵌入**的 **user_dense** / **item_dense** 连续向量 (例如，SUM 和 LMF4Ads 等用户侧嵌入，以及物品侧的物品嵌入)。
- 来自**四个域**、每个域含 9–14 个字段的**行为序列特征** (**seq_a** 至 **seq_d**)：每个域都是携带时间戳和动作类型、按时间排序的事件列表。

数据模式的两个性质直接影响模型设计。首先，若干 **user_dense** 数组与对应的 **user_int** 数组**逐元素对齐**：每个稠密值都是对应 ID 的逐元素统计量 (例如，停留时间或分数)，而非独立特征。UniDot 将其作为 ID 嵌入的**逐位置权重** (§C.2)，与其预期语义一致。其次，少数 ID 的基数极高 (fid 116 有 ≈9.4M 个取值)，因此采用 §C.5 中的跳跃嵌入处理。

B 实验设置

数据：TAAC × KDD Cup 2026 工业赛道 (35M 训练样本 / 12M 测试样本；第一轮为 2M)，转化标签。**指标**：ROC 的 AUC (官方指标)；我们也报告 LogLoss。**训练**：有效批量大小为 ≈3k (本地 A/B) / ≈12k (在线, 4 块 GPU)，双 Adagrad/Muon (稠密参数学习率 4e-4, Muon 权重衰减 1e-3, 稀疏参数学习率 0.1)，100 步预热, BCE + 辅助延迟损失 ($\lambda=0.01$)，并使用 **torch.compile** 和 bf16 自动混合精度。**模型**：表 8 所示的提交配置 (≈2.1B 参数, $d_{\text{model}}=128$, $N=2$ 多路径)。**推理**：部署模型使用 **torch.compile** 和 bf16 自动混合精度。在包含 12M 样本的测试集上进行端到端推理与评估—包括一次性编译—双路径模型耗时 ≈14,500s，单路径耗时 ≈7,200s (约为一半)，均处于竞赛推理预算内。bf16 自动混合精度仅造成轻微的 AUC 下降 (< 0.0001)。

训练与评估模式。我们使用三种模式 (表 7)：**tiny** 在单块 GPU 上将数据限制为随机选取的 4M 训练 / 1M 评估子集，用于快速 A/B 比较设计选择；**remote** 将保留下来的配置扩展到 4 块 GPU 上的完整数据集并采用留出划分，以确认收




图 6: 字段感知特征嵌入 (FAFE, §C.3): DIN 式注意力池针对排序候选为多值字段的每个值打分, 得到依赖候选的字段 token; 所有其他字段仍使用静态 NCB 池化。

益在全规模下仍然成立; **final** 在全部数据上重新训练, 并部署 EMA 权重用于提交。

C 实现与训练细节

下述组件大多独立于核心架构 (§4) — 它们属于数据特定的特征处理与训练机制 — 因此我们在此集中介绍。它们对于复现所报告的结果至关重要。

C.1 启用的配置

表 8 将 §4 中的每个符号解析为其提交取值。token 预算为: 用户侧 $T_u = 8 + 7 \cdot 2 = 22$ 个 token (8 个 NS token, 加上每个投影用户嵌入 fid 对应 2 个), 物品侧分别为 $T_i = 4 + 4 \cdot 2 = 12$ 和 $T_{ih} = 16 + 4 \cdot 2 = 24$ 个 token, 并有 $S = 4 + 1 = 5$ 条序列 (四个行为域加合并流); fid 轴压缩使每个位置具有统一的 $4 \cdot 128 = 512$ -d 宽度。参数总量为 ≈ 2.1 B, 但主要来自嵌入 (稀疏查找); 稠密计算路径仅有数千万参数。由于逐 fid 嵌入表的宽度为 d_{model} , 将 d_{model} 从 64 扩展到 128 会使占主导地位的嵌入参数量大致翻倍。

C.2 逐位置权重 (user_dense 配对)

§A 中的十个 **user_dense** 数组并非特征, 而是**逐位置乘数**。每个数组都与编号相同的多值 **user_int** fid 逐位置对齐 (长度相同), 并在池化前缩放该 ID 的嵌入, 因此每个值的贡献都由与其配对的统计量 (例如, 停留时长或交互次数) 加权。两类 fid 采用不同处理方式。**计数类** fid (62–66、118、121) 经过固定的 $\log(1+x)/10$ 变换——对数抑制长尾, /10 将其映射到约为单位尺度的范围——再乘以对应嵌入。**相似度类** fid (89–91, 有符号余弦值/分数值) 则被**截断**到 $[-1, 1]$, 并直接用作有符号乘数, 因此负亲和度可以减去某个值的嵌入。两种变换都使用固定 (不可学习) 常数, 因此在 §C.7 的冷重启重新初始化之间, 加权保持稳定。

C.3 字段感知特征嵌入 (FAFE)

少数高价值的多值 **user_int** 字段——fid 15、63–66、115–118、121、122 (行为 ID 列表)——采用**候选感知**池化, 而非静态池化: DIN 式注意力池针对排序候选为列表中的每个值打分 (图 6), 因此字段的池化嵌入对每个候选而言都是其各取值的不同组合。其余字段使用 §4.2 的静态 NCB 池化。这样可将候选感知能力集中到收益显著的大型行为 ID 列表上, 同时避免让整个 tokenizer 目标感知化所造成的性能退化。

C.4 预训练嵌入的投影与归一化

预训练稠密向量 (用户: SUM、LMF4Ads、...; 物品嵌入) 经由独立路径输入。**归一化**。其中具有长尾分布的计数维度首先使用在训练集上一次性估计的**固定统计量** (而非逐批统计量) 标

准化为零均值、单位方差, 因此推理时采用相同尺度, 投影器也不会因长尾而失稳。**投影**。每个归一化向量由两层 (Linear–GELU–Linear) MLP 映射为若干个 d 维 token, 随后由**逐 token 共享的 LayerNorm** 将其调整为单位尺度——与末尾采用 LayerNorm 的 NCB token (§4.2) 匹配, 从而避免总线 token 混合系统性地降低嵌入 token 的权重。所得 token 被迫加到用户/物品 token 集。

结构化子向量嵌入。一个预训练 fid (LMF4Ads, 320-d) 并非单一向量, 而是由 10 个分别经过 **L2 归一化** 的 32-d 子向量拼接而成, 每个子向量要么是单位向量, 要么全为零 (填充)。若将其展平为一个 320-d 输入并应用上述 MLP, 会模糊这种分块结构并混合各个独立归一化的子空间, 因此该 fid 使用**结构化 tokenizer**: 重塑为 10×32 , 使用共享线性映射将每个 32-d 槽位提升为一个 token, 屏蔽零填充槽位 (仅当槽位范数非零时才视为存在, 以免空槽位的偏置泄漏), 然后用 LCB 将 10 个槽位 token 压缩到与扁平路径相同的逐 fid token 数 (其末尾 LayerNorm 产生单位方差 token)。所有其他嵌入 fid (例如, SUM, 一个整体归一化的 256-d 嵌入) 仍使用扁平 MLP 投影。

C.5 高基数跳过嵌入

超过阈值 (2M) 的 fid 从逐 fid 路径中移出, 改由共享 **hash** (哈希技巧) 表处理。其池化信号也直接输入分类器 (式 (3) 中的 e_{skip}), 并在冷重启时重新初始化。物品 ID fid 还配有专用的 2M 槽位乘法哈希表, 其嵌入输入物品 tokenizer。

C.6 辅助转化延迟头

一个专用主干与头在 MSE 损失下回归 $\log(1+(t_{\text{label}}-t_{\text{event}}))$, 即距用户下一次动作的延迟。掩码为 $t_{\text{label}} > t_{\text{event}}$ (存在下一次动作), 因此它同时覆盖下一次点击但未转化和转化样本——几乎涵盖所有行, 而非仅 $\sim 12\%$ 的正例, 辅助信号约增加 $\sim 8\times$ 倍。它贡献式 (4) 中的 λL_{delay} 项 ($\lambda=0.01$)。

C.7 优化与训练

双优化器。嵌入参数使用 **Adagrad** (稀疏梯度)。稠密参数进一步拆分: ≥ 2 D 矩阵权重使用 **Muon** [14] (**Moonshot 变体** [19], 它加入解耦权重衰减, 并重新缩放正交化更新以匹配 AdamW 的更新 RMS, 使针对 AdamW 调优的学习率无需单独搜索 Muon 学习率即可迁移; 权重衰减为 $1e-3$), 而一维参数 (LayerNorm 缩放、偏置) 进入 **AdamW 辅助组** (权重衰减为 0)。二者共享线性学习率预热, 并可选择在每个冷重启边界衰减。**冷重启**: 从第二个 epoch 起, 在每个 epoch 边界, 将基数超过阈值的嵌入表——启用配置中为所有表 (阈值 0)——连同其 Adagrad 状态一起重新初始化, 而稠密参数保持不变: 骨干跨 epoch 持续训练, 嵌入则在每个 epoch 重新学习, 这一正则化方式与训练/测试间向前一步的时间差相匹配。每次重新初始化后, 稠密学习率都会**重新预热** (第二套预热计划), 让重新学习的嵌入先趋于稳定, 再恢复全速更新。**时间分桶**: 连续时间差 $t_{\text{now}} - t_{\text{event}}$ 映射到 64 个嵌入槽位 (0 = 填充), 边界覆盖 ≈ 1 s 至 ≈ 1.5 years, 并将容量集中在 1h–18 month 区间 (近期加权网格)。**Logit 截断**: 前向 logit 被截断到 $[-20, 20]$ 。**EMA 权重**: 我们跟踪稠密参数的指数移动平均 (衰减 0.999); 若有留出划分, 则每个 epoch 发布实时权重与 EMA 权重中在该划分上得分更高者, 而最终全数据提交使用 EMA 权重。每个重新初始化后的预热窗口内, EMA 都会被重置为实时权重, 避免高方差的重新预热步骤污染平均值。

表 8: 产生所报告结果的提交配置。

分组	设置
宏层 L / 每层混合块数 W	6 / 2
d_{model}	128
Token 混合块	Wukong (并行 LCB + FMB, 秩 32)
用户 NS / 用户嵌入 token	8 / 2 ($\times 7$ 个 fid) $\Rightarrow T_u = 22$
物品 NS token (混合/检索总线)	4 / 16 (+ 4 个嵌入 fid $\times 2$) $\Rightarrow T_i = 12, T_{ih} = 24$
融合/分类器隐藏维度倍数	4 / 8
序列近期窗口	a:256 b:256 c:512 d:512
合并流	abcd:512 ($\Rightarrow S = 5$)
序列 fid 压缩 token	4 ($\rightarrow$ 每位置 512-d)
DIN 条件 token (用户/物品/嵌入/融合)	2 / 4 / 1 / 4
主干编码器	Transformer, 1 层, 4 个头, 因果, 窗口 $w=128$, RoPE
主干前编码器 (逐域. + 合并)	深度 Conv1d, 核 21
视图投影	Linear $\rightarrow$ LN $\rightarrow$ GELU, 视图步幅 1
FuseFFN 增量门	sigmoid($\cdot$), 初值 0.5
分类器读出	NCB 压缩至 4 个 token + 交叉点积 Gram
跳过嵌入阈值/类型/槽位	2M / hash / 2M
物品 ID 哈希表	2M 个槽位
稠密优化器	Muon (wd $1e-3$); 稀疏: Adagrad
损失	BCE; 辅助延迟 ($\lambda=0.01$)
多路径 (DML)	$N=2$ 条路径, 共享稀疏嵌入
互学习损失/权重	MSE / $\lambda=20$ (从 epoch 1 起)
参数量	$\approx 2.1\text{B}$ (以嵌入为主)




图 7: 数据缩放 (tiny 模式, 单路径 $d=64$): 留出集 AUC (左, 蓝色) 与 LogLoss (右, 红色) 随训练样本数 ($\log_2$ 轴) 的变化。二者在完整的 4M–32M 范围内均呈对数线性改善。

D 数据缩放研究

作为模型缩放研究 (§5.4) 的补充, 我们在保持模型为 **tiny** 配置 (单路径 $d=64$) 不变的情况下扩展训练数据, 仅改变训练样本上限。留出集 AUC 随数据量呈**对数线性**增长——0.83657 (4M)、0.83899 (8M)、0.84187 (16M)、0.84396 (32M), 每翻倍约提升 +0.0025 AUC——LogLoss 也同步下降 (0.2151、0.2139、0.2125、0.2115); 见图 7。这一干净且贯穿完整 32M 范围、未中断的对数线性趋势表明, 统一模块对数据需求很大, 尚未饱和, 也由此推动后续生产部署与缩放定律研究。