

UniFormer：面向工业推荐的高效统一模型中心扩展框架

Bo Chen*, Jinlong Jiao*, Tijian Hu*, Ruihao Zhang, Yanzhi Liu, Chenghou Jin, Qinglin Jia, Baixuan He, Hechang Pan, Yiwu Liu, Jian Liang, Chaoyi Ma†, Ruiming Tang†, Han Li, Kun Gai

Kuaishou Technology

Beijing, China

{renze03,jiaojinlong,hutijian,machaoyi03,tangruiming}@kuaishou.com

摘要

近年来，以组件为中心的模型扩展推动了工业推荐领域的显著进展：行为建模、特征交互或任务建模等单个组件被分别扩展，以提升模型容量。尽管 HyFormer 和 OneTrans 等近期方法通过联合建模行为与交互，进一步探索了跨模块协同扩展，但其设计仍局限于特征空间，缺少覆盖整体建模空间的统一模型中心扩展框架。本文提出 **UniFormer**，一种面向工业推荐系统的高效统一模型中心扩展框架。为提高效率，UniFormer 将整体建模空间分解为特征空间和任务空间，并分别通过堆叠的特征空间交互模块与任务空间交互模块进行建模。此外，UniFormer 引入基于语义的分词方案，实现用户—物品解耦，从而获得请求级推理加速。为防止偏好坍塌，UniFormer 使用多序列交叉注意力分别捕获异构行为模式，随后利用自注意力增强交互建模。此外，模型还引入专用的多视图 FFN，以支持不同建模组件之间灵活且可扩展的参数扩展。在 Kuaishou 和 Kuaishou Lite 两个生产场景中的大规模在线 A/B 测试表明，UniFormer 能持续改善用户参与度和交互指标，App Stay Time 分别提升 +0.101%/+0.260%，Watch Time 分别提升 +0.729%/+1.113%。

CCS 概念

• Information Retrieval → Tagging Systems.

关键词

Scaling Law, Feature Interaction, Recommender Systems

1 引言

工业推荐系统利用用户的终身行为历史和异构特征（例如用户画像与物品元数据），估计各种用户—物品交互的效用。例如，短视频分享平台（例如 Kuaishou 和 TikTok）会预测多种用户反馈，如点击、点赞、分享、评论和完播，以决定最终的视频曝光 [32, 40]。为应对这种复杂性，工业推荐模型通常在嵌入层之上构建若干模块化组件：用于提取序列模式的行为建模模块 [35, 36]、用于建模跨特征依赖关系的特征交互模块 [3, 8, 24]，以及用于多目标优化的任务建模模块 [19, 22, 37]。为此，研究者开发了多种碎片化的手工设计算子 [28]。这些专用设计虽能有效提升预测性能，却增加了模型优化的复杂度，并限制了计算资源的高效利用 [30, 31]。

大语言模型（LLM）的卓越成功证明了模型扩展在获得更优性能方面的有效性 [17]，从而推动工业推荐系统扩大模型容量 [15, 16]。在特征空间的模型扩展方面，LONGER [1] 和 STCA [6] 等基于 Transformer 的架构改进长序列行为建模，而 HHFT [29] 和 RankMixer [40] 则通过自注意力或 token-mixing 算子扩展特

* 同等贡献。

† 通讯作者。




Figure 1: 代表性扩展方法的比较。(a)–(c) 展示以组件为中心的扩展范式；(d)–(e) 在特征空间内联合建模序列行为与特征交互；(f) 本文方法提出统一的协同扩展框架，实现序列行为、非序列特征与任务之间的高效协同扩展。

征交互容量。与此同时，SMES [32] 等基于 MoE 的方法在任务空间中借助可扩展专家增强多任务建模。尽管这些方法行之有效，但它们主要遵循图 1(a)–(c) 所示的组件中心扩展范式，这限制了计算资源的高效利用，也使模型无法充分获得整体扩展带来的收益。

因此，为充分释放模型扩展在推荐中的潜力，扩展范式应当从以组件为中心的扩展转向以模型为中心的扩展。OneTrans [33] 和 MixFormer [10] 等近期研究已初步尝试探索跨模块协同扩展。然而，这些方法仍主要局限于特征空间（如图 1(d)–(e) 所示），仅联合扩展行为建模和特征交互，而对任务建模的探索不足。

要实现高效统一的模型中心扩展，需要解决若干关键挑战。首先，工业推荐系统具有大量特征和任务，并要求高并发、低延迟服务，因此统一协同扩展模型必须保持较高的训练与推理效率，以缓解模型容量扩展带来的资源开销 [39]。其次，统一协同扩展模型应有效捕获异构用户行为以及短期和长期兴趣，确保全面个性化并防止偏好坍塌 [38]。第三，统一协同扩展模型应支持灵活且可扩展的参数分配，使不同组件的容量得以均衡发展，并避免参数过度集中于某个模块 [9, 40]。

为应对上述挑战，我们提出面向工业推荐系统的高效统一模型中心扩展框架 **UniFormer**。具体而言，为提升效率，UniFormer 将统一架构分解为特征空间交互（FIM）和任务空间交互（TIM），如图 1(f) 所示。前者扩展对序列与非序列特征的建模，后者捕获高阶特征与任务特定信号之间的交互。通过省略代价高昂的序列内部交互（类似 OneRec-v2 [34] 的惰性设计原则）以及序列

与任务之间的交互，UniFormer 显著提高了效率。此外，本文提出基于语义的分词方案，在推理期间实现用户—物品解耦，并获得请求级推理加速。为防止偏好坍塌，FIM 使用多序列交叉注意力机制分别建模异构行为序列，随后通过自注意力增强特征空间内的交互建模。此外，为实现灵活且可扩展的参数分配，UniFormer 分别为序列特征、非序列特征和任务信号引入多视图前馈网络 (FFN)，从而支持均衡的容量扩展。

综上，本文的主要贡献如下：

- 我们主张推荐模型从组件中心扩展转向模型中心扩展，并系统识别了构建高效统一扩展框架所面临的关键挑战。
- 我们提出高效统一的模型中心扩展框架 UniFormer，该框架集成特征空间交互 (FIM) 和任务空间交互 (TIM) 模块，利用标准化注意力算子和多视图 FFN 增强建模容量，同时实现灵活且可扩展的参数分配。
- 我们在 Kuaishou 工业推荐场景中开展了大规模离线实验与分析，验证了 UniFormer 的有效性。此外，在 Kuaishou 和 Kuaishou Lite 两个生产场景中的在线 A/B 测试显示，用户参与度和交互指标均获得稳定提升。

2 相关工作

2.1 扩展之前的推荐模型

基于深度学习的推荐模型通常包含两大组件：稀疏嵌入表和稠密神经网络 (DNN)。在模型扩展之前，大部分参数集中于稀疏嵌入表，而 DNN 相对轻量，形成了典型的稀疏嵌入主导型设计 [8, 14, 21, 24]。稠密建模部分则进一步以模块化方式构建，行为建模、特征交互和任务建模组件彼此独立设计。因此，性能改进主要来自组件级架构创新，而非稠密建模容量的扩展。

行为建模旨在从历史交互序列中捕获用户兴趣。DIN [36] 和 DIEN [35] 利用注意力机制建模用户行为与目标物品之间的相关性。为建模用户的终身兴趣，SIM [20] 和 TWIN [2] 等基于检索的方法从长行为序列中检索最相关的行为子序列。相比之下，VISTA [4] 和 C-Former [26] 采用基于压缩的范式提取紧凑的兴趣表示，从而高效建模用户的终身偏好。在特征交互建模方面，DeepFM [8]、DCN [24]、EENet [28] 及其多种扩展通过内积、外积和注意力机制等不同交互算子，捕获异构特征之间的关系。这些模型通过在表示空间中显式或隐式建模高阶特征交互来提升推荐性能。在任务建模方面，MMoE [19]、PLE [22] 和 HoME [25] 等多任务推荐模型设计了多种任务共享与任务特定网络架构，在多个目标之间平衡知识共享和任务专门化，从而提升整体多任务学习能力。尽管这些模型行之有效，但它们主要独立优化单个模块，并依赖规模相对较小的 DNN，尚未探索跨不同模块的参数扩展 [30, 31]。

2.2 推荐模型扩展

近年来，大语言模型 (LLM) 的参数扩展在世界知识和推理方面展现出显著的涌现能力，推动推荐模型向扩展范式演进。近期推荐架构主要关注以组件为中心的扩展。LONGER [1] 和 STCA [6] 等基于 Transformer 的架构增强长序列行为建模，而 HHFT [29] 和 RankMixer [40] 通过自注意力或 token-mixing 机制建模特征交互。SMES [32] 等基于 MoE 的方法则为多任务学习引入可扩展专家。

为统一建模序列与非序列特征，OneTrans [33] 和 TokenFormer [39] 在整个特征空间上采用自注意力架构。它们还引入金字塔式渐进收缩和滑动窗口注意力，以降低计算开销。此外，HyFormer [11]、MixFormer [10]、HeMix [23] 和 EST [18] 等工作设计了更高效的交互范式：通过轻量级交叉注意力建模序列与非序列特征之

间的交互，并通过 token mixing 或自注意力处理特征交互，从而避免完整自注意力带来的巨大计算成本。然而，现有统一协同扩展推荐模型主要关注特征空间交互建模，对跨特征空间与任务空间的统一建模探索有限。

3 预备知识

基于深度学习的工业推荐模型通常由若干模块化组件构成，包括嵌入 (即分词) 层、行为建模模块、特征交互模块和任务建模模块 [7, 32]。给定输入特征 $\mathbf{x}$ ，嵌入层生成稠密表示 $\mathbf{e} = \phi(\mathbf{x})$ [7]。整个过程可形式化为：

$$\mathbf{y} = \mathcal{F}_{\text{task}} \left(\mathcal{F}_{\text{interaction}} \left(\mathcal{F}_{\text{behavior}} (\mathbf{e}_{\text{seq}}, \mathbf{e}_{\text{non-seq}}), \mathbf{e}_{\text{task}} \right) \right), \quad (1)$$

其中， $\mathcal{F}_{\text{behavior}}(\cdot)$ 、 $\mathcal{F}_{\text{interaction}}(\cdot)$ 和 $\mathcal{F}_{\text{task}}(\cdot)$ 分别表示行为建模 (例如 DIN 和 SIM) [20, 36]、特征交互 (例如 DeepFM 和 DCN) [3, 8, 24] 以及任务建模函数 (例如 MMoE 和 PLE) [19, 22, 27]。尽管这些模块行之有效，但它们通常彼此独立设计，形成碎片化架构，限制了跨模块交互与统一建模 [30, 31]。

近年来，随着大语言模型 (LLM) 的快速发展和计算能力的显著提升，模型扩展已成为推动各领域涌现强大能力的关键因素。受这一趋势启发，推荐模型也开始探索扩展策略。然而，这些方法主要关注特征建模空间内的扩展 [10, 33, 40]，忽略了任务建模在扩展范式中的作用。为解决这一局限，我们提出一种超越特征空间、并将任务建模作为核心组件纳入其中的统一扩展框架：

$$\mathbf{y} = \mathcal{F}_{\text{co-scaling}} \left(\mathbf{e}_{\text{seq}}, \mathbf{e}_{\text{non-seq}}, \mathbf{e}_{\text{task}} \right). \quad (2)$$

通过以统一方式联合扩展序列行为建模、特征交互和任务建模，本文方法实现了表达能力更强、效率更高的表示学习。

4 方法

本节首先介绍所提出模型 UniFormer 的整体架构，随后详细阐述词元化与统一交互这两个关键组件，最后介绍 UniFormer 的优化与部署。

4.1 整体架构

图 2 展示了所提出的统一协同扩展框架 UniFormer，其包含两个核心组件：词元化模块与统一交互模块。词元化模块通过特征分组和投影，将输入层的序列特征、非序列特征及任务相关特征转换为紧凑的词元表示。为避免在整个空间内使用全注意力建模交互所带来的高昂计算开销 (以 OneTrans 为代表)，并实现高效的模型中心协同扩展，UniFormer 将整体建模空间解耦为特征空间和任务空间，分别由堆叠的特征空间交互模块 (Feature-space Interaction Modules, FIMs) 与任务空间交互模块 (Task-space Interaction Modules, TIMs) 进行建模。每个模块均采用由注意力层和 FFN 构成的标准 Transformer 风格架构，从而在保持计算效率的同时支持可扩展的参数分配。

4.2 词元化

4.2.1 序列特征. 根据对目标物品的依赖关系，用户行为序列特征可分为两类。第一类是物品无关行为，包括短期交互序列和长期压缩兴趣表示 (例如，C-Former [26])。第二类是物品相关行为，例如候选感知的检索序列 (例如，SIM [20])。为有效建模这些异构模式，我们设计了不同的词元化策略。

对于**物品无关行为**，我们保留原始序列结构，并对序列中的每个元素分别进行词元化。对于短期交互序列，第 i 个元素通过拼接物品的辅助信息来表示，例如视频 ID 嵌入 $\mathbf{e}_i^{\text{pid}}$ 、内容类




Figure 2: UniFormer 的整体架构，包含词元化和统一交互模块两个核心组件。统一交互模块由堆叠的特征空间交互模块（FIM）和任务空间交互模块（TIM）构成。FIM 以词元化后的序列特征和非序列特征为输入，通过注意力层和 FFN 层捕获特征空间交互。TIM 进一步接收 FIM 生成的高阶表示以及词元化后的任务特征，并采用相同的标准化算子捕获任务-特征交互与任务间交互。

型 $\mathbf{e}_i^{\text{tag}}$ 、创作者信息 $\mathbf{e}_i^{\text{paid}}$ 、观看时长 $\mathbf{e}_i^{\text{duration}}$ 等，由此形成词元表示 $\mathbf{e}_i^{\text{short}} = [\mathbf{e}_i^{\text{pid}} || \mathbf{e}_i^{\text{tag}} || \mathbf{e}_i^{\text{paid}} || \mathbf{e}_i^{\text{duration}} || \dots]$ 。对于长期压缩兴趣表示，我们直接保留每个词元的预训练嵌入而不作进一步修改，即 $\mathbf{e}_i^{\text{long}} = \mathbf{e}_i^{\text{pretrained}}$ 。

随后，遵循 OneRec-v2 [34]，通过 SwiGLU 层 [12] 将不同序列中的每个表示 $\mathbf{e}_i$ （即 $\mathbf{e}_i^{\text{short}}$ 或 $\mathbf{e}_i^{\text{long}}$ ）投影到统一的隐藏空间，得到 $\mathbf{z}_i \in \mathbb{R}^{d_{\text{seq}}}$ ，其维度为：

$$d_{\text{seq}} = S_{\text{kv}} \cdot L_{\text{kv}} \cdot d_{\text{model}}, \quad (3)$$

其中， S_{kv} 为键值拆分系数， L_{kv} 为键值层数。 $d_{\text{model}} = G_{\text{kv}} \cdot d_{\text{head}}$ ，其中 G_{kv} 为键值头数量， d_{head} 为注意力头维度。

表示 $\mathbf{z}_i$ 随后被进一步转换为供后续注意力机制使用的逐层键值对，得到 $[\mathbf{C}_i^0, \mathbf{C}_i^1, \dots, \mathbf{C}_i^{S_{\text{kv}} \cdot L_{\text{kv}} - 1}]$ ，其中 $\mathbf{C}_i^j \in \mathbb{R}^{d_{\text{model}}}$ 。对于第 l 层，归一化后的键值对 [34] 计算如下：

$$\mathbf{k}_i^{(l)} = \text{RMSNorm}_{k,l}(\mathbf{C}_i^{S_{\text{kv}} \cdot l})$$

$$\mathbf{v}_i^{(l)} = \begin{cases} \mathbf{k}_i^{(l)}, & \text{若 } S_{\text{kv}} = 1 \text{ (共享键值)} \\ \text{RMSNorm}_{v,l}(\mathbf{C}_i^{S_{\text{kv}} \cdot l + 1}), & \text{若 } S_{\text{kv}} = 2 \text{ (独立键值)}. \end{cases} \quad (4)$$

最终，短期序列与长期序列的输出结果分别为 $(\mathbf{K}_{\text{short}}, \mathbf{V}_{\text{short}})$ 和 $(\mathbf{K}_{\text{long}}, \mathbf{V}_{\text{long}})$ 。

对于**物品相关行为**（例如 SIM [20]），我们对序列进行聚合，而不保留原始序列结构。其核心动机是使交叉注意力中的键值表示与目标物品无关，从而实现请求级推理加速（见第 4.4.2 节）。具体而言，对于基于检索的序列，我们采用目标注意力词元化

器，将序列聚合为一个紧凑词元：

$$\mathbf{e}_{\text{search}} = \text{TA}(\mathbf{e}_{\text{target}}, \mathbf{K}_{\text{search}}, \mathbf{V}_{\text{search}}), \quad (5)$$

其中， $(\mathbf{K}_{\text{search}}, \mathbf{V}_{\text{search}})$ 为检索序列的键值对，其生成过程与上述序列相同（式 (4)）。

4.2.2 非序列特征. 对于非序列特征，我们同样根据其对于目标物品的依赖关系将其分为两类：**物品无关特征**（例如，用户 ID、用户画像特征和请求上下文特征）以及**物品相关特征**（例如，物品 ID、物品统计特征和用户-物品交叉特征）。在每一类内部，再根据语义对特征进一步分组，最终得到 m 个物品无关特征组和 n 个物品相关特征组。值得注意的是，物品相关行为（例如 SIM [20]）也被视作物品无关特征，并按照式 (5) 聚合为单个特征组（即 $\mathbf{e}_{\text{search}}$ ）。对于每个特征组，首先拼接相应的特征嵌入，再通过 SwiGLU 层将其投影到维度为 d_{model} 的统一隐藏空间，记为 $\mathbf{N}_{\text{NS}} \in \mathbb{R}^{q \times d_{\text{model}}}$ ，其中 $q = m + n$ 。

采用语义分组而非全局分组 [11] 的原因有两点。首先，语义分组将计算拆分为与用户请求相关的部分和与候选物品相关的部分。前者可在每次请求中仅计算一次并在候选物品之间复用，从而显著提升推理效率。具体实现将在第 4.4.2 节讨论。其次，后续交互通过对序列特征执行交叉注意力来建模，语义分组后的查询提供了多个异构视角，使模型能够从行为序列中提取多样化的用户偏好（见第 5.5.1 节）。

4.2.3 任务特征. 对于每个任务，将任务专属特征（例如，任务 ID、任务相关偏置特征）组合成一个词元。类似地，先拼接这

些嵌入，再通过 SwiGLU 层将其投影为 d_{model} 维的隐藏空间表示，得到 $\mathbf{N}_T \in \mathbb{R}^{t \times d_{\text{model}}}$ ，其中 t 为任务数量。

4.3 统一交互模块

统一交互模块联合集成了 M 层特征空间交互模块 (FIM) 和 N 层任务空间交互模块 (TIM)：前者用于建模序列特征与非序列特征之间的交互，后者用于捕获高阶特征与任务之间的交互，从而实现特征空间与任务空间的统一协同扩展。

4.3.1 特征空间交互模块. 特征空间交互模块 (FIM) 旨在捕获特征空间内的交互模式。它包含两个互补组件：面向序列的交互组件和面向非序列的交互组件。

面向序列的交互. 为在保留用户短期和长期兴趣的同时，从用户行为序列中有效提取信息信号，我们提出多序列交叉注意力机制，而不是对拼接后的异构序列应用共享交叉注意力层。其核心动机是避免偏好向某个特定序列坍缩 [38]，使模型能够保留来自异构行为序列的多样化、多视角兴趣。

以短期序列为例，在第 l 层中，以上一层输出词元作为查询，执行带残差连接的交叉注意力：

$$\mathbf{H}_{\text{short}}^{\text{feat},(l)} = \text{CA} \left(\text{RMSNorm}(\mathbf{Q}_{\text{cross}}^{\text{feat},(l-1)}), \mathbf{K}_{\text{short}}^{(l)}, \mathbf{V}_{\text{short}}^{(l)} \right) + \mathbf{Q}_{\text{cross}}^{\text{feat},(l-1)}, \quad (6)$$

其中， $\mathbf{Q}_{\text{cross}}^{\text{feat},(l-1)} \in \mathbb{R}^{q \times d_{\text{model}}}$ 表示查询词元， $(\mathbf{K}_{\text{short}}^{(l)}, \mathbf{V}_{\text{short}}^{(l)})$ 是由短期行为序列得到的第 l 层表示。受 OneRec-v2 [34] 中惰性解码器设计的启发，交叉层中的键值 (KV) 映射同样遵循惰性设计原则。默认情况下，我们设置 $S_{\text{kv}} = 1, L_{\text{kv}} = 1$ ，使所有层共享相同的 KV 表示，从而显著降低内存占用并提高计算效率。具体而言，在第一层中，使用来自词元化模块的 q 个语义分组词元作为查询，与多个行为序列交互，即 $\mathbf{Q}_{\text{cross}}^{\text{feat},(0)} = \mathbf{N}_{\text{NS}} \in \mathbb{R}^{q \times d_{\text{model}}}$ ，从而从异构行为来源中提取多样且互补的信息。值得注意的是，为稳定训练，我们还采用了 Pre-Norm RMSNorm [12] 操作。

随后，将所得表示输入带残差连接的面向序列 SwiGLU 前馈网络 (S-FFN)，以进一步增强序列感知模式：

$$\tilde{\mathbf{H}}_{\text{short}}^{\text{feat},(l)} = \text{FFN}_{\text{short}}^{\text{feat},(l)} \left(\mathbf{H}_{\text{short}}^{\text{feat},(l)} \right) + \mathbf{H}_{\text{short}}^{\text{feat},(l)}. \quad (7)$$

类似地，以相同方式处理长期行为序列，得到 $\tilde{\mathbf{H}}_{\text{long}}^{\text{feat},(l)}$ 。值得注意的是，我们采用 S-FFN 分别建模异构行为序列。其核心原因在于，面向序列的交互组件旨在捕获短期、长期和跨域序列等多样化的用户行为信号。引入序列专属建模网络，使 UniFormer 能够在各自独立的潜在空间中更好地捕获异构行为模式，从而实现更细粒度的用户兴趣建模。

最后，为整合从异构行为序列中提取的交互输出，我们提出两种自适应融合策略。1) **全局自适应融合** 学习全局系数 α ，以平衡不同行为序列的相对贡献： $\mathbf{H}_{\text{cross}}^{\text{feat},(l)} = \alpha \tilde{\mathbf{H}}_{\text{short}}^{\text{feat},(l)} + (1-\alpha) \tilde{\mathbf{H}}_{\text{long}}^{\text{feat},(l)}$ ，其中 $\alpha \in [0, 1]$ 是可学习的全局融合系数。2) 考虑到不同用户的短期与长期行为模式存在显著差异，尤其是高活跃用户与冷启动用户之间的差异，我们进一步提出 **个性化自适应融合**。该方法根据用户相关特征（例如，活跃度和交互行为）动态预测用户专属融合系数 α_i ： $\mathbf{H}_{\text{cross}}^{\text{feat},(l)} = \alpha_i \tilde{\mathbf{H}}_{\text{short}}^{\text{feat},(l)} + (1-\alpha_i) \tilde{\mathbf{H}}_{\text{long}}^{\text{feat},(l)}$ 。

面向非序列的交互. 由于面向序列的交互所提取的表示 $\mathbf{H}_{\text{cross}}^{\text{feat},(l)}$ 主要由序列信息主导，因此在充分进行高阶特征交互建模之前，UniFormer 进一步通过引入非序列信息执行 **交互增强**。具体而言，将 $\mathbf{H}_{\text{cross}}^{\text{feat},(l)}$ 与上一层查询 $\mathbf{Q}_{\text{self}}^{\text{feat},(l-1)}$ 拼接，以增强特征交互建模，即 $\mathbf{X}^{\text{feat},(l)} = [\mathbf{H}_{\text{cross}}^{\text{feat},(l)} || \mathbf{Q}_{\text{self}}^{\text{feat},(l-1)}]$ 。具体地， $\mathbf{Q}_{\text{self}}^{\text{feat},(0)} =$

$\mathbf{Q}_{\text{cross}}^{\text{feat},(0)} = \mathbf{N}_{\text{NS}}$ 。随后，将拼接后的张量 $\mathbf{X}^{\text{feat},(l)}$ 输入由自注意力层和前馈层构成的面向非序列交互组件进行交互建模。

具体而言，首先应用带残差连接的自注意力层：

$$\mathbf{H}_{\text{self}}^{\text{feat},(l)} = \text{SA} \left(\text{RMSNorm}(\mathbf{X}^{\text{feat},(l)}) \right) + \mathbf{X}^{\text{feat},(l)}, \quad (8)$$

其中， $\mathbf{H}_{\text{self}}^{\text{feat},(l)} \in \mathbb{R}^{2q \times d_{\text{model}}}$ 。随后，应用一组面向非序列的 SwiGLU 前馈网络 (NS-FFN)，以有效建模特征异构性。具体而言，对于每个切片 $\mathbf{h}_i^{\text{feat},(l)}, i \in \{0, \dots, 2q-1\}$ ，采用特征专属 FFN 来增强交互：

$$\mathbf{f}_i^{\text{feat},(l)} = \text{FFN}_i^{\text{feat},(l)} \left(\mathbf{h}_i^{\text{feat},(l)} \right) + \mathbf{h}_i^{\text{feat},(l)}, \quad (9)$$

由此得到第 l 层 FIM 的输出，记为 $\mathbf{F}^{\text{feat},(l)} \in \mathbb{R}^{2q \times d_{\text{model}}}$ 。随后，根据逐层拆分比例 $\beta^{(l)}$ ，沿特征维度将张量 $\mathbf{F}^{\text{feat},(l)}$ 划分为两个部分，即 $\mathbf{F}^{\text{feat},(l)} = [\mathbf{Q}_{\text{cross}}^{\text{feat},(l+1)} : \mathbf{Q}_{\text{self}}^{\text{feat},(l+1)}]$ ，其中 $\mathbf{Q}_{\text{cross}}^{\text{feat},(l+1)} \in \mathbb{R}^{2q\beta^{(l)} \times d_{\text{model}}}$ ， $\mathbf{Q}_{\text{self}}^{\text{feat},(l+1)} \in \mathbb{R}^{2q(1-\beta^{(l)}) \times d_{\text{model}}}$ 。随后将这两个部分分别输入下一层的交叉注意力层和自注意力层。默认情况下，拆分比例 $\beta^{(l)}$ 设为 0.5。此外，还可采用金字塔式设计，使 $\beta^{(l)}$ 随层数逐渐减小，从而逐步减轻交叉注意力计算并提高效率。

4.3.2 任务空间交互模块. 在特征空间交互模块 (FIM) 于特征空间中完成充分的交互建模后，UniFormer 进一步引入任务空间交互模块 (TIM) 来建模特征-任务关系。与 FIM 类似，TIM 也包含两个组件：用于任务内特征交互的面向特征交互组件，以及用于任务间建模的面向任务交互组件。

面向特征的交互. 为实现任务感知的特征交互，UniFormer 引入交叉注意力层，在 FIM 提取的最终特征空间表示 $\mathbf{F}^{\text{feat},(M)}$ 上执行任务专属交互。具体而言，在第 l 层中，以上一层输出作为查询执行交叉注意力：

$$\mathbf{H}_{\text{cross}}^{\text{task},(l)} = \text{CA} \left(\text{RMSNorm}(\mathbf{Q}_{\text{cross}}^{\text{task},(l-1)}), \mathbf{K}_{\text{feat}}^{(l)}, \mathbf{V}_{\text{feat}}^{(l)} \right) + \mathbf{Q}_{\text{cross}}^{\text{task},(l-1)}, \quad (10)$$

其中， $\mathbf{Q}_{\text{cross}}^{\text{task},(l-1)} \in \mathbb{R}^{t \times d_{\text{model}}}$ 表示查询词元；对于第一层，使用来自词元化模块的任务特征词元作为查询，即 $\mathbf{Q}_{\text{cross}}^{\text{task},(0)} = \mathbf{N}_T \in \mathbb{R}^{t \times d_{\text{model}}}$ 。此外，第一层的 $(\mathbf{K}_{\text{feat}}^{(1)}, \mathbf{V}_{\text{feat}}^{(1)})$ 满足 $\mathbf{K}_{\text{feat}}^{(1)} = \mathbf{V}_{\text{feat}}^{(1)} = \mathbf{F}^{\text{feat},(M)}$ 。与 FIM 类似，TIM 中的交叉注意力层默认也采用惰性设计，在所有层间共享键值表示以提高效率。该设计能够对高阶交互信息 $\mathbf{F}^{\text{feat},(M)}$ 进行任务感知的加权聚合，从而提供类似 MMoE 框架 [19] 的多任务表示。

面向任务的交互. 随后，为捕获任务间交互，UniFormer 引入自注意力层，并在其后接入一组面向任务的 SwiGLU 前馈网络 (T-FFN)，进一步增强任务专属建模能力。

$$\mathbf{H}_{\text{self}}^{\text{task},(l)} = \text{SA} \left(\text{RMSNorm}(\mathbf{H}_{\text{cross}}^{\text{task},(l)}) \right) + \mathbf{H}_{\text{cross}}^{\text{task},(l)}, \quad (11)$$

$$\mathbf{f}_i^{\text{task},(l)} = \text{FFN}_i^{\text{task},(l)} \left(\mathbf{h}_i^{\text{task},(l)} \right) + \mathbf{h}_i^{\text{task},(l)},$$

其中，张量 $\mathbf{h}_i^{\text{task},(l)}, i \in \{0, \dots, t-1\}$ 是 $\mathbf{H}_{\text{self}}^{\text{task},(l)}$ 的切片，第 l 层 TIM 的输出记为 $\mathbf{F}^{\text{task},(l)} \in \mathbb{R}^{t \times d_{\text{model}}}$ ，并作为下一层的查询，即 $\mathbf{Q}_{\text{cross}}^{\text{task},(l+1)} = \mathbf{F}^{\text{task},(l)}$ 。

4.3.3 输出模块. 最后，将第 N 层的输出 $\mathbf{F}^{\text{task},(N)}$ 视为任务专属表示，并输入任务专属 FFN 预测头，再经 Sigmoid 激活生成最终预测：

$$\hat{y}_i = \sigma(\text{FFN}_i \left(\mathbf{f}_i^{\text{task},(N)} \right)). \quad (12)$$

此外, 我们采用覆盖 t 个任务的加权多任务损失来优化 UniFormer:

$$\mathcal{L} = \sum_{i=1}^t \lambda_i \mathcal{L}_i(y_i, \hat{y}_i), \quad (13)$$

其中, y_i 表示第 i 个任务的真实标签, $\mathcal{L}_i$ 为任务专属损失函数, 例如二元交叉熵 (BCE) [27]。

4.4 优化与部署

4.4.1 训练优化. 为提高训练效率和可扩展性, 我们引入了多项系统级优化。

用户级公共压缩. 在推荐场景中, 同一请求或会话内的多个候选物品共享相同的用户侧行为序列。由于行为特征具有多值性且长度较长, 冗余存储和重复处理会带来显著的内存与计算开销。因此, 我们主要对用户侧行为特征应用公共压缩。对于每个唯一用户, 行为特征仅存储和处理一次, 同时使用索引映射将共享表示与对应的物品样本关联。该设计减少了冗余的序列嵌入查找、内存复制和聚合操作。

对于包含来自 U 个不同用户的 B 个样本的批次, 令 $\bar{k} = B/U$ 表示每个用户的平均样本数。令 C_{com} 表示处理用户侧公共特征的开销, C_{sample} 表示处理其余特征的开销。采用用户级公共压缩后, 特征处理开销可从 $B(C_{\text{com}} + C_{\text{sample}})$ 到 $UC_{\text{com}} + BC_{\text{sample}}$ 。因此, 理论加速比为 $\frac{B(C_{\text{com}} + C_{\text{sample}})}{UC_{\text{com}} + BC_{\text{sample}}} = \frac{C_{\text{com}} + C_{\text{sample}}}{C_{\text{sample}} + C_{\text{com}}/\bar{k}}$ 。

变长 FlashAttention. 我们采用变长 FlashAttention 来消除异构用户行为序列中的填充开销。在 UniFormer 中, 经过语义分组的查询词元关注长度不同的行为序列。给定序列长度为 $\{L_i\}_{i=1}^B$, 查询长度为 q 的批次, 带填充的交叉注意力复杂度为 $O(BqL_{\text{max}}d)$, 而变长形式可将其降低至 $O(q \sum_i L_i d)$ 。结合 FlashAttention 的 IO 感知分块 [5] (可避免显式构造完整注意力矩阵), 该优化同时减少了冗余计算和内存传输。

BF16 训练. 此外, 我们部署 BF16 混合精度训练, 以降低内存带宽需求并提高吞吐量。与 FP32 相比, BF16 可将张量存储减半, 并使矩阵密集型算子能够使用低精度 Tensor Core, 同时保持训练所需的足够数值精度。

4.4.2 推理优化. 为降低在线服务延迟和资源开销, 我们也对推理优化策略进行了相应调整。

用户-物品解耦. 在线服务期间, 一个用户请求通常会与 I 个候选物品配对进行排序 (通常为 512 或 1024 个)。得益于精心设计的词元化方案, UniFormer 将非序列特征分解为 m 个物品无关词元和 n 个物品相关词元, 同时聚合物品相关行为序列 (例如, SIM), 以确保交叉注意力中的键值表示与目标物品无关。基于这种分解, 物品无关词元可在每次请求中仅计算一次, 并在所有候选物品之间复用, 从而避免冗余的用户侧计算。

值得注意的是, 在该词元化方案下, FIM 中的交叉注意力层和 FFN 可以自然解耦。然而, 完整自注意力层涉及所有词元之间的交互, 使用用户侧表示依赖候选物品。为解决这一问题, 我们应用注意力掩码, 移除用户侧查询对物品侧键的注意力, 使用户侧注意力计算可在每次请求中仅执行一次并复用。

5 实验

5.1 实验设置

5.1.1 数据集与评估协议. 我们在快手单列短视频推荐平台上评估 UniFormer。该平台是快手最大的推荐场景, 服务超过 4 亿日活跃用户, 每天产生超过 500 亿条交互日志。每个样本由一个 (用户, 视频) 对及其关联的多类型反馈组成, 其中用户侧

行为特征包括短期浏览序列、根据目标物品检索的物品相关长期行为, 以及基于压缩的终身兴趣表征。根据实际部署需求, 我们关注四项关键预测任务: 有效观看、长时观看、点赞和关注。

我们采用 GAUC [36] 评估模型的预测性能, 这是我们短视频服务中最关键的离线指标。GAUC 独立计算每个用户的 AUC, 然后以样本数为权重聚合各用户的结果,

$$\text{GAUC} = \sum_u w_u \cdot \text{AUC}_u, \quad w_u = \frac{\# \text{样本}_u}{\sum_i \# \text{样本}_i}, \quad (14)$$

其中, w_u 表示用户 u 的样本在评估集中的占比。值得注意的是, 海量训练样本带来了较高稳定性, 因此相对 GAUC 提升 0.05% 即被视为高度显著, 并可带来可观的业务影响 [32]。

5.1.2 基线模型. 我们将 UniFormer 与若干具有代表性的强基线进行比较。这些基线涵盖扩展前和可扩展推荐模型, 并同时进行序列建模与特征交互: **SIM+DCN** 是一种经典的扩展前架构, 它将用于超长行为建模的 Search-based Interest Model (SIM) [20] 与用于特征交互的 Deep Cross Network (DCN) [24] 相结合。**SIM+HoME** 将 DCN 组件替换为 HoME [25], 后者是一种用于多任务监督的 Hierarchical-Mask MoE 模块。**SIM+RankMixer** 将 SIM 与 RankMixer [40] 相结合; RankMixer 是一种以组件为中心的扩展模块, 采用参数容量可扩展的 token 混合网络。**HyFormer** [11] 和 **MixFormer** [10] 是跨模块协同扩展方法, 在特征空间内联合扩展行为建模与特征交互建模。

5.1.3 实现细节. 为保证公平比较, 所有模型均在同一 GPU 集群上使用相同的优化设置从头训练。具体而言, 稀疏组件和稠密组件均采用 AdamW [13] 优化, 学习率为 $1e-3$, 权重衰减为 $1e-3$, 每张 GPU 的批量大小为 2048。我们的 UniFormer 默认采用 3 层架构, 隐藏维度 d_{head} 为 1280。

Table 1: 快手工业数据集上的离线 GAUC 结果。提升幅度以第一个基线 SIM+DCN 为参照计算。粗体表示最高分, 下划线表示基线中的最佳结果。最后一列报告稠密神经网络的参数量。

模型	有效观看		长时观看		点赞		关注		参数量
	GAUC	提升	GAUC	提升	GAUC	提升	GAUC	提升	
SIM+DCN	0.7418	-	0.7734	-	0.8486	-	0.8361	-	115.8M
SIM+HoME	0.7424	+0.08%	0.7740	+0.08%	0.8494	+0.09%	0.8374	+0.16%	114.8M
SIM+RankMixer	0.7443	+0.34%	0.7757	+0.30%	0.8507	+0.25%	0.8374	+0.16%	492.0M
HyFormer	0.7447	+0.39%	0.7762	+0.36%	0.8512	+0.31%	0.8381	+0.24%	496.5M
MixFormer	<u>0.7450</u>	<u>+0.43%</u>	<u>0.7764</u>	<u>+0.39%</u>	<u>0.8514</u>	<u>+0.33%</u>	<u>0.8388</u>	<u>+0.32%</u>	489.4M
UniFormer	0.7457	+0.53%	0.7771	+0.48%	0.8531	+0.53%	0.8435	+0.89%	516.0M
UniFormer-Large	0.7465	+0.63%	0.7779	+0.58%	0.8538	+0.61%	0.8448	+1.04%	995.3M

5.2 性能比较

我们与主流工业排序模型进行了实验比较, 结果见表 1。在所有目标上, UniFormer 均稳定优于所有先进基线, 由此得到以下观察。

- **以组件为中心的扩展.** RankMixer 显著优于 DCN 和 HoME, 在有效观看任务上的 GAUC 分别提升 0.34% 和 0.26%, 证明了推荐模型参数扩展的有效性。
- **特征空间内的跨模块协同扩展.** HyFormer 和 MixFormer 通过跨模块协同扩展进一步提升性能, 在统一框架内联合扩展行为建模和特征交互。二者相较 SIM+RankMixer 的显著收益证明了协同扩展的必要性, 表明联合扩展多个组件比以组件为中心的扩展能够带来更大的提升。
- **以模型为中心的协同扩展.** UniFormer 在所有比较方法中取得最佳性能, 相较最强基线 MixFormer 获得显著提升。HyFormer 和 MixFormer 主要关注特征空间扩展, 而 UniFormer




Figure 3: UniFormer 在快手工业数据集的有效观看和点赞任务上的消融研究。




Figure 4: GAUC 增益与模型参数量之间的扩展规律。横轴采用对数刻度。

进一步将任务空间纳入统一建模过程。此外，UniFormer 以模型为中心实现灵活且可扩展的参数分配，使整个模型的参数扩展更加均衡。

- **进一步扩展。** UniFormer-Large 相较 UniFormer 的 GAUC 进一步提升 +0.11%，取得最佳总体性能。这一提升得益于面向不同建模组件定制的多视角 FFN；随着模型容量增加，它们能够实现灵活且可扩展的参数分配。

5.3 消融研究

我们在快手工业数据集上进行消融研究，以验证 UniFormer 各项关键设计的有效性。具体而言，我们考虑以下变体：将多序列交叉注意力替换为共享交叉注意力（w/o Multi-seq CA）、移除交互增强（w/o IE），即 $\mathbf{X}^{\text{feat},(l)} = \mathbf{H}_{\text{cross}}^{\text{feat},(l)}$ ；移除任务空间交互模块（w/o TIM）；将面向序列的前馈网络替换为共享 FFN（w/o S-FFNs）；以及将面向非序列的前馈网络替换为共享 FFN（w/o NS-FFNs）。

如图 3 所示，UniFormer 在所有任务上均稳定优于全部消融变体，证明了模型设计的有效性。前三个变体的结果验证了统一交互块中统一模型设计的优势。通过联合考虑偏好完整性、全面的交互建模和任务相关性，UniFormer 在不同任务上获得了更稳健且一致的提升。值得注意的是，移除多序列交叉注意力会导致性能显著下降，尤其是在交互相关指标（如点赞）上，这证明了防止偏好坍塌的有效性。对于最后两个变体，将 S-FFNs 或 NS-FFNs 替换为共享 FFN 会导致最为明显的性能下降。这一结果证明了我们灵活且可扩展的参数分配设计的有效性，并凸显其对实现均衡、有效的容量扩展至关重要。

5.4 扩展分析

为研究 UniFormer 的容量潜力，我们通过增大多视角 FFN（包括 S-FFNs、NS-FFNs 和 T-FFNs）的隐藏维度开展扩展分析，结果如图 4 所示。




Figure 5: 不同 Token 化方式下的注意力模式可视化。




Figure 6: 特征—任务关系的注意力分布可视化。

从结果可以看出，UniFormer 呈现出明显的扩展规律：模型性能随参数容量增加而持续提升。此外，得益于面向不同建模组件定制的多视角 FFN，UniFormer 能够实现更加均衡且可扩展的参数分配，从而维持更强劲的性能增长趋势。这种以模型为中心的扩展范式有效缓解了传统以组件为中心的扩展中常见的早期边际收益递减规律 [40]。

5.5 可视化分析

5.5.1 语义 Token 化。 为说明语义 Token 化的优势，我们将其与不显式保留语义分组的全局 Token 化 [11, 23] 进行比较。如图 5 所示，在 FIM 中，语义 token 跨层呈现出更加多样且结构化的注意力行为。在不同的交叉注意力层中，语义 token 关注不同的行为模式，使 UniFormer 能够捕获多视角用户偏好。相比之下，全局 token 的注意力模式多样性较低，各层的注意力反复集中于相似位置。总体而言，语义 Token 化能够实现更加专门化且可随层自适应的信息提取，从而缓解全局 Token 化导致的注意力同质化。

5.5.2 特征—任务关系。 为研究 TIM 中特征与任务之间的关系，图 6 可视化了不同任务在特征 token 上的注意力分布。我们观察到，不同任务会根据各自的优化目标，自适应地关注不同的特征来源。某些特征（例如物品基础特征和基于检索的行为特征）在不同任务中始终获得较高的注意力权重，表明它们在多任务预测中发挥着重要作用。与交互任务相比，时长任务对物品统计特征（Tokens 11–14）赋予更高的注意力权重，而交互任务则更强调某些用户特征（Tokens 1–4）。此外，高度相关的任务也呈现出高度一致的注意力分布。例如，评论停留时长与评论率具有非常相似的特征注意力模式，说明 UniFormer 能够通过特征—任务交互捕获任务相关性。

5.6 在线 A/B 测试

5.6.1 在线结果. 为验证 UniFormer 的工业可行性, 我们将其部署在快手及快手极速版 APP 的最大短视频频道上, 开展为期七天的在线 A/B 测试, 并将 5% 的生产流量分配至实验桶。评估指标包括衡量用户参与总时长的 *App* 停留时长和观看时长, 以及点赞、评论等其他用户交互指标。在线 A/B 测试结果见表 2, 结果表明 UniFormer 在用户参与度和交互指标上均取得统计显著的提升。这些结果表明, 我们以模型为中心的协同扩展框架能够在多种在线指标上带来一致提升, 同时有效缓解竞争目标之间的跷跷板效应。

Table 2: 在线 A/B 测试结果。

类别	指标	快手极速版	快手
用户参与	App 停留时长	+0.260%	+0.101%
	观看时长	+1.113%	+0.729%
	视频观看量	+0.252%	+0.249%
用户交互	点赞	+1.089%	+0.155%
	评论	+1.818%	+1.488%
	收藏	+0.930%	+0.647%
	转发	+1.274%	+0.157%

5.6.2 效率分析. 得益于精心设计的 Token 化策略, UniFormer 根据特征对候选物品的依赖性, 将特征空间中的序列特征和非序列特征划分为物品无关组和物品相关组。该设计支持在线服务中的用户—物品解耦, 使物品无关网络每个请求只需计算一次, 并可在多个候选物品间复用, 从而实现请求级推理加速。在我们的生产服务场景中, 每个请求同时为 512 个候选物品打分。采用用户—物品解耦后, UniFormer 的推理 QPS 相较原始版本提升 **48%**, 同时仅产生可忽略的 GAUC 下降。这些结果进一步表明, UniFormer 非常适合工业部署: 它在保持强大效果的同时实现了显著的服务加速。

6 结论

本文倡导工业推荐系统从以组件为中心的扩展向以模型为中心的扩展进行范式转变, 并系统讨论了构建高效统一扩展框架所面临的关键挑战。为此, 我们提出 **UniFormer**, 它融合特征空间交互模块 (FIM) 与任务空间交互模块 (TIM), 以联合扩展特征建模和任务建模。借助标准化注意力算子和多视角 FFN, UniFormer 在增强建模能力的同时, 实现了跨不同组件的灵活、可扩展参数分配。快手工业推荐场景中的大量离线实验和在线 A/B 测试验证了 UniFormer 的有效性与实际价值, 并表明以模型为中心的协同扩展是工业推荐系统扩展的一条有前景的方向。

参考文献

- [1] Zheng Chai, Qin Ren, Xijun Xiao, Huizhi Yang, Bo Han, Sijun Zhang, Di Chen, Hui Lu, Wenlin Zhao, Lele Yu, et al. 2025. Longer: Scaling up long sequence modeling in industrial recommenders. In *Proceedings of the Nineteenth ACM Conference on Recommender Systems*. 247–256.
- [2] Jianxin Chang, Chenbin Zhang, Zhiyi Fu, Xiaoxue Zang, Lin Guan, Jing Lu, Yiqun Hui, Dewei Leng, Yanan Niu, Yang Song, et al. 2023. TWIN: Two-stage interest network for lifelong user behavior modeling in CTR prediction at kuaishou. In *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. 3785–3794.
- [3] Bo Chen, Yichao Wang, Zhirong Liu, Ruiming Tang, Wei Guo, Hongkun Zheng, Weiwei Yao, Muyu Zhang, and Xiuqiang He. 2021. Enhancing explicit and implicit feature interactions via information sharing for parallel deep CTR models. In *Proceedings of the 30th ACM international conference on information & knowledge management*. 3757–3766.
- [4] Zhimin Chen, Chenyu Zhao, Ka Chun Mo, Yunjiang Jiang, Jane H Lee, Khush-hall Chandra Mahajan, Ning Jiang, Kai Ren, Jinhui Li, and Wen-Yun Yang. 2025. Massive memorization with hundreds of trillions of parameters for sequential transducer generative recommenders. *arXiv preprint arXiv:2510.22049* (2025).
- [5] Tri Dao, Dan Fu, Stefano Ermon, Atri Rudra, and Christopher Ré. 2022. Flashattention: Fast and memory-efficient exact attention with io-awareness. *Advances in neural information processing systems* 35 (2022), 16344–16359.
- [6] Lin Guan, Jia-Qi Yang, Zhishan Zhao, Beichuan Zhang, Bo Sun, Xuanyuan Luo, Jinan Ni, Xiaowen Li, Yuhang Qi, Zhifang Fan, et al. 2026. Make it long, keep it fast: End-to-end 10k-sequence modeling at billion scale on Douyin. In *Proceedings of the ACM Web Conference 2026*. 7989–7998.
- [7] Huifeng Guo, Bo Chen, Ruiming Tang, Weinan Zhang, Zhenguo Li, and Xiuqiang He. 2021. An embedding learning framework for numerical features in ctr prediction. In *Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining*. 2910–2918.
- [8] Huifeng Guo, Ruiming Tang, Yunming Ye, Zhenguo Li, and Xiuqiang He. 2017. DeepFM: a factorization-machine based neural network for CTR prediction. *arXiv preprint arXiv:1703.04247* (2017).
- [9] Ruidong Han, Bin Yin, Shangyu Chen, He Jiang, Fei Jiang, Xiang Li, Chi Ma, Mincong Huang, Xiaoguang Li, Chunzhen Jing, et al. 2025. Mitgr: Industrial-scale generative recommendation framework in meituan. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management*. 5731–5738.
- [10] Xu Huang, Hao Zhang, Zhifang Fan, Yunwen Huang, Zhuoxing Wei, Zheng Chai, Jinan Ni, Yuchao Zheng, and Qiwei Chen. 2026. MixFormer: Co-Scaling Up Dense and Sequence in Industrial Recommenders. *arXiv preprint arXiv:2602.14110* (2026).
- [11] Yunwen Huang, Shiyong Hong, Xijun Xiao, Jinqiu Jin, Xuanyuan Luo, Zhe Wang, Zheng Chai, Shikang Wu, Yuchao Zheng, and Jingjian Lin. 2026. HyFormer: Revisiting the Roles of Sequence Modeling and Feature Interaction in CTR Prediction. *arXiv preprint arXiv:2601.12681* (2026).
- [12] Yuchen Jiang, Jie Zhu, Xintian Han, Hui Lu, Kunmin Bai, Mingyu Yang, Shikang Wu, Ruihao Zhang, Wenlin Zhao, Shipeng Bai, et al. 2026. TokenMixer-Large: Scaling Up Large Ranking Models in Industrial Recommenders. *arXiv preprint arXiv:2602.06563* (2026).
- [13] Diederik P Kingma and Jimmy Ba. 2014. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980* (2014).
- [14] Xiangyang Li, Bo Chen, HuiFeng Guo, Jingjie Li, Chenxu Zhu, Xiang Long, Sujian Li, Yichao Wang, Wei Guo, Longxia Mao, et al. 2022. Inttower: the next generation of two-tower model for pre-ranking system. In *Proceedings of the 31st ACM International Conference on Information & Knowledge Management*. 3292–3301.
- [15] Xiangyang Li, Bo Chen, Lu Hou, and Ruiming Tang. 2025. Ctrl: Connect collaborative and language model for ctr prediction. *ACM Transactions on Recommender Systems* 4, 2 (2025), 1–23.
- [16] Xiaopeng Li, Bo Chen, Junda She, Shiteng Cao, You Wang, Qinlin Jia, Haiying He, Zheli Zhou, Zhao Liu, Ji Liu, et al. 2025. A survey of generative recommendation from a tri-decoupled perspective: Tokenization, architecture, and optimization. (2025).
- [17] Aixin Liu, Bei Feng, Bing Xue, Bingxuan Wang, Bochao Wu, Chengda Lu, Cheng-gang Zhao, Chengqi Deng, Chenyu Zhang, Chong Ruan, et al. 2024. Deepseek-v3 technical report. *arXiv preprint arXiv:2412.19437* (2024).
- [18] Mingyang Liu, Yong Bai, Zhangming Chan, Sishuo Chen, Xiang-Rong Sheng, Han Zhu, Jian Xu, and Xinyang Chen. 2026. EST: Towards Efficient Scaling Laws in Click-Through Rate Prediction via Unified Modeling. *arXiv preprint arXiv:2602.10811* (2026).
- [19] Jiaqi Ma, Zhe Zhao, Xinyang Yi, Jilin Chen, Lichan Hong, and Ed H Chi. 2018. Modeling task relationships in multi-task learning with multi-gate mixture-of-experts. In *Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining*. 1930–1939.
- [20] Qi Pi, Guorui Zhou, Yujing Zhang, Zhe Wang, Lejian Ren, Ying Fan, Xiaoqiang Zhu, and Kun Gai. 2020. Search-based user interest modeling with lifelong sequential behavior data for click-through rate prediction. In *Proceedings of the 29th ACM International Conference on Information & Knowledge Management*. 2685–2692.
- [21] Liangcai Su, Junwei Pan, Ximei Wang, Xi Xiao, Shijie Quan, Xihua Chen, and Jie Jiang. 2024. STEM: unleashing the power of embeddings for multi-task recommendation. In *Proceedings of the AAAI conference on artificial intelligence*, Vol. 38. 9002–9010.
- [22] Hongyan Tang, Junning Liu, Ming Zhao, and Xudong Gong. 2020. Progressive layered extraction (ple): A novel multi-task learning (mtl) model for personalized recommendations. In *Proceedings of the 14th ACM conference on recommender systems*. 269–278.
- [23] Fangye Wang, Guowei Yang, Xiaojiang Zhou, Song Yang, and Pengjie Wang. 2026. Query-Mixed Interest Extraction and Heterogeneous Interaction: A Scalable CTR Model for Industrial Recommender Systems. *arXiv preprint arXiv:2602.09387* (2026).

- [24] Ruoxi Wang, Bin Fu, Gang Fu, and Mingliang Wang. 2017. Deep & cross network for ad click predictions. In *Proceedings of the ADKDD'17*. 1–7.
- [25] Xu Wang, Jiangxia Cao, Zhiyi Fu, Kun Gai, and Guorui Zhou. 2025. Home: Hierarchy of multi-gate experts for multi-task learning at kuaishou. In *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V. 1*. 2638–2647.
- [26] Xingmei Wang, Shiyao Wang, Wuchao Li, Jiaxin Deng, Song Lu, Defu Lian, and Guorui Zhou. 2025. Transformers are Good Clusterers for Lifelong User Behavior Sequence Modeling. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management*. 3123–3132.
- [27] Yuhao Wang, Ha Tsz Lam, Yi Wong, Ziru Liu, Xiangyu Zhao, Yichao Wang, Bo Chen, Huifeng Guo, and Ruiming Tang. 2023. Multi-task deep recommender systems: A survey. *arXiv preprint arXiv:2302.03525* (2023).
- [28] Dezhi Yi, Bo Chen, Ye Lu, Hang Liu, Suqi Shi, Yangsen Liu, Wei Guo, Kenan Song, Huifeng Guo, Yong Liu, et al. 2026. EENet: An Efficient and Effective Network for Large-Scale CTR Prediction. *ACM Transactions on Information Systems* 44, 4 (2026), 1–31.
- [29] Liren Yu, Wenming Zhang, Silu Zhou, Tao Zhang, Zhixuan Zhang, and Dan Ou. 2025. HHFT: Hierarchical Heterogeneous Feature Transformer for Recommendation Systems. *arXiv preprint arXiv:2511.20235* (2025).
- [30] Jiaqi Zhai, Lucy Liao, Xing Liu, Yueming Wang, Rui Li, Xuan Cao, Leon Gao, Zhaojie Gong, Fangda Gu, Michael He, et al. 2024. Actions speak louder than words: Trillion-parameter sequential transducers for generative recommendations. *arXiv preprint arXiv:2402.17152* (2024).
- [31] Buyun Zhang, Liang Luo, Yuxin Chen, Jade Nie, Xi Liu, Daifeng Guo, Yanli Zhao, Shen Li, Yuchen Hao, Yantao Yao, et al. 2024. Wukong: Towards a scaling law for large-scale recommendation. *arXiv preprint arXiv:2403.02545* (2024).
- [32] Yukun Zhang, Si Dong, Xu Wang, Bo Chen, Qinglin Jia, Shengzhe Wang, Jinlong Jiao, Runhan Li, Jiaqing Liu, Chaoyi Ma, et al. 2026. SMES: Towards Scalable Multi-Task Recommendation via Expert Sparsity. *arXiv preprint arXiv:2602.09386* (2026).
- [33] Zhaoqi Zhang, Haolei Pei, Jun Guo, Tianyu Wang, Yufei Feng, Hui Sun, Shaowei Liu, and Aixin Sun. 2026. Onetrans: Unified feature interaction and sequence modeling with one transformer in industrial recommender. In *Proceedings of the ACM Web Conference 2026*. 8162–8170.
- [34] Guorui Zhou, Hengrui Hu, Hongtao Cheng, Huanjie Wang, Jiaxin Deng, Jinghao Zhang, Kuo Cai, Lejian Ren, Lu Ren, Liao Yu, et al. 2025. Onerec-v2 technical report. *arXiv preprint arXiv:2508.20900* (2025).
- [35] Guorui Zhou, Na Mou, Ying Fan, Qi Pi, Weijie Bian, Chang Zhou, Xiaoqiang Zhu, and Kun Gai. 2019. Deep interest evolution network for click-through rate prediction. In *Proceedings of the AAAI conference on artificial intelligence*, Vol. 33. 5941–5948.
- [36] Guorui Zhou, Xiaoqiang Zhu, Chenru Song, Ying Fan, Han Zhu, Xiao Ma, Yanghui Yan, Junqi Jin, Han Li, and Kun Gai. 2018. Deep interest network for click-through rate prediction. In *Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining*. 1059–1068.
- [37] Rui Zhou, Qinglin Jia, Bo Chen, Peng Xu, Yijia Sun, Siyuan Lou, Chaoxin Fu, Mengyuan Fu, Guoming Shen, Zheli Zhou, et al. 2026. A Survey of User Lifelong Behavior Modeling: Perspectives on Efficiency and Effectiveness. (2026).
- [38] Yu Zhou, Chengcheng Guo, Kuo Cai, Ji Liu, Qiang Luo, Ruiming Tang, Han Li, Kun Gai, and Guorui Zhou. 2026. GEMs: Breaking the Long-Sequence Barrier in Generative Recommendation with a Multi-Stream Decoder. *arXiv preprint arXiv:2602.13631* (2026).
- [39] Yifeng Zhou, Yuehong Hu, Zhixiang Feng, Junwei Pan, Kaihui Wu, Hanyong Li, Shangyu Zhang, Shudong Huang, Zhangbin Zhu, Chengguo Yin, et al. 2026. TokenFormer: Unify the Multi-Field and Sequential Recommendation Worlds. *arXiv preprint arXiv:2604.13737* (2026).
- [40] Jie Zhu, Zhifang Fan, Xiaoxie Zhu, Yuchen Jiang, Hangyu Wang, Xintian Han, Haoran Ding, Xinmin Wang, Wenlin Zhao, Zhen Gong, et al. 2025. Rankmixer: Scaling up ranking models in industrial recommenders. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management*. 6309–6316.